



Universität Hamburg
DER FORSCHUNG | DER LEHRE | DER BILDUNG

B A C H E L O R A R B E I T

Entrauschung von EKG-Signalen mittels der diskreten Wavelet-Transformation

ausgeführt am

Fachbereich Mathematik
Fakultät für Mathematik, Informatik und Naturwissenschaften
Universität Hamburg

unter der Anleitung von

Name des Betreuers

durch

Hilda Beuting

Matrikelnummer: 12345678

Straße und Hausnummer

PLZ und Ort

Hamburg, am Datum

Inhaltsverzeichnis

1. Einleitung	1
1.1. Motivation: EKG-Signale und ihre Störquellen	1
1.2. Warum die Fourier-Analyse nicht genügt	1
1.3. Zielsetzung und Abgrenzung	2
1.4. Aufbau der Arbeit	2
2. Funktionalanalytische Grundlagen	3
2.1. Der Hilbertraum $L^2(\mathbb{R})$	3
2.2. Orthonormalbasen und ihre Charakterisierung	3
2.3. Unitäre Operatoren	4
2.4. Fourier-Transformation und Satz von Plancherel	4
2.5. Die gefensterter Fourier-Transformation	5
2.6. Grundbegriffe der Wahrscheinlichkeitsrechnung	5
3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse	6
3.1. Die kontinuierliche Wavelet-Transformation	6
3.1.1. Wavelets und die Zulässigkeitsbedingung	7
3.1.2. Die Wavelet-Familie und die Transformation	9
3.1.3. Die Plancherel-Formel	13
3.2. Das dyadische Gitter und die Multiskalenanalyse	16
3.2.1. Die Axiome	17
3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j	19
3.3.1. Die Orthonormalbasis auf allen Skalen	20
3.3.2. Die Approximationsoperatoren	20
3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$	21
3.4.1. Die Wavelet-Basis	22
4. Konstruktion der diskreten Wavelet-Transformation	24
4.1. Die Skalierungsgleichung	24
4.2. Filterkoeffizienten: Tiefpass und Hochpass	25
4.3. Bedingungen im Fourier-Bereich	27
4.4. Der Mallat-Algorithmus	28
4.5. Daubechies-Wavelets	30
5. Entrauschung durch Thresholding	34
5.1. Rauschmodell und diskrete Wavelet-Transformation	34
5.2. Diagonale Schätzer und Thresholding	37
5.3. Die Wahl der Schwelle	42
5.4. Schätzung der Rauschstärke	44

6. Anwendung: Entrauschung von EKG-Signalen	47
6.1. EKG-Signale: Morphologie und Störquellen	47
6.1.1. Der Herzzyklus: P-Welle, QRS-Komplex, T-Welle	47
6.1.2. Typische Störquellen	47
6.2. Bewertungsmaße und das Problem der fehlenden Referenz	48
6.3. Stufe 1: Synthetisch konstruiertes EKG-Signal	49
6.3.1. Konstruktion des Modellsignals	49
6.3.2. Rauschmodell und Wahl der Parameter	49
6.3.3. Wahl von Wavelet und Zerlegungstiefe	49
6.3.4. Vergleich von Hard- und Soft-Thresholding	49
6.3.5. Ergebnisse	49
6.4. Stufe 2: Reale Signale aus der MIT-BIH-Datenbank	50
6.4.1. Beschreibung des Datensatzes	50
6.4.2. Validierung ohne sauberes Referenzsignal	50
6.4.3. Ergebnisse	50
6.5. Diskussion	50
7. Fazit und Ausblick	52
A. Ergänzende Rechnungen	53
A.1. Fourier-Transformierte des Testsignals	53
A.2. Stammfunktion des Testsignals	54
B. Python-Code	55
B.1. Beispiel zur kontinuierlichen Wavelet-Transformation	55
B.2. Daubechies-Wavelet	57
B.3. Verrauschter Sinus	57
B.4. Sinus mit Spitzen	58
B.5. Detailkoeffizienten des Testsignals	59
B.6. Detailkoeffizienten der Messwerte	60
B.7. Entraushtes Testsignal	61
Literaturverzeichnis	63

1. Einleitung

Anmerkung. Einleitung ganz zum Schluss schreiben. Laut Vorlage muss hier stehen: (a) Worum geht es, (b) Einordnung ins Forschungsfeld, (c) Fragestellung, (d) Relevanz, (e) vorhandene Literatur, (f) EIGENER ANTEIL der Arbeit, (g) grober Aufbau der Arbeit.

1.1. Motivation: EKG-Signale und ihre Störquellen

Anmerkung. EKG-Signale und ihre Störquellen Das EKG ist ein nichtstationäres biomedizinisches Signal, dessen diagnostisch entscheidende Strukturen von Störungen überlagert werden, die im selben Frequenzband liegen wie das Nutzsignal — womit einfache Frequenzfilter ausscheiden.

Anmerkung. hier schon kurzer aufbau ekg signal kurzer qrskomplex und langer t p welle...

Belegstellen.

- LMR, Kap. 3.1.2 „EKG-Analyse“, S. 238–240 [bestätigt] — Herzklappenrhythmus und „late potentials“ als diagnostische Fragestellungen; Abb. 3.1 (S. 239)
- Gacek, Kap. 2.1, S. 21–22 [bestätigt] — diagnostische Bedeutung, historische Einordnung
- Gacek, Kap. 2.3, S. 25–27 [bestätigt] — Störquellen im Überblick
- Chatterjee, Kap. 1.1 „Predominant noises in ECG“, S. 570 [bestätigt]
- Aqil, Kap. 2, S. 53–54 [bestätigt] — Fig. 3, Rauschtypen
- Rebstadt, Kap. 2.1, S. 7–11 [bestätigt] — Abb. 2.3 (S. 10)

1.2. Warum die Fourier-Analyse nicht genügt

Anmerkung. VERSCHOBEN aus dem alten Abschnitt 2.5. Begründung: In Kapitel 2 war das ein Fremdkörper – dort werden Werkzeuge bereitgestellt, hier wird die Fragestellung motiviert. Der Abschnitt liefert genau das Argument, das die ganze Arbeit trägt: Die Fourier-Basis sagt, *welche* Frequenzen auftreten, nicht *wann*.

Anmerkung. Die Fourier-Basis ist global; sie sagt welche Frequenzen auftreten, nicht wann — bei einem QRS-Komplex ist genau die Lokalisierung entscheidend.

Belegstellen.

- LMR, Kap. 1.3.2 „Wavelet-Transformation und gefensterte Fourier-Transformation“, S. 36–37 [bestätigt] — direkter Vergleich beider Transformationen, in der 2. Auflage eigens dafür neu aufgenommen

1. Einleitung

- LMR, Kap. 1.3.1 „Phasenraumdarstellung“, S. 30–35 [bestätigt]
- LMR, Vorwort zur ersten Auflage, S. 3 [bestätigt] — fehlende Lokalisierungseigenschaft der Fourier-Transformation, prägnant formuliert
- Blatter, Kap. 1.4, S. 10–12 [bestätigt]; Kap. 2.3 „Heisenbergsche Unschärferelation“, S. 43–46 [bestätigt]
- SteinShakarchi, Kap. 5.4, S. 158–160 [bestätigt]
- HankeBourgeois, Beispiel 52.7 mit Abbildung 52.1, S. 403–404 [bestätigt] — reales EKG-Signal mit $N = 2048$ Meßwerten und seinen Bestapproximationen aus T_8 und T_{32} ; die scharfen Peaks werden mit sinkendem Polynomgrad ausgeglättet, t_8 „übersieht“ das Minimum am ca. 200. Datenpunkt
- HankeBourgeois, S. 433–434 [bestätigt] — quantitativ: die Fourierkoeffizienten von $\chi_{[a,b]}$ fallen nur wie $1/k$, der L^2 -Fehler nach n Termen ist $\sim n^{-1/2}$; „schlechte Lokalisierungseigenschaft bezüglich der Ortsvariablen“
- HankeBourgeois, Beispiel 56.3 mit Abbildung 56.2, S. 440 [bestätigt] — Fourier- vs. Waveletkoeffizienten desselben EKG-Signals in logarithmischer Skala
- Rebstadt, Abb. 2.7, S. 22 [bestätigt]
- Fußnote S. 404: Die EKG-Daten stammen laut HankeBourgeois von Prof. Dr. P. Maaß, Universität Bremen — demselben Maaß wie in Louis/Maaß/Rieder. Deine beiden deutschsprachigen Quellen arbeiten am selben Signal.

1.3. Zielsetzung und Abgrenzung

Anmerkung. Ziel ist die mathematisch vollständige Herleitung der DWT-Entrauschung; Abgrenzung gegenüber konkurrierenden Verfahren, die nur benannt werden.

Belegstellen.

- LMR, Vorwort zur ersten Auflage, S. 3–4 [bestätigt] — Verzahnung von Theorie und Anwendung als Programm
- Chatterjee, Kap. 2–4, S. 571–581
- Rebstadt, Kap. 2.3, S. 14–31 [bestätigt]

1.4. Aufbau der Arbeit

2. Funktionalanalytische Grundlagen

Anmerkung. Block A. Kapiteleinleitung: Ziel ist der funktionalanalytische Rahmen, in dem die Wavelet-Transformation als unitäre Abbildung erscheint.

2.1. Der Hilbertraum $L^2(\mathbb{R})$

Anmerkung. Einführung von $L^2(\mathbb{R})$ als vollständigem Raum mit Skalarprodukt — dem Raum, in dem sämtliche Signale und Wavelets im Folgenden leben.

Belegstellen.

- Serov, Kap. 25, S. 249–253 [bestätigt] (Def. 25.1 Skalarprodukt, Def. 25.7 Hilbertraum)
- Blatter, Kap. 2.1, S. 26–27 [bestätigt]
- LMR, „Notationen“, S. 9–12 [bestätigt] — Räume L^p , C^∞ , $S(\mathbb{R})$, $S'(\mathbb{R})$ in genau der Notation, die LMR durchgehend verwendet

2.2. Orthonormalbasen und ihre Charakterisierung

Anmerkung. Der zentrale Satz: Vollständigkeit, Parseval-Gleichung und die Entwicklung jedes Elements sind für ein Orthonormalsystem äquivalent.

Belegstellen.

- Serov, Satz 25.18 „Characterization of an orthonormal basis“, S. 258 [bestätigt]
- Serov, Def. 25.16–25.17, S. 257–258 [bestätigt]
- Serov, Satz 25.12 (Projektionssatz), S. 254–255 [geschätzt]
- Blatter, Kap. 2.1, S. 27 [bestätigt]
- HankeBourgeois, Satz 31.6, S. 281 [bestätigt] — (a) Entwicklung, (b) Satz des Pythagoras, (c) Bestapproximation, (d) Besselsche Ungleichung, mit Beweis
- HankeBourgeois, §31 „Innenprodukträume, Orthonormalbasen und Gramsche Matrizen“, S. 275–282 [bestätigt]; Definition von $L\omega$, S. 279–280 [geschätzt]

2.3. Unitäre Operatoren

Anmerkung. Ein unitärer Operator ist eine surjektive Isometrie; er erhält Skalarprodukte und damit Energie — der Grund, warum Rauschen unter der DWT seine Statistik behält.

Belegstellen.

- Serov, Def. 27.7 und Bem. 27.8, S. 282 [bestätigt] (Sachverz.: „unitary operator, 282“)
- LMR, Kap. 1.2 „Affine Operatoren“, S. 26–29 [bestätigt] — Dilatationsoperator D_a , Translationsoperator T_b , beide Isometrien mit Bild ganz L^2 , daher Adjungierte = Inverse
- LMR, Lemma 1.2.1 (adjungierte affine Operatoren), S. 27 [bestätigt]
- LMR, S. 27 [bestätigt] — affin-lineare Gruppe $G_{a,f}$ und Verknüpfungsgesetz $T_{b'}D_{a'}T_bD_a = T_{b'+a'b}D_{aa'}$

2.4. Fourier-Transformation und Satz von Plancherel

Anmerkung. Die Fourier-Transformation setzt sich von der Schwartz-Klasse eindeutig zu einem unitären Isomorphismus auf $L^2(\mathbb{R})$ fort.

Belegstellen.

- Serov, Satz 17.5 (Plancherel), S. 145 [bestätigt]
- Serov, Kap. 16–17, S. 133–152 [bestätigt]
- SteinShakarchi, Kap. 5.1, S. 131–144 [bestätigt]
- Blatter, Kap. 2.2, S. 31–42 [bestätigt]; Plancherel-Formel S. 36 [bestätigt]
- LMR, Anhang „Fourier-Transformation“, S. 313–316 [bestätigt] — kompakte Zusammenstellung genau der Regeln, die LMR im Waveletteil benutzt

Bemerkung 2.1 (Fourier-Konvention). In dieser Arbeit wird durchgehend die unitäre Normierung

$$\hat{f}(\omega) = (2\pi)^{-1/2} \int_{\mathbb{R}} f(t) e^{-i\omega t} dt$$

verwendet. Mit ihr ist die Fourier-Transformation ein unitärer Operator auf $L^2(\mathbb{R})$, und die Plancherel-Formel gilt ohne Vorfaktor: $\langle f, g \rangle = \langle \hat{f}, \hat{g} \rangle$.

Die Literatur normiert uneinheitlich, und die Konstanten der folgenden Kapitel hängen von der Wahl ab: Der Faktor 2π in der Zulässigkeitsbedingung (3.1) und der Wert $|\hat{\varphi}(0)| = (2\pi)^{-1/2}$ in Abschnitt 4.1 gelten nur für diese Normierung. Beim Vergleich mit einer Quelle ist deshalb zuerst deren Konvention nachzusehen.

Anmerkung. das vll besser erst später

2.5. Die gefensterterte Fourier-Transformation

Anmerkung. Hierher gehört die quantitative Begründung der festen Fensterbreite: Heisenbergsche Unschärferelation, Zeit-Bandbreite-Produkt. Abschnitt 3.1 verweist darauf. Belege: Blatter, Kap. 2.3, S. 43–46 [bestätigt]; LMR, Kap. 1.3.1, S. 30–35 [bestätigt].

2.6. Grundbegriffe der Wahrscheinlichkeitsrechnung

In Kapitel 5 wird das Rauschen in einem Messsignal als zufällig modelliert. Dafür genügen die folgenden Begriffe [Mal09, Anhang A.6]. Ein Zufallsvektor $X = (X_0, \dots, X_{N-1})$ besteht aus N Zufallsvariablen X_n . Hat eine Zufallsvariable X die Wahrscheinlichkeitsdichte p , so heißen

$$\mathbb{E}[X] = \int_{\mathbb{R}} x p(x) dx \quad \text{und} \quad \text{Var}(X) = \mathbb{E}[|X - \mathbb{E}[X]|^2]$$

ihr Erwartungswert und ihre Varianz; die Kovarianz zweier Zufallsvariablen ist

$$\text{Cov}(X_1, X_2) = \mathbb{E}[(X_1 - \mathbb{E}[X_1])(X_2 - \mathbb{E}[X_2])].$$

Ist $\text{Cov}(X_1, X_2) = 0$, so heißen X_1 und X_2 unkorreliert. Der Erwartungswert ist linear. Mit $\mathbb{P}$ bezeichnen wir Wahrscheinlichkeiten.

Definition 2.2 (Normalverteilung, vgl. [Mal09, Kap. 11.2.2]). Sei $\phi(x) = (2\pi)^{-1/2} e^{-x^2/2}$ die Gauß'sche Dichte. Eine Zufallsvariable X heißt normalverteilt mit Erwartungswert μ und Varianz $\sigma^2 > 0$, kurz $X \sim \mathcal{N}(\mu, \sigma^2)$, wenn sie die Dichte $p(x) = \sigma^{-1} \phi((x - \mu)/\sigma)$ hat, und standardnormalverteilt im Fall $\mu = 0, \sigma = 1$.

Gemeinsam normalverteilt heißen Zufallsvariablen, die zusammen einen Gauß'schen Zufallsvektor bilden. Für sie gilt:

Satz 2.3 ([Mal09, Kap. 11.1.1]). *Gemeinsam normalverteilte Zufallsvariablen, die paarweise unkorreliert sind, sind unabhängig.*

3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse

Anmerkung. Die kontinuierliche Wavelet-Transformation wird in diesem Kapitel nur so weit entwickelt, dass sichtbar wird, warum man sie diskretisieren muss. Zielpunkt des Kapitels ist die Multiskalenanalyse.

3.1. Die kontinuierliche Wavelet-Transformation

Die Darstellung dieses Abschnitts folgt im Wesentlichen [Bla03, Kap. 3.1–3.3]; ergänzend, insbesondere zum Abklingverhalten und zu den Approximationseigenschaften, wird [LMR98, Kap. 1.1] herangezogen. Es gilt durchgehend die Fourier-Konvention aus Bemerkung 2.1.

Die in Kapitel 2 entwickelte Fourier-Transformation zerlegt ein Signal in reine Schwingungen $e^{i\omega t}$ und misst mit $\hat{f}(\omega)$, wie stark jede Frequenz ω darin vertreten ist. Sie liefert damit welche Frequenzen vorkommen und in welcher Stärke – nicht aber, an welcher Stelle des Signals.

Für ein EKG-Signal ist das eine ungünstige Ausgangslage. Der QRS-Komplex ist zeitlich kurz und damit breitbandig, das heißt, seine Energie verteilt sich über einen weiten Frequenzbereich; P- und T-Welle sind zeitlich ausgedehnt und schmalbandig, ihre Energie konzentriert sich auf wenige tiefe Frequenzen [Reb21, Kap. 2.3.1]. Eine geeignete Analyse muss beide Anteile gleichzeitig auflösen können.

Die Fourier-Transformation kann das prinzipiell nicht leisten: Ihre Analysefunktionen $e^{i\omega t}$ haben auf ganz $\mathbb{R}$ konstanten Betrag, sie zerlegt also ausschließlich entlang der Frequenzachse [LMR98, Bem. 1.3.4]. Der zeitlich kurze QRS-Komplex wird dabei über das gesamte Spektrum verschmiert und liegt in keinem einzelnen Koeffizienten von den gleichzeitig vorhandenen Anteilen der P- und T-Welle getrennt vor [Bla03, Kap. 1.2–1.3]. Da die in Kapitel 5 betrachteten Schwellenwertverfahren koeffizientenweise arbeiten, trifft ein Eingriff, der Rauschen bei einer Frequenz entfernt, damit unvermeidlich das Signal zu allen Zeitpunkten.

Die in Abschnitt 2.5 beschriebene gefensterte Fourier-Transformation löst dieses Problem nur teilweise. Sie betrachtet nicht mehr das ganze Signal auf einmal, sondern schneidet mit einem Fenster jeweils einen Ausschnitt heraus und bestimmt dessen Frequenzgehalt. Damit ist bekannt, wann welche Frequenzen auftreten – allerdings nur so genau, wie das Fenster breit ist. Da diese Breite für alle Frequenzen dieselbe ist, muss man sich von vornherein festlegen: Ein Fenster, das schmal genug ist, um den QRS-Komplex zu isolieren, enthält zu wenige Perioden der T-Welle, um deren niedrige Frequenzanteile aufzulösen – und umgekehrt. Dass sich Zeit- und Frequenzauflösung dabei nicht gleichzeitig beliebig verbessern lassen, ist der Gehalt der Heisenbergschen Unschärferelation (Abschnitt 2.5); vgl. [Bla03, Kap. 2.3] und [LMR98, Kap. 1.3.1].

Anmerkung. wenn heisenbergunschärfe geschrieben dann richtigen verweis einfügen...

Die Wavelet-Transformation macht die Fensterbreite deshalb von der Frequenz abhängig, statt sie fest zu wählen. Hohe Frequenzen werden mit kurzen, tiefe mit langen Fenstern untersucht – schnelle Vorgänge also zeitlich genau, langsame dafür in der Frequenz genau [LMR98, Kap. 1.3.2].

Abbildung 3.1 stellt die Zeit-Frequenz-Auflösung der drei Transformationen einander gegenüber. Jede Kachel steht darin für die kleinste Zelle der Zeit-Frequenz-Ebene, die von der jeweiligen Transformation noch getrennt aufgelöst wird.




Abbildung 3.1.: Zeit-Frequenz-Auflösung im Vergleich. Jede Kachel steht für die kleinste Zelle, die von der jeweiligen Transformation noch getrennt aufgelöst wird. Alle Kacheln besitzen denselben Flächeninhalt; die Transformationen unterscheiden sich allein in deren Zuschnitt. In Anlehnung an [BK19, Figure 2.23].

Die drei Bilder lassen sich nacheinander lesen. In (a) ist jede Kachel so breit wie das ganze Signal: Die Frequenz wird so genau bestimmt, wie es die Signallänge zulässt, ihr Zeitpunkt überhaupt nicht. In (b) zerfällt die Ebene in ein gleichmäßiges Raster; Zeit- und Frequenzauflösung sind nun beide endlich, aber auf allen Frequenzen dieselbe – die Kachelform wird mit dem Fenster einmal festgelegt und gilt überall. In (c) ändert sie sich dagegen mit der Höhe: Oben, bei hohen Frequenzen, sind die Kacheln schmal und hoch, unten breit und flach.

Entscheidend ist, dass der Flächeninhalt dabei konstant bleibt. Auflösung lässt sich nicht gewinnen, sondern nur umverteilen; die Wavelet-Transformation verteilt sie dorthin, wo ein EKG sie braucht – Zeitauflösung beim kurzen, hochfrequenten QRS-Komplex, Frequenzauflösung bei der langen, tieffrequenten T-Welle.

Damit ist geklärt, welche Eigenschaft die Wavelet-Transformation von den beiden zuvor betrachteten Verfahren unterscheidet. Zwei Fragen bleiben offen: Welche Funktionen ψ sind überhaupt als Wavelet zugelassen, und wie ist die Transformation genau definiert? Die erste beantwortet der folgende Abschnitt, die zweite Abschnitt 3.1.2.

3.1.1. Wavelets und die Zulässigkeitsbedingung

Ausgangspunkt ist eine einzige Funktion ψ , aus der die gesamte Wavelet-Familie durch Skalierung und Verschiebung hervorgeht. An ψ ist eine Integralbedingung zu stellen; ihre Tragweite wird erst in Satz 3.10 vollständig sichtbar, wo sie sich als genau diejenige Bedingung erweist, unter

der die Transformation umkehrbar ist.

Anmerkung. davor auf jeden fall l2 norm definieren

Definition 3.1 (Wavelet, [Bla03, Kap. 3.1, Bedingungen (1) und (2)]). Eine Funktion $\psi \in L^2(\mathbb{R})$ mit $\|\psi\|_{L^2(\mathbb{R})} = 1$ heißt Mutter-Wavelet (kurz: Wavelet), falls sie die Zulässigkeitsbedingung

$$C_\psi := 2\pi \int_{\mathbb{R}^*} \frac{|\hat{\psi}(\omega)|^2}{|\omega|} d\omega < \infty \quad (3.1)$$

erfüllt, wobei $\mathbb{R}^* := \mathbb{R} \setminus \{0\}$.

Die Bedingung (3.1) ist abstrakt und für eine gegebene Funktion nicht unmittelbar sichtbar. Unter einer milden Abklingvoraussetzung lässt sie sich jedoch äquivalent durch eine Bedingung im Zeitbereich ersetzen, die unmittelbar überprüfbar ist und zugleich erklärt, warum die Bezeichnung Wavelet – kleine Welle – angemessen ist.

Satz 3.2 (Charakterisierung der Zulässigkeit, [Bla03, Satz (3.1)]). Sei $\psi \in L^2(\mathbb{R})$, $\psi \neq 0$, mit $\int_{\mathbb{R}} |t| |\psi(t)| dt < \infty$. Dann sind äquivalent:

(i) $C_\psi < \infty$,

(ii) $\int_{\mathbb{R}} \psi(t) dt = 0$, gleichbedeutend mit $\hat{\psi}(0) = 0$.¹

Der Beweis findet sich bei [Bla03, Beweis zu Satz (3.1)] und wird hier nicht ausgeführt.

Bemerkung 3.3. Jedes Wavelet $\psi \in L^1(\mathbb{R})$ hat den Mittelwert null: $\hat{\psi}$ ist dann stetig, und das Integral in (3.1) kann nur für $\hat{\psi}(0) = 0$ konvergieren [LMR98, Kap. 1.1]. Sein Graph verläuft daher notwendig teils oberhalb, teils unterhalb der t -Achse, wie bei einer Welle [Bla03, Kap. 3.1]. Die in den Anwendungen verwendeten Wavelets haben darüber hinaus kompakten Träger oder fallen schnell ab; erst zusammen damit ergibt sich das Bild einer zeitlich begrenzten, kleinen Welle.

Das folgende Beispiel macht Definition 3.1 und Satz 3.2 an der einfachsten möglichen Funktion konkret.

Beispiel 3.4 (Haar-Wavelet). Die Funktion

$$\psi^H(t) := \begin{cases} 1, & 0 \leq t < 1/2, \\ -1, & 1/2 \leq t < 1, \\ 0, & \text{sonst,} \end{cases}$$

hat kompakten Träger, also $\int_{\mathbb{R}} |t| |\psi^H(t)| dt < \infty$, und Mittelwert null, erfüllt also nach Satz 3.2 die Zulässigkeitsbedingung; wegen $\|\psi^H\|_{L^2(\mathbb{R})} = 1$ ist sie ein Wavelet im Sinne von Definition 3.1. Ihre Fourier-Transformierte lässt sich mit der stetig nach $x = 0$ fortgesetzten Funktion

$$\text{sinc}(x) := \frac{\sin x}{x} \quad (x \neq 0), \quad \text{sinc}(0) := 1,$$

¹Die Gleichbedeutung ist die Fourier-Konvention aus Bemerkung 2.1 an der Stelle $\omega = 0$: Dort steht $\hat{\psi}(0) = (2\pi)^{-1/2} \int_{\mathbb{R}} \psi(t) dt$, beide Formulierungen sagen also dasselbe. Der Punktwert ist dabei erklärt, weil die Voraussetzung $\psi \in L^1(\mathbb{R})$ erzwingt – auf $|t| \leq 1$ nach Cauchy–Schwarz, auf $|t| > 1$ wegen $|\psi(t)| \leq |t| |\psi(t)|$ – und $\hat{\psi}$ für L^1 -Funktionen stetig ist [Ser17, Satz 12.1].

geschlossen angeben als

$$\widehat{\psi^H}(\omega) = \frac{i}{\sqrt{2\pi}} e^{-i\omega/2} \sin(\omega/4) \operatorname{sinc}(\omega/4), \quad \omega \in \mathbb{R}. \quad (3.2)$$

Die Aussage von Satz 3.2 ist unmittelbar ablesbar: Der Faktor $\sin(\omega/4)$ verschwindet bei $\omega = 0$, also ist $\widehat{\psi^H}(0) = 0$. Da ψ^H reellwertig ist, gilt außerdem $\widehat{\psi^H}(-\omega) = \overline{\widehat{\psi^H}(\omega)}$, also ist $|\widehat{\psi^H}|$ eine gerade Funktion. Wegen $\sin(\omega/4) \operatorname{sinc}(\omega/4) = 4 \sin^2(\omega/4)/\omega$ für $\omega \neq 0$ ist $|\widehat{\psi^H}(\omega)|^2 = 16 \sin^4(\omega/4)/(2\pi\omega^2)$, und aus der Symmetrie des Integranden folgt

$$\begin{aligned} C_{\psi^H} &= 2\pi \cdot 2 \int_0^\infty \frac{16 \sin^4(\omega/4)}{2\pi \omega^2} \cdot \frac{d\omega}{\omega} = 32 \int_0^\infty \frac{\sin^4(\omega/4)}{\omega^3} d\omega \\ &= 32 \int_0^\infty \frac{\sin^4 u}{(4u)^3} 4 du = 2 \int_0^\infty \frac{\sin^4 u}{u^3} du = 2 \ln 2, \end{aligned}$$

wobei im vorletzten Schritt $u = \omega/4$ substituiert wurde; der Wert des letzten Integrals ist $\ln 2$. Abbildung 3.2 zeigt ψ^H und den Betrag ihrer Fourier-Transformierten [LMR98, Kap. 1.1, Beispiel (1)].




Abbildung 3.2.: Das Haar-Wavelet ψ^H im Zeitbereich (a) und der Betrag seiner Fourier-Transformierten (b); $\omega_0 \approx 4,66$ bezeichnet die Lage des globalen Maximums, nach [LMR98, Kap. 1.1, Beispiel (1)].

3.1.2. Die Wavelet-Familie und die Transformation

Wir wollen das feste Mutter-Wavelet nun skalieren und verschieben und dadurch eine Wavelet-Familie erhalten.

Definition 3.5 (Wavelet-Familie und kontinuierliche Wavelet-Transformation, [Bla03, Kap. 3.1, Gl. (4)–(6)]). Sei ψ ein Wavelet im Sinne von Definition 3.1. Für $(a, b) \in \mathbb{R}^* \times \mathbb{R}$ setzen wir

$$\psi_{a,b}(t) := \frac{1}{|a|^{1/2}} \psi\left(\frac{t-b}{a}\right), \quad t \in \mathbb{R}. \quad (3.3)$$

Die kontinuierliche Wavelet-Transformation (CWT) von $f \in L^2(\mathbb{R})$ bezüglich ψ ist die Funktion

$$W_\psi f: \mathbb{R}^* \times \mathbb{R} \rightarrow \mathbb{C}, \quad W_\psi f(a, b) := \langle f, \psi_{a,b} \rangle = \frac{1}{|a|^{1/2}} \int_{\mathbb{R}} f(t) \overline{\psi\left(\frac{t-b}{a}\right)} dt. \quad (3.4)$$

Die Menge $\mathbb{R}_\square^* := \mathbb{R}^* \times \mathbb{R}$, auf der $W_\psi f$ erklärt ist, heißt die zersägte (a, b) -Ebene. Ist das zugrunde liegende Wavelet aus dem Zusammenhang klar, schreiben wir kurz Wf .

Bemerkung 3.6 (Normierung der Familie). Die Substitution $t = as + b$ liefert

$$\|\psi_{a,b}\|_{L^2(\mathbb{R})}^2 = \frac{1}{|a|} \int_{\mathbb{R}} \left| \psi\left(\frac{t-b}{a}\right) \right|^2 dt = \int_{\mathbb{R}} |\psi(s)|^2 ds = \|\psi\|_{L^2(\mathbb{R})}^2$$

für alle $(a, b) \in \mathbb{R}^* \times \mathbb{R}$; dabei ist $dt = |a| ds$, was den Vorfaktor $|a|^{-1}$ gerade aufhebt – auch für $a < 0$, da die Substitution dann zusätzlich die Integrationsgrenzen vertauscht. Genau dafür ist der Faktor $|a|^{-1/2}$ gewählt: Jede andere Potenz von $|a|$ würde die Norm skalenabhängig machen. Mit $\|\psi\|_{L^2(\mathbb{R})} = 1$ aus Definition 3.1 ist somit die gesamte Wavelet-Familie normiert [Bla03, Kap. 3.1].

Anmerkung. davor support definieren - in grundlagen ist der träger einfach...

Bemerkung 3.7 (Bedeutung der beiden Parameter). Ist ψ kompakt getragen, so gilt $\text{supp } \psi_{a,b} = b + a \cdot \text{supp } \psi$, das heißt der Träger von $\psi_{a,b}$ ist das um den Faktor $|a|$ gestreckte und nach b verschobene Bild von $\text{supp } \psi$; für $a < 0$ wird ψ dabei zusätzlich an der Geraden $t = b$ gespiegelt. Der Parameter b verschiebt also das Wavelet entlang der Zeitachse, sodass $Wf(a, b)$ lokale Information über f in der Umgebung von $t = b$ trägt; der Parameter a steuert die Größe dieses Einflussbereichs. Für $a \rightarrow 0$ zoomt die Transformation immer schärfer auf $t = b$ [LMR98, Kap. 1.1]. Abbildung 3.3 zeigt die Skalierung und Verschiebung des Haar-Wavelets. Für das EKG bedeutet das: Der QRS-Komplex wird bei kleinen $|a|$ mit einem Träger von einigen zehn Millisekunden abgetastet – der QRS-Komplex selbst ist etwa 100 ms breit [Reb21, Kap. 2.3.1] –, die T-Welle bei großen $|a|$ mit einem entsprechend langen.

Beispiel 3.8 (Ein Testsignal mit zwei Frequenzen). Betrachtet wird

$$f(t) = \begin{cases} 1 - \cos(2\pi t), & 0 \leq t \leq 3, \\ \frac{1}{2}(1 - \cos(10\pi t)), & 4 \leq t \leq 5, \\ 0, & \text{sonst.} \end{cases}$$

Auf $[0, 3]$ schwingt f mit der Frequenz 1, auf $[4, 5]$ mit der Frequenz 5; in beide Intervalle passt jeweils eine ganze Anzahl von Perioden (Abbildung 3.4). Als beschränkte Funktion mit kompaktem Träger liegt f in $L^1(\mathbb{R}) \cap L^2(\mathbb{R})$.

Fourier-Transformierte. Elementare Integration, bei der die ganzzahligen Periodenzahlen die Randterme vereinfachen, liefert in der Konvention aus Bemerkung 2.1 (Rechnung in Anhang A.1)

$$\hat{f}(\omega) = \frac{i}{\sqrt{2\pi}\omega} \left[\frac{4\pi^2(1 - e^{-3i\omega})}{\omega^2 - 4\pi^2} + \frac{50\pi^2(e^{-4i\omega} - e^{-5i\omega})}{\omega^2 - 100\pi^2} \right], \quad (3.5)$$




Abbildung 3.3.: Die Wavelet-Familie (3.3) am Haar-Wavelet. (b) verschiebt den Träger nach $[\frac{3}{2}, \frac{5}{2}]$, ohne die Form zu ändern. (c) staucht ihn auf $[0, \frac{1}{2}]$, wobei die Amplitude auf $\sqrt{2}$ steigt; (d) streckt ihn auf $[1, 3]$ bei Amplitude $1/\sqrt{2}$. Die gestrichelten Linien markieren ± 1 . In allen vier Fällen ist das Produkt aus Trägerlänge und quadrierter Amplitude gleich eins — die Familie ist normiert (Bemerkung 3.6).





Abbildung 3.4.: Das Signal f aus Beispiel 3.8.


 Abbildung 3.5.: Betragsspektrum $|\hat{f}(\omega)|$ nach (3.5); gestrichelt die Stellen $\pm 2\pi$ und $\pm 10\pi$.

wobei die Stellen $\omega \in \{0, \pm 2\pi, \pm 10\pi\}$ hebbar sind. Abbildung 3.5 zeigt beide Frequenzen als Maxima nahe $\pm 2\pi$ und $\pm 10\pi$; durch Überlagerung mit den Nebenkeulen sind sie leicht verschoben, nach $\omega \approx \pm 1,90\pi$ bzw. $\omega \approx \pm 9,73\pi$.

Wann die jeweilige Frequenz auftritt, ist $|\hat{f}|$ nicht zu entnehmen. Für die an $t = \frac{5}{2}$ gespiegelte Funktion $g(t) := f(5 - t)$, in der die beiden Komponenten ihre Plätze tauschen, gilt nämlich $\hat{g}(\omega) = e^{-5i\omega} \hat{f}(\omega)$, da f reell ist, also $|\hat{g}| = |\hat{f}|$. Die zeitliche Information ist in $\hat{f}$ zwar vorhanden, steckt aber vollständig in der Phase.

Wavelet-Transformierte. Wir transformieren nun mit dem Haar-Wavelet ψ^H aus Beispiel 3.4 und beschränken uns auf $a > 0$. Für $a > 0$ nimmt $\psi^H(\frac{t-b}{a})$ auf $[b, b + \frac{a}{2}[$ den Wert 1, auf $[b + \frac{a}{2}, b + a[$ den Wert -1 an und verschwindet sonst; das Wavelet ist also ein Fenster über $[b, b + a]$ mit Sprungstelle in der Mitte. Da ψ^H reellwertig ist, entfällt die Konjugation in (3.4), und mit der Stammfunktion $F(t) := \int_{-\infty}^t f(s) ds$ folgt

$$W_{\psi^H} f(a, b) = \frac{1}{\sqrt{a}} \left(\int_b^{b+a/2} f(t) dt - \int_{b+a/2}^{b+a} f(t) dt \right) = \frac{2F(b + \frac{a}{2}) - F(b) - F(b + a)}{\sqrt{a}}. \quad (3.6)$$

Die Transformation vergleicht also das Integral von f über die linke Fensterhälfte mit dem über die rechte; sie wirkt als Differenzenfilter. Die Stammfunktion ist elementar (Anhang A.2):

$$F(t) = \begin{cases} 0, & t < 0, \\ t - \frac{\sin(2\pi t)}{2\pi}, & 0 \leq t \leq 3, \\ 3, & 3 \leq t \leq 4, \\ 3 + \frac{t-4}{2} - \frac{\sin(10\pi t)}{20\pi}, & 4 \leq t \leq 5, \\ \frac{7}{2}, & t > 5. \end{cases}$$

Damit ist $W_{\psi_H} f$ für alle (a, b) in geschlossener Form bekannt; Abbildung 3.6 zeigt ihren Betrag, ausgewertet nach (3.6) (Code in Anhang B).




Abbildung 3.6.: Betrag der Wavelet-Transformierten nach (3.6); die Skalenachse ist logarithmisch.

Abbildung 3.6 zerfällt in zwei Bereiche. In der Ortsvariablen b liegen sie über den Trägern $[0, 3]$ und $[4, 5]$, in der Skala a unterscheiden sie sich um den Faktor fünf – genau das Verhältnis der beiden Frequenzen. Zeitpunkt und Frequenz sind also gleichzeitig ablesbar. Auch die schwache schnelle Komponente, die in Abbildung 3.5 kaum hervortritt, bildet hier ein eigenes Band: Bei kleinem a wertet die Transformation nur ein kurzes Zeitfenster aus, in dem die lange Dauer der langsamen Komponente nicht ins Gewicht fällt.

Damit ist an einem Beispiel vorgeführt, was die Transformation leistet: sie trennt, was im Betragsspektrum vermengt bleibt.

Belegstellen. Haar-Wavelet und seine Fourier-Transformierte: [LMR98, Kap. 1.1], [Bla03, Kap. 1.6]. Zur Darstellung von Wavelet-Transformierten und zur Wahl zusammengesetzter Testsignale vgl. [Bla03, Kap. 3.1] sowie [LMR98, Kap. 1.1].

3.1.3. Die Plancherel-Formel

Offen ist, ob sich f aus $W_{\psi} f$ zurückgewinnen lässt. Für die Fourier-Transformation beantwortet das der Satz von Plancherel (Abschnitt 2.4): Wegen $\|\hat{f}\| = \|f\|$ bleibt die Energie $\|f\|^2 = \int_{\mathbb{R}} |f(t)|^2 dt$ erhalten, und zwei verschiedene Signale können nicht dasselbe Spektrum besitzen. Für die CWT gilt eine entsprechende Aussage. Da $W_{\psi} f$ eine Funktion auf der (a, b) -Ebene ist, muss dazu zunächst festgelegt werden, wie dort Energie gemessen wird.

Definition 3.9 (Bildraum, [Bla03, Kap. 3.2, Gl. (2)]). Auf der zersägten Ebene $\mathbb{R}_\square^*$ aus Definition 3.5 sei

$$\mathcal{H} := \left\{ u: \mathbb{R}_\square^* \rightarrow \mathbb{C} \mid \int_{\mathbb{R}_\square^*} |u(a, b)|^2 \frac{da db}{a^2} < \infty \right\}, \quad \langle u, v \rangle_{\mathcal{H}} := \int_{\mathbb{R}_\square^*} u(a, b) \overline{v(a, b)} \frac{da db}{a^2}.$$

Dabei sind nur messbare Funktionen u zugelassen, und wie bei $L^2(\mathbb{R})$ in Abschnitt 2.1 werden Funktionen, die fast überall übereinstimmen, identifiziert.

Anmerkung. Hier noch Verweis auf Abschnitt 2.5 einfügen: Vergleich mit der gefensterter Fourier-Transformation. Dort genügt auf der (b, ω) -Ebene das gewöhnliche Maß $d\omega db$, weil Verschiebung und Modulation Flächen nicht verzerren; bei der CWT streckt der Parameter a , daher das Gewicht a^{-2} .

$\mathcal{H}$ ist also der Raum L^2 über der (a, b) -Ebene, mit dem Unterschied, dass beim Integrieren das Gewicht $|a|^{-2}$ eingeht; kurz $\mathcal{H} = L^2(\mathbb{R}_\square^*, d\mu)$ mit $d\mu = |a|^{-2} da db$ [Bla03, Kap. 3.2, Gl. (2)]. Die Energie von $W_\psi f$ ist damit $\|W_\psi f\|_{\mathcal{H}}^2 = \int_{\mathbb{R}_\square^*} |W_\psi f(a, b)|^2 \frac{da db}{a^2}$, und mit diesem Gewicht gilt der folgende Satz.

Satz 3.10 (Plancherel-Formel für die CWT, [Bla03, Satz (3.3)]). Sei ψ ein Wavelet mit Zulässigkeitskonstante C_ψ gemäß (3.1). Dann ist $W_\psi f \in \mathcal{H}$ für jedes $f \in L^2(\mathbb{R})$, und es gilt

$$\langle W_\psi f, W_\psi g \rangle_{\mathcal{H}} = C_\psi \langle f, g \rangle \quad \text{für alle } f, g \in L^2(\mathbb{R}). \quad (3.7)$$

Insbesondere ist $C_\psi^{-1/2} W_\psi$ eine Isometrie und W_ψ injektiv.

Der Satz besagt: Mit $g = f$ ist

$$\|W_\psi f\|_{\mathcal{H}}^2 = \langle W_\psi f, W_\psi f \rangle_{\mathcal{H}} = C_\psi \langle f, f \rangle = C_\psi \|f\|^2 < \infty.$$

Die Transformierte hat also endliche Energie, und diese ist genau das C_ψ -Fache der Energie von f . Teilt man durch $\sqrt{C_\psi}$, so bleibt die Norm erhalten:

$$\|C_\psi^{-1/2} W_\psi f\|_{\mathcal{H}} = \|f\| \quad \text{für alle } f \in L^2(\mathbb{R}).$$

$C_\psi^{-1/2} W_\psi$ ist also eine Isometrie; unitär im Sinne von Abschnitt 2.3 wäre sie erst, wenn sie zusätzlich surjektiv wäre – das ist sie nicht, ihr Bild ist ein echter Teilraum von $\mathcal{H}$ [Bla03, Kap. 3.4], vgl. Bemerkung 3.13. Der Beweis beruht auf mehrfacher Anwendung des Satzes von Plancherel und des Satzes von Fubini; die Zulässigkeitsbedingung sichert dabei die Endlichkeit der Konstante. Er findet sich bei [Bla03, Beweis zu Satz (3.3)], vgl. auch [LMR98, Satz 1.1.8].

Damit ist die Eingangsfrage beantwortet: Da W_ψ injektiv ist, ist f durch $W_\psi f$ eindeutig bestimmt. Wie man f konkret zurückgewinnt, sagt die folgende Umkehrformel.

Korollar 3.11 (Umkehrformel, [Bla03, Kap. 3.3, Gl. (2) und (4)]). Für alle $f, g \in L^2(\mathbb{R})$ gilt $\langle f, g \rangle = C_\psi^{-1} \int_{\mathbb{R}_\square^*} W_\psi f(a, b) \langle \psi_{a,b}, g \rangle \frac{da db}{a^2}$, in diesem schwachen Sinn also

$$f = \frac{1}{C_\psi} \int_{\mathbb{R}_\square^*} W_\psi f(a, b) \psi_{a,b} \frac{da db}{a^2}.$$

Beispiel 3.12 (Plancherel-Formel am Testsignal). Wir prüfen Satz 3.10 am Signal f aus Beispiel 3.8 mit dem Haar-Wavelet, und zwar an zwei Paaren: (i) für $g = f$ als Erhaltung der Energie, (ii) für die beiden Komponenten von f als Erhaltung der Orthogonalität. Die beiden Seiten von (3.7) werden dabei auf verschiedenen Wegen berechnet: C_{ψ^H} im Frequenzbereich (Beispiel 3.4), $W_{\psi^H}f$ rein im Zeitbereich nach (3.6).

(i) Energie. Als beschränkte Funktion mit kompaktem Träger liegt f in $L^2(\mathbb{R})$. Wegen $(1 - \cos x)^2 = 1 - 2\cos x + \frac{1}{2}(1 + \cos 2x)$ verschwinden bei Integration über ganze Perioden alle Cosinus-Terme, und es bleibt das $\frac{3}{2}$ -Fache der Intervalllänge:

$$\|f\|^2 = \int_0^3 (1 - \cos(2\pi t))^2 dt + \frac{1}{4} \int_4^5 (1 - \cos(10\pi t))^2 dt = \frac{9}{2} + \frac{3}{8} = \frac{39}{8}.$$

Mit $C_{\psi^H} = 2\ln 2$ aus Beispiel 3.4 folgt nach (3.7) mit $g = f$ $\|W_{\psi^H}f\|_{\mathcal{H}}^2 = C_{\psi^H}\|f\|^2 = 2\ln 2 \cdot \frac{39}{8} \approx 6,76$. Da ψ^H reellwertig ist, entfällt davon auf die in Abbildung 3.6 gezeigte Halbebene $a > 0$ genau die Hälfte [Bla03, Satz (3.4)]. Für das Haar-Wavelet sieht man das direkt: Wegen $\psi^H(-x) = -\psi^H(x+1)$ für fast alle $x \in \mathbb{R}$ ist für $c > 0$

$$\begin{aligned} \psi_{-c,b}^H(t) &= \frac{1}{\sqrt{c}} \psi^H\left(-\frac{t-b}{c}\right) = -\frac{1}{\sqrt{c}} \psi^H\left(\frac{t-(b-c)}{c}\right) = -\psi_{c,b-c}^H(t), \\ \text{also} \quad W_{\psi^H}f(-c, b) &= -W_{\psi^H}f(c, b-c). \end{aligned}$$

Die Werte auf der Halbebene $a < 0$ sind also bis aufs Vorzeichen die in b verschobenen Werte auf $a > 0$; da db verschiebungsinvariant ist, tragen beide Halbebenen dieselbe Energie. Damit ist

$$\int_0^\infty \int_{\mathbb{R}} |W_{\psi^H}f(a, b)|^2 \frac{db da}{a^2} = \ln 2 \cdot \frac{39}{8} \approx 3,379.$$

Zur Kontrolle werten wir dieses Doppelintegral mit der geschlossenen Form (3.6) numerisch aus und erhalten 3,3790, in Übereinstimmung mit dem exakten Wert.

(ii) Orthogonalität. Zerlegt man $f = f_1 + f_2$ in die langsame Komponente auf $[0, 3]$ und die schnelle auf $[4, 5]$, so ist $\langle f_1, f_2 \rangle = 0$ wegen der disjunkten Träger, nach (3.7) also auch $\langle W_{\psi^H}f_1, W_{\psi^H}f_2 \rangle_{\mathcal{H}} = 0$ – obwohl sich die beiden Bänder in Abbildung 3.6 für große a überlappen. Nach derselben Symmetrie wie in (i) verschwindet das Skalarprodukt auch auf der Halbebene $a > 0$ allein. Die Energien $\ln 2 \cdot \frac{9}{2}$ und $\ln 2 \cdot \frac{3}{8}$ der beiden Komponenten addieren sich daher ohne Mischterm.

Das Beispiel bestätigt (3.7) damit in beiden Lesarten: als Erhaltung der Energie und als Erhaltung der Orthogonalität.

Anmerkung. finde das beispiel noch nicht wirklich gut... eher nochmal was einfacheres/anschaulicheres

Bemerkung 3.13 (Redundanz der CWT). Die CWT stellt ein Signal, also eine Funktion der einen Variablen t , durch eine Funktion der beiden Variablen (a, b) dar. Neue Information entsteht dabei nicht, denn nach Satz 3.10 ist W_ψ injektiv und f aus $W_\psi f$ eindeutig bestimmt. Dieselbe Information wird lediglich auf sehr viel mehr Werte verteilt. Im Endlichdimensionalen lässt sich das abzählen: Ein Signal aus N Abtastwerten liefert bei N Skalen und N Verschiebungen N^2 Koeffizienten, die aber nur einen höchstens N -dimensionalen Teilraum des $\mathbb{C}^{N^2}$ ausfüllen können [Bla03, Kap. 4.1]. Entsprechend sind die Funktionen $\psi_{a,b}$ nicht linear unabhängig [Bla03, Kap. 3.4].

Die Werte einer Wavelet-Transformierten sind deshalb nicht frei wählbar, sondern müssen zueinander passen. Blatter macht das mit dem reproduzierenden Kern präzise: Jeder Wert ist durch alle übrigen festgelegt, und nicht jede Funktion von (a, b) ist die Transformierte eines Signals [Bla03, Kap. 3.4, Satz (3.9)].

Die Schwellenwertverfahren, mit denen in Kapitel 5 entauscht wird, sind dagegen für Orthonormalbasen formuliert [Mal09, Kap. 11.2]. Gesucht ist daher eine abzählbare Auswahl von Parametern (a, b) , für die $\{\psi_{a,b}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ ist. Der Rest dieses Kapitels führt dorthin.

3.2. Das dyadische Gitter und die Multiskalenanalyse

Nach Bemerkung 3.13 ist eine abzählbare Auswahl von Parametern (a, b) zu treffen, mit der Skala a und der Verschiebung b in der Zeit. Einen Maßstab liefert die Plancherel-Formel (3.7) für $g = f$:

$$\|f\|^2 = \frac{1}{C_\psi} \int_{\mathbb{R}_+^*} |W_\psi f(a, b)|^2 \frac{da}{a} \frac{db}{a}.$$

Die Energie wird also über die (a, b) -Ebene verteilt, wobei da/a jede Verdopplung der Skala gleich zählt und db/a die Zeit in Vielfachen der Wavelet-Breite a misst. Vertritt jeder Gitterpunkt einen Bereich gleichen Inhalts, dürfen alle Gitterpunkte gleich gewichtet werden [Bla03, Kap. 4.3]. Für $c > 0$ und $b_1 \in \mathbb{R}$ gilt

$$\int_{b_1}^{b_1+c} \int_c^{2c} \frac{da db}{a^2} = c \left(\frac{1}{c} - \frac{1}{2c} \right) = \frac{1}{2}.$$

Das legt das Gitter $a = 2^j$, $b = k 2^j$ nahe: ein Punkt pro Verdopplung der Skala und ein Zeitschritt, der mit der Wavelet-Breite mitwächst. Zellen gleichen Inhalts liefert ebenso jedes Gitter $(a_0^j, k b_0 a_0^j)$ mit $a_0 > 1$, $b_0 > 0$ [LMR98, Kap. 2.1.1]; die Wahl $a_0 = 2$ ist die in der Praxis übliche [Bla03, Kap. 5]. Ob die so ausgewählten Funktionen tatsächlich eine Orthonormalbasis bilden, hängt dabei allein von ψ ab.

Definition 3.14 (Dyadische Wavelet-Familie, [Bla03, Kap. 5.1]). Sei ψ ein Wavelet. Für die Elemente der Wavelet-Familie (3.3) auf dem dyadischen Gitter $\{(2^j, k 2^j) : j, k \in \mathbb{Z}\} \subset \mathbb{R}_+^*$ schreiben wir kurz

$$\psi_{j,k} := \psi_{2^j, k 2^j}, \quad \text{also} \quad \psi_{j,k}(t) = 2^{-j/2} \psi\left(\frac{t}{2^j} - k\right), \quad j, k \in \mathbb{Z}. \quad (3.8)$$

Dabei gehört zu kleinerem j die feinere Skala: Für $j \rightarrow -\infty$ wird $\psi_{j,k}$ schmal, für $j \rightarrow +\infty$ breit.²

Die beiden hervorgehobenen Zellen in Abbildung 3.7 zeigen das konkret. Die feine Zelle $[\frac{1}{2}, 1] \times [0, \frac{1}{2}]$ zur Skala $j = -1$ hat den Inhalt

$$\int_0^{1/2} \int_{1/2}^1 \frac{da db}{a^2} = \frac{1}{2} \cdot (2 - 1) = \frac{1}{2},$$

²Diese Konvention folgt Blatter und Louis/Maaß/Rieder; ein Teil der Literatur zählt umgekehrt, so Hanke-Bourgeois [HB09, § 56].




Abbildung 3.7.: Das dyadische Gitter $(2^j, k 2^j)$ mit logarithmisch aufgetragener Skala a . Jeder Gitterpunkt vertritt die Zelle $[2^j, 2^{j+1}] \times [k 2^j, (k+1) 2^j]$ rechts oberhalb von ihm; alle Zellen haben bezüglich $da db/a^2$ den Inhalt $\frac{1}{2}$. Nur die Skalenachse ist logarithmisch, weil Stauchen multiplikativ, Verschieben dagegen additiv wirkt.

die grobe Zelle $[4, 8] \times [4, 8]$ zur Skala $j = 2$ den Inhalt

$$\int_4^8 \int_4^8 \frac{da db}{a^2} = 4 \cdot \left(\frac{1}{4} - \frac{1}{8} \right) = \frac{1}{2}.$$

Im gewöhnlichen Sinn ist die grobe Zelle mit Fläche 16 gegenüber $\frac{1}{4}$ zwar 64-mal so groß, das Gewicht $1/a^2$ ist dort aber entsprechend kleiner.

3.2.1. Die Axiome

Gesucht ist ein Wavelet ψ , dessen dyadische Familie $\{\psi_{j,k}\}$ aus Definition 3.14 eine Orthonormalbasis von $L^2(\mathbb{R})$ ist. Direkt lässt sich ein solches ψ kaum finden; bekannt sind zunächst nur Einzelfälle wie das Haar-Wavelet [LMR98, Kap. 2.2.1]. Die Multiskalenanalyse geht deshalb einen Umweg: Statt nach ψ zu suchen, beschreibt man zuerst, wie ein Signal auf verschiedenen Skalen vergrößert wird. Das Wavelet ergibt sich danach aus dem Übergang zwischen zwei benachbarten Skalen [Bla03, Kap. 5.1]. Das folgende Beispiel zeigt das am Haar-Wavelet.

Beispiel 3.15 (Mittelwerte und Details, [LMR98, Kap. 2.2.1]). Sei V_j der Raum der Funktionen in $L^2(\mathbb{R})$, die auf jedem Intervall $[k 2^j, (k+1) 2^j[$ konstant sind. Die Orthogonalprojektion P_j auf V_j ersetzt eine Funktion auf jedem dieser Intervalle durch ihren Mittelwert [HB09, Satz 43.1]. Wir wenden das auf die Treppenfunktion

$$f = 4 \cdot \mathbf{1}_{[0,1[} + 2 \cdot \mathbf{1}_{[1,2[} + 5 \cdot \mathbf{1}_{[2,3[} + 7 \cdot \mathbf{1}_{[3,4[} \in V_0$$

an und schreiben kurz $f = (4, 2, 5, 7)$ für ihre Werte auf den vier Intervallen (Abbildung 3.8).

Mittlung über je zwei benachbarte Intervalle liefert $P_1 f = (3, 3, 6, 6)$. Dabei geht $f - P_1 f = (1, -1, -1, 1)$ verloren; mit dem Haar-Wavelet ψ^H aus Beispiel 3.4 ist das

$$(f - P_1 f)(t) = \psi^H\left(\frac{t}{2}\right) - \psi^H\left(\frac{t}{2} - 1\right).$$




Abbildung 3.8.: Die Treppenfunktion $f = (4, 2, 5, 7)$ aus Beispiel 3.15 und ihre Mittelungen P_1f und P_2f (oben). Darunter steht jeweils das Detail, das beim Übergang zu dieser Mittelung verloren geht (unten). Alle Panels haben denselben vertikalen Maßstab. Jedes Detail ist ein Vielfaches eines gestreckten und verschobenen Haar-Wavelets.

Nochmalige Mittelung liefert $P_2f = (4,5, 4,5, 4,5, 4,5)$, und verloren geht $P_1f - P_2f = (-1,5, -1,5, 1,5, 1,5)$, also $(P_1f - P_2f)(t) = -1,5 \psi^H(\frac{t}{4})$. Insgesamt ist

$$f(t) = 4,5 \cdot \mathbf{1}_{[0,4]}(t) - 1,5 \psi^H(\frac{t}{4}) + \psi^H(\frac{t}{2}) - \psi^H(\frac{t}{2} - 1), \quad t \in \mathbb{R}.$$

Die vier Werte von f sind damit durch vier andere Zahlen ersetzt: den Mittelwert 4,5, ein grobes Detail $-1,5$ und zwei feine Details 1 und -1 . Aus ihnen lässt sich f exakt zurückgewinnen. Die Zahlen sind hier ohne die Normierungsfaktoren $2^{-j/2}$ aus (3.8) angegeben.

Definition 3.16 (Multiskalenanalyse, [Bla03, Kap. 5.1, (a)–(c)]). Eine Multiskalenanalyse (MSA) von $L^2(\mathbb{R})$ ist eine Folge $(V_j)_{j \in \mathbb{Z}}$ abgeschlossener Teilräume von $L^2(\mathbb{R})$ mit den folgenden Eigenschaften:

(M1) (Schachtelung) $\cdots \subset V_2 \subset V_1 \subset V_0 \subset V_{-1} \subset V_{-2} \subset \cdots \subset L^2(\mathbb{R})$,

(M2) (Separation) $\bigcap_{j \in \mathbb{Z}} V_j = \{0\}$,

(M3) (Vollständigkeit) $\overline{\bigcup_{j \in \mathbb{Z}} V_j} = L^2(\mathbb{R})$,

(M4) (Skalierung) $f \in V_j \iff f(2^j \cdot) \in V_0$ für alle $j \in \mathbb{Z}$,

(M5) (Erzeugende Funktion) Es gibt ein $\varphi \in L^2(\mathbb{R}) \cap L^1(\mathbb{R})$,³ sodass $\{\varphi(\cdot - k) : k \in \mathbb{Z}\}$ eine Orthonormalbasis von V_0 ist.

Die Funktion φ heißt Skalierungsfunktion der MSA.

Bemerkung 3.17 (Zu den Axiomen, [Bla03, Kap. 5.1]). (a) Die anschauliche Bedeutung von (M1)–(M3): Ein $f \in V_j$ enthält nur Strukturen der zeitlichen Ausdehnung $\gtrsim 2^j$. Je kleiner j , desto feinere Details sind zugelassen; (M3) besagt, dass im Limes $j \rightarrow -\infty$ jedes Signal erreichbar ist, (M2), dass im Limes $j \rightarrow +\infty$ nichts übrigbleibt [LMR98, Bem. 2.2.2].⁴

(b) Axiom (M4) ist die eigentliche Substanz: Die V_j sind nicht irgendwelche geschachtelten Räume, sondern skalierte Kopien ein und desselben Raumes V_0 . Erst dadurch genügt eine einzige Funktion φ , um die gesamte Hierarchie festzulegen.

Beispiel 3.18 (Die Haar-MSA, [Bla03, Kap. 5.1, Beispiel ①]). Die Räume V_j aus Beispiel 3.15, also die Treppenfunktionen der Stufenbreite 2^j , bilden eine MSA mit der Skalierungsfunktion $\varphi := \mathbf{1}_{[0,1]}$, einer einzelnen Stufe (nicht dem Haar-Wavelet). (M1) gilt, weil eine Treppe der Stufenbreite 2 auch eine der Stufenbreite 1 ist; (M4), weil f genau dann auf allen Intervallen $[k2^j, (k+1)2^j[$ konstant ist, wenn $f(2^j \cdot)$ auf allen Intervallen $[k, k+1[$ konstant ist – etwa $\mathbf{1}_{[0,2]} \in V_1$ und $\mathbf{1}_{[0,2]}(2 \cdot) = \mathbf{1}_{[0,1]} \in V_0$. Für (M5) sind die Verschiebungen $\varphi(\cdot - k) = \mathbf{1}_{[k, k+1]}$ orthonormal, und etwa $f = (4, 2, 5, 7) = 4\varphi + 2\varphi(\cdot - 1) + 5\varphi(\cdot - 2) + 7\varphi(\cdot - 3)$.

(M2): Liegt f in allen V_j , so ist f auf $[0, 2^j[$ für jedes j konstant, also auf ganz $[0, \infty[$; das ist in $L^2(\mathbb{R})$ nur für $f = 0$ möglich, ebenso auf $] -\infty, 0[$. (M3): $\mathbf{1}_{[0,1/3]}$ liegt in keinem V_j , lässt sich aber annähern, etwa durch $\mathbf{1}_{[0,5/16]} \in V_{-4}$ mit Fehlerquadrat $\frac{1}{3} - \frac{5}{16} = \frac{1}{48}$. Mit feineren Stufen wird der Fehler beliebig klein, und da Treppenfunktionen mit dyadischen Sprungstellen dicht in $L^2(\mathbb{R})$ liegen [Bla03, Kap. 5.1], folgt (M3).

Anmerkung. Dieses Beispiel wird in Kapitel 4 bis zum Haar-Wavelet durchgerechnet und ist in Kapitel 6 der Referenzfall, gegen den db2 antritt. Es lohnt sich, es hier vollständig zu bringen.

Beispiel 3.15 zeigt die Multiskalenanalyse im Kleinen. Jede gröbere Näherung $P_{j+1}f$ entsteht aus der feineren $P_j f$ durch Mittelung; darin spiegelt sich die Schachtelung (M1). Was bei der Mittelung verloren geht, sind Vielfache gestreckter und verschobener Haar-Wavelets [LMR98, Kap. 2.2.1]; diese Unterschiede zwischen zwei Stufen werden in Abschnitt 3.4 als Detailräume W_j gefasst. Schließlich werden aus 4 Werten wieder 4 Koeffizienten: Die Zerlegung ist frei von der Redundanz, die Bemerkung 3.13 an der CWT bemängelt.

3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j

Axiom (M5) stattet nur den Grundraum V_0 mit einer Orthonormalbasis aus [Bla03, Kap. 5.1, (c)]. In diesem Abschnitt wird diese Basis auf alle Skalen übertragen (Satz 3.19), und es wird festgehalten, dass die Orthogonalprojektionen P_j auf V_j für $j \rightarrow -\infty$ gegen die Identität und für $j \rightarrow +\infty$ gegen null streben (Proposition 3.21). Beides zusammen liefert in Abschnitt 3.4

³Die Forderung $\varphi \in L^1(\mathbb{R})$ folgt Blatter und sichert, dass $\hat{\varphi}$ stetig ist; das wird in Kapitel 4 bei der Auswertung der Skalierungsgleichung an der Stelle $\omega = 0$ gebraucht.

⁴Louis, Maaß und Rieder verlangen in (M5) nur eine Riesz-Basis [LMR98, Def. 2.2.1]; wir folgen Blatter und fordern eine Orthonormalbasis.

die Zerlegung von $L^2(\mathbb{R})$ in Detailräume. Normen ohne Index sind im Folgenden stets Normen in $L^2(\mathbb{R})$.

3.3.1. Die Orthonormalbasis auf allen Skalen

Mit dem Dilatationsoperator $D_a f := |a|^{-1/2} f(\cdot/a)$, $a \in \mathbb{R}^*$, lässt sich (M4) als Aussage über Räume lesen: f liegt genau dann in V_j , wenn $f = h(\cdot/2^j)$ mit einem $h \in V_0$ ist. Da V_j ein linearer Raum ist, spielt der Vorfaktor keine Rolle, und es folgt

$$V_j = D_{2^j}(V_0) \quad \text{für alle } j \in \mathbb{Z}. \quad (3.9)$$

Jedes V_j ist also eine gestreckte Kopie von V_0 [Bla03, Kap. 5.1, (b)]. Da D_{2^j} unitär ist [LMR98, Kap. 1.2], überträgt sich damit auch die Basis.

Satz 3.19 (Orthonormalbasis von V_j , [Bla03, Kap. 5.1]). *Sei $(V_j)_{j \in \mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ . Setzt man*

$$\varphi_{j,k}(t) := 2^{-j/2} \varphi\left(\frac{t}{2^j} - k\right), \quad j, k \in \mathbb{Z}, \quad (3.10)$$

so ist $\{\varphi_{j,k} : k \in \mathbb{Z}\}$ für jedes feste $j \in \mathbb{Z}$ eine Orthonormalbasis von V_j .

Die Aussage folgt direkt aus (3.9): Ein unitärer Operator erhält Skalarprodukte und bildet deshalb eine Orthonormalbasis eines abgeschlossenen Teilraums auf eine Orthonormalbasis von dessen Bild ab [Ser17, Def. 27.7, Satz 25.18]. Angewandt auf die Basis $\{\varphi(\cdot - k)\}_k$ von V_0 aus (M5) liefert D_{2^j} die Basis $\{D_{2^j}\varphi(\cdot - k)\}_k = \{\varphi_{j,k}\}_k$ von V_j . Benachbarte Basisfunktionen sind dabei um die Schrittweite 2^j gegeneinander verschoben [Bla03, Kap. 5.1].

Anmerkung. Der rote Faden: Die gesamte Konstruktion liefert Orthonormalbasen. In Abschnitt 5.1 ist es die Orthogonalität der DWT (Lemma 5.3), die das Rauschen invariant lässt.

3.3.2. Die Approximationsoperatoren

Definition 3.20 (Approximationsoperator). Für $f \in L^2(\mathbb{R})$ und $j \in \mathbb{Z}$ heißen die Zahlen $a_{j,k} := \langle f, \varphi_{j,k} \rangle$, $k \in \mathbb{Z}$, die Approximationskoeffizienten von f auf der Skala j , und

$$P_j f := \sum_{k \in \mathbb{Z}} a_{j,k} \varphi_{j,k} \quad (3.11)$$

heißt die Approximation von f auf der Skala j ; die Abbildung $P_j : L^2(\mathbb{R}) \rightarrow V_j$ heißt Approximationsoperator [LMR98, Bem. 2.2.2 (a)].

Da $\{\varphi_{j,k}\}_k$ nach Satz 3.19 eine Orthonormalbasis von V_j ist, konvergiert die Reihe in $L^2(\mathbb{R})$, und es gilt $\|P_j f\|^2 = \sum_k |a_{j,k}|^2$ [Ser17, Satz 25.18], [Bla03, Kap. 5.1, Gl. (7)]. Wegen $\langle f - P_j f, \varphi_{j,l} \rangle = a_{j,l} - a_{j,l} = 0$ für alle $l \in \mathbb{Z}$ steht $f - P_j f$ senkrecht auf V_j ; P_j ist also die Orthogonalprojektion auf V_j . Für jedes $g \in V_j$ folgt daraus nach Pythagoras $\|f - g\| \geq \|f - P_j f\|$, das heißt, $P_j f$ ist die beste Näherung von f in V_j .

Blatter deutet P_j als Tiefpass-Filter: $P_j f$ enthält noch alle Details von f , die wenigstens die Ausdehnung 2^j auf der Zeitachse besitzen [Bla03, Kap. 5.1]. Für die Haar-MSA aus Beispiel 3.18 ist $\varphi_{j,k} = 2^{-j/2} \mathbf{1}_{I_{j,k}}$ mit $I_{j,k} := [k2^j, (k+1)2^j[$, also

$$a_{j,k} \varphi_{j,k} = \left(\frac{1}{2^j} \int_{I_{j,k}} f(t) dt \right) \mathbf{1}_{I_{j,k}},$$

und P_j ersetzt f auf jedem $I_{j,k}$ durch seinen Mittelwert [LMR98, Kap. 2.2]. Das ist die in Beispiel 3.15 benutzte Aussage; die dort angegebenen Mittelwerte sind die Zahlen $2^{-j/2} a_{j,k}$.

Proposition 3.21 (Approximationseigenschaft, [LMR98, Bem. 2.2.2 (a)]). *Für jedes $f \in L^2(\mathbb{R})$ gilt*

$$(a) \lim_{j \rightarrow -\infty} \|P_j f - f\| = 0 \quad \text{und} \quad (b) \lim_{j \rightarrow +\infty} \|P_j f\| = 0.$$

Aussage (a) folgt aus (M3), da $P_j f$ die beste Näherung von f in $V_j \supset V_{j_0}$ ist; Aussage (b) folgt aus (M2) [Bla03, Prop. (5.1)].

3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$

Die Basen $\{\varphi_{j,k}\}_k$ der einzelnen V_j lassen sich nicht zu einer Orthonormalbasis von $L^2(\mathbb{R})$ vereinigen, denn wegen $V_j \subset V_{j-1}$ sind sie über die Skalen hinweg nicht orthogonal. Man betrachtet deshalb nur den Zuwachs beim Übergang zur nächstfeineren Skala [Bla03, Kap. 5.1].

Definition 3.22 (Detailräume, [Bla03, Kap. 5.1, Gl. (8)]). Für $j \in \mathbb{Z}$ sei W_j das orthogonale Komplement von V_j in V_{j-1} , also

$$V_{j-1} = V_j \oplus W_j, \quad W_j \perp V_j, \quad (3.12)$$

und $Q_j := P_{j-1} - P_j$.

Q_j ist die Orthogonalprojektion auf W_j [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.9)]: Es ist $Q_j f = (f - P_j f) - (f - P_{j-1} f) \in V_{j-1}$, und beide Klammern stehen senkrecht auf V_j ; also liegt $Q_j f$ in W_j , und $f - Q_j f = (f - P_{j-1} f) + P_j f$ steht senkrecht auf W_j .

Zwei weitere Eigenschaften folgen unmittelbar. Da D_{2^j} unitär ist und nach (3.9) V_0 auf V_j sowie V_{-1} auf V_{j-1} abbildet, gilt

$$W_j = D_{2^j}(W_0) \quad \text{für alle } j \in \mathbb{Z} \quad (3.13)$$

[Bla03, Kap. 5.1, Gl. (9)]. Für $i > j$ ist außerdem $W_i \subset V_{i-1} \subset V_j \perp W_j$; die Detailräume sind also paarweise orthogonal [Bla03, Prop. (5.1)].

Satz 3.23 (Zerlegung von $L^2(\mathbb{R})$ in Detailräume, [Bla03, Prop. (5.1)]). *Sei $(V_j)_{j \in \mathbb{Z}}$ eine MSA mit Detailräumen W_j . Dann gilt*

$$L^2(\mathbb{R}) = \bigoplus_{j \in \mathbb{Z}} W_j \quad (3.14)$$

als orthogonale direkte Summe, und für jedes $f \in L^2(\mathbb{R})$ ist $f = \sum_{j \in \mathbb{Z}} Q_j f$ mit

$$\|f\|^2 = \sum_{j \in \mathbb{Z}} \|Q_j f\|^2. \quad (3.15)$$

Ferner gilt für jedes feste $J \in \mathbb{Z}$

$$L^2(\mathbb{R}) = V_J \oplus \bigoplus_{j \leq J} W_j, \quad f = P_J f + \sum_{j \leq J} Q_j f. \quad (3.16)$$

Die Orthogonalität ist eben gezeigt. Nach Definition von Q_j ist $\sum_{j=J_1+1}^{J_2} Q_j f = P_{J_1} f - P_{J_2} f$ eine Teleskopsumme, die nach Proposition 3.21 für $J_1 \rightarrow -\infty$, $J_2 \rightarrow +\infty$ gegen f strebt; mit $J_2 = J$ ergibt sich (3.16). Die Energiegleichung folgt aus der Orthogonalität der Summanden [Bla03, Prop. (5.1)], [LMR98, Gl. (2.2.11), (2.2.12)].

In der Anwendung wird stets die endliche Fassung (3.16) benutzt: $P_J f$ entspricht einem Tiefpass, die $Q_j f$ den Anteilen von f in verschiedenen Frequenzbändern [LMR98, Kap. 2.2]. Der Abbruch bei einer endlichen größten Skala J ist dabei nötig, denn ein nichtverschwindender Mittelwert wird durch P_j nicht beseitigt, sondern nur immer weiter auseinandergezogen; für die Treppenfunktion aus Beispiel 3.15 ist etwa $P_j f = 18 \cdot 2^{-j} \mathbf{1}_{[0, 2^j[}$ für alle $j \geq 2$. Am EKG beobachten Louis, Maaß und Rieder, dass die feinste Detailstufe fast das gesamte Rauschen aufnimmt, während die gröberen Stufen den Signalverlauf tragen [LMR98, Kap. 3.1.2].

3.4.1. Die Wavelet-Basis

Satz 3.23 sagt noch nichts darüber, wie eine Basis von W_j aussieht. Da V_{-1} zwei Basisfunktionen pro Zeiteinheit besitzt und V_0 eine, liegt es nahe, W_0 ebenfalls durch die ganzzahligen Verschiebungen einer einzigen Funktion ψ aufzuspannen [Bla03, Kap. 5.1]. Dass es ein solches ψ gibt, wird in Kapitel 4 gezeigt [LMR98, Satz 2.2.10]; im Haar-Fall ist es ψ^H , wie Beispiel 3.15 bereits nahelegt [LMR98, Kap. 2.2].

Korollar 3.24 (Wavelet-Basis, [Bla03, Kap. 5.1]). *Sei $(V_j)_{j \in \mathbb{Z}}$ eine MSA, und sei $\psi \in L^2(\mathbb{R})$ so, dass $\{\psi(\cdot - k) : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_0 ist. Mit $\psi_{j,k}$ wie in (3.8) gilt dann:*

(i) *Für jedes feste $j \in \mathbb{Z}$ ist $\{\psi_{j,k} : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_j .*

(ii) *Die Familie*

$$\{\psi_{j,k} : j, k \in \mathbb{Z}\} \quad (3.17)$$

ist eine Orthonormalbasis von $L^2(\mathbb{R})$, die Wavelet-Basis der MSA.

(iii) *Mit den Detailkoeffizienten $d_{j,k} := \langle f, \psi_{j,k} \rangle$ gilt für jedes $f \in L^2(\mathbb{R})$ und jedes $J \in \mathbb{Z}$*

$$f = \sum_{k \in \mathbb{Z}} a_{J,k} \varphi_{J,k} + \sum_{j \leq J} \sum_{k \in \mathbb{Z}} d_{j,k} \psi_{j,k}, \quad \|f\|^2 = \sum_{k \in \mathbb{Z}} |a_{J,k}|^2 + \sum_{j \leq J} \sum_{k \in \mathbb{Z}} |d_{j,k}|^2. \quad (3.18)$$

Aussage (i) folgt wie Satz 3.19 aus (3.13). Nach (i) ist $Q_j f = \sum_k d_{j,k} \psi_{j,k}$, und damit folgen (ii) und (iii) aus Satz 3.23 und (3.11) [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.13)].

Beispiel 3.25 (Wavelet-Koeffizienten der Treppenfunktion). Wir zerlegen die Treppenfunktion $f = (4, 2, 5, 7)$ aus Beispiel 3.15 in der Haar-Wavelet-Basis, also mit $\psi = \psi^H$ [LMR98, Kap. 2.2]. Da $\psi_{j,k}$ auf der linken Hälfte von $I_{j,k} = [k2^j, (k+1)2^j[$ den Wert $2^{-j/2}$ und auf der rechten

den Wert $-2^{-j/2}$ annimmt, ist $d_{j,k}$ das $2^{-j/2}$ -Fache der Differenz der Integrale von f über die beiden Hälften. Für $J = 2$ erhält man

$$a_{2,0} = \frac{1}{2}(4+2+5+7) = 9, \quad d_{2,0} = \frac{1}{2}((4+2)-(5+7)) = -3, \quad d_{1,0} = \frac{4-2}{\sqrt{2}} = \sqrt{2}, \quad d_{1,1} = \frac{5-7}{\sqrt{2}} = -\sqrt{2},$$

alle übrigen Koeffizienten mit $j \leq 2$ verschwinden, weil ihre Träger f nicht treffen oder f dort konstant ist. Nach (3.18) ist also

$$f = 9\varphi_{2,0} - 3\psi_{2,0} + \sqrt{2}\psi_{1,0} - \sqrt{2}\psi_{1,1}, \quad \|f\|^2 = 81 + 9 + 2 + 2 = 94.$$

Bis auf den Normierungsfaktor $2^{j/2}$ sind das die Zahlen 4,5, $-1,5$, 1 und -1 aus Beispiel 3.15.

Zwei Beobachtungen verbinden das Beispiel mit dem Rest der Arbeit. Erstens ist nach Definition 3.14 $d_{j,k} = \langle f, \psi_{2^j, k2^j} \rangle = W_\psi f(2^j, k2^j)$: Die Detailkoeffizienten sind die Werte der CWT auf dem dyadischen Gitter, aber ohne deren Redundanz (Bemerkung 3.13) – vier Funktionswerte ergeben vier Koeffizienten. Zweitens: Setzt man die beiden betragskleinsten Koeffizienten $d_{1,0}$ und $d_{1,1}$ auf null, so bleibt $9\varphi_{2,0} - 3\psi_{2,0} = P_1 f = (3, 3, 6, 6)$, und nach der Energiegleichung ist der Fehler genau die Summe der Quadrate der gestrichenen Koeffizienten, $\|f - P_1 f\|^2 = 2 + 2 = 4$. Welche Koeffizienten man streicht, lässt sich also allein im Koeffizientenraum entscheiden; darauf beruht die Entrauschung in Kapitel 5.

Gleichung (3.18) ist der Ausgangspunkt der beiden folgenden Kapitel. Kapitel 4 konstruiert ψ und berechnet die Koeffizienten allein durch Filteroperationen aus denen der feinsten Skala; der Schlüssel ist die Inklusion $\varphi \in V_0 \subset V_{-1}$, die auf die Skalierungsgleichung führt [LMR98, Lemma 2.2.3], [Bla03, Satz (5.3)]. Kapitel 5 nutzt, dass $f \mapsto (a_{J,k}, d_{j,k})$ nach der Energiegleichung eine Isometrie ist.

Anmerkung. Die Energiegleichung (3.18) ist das, was Abschnitt 5.1 braucht: Die Wavelet-Koeffizienten sind Koordinaten bezüglich einer Orthonormalbasis.

4. Konstruktion der diskreten Wavelet-Transformation

Kapitel 3 endete mit einer bedingten Aussage: Gibt es eine Funktion ψ , deren um ganze Zahlen verschobene Kopien $\psi(\cdot - k)$, $k \in \mathbb{Z}$, eine Orthonormalbasis von W_0 bilden, so ist $\{\psi_{j,k}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ (Korollar 3.24). Dieses Kapitel konstruiert ein solches ψ und beantwortet dabei drei Fragen: Wie erhält man ψ aus φ ? Wie berechnet man die Koeffizienten $a_{j,k}$ und $d_{j,k}$, ohne ein einziges Integral auszuwerten? Und welche Wavelets eignen sich für Signale wie das EKG? Alle drei Antworten stecken in einer einzigen Zahlenfolge $(h_k)_{k \in \mathbb{Z}}$. Begleitet wird das Kapitel von zwei Beispielen: dem Haar-Wavelet aus Kapitel 3 und dem Daubechies-Wavelet mit vier Koeffizienten, das in Kapitel 6 verwendet wird.

4.1. Die Skalierungsgleichung

Belegstellen. LMR, Lemma 2.2.3, S. 113 [bestätigt]; LMR, Gl. (2.2.23), (2.2.24) und Satz 2.2.9, S. 121 [bestätigt]; LMR, Anhang, S. 314 [bestätigt]; Serov, Satz 25.18, S. 257–258 [bestätigt]; Blatter, Kap. 5.2, Gl. (1), S. 110 [bestätigt], bewiesen in Satz (5.8) [Seite nachtragen]; Blatter, Satz (5.3), S. 111 [bestätigt].

In diesem Abschnitt wird die Skalierungsfunktion φ durch eine Zahlenfolge (h_k) beschrieben, und es werden zwei Bedingungen an diese Folge hergeleitet. Alles Weitere in diesem Kapitel wird nur noch mit den h_k rechnen; die Funktionen φ und ψ selbst werden dafür nicht mehr benötigt.

Nach (M1) ist $\varphi \in V_0 \subset V_{-1}$, und nach Satz 3.19 bilden die Funktionen $\varphi_{-1,k}(t) = \sqrt{2} \varphi(2t - k)$ eine Orthonormalbasis von V_{-1} . Also lässt sich φ in dieser Basis darstellen:

$$\varphi = \sum_{k \in \mathbb{Z}} \langle \varphi, \varphi_{-1,k} \rangle \varphi_{-1,k}.$$

Rechts steht eine gewichtete Summe der Funktionen $\varphi(2t - k)$. Jede davon ist eine Kopie von φ , die um den Faktor 2 zusammengedrückt und um $k/2$ verschoben ist, denn $\varphi(2t - k) = \varphi(2(t - k/2))$. Die Skalierungsfunktion lässt sich also aus schmalere Kopien ihrer selbst zusammensetzen.

Satz 4.1 (Skalierungsgleichung, vgl. [LMR98, Lemma 2.2.3]). Sei $(V_j)_{j \in \mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ . Mit $h_k := \langle \varphi, \varphi_{-1,k} \rangle$ gilt

$$\varphi(t) = \sqrt{2} \sum_{k \in \mathbb{Z}} h_k \varphi(2t - k) \quad \text{für fast alle } t \in \mathbb{R} \quad \text{und} \quad \sum_{k \in \mathbb{Z}} |h_k|^2 = 1, \quad (4.1)$$

wobei die Reihe in $L^2(\mathbb{R})$ konvergiert. Die Folge (h_k) heißt Skalierungsfolge oder Tiefpassfilter der MSA.

Beweis. Nach (M1) liegt φ in V_{-1} , und $\{\varphi_{-1,k}\}_k$ ist nach Satz 3.19 eine Orthonormalbasis von V_{-1} . Die Fourier-Entwicklung in dieser Basis [Ser17, Satz 25.18 (3)] lautet $\varphi = \sum_k h_k \varphi_{-1,k}$ mit $h_k \varphi_{-1,k}(t) = \sqrt{2} h_k \varphi(2t - k)$. Nach der Parseval-Gleichung [Ser17, Satz 25.18 (5)] ist $\sum_k |h_k|^2 = \|\varphi\|^2 = 1$, denn φ ist nach (M5) selbst Element der Orthonormalbasis $\{\varphi(\cdot - k)\}_k$ von V_0 . $\square$

Beispiel 4.2 (Haar). Für $\varphi = \mathbf{1}_{[0,1]}$ aus Beispiel 3.18 ist $\varphi(2t) = \mathbf{1}_{[0,1/2]}$ und $\varphi(2t - 1) = \mathbf{1}_{[1/2,1]}$. Eine Stufe der Breite 1 besteht also aus zwei Stufen der Breite $\frac{1}{2}$:

$$\varphi(t) = \varphi(2t) + \varphi(2t - 1) = \sqrt{2} \left(\frac{1}{\sqrt{2}} \varphi(2t) + \frac{1}{\sqrt{2}} \varphi(2t - 1) \right).$$

Der Vergleich mit (4.1) liefert $h_0 = h_1 = \frac{1}{\sqrt{2}}$ und $h_k = 0$ sonst, in Übereinstimmung mit $h_0 = \langle \varphi, \varphi_{-1,0} \rangle = \sqrt{2} \cdot \frac{1}{2}$ und $\sum_k |h_k|^2 = 1$.

Aus der Skalierungsgleichung folgt eine zweite Bedingung an (h_k) , die man im Frequenzbereich sieht; dabei sei $\sum_k |h_k| < \infty$, was für endliche Filter stets gilt. Nach den Rechenregeln der Fourier-Transformation für Stauchung und Verschiebung [LMR98, Anhang] ist $\widehat{\varphi_{-1,k}}(\omega) = \frac{1}{\sqrt{2}} e^{-ik\omega/2} \hat{\varphi}(\frac{\omega}{2})$. Transformiert man $\varphi = \sum_k h_k \varphi_{-1,k}$ gliedweise und zieht den von k unabhängigen Faktor $\hat{\varphi}(\omega/2)$ vor die Summe, so wird die Skalierungsgleichung mit dem 2π -periodischen Fourier-Filter

$$H(\omega) := \frac{1}{\sqrt{2}} \sum_{k \in \mathbb{Z}} h_k e^{-ik\omega} \quad (4.2)$$

zu einem Produkt [LMR98, Gl. (2.2.23)]:

$$\hat{\varphi}(\omega) = H\left(\frac{\omega}{2}\right) \hat{\varphi}\left(\frac{\omega}{2}\right), \quad \omega \in \mathbb{R}. \quad (4.3)$$

Für die hier betrachteten MSA ist $|\hat{\varphi}(0)| = (2\pi)^{-1/2}$, insbesondere $\hat{\varphi}(0) \neq 0$ [Bla03, Kap. 5.2]. Da beide Seiten von (4.3) stetig sind, darf man $\omega = 0$ einsetzen; Division durch $\hat{\varphi}(0)$ ergibt

$$H(0) = 1, \quad \text{das heißt} \quad \sum_{k \in \mathbb{Z}} h_k = \sqrt{2}, \quad (4.4)$$

im Haar-Fall $\frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} = \sqrt{2}$; vgl. [LMR98, Satz 2.2.9].

4.2. Filterkoeffizienten: Tiefpass und Hochpass

Belegstellen. LMR, Lemma 2.2.8, Gl. (2.2.22) [Seite nachtragen, vermutl. S. 120–121]; LMR, Satz 2.2.10, S. 122, Beweis S. 122–123 [bestätigt]; LMR, Beispiel S. 169 und Tabelle 2.3, S. 170 [bestätigt], dort umgekehrte Reihenfolge wegen $e^{+ik\omega}$; Serov, Satz 25.18, S. 257–258 [bestätigt]; Blatter, Kap. 5.2, S. 110–116 [bestätigt].

Bisher wurde die Folge (h_k) aus einer gegebenen Skalierungsfunktion gewonnen. Für die Konstruktion neuer Wavelets geht man umgekehrt vor: Man wählt die Zahlen h_k und erhält φ und ψ daraus. Dafür muss man wissen, welche Bedingungen eine Folge erfüllen muss, um zu einer MSA zu gehören. Neben (4.4) übersetzt sich auch die Orthonormalität der Verschiebungen $\varphi(\cdot - k)$ aus (M5) in eine Bedingung an die Folge selbst.

Lemma 4.3 (Orthogonalität der Filterkoeffizienten, vgl. [LMR98, Lemma 2.2.8]). Die Skalierungsfolge einer MSA erfüllt

$$\sum_{n \in \mathbb{Z}} h_n \overline{h_{n-2m}} = \delta_{m,0} \quad \text{für alle } m \in \mathbb{Z}. \quad (4.5)$$

Beweis. Ersetzt man in (4.1) t durch $t - m$ und setzt $n = k + 2m$, so wird $\varphi(t - m) = \sqrt{2} \sum_k h_k \varphi(2t - 2m - k) = \sum_n h_{n-2m} \varphi_{-1,n}(t)$. Die Vollständigkeitsrelation in V_{-1} [Ser17, Satz 25.18 (4)] und (M5) liefern $\delta_{m,0} = \langle \varphi, \varphi(\cdot - m) \rangle = \sum_n h_n \overline{h_{n-2m}}$. $\square$

Anschaulich: Die Basisfunktionen $\varphi_{-1,n}$ liegen im Abstand $\frac{1}{2}$. Verschiebt man φ um 1, so rückt ihr Koeffizientenvektor (h_n) deshalb um zwei Stellen weiter. Die Orthogonalität der verschobenen Funktionen wird so zur Orthogonalität des Vektors (h_n) zu seinen um gerade Schrittweiten verschobenen Kopien. Für das Haar-Filter ist das trivial, denn für $m \neq 0$ überlappen (h_n) und (h_{n-2m}) nicht.

Beispiel 4.4 (Ein Filter der Länge vier). Gesucht seien reelle $h_0, \dots, h_3$, alle übrigen null. Die Bedingungen (4.4) und (4.5) lauten

$$h_0 + h_1 + h_2 + h_3 = \sqrt{2}, \quad h_0^2 + h_1^2 + h_2^2 + h_3^2 = 1, \quad h_0 h_2 + h_1 h_3 = 0;$$

für $|m| \geq 2$ überlappen die Folgen nicht. Drei Gleichungen für vier Unbekannte lassen eine einparametrische Lösungsschar, zu der auch das Haar-Filter $(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}, 0, 0)$ gehört. Eine weitere Lösung ist

$$h_0 = \frac{1+\sqrt{3}}{4\sqrt{2}}, \quad h_1 = \frac{3+\sqrt{3}}{4\sqrt{2}}, \quad h_2 = \frac{3-\sqrt{3}}{4\sqrt{2}}, \quad h_3 = \frac{1-\sqrt{3}}{4\sqrt{2}} \quad (4.6)$$

[LMR98, Tabelle 2.3], dort in umgekehrter Reihenfolge. Zur Probe: Die Zähler summieren sich zu 8, also $\sum h_k = 8/(4\sqrt{2}) = \sqrt{2}$. Die quadrierten Zähler ergeben $(4 + 2\sqrt{3}) + (12 + 6\sqrt{3}) + (12 - 6\sqrt{3}) + (4 - 2\sqrt{3}) = 32 = (4\sqrt{2})^2$, also $\sum h_k^2 = 1$. Schließlich ist $(1 + \sqrt{3})(3 - \sqrt{3}) + (3 + \sqrt{3})(1 - \sqrt{3}) = 2\sqrt{3} - 2\sqrt{3} = 0$. Warum gerade diese Lösung aus der Schar ausgewählt wird, klärt Abschnitt 4.5.

Im Haar-Fall haben die Zahlen h_k eine einfache Bedeutung: Mit $h_0 = h_1 = \frac{1}{\sqrt{2}}$ bildet (h_k) aus zwei benachbarten Werten deren (normierten) Mittelwert, wie in Beispiel 3.15. Konstante Signale bleiben dabei erhalten, rasche Schwankungen werden geglättet; daher der Name Tiefpass. Das Gegenstück, das in Beispiel 3.15 die verlorenen Details liefert, ist die Differenz benachbarter Werte. Sie verschwindet für konstante Signale und heißt Hochpass. Für allgemeine (h_k) gewinnt man die Hochpassfolge durch Umkehren der Reihenfolge und alternierende Vorzeichen.

Satz 4.5 (Wavelet aus der Skalierungsfolge, vgl. [LMR98, Satz 2.2.10]). Sei (V_j) eine MSA mit Skalierungsfolge (h_k) . Setzt man

$$g_k := (-1)^k \overline{h_{1-k}}, \quad \psi(t) := \sqrt{2} \sum_{k \in \mathbb{Z}} g_k \varphi(2t - k), \quad (4.7)$$

so ist $\{\psi(\cdot - k) : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_0 . Nach Korollar 3.24 ist dann $\{\psi_{j,k} : j, k \in \mathbb{Z}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$.

Der vollständige Beweis steht bei [LMR98, Satz 2.2.10].

Beispiel 4.6 (Haar, Fortsetzung). Aus $h_0 = h_1 = 1/\sqrt{2}$ folgt $g_0 = h_1 = 1/\sqrt{2}$ und $g_1 = -h_0 = -1/\sqrt{2}$, also

$$\psi(t) = \varphi(2t) - \varphi(2t - 1) = \mathbf{1}_{[0,1/2[}(t) - \mathbf{1}_{[1/2,1[}(t) = \psi^H(t).$$

Damit ist ψ^H als Wavelet der Haar-MSA nachgewiesen, wie es Beispiel 3.15 nahegelegt hatte. Für die Folge (4.6) ist entsprechend $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$.

4.3. Bedingungen im Fourier-Bereich

Belegstellen. LMR, Satz 2.2.9, S. 121 [bestätigt]; LMR, Korollar 2.2.12, S. 123 [bestätigt]; LMR, Bem. 2.4.19, S. 165 [bestätigt]; LMR, Kap. 2.4.2, S. 145–164 [bestätigt].

In Abschnitt 4.2 wurden die Namen Tiefpass und Hochpass nur am Haar-Filter begründet. Für beliebige Filter liefert das Fourier-Filter H aus (4.2) die Begründung. Es gibt an, wie stark der Filter eine Schwingung der Frequenz ω durchlässt: Für $x_n = e^{i\omega n}$ ist $\sum_k h_k x_{n-k} = \sqrt{2} H(\omega) x_n$. Für $\omega = 0$ ist $x_n = 1$ konstant, für $\omega = \pi$ ist $x_n = (-1)^n$, die Folge wechselt also bei jedem Schritt das Vorzeichen. Schneller kann eine abgetastete Schwingung nicht oszillieren, da $e^{i(\omega+2\pi)n} = e^{i\omega n}$ gilt. Wie in Abschnitt 4.1 sei $\sum_k |h_k| < \infty$.

Satz 4.7 (Bedingungen an das Fourier-Filter, [LMR98, Satz 2.2.9]). *Das Fourier-Filter (4.2) einer MSA erfüllt*

$$H(0) = 1 \quad \text{und} \quad |H(\omega)|^2 + |H(\omega + \pi)|^2 = 1 \quad \text{für alle } \omega \in \mathbb{R}. \quad (4.8)$$

Die erste Gleichung ist (4.4). Die zweite ist Lemma 4.3, in den Frequenzbereich übersetzt: Die unendlich vielen Gleichungen für die Zahlen h_k werden zu einer einzigen Gleichung für die Funktion H . Umgekehrt liefert jede endliche Folge mit (4.8), deren Fourier-Filter auf $[-\pi/2, \pi/2]$ keine Nullstelle hat, eine Lösung φ der Skalierungsgleichung mit orthonormalen Verschiebungen $\varphi(\cdot - k)$ [LMR98, Satz 2.4.7].

Für die Hochpassfolge (g_k) aus (4.7) setzt man analog $G(\omega) := 2^{-1/2} \sum_k g_k e^{-ik\omega}$. Die Substitution $n = 1 - k$ ergibt

$$G(\omega) = -e^{-i\omega} \overline{H(\omega + \pi)}, \quad \hat{\psi}(\omega) = G\left(\frac{\omega}{2}\right) \hat{\varphi}\left(\frac{\omega}{2}\right) \quad (4.9)$$

[LMR98, Korollar 2.2.12], also $|G(\omega)| = |H(\omega + \pi)|$. Aus (4.8) und (4.9) folgen drei Aussagen:

- (a) $H(0) = 1$ und $H(\pi) = 0$: (h_k) lässt konstante Signale vollständig durch und löscht die schnellste Schwingung aus. Das ist ein Tiefpass.
- (b) $G(0) = 0$ und $|G(\pi)| = 1$: (g_k) verhält sich genau umgekehrt. Das ist ein Hochpass. Wegen $\hat{\psi}(0) = G(0) \hat{\varphi}(0) = 0$ hat ψ Mittelwert null, wie es Satz 3.2 von einem zulässigen Wavelet verlangt; zulässig ist ψ tatsächlich stets [LMR98, Satz 2.2.10 (iii)].
- (c) $|H(\omega)|^2 + |G(\omega)|^2 = 1$: Jede Frequenz wird vollständig auf die beiden Filter aufgeteilt, es geht nichts verloren. In der Signalverarbeitung heißen solche Filterpaare Conjugate Quadrature Filter [LMR98, Bem. 2.4.19].

Abbildung 4.1 zeigt beide Filter. Beim Haar-Filter ist $|H(\omega)| = |\cos(\omega/2)|$ und die Nullstelle bei $\omega = \pi$ einfach. Für (4.6) ist $|H(\omega)|^2 = \cos^4(\omega/2) (1 + 2 \sin^2(\omega/2))$, vgl. [LMR98, Kap. 2.4.3], die Nullstelle also doppelt, und die Kurven verlaufen an den Rändern flacher. Abschnitt 4.5 zeigt, dass genau diese Ordnung der Nullstelle bestimmt, wie gut sich ein Wavelet für glatte Signalabschnitte eignet.




Abbildung 4.1.: Betrag der Fourier-Filter H (Tiefpass) und G (Hochpass) für das Haar-Filter (gestrichelt) und das Filter (4.6) (durchgezogen) auf $[0, \pi]$. In beiden Fällen ist $|H|^2 + |G|^2 = 1$.

4.4. Der Mallat-Algorithmus

Belegstellen. Blatter, Kap. 5.4, S. 130–136 [bestätigt], insb. Skalierungsgleichungen 5.4.(1)/(2), S. 130 [bestätigt], Zwei-Skalen-Relation 5.4.(3)/(4) mit Herleitung, S. 131 [bestätigt], Analyseformeln (eingerahmt, unnummeriert), S. 132–133 [bestätigt]; LMR, Kap. 2.3, S. 132–141 [bestätigt], insb. Analyseformeln (unnummeriert, mit Verweis auf Skalierungsgl. (2.2.8)/(2.2.27)), S. 133 [bestätigt], Gl. (2.3.1)/(2.3.2), S. 133 [bestätigt], Abb. 2.8, S. 134 [bestätigt]; Aufwand: Blatter, Kap. 5.4, S. 133–135 [bestätigt], Hanke-Bourgeois, § 56, S. 438 [bestätigt]; LMR, Kap. 3.1.1, S. 237–238 [bestätigt].

Bisher erfordert jeder Koeffizient

$$a_{j,k} = \langle f, \varphi_{j,k} \rangle = \int_{\mathbb{R}} f(t) \varphi_{j,k}(t) dt, \quad d_{j,k} = \langle f, \psi_{j,k} \rangle = \int_{\mathbb{R}} f(t) \psi_{j,k}(t) dt$$

(Definition 3.20, Korollar 3.24) ein eigenes Integral. Nach [Bla03, Kap. 5.4] und [LMR98, Kap. 2.3, Abb. 2.8] lassen sich $a_{j,\cdot}$ und $d_{j,\cdot}$ jedoch allein aus $a_{j-1,\cdot}$ und den Filtern h, g berechnen. Grundlage dafür ist die folgende Darstellung der Basisfunktionen der Skala j durch die der feineren Skala $j-1$.

Lemma 4.8 (Zwei-Skalen-Relation, [Bla03, Kap. 5.4, (3), (4)]). Für alle $j, k \in \mathbb{Z}$ gilt

$$\varphi_{j,k} = \sum_{n \in \mathbb{Z}} h_{n-2k} \varphi_{j-1,n}, \quad \psi_{j,k} = \sum_{n \in \mathbb{Z}} g_{n-2k} \varphi_{j-1,n}. \quad (4.10)$$

Für einen Beweis siehe [Bla03, Kap. 5.4]. Bildet man in (4.10) das Skalarprodukt mit f , so überträgt sich die Relation auf die Koeffizienten.

Satz 4.9 (Analyseschritt, [Bla03, Kap. 5.4]). Für reelle Filter h, g und alle $j, k \in \mathbb{Z}$ gilt

$$a_{j,k} = \sum_{n \in \mathbb{Z}} h_{n-2k} a_{j-1,n}, \quad d_{j,k} = \sum_{n \in \mathbb{Z}} g_{n-2k} a_{j-1,n}. \quad (4.11)$$

Beweis. Vgl. [Bla03, Kap. 5.4]. Die Reihe in (4.10) konvergiert in $L^2(\mathbb{R})$, da $(h_n) \in \ell^2(\mathbb{Z})$ und $\{\varphi_{j-1,n}\}_{n \in \mathbb{Z}}$ orthonormal ist. Wegen der Stetigkeit des Skalarprodukts und $h_n \in \mathbb{R}$ folgt

$$a_{j,k} = \left\langle f, \sum_n h_{n-2k} \varphi_{j-1,n} \right\rangle = \sum_n h_{n-2k} \langle f, \varphi_{j-1,n} \rangle = \sum_n h_{n-2k} a_{j-1,n}.$$

Analog für $d_{j,k}$ mit g . □

Die Koeffizienten der Skala j sind also gewichtete Summen der Approximationskoeffizienten der Skala $j-1$; Integrale treten nur noch bei der Berechnung der Startwerte $a_{0,\cdot}$ auf.

Haben h und g jeweils höchstens L von Null verschiedene Einträge, so sind die Summen in (4.11) endlich: Jeder Koeffizient $a_{j,k}$ bzw. $d_{j,k}$ erfordert höchstens L Multiplikationen, vgl. [Bla03, Kap. 5.4]. Da die Gewichte mit $k \mapsto k+1$ um zwei Indizes weiterrücken, halbiert sich zudem die Anzahl der Koeffizienten von Skala zu Skala bis auf einen Randterm der Größe $L-2$, vgl. [Bla03, Kap. 5.4, (7)].

Algorithmus 1 Schnelle Wavelet-Transformation, vgl. [Bla03, Kap. 5.4], [LMR98, Kap. 2.3, Abb. 2.8]

Eingabe: Startfolge $a_{0,\cdot}$, Filter h, g , Tiefe $J \in \mathbb{N}$

Ausgabe: Detailfolgen $d_{1,\cdot}, \dots, d_{J,\cdot}$ und Approximation $a_{J,\cdot}$.

```

1: für  $j = 1, \dots, J$  tue
2:   für alle  $k$  tue
3:      $a_{j,k} \leftarrow \sum_n h_{n-2k} a_{j-1,n}$ 
4:      $d_{j,k} \leftarrow \sum_n g_{n-2k} a_{j-1,n}$ 
5:   Ende für
6: Ende für
7: Rückgabe  $d_{1,\cdot}, \dots, d_{J,\cdot}, a_{J,\cdot}$ 

```




Abbildung 4.2.: Ablauf von Algorithmus 1, in Anlehnung an [Bla03, Kap. 5.4, (6)]; vgl. auch [LMR98, Abb. 2.8]. Jeder Pfeil ist ein Rechenschritt nach (4.11) mit dem Filter h bzw. g und halbiert die Anzahl der Werte. Nur die Approximationskoeffizienten werden weiter zerlegt.

Beispiel 4.10 (Haar, Fortsetzung von Beispiel 3.25). Für das Haar-Filter $h_0 = h_1 = \frac{1}{\sqrt{2}}$ liefert (4.7) $g_0 = \frac{1}{\sqrt{2}}, g_1 = -\frac{1}{\sqrt{2}}$; alle übrigen h_k, g_k verschwinden. In (4.11) bleiben daher nur die Summanden $n = 2k$ und $n = 2k + 1$:

$$a_{j,k} = \frac{a_{j-1,2k} + a_{j-1,2k+1}}{\sqrt{2}}, \quad d_{j,k} = \frac{a_{j-1,2k} - a_{j-1,2k+1}}{\sqrt{2}},$$

also genau Mitteln und Differenzbildern aus Beispiel 3.15. Für die Treppenfunktion $f = (4, 2, 5, 7)$ der Haar-MSA ist $a_{0,k} = f(k)$. Die erste Stufe liefert $a_1 = (\frac{6}{\sqrt{2}}, \frac{12}{\sqrt{2}}) = (3\sqrt{2}, 6\sqrt{2})$ und $d_1 = (\sqrt{2}, -\sqrt{2})$, die zweite $a_{2,0} = 9$ und $d_{2,0} = -3$. Das sind genau die Koeffizienten aus Beispiel 3.25, nun ohne ein einziges Integral berechnet.

Der Aufwand ist gering. Hat der Filter die Länge L , kostet eine Stufe mit N Eingangswerten etwa LN Multiplikationen. Da sich die Anzahl der Werte von Stufe zu Stufe ungefähr halbiert, sind es insgesamt etwa $L(N + N/2 + N/4 + \dots) \approx 2LN$, also $O(N)$ Operationen [Bla03, Kap. 5.4]. Die schnelle Fourier-Transformation braucht dagegen $O(N \log N)$ [HB09, § 53].

Jeder Schritt lässt sich exakt rückgängig machen.

Satz 4.11 (Rekonstruktion, [Bla03, Kap. 5.4]). Für alle $j, n \in \mathbb{Z}$ gilt

$$a_{j-1,n} = \sum_{k \in \mathbb{Z}} h_{n-2k} a_{j,k} + \sum_{k \in \mathbb{Z}} g_{n-2k} d_{j,k}. \quad (4.12)$$

Beweis. Nach Definition 3.22 und Korollar 3.24 ist $P_{j-1}f = P_j f + Q_j f = \sum_k a_{j,k} \varphi_{j,k} + \sum_k d_{j,k} \psi_{j,k}$. Skalarprodukt mit $\varphi_{j-1,n}$ und Lemma 4.8 liefern (4.12), vgl. [Bla03, Kap. 5.4]. $\square$

Im Haar-Fall wird daraus $a_{j-1,2k} = (a_{j,k} + d_{j,k})/\sqrt{2}$ und $a_{j-1,2k+1} = (a_{j,k} - d_{j,k})/\sqrt{2}$, im Beispiel $(3\sqrt{2} \pm \sqrt{2})/\sqrt{2} = 4$ bzw. 2 . Auch die Rekonstruktion kostet nur $O(N)$ Operationen, bleibt also weiterhin linear [Bla03, Kap. 5.4].

Bemerkung 4.12. Jeder Schritt $a_{j-1,\cdot} \mapsto (a_{j,\cdot}, d_{j,\cdot})$ von Algorithmus 1 ersetzt die Orthonormalbasis $\{\varphi_{j-1,n}\}_n$ von V_{j-1} durch die Orthonormalbasis $\{\varphi_{j,k}\}_k \cup \{\psi_{j,k}\}_k$ [Bla03, Kap. 5.4]. Die Parseval-Gleichung [Ser17, Satz 25.18 (5)], angewandt auf $P_{j-1}f$ in beiden Basen, liefert

$$\sum_n |a_{j-1,n}|^2 = \|P_{j-1}f\|^2 = \sum_k |a_{j,k}|^2 + \sum_k |d_{j,k}|^2,$$

im Beispiel $4^2 + 2^2 = 20 = (3\sqrt{2})^2 + (\sqrt{2})^2$. Ein Schritt ist also eine orthogonale Abbildung der Koeffizientenfolgen; genau diese Eigenschaft wird in Abschnitt 5.1 gebraucht.

In der Anwendung ist f nicht bekannt, sondern nur durch Abtastwerte gegeben. Diese werden als Koeffizienten $a_{0,k}$ der feinsten Skala verwendet [Bla03, Kap. 5.4]; wie ein endliches Signal dabei am Rand fortgesetzt wird, beschreibt Abschnitt 5.1.

4.5. Daubechies-Wavelets

Belegstellen. Blatter, Kap. 3.5, S. 74 [bestätigt]; LMR, Lemma 2.4.30, S. 176 [bestätigt]; LMR, Satz 2.4.9, S. 153 [bestätigt]; LMR, Kap. 2.4.4, S. 173–175 [bestätigt], insb. Satz 2.4.28 (Momente), S. 174, Träger von ψ_N , S. 175, Regularität H^{α_N} , $\alpha > 0,2$, S. 173; Blatter, Kap. 6.2, S. 146–151 [bestätigt]; Blatter, Kap. 6.3, S. 158 [bestätigt]; Rebstadt, Kap. 2.3.1, S. 16–20 [bestätigt].

Die Formeln des Mallat-Algorithmus gelten für die Skalierungsfolge jeder MSA; offen ist aber, welche man wählen soll. Das Haar-Filter erzeugt selbst auf glatten Signalabschnitten von null verschiedene Detailkoeffizienten. Gesucht sind daher kurze Filter, deren Wavelet glatte Abschnitte möglichst nicht sieht. Die dafür entscheidende Eigenschaft ist die folgende.

Definition 4.13 (Verschwindende Momente, vgl. [Bla03, Kap. 3.5]). Ein Wavelet ψ mit kompaktem Träger hat p verschwindende Momente,¹ falls

$$\int_{\mathbb{R}} t^m \psi(t) dt = 0 \quad \text{für } m = 0, 1, \dots, p-1.$$

Das Moment $m = 0$ ist die Zulässigkeitsbedingung aus Satz 3.2. Allgemein ist $\int_{\mathbb{R}} q(t) \psi_{j,k}(t) dt = 0$ für jedes Polynom q vom Grad $< p$: Das Wavelet sieht Polynome niedrigen Grades nicht. Wie sich das im Mallat-Algorithmus auswirkt, zeigt das folgende Beispiel.

Beispiel 4.14 (Ein lineares Signal). Nach (4.11) liefert die linear ansteigende Folge $a_{0,n} = n$ die Detailkoeffizienten

$$d_{1,k} = \sum_m g_m (m + 2k) = \sum_m m g_m + 2k \sum_m g_m.$$

Für Haar ist $g_0 = -g_1 = 1/\sqrt{2}$ (Beispiel 4.6), also $\sum_m g_m = 0$, aber $\sum_m m g_m = g_1 = -1/\sqrt{2}$. Damit ist $d_{1,k} = -1/\sqrt{2}$ für jedes k , obwohl das Signal überall gleichmäßig ansteigt und weder Spitzen noch Knicke besitzt. Für die Koeffizienten $h_0, \dots, h_3$ aus (4.6) ist $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$, und es gilt

$$\begin{aligned} 4\sqrt{2} \sum_m g_m &= (1 - \sqrt{3}) - (3 - \sqrt{3}) + (3 + \sqrt{3}) - (1 + \sqrt{3}) = 0, \\ 4\sqrt{2} \sum_m m g_m &= -2(1 - \sqrt{3}) + (3 - \sqrt{3}) - (1 + \sqrt{3}) = 0, \end{aligned}$$

also $d_{1,k} = 0$: Lineare Abschnitte landen vollständig in den Approximationskoeffizienten, vgl. [LMR98, Lemma 2.4.29]. Damit ist auch die Frage aus Beispiel 4.4 beantwortet: Die Folge (4.6) ist das Daubechies-Filter mit zwei verschwindenden Momenten [Bla03, Kap. 6.3], das Haar-Filter aus derselben Schar hat nur eines.

Für glatte, nicht polynomiale Signale gilt das näherungsweise, umso besser, je feiner die Skala ist.

Lemma 4.15 (Abklingen der Detailkoeffizienten, vgl. [LMR98, Beweis von Lemma 2.4.30]). Sei ψ ein Wavelet mit p verschwindenden Momenten und $\text{supp } \psi = [\alpha, \beta] \ni 0$. Ist f auf $I_{j,k} := \text{supp } \psi_{j,k}$ p -mal stetig differenzierbar mit $|f^{(p)}| \leq M_{j,k}$, so gilt

$$|d_{j,k}| \leq 2^{j(p+1/2)} \frac{M_{j,k}}{p!} \int_{\mathbb{R}} |t^p \psi(t)| dt.$$

¹Wie bei Mallat bezeichnet p die Zahl der Momente; N bleibt der Signallänge vorbehalten.

Beweis. Die Substitution $x = 2^j(t + k)$ ergibt $d_{j,k} = 2^{j/2} \int_{\mathbb{R}} f(2^j k + 2^j t) \psi(t) dt$. Nach Taylor [LMR98, (2.4.20)] ist $f(2^j k + 2^j t) = q(t) + R(t)$ mit einem Polynom q vom Grad $< p$ und dem Rest $R(t) = \frac{1}{p!} f^{(p)}(\eta_t) (2^j t)^p$, $\eta_t \in I_{j,k}$. Wegen der verschwindenden Momente ist $\int_{\mathbb{R}} q \psi dt = 0$, also $d_{j,k} = 2^{j/2} \int_{\mathbb{R}} R(t) \psi(t) dt$, und $|R(t)| \leq \frac{M_{j,k}}{p!} 2^{jp} |t|^p$ liefert die Behauptung. $\square$

Nach Lemma 4.15 werden die Detailkoeffizienten glatter Abschnitte auf feinen Skalen ($j \rightarrow -\infty$) also schnell klein, umso schneller, je größer p ist. An Sprüngen oder steilen Spitzen ist die Voraussetzung des Lemmas verletzt, und die Koeffizienten bleiben dort groß.

Für den Mallat-Algorithmus braucht man zugleich kurze Filter, denn er ist nur mit endlichen Filtern exakt ausführbar. Viele verschwindende Momente und kurze Filter verbinden die Daubechies-Wavelets.

Satz 4.16 (Daubechies-Wavelets, [Bla03, Kap. 6.2], [LMR98, Kap. 2.4.4]). *Zu jedem $p \in \mathbb{N}$ gibt es eine reelle Skalierungsfolge $h_0, \dots, h_{2p-1}$ einer MSA mit*

$$\text{supp } \varphi_p = [0, 2p - 1], \quad \text{supp } \psi_p = [1 - p, p],$$

und das zugehörige Wavelet ψ_p besitzt p verschwindende Momente.

Anmerkung. brauch ich dafür nen beweis??

Der Träger von ψ_p folgt aus (4.7), da dort nur $g_{2-2p}, \dots, g_1$ von null verschieden sind, vgl. [LMR98, Kap. 2.4.4]. Für $p = 1$ entsteht das Haar-Wavelet, für $p = 2$ die Folge (4.6) [Bla03, Kap. 6.3] mit φ_2 und ψ_2 aus Abbildung 4.3. In PyWavelets [?] heißt ψ_p dbp; das Wavelet mit vier Koeffizienten ist also db2, nicht db4.

Anmerkung. Bib-Eintrag pywavelets anlegen und über DOI prüfen.




Abbildung 4.3.: Skalierungsfunktion φ_2 auf $[0, 3]$ (a) und Wavelet ψ_2 auf $[-1, 2]$ (b) zur Folge (4.6), berechnet durch Iteration der Skalierungsgleichung (4.1).

Anmerkung. Python-Datei zur Abbildung richtig ablegen.

Gegenüber Haar ist ψ_2 stetig [Bla03, Satz (6.11)], aber dreimal so breit. Allgemein wird ψ_p mit wachsendem p glatter, nämlich $\psi_p \in H^{\alpha p}(\mathbb{R})$ mit $\alpha > 0,2$ [LMR98, Kap. 2.4.4], zugleich wächst aber die Trägerlänge $2p - 1$. Bei der Wahl von p muss man daher abwägen. Viele Momente

sind gut für die ruhigen, langsam verlaufenden Teile des EKG wie P- und T-Welle: Dort werden die Detailkoeffizienten fast null (Lemma 4.15). Ein breiter Träger ist dagegen schlecht für den steilen QRS-Komplex [Reb21, Kap. 2.3.1], denn dessen Spitze wird dann von mehreren Wavelets gleichzeitig erfasst und verteilt sich auf mehrere Koeffizienten. Insgesamt bleibt das Bild aber dasselbe: Wenige große Koeffizienten tragen die Spitzen, fast alle übrigen sind klein [HB09, Beispiel 56.3]. Auf dieser Dünnbesetztheit baut Abschnitt 5.2 auf.

Damit liegen die drei Eigenschaften vor, die Kapitel 5 voraussetzt: Die diskrete Wavelet-Transformation ist orthogonal (Bemerkung 4.12), in $O(N)$ Operationen berechenbar (Algorithmus 1) und stellt stückweise glatte Signale dünnbesetzt dar (Lemma 4.15).

5. Entrauschung durch Thresholding

Ziel dieses Kapitels ist, aus verrauschten Messwerten das ursprüngliche Signal möglichst genau zurückzugewinnen. Dafür verwenden wir die diskrete Wavelet-Transformation aus Kapitel 4. Die Idee: Eine geeignet gewählte Orthonormalbasis stellt das Signal mit wenigen Koeffizienten dar [Mal09, Kap. 11.3], während sich das Rauschen gleichmäßig auf alle Koeffizienten verteilt [Mal09, Kap. 11.2.1]. Setzt man die kleinen Koeffizienten auf null, verschwindet vor allem Rauschen, während große Waveletkoeffizienten und damit scharfe Kanten erhalten bleiben [Mal09, Kap. 11.3.1]. Donoho und Johnstone haben gezeigt, dass dieses einfache Thresholding fast optimale Schätzer liefert [Mal09, Kap. 11.2]. Das Verfahren hat drei Schritte (Abbildung 5.1).




Abbildung 5.1.: Ablauf des Entrauschens: Die Messwerte Y werden mit Algorithmus 1 in Koeffizienten $\tilde{Y}$ zerlegt, jeder Koeffizient wird mit einer Schwelle bearbeitet, und die inverse DWT (Satz 4.11) liefert die Schätzung $\hat{f}$ des Signals. Die Bezeichnungen werden in den Abschnitten 5.1 bis 5.4 eingeführt. Vgl. [Mal09, Gl. (11.84)], [Reb21, Abb. 2.10].

Daraus ergeben sich die Fragen der folgenden Abschnitte: Was macht die Transformation mit dem Rauschen, was mit dem Signal? Wie setzt man kleine Koeffizienten auf null, wo liegt die Grenze, und wie bestimmt man sie aus den Daten? Ein Testsignal begleitet alle Abschnitte. Die Darstellung folgt [Mal09, Kap. 11.2–11.3.1].

5.1. Rauschmodell und diskrete Wavelet-Transformation

Das Rauschen wird als zufällig modelliert; die dafür benötigten Begriffe stehen in Abschnitt 2.6.

Definition 5.1 (Gauß'sches weißes Rauschen, [Mal09, Kap. 11.2.1–11.2.2]). Ein Zufallsvektor $W = (W_0, \dots, W_{N-1})$ heißt weißes Rauschen der Varianz σ^2 , wenn $\mathbb{E}[W_n] = 0$ und $\mathbb{E}[W_n W_k] = \sigma^2 \delta_{n,k}$ für alle n, k gilt. Sind die W_n zudem gemeinsam normalverteilt, heißt W Gauß'sches weißes Rauschen.

Nach Satz 2.3 sind die Komponenten eines Gauß'schen weißen Rauschens der Varianz 1 unabhängig und standardnormalverteilt.

Das Modell. Beobachtet werden N Messwerte

$$Y_n = f_n + \sigma Z_n, \quad n = 0, \dots, N-1, \quad (5.1)$$

mit Gauß'schem weißem Rauschen Z der Varianz 1 und Rauschstärke $\sigma > 0$ [Mal09, Gl. (11.26)]. Anders als in den Kapiteln 3 und 4 ist f hier keine Funktion, sondern der unbekannte Vektor $f \in \mathbb{R}^N$ der Abtastwerte des Signals. Die Messwerte dienen direkt als Startkoeffizienten $a_{0,n}$ von Algorithmus 1 [LMR98, Kap. 3.1.1], [Mal09, Kap. 7.3.1]. Das Rauschen wird mit Z bezeichnet, da W bereits für die Detailräume vergeben ist.

Definition 5.2 (Schätzer und Risiko, [Mal09, Kap. 1.2.4]). Ein Schätzer ordnet den Messwerten Y einen Vektor $\hat{f} \in \mathbb{R}^N$ zu, der f annähern soll. Sein Risiko ist der erwartete quadratische Fehler

$$r(f) := \mathbb{E} \|\hat{f} - f\|^2.$$

Für eine einzelne Realisierung des Rauschens heißt $\|\hat{f} - f\|^2$ die Fehlerenergie.

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie die Energie des Rauschens $\|\sigma Z\|^2$, und ihr Erwartungswert ist $r(f) = N\sigma^2$ [Mal09, Kap. 11.1.1].

Die DWT eines endlichen Signals. In Algorithmus 1 ist

$$a_{1,k} = \sum_{n \in \mathbb{Z}} h_{n-2k} a_{0,n},$$

die Summe läuft also formal über alle ganzen Zahlen n . Beim Filter (4.6) sind nur $h_0, \dots, h_3$ von null verschieden; für jedes k bleiben daher nur die vier Summanden mit $n = 2k, \dots, 2k+3$. Ein Messsignal hat aber nur die N Werte $a_{0,0}, \dots, a_{0,N-1}$. Für $N = 8$ ist etwa

$$a_{1,3} = h_0 a_{0,6} + h_1 a_{0,7} + h_2 a_{0,8} + h_3 a_{0,9},$$

und $a_{0,8}, a_{0,9}$ gibt es nicht. Man setzt das Signal daher periodisch fort, $a_{0,8} := a_{0,0}$, $a_{0,9} := a_{0,1}$ [LMR98, Kap. 2.4.7.2]. Das ist der einfachste von drei Wegen, die Mallat beschreibt; die anderen spiegeln das Signal am Rand oder verwenden eigene Randwavelets [Mal09, Kap. 7.3.1, 7.5].

Schreibt man die vier Gleichungen für $a_{1,0}, \dots, a_{1,3}$ untereinander, entsteht eine Matrix $H \in \mathbb{R}^{4 \times 8}$ mit $(a_{1,k})_k = H (a_{0,n})_n$:

$$H = \begin{pmatrix} h_0 & h_1 & h_2 & h_3 & 0 & 0 & 0 & 0 \\ 0 & 0 & h_0 & h_1 & h_2 & h_3 & 0 & 0 \\ 0 & 0 & 0 & 0 & h_0 & h_1 & h_2 & h_3 \\ h_2 & h_3 & 0 & 0 & 0 & 0 & h_0 & h_1 \end{pmatrix}.$$

Jede Zeile ist die vorige, um zwei Stellen verschoben; was rechts herausfällt, kommt links wieder hinein. Ebenso liefert eine Matrix $G \in \mathbb{R}^{4 \times 8}$ aus den g_k die Details $d_{1,0}, \dots, d_{1,3}$.

Allgemein sei M gerade und $w \in \mathbb{R}^M$ periodisch fortgesetzt, $w_{n+M} := w_n$. Die periodischen Mallat-Transformationen $H_M, G_M: \mathbb{R}^M \rightarrow \mathbb{R}^{M/2}$ sind

$$(H_M w)_k := \sum_{n \in \mathbb{Z}} h_{n-2k} w_n, \quad (G_M w)_k := \sum_{n \in \mathbb{Z}} g_{n-2k} w_n, \quad 0 \leq k < \frac{M}{2}$$

[LMR98, Kap. 3.6.2]; das sind die Formeln aus Algorithmus 1 mit periodisch gelesenen Indizes. Wir setzen $S_M := \begin{pmatrix} H_M \\ G_M \end{pmatrix} \in \mathbb{R}^{M \times M}$; das Beispiel oben ist $H = H_8$.

Lemma 5.3 ([LMR98, Kap. 3.6.2, Gl. (3.6.18)–(3.6.20)]). Für die Filter h, g aus Kapitel 4 gilt $H_M H_M^\top = G_M G_M^\top = I$, $H_M G_M^\top = 0$ und $H_M^\top H_M + G_M^\top G_M = I$. Die Matrix S_M ist also orthogonal, das heißt $S_M^\top S_M = S_M S_M^\top = I$.

Der Preis des Periodisierens: Sind Anfang und Ende des Signals verschieden, so verhalten sich die Koeffizienten am Rand, als hätte das Signal dort einen Sprung, und werden groß [Mal09, Kap. 7.5.1].

Die DWT als orthogonale Matrix. Die DWT der Tiefe J wendet S_N auf alle N Werte an und danach jeweils nur auf die zuletzt berechneten Approximationskoeffizienten; die Details bleiben stehen. Da jeder Schritt die Anzahl der Approximationskoeffizienten halbiert, sei N durch 2^J teilbar. Als Matrix ist das

$$A := \begin{pmatrix} S_{N/2^{J-1}} & 0 \\ 0 & I \end{pmatrix} \cdots \begin{pmatrix} S_{N/2} & 0 \\ 0 & I \end{pmatrix} S_N \in \mathbb{R}^{N \times N}, \quad AY = (a_J, d_J, \dots, d_1),$$

für $N = 8$, $J = 3$ etwa

$$A = \begin{pmatrix} S_2 & 0 \\ 0 & I_6 \end{pmatrix} \begin{pmatrix} S_4 & 0 \\ 0 & I_4 \end{pmatrix} S_8, \quad AY = (a_3, d_3, d_2, d_1)$$

mit 1, 1, 2 und 4 Einträgen. Jeder Faktor ist nach Lemma 5.3 orthogonal, also auch A . Wir bezeichnen die Zeilen von A mit $v_0, \dots, v_{N-1}$. Sie bilden eine Orthonormalbasis des $\mathbb{R}^N$, und jeder Koeffizient ist ein Skalarprodukt mit einer von ihnen; Mallat nennt sie diskrete Wavelets und Skalierungsfunktionen [Mal09, Kap. 7.5, Gl. (7.173)]. Aus (5.1) wird damit

$$\tilde{Y}_m = \theta_m + \sigma \tilde{Z}_m \quad \text{mit } \tilde{Y}_m = \langle Y, v_m \rangle, \quad \theta_m = \langle f, v_m \rangle, \quad \tilde{Z}_m = \langle Z, v_m \rangle, \quad (5.2)$$

kurz $\tilde{Y} = AY$, $\theta = Af$, $\tilde{Z} = AZ$.

Was mit dem Rauschen geschieht.

Lemma 5.4 ([Mal09, Kap. 11.2.1–11.2.2]). $\tilde{Z}$ ist wieder Gauß'sches weißes Rauschen der Varianz 1; die $\tilde{Z}_0, \dots, \tilde{Z}_{N-1}$ sind also unabhängig und standardnormalverteilt.

Beweis. Wegen der Linearität des Erwartungswerts ist $\mathbb{E}[\tilde{Z}_m] = \sum_n v_m[n] \mathbb{E}[Z_n] = 0$ und

$$\mathbb{E}[\tilde{Z}_m \tilde{Z}_p] = \sum_{n=0}^{N-1} \sum_{k=0}^{N-1} v_m[n] v_p[k] \mathbb{E}[Z_n Z_k] = \sum_{n=0}^{N-1} v_m[n] v_p[n] = \langle v_m, v_p \rangle = \delta_{m,p}$$

[Mal09, Kap. 11.2.1], da die v_m eine Orthonormalbasis bilden. Die $\tilde{Z}_m$ sind Linearkombinationen der gemeinsam normalverteilten Z_n und damit selbst gemeinsam normalverteilt [Mal09, Kap. 11.2.2]; nach Satz 2.3 sind sie also unabhängig. $\square$

Die Transformation verändert also das Signal, das Rauschen aber nicht: Jeder Koeffizient trägt Rauschen derselben Stärke σ , und das Rauschen beeinflusst die Wahl der Basis nicht [Mal09, Kap. 11.2.1].

Beispiel 5.5 (Ein verrauschter Sinus). Als Testsignal dient ein Sinus mit Amplitude 1 und Periode 1, abgetastet an den $N = 2048$ Zeitpunkten $t_n = 8n/N = n/256$ im Intervall $[0, 8)$:

$$u_n := \sin(2\pi t_n), \quad n = 0, \dots, 2047.$$

Jede Periode umfasst also 256 Abtastwerte, insgesamt sind es acht volle Perioden. Dazu kommt Rauschen der Stärke $\sigma = 0,3$: Die Z_n werden als Pseudozufallszahlen erzeugt, und nach (5.1) sind die Messwerte $Y_n = u_n + 0,3 Z_n$ (Abbildung 5.2). Zerlegt wird mit dem Filter (4.6), periodisiert, in $J = 5$ Stufen; gerechnet ist mit PyWavelets [?] (Code in Anhang B.3).

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie gleich der Energie des Rauschens, $\|Y - u\|^2 = 181,3$, nahe am Erwartungswert $N\sigma^2 = 2048 \cdot 0,09 = 184,3$; dieser Wert dient später als Vergleich. Für die 2048 Werte $\tilde{Z}_m$ sind der empirische Mittelwert $\bar{z} = \frac{1}{N} \sum_m \tilde{Z}_m = 0,01$ und die empirische Varianz $\frac{1}{N} \sum_m (\tilde{Z}_m - \bar{z})^2 = 0,98$, wie nach Lemma 5.4 zu erwarten.




Abbildung 5.2.: Der Sinus u aus Beispiel 5.5 (oben) und die Messwerte $Y = u + 0,3 Z$ (unten), $N = 2048$.

5.2. Diagonale Schätzer und Thresholding

Nach Abschnitt 5.1 bilden die Zeilen $v_0, \dots, v_{N-1}$ von A eine Orthonormalbasis des $\mathbb{R}^N$, und die Koeffizienten der Messwerte in dieser Basis sind $\tilde{Y}_m = \langle Y, v_m \rangle = \theta_m + \sigma \tilde{Z}_m$ nach (5.2). Im mittleren Schritt von Abbildung 5.1 wird jeder dieser Koeffizienten für sich mit einem Faktor λ_m multipliziert, der angibt, wie viel von ihm übrig bleibt: $\lambda_m = 1$ behält ihn, $\lambda_m = 0$ löscht ihn, ein Wert dazwischen verkleinert ihn.

Definition 5.6 (Diagonaler Schätzer, [Mal09, Gl. (11.27)]). Ein Schätzer heißt diagonal in der Basis $\{v_m\}$, wenn er jeden Koeffizienten mit einem Faktor λ_m multipliziert,

$$\hat{\theta}_m = \lambda_m \tilde{Y}_m \quad (m = 0, \dots, N-1),$$

und das Ergebnis mit $A^{-1} = A^\top$ zurücktransformiert: $\hat{f} = A^\top \hat{\theta}$. Dabei darf λ_m von den Messwerten nur über $\tilde{Y}_m$ abhängen, nicht über die übrigen Koeffizienten $\tilde{Y}_k$, $k \neq m$. Hängt kein λ_m von den Messwerten ab, heißt der Schätzer linear.

Bei einem linearen diagonalen Schätzer sind die λ_m feste Zahlen; sie dürfen von f und σ abhängen, aber nicht vom Zufall. In den Koeffizienten wirkt er als Multiplikation mit einer Diagonalmatrix,

$$\hat{\theta} = \begin{pmatrix} \lambda_0 & 0 & \cdots & 0 \\ 0 & \lambda_1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_{N-1} \end{pmatrix} \tilde{Y},$$

daher der Name. Die beiden wichtigsten diagonalen Schätzer sind dagegen nicht linear: Sie vergleichen den Betrag jedes Koeffizienten mit einer Schwelle $T > 0$, und ob ein Koeffizient bleibt, hängt damit von $\tilde{Y}_m$ selbst ab [Mal09, Kap. 11.2.2].

Definition 5.7 (Hard- und Soft-Thresholding, [Mal09, Gl. (11.47), (11.49)]). Für $T > 0$ heißen

$$\rho_T^H(x) := \begin{cases} x, & |x| > T, \\ 0, & |x| \leq T, \end{cases} \quad \rho_T^S(x) := \begin{cases} x - T, & x > T, \\ x + T, & x < -T, \\ 0, & |x| \leq T \end{cases}$$

Hard- bzw. Soft-Thresholding. Der zugehörige Schätzer berechnet mit ρ_T für eine der beiden Funktionen die Koeffizienten $\hat{\theta}_m = \rho_T(\tilde{Y}_m)$ und transformiert zurück: $\hat{f} = A^\top \hat{\theta}$.




Abbildung 5.3.: Die Funktionen ρ_T^H (a) und ρ_T^S (b); gestrichelt die Identität.

Beispiel 5.8 (Fortsetzung von Beispiel 4.10). Wir gehen alle drei Schritte für die Messwerte $Y = (4, 2, 5, 7)$ durch, mit dem Haar-Filter, $N = 4$ und $J = 2$.

Schritt 1, Transformieren: Nach Beispiel 4.10 ist $\tilde{Y} = AY = (a_{2,0}; d_{2,0}; d_{1,0}; d_{1,1}) = (9; -3; \sqrt{2}; -\sqrt{2})$.

Schritt 2, Thresholding: Mit $T = 2$ vergleicht Hard-Thresholding den Betrag jedes Koeffizienten mit T :

$$|9| > 2, \quad |-3| > 2, \quad |\sqrt{2}| \leq 2, \quad |-\sqrt{2}| \leq 2.$$

Die Koeffizienten 9 und -3 liegen über der Schwelle und bleiben unverändert, $\lambda_0 = \lambda_1 = 1$. Die beiden feinen Details $\pm\sqrt{2} \approx \pm 1,41$ liegen nicht darüber und werden auf null gesetzt, $\lambda_2 = \lambda_3 = 0$. Also ist $\hat{\theta} = (9; -3; 0; 0)$.

Schritt 3, Zurücktransformieren: Mit der Rekonstruktion aus Satz 4.11 ist zunächst $a_1 = (\frac{9-3}{\sqrt{2}}, \frac{9+3}{\sqrt{2}}) = (3\sqrt{2}, 6\sqrt{2})$ und, da beide $d_{1,k}$ null sind,

$$\hat{f} = A^\top \hat{\theta} = (3, 3, 6, 6).$$

Jedes Paar benachbarter Werte ist durch seinen Mittelwert ersetzt; das Nullsetzen der feinen Details wirkt also wie ein lokales Mitteln.

Soft-Thresholding setzt dieselben Koeffizienten auf null, verkleinert die übrigen aber zusätzlich um T : $\hat{\theta} = (7; -1; 0; 0)$ und damit $\hat{f} = (3, 3, 4, 4)$ (Abbildung 5.4). Dabei verkleinert es auch den Approximationskoeffizienten von 9 auf 7 und senkt so den Mittelwert von 4,5 auf 3,5; darauf kommt Abschnitt 5.4 zurück. In beiden Fällen wird jeder Koeffizient allein anhand seines eigenen Betrags behandelt (Abbildung 5.3). Nicht diagonal wäre dagegen etwa $\hat{\theta}_1 = \frac{1}{2}(\tilde{Y}_0 + \tilde{Y}_1)$, da hier $\hat{\theta}_1$ auch von $\tilde{Y}_0$ abhängt.




Abbildung 5.4.: Die Messwerte $Y = (4, 2, 5, 7)$ aus Beispiel 5.8 (a) und die Schätzungen $\hat{f} = (3, 3, 6, 6)$ nach Hard-Thresholding (b) und $\hat{f} = (3, 3, 4, 4)$ nach Soft-Thresholding (c), jeweils mit $T = 2$; gestrichelt Y .

Wie gut kann ein solcher Schätzer bestenfalls sein? Dazu zerlegt man den Fehler in die Beiträge der einzelnen Koeffizienten.

Lemma 5.9 ([Mal09, Gl. (11.28)]). Für jeden Schätzer der Form $\hat{f} = A^\top \hat{\theta}$ gilt

$$\mathbb{E} \|\hat{f} - f\|^2 = \sum_{m=0}^{N-1} \mathbb{E} |\hat{\theta}_m - \theta_m|^2. \quad (5.3)$$

Beweis. Hier ist $\|x\|^2 = \sum_{n=0}^{N-1} x_n^2$ die euklidische Norm des $\mathbb{R}^N$. Wegen $\hat{f} = A^\top \hat{\theta}$ und $AA^\top = I$ ist $A\hat{f} = \hat{\theta}$, und nach (5.2) ist $Af = \theta$. Da A nach Lemma 5.3 orthogonal ist und daher die Länge erhält, folgt

$$\|\hat{f} - f\|^2 = \|A(\hat{f} - f)\|^2 = \|\hat{\theta} - \theta\|^2 = \sum_{m=0}^{N-1} |\hat{\theta}_m - \theta_m|^2.$$

Bilden des Erwartungswerts, der linear ist, liefert (5.3). □

Bei einem diagonalen Schätzer hängt der m -te Summand nur vom m -ten Koeffizienten ab; man kann also für jeden Koeffizienten einzeln entscheiden, was mit ihm geschieht. Jeder Koeffizient $\tilde{Y}_m = \theta_m + \sigma \tilde{Z}_m$ besteht aus einem Signalanteil θ_m und einem Rauschanteil $\sigma \tilde{Z}_m$; bekannt ist nur die Summe. Wir betrachten feste Faktoren $\lambda_m \in \{0, 1\}$, also lineare diagonale Schätzer, die jeden Koeffizienten entweder behalten oder löschen [Mal09, Kap. 11.2.1]:

- Behalten, $\lambda_m = 1$: Das Signal bleibt, aber auch das Rauschen; die Abweichung ist $\hat{\theta}_m - \theta_m = \sigma \tilde{Z}_m$. Da $\tilde{Z}_m$ nach Lemma 5.4 Mittelwert 0 und Varianz 1 hat, ist $\mathbb{E}|\hat{\theta}_m - \theta_m|^2 = \sigma^2 \mathbb{E}[\tilde{Z}_m^2] = \sigma^2$.
- Löschen, $\lambda_m = 0$: Dann ist $\hat{\theta}_m = 0$. Das Rauschen ist weg, aber ebenso das Signal; die Abweichung ist $-\theta_m$, der Fehler θ_m^2 .

Behalten kostet also stets σ^2 , Löschen θ_m^2 . Behalten ist daher genau dann mindestens so gut wie Löschen, wenn $|\theta_m|$ mindestens so groß wie σ ist: Für $\sigma = 0,3$ ist etwa bei $\theta_m = 2$ Behalten besser (0,09 statt 4), bei $\theta_m = 0,1$ Löschen (0,01 statt 0,09).

Definition 5.10 (Ideale Auswahl, [Mal09, Gl. (11.32)–(11.34)]). Die ideale Auswahl ist der lineare diagonale Schätzer mit $\lambda_m = 1$ für $|\theta_m| \geq \sigma$ und $\lambda_m = 0$ sonst. Nach Lemma 5.9 ist ihr Risiko

$$r_{\text{id}}(f) = \sum_{m=0}^{N-1} \min(\theta_m^2, \sigma^2), \quad (5.4)$$

und kein linearer diagonal Schätzer mit Faktoren $\lambda_m \in \{0, 1\}$ hat ein kleineres Risiko.

Die Einschränkung auf feste Faktoren ist wesentlich. Dürfte λ_m zugleich von θ_m und $\tilde{Y}_m$ abhängen, so könnte man etwa genau dann behalten, wenn der Rauschanteil kleiner ist als der Signalanteil, $\sigma^2 \tilde{Z}_m^2 < \theta_m^2$, und erhielte den Fehler $\mathbb{E}[\min(\sigma^2 \tilde{Z}_m^2, \theta_m^2)] < \min(\sigma^2, \theta_m^2)$.

Da die λ_m der idealen Auswahl vom unbekannten θ_m abhängen, lässt sie sich nicht berechnen; Mallat spricht von einem Orakel [Mal09, Kap. 11.2.1]. Hard-Thresholding ist ihr praktischer Ersatz: Es behält oder löscht ebenfalls jeden Koeffizienten, entscheidet aber nach dem bekannten $|\tilde{Y}_m|$ und der Schwelle T statt nach $|\theta_m|$ und σ . Sein Risiko ist mindestens $r_{\text{id}}(f)$ [Mal09, Kap. 11.2.2]; die ideale Auswahl ist also eine untere Schranke für das, was Hard-Thresholding erreichen kann.

Anschaulich glättet das Verfahren nur dort, wo das Signal glatt ist: Große Koeffizienten an scharfen Übergängen bleiben erhalten, und wo alle Koeffizienten unter T liegen, wirkt das Nullsetzen wie ein lokales Mitteln der Messwerte [Mal09, Kap. 11.3.1]. Soft-Thresholding verkleinert zusätzlich jeden verbleibenden Koeffizienten um T . Ist T größer als alle Rauschwerte $|\sigma \tilde{Z}_m|$, so ist deshalb $|\rho_T^S(\tilde{Y}_m)| \leq |\theta_m|$ für alle m : Kein Koeffizient der Schätzung ist betragsmäßig größer als der entsprechende Koeffizient von f [Mal09, Gl. (11.50)]. Hard-Thresholding lässt die Koeffizienten über T unverändert; sie können durch das Rauschen größer sein als die von f [Mal09, Kap. 11.3.1]. Beides zeigt Beispiel 5.8 (Abbildung 5.4): Jedes Wertepaar wird gemittelt, der Sprung zwischen den Paaren bleibt beim Hard-Thresholding erhalten und wird beim Soft-Thresholding verkleinert.

Wann ist $r_{\text{id}}(f)$ klein? Sind M Koeffizienten mindestens so groß wie σ , so ist

$$r_{\text{id}}(f) = \sum_{|\theta_m| < \sigma} \theta_m^2 + M\sigma^2$$

[Mal09, Gl. (11.36), (11.37)]: der Fehler, wenn man f nur durch die M größten Koeffizienten darstellt, plus das Rauschen auf diesen M Koeffizienten. Klein ist $r_{\text{id}}(f)$ also nur dann, wenn wenige Koeffizienten groß und alle übrigen klein sind, das heißt wenn f sich durch wenige Basisvektoren gut darstellen lässt [Mal09, Kap. 11.2.2]. In diesem Fall nennen wir f in der Basis $\{v_m\}$ dünnbesetzt: Nur wenige Koeffizienten, $M \ll N$, sind mindestens so groß wie σ , und die übrigen tragen zusammen nur wenig Energie $\sum_{|\theta_m| < \sigma} \theta_m^2$. Dünnbesetzt zu sein heißt also gerade, dass $r_{\text{id}}(f)$ klein ist gegenüber dem Risiko $N\sigma^2$ ohne Bearbeitung. Darauf kommt es bei der Wahl der Basis an. Für Wavelets ist das Kriterium bei stückweise glatten Signalen erfüllt: Große Koeffizienten entstehen nur dort, wo das Signal auf dem Träger des Wavelets einen scharfen Übergang hat, und davon gibt es nur wenige [Mal09, Kap. 11.3.1].

Beispiel 5.11 (Fortsetzung: Sinus mit Spitzen). Wir gehen vom Sinus u aus Beispiel 5.5 aus und setzen drei schmale Spitzen hinzu:

$$s_n := \sum_{c \in \{1,3; 3,7; 6,2\}} 3 \max\left(0, 1 - \frac{|t_n - c|}{0,03}\right), \quad f := u + s,$$

also drei Dreiecke der Höhe 3 und halben Breite 0,03 (Abbildung 5.5). Der Sinus ist glatt, die Spitzen sind scharfe Übergänge an drei Stellen.




Abbildung 5.5.: Das Testsignal $f = u + s$ aus Beispiel 5.11 (oben) und die Beobachtung $Y = f + 0,3 Z$ (unten), $N = 2048$ (Code in Anhang B.4).

Beide Signale transformieren wir wie in Beispiel 5.5: mit dem Filter (4.6), periodisiert, in $J = 5$ Stufen. Das liefert die $N = 2048$ Koeffizienten $\theta = Af = (a_5, d_5, \dots, d_1)$; jede Stufe halbiert die Anzahl, sodass d_1 aus 1024, d_2 aus 512, $\dots$, d_5 aus 64 Koeffizienten besteht und die übrigen 64 die Approximation a_5 bilden. Für jede Stufe zeigt die Tabelle (Code in Anhang B.4):

- Anzahl: wie viele Koeffizienten die Stufe hat;
- größter Betrag (u): den betragsgrößten Koeffizienten des Sinus auf dieser Stufe;

- $\geq \sigma(u)$ und $\geq \sigma(f)$: wie viele Koeffizienten von u bzw. f betragsmäßig mindestens $\sigma = 0,3$ sind. Genau diese behält die ideale Auswahl (Definition 5.10); ihre Summe ist die Zahl M aus dem vorigen Absatz.

Anmerkung. python code für tabelle nach unten...

Stufe	Anzahl	größter Betrag (u)	$\geq \sigma(u)$	$\geq \sigma(f)$
a_5	64	5,4	64	64
d_5 (grob)	64	0,36	32	33
d_4	128	0,066	0	8
d_3	256	0,012	0	9
d_2	512	0,0021	0	4
d_1 (fein)	1024	0,00037	0	3
Summe	2048		96	121

Für den Sinus sind nur die 64 Approximationskoeffizienten und 32 Detailkoeffizienten auf Stufe 5 mindestens so groß wie σ , also $M = 96$ von 2048; ab Stufe 4 liegen alle Detailkoeffizienten weit darunter. Der Sinus ist in der Waveletbasis also dünnbesetzt. Dass der größte Detailkoeffizient von Stufe zu Stufe um den Faktor 5,5 bis 5,7 kleiner wird, passt zu Lemma 4.15: Die Schranke für $|d_{j,k}|$ ändert sich pro Stufe um $2^{p+1/2} = 2^{5/2} \approx 5,66$ für $p = 2$. Die Spitzen fügen 25 große Koeffizienten hinzu, $M = 121$, fast alle auf den feinen Stufen d_4 bis d_1 und nur in der Nähe der drei Spitzen; in Abbildung 5.6 heben sie sich deutlich von den kleinen Koeffizienten des Sinus ab.

Daraus ergibt sich das Risiko (5.4) der idealen Auswahl. Jeder behaltene Koeffizient kostet $\sigma^2 = 0,09$, jeder gelöschte sein Quadrat θ_m^2 . Für den Sinus ist $M\sigma^2 = 96 \cdot 0,09 = 8,6$, die gelöschten Koeffizienten tragen 1,1 bei, zusammen $r_{\text{id}}(u) = 9,7$. Für das Signal mit Spitzen ist $M\sigma^2 = 121 \cdot 0,09 = 10,9$, mit den gelöschten Koeffizienten $r_{\text{id}}(f) = 12,6$. Ohne Bearbeitung wäre das Risiko $N\sigma^2 = 184,3$; selbst mit Spitzen ist der Fehler der idealen Auswahl also rund fünfzehnmal kleiner.

5.3. Die Wahl der Schwelle

Die Schwelle T soll das Rauschen entfernen, aber möglichst wenig vom Signal. Ist $f = 0$, so besteht jeder Koeffizient nur aus Rauschen, $\tilde{Y}_m = \sigma \tilde{Z}_m$; damit alle gelöscht werden, muss T größer sein als der größte Rauschanteil $\max_m |\sigma \tilde{Z}_m|$. Ist $f \neq 0$, darf T nicht viel größer sein, sonst gehen auch Koeffizienten mit großem Signalanteil verloren. T soll also knapp über dem größten Rauschanteil liegen [Mal09, Kap. 11.2.2]. Dieses Maximum ist unbekannt. Für N unabhängige Rauschanteile liegt es aber mit hoher Wahrscheinlichkeit knapp unter $\sigma\sqrt{2 \ln N}$ [Mal09, Gl. (11.64)]. Das begründet die universelle Schwelle [Mal09, Kap. 11.3.2]

$$T = \sigma\sqrt{2 \ln N}. \quad (5.5)$$

Dass T mit N wächst, liegt an den Ausläufern der Normalverteilung: Unter mehr Werten kommen auch größere vor [Mal09, Kap. 11.2.2].




Abbildung 5.6.: Detailkoeffizienten d_5 (oben, grob) bis d_1 (unten, fein) des Testsignals $f = u + s$ aus Beispiel 5.11, aufgetragen über der Zeit t ; sehr große Werte abgeschnitten.

Satz 5.12 (Donoho–Johnstone, [Mal09, Satz 11.7]). Für $N \geq 4$ und $T = \sigma\sqrt{2\ln N}$ erfüllt das Risiko des Hard- und des Soft-Thresholding-Schätzers

$$r(f) \leq (2\ln N + 1)(\sigma^2 + r_{\text{id}}(f)). \quad (5.6)$$

Für den Beweis siehe [Mal09, Satz 11.7, Lemma 11.1]. Bis auf den Faktor $2\ln N + 1$ ist Thresholding also so gut wie die ideale Auswahl: Ist f dünnbesetzt und damit $r_{\text{id}}(f)$ klein, so ist auch $r(f)$ klein. Mit diagonalen Schätzern lässt sich dieser Faktor für große N nicht verbessern [Mal09, Gl. (11.52)].

Woher der Faktor $2\ln N$ kommt, erklärt Mallat anschaulich [Mal09, Kap. 11.2.2]: Ist $|\theta_m| \leq \sigma$, so löscht Hard-Thresholding den Koeffizienten sehr wahrscheinlich, ist $|\theta_m| \geq 2T$, so behält es ihn sehr wahrscheinlich, beides wie die ideale Auswahl. Nur wenn $|\theta_m|$ in der Größenordnung von T liegt, kann es irrtümlich löschen; das kostet $\theta_m^2 \approx T^2 = 2\ln N \sigma^2$ statt σ^2 . Da solche Koeffizienten meist selten sind, ist das Verhältnis zum Risiko der idealen Auswahl meist deutlich kleiner als $2\ln N$. Die Schwelle (5.5) ist allerdings nicht optimal: Eine kleinere Schwelle senkt das Risiko oft, und Soft-Thresholding braucht für ähnliche Ergebnisse wie Hard-Thresholding etwa die halbe Schwelle [Mal09, Kap. 11.2.2].

5.4. Schätzung der Rauschstärke

Die Schwelle enthält das unbekannte σ . Mallat schätzt es aus den $N/2$ Detailkoeffizienten $d_{1,k}$ der feinsten Stufe [Mal09, Kap. 11.3.1]: Wo das Signal auf dem Träger des Wavelets glatt ist, ist sein Koeffizient klein, und $d_{1,k}$ besteht praktisch nur aus Rauschen. Nur an den wenigen scharfen Übergängen ist er groß; diese Werte nennt Mallat Ausreißer. Auch beim gemessenen EKG enthält d_1 fast das gesamte Rauschen [LMR98, Kap. 3.1.2].

Der Median von P Zahlen ist der mittlere Wert, wenn man sie der Größe nach ordnet, also der Wert vom Rang $P/2$ [Mal09, Kap. 11.3.1]. Anders als der Mittelwert hängt er nicht davon ab, wie groß die Werte über ihm sind, und wird von wenigen Ausreißern daher kaum verändert. Ist M der Median der Beträge von P unabhängigen normalverteilten Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2 , so ist $\mathbb{E}[M] \approx 0,6745 \sigma$ [Mal09, Kap. 11.3.1]. Daraus ergibt sich der Schätzer

$$\hat{\sigma} = \frac{\text{Median}(|d_{1,k}| : 0 \leq k < N/2)}{0,6745} \quad (5.7)$$

[Mal09, Gl. (11.85)]. Er setzt voraus, dass das Rauschen in allen Koeffizienten dieselbe Stärke hat, was nach Lemma 5.4 für weißes Rauschen zutrifft. Ist das Rauschen nicht weiß, hängt seine Varianz vom Basisvektor ab, und die Schwelle muss mit dem Koeffizienten variieren [Mal09, Kap. 11.2.2]; darauf kommt Kapitel 6 zurück.

Das vollständige Verfahren. Mallat schwellt alle Koeffizienten der Waveletbasis, auch die der größten Approximation [Mal09, Gl. (11.84)], und bestimmt σ mit (5.7) [Mal09, Kap. 11.3.1]. Zusammen ergibt sich:

Algorithmus 2 Entrauschen mit universeller Schwelle nach [Mal09, Kap. 11.2–11.3]

Eingabe: Messwerte $Y \in \mathbb{R}^N$, Filter h, g , Tiefe J mit $2^J \mid N$

- 1: $(a_J, d_J, \dots, d_1) \leftarrow AY$ ▷ Algorithmus 1, periodisiert
 - 2: $T \leftarrow \hat{\sigma} \sqrt{2 \ln N}$ mit $\hat{\sigma}$ aus (5.7)
 - 3: ersetze jeden Koeffizienten c von $a_J, d_J, \dots, d_1$ durch $\rho_T(c)$
 - 4: **Rückgabe** $\hat{f} \leftarrow A^\top$ (geschwellte Koeffizienten) ▷ Satz 4.11
-

Satz 5.12 setzt das wahre σ voraus; mit dem geschätzten $\hat{\sigma}$ ist die Schranke (5.6) nur ein Anhaltspunkt. Ferner werden in Zeile 3 auch die Approximationskoeffizienten a_J geschwellt. Sie tragen den glatten, groben Anteil des Signals und sind meist groß; Soft-Thresholding verkleinert jeden von ihnen um T und verschiebt so den glatten Anteil, wie schon in Beispiel 5.8 den Mittelwert. In seinem Beispiel zur Bildentrauschung schwellt Mallat die Skalierungskoeffizienten deshalb nicht [Mal09, Kap. 11.3.2].

Beispiel 5.13 (Fortsetzung: Entrauschen des Testsignals). Wir entrauschen jetzt die Messwerte $Y = f + 0,3 Z$ aus Beispiel 5.11.

Zuerst wird die Schwelle bestimmt. Der Schätzer (5.7) liefert $\hat{\sigma} = 0,300$, trifft das wahre $\sigma = 0,3$ also sehr genau. Damit ist $T = \hat{\sigma} \sqrt{2 \ln N} = 1,17$.

Abbildung 5.7 zeigt, was diese Schwelle trennt. Das Rauschen bleibt auf allen Stufen zwischen den gestrichelten Linien: Kein einziger Rauschkoeffizient erreicht T , der größte hat den Betrag 1,02. Darüber ragen nur die Koeffizienten an den drei Spitzen hinaus. Hard-Thresholding behält deshalb nur 75 der 2048 Koeffizienten.

Das Ergebnis zeigt Abbildung 5.8. Mit Hard-Thresholding sinkt die Fehlerenergie von 181,3 auf 27,6, also auf etwa ein Siebtel, und die Spitzen bleiben weitgehend erhalten. Soft-Thresholding mit derselben Schwelle erreicht nur 127,1 und macht die Spitzen deutlich niedriger. Der Grund ist, dass Soft-Thresholding auch jeden behaltenen Koeffizienten um T verkleinert. Das betrifft vor allem die 64 Approximationskoeffizienten, die alle größer als T sind und den glatten Sinus tragen.




Abbildung 5.7.: Detailkoeffizienten d_5 (oben) bis d_1 (unten) der Messwerte $Y = f + 0,3 Z$ aus Beispiel 5.13, im selben Maßstab wie Abbildung 5.6; gestrichelt die Schwelle $\pm T = \pm 1,17$.




Abbildung 5.8.: Schätzungen aus Y mit Algorithmus 2, $T = 1,17$ (links), und Ausschnitt um die mittlere Spitze mit dem wahren Signal f (rechts)(Code in Anhang B.7).

6. Anwendung: Entrauschung von EKG-Signalen

Anmerkung. Block H. Aufbau in drei Stufen mit ABNEHMENDER Referenzinformation: (1) synthetisch: sauberes Signal exakt bekannt -> SNR/MSE quantitativ messbar; (2) MIT-BIH: kein sauberes Signal, aber Experten-Annotationen -> indirekte Validierung; (3) Herzzentrum: weder Referenz noch Annotationen -> nur qualitative Beurteilung. Diese Abstufung ist der rote Faden des Kapitels.

6.1. EKG-Signale: Morphologie und Störquellen

6.1.1. Der Herzzyklus: P-Welle, QRS-Komplex, T-Welle

Anmerkung. Die P-Welle entspricht der Vorhoferregung, der QRS-Komplex der Kammerdepolarisation, die T-Welle der Repolarisation.

Belegstellen.

- Gacek, Abb. 2.2, S. 28 [bestätigt]
- Gacek, Kap. 2.2, S. 24–25 [bestätigt]
- Aqil, Abb. 2 und Tab. 1, S. 52 [bestätigt]
- Rebstadt, Kap. 2.1, S. 7–10 [bestätigt] — Abb. 2.1 (S. 8), Abb. 2.2 (S. 10)
- LMR, S. 239 [bestätigt] — knappe mathematiknahe Beschreibung: Hauptmuskelkontraktion als ausgeprägtes Maximum, Herzklappenausschläge „fast im Rauschen versteckt“

6.1.2. Typische Störquellen

Anmerkung. Baseline Wander, Muskelartefakte, Netzbrummen (50/60 Hz) und additives weißes Rauschen.

Belegstellen.

- Gacek, S. 31–33 [bestätigt] — Abb. 2.5, 2.6, 2.7
- Chatterjee, Kap. 1.1, S. 570 [bestätigt]
- Aqil, Abb. 3, S. 54 [bestätigt]
- Rebstadt, Abb. 2.3, S. 10 [bestätigt]

Anmerkung. Aus ausgelagertem Abschnitt 3.1.x übernommen: Wavelets haben Mittelwert null, daher erzeugt ein konstanter Signalanteil auf keiner Skala Koeffizienten; Basisliniendrift ist langsam veränderlich und konzentriert sich deshalb auf die größten Skalen. Das ist der Grund, warum Baseline Wander durch Nullsetzen der größten Approximation entfernt werden kann.

Anmerkung. Basislinienwanderung (Atmung, tieffrequent), Netzbrummen (50 Hz), Muskelartefakte (EMG, breitbandig), Bewegungsartefakte. Wichtig: nur ein Teil davon ist weißes Rauschen im Sinne von Kapitel 5. Diese Diskrepanz zwischen Modellannahme und Realität hier offen benennen – sie wird in Abschnitt 6.5 wieder aufgegriffen. Quelle: „An Introduction to ECG Signal Processing and Analysis“.

6.2. Bewertungsmaße und das Problem der fehlenden Referenz

Anmerkung. SNR, MSE und PRD setzen ein rauschfreies Referenzsignal voraus, das bei realen Messungen prinzipiell nicht existiert.

Belegstellen.

- Chatterjee, Gl. (56) ff., S. 582 [bestätigt]
- Aqil, Kap. 3, S. 59 [bestätigt]
- Rebstadt, Kap. 4.3, S. 54–55 [bestätigt]

Anmerkung. Zentraler methodischer Abschnitt. SNR und MSE setzen ein BEKANNTES sauberes Signal voraus. Auf realen Daten existiert dieses nicht – sonst bräuchte man kein Denoising. Daraus folgt die Dreistufigkeit der folgenden Abschnitte. Hier definieren: SNR, MSE; und benennen, welche Ersatzkriterien auf realen Daten zur Verfügung stehen.

Anmerkung. 6.2a Vorverarbeitung: warum $a_{0,k} := X(k)$ zulässig ist (neu einzufügen) Die Abtastwerte s_k dürfen als Skalierungskoeffizienten der Stufe 0 gelesen werden, weil für hölderstetige Signale und eine Skalierungsfunktion mit kompaktem Träger und $\sum_k \varphi(x - k) = 1$ der Fehler nur $O(h^\alpha)$ beträgt.

Belegstellen.

- LMR, Kap. 3.1.1 „Vorbereitungen“, S. 237–238 [bestätigt] — die beiden Vorverarbeitungsschritte, Gl. (3.1.1): $fwelle(kh) = s_k + (h^\alpha)$
- LMR, Bemerkung 3.1.1, S. 238 [bestätigt] — Quadraturformeln höherer Ordnung, falls die Fehlerordnung nicht genügt
- LMR, Lemma 2.4.29 / Gl. (2.4.17), S. 175 [bestätigt] — die dabei benötigte Bedingung $\sum_k \varphi(x - k) = 1$
- LMR, Aufgabe 3.1, S. 311 [geschätzt] — der Beweis von (3.1.1) ist dort als Übung gestellt

6.3. Stufe 1: Synthetisch konstruiertes EKG-Signal

Anmerkung. Kontrollierte Umgebung mit bekanntem f : erlaubt exakte SNR-Messung und damit die numerische Überprüfung der Theorie aus Kapitel 5.

Belegstellen.

- LMR, Kap. 3.1.2, S. 238–240 [bestätigt] — methodisches Vorbild: ein einzelner Herzschlag, MSA über vier Stufen, Histogramme der Koeffizienten (Abb. 3.2, S. 240)
- LMR, Tabelle der Skalierungskoeffizienten, S. 170 [bestätigt] — Filterkoeffizienten für die Implementierung
- Aqil, Kap. 4, S. 61–65 [bestätigt] — Fig. 9, 11, 14, Tab. 4
- Rebstadt, Kap. 4.1–4.2, S. 49–53 [bestätigt] — Abb. 4.1 (S. 50)
- Mallat, Abb. 11.4–11.5, S. 635, 638 [bestätigt]
- Eigene Implementierung (NumPy) — keine Fremdquelle

6.3.1. Konstruktion des Modellsignals

Anmerkung. Ansatz überlegen: Summe von Gauß-Glocken für P/T-Wellen plus schmale, hohe Komponente für den QRS-Komplex. Vorteil gegenüber einem Testsignal aus der Literatur: die Parameter (Amplituden, Breiten, Herzfrequenz) sind frei wählbar und damit systematisch variierbar.

6.3.2. Rauschmodell und Wahl der Parameter

Anmerkung. Pseudo-zufälliges Gaußsches Rauschen verwenden – deterministische Alternativen verletzen die Voraussetzungen des MAD-Schätzers!

6.3.3. Wahl von Wavelet und Zerlegungstiefe

Anmerkung. Systematischer Vergleich: Haar (db1) vs. db2 vs. Symlet; Zerlegungstiefe $J = 1, \dots, 6$. PRÜFEN: In den Vorexperimenten stand hier db4 (PyWavelets, acht Koeffizienten), Kapitel 4 führt aber db2 vor (Bemerkung ??) – einheitlich entscheiden. Erwartung aus den Vorexperimenten: das Daubechies-Wavelet schlägt Haar, und die Zerlegungstiefe verhält sich NICHT monoton (Optimum um $J = 3$). Genau dieses nichtmonotone Verhalten ist ein Ergebnis und sollte als solches dargestellt werden.

6.3.4. Vergleich von Hard- und Soft-Thresholding

6.3.5. Ergebnisse

Anmerkung. Tabelle mit SNR/MSE (booktabs) + Abbildung Original/verrauscht/entrauscht

6.4. Stufe 2: Reale Signale aus der MIT-BIH-Datenbank

Anmerkung. Standardisierte, annotierte EKG-Aufzeichnungen; da kein rauschfreies Original existiert, wird künstliches Rauschen additiv aufgeprägt.

Belegstellen.

- Rebstadt, Kap. 5.1.1, S. 61–62 [bestätigt] — Abb. 5.1, Datensatz 205
- Chatterjee, Tab. 9, S. 586 [bestätigt]
- Aqil, Kap. 3–4, S. 60–66 [bestätigt]

6.4.1. Beschreibung des Datensatzes

Anmerkung. MIT-BIH Arrhythmia Database (PhysioNet): Abtastrate, Auflösung, Ableitungen, Annotationen. Auswahl der verwendeten Datensätze begründen.

6.4.2. Validierung ohne sauberes Referenzsignal

Anmerkung. Hier greift Abschnitt 6.2. Mögliche Wege: (a) künstliches Rauschen ZUSÄTZLICH addieren und das Originalsignal als Pseudo-Referenz behandeln – methodisch sauber, aber das Original ist selbst schon verrauscht; (b) Erhalt der annotierten R-Zacken-Positionen prüfen; (c) Amplitudentreue des QRS-Komplexes vor/nach Entrauschung. Die gewählte Strategie muss klar begründet werden.

6.4.3. Ergebnisse

Anmerkung. Stufe 3 (klinische Daten des Herzzentrums).!!

6.5. Diskussion

Anmerkung. Wo bestätigt das Experiment die Theorie, wo nicht — und welche Modellannahmen sind bei echten EKGs verletzt.

Belegstellen.

- Mallat, S. 626–627 [bestätigt] — skalenabhängige Rauschvarianz, Grenzen der universellen Schwelle
- LMR, S. 238 [bestätigt] — die Wahl von Skalierungsfunktion, Wavelet und Filtern „verlangt unter Umständen einiges Fingerspitzengefühl“; ehrliche Einordnung der Theoriegrenzen aus mathematischer Feder
- Rebstadt, Kap. 4.4, S. 56–59 [bestätigt] — die DWT wurde dort von einem konkurrierenden Verfahren geschlagen
- Chatterjee, Kap. 5, S. 585–587 [bestätigt]

Anmerkung. Die drei Stufen zusammenführen: Wo hält die Theorie aus Kapitel 5, wo bricht sie? Insbesondere: Basislinienwanderung und Netzbrummen sind kein weißes Rauschen, die Modellannahme ist auf realen Daten also nur teilweise erfüllt. Genau das erklärt eine mögliche Verschlechterung der Ergebnisse von Stufe 1 zu Stufe 3.

7. Fazit und Ausblick

Anmerkung. Zusammenfassung des Argumentationsbogens und Ausblick auf translationsinvariantes Thresholding, adaptive Schwellen und konkurrierende Zerlegungen.

Belegstellen.

- Mallat, „Translation-Invariant Thresholding“, S. 632–633 [bestätigt]; S. 639 [bestätigt]
- Mallat, „Multiscale Sure Thresholds“, S. 637 [bestätigt]
- LMR, Kap. 2.4.5 „Biorthogonale Wavelets“, S. 184–190 [bestätigt]; Kap. 2.4.7.3 „Coiflets“, S. 209 [bestätigt] — naheliegende Erweiterungen der Basiswahl
- LMR, Vorwort zur zweiten Auflage, S. 1 [bestätigt] — Multiwavelets und das Lifting-Prinzip als weiterführende Richtungen
- Rebstadt, Kap. 6.2, S. 76–77 [bestätigt]
- Chatterjee, Kap. 5, S. 585–587 [bestätigt]

A. Ergänzende Rechnungen

A.1. Fourier-Transformierte des Testsignals

Wir leiten (3.5) aus Beispiel 3.8 her. Wegen $f \in L^1(\mathbb{R})$ ist $\hat{f}$ punktweise durch das Integral gegeben; in der Konvention aus Bemerkung 2.1 ist

$$\hat{f}(\omega) = \frac{1}{\sqrt{2\pi}} \left(\int_0^3 (1 - \cos(2\pi t)) e^{-i\omega t} dt + \frac{1}{2} \int_4^5 (1 - \cos(10\pi t)) e^{-i\omega t} dt \right).$$

Sei zunächst $\omega \notin \{0, \pm 2\pi, \pm 10\pi\}$. Benutzt werden nur $\cos x = \frac{1}{2}(e^{ix} + e^{-ix})$ und

$$\int_{\alpha}^{\beta} e^{ct} dt = \frac{1}{c}(e^{c\beta} - e^{c\alpha}), \quad c \in \mathbb{C} \setminus \{0\}. \quad (\text{A.1})$$

Die langsame Komponente. Mit $q_1 := 1 - e^{-3i\omega}$ zerlegen wir

$$\int_0^3 (1 - \cos(2\pi t)) e^{-i\omega t} dt = \underbrace{\int_0^3 e^{-i\omega t} dt}_{=: A_1} - \underbrace{\int_0^3 \cos(2\pi t) e^{-i\omega t} dt}_{=: B_1}.$$

Nach (A.1) mit $c = -i\omega$ ist

$$A_1 = \frac{e^{-3i\omega} - 1}{-i\omega} = \frac{q_1}{i\omega}.$$

Für B_1 schreiben wir $\cos(2\pi t) e^{-i\omega t} = \frac{1}{2}(e^{i(2\pi-\omega)t} + e^{-i(2\pi+\omega)t})$ und erhalten nach (A.1)

$$B_1 = \frac{e^{3i(2\pi-\omega)} - 1}{2i(2\pi - \omega)} + \frac{e^{-3i(2\pi+\omega)} - 1}{-2i(2\pi + \omega)}.$$

Da auf $[0, 3]$ genau drei volle Perioden liegen, ist $e^{\pm 6\pi i} = 1$ und damit $e^{3i(2\pi-\omega)} = e^{-3i(2\pi+\omega)} = e^{-3i\omega}$. Beide Zähler werden zu $-q_1$, und

$$B_1 = \frac{q_1}{2i} \left(\frac{1}{2\pi + \omega} - \frac{1}{2\pi - \omega} \right) = \frac{q_1}{2i} \cdot \frac{2\omega}{\omega^2 - 4\pi^2} = \frac{q_1 \omega}{i(\omega^2 - 4\pi^2)}.$$

Mit $1/i = -i$ folgt

$$A_1 - B_1 = \frac{q_1}{i} \left(\frac{1}{\omega} - \frac{\omega}{\omega^2 - 4\pi^2} \right) = \frac{q_1}{i} \cdot \frac{-4\pi^2}{\omega(\omega^2 - 4\pi^2)} = \frac{i 4\pi^2 q_1}{\omega(\omega^2 - 4\pi^2)}.$$

Die schnelle Komponente. Mit $q_2 := e^{-4i\omega} - e^{-5i\omega}$ verläuft die Rechnung wörtlich gleich, nun mit 10π statt 2π und den Grenzen 4 und 5. An die Stelle von $e^{\pm 6\pi i} = 1$ treten $e^{\pm 40\pi i} = e^{\pm 50\pi i} = 1$, und man erhält

$$A_2 = \int_4^5 e^{-i\omega t} dt = \frac{q_2}{i\omega}, \quad B_2 = \int_4^5 \cos(10\pi t) e^{-i\omega t} dt = \frac{q_2 \omega}{i(\omega^2 - 100\pi^2)},$$

also mit dem Amplitudenfaktor $\frac{1}{2}$

$$\frac{1}{2}(A_2 - B_2) = \frac{q_2}{2i} \cdot \frac{-100\pi^2}{\omega(\omega^2 - 100\pi^2)} = \frac{i 50\pi^2 q_2}{\omega(\omega^2 - 100\pi^2)}.$$

Addition beider Anteile und der Vorfaktor $(2\pi)^{-1/2}$ ergeben (3.5).

Die Ausnahmestellen. Da $\hat{f}$ als Fourier-Transformierte einer L^1 -Funktion stetig ist [Ser17, Satz 12.1], gilt (3.5) an den Stellen $\omega \in \{0, \pm 2\pi, \pm 10\pi\}$ im Sinne des Grenzwerts; dort verschwinden jeweils auch die Zähler, etwa $q_1 = 1 - e^{-6\pi i} = 0$ für $\omega = 2\pi$. Die Werte lassen sich einfacher direkt aus dem Integral bestimmen. Für $\omega = 0$ ist $\hat{f}(0) = (2\pi)^{-1/2} \int_{\mathbb{R}} f = (2\pi)^{-1/2}(3 + \frac{1}{2})$. Für $\omega = 2\pi$ zerfällt der Integrand in Exponentialterme $e^{i\nu t}$; alle mit $\nu \neq 0$ integrieren sich über $[0, 3]$ bzw. $[4, 5]$ zu null, da ν jeweils ein ganzzahliges Vielfaches von 2π ist. Übrig bleibt allein der konstante Term $-\frac{1}{2}e^{2\pi i t}e^{-2\pi i t} = -\frac{1}{2}$ im ersten Integral, also $\hat{f}(2\pi) = -\frac{3}{2}(2\pi)^{-1/2}$. Ebenso ist $\hat{f}(10\pi) = \frac{1}{2} \cdot (-\frac{1}{2})(2\pi)^{-1/2}$, und wegen $\hat{f}(-\omega) = \overline{\hat{f}(\omega)}$ folgt

$$|\hat{f}(0)| = \frac{7}{2\sqrt{2\pi}} \approx 1,396, \quad |\hat{f}(\pm 2\pi)| = \frac{3}{2\sqrt{2\pi}} \approx 0,598, \quad |\hat{f}(\pm 10\pi)| = \frac{1}{4\sqrt{2\pi}} \approx 0,0997.$$

Die in Beispiel 3.8 angegebenen Lagen der Maxima, $\omega \approx 1,90\pi$ mit $|\hat{f}| \approx 0,629$ und $\omega \approx 9,73\pi$ mit $|\hat{f}| \approx 0,102$, wurden numerisch aus (3.5) bestimmt; zur Kontrolle wurde (3.5) an mehreren Stellen mit numerischer Quadratur des definierenden Integrals verglichen (Anhang B).

A.2. Stammfunktion des Testsignals

Für $0 \leq t \leq 3$ ist $F(t) = \int_0^t (1 - \cos(2\pi s)) ds = t - \frac{\sin(2\pi t)}{2\pi}$, insbesondere $F(3) = 3$ wegen $\sin(6\pi) = 0$. Auf $[3, 4]$ verschwindet f , also $F \equiv 3$. Für $4 \leq t \leq 5$ ist

$$F(t) = 3 + \frac{1}{2} \int_4^t (1 - \cos(10\pi s)) ds = 3 + \frac{t-4}{2} - \frac{\sin(10\pi t) - \sin(40\pi)}{20\pi} = 3 + \frac{t-4}{2} - \frac{\sin(10\pi t)}{20\pi},$$

und wegen $\sin(50\pi) = 0$ ist $F(5) = \frac{7}{2} = \int_{\mathbb{R}} f$, in Übereinstimmung mit $\hat{f}(0) = (2\pi)^{-1/2} \cdot \frac{7}{2}$. Da f stetig ist – an allen vier Trägerschritten hat $1 - \cos x = 2\sin^2(x/2)$ eine doppelte Nullstelle –, ist F stetig differenzierbar mit $F' = f$.

B. Python-Code

Alle Abbildungen und numerischen Werte dieser Arbeit wurden mit Python (NumPy, PyWavelets [?], Matplotlib) erzeugt.

Anmerkung. Versionen angeben (`python -version, pip show numpy matplotlib pywavelets`).

Die Skripte zu Kapitel 5 verwenden durchgehend den Filter (4.6), die periodisierte Transformation (Abschnitt 5.1) mit $J = 5$ Stufen und $N = 2048$ Abtastwerte. Der feste Startwert 93 des Zufallsgenerators sorgt dafür, dass alle Abbildungen dieses Kapitels dieselbe Realisierung des Rauschens zeigen.

B.1. Beispiel zur kontinuierlichen Wavelet-Transformation

Der folgende Code erzeugt die Abbildungen 3.4, 3.5 und 3.6. Die Wavelet-Transformierte wird nicht durch numerische Quadratur, sondern exakt nach (3.6) aus der Stammfunktion F berechnet.

Listing B.1: Testsignal aus Beispiel 3.8

```
1 # Beispiel aus Abschnitt 3.1.2: Signal, Fourier-Transformierte und Haar-CWT.
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 pi = np.pi
6
7
8 def f(t):
9     y = np.zeros_like(t)
10    m = (t >= 0) & (t <= 3)
11    y[m] += 1 - np.cos(2 * pi * t[m])
12    m = (t >= 4) & (t <= 5)
13    y[m] += 0.5 * (1 - np.cos(10 * pi * t[m]))
14    return y
15
16
17 def F(t):
18     y = np.zeros_like(t)
19     m = (t > 0) & (t < 3)
20     y[m] += t[m] - np.sin(2 * pi * t[m]) / (2 * pi)
21     y[t >= 3] += 3
22     m = (t > 4) & (t < 5)
23     y[m] += 0.5 * ((t[m] - 4) - np.sin(10 * pi * t[m]) / (10 * pi))
24     y[t >= 5] += 0.5
25     return y
26
27
```

```

28 def fourier(w):
29     w = w.astype(complex)
30     for p in [0, 2 * pi, -2 * pi, 10 * pi, -10 * pi]:
31         w = np.where(np.abs(w - p) < 1e-7, p + 1e-7, w)
32     a = 4 * pi**2 * (1 - np.exp(-3j * w)) / (w**2 - 4 * pi**2)
33     b = 50 * pi**2 * (np.exp(-4j * w) - np.exp(-5j * w)) / (w**2 - 100 * pi
        **2)
34     return 1j * (a + b) / (np.sqrt(2 * pi) * w)
35
36
37 def cwt_haar(a, b):
38     return (2 * F(b + a / 2) - F(b) - F(b + a)) / np.sqrt(a)
39
40
41 plt.rcParams.update({"font.size": 9, "font.family": "serif", "savefig.dpi":
    300})
42
43 t = np.linspace(-0.6, 5.6, 40000)
44 fig, ax = plt.subplots(figsize=(7.0, 2.8))
45 ax.plot(t, f(t), color="royalblue", lw=0.9)
46 for x in [0, 3, 4, 5]:
47     ax.axvline(x, color="gray", lw=0.6, alpha=0.3)
48 ax.set_xlim(-0.6, 5.6)
49 ax.set_ylim(-0.25, 2.45)
50 ax.set_xticks(range(6))
51 ax.set_xlabel("$t$")
52 ax.set_ylabel("$f(t)$")
53 ax.annotate("$f_1$", (1.5, 2.18), ha="center")
54 ax.annotate("$f_2$", (4.5, 1.22), ha="center")
55 ax.spines[["top", "right"]].set_visible(False)
56
57 w = np.linspace(-50, 50, 40000)
58 fig, ax = plt.subplots(figsize=(7.0, 2.8))
59 ax.plot(w, np.abs(fourier(w)), color="royalblue", lw=0.9)
60 for p in [-10 * pi, -2 * pi, 0, 2 * pi, 10 * pi]:
61     ax.axvline(p, color="gray", ls="--", lw=0.6)
62 ax.set_xlim(-50, 50)
63 ax.set_ylim(0, 1.55)
64 ax.set_xticks([-10 * pi, -2 * pi, 0, 2 * pi, 10 * pi])
65 ax.set_xticklabels([r"$-10\pi$", r"$-2\pi$", "$0$", r"$2\pi$", r"$10\pi$"])
66 ax.set_xlabel(r"$\omega$")
67 ax.set_ylabel(r"$\hat{f}(\omega)$")
68 ax.spines[["top", "right"]].set_visible(False)
69
70 a = np.logspace(np.log10(0.02), np.log10(3.0), 900)[: , None]
71 b = np.linspace(-0.6, 5.6, 1400)[None, :]
72 fig, ax = plt.subplots(figsize=(9.0, 4.6))
73 pc = ax.pcolormesh(b.ravel(), a.ravel(), np.abs(cwt_haar(a, b)), shading="
    gouraud", cmap="magma")
74 ax.set_yscale("log")
75 ax.set_xticks(range(6))
76 ax.set_xlabel("$b$")
77 ax.set_ylabel("$a$")
78 fig.colorbar(pc, ax=ax).set_label(r"$W_\psi f(a,b)$")
79

```

```
80 plt.show()
```

B.2. Daubechies-Wavelet

Der folgende Code erzeugt Abbildung 4.3. PyWavelets berechnet φ_2 und ψ_2 durch Iteration der Skalierungsgleichung (4.1) und legt ψ_2 auf $[0, 3]$. Die Verschiebung um 1 ergibt den Träger $[-1, 2]$, der nach Satz 4.16 zur Wahl (4.7) gehört.

Listing B.2: Skalierungsfunktion φ_2 und Wavelet ψ_2 aus Satz 4.16

```
1 # Daubechies-Skalierungsfunktion phi_2 und Wavelet psi_2 aus Kapitel 4.
2 import pywt
3 import matplotlib.pyplot as plt
4
5 phi, psi, t = pywt.Wavelet("db2").wavfun(level=10)
6
7 plt.rcParams.update({"font.size": 11, "axes.titlesize": 11, "mathtext.
8     fontset": "cm"})
9 fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.6))
10
11 ax[0].plot(t, phi, color="royalblue", lw=0.9)
12 ax[0].set_title(r"(a)  $\varphi_2$ ")
13 ax[1].plot(t - 1, psi, color="royalblue", lw=0.9)
14 ax[1].set_title(r"(b)  $\psi_2$ ")
15
16 for a in ax:
17     a.axhline(0, color="black", lw=0.5)
18     a.set_xlabel("$t$")
19     a.spines[["top", "right"]].set_visible(False)
20
21 plt.show()
```

B.3. Verrauschter Sinus

Der folgende Code erzeugt Abbildung 5.2 und die Zahlen aus Beispiel 5.5: die Fehlerenergie $\|Y - u\|^2$, ihren Erwartungswert $N\sigma^2$ sowie empirischen Mittelwert und empirische Varianz von $\tilde{Z} = AZ$. Als Kontrolle von Lemma 5.3 gibt das Skript zusätzlich $\|AZ\| - \|Z\|$ aus; der Wert verschwindet im Rahmen der Rundungsgenauigkeit.

Listing B.3: Verrauschter Sinus aus Beispiel 5.5

```
1 # Beispiel aus Kapitel 5: Sinus mit drei Spitzen, Koeffizienten pro Stufe
2   und Risiko der idealen Auswahl (Abb. 5.1).
3 import numpy as np
4 import pywt
5 import matplotlib.pyplot as plt
6
7 N = 2048
8 J = 5
9 sigma = 0.3
10 zentren = [1.3, 3.7, 6.2]
```

```

10
11 t = 8 * np.arange(N) / N
12 u = np.sin(2 * np.pi * t)
13
14 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
15 f = u + s
16
17 Z = np.random.default_rng(93).standard_normal(N)
18 Y = f + sigma * Z
19
20 cu = pywt.wavedec(u, "db2", mode="periodization", level=J)
21 cf = pywt.wavedec(f, "db2", mode="periodization", level=J)
22
23 namen = ["a5", "d5", "d4", "d3", "d2", "d1"]
24 print("Stufe  Anzahl  max|u|  >=sigma(u)  >=sigma(f)")
25 for name, a, b in zip(namen, cu, cf):
26     print(f"{name:5}  {len(a):6}  {np.max(np.abs(a)):.2g}  {np.sum(np.abs(a)
27         >= sigma):10}  {np.sum(np.abs(b) >= sigma):10}")
28
29 for name, c in [("u", cu), ("f", cf)]:
30     theta = np.concatenate(c)
31     M = np.sum(np.abs(theta) >= sigma)
32     r = np.sum(np.minimum(theta**2, sigma**2))
33     print(f"{name}: M = {M}, M sigma^2 = {M * sigma**2:.1f}, r_id = {r:.1f}")
34
35 print(f"N sigma^2 = {N * sigma**2:.1f}")
36
37 plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
38 fig, ax = plt.subplots(2, 1, figsize=(7.0, 3.6), sharex=True)
39
40 ax[0].plot(t, f, color="royalblue", lw=0.9)
41 ax[0].set_ylabel("$f$")
42 ax[1].plot(t, Y, color="gray", lw=0.5)
43 ax[1].set_ylabel("$Y$")
44 ax[1].set_xlabel("$t$")
45 ax[1].set_xlim(0, 8)
46
47 for a in ax:
48     a.set_ylim(-2.2, 4.0)
49     a.spines[["top", "right"]].set_visible(False)
50
51 plt.show()

```

B.4. Sinus mit Spitzen

Der folgende Code erzeugt Abbildung 5.5 und die Zahlen aus Beispiel 5.11: für jede Stufe die Anzahl der Koeffizienten, den größten Betrag beim Sinus und die Anzahl der Koeffizienten von u und f mit Betrag mindestens σ , außerdem M und das Risiko r_{id} der idealen Auswahl (5.4).

Listing B.4: Sinus mit Spitzen aus Beispiel 5.11

```

1 # Testsignal aus Kapitel 5: Sinus mit drei Spitzen und verrauschte Messwerte
  (Abb. 5.1).
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 N = 2048
6 sigma = 0.3
7 zentren = [1.3, 3.7, 6.2]
8
9 t = 8 * np.arange(N) / N
10 u = np.sin(2 * np.pi * t)
11
12 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
13 f = u + s
14
15 Z = np.random.default_rng(93).standard_normal(N)
16 Y = f + sigma * Z
17
18 plt.rcParams.update({"font.size": 9, "font.family": "serif"})
19 fig, ax = plt.subplots(2, 1, figsize=(6.0, 3.2), sharex=True)
20
21 ax[0].plot(t, f, color="royalblue", lw=0.9)
22 ax[0].set_ylabel("$f$")
23 ax[1].plot(t, Y, color="gray", lw=0.5)
24 ax[1].set_ylabel("$Y$")
25 ax[1].set_xlabel("$t$")
26 ax[1].set_xlim(0, 8)
27
28 for a in ax:
29     a.set_ylim(-2.2, 4.0)
30     a.spines[["top", "right"]].set_visible(False)
31
32 plt.show()

```

B.5. Detailkoeffizienten des Testsignals

Der folgende Code erzeugt Abbildung 5.6. Der k -te Koeffizient der Stufe j wird in der Mitte des Zeitabschnitts $[k 2^j / 256, (k + 1) 2^j / 256)$ eingezeichnet, für den er steht. Beträge über 2,5 werden abgeschnitten.

Listing B.5: Detailkoeffizienten des Testsignals aus Beispiel 5.11

```

1 # Beispiel aus Kapitel 5: Detailkoeffizienten d_5 bis d_1 des Testsignals f
  (Abb. 5.6).
2 import numpy as np
3 import pywt
4 import matplotlib.pyplot as plt
5
6 N = 2048
7 J = 5
8 zentren = [1.3, 3.7, 6.2]
9
10 t = 8 * np.arange(N) / N

```

```

11 u = np.sin(2 * np.pi * t)
12
13 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
14 f = u + s
15
16 c = pywt.wavedec(f, "db2", mode="periodization", level=J)
17
18 plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
19 fig, ax = plt.subplots(J, 1, figsize=(7.0, 6.0), sharex=True)
20
21 for i in range(J):
22     j = J - i
23     d = c[i + 1]
24     pos = (np.arange(len(d)) + 0.5) * 2**j / 256
25     ax[i].vlines(pos, 0, np.clip(d, -2.5, 2.5), color="royalblue", lw=1.1)
26     ax[i].axhline(0, color="black", lw=0.4)
27     ax[i].set_ylim(-2.5, 2.5)
28     ax[i].set_yticks([-2, 0, 2])
29     ax[i].set_ylabel(f"$d_{j}$", rotation=0, labelpad=12, va="center")
30     ax[i].spines[["top", "right"]].set_visible(False)
31
32 ax[-1].set_xlim(0, 8)
33 ax[-1].set_xlabel("$t$")
34 fig.tight_layout(h_pad=0.3)
35
36 plt.show()

```

B.6. Detailkoeffizienten der Messwerte

Der folgende Code erzeugt Abbildung 5.7 und die Zahlen aus dem ersten Absatz von Beispiel 5.13: den Schätzwert $\hat{\sigma}$ nach (5.7), die Schwelle T , den größten Rauschkoeffizienten $\max_m |0,3 \tilde{Z}_m|$ und die Anzahl der Koeffizienten, die Hard-Thresholding behält.

Listing B.6: Detailkoeffizienten der Messwerte aus Beispiel 5.13

```

1 # Beispiel aus Kapitel 5: Detailkoeffizienten d_5 bis d_1 der Messwerte Y
  mit Schwelle T (Abb. 5.7).
2 import numpy as np
3 import pywt
4 import matplotlib.pyplot as plt
5
6 N = 2048
7 J = 5
8 sigma = 0.3
9 zentren = [1.3, 3.7, 6.2]
10
11 t = 8 * np.arange(N) / N
12 u = np.sin(2 * np.pi * t)
13
14 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
15 f = u + s
16
17 Z = np.random.default_rng(93).standard_normal(N)

```

```

18 Y = f + sigma * Z
19
20 c = pywt.wavedec(Y, "db2", mode="periodization", level=J)
21
22 sigma_dach = np.median(np.abs(c[-1])) / 0.6745
23 T = sigma_dach * np.sqrt(2 * np.log(N))
24 AZ = np.concatenate(pywt.wavedec(Z, "db2", mode="periodization", level=J))
25
26 print(f"sigma_dach = {sigma_dach:.3f}")
27 print(f"T = {T:.2f}")
28 print(f"max|AZ| = {np.max(np.abs(AZ)):.2f}, max|sigma AZ| = {sigma * np.max(
    np.abs(AZ)):.2f}")
29 print(f"behalten (hart): {np.sum(np.abs(np.concatenate(c)) > T)} von {N}")
30
31 plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
32 fig, ax = plt.subplots(J, 1, figsize=(7.0, 6.0), sharex=True)
33
34 for i in range(J):
35     j = J - i
36     d = c[i + 1]
37     pos = (np.arange(len(d)) + 0.5) * 2*j / 256
38     ax[i].vlines(pos, 0, np.clip(d, -2.5, 2.5), color="royalblue", lw=1.0)
39     ax[i].axhline(0, color="black", lw=0.4)
40     ax[i].axhline(T, color="gray", ls="--", lw=0.8)
41     ax[i].axhline(-T, color="gray", ls="--", lw=0.8)
42     ax[i].set_ylim(-2.5, 2.5)
43     ax[i].set_yticks([-2, 0, 2])
44     ax[i].set_ylabel(f"$d_{j}$", rotation=0, labelpad=12, va="center")
45     ax[i].spines[["top", "right"]].set_visible(False)
46
47 ax[-1].set_xlim(0, 8)
48 ax[-1].set_xlabel("$t$")
49 fig.tight_layout(h_pad=0.3)
50
51 plt.show()

```

B.7. Entraushtes Testsignal

Der folgende Code erzeugt Abbildung 5.8 und die Fehlerenergien aus Beispiel 5.13. Wie in Algorithmus 2 werden alle Koeffizienten mit der Schwelle T bearbeitet, einschließlich der Approximation a_5 .

Listing B.7: Entrauschen des Testsignals aus Beispiel 5.13

```

1 # Beispiel aus Kapitel 5: Entrauschen des Testsignals mit Hard- und Soft-
    Thresholding (Abb. 5.8).
2 import numpy as np
3 import pywt
4 import matplotlib.pyplot as plt
5
6 N = 2048
7 J = 5
8 sigma = 0.3

```

```

9  zentren = [1.3, 3.7, 6.2]
10
11  t = 8 * np.arange(N) / N
12  u = np.sin(2 * np.pi * t)
13
14  s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
15  f = u + s
16
17  Z = np.random.default_rng(93).standard_normal(N)
18  Y = f + sigma * Z
19
20  c = pywt.wavedec(Y, "db2", mode="periodization", level=J)
21  sigma_dach = np.median(np.abs(c[-1])) / 0.6745
22  T = sigma_dach * np.sqrt(2 * np.log(N))
23
24  hart = pywt.waverec([pywt.threshold(d, T, "hard") for d in c], "db2", mode="
    periodization")
25  weich = pywt.waverec([pywt.threshold(d, T, "soft") for d in c], "db2", mode=
    "periodization")
26
27  print(f"||Y - f||^2 = {np.sum((Y - f) ** 2):.1f}")
28  print(f"hart: ||f_hart - f||^2 = {np.sum((hart - f) ** 2):.1f}")
29  print(f"weich: ||f_weich - f||^2 = {np.sum((weich - f) ** 2):.1f}")
30
31  plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
32  fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.8), sharey=True, gridspec_kw={"
    width_ratios": [2.2, 1]})
33
34  ax[0].plot(t, hart, color="royalblue", lw=0.9, label="hart")
35  ax[0].plot(t, weich, color="red", lw=0.7, label="weich")
36  ax[0].set_xlim(0, 8)
37  ax[0].set_ylim(-2.2, 4.0)
38  ax[0].set_xlabel("$t$")
39
40  aus = (t > 3.45) & (t < 3.95)
41  ax[1].plot(t[aus], f[aus], color="black", ls=":", lw=0.9, label="$f$")
42  ax[1].plot(t[aus], hart[aus], color="royalblue", lw=0.9, label="hart")
43  ax[1].plot(t[aus], weich[aus], color="red", lw=0.7, label="weich")
44  ax[1].set_xlabel("$t$ (Ausschnitt)")
45  ax[1].legend(frameon=False, loc="upper right")
46
47  for a in ax:
48      a.spines[["top", "right"]].set_visible(False)
49
50  fig.tight_layout()
51
52  plt.show()

```

Literaturverzeichnis

- [AJB17] Mounaim Aqil, Atman Jbari, and Abdennasser Bourouhou. ECG signal denoising by discrete wavelet transform. *International Journal of Online Engineering (iJOE)*, 13(9):51–68, 2017.
- [BK19] Steven L. Brunton and J. Nathan Kutz. *Fourier and Wavelet Transforms*, pages 47–83. Cambridge University Press, Cambridge, 2019.
- [Bla03] Christian Blatter. *Wavelets – Eine Einführung*. Advanced Lectures in Mathematics. Vieweg, Braunschweig/Wiesbaden, 2., durchgesehene edition, 2003.
- [CTY⁺20] Shubhojeet Chatterjee, Rini Smita Thakur, Ram Narayan Yadav, Lalita Gupta, and Deepak Kumar Raghuvanshi. Review of noise removal techniques in ECG signals. *IET Signal Processing*, 14(9):569–590, 2020.
- [Gac12] Adam Gacek. An introduction to ECG signal processing and analysis. In Adam Gacek and Witold Pedrycz, editors, *ECG Signal Processing, Classification and Interpretation*, pages 21–46. Springer, London, 2012.
- [HB09] Martin Hanke-Bourgeois. *Grundlagen der Numerischen Mathematik und des Wissenschaftlichen Rechnens*. Vieweg+Teubner, Wiesbaden, 3., aktualisierte edition, 2009.
- [LMR98] Alfred Karl Louis, Peter Maaß, and Andreas Rieder. *Wavelets: Theorie und Anwendungen*. Teubner-Studienbücher: Mathematik. B. G. Teubner, Stuttgart, 2., überarbeitete und erweiterte edition, 1998.
- [Mal09] Stéphane Mallat. *A Wavelet Tour of Signal Processing: The Sparse Way*. Academic Press / Elsevier, Burlington, MA, 3. edition, 2009.
- [Reb21] Linda Rebstadt. Spark-basierte analyse von monitoring-daten intensiv überwachter patienten zur identifikation von anomalien: Ein use case der charité health data platform. Masterarbeit, Hochschule Darmstadt, 2021.
- [Ser17] Valery Serov. *Fourier Series, Fourier Transform and Their Applications to Mathematical Physics*, volume 197 of *Applied Mathematical Sciences*. Springer, Cham, 2017.
- [SS03] Elias M. Stein and Rami Shakarchi. *Fourier Analysis: An Introduction*, volume I of *Princeton Lectures in Analysis*. Princeton University Press, Princeton, 2003.