

Universität Hamburg
DER FORSCHUNG | DER LEHRE | DER BILDUNG

BACHELORARBEIT

Entrauschung von EKG-Signalen mittels der diskreten Wavelet-Transformation

ausgeführt am

Fachbereich Mathematik
Fakultät für Mathematik, Informatik und Naturwissenschaften
Universität Hamburg

unter der Anleitung von

Name des Betreuers

durch

Hilda Beuting
Matrikelnummer: 12345678
Straße und Hausnummer
PLZ und Ort

Hamburg, am Datum

Inhaltsverzeichnis

1. Einleitung **1**
- 1.1. Motivation: EKG-Signale und ihre Störquellen . . . 1
- 1.2. Warum die Fourier-Analyse nicht genügt . . . 1
- 1.3. Zielsetzung und Abgrenzung . . . 2
- 1.4. Aufbau der Arbeit . . . 2

2. Funktionalanalytische Grundlagen **3**
- 2.1. Der Hilbertraum $L^2(\mathbb{R})$ . . . 3
- 2.2. Orthonormalbasen und ihre Charakterisierung . . . 3
- 2.3. Unitäre Operatoren . . . 4
- 2.4. Fourier-Transformation und Satz von Plancherel . . . 4
- 2.5. Die gefensterte Fourier-Transformation . . . 5
- 2.6. Grundbegriffe der Wahrscheinlichkeitsrechnung . . . 5

3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse **6**
- 3.1. Die kontinuierliche Wavelet-Transformation . . . 6
  - 3.1.1. Wavelets und die Zulässigkeitsbedingung . . . 7
  - 3.1.2. Die Wavelet-Familie und die Transformation . . . 9
  - 3.1.3. Die Plancherel-Formel . . . 13
- 3.2. Das dyadische Gitter und die Multiskalenanalyse . . . 16
  - 3.2.1. Die Axiome . . . 17
- 3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j . . . 19
  - 3.3.1. Die Orthonormalbasis auf allen Skalen . . . 20
  - 3.3.2. Die Approximationsoperatoren . . . 20
- 3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$ . . . 21
  - 3.4.1. Die Wavelet-Basis . . . 22

4. Konstruktion der diskreten Wavelet-Transformation **24**
- 4.1. Die Skalierungsgleichung . . . 24
- 4.2. Filterkoeffizienten: Tiefpass und Hochpass . . . 25
- 4.3. Bedingungen im Fourier-Bereich . . . 27
- 4.4. Der Mallat-Algorithmus . . . 28
- 4.5. Daubechies-Wavelets . . . 30

5. Entrauschung durch Thresholding **34**
- 5.1. Rauschmodell und diskrete Wavelet-Transformation . . . 34
- 5.2. Diagonale Schätzer und Thresholding . . . 37
- 5.3. Die Wahl der Schwelle . . . 42
- 5.4. Schätzung der Rauschstärke . . . 43

6. Anwendung: Entrauschung von EKG-Signalen **46**
6.1. EKG-Signale und ihre Störquellen . . . 46
6.2. Die Datensätze . . . 47
6.3. Skalen als Frequenzbänder . . . 49
6.4. Das Verfahren . . . 50
6.4.1. Modell und Ein-Schritt-Verfahren . . . 51
6.4.2. Tiefe J für die Drift . . . 52
6.4.3. Anzahl J_S der geschwellten Stufen . . . 53
6.4.4. Schwelle . . . 53
6.5. Test an einem künstlichen EKG . . . 53
6.6. Anwendung auf die Datensätze 100 und 103 . . . 56
6.7. Diskussion . . . 56

7. Fazit und Ausblick **59**

A. Ergänzende Rechnungen **60**
A.1. Fourier-Transformierte des Testsignals . . . 60
A.2. Stammfunktion des Testsignals . . . 61

B. Python-Code **62**
B.1. Beispiel zur kontinuierlichen Wavelet-Transformation . . . 62
B.2. Daubechies-Wavelet . . . 64
B.3. Daubechies-Wavelet mit zwölf Koeffizienten . . . 64
B.4. Verrauschter Sinus . . . 65
B.5. Sinus mit Spitzen . . . 66
B.6. Detailkoeffizienten des Testsignals . . . 67
B.7. Detailkoeffizienten der Messwerte . . . 68
B.8. Entrauschtes Testsignal . . . 69
B.9. Anwendung auf EKG-Signale . . . 70

Literaturverzeichnis **80**

1. Einleitung

Anmerkung. Einleitung ganz zum Schluss schreiben. Laut Vorlage muss hier stehen: (a) Worum geht es, (b) Einordnung ins Forschungsfeld, (c) Fragestellung, (d) Relevanz, (e) vorhandene Literatur, (f) EIGENER ANTEIL der Arbeit, (g) grober Aufbau der Arbeit.

1.1. Motivation: EKG-Signale und ihre Störquellen

Anmerkung. EKG-Signale und ihre Störquellen Das EKG ist ein nichtstationäres biomedizinisches Signal, dessen diagnostisch entscheidende Strukturen von Störungen überlagert werden, die im selben Frequenzband liegen wie das Nutzsignal — womit einfache Frequenzfilter ausscheiden.

Anmerkung. hier schon kurzer aufbau ekg signal kurzer qrskomplex und langer t p welle...

Belegstellen.

- LMR, Kap. 3.1.2 „EKG-Analyse", S. 238–240 [bestätigt] — Herzklappenrhythmus und „late potentialsäls diagnostische Fragestellungen; Abb. 3.1 (S. 239)
- Gacek, Kap. 2.1, S. 21–22 [bestätigt] — diagnostische Bedeutung, historische Einordnung
- Gacek, Kap. 2.3, S. 25–27 [bestätigt] — Störquellen im Überblick
- Chatterjee, Kap. 1.1 „Predominant noises in ECG", S. 570 [bestätigt]
- Aqil, Kap. 2, S. 53–54 [bestätigt] — Fig. 3, Rauschtypen
- Rebstadt, Kap. 2.1, S. 7–11 [bestätigt] — Abb. 2.3 (S. 10)

1.2. Warum die Fourier-Analyse nicht genügt

Anmerkung. VERSCHOBEN aus dem alten Abschnitt 2.5. Begründung: In Kapitel 2 war das ein Fremdkörper – dort werden Werkzeuge bereitgestellt, hier wird die Fragestellung motiviert. Der Abschnitt liefert genau das Argument, das die ganze Arbeit trägt: Die Fourier-Basis sagt, *welche* Frequenzen auftreten, nicht *wann*.

Anmerkung. Die Fourier-Basis ist global; sie sagt welche Frequenzen auftreten, nicht wann — bei einem QRS-Komplex ist genau die Lokalisierung entscheidend.

Belegstellen.

- LMR, Kap. 1.3.2 „Wavelet-Transformation und gefensterte Fourier-Transformation", S. 36–37 [bestätigt] — direkter Vergleich beider Transformationen, in der 2. Auflage eigens dafür neu aufgenommen

- LMR, Kap. 1.3.1 „Phasenraumdarstellung", S. 30–35 [bestätigt]
- LMR, Vorwort zur ersten Auflage, S. 3 [bestätigt] — fehlende Lokalisierungseigenschaft der Fourier-Transformation, prägnant formuliert
- Blatter, Kap. 1.4, S. 10–12 [bestätigt]; Kap. 2.3 „Heisenbergsche Unschärferelation", S. 43–46 [bestätigt]
- SteinShakarchi, Kap. 5.4, S. 158–160 [bestätigt]
- HankeBourgeois, Beispiel 52.7 mit Abbildung 52.1, S. 403–404 [bestätigt] — reales EKG-Signal mit $N = 2048$ Meßwerten und seinen Bestapproximationen aus T_8 und T_{32} ; die scharfen Peaks werden mit sinkendem Polynomgrad ausgeglättet, t_8 „übersieht"das Minimum am ca. 200. Datenpunkt
- HankeBourgeois, S. 433–434 [bestätigt] — quantitativ: die Fourierkoeffizienten von $\chi_{[a,b]}$ fallen nur wie $1/k$, der L^2-Fehler nach n Termen ist $\sim n^{-1/2}$; „schlechte Lokalisierungseigenschaft bezüglich der Ortsvariablen"
- HankeBourgeois, Beispiel 56.3 mit Abbildung 56.2, S. 440 [bestätigt] — Fourier- vs. Waveletkoeffizienten desselben EKG-Signals in logarithmischer Skala
- Rebstadt, Abb. 2.7, S. 22 [bestätigt]
- Fußnote S. 404: Die EKG-Daten stammen laut HankeBourgeois von Prof. Dr. P. Maaß, Universität Bremen — demselben Maaß wie in Louis/Maaß/Rieder. Deine beiden deutschsprachigen Quellen arbeiten am selben Signal.

1.3. Zielsetzung und Abgrenzung

Anmerkung. Ziel ist die mathematisch vollständige Herleitung der DWT-Entrauschung; Abgrenzung gegenüber konkurrierenden Verfahren, die nur benannt werden.

Belegstellen.

- LMR, Vorwort zur ersten Auflage, S. 3–4 [bestätigt] — Verzahnung von Theorie und Anwendung als Programm
- Chatterjee, Kap. 2–4, S. 571–581
- Rebstadt, Kap. 2.3, S. 14–31 [bestätigt]

1.4. Aufbau der Arbeit

2. Funktionalanalytische Grundlagen

Anmerkung. Block A. Kapiteleinleitung: Ziel ist der funktionalanalytische Rahmen, in dem die Wavelet-Transformation als unitäre Abbildung erscheint.

2.1. Der Hilbertraum $L^2(\mathbb{R})$

Anmerkung. Einführung von $L^2(\mathbb{R})$ als vollständigem Raum mit Skalarprodukt — dem Raum, in dem sämtliche Signale und Wavelets im Folgenden leben.

Belegstellen.

- Serov, Kap. 25, S. 249–253 [bestätigt] (Def. 25.1 Skalarprodukt, Def. 25.7 Hilbertraum)
- Blatter, Kap. 2.1, S. 26–27 [bestätigt]
- LMR, „Notationen", S. 9–12 [bestätigt] — Räume $L^p, C^(\infty), S(\mathbb{R}), S'(\mathbb{R})$ in genau der Notation, die LMR durchgehend verwendet

2.2. Orthonormalbasen und ihre Charakterisierung

Anmerkung. Der zentrale Satz: Vollständigkeit, Parseval-Gleichung und die Entwicklung jedes Elements sind für ein Orthonormalsystem äquivalent.

Belegstellen.

- Serov, Satz 25.18 „Characterization of an orthonormal basis", S. 258 [bestätigt]
- Serov, Def. 25.16–25.17, S. 257–258 [bestätigt]
- Serov, Satz 25.12 (Projektionssatz), S. 254–255 [geschätzt]
- Blatter, Kap. 2.1, S. 27 [bestätigt]
- HankeBourgeois, Satz 31.6, S. 281 [bestätigt] — (a) Entwicklung, (b) Satz des Pythagoras, (c) Bestapproximation, (d) Besselsche Ungleichung, mit Beweis
- HankeBourgeois, §31 „Innenprodukträume, Orthonormalbasen und Gramsche Matrizen", S. 275–282 [bestätigt]; Definition von $L\omega$, S. 279–280 [geschätzt]

2.3. Unitäre Operatoren

Anmerkung. Ein unitärer Operator ist eine surjektive Isometrie; er erhält Skalarprodukte und damit Energie — der Grund, warum Rauschen unter der DWT seine Statistik behält.

Belegstellen.

- Serov, Def. 27.7 und Bem. 27.8, S. 282 [bestätigt] (Sachverz.: „unitary operator, 282")
- LMR, Kap. 1.2 „Affine Operatoren", S. 26–29 [bestätigt] — Dilatationsoperator D_a, Translationsoperator T_b, beide Isometrien mit Bild ganz L^2, daher Adjungierte = Inverse
- LMR, Lemma 1.2.1 (adjungierte affine Operatoren), S. 27 [bestätigt]
- LMR, S. 27 [bestätigt] — affin-lineare Gruppe $G_{a,f}$ und Verknüpfungsgesetz $T_{b'}D_{a'}T_bD_a = T_{b'+a'b}D_{aa'}$

2.4. Fourier-Transformation und Satz von Plancherel

Anmerkung. Die Fourier-Transformation setzt sich von der Schwartz-Klasse eindeutig zu einem unitären Isomorphismus auf $L^2(\mathbb{R})$ fort.

Belegstellen.

- Serov, Satz 17.5 (Plancherel), S. 145 [bestätigt]
- Serov, Kap. 16–17, S. 133–152 [bestätigt]
- SteinShakarchi, Kap. 5.1, S. 131–144 [bestätigt]
- Blatter, Kap. 2.2, S. 31–42 [bestätigt]; Plancherel-Formel S. 36 [bestätigt]
- LMR, Anhang „Fourier-Transformation", S. 313–316 [bestätigt] — kompakte Zusammenstellung genau der Regeln, die LMR im Waveletteil benutzt

Bemerkung 2.1 (Fourier-Konvention). In dieser Arbeit wird durchgehend die unitäre Normierung

$$\hat{f}(\omega) \;=\; (2\pi)^{-1/2} \int_{\mathbb{R}} f(t)\, e^{-i\omega t}\, dt$$

verwendet. Mit ihr ist die Fourier-Transformation ein unitärer Operator auf $L^2(\mathbb{R})$, und die Plancherel-Formel gilt ohne Vorfaktor: $\langle f, g\rangle = \langle \hat{f}, \hat{g}\rangle$.

Die Literatur normiert uneinheitlich, und die Konstanten der folgenden Kapitel hängen von der Wahl ab: Der Faktor 2π in der Zulässigkeitsbedingung (3.1) und der Wert $|\hat{\varphi}(0)| = (2\pi)^{-1/2}$ in Abschnitt 4.1 gelten nur für diese Normierung. Beim Vergleich mit einer Quelle ist deshalb zuerst deren Konvention nachzusehen.

Anmerkung. das vll besser erst später

2.5. Die gefensterte Fourier-Transformation

Anmerkung. Hierher gehört die quantitative Begründung der festen Fensterbreite: Heisenbergsche Unschärferelation, Zeit-Bandbreite-Produkt. Abschnitt 3.1 verweist darauf. Belege: Blatter, Kap. 2.3, S. 43–46 [bestätigt]; LMR, Kap. 1.3.1, S. 30–35 [bestätigt].

2.6. Grundbegriffe der Wahrscheinlichkeitsrechnung

In Kapitel 5 wird das Rauschen in einem Messsignal als zufällig modelliert. Dafür genügen die folgenden Begriffe [Mal09, Anhang A.6]. Ein Zufallsvektor $X = (X_0, \dots, X_{N-1})$ besteht aus N Zufallsvariablen X_n. Hat eine Zufallsvariable X die Wahrscheinlichkeitsdichte p, so heißen

$$\mathbb{E}[X] \;=\; \int_{\mathbb{R}} x\, p(x)\, dx \qquad \text{und} \qquad \operatorname{Var}(X) \;=\; \mathbb{E}\big[|X - \mathbb{E}[X]|^2\big]$$

ihr Erwartungswert und ihre Varianz; die Kovarianz zweier Zufallsvariablen ist

$$\operatorname{Cov}(X_1, X_2) \;=\; \mathbb{E}\big[(X_1 - \mathbb{E}[X_1])\,(X_2 - \mathbb{E}[X_2])\big].$$

Ist $\operatorname{Cov}(X_1, X_2) = 0$, so heißen X_1 und X_2 unkorreliert. Der Erwartungswert ist linear. Mit $\mathbb{P}$ bezeichnen wir Wahrscheinlichkeiten.

Definition 2.2 (Normalverteilung, vgl. [Mal09, Kap. 11.2.2]). Sei $\phi(x) = (2\pi)^{-1/2} e^{-x^2/2}$ die Gauß'sche Dichte. Eine Zufallsvariable X heißt normalverteilt mit Erwartungswert μ und Varianz $\sigma^2 > 0$, kurz $X \sim \mathcal{N}(\mu, \sigma^2)$, wenn sie die Dichte $p(x) = \sigma^{-1}\phi\big((x-\mu)/\sigma\big)$ hat, und standardnormalverteilt im Fall $\mu = 0$, $\sigma = 1$.

Gemeinsam normalverteilt heißen Zufallsvariablen, die zusammen einen Gauß'schen Zufallsvektor bilden. Für sie gilt:

Satz 2.3 (vgl. [Mal09, Kap. 11.1.1]). *Gemeinsam normalverteilte Zufallsvariablen, die paarweise unkorreliert sind, sind unabhängig.*

3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse

Anmerkung. Die kontinuierliche Wavelet-Transformation wird in diesem Kapitel nur so weit entwickelt, dass sichtbar wird, warum man sie diskretisieren muss. Zielpunkt des Kapitels ist die Multiskalenanalyse.

3.1. Die kontinuierliche Wavelet-Transformation

Die Darstellung dieses Abschnitts folgt im Wesentlichen [Bla03, Kap. 3.1–3.3]; ergänzend, insbesondere zum Abklingverhalten und zu den Approximationseigenschaften, wird [LMR98, Kap. 1.1] herangezogen. Es gilt durchgehend die Fourier-Konvention aus Bemerkung 2.1.

Die in Kapitel 2 entwickelte Fourier-Transformation zerlegt ein Signal in reine Schwingungen $e^{i\omega t}$ und misst mit $\hat{f}(\omega)$, wie stark jede Frequenz ω darin vertreten ist. Sie liefert damit welche Frequenzen vorkommen und in welcher Stärke – nicht aber, an welcher Stelle des Signals.

Für ein EKG-Signal ist das eine ungünstige Ausgangslage. Der QRS-Komplex ist zeitlich kurz und damit breitbandig, das heißt, seine Energie verteilt sich über einen weiten Frequenzbereich; P- und T-Welle sind zeitlich ausgedehnt und schmalbandig, ihre Energie konzentriert sich auf wenige tiefe Frequenzen [Reb21, Kap. 2.3.1]. Eine geeignete Analyse muss beide Anteile gleichzeitig auflösen können.

Die Fourier-Transformation kann das prinzipiell nicht leisten: Ihre Analysefunktionen $e^{i\omega t}$ haben auf ganz $\mathbb{R}$ konstanten Betrag, sie zerlegt also ausschließlich entlang der Frequenzachse [LMR98, Bem. 1.3.4]. Der zeitlich kurze QRS-Komplex wird dabei über das gesamte Spektrum verschmiert und liegt in keinem einzelnen Koeffizienten von den gleichzeitig vorhandenen Anteilen der P- und T-Welle getrennt vor [Bla03, Kap. 1.2–1.3]. Da die in Kapitel 5 betrachteten Schwellenwertverfahren koeffizientenweise arbeiten, trifft ein Eingriff, der Rauschen bei einer Frequenz entfernt, damit unvermeidlich das Signal zu allen Zeitpunkten.

Die in Abschnitt 2.5 beschriebene gefensterte Fourier-Transformation löst dieses Problem nur teilweise. Sie betrachtet nicht mehr das ganze Signal auf einmal, sondern schneidet mit einem Fenster jeweils einen Ausschnitt heraus und bestimmt dessen Frequenzgehalt. Damit ist bekannt, wann welche Frequenzen auftreten – allerdings nur so genau, wie das Fenster breit ist. Da diese Breite für alle Frequenzen dieselbe ist, muss man sich von vornherein festlegen: Ein Fenster, das schmal genug ist, um den QRS-Komplex zu isolieren, enthält zu wenige Perioden der T-Welle, um deren niedrige Frequenzanteile aufzulösen – und umgekehrt. Dass sich Zeit- und Frequenzauflösung dabei nicht gleichzeitig beliebig verbessern lassen, ist der Gehalt der Heisenbergschen Unschärferelation (Abschnitt 2.5); vgl. [Bla03, Kap. 2.3] und [LMR98, Kap. 1.3.1].

Anmerkung. wenn heisenbergunschärfe geschirieben dann richtigen verweis einfügen...

Die Wavelet-Transformation macht die Fensterbreite deshalb von der Frequenz abhängig, statt sie fest zu wählen. Hohe Frequenzen werden mit kurzen, tiefe mit langen Fenstern untersucht – schnelle Vorgänge also zeitlich genau, langsame dafür in der Frequenz genau [LMR98, Kap. 1.3.2].

Abbildung 3.1 stellt die Zeit-Frequenz-Auflösung der drei Transformationen einander gegenüber. Jede Kachel steht darin für die kleinste Zelle der Zeit-Frequenz-Ebene, die von der jeweiligen Transformation noch getrennt aufgelöst wird.

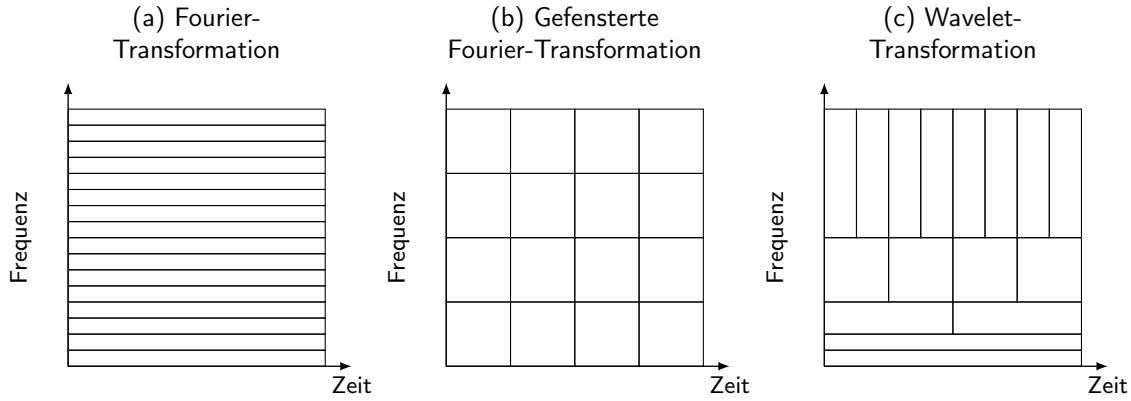


Abbildung 3.1.: Zeit-Frequenz-Auflösung im Vergleich. Jede Kachel steht für die kleinste Zelle, die von der jeweiligen Transformation noch getrennt aufgelöst wird. Alle Kacheln besitzen denselben Flächeninhalt; die Transformationen unterscheiden sich allein in deren Zuschnitt. In Anlehnung an [BK19, Figure 2.23].

Die drei Bilder lassen sich nacheinander lesen. In (a) ist jede Kachel so breit wie das ganze Signal: Die Frequenz wird so genau bestimmt, wie es die Signallänge zulässt, ihr Zeitpunkt überhaupt nicht. In (b) zerfällt die Ebene in ein gleichmäßiges Raster; Zeit- und Frequenzauflösung sind nun beide endlich, aber auf allen Frequenzen dieselbe – die Kachelform wird mit dem Fenster einmal festgelegt und gilt überall. In (c) ändert sie sich dagegen mit der Höhe: Oben, bei hohen Frequenzen, sind die Kacheln schmal und hoch, unten breit und flach.

Entscheidend ist, dass der Flächeninhalt dabei konstant bleibt. Auflösung lässt sich nicht gewinnen, sondern nur umverteilen; die Wavelet-Transformation verteilt sie dorthin, wo ein EKG sie braucht – Zeitauflösung beim kurzen, hochfrequenten QRS-Komplex, Frequenzauflösung bei der langen, tieffrequenten T-Welle.

Damit ist geklärt, welche Eigenschaft die Wavelet-Transformation von den beiden zuvor betrachteten Verfahren unterscheidet. Zwei Fragen bleiben offen: Welche Funktionen ψ sind überhaupt als Wavelet zugelassen, und wie ist die Transformation genau definiert? Die erste beantwortet der folgende Abschnitt, die zweite Abschnitt 3.1.2.

3.1.1. Wavelets und die Zulässigkeitsbedingung

Ausgangspunkt ist eine einzige Funktion ψ, aus der die gesamte Wavelet-Familie durch Skalierung und Verschiebung hervorgeht. An ψ ist eine Integralbedingung zu stellen; ihre Tragweite wird erst in Satz 3.10 vollständig sichtbar, wo sie sich als genau diejenige Bedingung erweist, unter

der die Transformation umkehrbar ist.

Anmerkung. davor auf jeden fall l2 norm definienren

Definition 3.1 (Wavelet, [Bla03, Kap. 3.1, Bedingungen (1) und (2)]). Eine Funktion $\psi \in L^2(\mathbb{R})$ mit $\|\psi\|_{L^2(\mathbb{R})} = 1$ heißt Mutter-Wavelet (kurz: Wavelet), falls sie die Zulässigkeitsbedingung

$$C_\psi := 2\pi \int_{\mathbb{R}^*} \frac{|\hat{\psi}(\omega)|^2}{|\omega|}\, d\omega < \infty \tag{3.1}$$

erfüllt, wobei $\mathbb{R}^* := \mathbb{R} \setminus \{0\}$.

Die Bedingung (3.1) ist abstrakt und für eine gegebene Funktion nicht unmittelbar sichtbar. Unter einer milden Abklingvoraussetzung lässt sie sich jedoch äquivalent durch eine Bedingung im Zeitbereich ersetzen, die unmittelbar überprüfbar ist und zugleich erklärt, warum die Bezeichnung Wavelet – kleine Welle – angemessen ist.

Satz 3.2 (Charakterisierung der Zulässigkeit, [Bla03, Satz (3.1)]). *Sei $\psi \in L^2(\mathbb{R})$, $\psi \neq 0$, mit $\int_{\mathbb{R}} |t|\,|\psi(t)|\,dt < \infty$. Dann sind äquivalent:*

(i) $C_\psi < \infty$,

(ii) $\int_{\mathbb{R}} \psi(t)\,dt = 0$, *gleichbedeutend mit* $\hat{\psi}(0) = 0$.[1]

Der Beweis findet sich bei [Bla03, Beweis zu Satz (3.1)] und wird hier nicht ausgeführt.

Bemerkung 3.3. Jedes Wavelet $\psi \in L^1(\mathbb{R})$ hat den Mittelwert null: $\hat{\psi}$ ist dann stetig, und das Integral in (3.1) kann nur für $\hat{\psi}(0) = 0$ konvergieren [LMR98, Kap. 1.1]. Sein Graph verläuft daher notwendig teils oberhalb, teils unterhalb der t-Achse, wie bei einer Welle [Bla03, Kap. 3.1]. Die in den Anwendungen verwendeten Wavelets haben darüber hinaus kompakten Träger oder fallen schnell ab; erst zusammen damit ergibt sich das Bild einer zeitlich begrenzten, kleinen Welle.

Das folgende Beispiel macht Definition 3.1 und Satz 3.2 an der einfachsten möglichen Funktion konkret.

Beispiel 3.4 (Haar-Wavelet). Die Funktion

$$\psi^{\mathrm{H}}(t) := \begin{cases} 1, & 0 \le t < 1/2, \\ -1, & 1/2 \le t < 1, \\ 0, & \text{sonst}, \end{cases}$$

hat kompakten Träger, also $\int_{\mathbb{R}} |t|\,|\psi^{\mathrm{H}}(t)|\,dt < \infty$, und Mittelwert null, erfüllt also nach Satz 3.2 die Zulässigkeitsbedingung; wegen $\|\psi^{\mathrm{H}}\|_{L^2(\mathbb{R})} = 1$ ist sie ein Wavelet im Sinne von Definition 3.1. Ihre Fourier-Transformierte lässt sich mit der stetig nach $x = 0$ fortgesetzten Funktion

$$\operatorname{sinc}(x) := \frac{\sin x}{x} \quad (x \neq 0), \qquad \operatorname{sinc}(0) := 1,$$

[1] Die Gleichbedeutung ist die Fourier-Konvention aus Bemerkung 2.1 an der Stelle $\omega = 0$: Dort steht $\hat{\psi}(0) = (2\pi)^{-1/2} \int_{\mathbb{R}} \psi(t)\,dt$, beide Formulierungen sagen also dasselbe. Der Punktwert ist dabei erklärt, weil die Voraussetzung $\psi \in L^1(\mathbb{R})$ erzwingt – auf $|t| \le 1$ nach Cauchy–Schwarz, auf $|t| > 1$ wegen $|\psi(t)| \le |t|\,|\psi(t)|$ – und $\hat{\psi}$ für L^1-Funktionen stetig ist [Ser17, Satz 12.1].

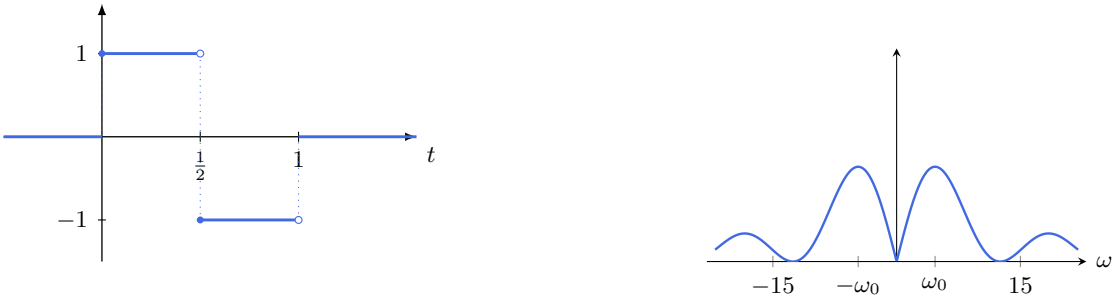
geschlossen angeben als

$$\widehat{\psi^{\mathrm{H}}}(\omega) \;=\; \frac{i}{\sqrt{2\pi}}\, e^{-i\omega/2}\, \sin(\omega/4)\, \operatorname{sinc}(\omega/4), \qquad \omega \in \mathbb{R}. \tag{3.2}$$

Die Aussage von Satz 3.2 ist unmittelbar ablesbar: Der Faktor $\sin(\omega/4)$ verschwindet bei $\omega = 0$, also ist $\widehat{\psi^{\mathrm{H}}}(0) = 0$. Da ψ^{H} reellwertig ist, gilt außerdem $\widehat{\psi^{\mathrm{H}}}(-\omega) = \overline{\widehat{\psi^{\mathrm{H}}}(\omega)}$, also ist $|\widehat{\psi^{\mathrm{H}}}|$ eine gerade Funktion. Wegen $\sin(\omega/4)\operatorname{sinc}(\omega/4) = 4\sin^2(\omega/4)/\omega$ für $\omega \neq 0$ ist $|\widehat{\psi^{\mathrm{H}}}(\omega)|^2 = 16\sin^4(\omega/4)/(2\pi\omega^2)$, und aus der Symmetrie des Integranden folgt

$$\begin{aligned} C_{\psi^{\mathrm{H}}} &= 2\pi \cdot 2 \int_0^\infty \frac{16\sin^4(\omega/4)}{2\pi\,\omega^2} \cdot \frac{d\omega}{\omega} \;=\; 32 \int_0^\infty \frac{\sin^4(\omega/4)}{\omega^3}\, d\omega \\ &= 32 \int_0^\infty \frac{\sin^4 u}{(4u)^3}\, 4\, du \;=\; 2\int_0^\infty \frac{\sin^4 u}{u^3}\, du \;=\; 2\ln 2, \end{aligned}$$

wobei im vorletzten Schritt $u = \omega/4$ substituiert wurde; der Wert des letzten Integrals ist $\ln 2$. Abbildung 3.2 zeigt ψ^{H} und den Betrag ihrer Fourier-Transformierten [LMR98, Kap. 1.1, Beispiel (1)].



(a) ψ^{H} (b) $|\widehat{\psi^{\mathrm{H}}}|$

Abbildung 3.2.: Das Haar-Wavelet ψ^{H} im Zeitbereich (a) und der Betrag seiner Fourier-Transformierten (b); $\omega_0 \approx 4{,}66$ bezeichnet die Lage des globalen Maximums, nach [LMR98, Kap. 1.1, Beispiel (1)].

3.1.2. Die Wavelet-Familie und die Transformation

Wir wollen das feste Mutter-Wavelet nun skalieren und verschieben und dadurch eine Wavelet-Familie erhalten.

Definition 3.5 (Wavelet-Familie und kontinuierliche Wavelet-Transformation, [Bla03, Kap. 3.1, Gl. (4)–(6)]). Sei ψ ein Wavelet im Sinne von Definition 3.1. Für $(a, b) \in \mathbb{R}^* \times \mathbb{R}$ setzen wir

$$\psi_{a,b}(t) \;:=\; \frac{1}{|a|^{1/2}}\, \psi\!\left(\frac{t-b}{a}\right), \qquad t \in \mathbb{R}. \tag{3.3}$$

Die kontinuierliche Wavelet-Transformation (CWT) von $f \in L^2(\mathbb{R})$ bezüglich ψ ist die Funktion

$$W_\psi f \colon \mathbb{R}^* \times \mathbb{R} \to \mathbb{C}, \qquad W_\psi f(a,b) \;:=\; \langle f, \psi_{a,b} \rangle \;=\; \frac{1}{|a|^{1/2}} \int_{\mathbb{R}} f(t)\, \overline{\psi\left(\frac{t-b}{a}\right)}\, dt. \tag{3.4}$$

Die Menge $\mathbb{R}^*_\square := \mathbb{R}^* \times \mathbb{R}$, auf der $W_\psi f$ erklärt ist, heißt die zersägte (a,b)-Ebene. Ist das zugrunde liegende Wavelet aus dem Zusammenhang klar, schreiben wir kurz Wf.

Bemerkung 3.6 (Normierung der Familie)**.** Die Substitution $t = as + b$ liefert

$$\|\psi_{a,b}\|^2_{L^2(\mathbb{R})} \;=\; \frac{1}{|a|} \int_{\mathbb{R}} \left|\psi\left(\tfrac{t-b}{a}\right)\right|^2 dt \;=\; \int_{\mathbb{R}} |\psi(s)|^2\, ds \;=\; \|\psi\|^2_{L^2(\mathbb{R})}$$

für alle $(a,b) \in \mathbb{R}^* \times \mathbb{R}$; dabei ist $dt = |a|\, ds$, was den Vorfaktor $|a|^{-1}$ gerade aufhebt – auch für $a < 0$, da die Substitution dann zusätzlich die Integrationsgrenzen vertauscht. Genau dafür ist der Faktor $|a|^{-1/2}$ gewählt: Jede andere Potenz von $|a|$ würde die Norm skalenabhängig machen. Mit $\|\psi\|_{L^2(\mathbb{R})} = 1$ aus Definition 3.1 ist somit die gesamte Wavelet-Familie normiert [Bla03, Kap. 3.1].

Anmerkung. davor support definieren - in grundlagen ist der träger einfach...

Bemerkung 3.7 (Bedeutung der beiden Parameter)**.** Ist ψ kompakt getragen, so gilt $\operatorname{supp} \psi_{a,b} = b + a \cdot \operatorname{supp} \psi$, das heißt der Träger von $\psi_{a,b}$ ist das um den Faktor $|a|$ gestreckte und nach b verschobene Bild von $\operatorname{supp} \psi$; für $a < 0$ wird ψ dabei zusätzlich an der Geraden $t = b$ gespiegelt. Der Parameter b verschiebt also das Wavelet entlang der Zeitachse, sodass $Wf(a,b)$ lokale Information über f in der Umgebung von $t = b$ trägt; der Parameter a steuert die Größe dieses Einflussbereichs. Für $a \to 0$ zoomt die Transformation immer schärfer auf $t = b$ [LMR98, Kap. 1.1]. Abbildung 3.3 zeigt die Skalierung und Verschiebung des Haar-Wavelets. Für das EKG bedeutet das: Der QRS-Komplex wird bei kleinen $|a|$ mit einem Träger von einigen zehn Millisekunden abgetastet – der QRS-Komplex selbst ist etwa 100 ms breit [Reb21, Kap. 2.3.1] –, die T-Welle bei großen $|a|$ mit einem entsprechend langen.

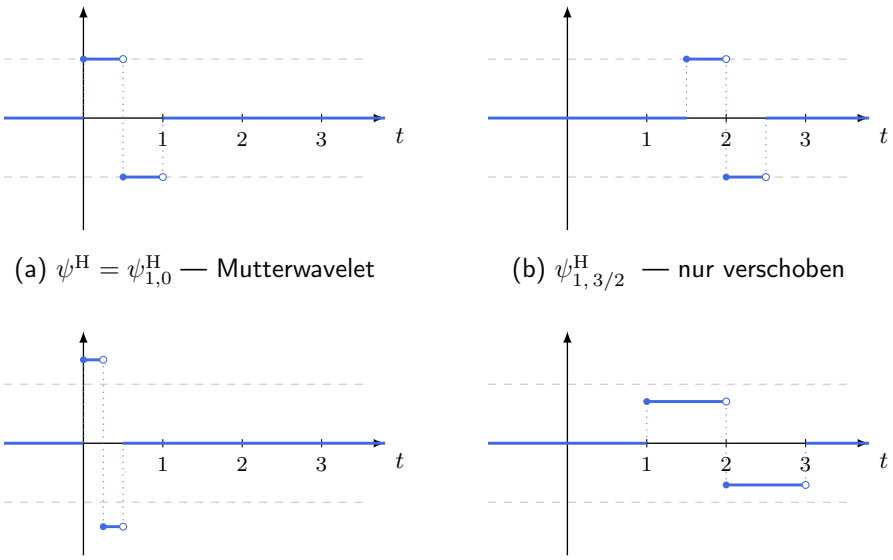
Beispiel 3.8 (Ein Testsignal mit zwei Frequenzen)**.** Betrachtet wird

$$f(t) = \begin{cases} 1 - \cos(2\pi t), & 0 \le t \le 3, \\ \frac{1}{2}\big(1 - \cos(10\pi t)\big), & 4 \le t \le 5, \\ 0, & \text{sonst.} \end{cases}$$

Auf $[0,3]$ schwingt f mit der Frequenz 1, auf $[4,5]$ mit der Frequenz 5; in beide Intervalle passt jeweils eine ganze Anzahl von Perioden (Abbildung 3.4). Als beschränkte Funktion mit kompaktem Träger liegt f in $L^1(\mathbb{R}) \cap L^2(\mathbb{R})$.

Fourier-Transformierte. Elementare Integration, bei der die ganzzahligen Periodenzahlen die Randterme vereinfachen, liefert in der Konvention aus Bemerkung 2.1 (Rechnung in Anhang A.1)

$$\hat{f}(\omega) = \frac{i}{\sqrt{2\pi}\,\omega} \left[\frac{4\pi^2\big(1 - e^{-3i\omega}\big)}{\omega^2 - 4\pi^2} + \frac{50\pi^2\big(e^{-4i\omega} - e^{-5i\omega}\big)}{\omega^2 - 100\pi^2} \right], \tag{3.5}$$



(a) $\psi^{\mathrm{H}} = \psi^{\mathrm{H}}_{1,0}$ — Mutterwavelet

(b) $\psi^{\mathrm{H}}_{1,\,3/2}$ — nur verschoben

(c) $\psi^{\mathrm{H}}_{1/2,\,0}$ — nur skaliert

(d) $\psi^{\mathrm{H}}_{2,\,1}$ — beides

Abbildung 3.3.: Die Wavelet-Familie (3.3) am Haar-Wavelet. (b) verschiebt den Träger nach $[\frac{3}{2}, \frac{5}{2}]$, ohne die Form zu ändern. (c) staucht ihn auf $[0, \frac{1}{2}]$, wobei die Amplitude auf $\sqrt{2}$ steigt; (d) streckt ihn auf $[1, 3]$ bei Amplitude $1/\sqrt{2}$. Die gestrichelten Linien markieren ± 1. In allen vier Fällen ist das Produkt aus Trägerlänge und quadrierter Amplitude gleich eins — die Familie ist normiert (Bemerkung 3.6).

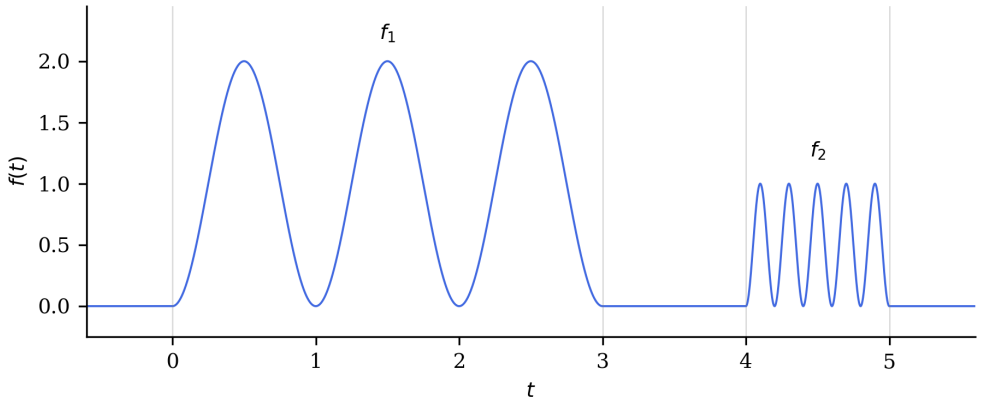


Abbildung 3.4.: Das Signal f aus Beispiel 3.8.

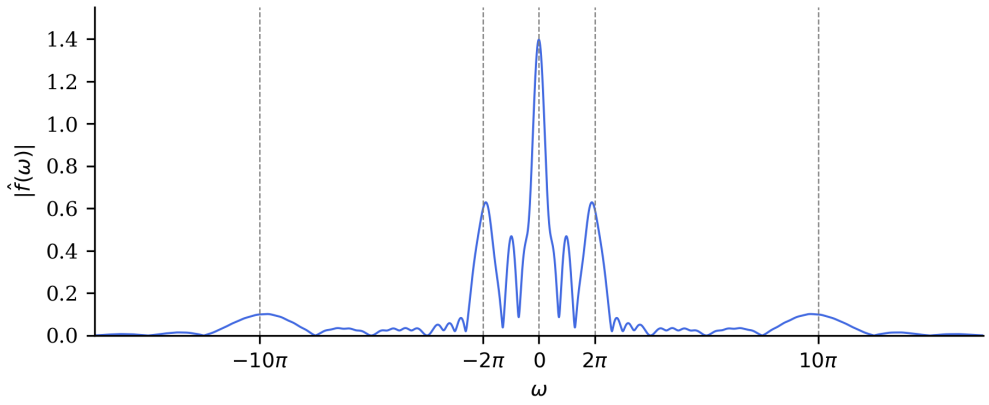


Abbildung 3.5.: Betragsspektrum $|\hat{f}(\omega)|$ nach (3.5); gestrichelt die Stellen $\pm 2\pi$ und $\pm 10\pi$.

wobei die Stellen $\omega \in \{0, \pm 2\pi, \pm 10\pi\}$ hebbar sind. Abbildung 3.5 zeigt beide Frequenzen als Maxima nahe $\pm 2\pi$ und $\pm 10\pi$; durch Überlagerung mit den Nebenkeulen sind sie leicht verschoben, nach $\omega \approx \pm 1{,}90\pi$ bzw. $\omega \approx \pm 9{,}73\pi$.

Wann die jeweilige Frequenz auftritt, ist $|\hat{f}|$ nicht zu entnehmen. Für die an $t = \frac{5}{2}$ gespiegelte Funktion $g(t) := f(5-t)$, in der die beiden Komponenten ihre Plätze tauschen, gilt nämlich $\hat{g}(\omega) = e^{-5i\omega}\,\overline{\hat{f}(\omega)}$, da f reell ist, also $|\hat{g}| = |\hat{f}|$. Die zeitliche Information ist in $\hat{f}$ zwar vorhanden, steckt aber vollständig in der Phase.

Wavelet-Transformierte. Wir transformieren nun mit dem Haar-Wavelet ψ^{H} aus Beispiel 3.4 und beschränken uns auf $a > 0$. Für $a > 0$ nimmt $\psi^{\mathrm{H}}\big(\frac{t-b}{a}\big)$ auf $[b,\, b + \frac{a}{2}[$ den Wert 1, auf $[b + \frac{a}{2},\, b + a[$ den Wert -1 an und verschwindet sonst; das Wavelet ist also ein Fenster über $[b, b+a]$ mit Sprungstelle in der Mitte. Da ψ^{H} reellwertig ist, entfällt die Konjugation in (3.4), und mit der Stammfunktion $F(t) := \int_{-\infty}^{t} f(s)\,ds$ folgt

$$W_{\psi^{\mathrm{H}}} f(a,b) = \frac{1}{\sqrt{a}} \left(\int_b^{b+a/2} f(t)\,dt - \int_{b+a/2}^{b+a} f(t)\,dt \right) = \frac{2F\big(b+\frac{a}{2}\big) - F(b) - F(b+a)}{\sqrt{a}}. \tag{3.6}$$

Die Transformation vergleicht also das Integral von f über die linke Fensterhälfte mit dem über die rechte; sie wirkt als Differenzenfilter. Die Stammfunktion ist elementar (Anhang A.2):

$$F(t) = \begin{cases} 0, & t < 0, \\ t - \dfrac{\sin(2\pi t)}{2\pi}, & 0 \le t \le 3, \\ 3, & 3 \le t \le 4, \\ 3 + \dfrac{t-4}{2} - \dfrac{\sin(10\pi t)}{20\pi}, & 4 \le t \le 5, \\ \dfrac{7}{2}, & t > 5. \end{cases}$$

Damit ist $W_{\psi_H} f$ für alle (a, b) in geschlossener Form bekannt; Abbildung 3.6 zeigt ihren Betrag, ausgewertet nach (3.6) (Code in Anhang B).

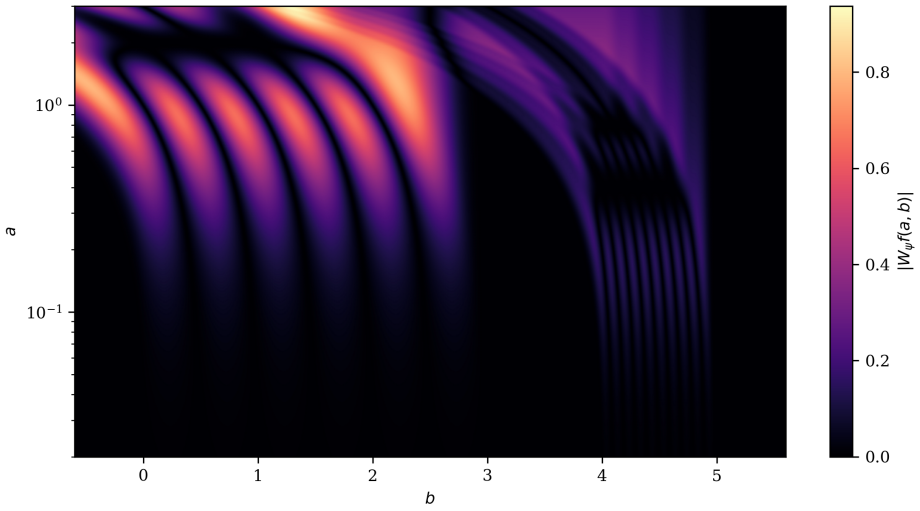


Abbildung 3.6.: Betrag der Wavelet-Transformierten nach (3.6); die Skalenachse ist logarithmisch.

Abbildung 3.6 zerfällt in zwei Bereiche. In der Ortsvariablen b liegen sie über den Trägern $[0, 3]$ und $[4, 5]$, in der Skala a unterscheiden sie sich um den Faktor fünf – genau das Verhältnis der beiden Frequenzen. Zeitpunkt und Frequenz sind also gleichzeitig ablesbar. Auch die schwache schnelle Komponente, die in Abbildung 3.5 kaum hervortritt, bildet hier ein eigenes Band: Bei kleinem a wertet die Transformation nur ein kurzes Zeitfenster aus, in dem die lange Dauer der langsamen Komponente nicht ins Gewicht fällt.

Damit ist an einem Beispiel vorgeführt, was die Transformation leistet: sie trennt, was im Betragsspektrum vermengt bleibt.

Belegstellen. Haar-Wavelet und seine Fourier-Transformierte: [LMR98, Kap. 1.1], [Bla03, Kap. 1.6]. Zur Darstellung von Wavelet-Transformierten und zur Wahl zusammengesetzter Testsignale vgl. [Bla03, Kap. 3.1] sowie [LMR98, Kap. 1.1].

3.1.3. Die Plancherel-Formel

Offen ist, ob sich f aus $W_\psi f$ zurückgewinnen lässt. Für die Fourier-Transformation beantwortet das der Satz von Plancherel (Abschnitt 2.4): Wegen $\|\hat{f}\| = \|f\|$ bleibt die Energie $\|f\|^2 = \int_{\mathbb{R}} |f(t)|^2 \, dt$ erhalten, und zwei verschiedene Signale können nicht dasselbe Spektrum besitzen. Für die CWT gilt eine entsprechende Aussage. Da $W_\psi f$ eine Funktion auf der (a, b)-Ebene ist, muss dazu zunächst festgelegt werden, wie dort Energie gemessen wird.

Definition 3.9 (Bildraum, [Bla03, Kap. 3.2, Gl. (2)]). Auf der zersägten Ebene $\mathbb{R}^*_\square$ aus Definition 3.5 sei

$$\mathcal{H} := \Big\{ u\colon \mathbb{R}^*_\square \to \mathbb{C} \;\Big|\; \int_{\mathbb{R}^*_\square} |u(a,b)|^2 \,\frac{da\,db}{a^2} < \infty \Big\}, \qquad \langle u, v\rangle_{\mathcal{H}} := \int_{\mathbb{R}^*_\square} u(a,b)\,\overline{v(a,b)}\,\frac{da\,db}{a^2}.$$

Dabei sind nur messbare Funktionen u zugelassen, und wie bei $L^2(\mathbb{R})$ in Abschnitt 2.1 werden Funktionen, die fast überall übereinstimmen, identifiziert.

Anmerkung. Hier noch Verweis auf Abschnitt 2.5 einfügen: Vergleich mit der gefensterten Fourier-Transformation. Dort genügt auf der (b,ω)-Ebene das gewöhnliche Maß $d\omega\,db$, weil Verschiebung und Modulation Flächen nicht verzerren; bei der CWT streckt der Parameter a, daher das Gewicht a^{-2}.

$\mathcal{H}$ ist also der Raum L^2 über der (a,b)-Ebene, mit dem Unterschied, dass beim Integrieren das Gewicht $|a|^{-2}$ eingeht; kurz $\mathcal{H} = L^2(\mathbb{R}^*_\square, d\mu)$ mit $d\mu = |a|^{-2}\,da\,db$ [Bla03, Kap. 3.2, Gl. (2)]. Die Energie von $W_\psi f$ ist damit $\|W_\psi f\|^2_{\mathcal{H}} = \int_{\mathbb{R}^*_\square} |W_\psi f(a,b)|^2 \,\frac{da\,db}{a^2}$, und mit diesem Gewicht gilt der folgende Satz.

Satz 3.10 (Plancherel-Formel für die CWT, [Bla03, Satz (3.3)]). *Sei ψ ein Wavelet mit Zulässigkeitskonstante C_ψ gemäß(3.1). Dann ist $W_\psi f \in \mathcal{H}$ für jedes $f \in L^2(\mathbb{R})$, und es gilt*

$$\langle W_\psi f, W_\psi g\rangle_{\mathcal{H}} \;=\; C_\psi\,\langle f, g\rangle \qquad \text{für alle } f, g \in L^2(\mathbb{R}). \tag{3.7}$$

Insbesondere ist $C_\psi^{-1/2}\,W_\psi$ eine Isometrie und W_ψ injektiv.

Der Satz besagt: Mit $g = f$ ist

$$\|W_\psi f\|^2_{\mathcal{H}} = \langle W_\psi f, W_\psi f\rangle_{\mathcal{H}} = C_\psi\,\langle f, f\rangle = C_\psi\,\|f\|^2 < \infty.$$

Die Transformierte hat also endliche Energie, und diese ist genau das C_ψ-Fache der Energie von f. Teilt man durch $\sqrt{C_\psi}$, so bleibt die Norm erhalten:

$$\|C_\psi^{-1/2}\,W_\psi f\|_{\mathcal{H}} = \|f\| \qquad \text{für alle } f \in L^2(\mathbb{R}).$$

$C_\psi^{-1/2} W_\psi$ ist also eine Isometrie; unitär im Sinne von Abschnitt 2.3 wäre sie erst, wenn sie zusätzlich surjektiv wäre – das ist sie nicht, ihr Bild ist ein echter Teilraum von $\mathcal{H}$ [Bla03, Kap. 3.4], vgl. Bemerkung 3.13. Der Beweis beruht auf mehrfacher Anwendung des Satzes von Plancherel und des Satzes von Fubini; die Zulässigkeitsbedingung sichert dabei die Endlichkeit der Konstante. Er findet sich bei [Bla03, Beweis zu Satz (3.3)], vgl. auch [LMR98, Satz 1.1.8].

Damit ist die Eingangsfrage beantwortet: Da W_ψ injektiv ist, ist f durch $W_\psi f$ eindeutig bestimmt. Wie man f konkret zurückgewinnt, sagt die folgende Umkehrformel.

Korollar 3.11 (Umkehrformel, [Bla03, Kap. 3.3, Gl. (2) und (4)]). *Für alle $f, g \in L^2(\mathbb{R})$ gilt $\langle f, g\rangle = C_\psi^{-1} \int_{\mathbb{R}^*_\square} W_\psi f(a,b)\,\langle \psi_{a,b}, g\rangle \,\frac{da\,db}{a^2}$, in diesem schwachen Sinn also*

$$f \;=\; \frac{1}{C_\psi} \int_{\mathbb{R}^*_\square} W_\psi f(a,b)\,\psi_{a,b}\,\frac{da\,db}{a^2}.$$

Beispiel 3.12 (Plancherel-Formel am Testsignal)**.** Wir prüfen Satz 3.10 am Signal f aus Beispiel 3.8 mit dem Haar-Wavelet, und zwar an zwei Paaren: (i) für $g = f$ als Erhaltung der Energie, (ii) für die beiden Komponenten von f als Erhaltung der Orthogonalität. Die beiden Seiten von (3.7) werden dabei auf verschiedenen Wegen berechnet: $C_{\psi^{\mathrm{H}}}$ im Frequenzbereich (Beispiel 3.4), $W_{\psi^{\mathrm{H}}} f$ rein im Zeitbereich nach (3.6).

(i) Energie. Als beschränkte Funktion mit kompaktem Träger liegt f in $L^2(\mathbb{R})$. Wegen $(1-\cos x)^2 = 1 - 2\cos x + \frac{1}{2}(1+\cos 2x)$ verschwinden bei Integration über ganze Perioden alle Cosinus-Terme, und es bleibt das $\frac{3}{2}$-Fache der Intervalllänge:

$$\|f\|^2 = \int_0^3 \big(1-\cos(2\pi t)\big)^2\,dt + \frac{1}{4}\int_4^5 \big(1-\cos(10\pi t)\big)^2\,dt = \frac{9}{2} + \frac{3}{8} = \frac{39}{8}.$$

Mit $C_{\psi^{\mathrm{H}}} = 2\ln 2$ aus Beispiel 3.4 folgt nach (3.7) mit $g = f$ $\|W_{\psi^{\mathrm{H}}} f\|^2_{\mathcal{H}} = C_{\psi^{\mathrm{H}}}\|f\|^2 = 2\ln 2 \cdot \frac{39}{8} \approx 6{,}76$. Da ψ^{H} reellwertig ist, entfällt davon auf die in Abbildung 3.6 gezeigte Halbebene $a > 0$ genau die Hälfte [Bla03, Satz (3.4)]. Für das Haar-Wavelet sieht man das direkt: Wegen $\psi^{\mathrm{H}}(-x) = -\psi^{\mathrm{H}}(x+1)$ für fast alle $x \in \mathbb{R}$ ist für $c > 0$

$$\psi^{\mathrm{H}}_{-c,b}(t) = \frac{1}{\sqrt{c}}\,\psi^{\mathrm{H}}\Big(-\frac{t-b}{c}\Big) = -\frac{1}{\sqrt{c}}\,\psi^{\mathrm{H}}\Big(\frac{t-(b-c)}{c}\Big) = -\psi^{\mathrm{H}}_{c,\,b-c}(t),$$
$$\text{also} \qquad W_{\psi^{\mathrm{H}}} f(-c, b) = -W_{\psi^{\mathrm{H}}} f(c,\, b-c).$$

Die Werte auf der Halbebene $a < 0$ sind also bis aufs Vorzeichen die in b verschobenen Werte auf $a > 0$; da db verschiebungsinvariant ist, tragen beide Halbebenen dieselbe Energie. Damit ist

$$\int_0^\infty \int_{\mathbb{R}} \big|W_{\psi^{\mathrm{H}}} f(a,b)\big|^2\,\frac{db\,da}{a^2} = \ln 2 \cdot \frac{39}{8} \approx 3{,}379.$$

Zur Kontrolle werten wir dieses Doppelintegral mit der geschlossenen Form (3.6) numerisch aus und erhalten $3{,}3790$, in Übereinstimmung mit dem exakten Wert.

(ii) Orthogonalität. Zerlegt man $f = f_1 + f_2$ in die langsame Komponente auf $[0,3]$ und die schnelle auf $[4,5]$, so ist $\langle f_1, f_2\rangle = 0$ wegen der disjunkten Träger, nach (3.7) also auch $\langle W_{\psi^{\mathrm{H}}} f_1, W_{\psi^{\mathrm{H}}} f_2\rangle_{\mathcal{H}} = 0$ – obwohl sich die beiden Bänder in Abbildung 3.6 für große a überlappen. Nach derselben Symmetrie wie in (i) verschwindet das Skalarprodukt auch auf der Halbebene $a > 0$ allein. Die Energien $\ln 2 \cdot \frac{9}{2}$ und $\ln 2 \cdot \frac{3}{8}$ der beiden Komponenten addieren sich daher ohne Mischterm.

Das Beispiel bestätigt (3.7) damit in beiden Lesarten: als Erhaltung der Energie und als Erhaltung der Orthogonalität.

Anmerkung. finde das beispiel noch nciht wirklich gut... eher ncohmal was einfacheres/Anschaulicheres

Bemerkung 3.13 (Redundanz der CWT)**.** Die CWT stellt ein Signal, also eine Funktion der einen Variablen t, durch eine Funktion der beiden Variablen (a,b) dar. Neue Information entsteht dabei nicht, denn nach Satz 3.10 ist W_ψ injektiv und f aus $W_\psi f$ eindeutig bestimmt. Dieselbe Information wird lediglich auf sehr viel mehr Werte verteilt. Im Endlichdimensionalen lässt sich das abzählen: Ein Signal aus N Abtastwerten liefert bei N Skalen und N Verschiebungen N^2 Koeffizienten, die aber nur einen höchstens N-dimensionalen Teilraum des $\mathbb{C}^{N^2}$ ausfüllen können [Bla03, Kap. 4.1]. Entsprechend sind die Funktionen $\psi_{a,b}$ nicht linear unabhängig [Bla03, Kap. 3.4].

Die Werte einer Wavelet-Transformierten sind deshalb nicht frei wählbar, sondern müssen zueinander passen. Blatter macht das mit dem reproduzierenden Kern präzise: Jeder Wert ist durch alle übrigen festgelegt, und nicht jede Funktion von (a, b) ist die Transformierte eines Signals [Bla03, Kap. 3.4, Satz (3.9)].

Die Schwellenwertverfahren, mit denen in Kapitel 5 entrauscht wird, sind dagegen für Orthonormalbasen formuliert [Mal09, Kap. 11.2]. Gesucht ist daher eine abzählbare Auswahl von Parametern (a, b), für die $\{\psi_{a,b}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ ist. Der Rest dieses Kapitels führt dorthin.

3.2. Das dyadische Gitter und die Multiskalenanalyse

Nach Bemerkung 3.13 ist eine abzählbare Auswahl von Parametern (a, b) zu treffen, mit der Skala a und der Verschiebung b in der Zeit. Einen Maßstab liefert die Plancherel-Formel (3.7) für $g = f$:

$$\|f\|^2 \;=\; \frac{1}{C_\psi} \int_{\mathbb{R}^*_\square} |W_\psi f(a,b)|^2 \, \frac{da}{a} \, \frac{db}{a}.$$

Die Energie wird also über die (a, b)-Ebene verteilt, wobei da/a jede Verdopplung der Skala gleich zählt und db/a die Zeit in Vielfachen der Wavelet-Breite a misst. Vertritt jeder Gitterpunkt einen Bereich gleichen Inhalts, dürfen alle Gitterpunkte gleich gewichtet werden [Bla03, Kap. 4.3]. Für $c > 0$ und $b_1 \in \mathbb{R}$ gilt

$$\int_{b_1}^{b_1+c} \int_{c}^{2c} \frac{da\, db}{a^2} \;=\; c\left(\frac{1}{c} - \frac{1}{2c}\right) \;=\; \frac{1}{2}.$$

Das legt das Gitter $a = 2^j$, $b = k\,2^j$ nahe: ein Punkt pro Verdopplung der Skala und ein Zeitschritt, der mit der Wavelet-Breite mitwächst. Zellen gleichen Inhalts liefert ebenso jedes Gitter $(a_0^j, k\,b_0 a_0^j)$ mit $a_0 > 1$, $b_0 > 0$ [LMR98, Kap. 2.1.1]; die Wahl $a_0 = 2$ ist die in der Praxis übliche [Bla03, Kap. 5]. Ob die so ausgewählten Funktionen tatsächlich eine Orthonormalbasis bilden, hängt dabei allein von ψ ab.

Definition 3.14 (Dyadische Wavelet-Familie, [Bla03, Kap. 5.1])**.** Sei ψ ein Wavelet. Für die Elemente der Wavelet-Familie (3.3) auf dem dyadischen Gitter $\{(2^j, k2^j) : j, k \in \mathbb{Z}\} \subset \mathbb{R}^*_\square$ schreiben wir kurz

$$\psi_{j,k} \;:=\; \psi_{2^j,\,k2^j}, \qquad \text{also} \qquad \psi_{j,k}(t) \;=\; 2^{-j/2}\,\psi\!\left(\frac{t}{2^j} - k\right), \qquad j, k \in \mathbb{Z}. \tag{3.8}$$

Dabei gehört zu kleinerem j die feinere Skala: Für $j \to -\infty$ wird $\psi_{j,k}$ schmal, für $j \to +\infty$ breit.[2]

Die beiden hervorgehobenen Zellen in Abbildung 3.7 zeigen das konkret. Die feine Zelle $[\frac{1}{2}, 1] \times [0, \frac{1}{2}]$ zur Skala $j = -1$ hat den Inhalt

$$\int_{0}^{1/2} \int_{1/2}^{1} \frac{da\, db}{a^2} \;=\; \frac{1}{2} \cdot \Big(2 - 1\Big) \;=\; \frac{1}{2},$$

[2] Diese Konvention folgt Blatter und Louis/Maaß/Rieder; ein Teil der Literatur zählt umgekehrt, so Hanke-Bourgeois [HB09, § 56].

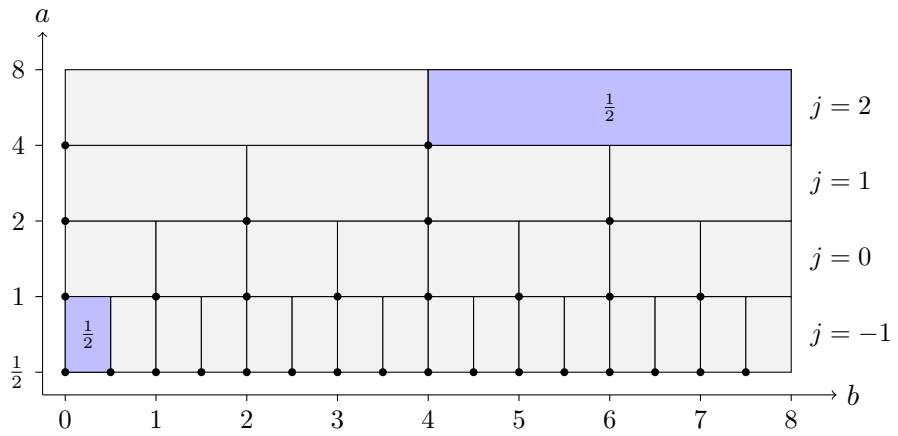


Abbildung 3.7.: Das dyadische Gitter $(2^j, k\,2^j)$ mit logarithmisch aufgetragener Skala a. Jeder Gitterpunkt vertritt die Zelle $[2^j, 2^{j+1}] \times [k\,2^j, (k+1)\,2^j]$ rechts oberhalb von ihm; alle Zellen haben bezüglich $da\,db/a^2$ den Inhalt $\frac{1}{2}$. Nur die Skalenachse ist logarithmisch, weil Stauchen multiplikativ, Verschieben dagegen additiv wirkt.

die grobe Zelle $[4,8] \times [4,8]$ zur Skala $j = 2$ den Inhalt

$$\int_4^8 \int_4^8 \frac{da\,db}{a^2} \;=\; 4 \cdot \Big(\frac{1}{4} - \frac{1}{8}\Big) \;=\; \frac{1}{2}.$$

Im gewöhnlichen Sinn ist die grobe Zelle mit Fläche 16 gegenüber $\frac{1}{4}$ zwar 64-mal so groß, das Gewicht $1/a^2$ ist dort aber entsprechend kleiner.

3.2.1. Die Axiome

Gesucht ist ein Wavelet ψ, dessen dyadische Familie $\{\psi_{j,k}\}$ aus Definition 3.14 eine Orthonormalbasis von $L^2(\mathbb{R})$ ist. Direkt lässt sich ein solches ψ kaum finden; bekannt sind zunächst nur Einzelfälle wie das Haar-Wavelet [LMR98, Kap. 2.2.1]. Die Multiskalenanalyse geht deshalb einen Umweg: Statt nach ψ zu suchen, beschreibt man zuerst, wie ein Signal auf verschiedenen Skalen vergröbert wird. Das Wavelet ergibt sich danach aus dem Übergang zwischen zwei benachbarten Skalen [Bla03, Kap. 5.1]. Das folgende Beispiel zeigt das am Haar-Wavelet.

Beispiel 3.15 (Mittelwerte und Details, [LMR98, Kap. 2.2.1]). Sei V_j der Raum der Funktionen in $L^2(\mathbb{R})$, die auf jedem Intervall $[k2^j, (k+1)2^j[$ konstant sind. Die Orthogonalprojektion P_j auf V_j ersetzt eine Funktion auf jedem dieser Intervalle durch ihren Mittelwert [HB09, Satz 43.1]. Wir wenden das auf die Treppenfunktion

$$f \;=\; 4 \cdot \mathbf{1}_{[0,1[} + 2 \cdot \mathbf{1}_{[1,2[} + 5 \cdot \mathbf{1}_{[2,3[} + 7 \cdot \mathbf{1}_{[3,4[} \;\in\; V_0$$

an und schreiben kurz $f = (4,2,5,7)$ für ihre Werte auf den vier Intervallen (Abbildung 3.8).

Mittelung über je zwei benachbarte Intervalle liefert $P_1 f = (3,3,6,6)$. Dabei geht $f - P_1 f = (1,-1,-1,1)$ verloren; mit dem Haar-Wavelet ψ^{H} aus Beispiel 3.4 ist das

$$(f - P_1 f)(t) \;=\; \psi^{\mathrm{H}}\big(\tfrac{t}{2}\big) - \psi^{\mathrm{H}}\big(\tfrac{t}{2} - 1\big).$$

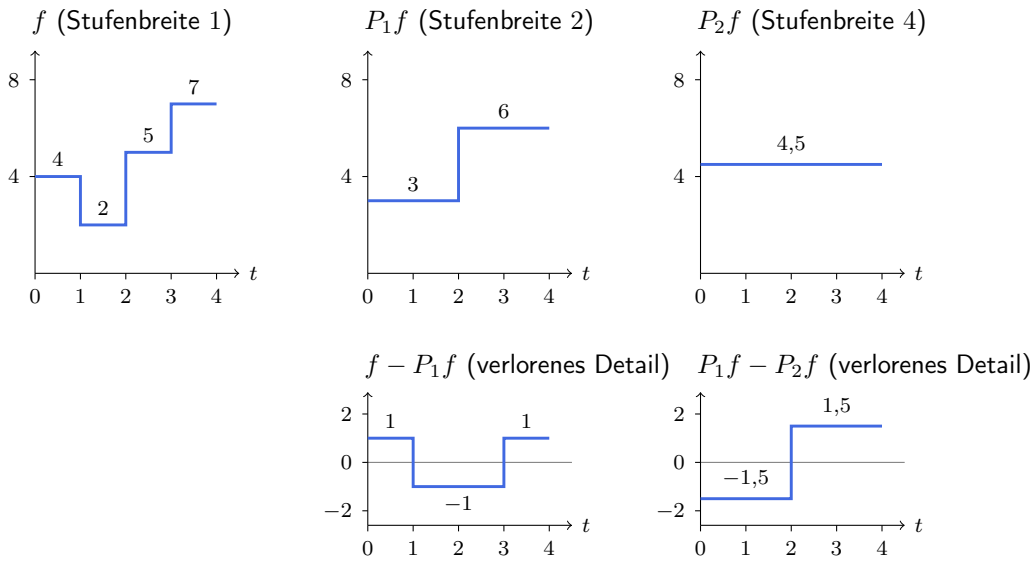


Abbildung 3.8.: Die Treppenfunktion $f = (4, 2, 5, 7)$ aus Beispiel 3.15 und ihre Mittelungen $P_1 f$ und $P_2 f$ (oben). Darunter steht jeweils das Detail, das beim Übergang zu dieser Mittelung verloren geht (unten). Alle Panels haben denselben vertikalen Maßstab. Jedes Detail ist ein Vielfaches eines gestreckten und verschobenen Haar-Wavelets.

Nochmalige Mittelung liefert $P_2 f = (4{,}5,\ 4{,}5,\ 4{,}5,\ 4{,}5)$, und verloren geht $P_1 f - P_2 f = (-1{,}5,\ -1{,}5,\ 1{,}5,\ 1{,}5)$, also $(P_1 f - P_2 f)(t) = -1{,}5\,\psi^{\mathrm{H}}\big(\frac{t}{4}\big)$. Insgesamt ist

$$f(t) \;=\; 4{,}5 \cdot \mathbf{1}_{[0,4[}(t) \;-\; 1{,}5\,\psi^{\mathrm{H}}\big(\tfrac{t}{4}\big) \;+\; \psi^{\mathrm{H}}\big(\tfrac{t}{2}\big) \;-\; \psi^{\mathrm{H}}\big(\tfrac{t}{2} - 1\big), \qquad t \in \mathbb{R}.$$

Die vier Werte von f sind damit durch vier andere Zahlen ersetzt: den Mittelwert $4{,}5$, ein grobes Detail $-1{,}5$ und zwei feine Details 1 und -1. Aus ihnen lässt sich f exakt zurückgewinnen. Die Zahlen sind hier ohne die Normierungsfaktoren $2^{-j/2}$ aus (3.8) angegeben.

Definition 3.16 (Multiskalenanalyse, [Bla03, Kap. 5.1, (a)–(c)]). Eine Multiskalenanalyse (MSA) von $L^2(\mathbb{R})$ ist eine Folge $(V_j)_{j\in\mathbb{Z}}$ abgeschlossener Teilräume von $L^2(\mathbb{R})$ mit den folgenden Eigenschaften:

(M1) (Schachtelung) $\cdots \subset V_2 \subset V_1 \subset V_0 \subset V_{-1} \subset V_{-2} \subset \cdots \subset L^2(\mathbb{R})$,

(M2) (Separation) $\bigcap_{j\in\mathbb{Z}} V_j = \{0\}$,

(M3) (Vollständigkeit) $\overline{\bigcup_{j\in\mathbb{Z}} V_j} = L^2(\mathbb{R})$,

(M4) (Skalierung) $f \in V_j \iff f(2^j\,\cdot\,) \in V_0$ für alle $j \in \mathbb{Z}$,

(M5) (Erzeugende Funktion) Es gibt ein $\varphi \in L^2(\mathbb{R}) \cap L^1(\mathbb{R})$,[3] sodass $\{\varphi(\cdot - k) : k \in \mathbb{Z}\}$ eine Orthonormalbasis von V_0 ist.

Die Funktion φ heißt Skalierungsfunktion der MSA.

Bemerkung 3.17 (Zu den Axiomen, [Bla03, Kap. 5.1]). (a) Die anschauliche Bedeutung von (M1)–(M3): Ein $f \in V_j$ enthält nur Strukturen der zeitlichen Ausdehnung $\gtrsim 2^j$. Je kleiner j, desto feinere Details sind zugelassen; (M3) besagt, dass im Limes $j \to -\infty$ jedes Signal erreichbar ist, (M2), dass im Limes $j \to +\infty$ nichts übrigbleibt [LMR98, Bem. 2.2.2].[4]

(b) Axiom (M4) ist die eigentliche Substanz: Die V_j sind nicht irgendwelche geschachtelten Räume, sondern skalierte Kopien ein und desselben Raumes V_0. Erst dadurch genügt eine einzige Funktion φ, um die gesamte Hierarchie festzulegen.

Beispiel 3.18 (Die Haar-MSA, [Bla03, Kap. 5.1, Beispiel ①]). Die Räume V_j aus Beispiel 3.15, also die Treppenfunktionen der Stufenbreite 2^j, bilden eine MSA mit der Skalierungsfunktion $\varphi := \mathbf{1}_{[0,1[}$, einer einzelnen Stufe (nicht dem Haar-Wavelet). (M1) gilt, weil eine Treppe der Stufenbreite 2 auch eine der Stufenbreite 1 ist; (M4), weil f genau dann auf allen Intervallen $[k2^j, (k+1)2^j[$ konstant ist, wenn $f(2^j\,\cdot)$ auf allen Intervallen $[k, k+1[$ konstant ist – etwa $\mathbf{1}_{[0,2[} \in V_1$ und $\mathbf{1}_{[0,2[}(2\,\cdot) = \mathbf{1}_{[0,1[} \in V_0$. Für (M5) sind die Verschiebungen $\varphi(\cdot - k) = \mathbf{1}_{[k,k+1[}$ orthonormal, und etwa $f = (4,2,5,7) = 4\varphi + 2\varphi(\cdot - 1) + 5\varphi(\cdot - 2) + 7\varphi(\cdot - 3)$.

(M2): Liegt f in allen V_j, so ist f auf $[0, 2^j[$ für jedes j konstant, also auf ganz $[0,\infty[$; das ist in $L^2(\mathbb{R})$ nur für $f = 0$ möglich, ebenso auf $]-\infty, 0[$. (M3): $\mathbf{1}_{[0,1/3[}$ liegt in keinem V_j, lässt sich aber annähern, etwa durch $\mathbf{1}_{[0,5/16[} \in V_{-4}$ mit Fehlerquadrat $\frac{1}{3} - \frac{5}{16} = \frac{1}{48}$. Mit feineren Stufen wird der Fehler beliebig klein, und da Treppenfunktionen mit dyadischen Sprungstellen dicht in $L^2(\mathbb{R})$ liegen [Bla03, Kap. 5.1], folgt (M3).

Anmerkung. Dieses Beispiel wird in Kapitel 4 bis zum Haar-Wavelet durchgerechnet und ist in Kapitel 6 der Referenzfall, gegen den db2 antritt. Es lohnt sich, es hier vollständig zu bringen.

Beispiel 3.15 zeigt die Multiskalenanalyse im Kleinen. Jede gröbere Näherung $P_{j+1}f$ entsteht aus der feineren $P_j f$ durch Mittelung; darin spiegelt sich die Schachtelung (M1). Was bei der Mittelung verloren geht, sind Vielfache gestreckter und verschobener Haar-Wavelets [LMR98, Kap. 2.2.1]; diese Unterschiede zwischen zwei Stufen werden in Abschnitt 3.4 als Detailräume W_j gefasst. Schließlich werden aus 4 Werten wieder 4 Koeffizienten: Die Zerlegung ist frei von der Redundanz, die Bemerkung 3.13 an der CWT bemängelt.

3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j

Axiom (M5) stattet nur den Grundraum V_0 mit einer Orthonormalbasis aus [Bla03, Kap. 5.1, (c)]. In diesem Abschnitt wird diese Basis auf alle Skalen übertragen (Satz 3.19), und es wird festgehalten, dass die Orthogonalprojektionen P_j auf V_j für $j \to -\infty$ gegen die Identität und für $j \to +\infty$ gegen null streben (Proposition 3.21). Beides zusammen liefert in Abschnitt 3.4

[3] Die Forderung $\varphi \in L^1(\mathbb{R})$ folgt Blatter und sichert, dass $\hat{\varphi}$ stetig ist; das wird in Kapitel 4 bei der Auswertung der Skalierungsgleichung an der Stelle $\omega = 0$ gebraucht.

[4] Louis, Maaß und Rieder verlangen in (M5) nur eine Riesz-Basis [LMR98, Def. 2.2.1]; wir folgen Blatter und fordern eine Orthonormalbasis.

die Zerlegung von $L^2(\mathbb{R})$ in Detailräume. Normen ohne Index sind im Folgenden stets Normen in $L^2(\mathbb{R})$.

3.3.1. Die Orthonormalbasis auf allen Skalen

Mit dem Dilatationsoperator $D_a f := |a|^{-1/2} f(\cdot/a)$, $a \in \mathbb{R}^*$, lässt sich (M4) als Aussage über Räume lesen: f liegt genau dann in V_j, wenn $f = h(\cdot/2^j)$ mit einem $h \in V_0$ ist. Da V_j ein linearer Raum ist, spielt der Vorfaktor keine Rolle, und es folgt

$$V_j \;=\; D_{2^j}(V_0) \qquad \text{für alle } j \in \mathbb{Z}. \tag{3.9}$$

Jedes V_j ist also eine gestreckte Kopie von V_0 [Bla03, Kap. 5.1, (b)]. Da D_{2^j} unitär ist [LMR98, Kap. 1.2], überträgt sich damit auch die Basis.

Satz 3.19 (Orthonormalbasis von V_j, [Bla03, Kap. 5.1]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ. Setzt man*

$$\varphi_{j,k}(t) \;:=\; 2^{-j/2}\,\varphi\!\left(\frac{t}{2^j} - k\right), \qquad j,k \in \mathbb{Z}, \tag{3.10}$$

so ist $\{\varphi_{j,k} : k \in \mathbb{Z}\}$ für jedes feste $j \in \mathbb{Z}$ eine Orthonormalbasis von V_j.

Die Aussage folgt direkt aus (3.9): Ein unitärer Operator erhält Skalarprodukte und bildet deshalb eine Orthonormalbasis eines abgeschlossenen Teilraums auf eine Orthonormalbasis von dessen Bild ab [Ser17, Def. 27.7, Satz 25.18]. Angewandt auf die Basis $\{\varphi(\cdot - k)\}_k$ von V_0 aus (M5) liefert D_{2^j} die Basis $\{D_{2^j}\varphi(\cdot - k)\}_k = \{\varphi_{j,k}\}_k$ von V_j. Benachbarte Basisfunktionen sind dabei um die Schrittweite 2^j gegeneinander verschoben [Bla03, Kap. 5.1].

Anmerkung. Der rote Faden: Die gesamte Konstruktion liefert Orthonormalbasen. In Abschnitt 5.1 ist es die Orthogonalität der DWT (Lemma 5.3), die das Rauschen invariant lässt.

3.3.2. Die Approximationsoperatoren

Definition 3.20 (Approximationsoperator). Für $f \in L^2(\mathbb{R})$ und $j \in \mathbb{Z}$ heißen die Zahlen $a_{j,k} := \langle f, \varphi_{j,k}\rangle$, $k \in \mathbb{Z}$, die Approximationskoeffizienten von f auf der Skala j, und

$$P_j f \;:=\; \sum_{k\in\mathbb{Z}} a_{j,k}\,\varphi_{j,k} \tag{3.11}$$

heißt die Approximation von f auf der Skala j; die Abbildung $P_j\colon L^2(\mathbb{R}) \to V_j$ heißt Approximationsoperator [LMR98, Bem. 2.2.2 (a)].

Da $\{\varphi_{j,k}\}_k$ nach Satz 3.19 eine Orthonormalbasis von V_j ist, konvergiert die Reihe in $L^2(\mathbb{R})$, und es gilt $\|P_j f\|^2 = \sum_k |a_{j,k}|^2$ [Ser17, Satz 25.18], [Bla03, Kap. 5.1, Gl. (7)]. Wegen $\langle f - P_j f, \varphi_{j,l}\rangle = a_{j,l} - a_{j,l} = 0$ für alle $l \in \mathbb{Z}$ steht $f - P_j f$ senkrecht auf V_j; P_j ist also die Orthogonalprojektion auf V_j. Für jedes $g \in V_j$ folgt daraus nach Pythagoras $\|f - g\| \geq \|f - P_j f\|$, das heißt, $P_j f$ ist die beste Näherung von f in V_j.

Blatter deutet P_j als Tiefpass-Filter: $P_j f$ enthält noch alle Details von f, die wenigstens die Ausdehnung 2^j auf der Zeitachse besitzen [Bla03, Kap. 5.1]. Für die Haar-MSA aus Beispiel 3.18 ist $\varphi_{j,k} = 2^{-j/2}\,\mathbf{1}_{I_{j,k}}$ mit $I_{j,k} := [k2^j, (k+1)2^j[$, also

$$a_{j,k}\,\varphi_{j,k} \;=\; \Big(\frac{1}{2^j}\int_{I_{j,k}} f(t)\,dt\Big)\,\mathbf{1}_{I_{j,k}},$$

und P_j ersetzt f auf jedem $I_{j,k}$ durch seinen Mittelwert [LMR98, Kap. 2.2]. Das ist die in Beispiel 3.15 benutzte Aussage; die dort angegebenen Mittelwerte sind die Zahlen $2^{-j/2}a_{j,k}$.

Proposition 3.21 (Approximationseigenschaft, [LMR98, Bem. 2.2.2 (a)]). *Für jedes $f \in L^2(\mathbb{R})$ gilt*

$$\textit{(a)}\quad \lim_{j\to-\infty}\|P_j f - f\| = 0 \qquad \textit{und} \qquad \textit{(b)}\quad \lim_{j\to+\infty}\|P_j f\| = 0.$$

Aussage (a) folgt aus (M3), da $P_j f$ die beste Näherung von f in $V_j \supset V_{j_0}$ ist; Aussage (b) folgt aus (M2) [Bla03, Prop. (5.1)].

3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$

Die Basen $\{\varphi_{j,k}\}_k$ der einzelnen V_j lassen sich nicht zu einer Orthonormalbasis von $L^2(\mathbb{R})$ vereinigen, denn wegen $V_j \subset V_{j-1}$ sind sie über die Skalen hinweg nicht orthogonal. Man betrachtet deshalb nur den Zuwachs beim Übergang zur nächstfeineren Skala [Bla03, Kap. 5.1].

Definition 3.22 (Detailräume, [Bla03, Kap. 5.1, Gl. (8)]). Für $j \in \mathbb{Z}$ sei W_j das orthogonale Komplement von V_j in V_{j-1}, also

$$V_{j-1} \;=\; V_j \oplus W_j, \qquad W_j \perp V_j, \tag{3.12}$$

und $Q_j := P_{j-1} - P_j$.

Q_j ist die Orthogonalprojektion auf W_j [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.9)]: Es ist $Q_j f = (f - P_j f) - (f - P_{j-1} f) \in V_{j-1}$, und beide Klammern stehen senkrecht auf V_j; also liegt $Q_j f$ in W_j, und $f - Q_j f = (f - P_{j-1} f) + P_j f$ steht senkrecht auf W_j.

Zwei weitere Eigenschaften folgen unmittelbar. Da D_{2^j} unitär ist und nach (3.9) V_0 auf V_j sowie V_{-1} auf V_{j-1} abbildet, gilt

$$W_j \;=\; D_{2^j}(W_0) \qquad \text{für alle } j \in \mathbb{Z} \tag{3.13}$$

[Bla03, Kap. 5.1, Gl. (9)]. Für $i > j$ ist außerdem $W_i \subset V_{i-1} \subset V_j \perp W_j$; die Detailräume sind also paarweise orthogonal [Bla03, Prop. (5.1)].

Satz 3.23 (Zerlegung von $L^2(\mathbb{R})$ in Detailräume, [Bla03, Prop. (5.1)]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Detailräumen W_j. Dann gilt*

$$L^2(\mathbb{R}) \;=\; \bigoplus_{j\in\mathbb{Z}} W_j \tag{3.14}$$

als orthogonale direkte Summe, und für jedes $f \in L^2(\mathbb{R})$ ist $f = \sum_{j\in\mathbb{Z}} Q_j f$ mit

$$\|f\|^2 \;=\; \sum_{j\in\mathbb{Z}} \|Q_j f\|^2. \tag{3.15}$$

Ferner gilt für jedes feste $J \in \mathbb{Z}$

$$L^2(\mathbb{R}) \;=\; V_J \oplus \bigoplus_{j \le J} W_j, \qquad f \;=\; P_J f + \sum_{j \le J} Q_j f. \tag{3.16}$$

Die Orthogonalität ist eben gezeigt. Nach Definition von Q_j ist $\sum_{j=J_1+1}^{J_2} Q_j f = P_{J_1} f - P_{J_2} f$ eine Teleskopsumme, die nach Proposition 3.21 für $J_1 \to -\infty$, $J_2 \to +\infty$ gegen f strebt; mit $J_2 = J$ ergibt sich (3.16). Die Energiegleichung folgt aus der Orthogonalität der Summanden [Bla03, Prop. (5.1)], [LMR98, Gl. (2.2.11), (2.2.12)].

In der Anwendung wird stets die endliche Fassung (3.16) benutzt: $P_J f$ entspricht einem Tiefpass, die $Q_j f$ den Anteilen von f in verschiedenen Frequenzbändern [LMR98, Kap. 2.2]. Der Abbruch bei einer endlichen gröbsten Skala J ist dabei nötig, denn ein nichtverschwindender Mittelwert wird durch P_j nicht beseitigt, sondern nur immer weiter auseinandergezogen; für die Treppenfunktion aus Beispiel 3.15 ist etwa $P_j f = 18 \cdot 2^{-j} \mathbf{1}_{[0,2^j[}$ für alle $j \ge 2$. Am EKG beobachten Louis, Maaß und Rieder, dass die feinste Detailstufe fast das gesamte Rauschen aufnimmt, während die gröberen Stufen den Signalverlauf tragen [LMR98, Kap. 3.1.2].

3.4.1. Die Wavelet-Basis

Satz 3.23 sagt noch nichts darüber, wie eine Basis von W_j aussieht. Da V_{-1} zwei Basisfunktionen pro Zeiteinheit besitzt und V_0 eine, liegt es nahe, W_0 ebenfalls durch die ganzzahligen Verschiebungen einer einzigen Funktion ψ aufzuspannen [Bla03, Kap. 5.1]. Dass es ein solches ψ gibt, wird in Kapitel 4 gezeigt [LMR98, Satz 2.2.10]; im Haar-Fall ist es ψ^{H}, wie Beispiel 3.15 bereits nahelegt [LMR98, Kap. 2.2].

Korollar 3.24 (Wavelet-Basis, [Bla03, Kap. 5.1]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA, und sei $\psi \in L^2(\mathbb{R})$ so, dass $\{\psi(\,\cdot - k) : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_0 ist. Mit $\psi_{j,k}$ wie in (3.8) gilt dann:*

(i) Für jedes feste $j \in \mathbb{Z}$ ist $\{\psi_{j,k} : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_j.

(ii) Die Familie

$$\{\psi_{j,k} : j,k \in \mathbb{Z}\} \tag{3.17}$$

ist eine Orthonormalbasis von $L^2(\mathbb{R})$, die Wavelet-Basis der MSA.

(iii) Mit den Detailkoeffizienten $d_{j,k} := \langle f, \psi_{j,k}\rangle$ gilt für jedes $f \in L^2(\mathbb{R})$ und jedes $J \in \mathbb{Z}$

$$f \;=\; \sum_{k\in\mathbb{Z}} a_{J,k}\,\varphi_{J,k} + \sum_{j\le J}\sum_{k\in\mathbb{Z}} d_{j,k}\,\psi_{j,k}, \qquad \|f\|^2 \;=\; \sum_{k\in\mathbb{Z}} |a_{J,k}|^2 + \sum_{j\le J}\sum_{k\in\mathbb{Z}} |d_{j,k}|^2. \tag{3.18}$$

Aussage (i) folgt wie Satz 3.19 aus (3.13). Nach (i) ist $Q_j f = \sum_k d_{j,k}\,\psi_{j,k}$, und damit folgen (ii) und (iii) aus Satz 3.23 und (3.11) [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.13)].

Beispiel 3.25 (Wavelet-Koeffizienten der Treppenfunktion). Wir zerlegen die Treppenfunktion $f = (4, 2, 5, 7)$ aus Beispiel 3.15 in der Haar-Wavelet-Basis, also mit $\psi = \psi^{\mathrm{H}}$ [LMR98, Kap. 2.2]. Da $\psi_{j,k}$ auf der linken Hälfte von $I_{j,k} = [k2^j, (k+1)2^j[$ den Wert $2^{-j/2}$ und auf der rechten

den Wert $-2^{-j/2}$ annimmt, ist $d_{j,k}$ das $2^{-j/2}$-Fache der Differenz der Integrale von f über die beiden Hälften. Für $J = 2$ erhält man

$$a_{2,0} = \tfrac{1}{2}(4{+}2{+}5{+}7) = 9, \qquad d_{2,0} = \tfrac{1}{2}\big((4{+}2){-}(5{+}7)\big) = -3, \qquad d_{1,0} = \tfrac{4-2}{\sqrt{2}} = \sqrt{2}, \qquad d_{1,1} = \tfrac{5-7}{\sqrt{2}} = -\sqrt{2};$$

alle übrigen Koeffizienten mit $j \le 2$ verschwinden, weil ihre Träger f nicht treffen oder f dort konstant ist. Nach (3.18) ist also

$$f \;=\; 9\,\varphi_{2,0} \;-\; 3\,\psi_{2,0} \;+\; \sqrt{2}\,\psi_{1,0} \;-\; \sqrt{2}\,\psi_{1,1}, \qquad \|f\|^2 \;=\; 81 + 9 + 2 + 2 \;=\; 94.$$

Bis auf den Normierungsfaktor $2^{j/2}$ sind das die Zahlen $4{,}5$, $-1{,}5$, 1 und -1 aus Beispiel 3.15.

Zwei Beobachtungen verbinden das Beispiel mit dem Rest der Arbeit. Erstens ist nach Definition 3.14 $d_{j,k} = \langle f, \psi_{2^j,\,k2^j}\rangle = W_\psi f(2^j, k2^j)$: Die Detailkoeffizienten sind die Werte der CWT auf dem dyadischen Gitter, aber ohne deren Redundanz (Bemerkung 3.13) – vier Funktionswerte ergeben vier Koeffizienten. Zweitens: Setzt man die beiden betragskleinsten Koeffizienten $d_{1,0}$ und $d_{1,1}$ auf null, so bleibt $9\,\varphi_{2,0} - 3\,\psi_{2,0} = P_1 f = (3,3,6,6)$, und nach der Energiegleichung ist der Fehler genau die Summe der Quadrate der gestrichenen Koeffizienten, $\|f - P_1 f\|^2 = 2 + 2 = 4$. Welche Koeffizienten man streicht, lässt sich also allein im Koeffizientenraum entscheiden; darauf beruht die Entrauschung in Kapitel 5.

Gleichung (3.18) ist der Ausgangspunkt der beiden folgenden Kapitel. Kapitel 4 konstruiert ψ und berechnet die Koeffizienten allein durch Filteroperationen aus denen der feinsten Skala; der Schlüssel ist die Inklusion $\varphi \in V_0 \subset V_{-1}$, die auf die Skalierungsgleichung führt [LMR98, Lemma 2.2.3], [Bla03, Satz (5.3)]. Kapitel 5 nutzt, dass $f \mapsto (a_{J,k}, d_{j,k})$ nach der Energiegleichung eine Isometrie ist.

Anmerkung. Die Energiegleichung (3.18) ist das, was Abschnitt 5.1 braucht: Die Wavelet-Koeffizienten sind Koordinaten bezüglich einer Orthonormalbasis.

4. Konstruktion der diskreten Wavelet-Transformation

Kapitel 3 endete mit einer bedingten Aussage: Gibt es eine Funktion ψ, deren um ganze Zahlen verschobene Kopien $\psi(\cdot - k)$, $k \in \mathbb{Z}$, eine Orthonormalbasis von W_0 bilden, so ist $\{\psi_{j,k}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ (Korollar 3.24). Dieses Kapitel konstruiert ein solches ψ und beantwortet dabei drei Fragen: Wie erhält man ψ aus φ? Wie berechnet man die Koeffizienten $a_{j,k}$ und $d_{j,k}$, ohne ein einziges Integral auszuwerten? Und welche Wavelets eignen sich für Signale wie das EKG? Alle drei Antworten stecken in einer einzigen Zahlenfolge $(h_k)_{k\in\mathbb{Z}}$. Begleitet wird das Kapitel von zwei Beispielen: dem Haar-Wavelet aus Kapitel 3 und dem Daubechies-Wavelet mit vier Koeffizienten, das in Kapitel 6 verwendet wird.

4.1. Die Skalierungsgleichung

Belegstellen. LMR, Lemma 2.2.3, S. 113 [bestätigt]; LMR, Gl. (2.2.23), (2.2.24) und Satz 2.2.9, S. 121 [bestätigt]; LMR, Anhang, S. 314 [bestätigt]; Serov, Satz 25.18, S. 257–258 [bestätigt]; Blatter, Kap. 5.2, Gl. (1), S. 110 [bestätigt], bewiesen in Satz (5.8) [Seite nachtragen]; Blatter, Satz (5.3), S. 111 [bestätigt].

In diesem Abschnitt wird die Skalierungsfunktion φ durch eine Zahlenfolge (h_k) beschrieben, und es werden zwei Bedingungen an diese Folge hergeleitet. Alles Weitere in diesem Kapitel wird nur noch mit den h_k rechnen; die Funktionen φ und ψ selbst werden dafür nicht mehr benötigt.

Nach (M1) ist $\varphi \in V_0 \subset V_{-1}$, und nach Satz 3.19 bilden die Funktionen $\varphi_{-1,k}(t) = \sqrt{2}\,\varphi(2t-k)$ eine Orthonormalbasis von V_{-1}. Also lässt sich φ in dieser Basis darstellen:

$$\varphi = \sum_{k\in\mathbb{Z}} \langle \varphi, \varphi_{-1,k}\rangle\, \varphi_{-1,k}.$$

Rechts steht eine gewichtete Summe der Funktionen $\varphi(2t-k)$. Jede davon ist eine Kopie von φ, die um den Faktor 2 zusammengedrückt und um $k/2$ verschoben ist, denn $\varphi(2t-k) = \varphi\big(2(t-k/2)\big)$. Die Skalierungsfunktion lässt sich also aus schmaleren Kopien ihrer selbst zusammensetzen.

Satz 4.1 (Skalierungsgleichung, vgl. [LMR98, Lemma 2.2.3]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ. Mit $h_k := \langle \varphi, \varphi_{-1,k}\rangle$ gilt*

$$\varphi(t) \;=\; \sqrt{2}\sum_{k\in\mathbb{Z}} h_k\,\varphi(2t-k) \quad \textit{für fast alle } t\in\mathbb{R} \qquad \textit{und} \qquad \sum_{k\in\mathbb{Z}} |h_k|^2 \;=\; 1, \tag{4.1}$$

wobei die Reihe in $L^2(\mathbb{R})$ konvergiert. Die Folge (h_k) heißt Skalierungsfolge oder Tiefpassfilter der MSA.

Beweis. Nach (M1) liegt φ in V_{-1}, und $\{\varphi_{-1,k}\}_k$ ist nach Satz 3.19 eine Orthonormalbasis von V_{-1}. Die Fourier-Entwicklung in dieser Basis [Ser17, Satz 25.18 (3)] lautet $\varphi = \sum_k h_k\,\varphi_{-1,k}$ mit $h_k\,\varphi_{-1,k}(t) = \sqrt{2}\,h_k\,\varphi(2t-k)$. Nach der Parseval-Gleichung [Ser17, Satz 25.18 (5)] ist $\sum_k |h_k|^2 = \|\varphi\|^2 = 1$, denn φ ist nach (M5) selbst Element der Orthonormalbasis $\{\varphi(\cdot - k)\}_k$ von V_0. □

Beispiel 4.2 (Haar). Für $\varphi = \mathbf{1}_{[0,1[}$ aus Beispiel 3.18 ist $\varphi(2t) = \mathbf{1}_{[0,1/2[}(t)$ und $\varphi(2t-1) = \mathbf{1}_{[1/2,1[}(t)$. Eine Stufe der Breite 1 besteht also aus zwei Stufen der Breite $\frac{1}{2}$:

$$\varphi(t) \;=\; \varphi(2t) + \varphi(2t-1) \;=\; \sqrt{2}\Big(\tfrac{1}{\sqrt{2}}\,\varphi(2t) + \tfrac{1}{\sqrt{2}}\,\varphi(2t-1)\Big).$$

Der Vergleich mit (4.1) liefert $h_0 = h_1 = \frac{1}{\sqrt{2}}$ und $h_k = 0$ sonst, in Übereinstimmung mit $h_0 = \langle \varphi, \varphi_{-1,0}\rangle = \sqrt{2}\cdot\frac{1}{2}$ und $\sum_k |h_k|^2 = 1$.

Aus der Skalierungsgleichung folgt eine zweite Bedingung an (h_k), die man im Frequenzbereich sieht; dabei sei $\sum_k |h_k| < \infty$, was für endliche Filter stets gilt. Nach den Rechenregeln der Fourier-Transformation für Stauchung und Verschiebung [LMR98, Anhang] ist $\widehat{\varphi_{-1,k}}(\omega) = \frac{1}{\sqrt{2}}\,e^{-ik\omega/2}\,\hat\varphi\big(\frac{\omega}{2}\big)$. Transformiert man $\varphi = \sum_k h_k\,\varphi_{-1,k}$ gliedweise und zieht den von k unabhängigen Faktor $\hat\varphi(\omega/2)$ vor die Summe, so wird die Skalierungsgleichung mit dem 2π-periodischen Fourier-Filter

$$H(\omega) \;:=\; \frac{1}{\sqrt{2}}\sum_{k\in\mathbb{Z}} h_k\,e^{-ik\omega} \tag{4.2}$$

zu einem Produkt [LMR98, Gl. (2.2.23)]:

$$\hat\varphi(\omega) \;=\; H\big(\tfrac{\omega}{2}\big)\,\hat\varphi\big(\tfrac{\omega}{2}\big), \qquad \omega\in\mathbb{R}. \tag{4.3}$$

Für die hier betrachteten MSA ist $|\hat\varphi(0)| = (2\pi)^{-1/2}$, insbesondere $\hat\varphi(0)\neq 0$ [Bla03, Kap. 5.2]. Da beide Seiten von (4.3) stetig sind, darf man $\omega = 0$ einsetzen; Division durch $\hat\varphi(0)$ ergibt

$$H(0) \;=\; 1, \qquad \text{das heißt} \qquad \sum_{k\in\mathbb{Z}} h_k \;=\; \sqrt{2}, \tag{4.4}$$

im Haar-Fall $\frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} = \sqrt{2}$; vgl. [LMR98, Satz 2.2.9].

4.2. Filterkoeffizienten: Tiefpass und Hochpass

Belegstellen. LMR, Lemma 2.2.8, Gl. (2.2.22) [Seite nachtragen, vermutl. S. 120–121]; LMR, Satz 2.2.10, S. 122, Beweis S. 122–123 [bestätigt]; LMR, Beispiel S. 169 und Tabelle 2.3, S. 170 [bestätigt], dort umgekehrte Reihenfolge wegen $e^{+ik\omega}$; Serov, Satz 25.18, S. 257–258 [bestätigt]; Blatter, Kap. 5.2, S. 110–116 [bestätigt].

Bisher wurde die Folge (h_k) aus einer gegebenen Skalierungsfunktion gewonnen. Für die Konstruktion neuer Wavelets geht man umgekehrt vor: Man wählt die Zahlen h_k und erhält φ und ψ daraus. Dafür muss man wissen, welche Bedingungen eine Folge erfüllen muss, um zu einer MSA zu gehören. Neben (4.4) übersetzt sich auch die Orthonormalität der Verschiebungen $\varphi(\cdot - k)$ aus (M5) in eine Bedingung an die Folge selbst.

Lemma 4.3 (Orthogonalität der Filterkoeffizienten, vgl. [LMR98, Lemma 2.2.8]). *Die Skalierungsfolge einer MSA erfüllt*

$$\sum_{n\in\mathbb{Z}} h_n\,\overline{h_{n-2m}} \;=\; \delta_{m,0} \qquad \text{für alle } m\in\mathbb{Z}. \tag{4.5}$$

Beweis. Ersetzt man in (4.1) t durch $t-m$ und setzt $n=k+2m$, so wird $\varphi(t-m)=\sqrt{2}\sum_k h_k\,\varphi(2t-2m-k)=\sum_n h_{n-2m}\,\varphi_{-1,n}(t)$. Die Vollständigkeitsrelation in V_{-1} [Ser17, Satz 25.18 (4)] und (M5) liefern $\delta_{m,0}=\langle\varphi,\varphi(\,\cdot-m)\rangle=\sum_n h_n\,\overline{h_{n-2m}}$. □

Anschaulich: Die Basisfunktionen $\varphi_{-1,n}$ liegen im Abstand $\frac{1}{2}$. Verschiebt man φ um 1, so rückt ihr Koeffizientenvektor (h_n) deshalb um zwei Stellen weiter. Die Orthogonalität der verschobenen Funktionen wird so zur Orthogonalität des Vektors (h_n) zu seinen um gerade Schrittweiten verschobenen Kopien. Für das Haar-Filter ist das trivial, denn für $m\neq 0$ überlappen (h_n) und (h_{n-2m}) nicht.

Beispiel 4.4 (Ein Filter der Länge vier). Gesucht seien reelle $h_0,\dots,h_3$, alle übrigen null. Die Bedingungen (4.4) und (4.5) lauten

$$h_0+h_1+h_2+h_3=\sqrt{2},\qquad h_0^2+h_1^2+h_2^2+h_3^2=1,\qquad h_0h_2+h_1h_3=0;$$

für $|m|\geq 2$ überlappen die Folgen nicht. Drei Gleichungen für vier Unbekannte lassen eine einparametrige Lösungsschar, zu der auch das Haar-Filter $(\frac{1}{\sqrt{2}},\frac{1}{\sqrt{2}},0,0)$ gehört. Eine weitere Lösung ist

$$h_0=\tfrac{1+\sqrt{3}}{4\sqrt{2}},\qquad h_1=\tfrac{3+\sqrt{3}}{4\sqrt{2}},\qquad h_2=\tfrac{3-\sqrt{3}}{4\sqrt{2}},\qquad h_3=\tfrac{1-\sqrt{3}}{4\sqrt{2}} \tag{4.6}$$

[LMR98, Tabelle 2.3], dort in umgekehrter Reihenfolge. Zur Probe: Die Zähler summieren sich zu 8, also $\sum h_k=8/(4\sqrt{2})=\sqrt{2}$. Die quadrierten Zähler ergeben $(4+2\sqrt{3})+(12+6\sqrt{3})+(12-6\sqrt{3})+(4-2\sqrt{3})=32=(4\sqrt{2})^2$, also $\sum h_k^2=1$. Schließlich ist $(1+\sqrt{3})(3-\sqrt{3})+(3+\sqrt{3})(1-\sqrt{3})=2\sqrt{3}-2\sqrt{3}=0$. Warum gerade diese Lösung aus der Schar ausgewählt wird, klärt Abschnitt 4.5.

Im Haar-Fall haben die Zahlen h_k eine einfache Bedeutung: Mit $h_0=h_1=\frac{1}{\sqrt{2}}$ bildet (h_k) aus zwei benachbarten Werten deren (normierten) Mittelwert, wie in Beispiel 3.15. Konstante Signale bleiben dabei erhalten, rasche Schwankungen werden geglättet; daher der Name Tiefpass. Das Gegenstück, das in Beispiel 3.15 die verlorenen Details liefert, ist die Differenz benachbarter Werte. Sie verschwindet für konstante Signale und heißt Hochpass. Für allgemeine (h_k) gewinnt man die Hochpassfolge durch Umkehren der Reihenfolge und alternierende Vorzeichen.

Satz 4.5 (Wavelet aus der Skalierungsfolge, vgl. [LMR98, Satz 2.2.10]). *Sei (V_j) eine MSA mit Skalierungsfolge (h_k). Setzt man*

$$g_k \;:=\; (-1)^k\,\overline{h_{1-k}},\qquad \psi(t) \;:=\; \sqrt{2}\sum_{k\in\mathbb{Z}} g_k\,\varphi(2t-k), \tag{4.7}$$

so ist $\{\psi(\,\cdot-k):k\in\mathbb{Z}\}$ eine Orthonormalbasis von W_0. Nach Korollar 3.24 ist dann $\{\psi_{j,k}:j,k\in\mathbb{Z}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$.

Der vollständige Beweis steht bei [LMR98, Satz 2.2.10].

Beispiel 4.6 (Haar, Fortsetzung). Aus $h_0 = h_1 = 1/\sqrt{2}$ folgt $g_0 = h_1 = 1/\sqrt{2}$ und $g_1 = -h_0 = -1/\sqrt{2}$, also

$$\psi(t) \;=\; \varphi(2t) - \varphi(2t-1) \;=\; \mathbf{1}_{[0,1/2[}(t) - \mathbf{1}_{[1/2,1[}(t) \;=\; \psi^{\mathrm{H}}(t).$$

Damit ist ψ^{H} als Wavelet der Haar-MSA nachgewiesen, wie es Beispiel 3.15 nahegelegt hatte. Für die Folge (4.6) ist entsprechend $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$.

4.3. Bedingungen im Fourier-Bereich

Belegstellen. LMR, Satz 2.2.9, S. 121 [bestätigt]; LMR, Korollar 2.2.12, S. 123 [bestätigt]; LMR, Bem. 2.4.19, S. 165 [bestätigt]; LMR, Kap. 2.4.2, S. 145–164 [bestätigt].

In Abschnitt 4.2 wurden die Namen Tiefpass und Hochpass nur am Haar-Filter begründet. Für beliebige Filter liefert das Fourier-Filter H aus (4.2) die Begründung. Es gibt an, wie stark der Filter eine Schwingung der Frequenz ω durchlässt: Für $x_n = e^{i\omega n}$ ist $\sum_k h_k\, x_{n-k} = \sqrt{2}\, H(\omega)\, x_n$. Für $\omega = 0$ ist $x_n = 1$ konstant, für $\omega = \pi$ ist $x_n = (-1)^n$, die Folge wechselt also bei jedem Schritt das Vorzeichen. Schneller kann eine abgetastete Schwingung nicht oszillieren, da $e^{i(\omega+2\pi)n} = e^{i\omega n}$ gilt. Wie in Abschnitt 4.1 sei $\sum_k |h_k| < \infty$.

Satz 4.7 (Bedingungen an das Fourier-Filter, [LMR98, Satz 2.2.9]). *Das Fourier-Filter* (4.2) *einer MSA erfüllt*

$$H(0) = 1 \qquad \textit{und} \qquad |H(\omega)|^2 + |H(\omega+\pi)|^2 = 1 \quad \textit{für alle } \omega \in \mathbb{R}. \tag{4.8}$$

Die erste Gleichung ist (4.4). Die zweite ist Lemma 4.3, in den Frequenzbereich übersetzt: Die unendlich vielen Gleichungen für die Zahlen h_k werden zu einer einzigen Gleichung für die Funktion H. Umgekehrt liefert jede endliche Folge mit (4.8), deren Fourier-Filter auf $[-\pi/2, \pi/2]$ keine Nullstelle hat, eine Lösung φ der Skalierungsgleichung mit orthonormalen Verschiebungen $\varphi(\cdot - k)$ [LMR98, Satz 2.4.7].

Für die Hochpassfolge (g_k) aus (4.7) setzt man analog $G(\omega) := 2^{-1/2} \sum_k g_k e^{-ik\omega}$. Die Substitution $n = 1 - k$ ergibt

$$G(\omega) \;=\; -e^{-i\omega}\, \overline{H(\omega+\pi)}, \qquad \hat{\psi}(\omega) \;=\; G\big(\tfrac{\omega}{2}\big)\, \hat{\varphi}\big(\tfrac{\omega}{2}\big) \tag{4.9}$$

[LMR98, Korollar 2.2.12], also $|G(\omega)| = |H(\omega+\pi)|$. Aus (4.8) und (4.9) folgen drei Aussagen:

(a) $H(0) = 1$ und $H(\pi) = 0$: (h_k) lässt konstante Signale vollständig durch und löscht die schnellste Schwingung aus. Das ist ein Tiefpass.

(b) $G(0) = 0$ und $|G(\pi)| = 1$: (g_k) verhält sich genau umgekehrt. Das ist ein Hochpass. Wegen $\hat{\psi}(0) = G(0)\, \hat{\varphi}(0) = 0$ hat ψ Mittelwert null, wie es Satz 3.2 von einem zulässigen Wavelet verlangt; zulässig ist ψ tatsächlich stets [LMR98, Satz 2.2.10 (iii)].

(c) $|H(\omega)|^2 + |G(\omega)|^2 = 1$: Jede Frequenz wird vollständig auf die beiden Filter aufgeteilt, es geht nichts verloren. In der Signalverarbeitung heißen solche Filterpaare Conjugate Quadrature Filter [LMR98, Bem. 2.4.19].

Abbildung 4.1 zeigt beide Filter. Beim Haar-Filter ist $|H(\omega)| = |\cos(\omega/2)|$ und die Nullstelle bei $\omega = \pi$ einfach. Für (4.6) ist $|H(\omega)|^2 = \cos^4(\omega/2)\left(1 + 2\sin^2(\omega/2)\right)$, vgl. [LMR98, Kap. 2.4.3], die Nullstelle also doppelt, und die Kurven verlaufen an den Rändern flacher. Abschnitt 4.5 zeigt, dass genau diese Ordnung der Nullstelle bestimmt, wie gut sich ein Wavelet für glatte Signalabschnitte eignet.

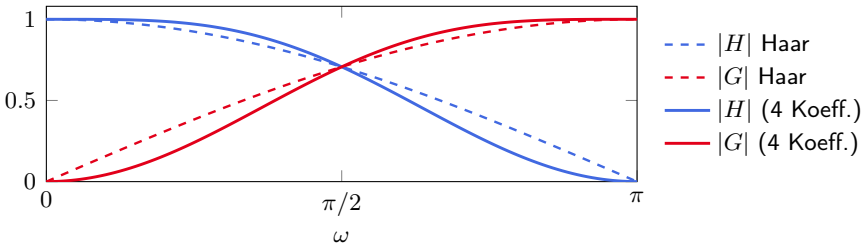


Abbildung 4.1.: Betrag der Fourier-Filter H (Tiefpass) und G (Hochpass) für das Haar-Filter (gestrichelt) und das Filter (4.6) (durchgezogen) auf $[0, \pi]$. In beiden Fällen ist $|H|^2 + |G|^2 = 1$.

4.4. Der Mallat-Algorithmus

Belegstellen. Blatter, Kap. 5.4, S. 130–136 [bestätigt], insb. Skalierungs- gleichungen 5.4.(1)/(2), S. 130 [bestätigt], Zwei-Skalen-Relation 5.4.(3)/(4) mit Herleitung, S. 131 [bestätigt], Analyseformeln (eingerahmt, unnummeriert), S. 132–133 [bestätigt]; LMR, Kap. 2.3, S. 132–141 [bestätigt], insb. Analyseformeln (unnummeriert, mit Verweis auf Skalierungsgl. (2.2.8)/(2.2.27)), S. 133 [bestätigt], Gl. (2.3.1)/(2.3.2), S. 133 [bestätigt], Abb. 2.8, S. 134 [bestätigt]; Aufwand: Blatter, Kap. 5.4, S. 133–135 [bestätigt], Hanke-Bourgeois, § 56, S. 438 [bestätigt]; LMR, Kap. 3.1.1, S. 237–238 [bestätigt].

Bisher erfordert jeder Koeffizient

$$a_{j,k} = \langle f, \varphi_{j,k} \rangle = \int_{\mathbb{R}} f(t)\, \varphi_{j,k}(t)\, dt, \qquad d_{j,k} = \langle f, \psi_{j,k} \rangle = \int_{\mathbb{R}} f(t)\, \psi_{j,k}(t)\, dt$$

(Definition 3.20, Korollar 3.24) ein eigenes Integral. Nach [Bla03, Kap. 5.4] und [LMR98, Kap. 2.3, Abb. 2.8] lassen sich $a_{j,\cdot}$ und $d_{j,\cdot}$ jedoch allein aus $a_{j-1,\cdot}$ und den Filtern h, g berechnen. Grundlage dafür ist die folgende Darstellung der Basisfunktionen der Skala j durch die der feineren Skala $j - 1$.

Lemma 4.8 (Zwei-Skalen-Relation, [Bla03, Kap. 5.4, (3), (4)]). *Für alle $j, k \in \mathbb{Z}$ gilt*

$$\varphi_{j,k} = \sum_{n \in \mathbb{Z}} h_{n-2k}\, \varphi_{j-1,n}, \qquad \psi_{j,k} = \sum_{n \in \mathbb{Z}} g_{n-2k}\, \varphi_{j-1,n}. \tag{4.10}$$

Für einen Beweis siehe [Bla03, Kap. 5.4]. Bildet man in (4.10) das Skalarprodukt mit f, so überträgt sich die Relation auf die Koeffizienten.

Satz 4.9 (Analyseschritt, [Bla03, Kap. 5.4]). *Für reelle Filter h, g und alle $j, k \in \mathbb{Z}$ gilt*

$$a_{j,k} = \sum_{n\in\mathbb{Z}} h_{n-2k}\, a_{j-1,n}, \qquad d_{j,k} = \sum_{n\in\mathbb{Z}} g_{n-2k}\, a_{j-1,n}. \tag{4.11}$$

Beweis. Vgl. [Bla03, Kap. 5.4]. Die Reihe in (4.10) konvergiert in $L^2(\mathbb{R})$, da $(h_n) \in \ell^2(\mathbb{Z})$ und $\{\varphi_{j-1,n}\}_{n\in\mathbb{Z}}$ orthonormal ist. Wegen der Stetigkeit des Skalarprodukts und $h_n \in \mathbb{R}$ folgt

$$a_{j,k} = \Big\langle f, \sum_n h_{n-2k}\, \varphi_{j-1,n} \Big\rangle = \sum_n h_{n-2k} \langle f, \varphi_{j-1,n}\rangle = \sum_n h_{n-2k}\, a_{j-1,n}.$$

Analog für $d_{j,k}$ mit g. □

Die Koeffizienten der Skala j sind also gewichtete Summen der Approximationskoeffizienten der Skala $j-1$; Integrale treten nur noch bei der Berechnung der Startwerte $a_{0,\cdot}$ auf.

Haben h und g jeweils höchstens L von Null verschiedene Einträge, so sind die Summen in (4.11) endlich: Jeder Koeffizient $a_{j,k}$ bzw. $d_{j,k}$ erfordert höchstens L Multiplikationen, vgl. [Bla03, Kap. 5.4]. Da die Gewichte mit $k \mapsto k+1$ um zwei Indizes weiterrücken, halbiert sich zudem die Anzahl der Koeffizienten von Skala zu Skala bis auf einen Randterm der Größe $L-2$, vgl. [Bla03, Kap. 5.4, (7)].

Algorithmus 1 Schnelle Wavelet-Transformation, vgl. [Bla03, Kap. 5.4], [LMR98, Kap. 2.3, Abb. 2.8]

Eingabe: Startfolge $a_{0,\cdot}$, Filter h, g, Tiefe $J \in \mathbb{N}$
Ausgabe: Detailfolgen $d_{1,\cdot}, \ldots, d_{J,\cdot}$ und Approximation $a_{J,\cdot}$

1: **für** $j = 1, \ldots, J$ **tue**
2: **für** alle k **tue**
3: $a_{j,k} \leftarrow \sum_n h_{n-2k}\, a_{j-1,n}$
4: $d_{j,k} \leftarrow \sum_n g_{n-2k}\, a_{j-1,n}$
5: **Ende für**
6: **Ende für**
7: **Rückgabe** $d_{1,\cdot}, \ldots, d_{J,\cdot}, \; a_{J,\cdot}$

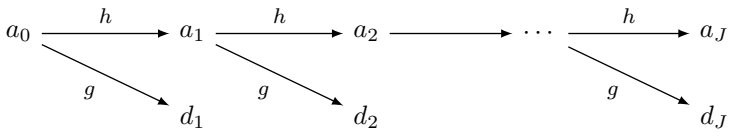


Abbildung 4.2.: Ablauf von Algorithmus 1, in Anlehnung an [Bla03, Kap. 5.4, (6)]; vgl. auch [LMR98, Abb. 2.8]. Jeder Pfeil ist ein Rechenschritt nach (4.11) mit dem Filter h bzw. g und halbiert die Anzahl der Werte. Nur die Approximationskoeffizienten werden weiter zerlegt.

Beispiel 4.10 (Haar, Fortsetzung von Beispiel 3.25)**.** Für das Haar-Filter $h_0 = h_1 = \frac{1}{\sqrt{2}}$ liefert (4.7) $g_0 = \frac{1}{\sqrt{2}}$, $g_1 = -\frac{1}{\sqrt{2}}$; alle übrigen h_k, g_k verschwinden. In (4.11) bleiben daher nur die Summanden $n = 2k$ und $n = 2k+1$:

$$a_{j,k} = \frac{a_{j-1,2k} + a_{j-1,2k+1}}{\sqrt{2}}, \qquad d_{j,k} = \frac{a_{j-1,2k} - a_{j-1,2k+1}}{\sqrt{2}},$$

also genau Mitteln und Differenzbilden aus Beispiel 3.15. Für die Treppenfunktion $f = (4, 2, 5, 7)$ der Haar-MSA ist $a_{0,k} = f(k)$. Die erste Stufe liefert $a_1 = (\frac{6}{\sqrt{2}}, \frac{12}{\sqrt{2}}) = (3\sqrt{2}, 6\sqrt{2})$ und $d_1 = (\sqrt{2}, -\sqrt{2})$, die zweite $a_{2,0} = 9$ und $d_{2,0} = -3$. Das sind genau die Koeffizienten aus Beispiel 3.25, nun ohne ein einziges Integral berechnet.

Der Aufwand ist gering. Hat der Filter die Länge L, kostet eine Stufe mit N Eingangswerten etwa LN Multiplikationen. Da sich die Anzahl der Werte von Stufe zu Stufe ungefähr halbiert, sind es insgesamt etwa $L\,(N + N/2 + N/4 + \cdots) \approx 2LN$, also $O(N)$ Operationen [Bla03, Kap. 5.4]. Die schnelle Fourier-Transformation braucht dagegen $O(N \log N)$ [HB09, § 53].

Jeder Schritt lässt sich exakt rückgängig machen.

Satz 4.11 (Rekonstruktion, [Bla03, Kap. 5.4])**.** *Für alle $j, n \in \mathbb{Z}$ gilt*

$$a_{j-1,n} \;=\; \sum_{k\in\mathbb{Z}} h_{n-2k}\, a_{j,k} \;+\; \sum_{k\in\mathbb{Z}} g_{n-2k}\, d_{j,k}. \tag{4.12}$$

Beweis. Nach Definition 3.22 und Korollar 3.24 ist $P_{j-1}f = P_j f + Q_j f = \sum_k a_{j,k}\varphi_{j,k} + \sum_k d_{j,k}\psi_{j,k}$. Skalarprodukt mit $\varphi_{j-1,n}$ und Lemma 4.8 liefern (4.12), vgl. [Bla03, Kap. 5.4]. □

Im Haar-Fall wird daraus $a_{j-1,2k} = (a_{j,k} + d_{j,k})/\sqrt{2}$ und $a_{j-1,2k+1} = (a_{j,k} - d_{j,k})/\sqrt{2}$, im Beispiel $(3\sqrt{2} \pm \sqrt{2})/\sqrt{2} = 4$ bzw. 2. Auch die Rekonstruktion kostet nur $O(N)$ Operationen, bleibt also weiterhin linear [Bla03, Kap. 5.4].

Bemerkung 4.12. Jeder Schritt $a_{j-1,\cdot} \mapsto (a_{j,\cdot}, d_{j,\cdot})$ von Algorithmus 1 ersetzt die Orthonormalbasis $\{\varphi_{j-1,n}\}_n$ von V_{j-1} durch die Orthonormalbasis $\{\varphi_{j,k}\}_k \cup \{\psi_{j,k}\}_k$ [Bla03, Kap. 5.4]. Die Parseval-Gleichung [Ser17, Satz 25.18 (5)], angewandt auf $P_{j-1}f$ in beiden Basen, liefert

$$\sum_n |a_{j-1,n}|^2 \;=\; \|P_{j-1}f\|^2 \;=\; \sum_k |a_{j,k}|^2 + \sum_k |d_{j,k}|^2,$$

im Beispiel $4^2 + 2^2 = 20 = (3\sqrt{2})^2 + (\sqrt{2})^2$. Ein Schritt ist also eine orthogonale Abbildung der Koeffizientenfolgen; genau diese Eigenschaft wird in Abschnitt 5.1 gebraucht.

In der Anwendung ist f nicht bekannt, sondern nur durch Abtastwerte gegeben. Diese werden als Koeffizienten $a_{0,k}$ der feinsten Skala verwendet [Bla03, Kap. 5.4]; wie ein endliches Signal dabei am Rand fortgesetzt wird, beschreibt Abschnitt 5.1.

4.5. Daubechies-Wavelets

Belegstellen. Blatter, Kap. 3.5, S. 74 [bestätigt]; LMR, Lemma 2.4.30, S. 176 [bestätigt]; LMR, Satz 2.4.9, S. 153 [bestätigt]; LMR, Kap. 2.4.4, S. 173–175 [bestätigt], insb. Satz 2.4.28 (Momente), S. 174, Träger von ψ_N, S. 175, Regularität $H^{\alpha N}$, $\alpha > 0{,}2$, S. 173; Blatter, Kap. 6.2, S. 146–151 [bestätigt]; Blatter, Kap. 6.3, S. 158 [bestätigt]; Rebstadt, Kap. 2.3.1, S. 16–20 [bestätigt].

Die Formeln des Mallat-Algorithmus gelten für die Skalierungsfolge jeder MSA; offen ist aber, welche man wählen soll. Das Haar-Filter erzeugt selbst auf glatten Signalabschnitten von null verschiedene Detailkoeffizienten. Gesucht sind daher kurze Filter, deren Wavelet glatte Abschnitte möglichst nicht sieht. Die dafür entscheidende Eigenschaft ist die folgende.

Definition 4.13 (Verschwindende Momente, vgl. [Bla03, Kap. 3.5]). Ein Wavelet ψ mit kompaktem Träger hat p verschwindende Momente,[1] falls

$$\int_{\mathbb{R}} t^m \, \psi(t) \, dt \;=\; 0 \qquad \text{für } m = 0, 1, \ldots, p-1.$$

Das Moment $m = 0$ ist die Zulässigkeitsbedingung aus Satz 3.2. Allgemein ist $\int_{\mathbb{R}} q(t)\, \psi_{j,k}(t)\, dt = 0$ für jedes Polynom q vom Grad $< p$: Das Wavelet sieht Polynome niedrigen Grades nicht. Wie sich das im Mallat-Algorithmus auswirkt, zeigt das folgende Beispiel.

Beispiel 4.14 (Ein lineares Signal). Nach (4.11) liefert die linear ansteigende Folge $a_{0,n} = n$ die Detailkoeffizienten

$$d_{1,k} \;=\; \sum_m g_m \, (m + 2k) \;=\; \sum_m m\, g_m + 2k \sum_m g_m.$$

Für Haar ist $g_0 = -g_1 = 1/\sqrt{2}$ (Beispiel 4.6), also $\sum_m g_m = 0$, aber $\sum_m m\, g_m = g_1 = -1/\sqrt{2}$. Damit ist $d_{1,k} = -1/\sqrt{2}$ für jedes k, obwohl das Signal überall gleichmäßig ansteigt und weder Spitzen noch Knicke besitzt. Für die Koeffizienten $h_0, \ldots, h_3$ aus (4.6) ist $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$, und es gilt

$$4\sqrt{2} \sum_m g_m \;=\; (1-\sqrt{3}) - (3-\sqrt{3}) + (3+\sqrt{3}) - (1+\sqrt{3}) \;=\; 0,$$

$$4\sqrt{2} \sum_m m\, g_m \;=\; -2(1-\sqrt{3}) + (3-\sqrt{3}) - (1+\sqrt{3}) \;=\; 0,$$

also $d_{1,k} = 0$: Lineare Abschnitte landen vollständig in den Approximationskoeffizienten, vgl. [LMR98, Lemma 2.4.29]. Damit ist auch die Frage aus Beispiel 4.4 beantwortet: Die Folge (4.6) ist das Daubechies-Filter mit zwei verschwindenden Momenten [Bla03, Kap. 6.3], das Haar-Filter aus derselben Schar hat nur eines.

Für glatte, nicht polynomiale Signale gilt das näherungsweise, umso besser, je feiner die Skala ist.

Lemma 4.15 (Abklingen der Detailkoeffizienten, vgl. [LMR98, Beweis von Lemma 2.4.30]). *Sei ψ ein Wavelet mit p verschwindenden Momenten und $\operatorname{supp}\psi = [\alpha, \beta] \ni 0$. Ist f auf $I_{j,k} := \operatorname{supp}\psi_{j,k}$ p-mal stetig differenzierbar mit $|f^{(p)}| \le M_{j,k}$, so gilt*

$$|d_{j,k}| \;\le\; 2^{j(p+1/2)} \, \frac{M_{j,k}}{p!} \int_{\mathbb{R}} |t^p \, \psi(t)| \, dt.$$

[1] Wie bei Mallat bezeichnet p die Zahl der Momente; N bleibt der Signallänge vorbehalten.

Beweis. Die Substitution $x = 2^j(t+k)$ ergibt $d_{j,k} = 2^{j/2} \int_{\mathbb{R}} f(2^j k + 2^j t)\, \psi(t)\, dt$. Nach Taylor [LMR98, (2.4.20)] ist $f(2^j k + 2^j t) = q(t) + R(t)$ mit einem Polynom q vom Grad $< p$ und dem Rest $R(t) = \frac{1}{p!} f^{(p)}(\eta_t)\, (2^j t)^p$, $\eta_t \in I_{j,k}$. Wegen der verschwindenden Momente ist $\int_{\mathbb{R}} q\, \psi\, dt = 0$, also $d_{j,k} = 2^{j/2} \int_{\mathbb{R}} R(t)\, \psi(t)\, dt$, und $|R(t)| \le \frac{M_{j,k}}{p!}\, 2^{jp}\, |t|^p$ liefert die Behauptung. □

Nach Lemma 4.15 werden die Detailkoeffizienten glatter Abschnitte auf feinen Skalen ($j \to -\infty$) also schnell klein, umso schneller, je größer p ist. An Sprüngen oder steilen Spitzen ist die Voraussetzung des Lemmas verletzt, und die Koeffizienten bleiben dort groß.

Für den Mallat-Algorithmus braucht man zugleich kurze Filter, denn er ist nur mit endlichen Filtern exakt ausführbar. Viele verschwindende Momente und kurze Filter verbinden die Daubechies-Wavelets.

Satz 4.16 (Daubechies-Wavelets, [Bla03, Kap. 6.2], [LMR98, Kap. 2.4.4]). *Zu jedem $p \in \mathbb{N}$ gibt es eine reelle Skalierungsfolge $h_0, \dots, h_{2p-1}$ einer MSA mit*

$$\operatorname{supp} \varphi_p = [0,\, 2p-1], \qquad \operatorname{supp} \psi_p = [1-p,\, p],$$

und das zugehörige Wavelet ψ_p besitzt p verschwindende Momente.

Anmerkung. bruach ich dafür nen beweis??

Der Träger von ψ_p folgt aus (4.7), da dort nur $g_{2-2p}, \dots, g_1$ von null verschieden sind, vgl. [LMR98, Kap. 2.4.4]. Für $p = 1$ entsteht das Haar-Wavelet, für $p = 2$ die Folge (4.6) [Bla03, Kap. 6.3] mit φ_2 und ψ_2 aus Abbildung 4.3. In PyWavelets [LGW+19] heißt ψ_p `dbp`; das Wavelet mit vier Koeffizienten ist also `db2`, nicht `db4`.

Anmerkung. Bib-Eintrag pywavelets anlegen und über DOI prüfen.

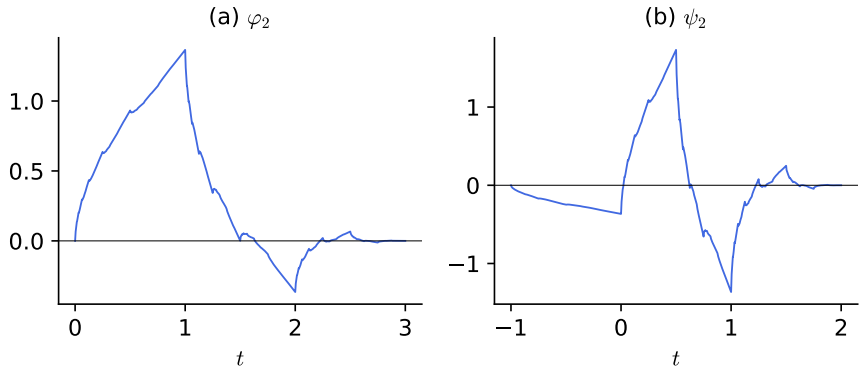


Abbildung 4.3.: Skalierungsfunktion φ_2 auf $[0, 3]$ (a) und Wavelet ψ_2 auf $[-1, 2]$ (b) zur Folge (4.6), berechnet durch Iteration der Skalierungsgleichung (4.1).

Anmerkung. Python-Datei zur Abbildung richtig ablegen.

Gegenüber Haar ist ψ_2 stetig [Bla03, Satz (6.11)], aber dreimal so breit. Allgemein wird ψ_p mit wachsendem p glatter, nämlich $\psi_p \in H^{\alpha p}(\mathbb{R})$ mit $\alpha > 0{,}2$ [LMR98, Kap. 2.4.4], zugleich wächst aber die Trägerlänge $2p-1$. Bei der Wahl von p muss man daher abwägen. Viele Momente

sind gut für die ruhigen, langsam verlaufenden Teile des EKG wie P- und T-Welle: Dort werden die Detailkoeffizienten fast null (Lemma 4.15). Ein breiter Träger ist dagegen schlecht für den steilen QRS-Komplex [Reb21, Kap. 2.3.1], denn dessen Spitze wird dann von mehreren Wavelets gleichzeitig erfasst und verteilt sich auf mehrere Koeffizienten. Insgesamt bleibt das Bild aber dasselbe: Wenige große Koeffizienten tragen die Spitzen, fast alle übrigen sind klein [HB09, Beispiel 56.3]. Auf dieser Dünnbesetztheit baut Abschnitt 5.2 auf.

Beispiel 4.17 (Das Daubechies-Wavelet mit $p = 6$)**.** Für $p = 6$ liefert Satz 4.16 die zwölf Filterkoeffizienten $h_0, \dots, h_{11}$, gerundet auf sechs Stellen

$$\begin{aligned}(h_0, \dots, h_5) &= (0{,}111541,\ 0{,}494624,\ 0{,}751134,\ 0{,}315250,\ -0{,}226265,\ -0{,}129767),\\ (h_6, \dots, h_{11}) &= (0{,}097502,\ 0{,}027523,\ -0{,}031582,\ 0{,}000554,\ 0{,}004777,\ -0{,}001077),\end{aligned} \tag{4.13}$$

mit $\operatorname{supp}\varphi_6 = [0, 11]$ und $\operatorname{supp}\psi_6 = [-5, 6]$. Blatter verweist für die Werte bis $p = 10$ auf die Tabelle bei Daubechies [Bla03, Kap. 6.2]; die Werte oben stammen aus PyWavelets [LGW+19], wo ψ_6 db6 heißt. Sie erfüllen (4.4) und (4.5) bis auf Rundungsfehler, und für die Hochpassfolge $g_k = (-1)^k h_{1-k}$, $k = -10, \dots, 1$, aus (4.7) gilt wie in Beispiel 4.14

$$\sum_k k^m g_k = 0 \qquad \text{für } m = 0, \dots, 5;$$

das sind die sechs verschwindenden Momente von ψ_6 in der Form, in der sie im Mallat-Algorithmus wirken. Abbildung 4.4 zeigt φ_6 und ψ_6. Gegenüber ψ_2 ist der Träger fast viermal so lang, und ψ_6 ist glatter, $\psi_6 \in H^{6\alpha}(\mathbb{R})$ mit $\alpha > 0{,}2$ [LMR98, Kap. 2.4.4]. Castillo et al. verwenden ψ_6 für EKG-Signale, weil es einem echten EKG ähnelt [CMG+13, Abschn. 3.1.1]; wir übernehmen es in Kapitel 6.

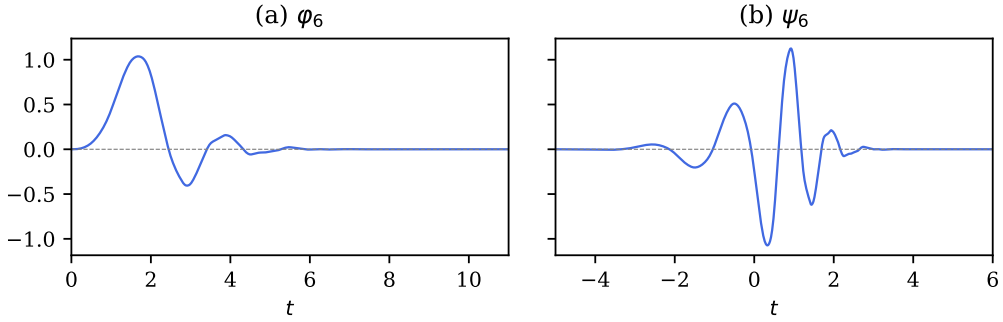


Abbildung 4.4.: Skalierungsfunktion φ_6 auf $[0, 11]$ (a) und Wavelet ψ_6 auf $[-5, 6]$ (b) zur Folge (4.13), berechnet durch Iteration der Skalierungsgleichung (4.1) (Code in Anhang B.3).

Damit liegen die drei Eigenschaften vor, die Kapitel 5 voraussetzt: Die diskrete Wavelet-Transformation ist orthogonal (Bemerkung 4.12), in $O(N)$ Operationen berechenbar (Algorithmus 1) und stellt stückweise glatte Signale dünnbesetzt dar (Lemma 4.15).

5. Entrauschung durch Thresholding

Ziel dieses Kapitels ist, aus verrauschten Messwerten das ursprüngliche Signal möglichst genau zurückzugewinnen. Dafür verwenden wir die diskrete Wavelet-Transformation aus Kapitel 4. Die Idee: Eine geeignet gewählte Orthonormalbasis stellt das Signal mit wenigen Koeffizienten dar [Mal09, Kap. 11.3], während sich das Rauschen gleichmäßig auf alle Koeffizienten verteilt [Mal09, Kap. 11.2.1]. Setzt man die kleinen Koeffizienten auf null, verschwindet vor allem Rauschen, während große Waveletkoeffizienten und damit scharfe Kanten erhalten bleiben [Mal09, Kap. 11.3.1]. Donoho und Johnstone haben gezeigt, dass dieses einfache Thresholding fast optimale Schätzer liefert [Mal09, Kap. 11.2]. Das Verfahren hat drei Schritte (Abbildung 5.1).

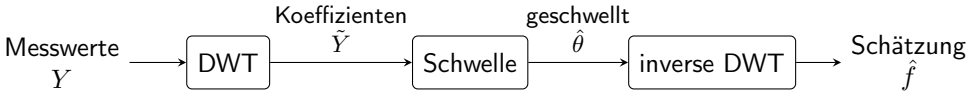


Abbildung 5.1.: Ablauf des Entrauschens: Die Messwerte Y werden mit Algorithmus 1 in Koeffizienten $\tilde{Y}$ zerlegt, jeder Koeffizient wird mit einer Schwelle bearbeitet, und die inverse DWT (Satz 4.11) liefert die Schätzung $\hat{f}$ des Signals. Die Bezeichnungen werden in den Abschnitten 5.1 bis 5.4 eingeführt. Vgl. [Mal09, Gl. (11.84)], [Reb21, Abb. 2.10].

Daraus ergeben sich die Fragen der folgenden Abschnitte: Was macht die Transformation mit dem Rauschen, was mit dem Signal? Wie setzt man kleine Koeffizienten auf null, wo liegt die Grenze, und wie bestimmt man sie aus den Daten? Ein Testsignal begleitet alle Abschnitte. Die Darstellung folgt [Mal09, Kap. 11.2–11.3.1].

5.1. Rauschmodell und diskrete Wavelet-Transformation

Das Rauschen wird als zufällig modelliert; die dafür benötigten Begriffe stehen in Abschnitt 2.6.

Definition 5.1 (Gauß'sches weißes Rauschen, [Mal09, Kap. 11.2.1–11.2.2]). Ein Zufallsvektor $W = (W_0, \dots, W_{N-1})$ heißt weißes Rauschen der Varianz σ^2, wenn $\mathbb{E}[W_n] = 0$ und $\mathbb{E}[W_n W_k] = \sigma^2 \, \delta_{n,k}$ für alle n, k gilt. Sind die W_n zudem gemeinsam normalverteilt, heißt W Gauß'sches weißes Rauschen.

Nach Satz 2.3 sind die Komponenten eines Gauß'schen weißen Rauschens der Varianz 1 unabhängig und standardnormalverteilt.

Das Modell. Beobachtet werden N Messwerte

$$Y_n \;=\; f_n + \sigma Z_n, \qquad n = 0, \dots, N-1, \tag{5.1}$$

mit Gauß'schem weißem Rauschen Z der Varianz 1 und Rauschstärke $\sigma > 0$ [Mal09, Gl. (11.26)]. Anders als in den Kapiteln 3 und 4 ist f hier keine Funktion, sondern der unbekannte Vektor $f \in \mathbb{R}^N$ der Abtastwerte des Signals. Die Messwerte dienen direkt als Startkoeffizienten $a_{0,n}$ von Algorithmus 1 [LMR98, Kap. 3.1.1]. Das Rauschen wird mit Z bezeichnet, da W bereits für die Detailräume vergeben ist.

Definition 5.2 (Schätzer und Risiko, [Mal09, Kap. 1.2.4]). Ein Schätzer ordnet den Messwerten Y einen Vektor $\hat{f} \in \mathbb{R}^N$ zu, der f annähern soll. Sein Risiko ist der erwartete quadratische Fehler

$$r(f) \;:=\; \mathbb{E}\,\|\hat{f} - f\|^2.$$

Für eine einzelne Realisierung des Rauschens heißt $\|\hat{f} - f\|^2$ die Fehlerenergie.

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie die Energie des Rauschens $\|\sigma Z\|^2$, und ihr Erwartungswert ist $r(f) = N\sigma^2$ [Mal09, Kap. 11.1.1].

Die DWT eines endlichen Signals. In Algorithmus 1 ist

$$a_{1,k} \;=\; \sum_{n\in\mathbb{Z}} h_{n-2k}\, a_{0,n},$$

die Summe läuft also formal über alle ganzen Zahlen n. Beim Filter (4.6) sind nur $h_0, \dots, h_3$ von null verschieden; für jedes k bleiben daher nur die vier Summanden mit $n = 2k, \dots, 2k+3$. Ein Messsignal hat aber nur die N Werte $a_{0,0}, \dots, a_{0,N-1}$. Für $N = 8$ ist etwa

$$a_{1,3} \;=\; h_0 a_{0,6} + h_1 a_{0,7} + h_2 a_{0,8} + h_3 a_{0,9},$$

und $a_{0,8}$, $a_{0,9}$ gibt es nicht. Man setzt das Signal daher periodisch fort, $a_{0,8} := a_{0,0}$, $a_{0,9} := a_{0,1}$ [LMR98, Kap. 2.4.7.2]. Das ist der einfachste von drei Wegen, die Mallat beschreibt; die anderen spiegeln das Signal am Rand oder verwenden eigene Randwavelets [Mal09, Kap. 7.3.1, 7.5].

Schreibt man die vier Gleichungen für $a_{1,0}, \dots, a_{1,3}$ untereinander, entsteht eine Matrix $H \in \mathbb{R}^{4\times 8}$ mit $(a_{1,k})_k = H\,(a_{0,n})_n$:

$$H \;=\; \begin{pmatrix} h_0 & h_1 & h_2 & h_3 & 0 & 0 & 0 & 0 \\ 0 & 0 & h_0 & h_1 & h_2 & h_3 & 0 & 0 \\ 0 & 0 & 0 & 0 & h_0 & h_1 & h_2 & h_3 \\ h_2 & h_3 & 0 & 0 & 0 & 0 & h_0 & h_1 \end{pmatrix}.$$

Jede Zeile ist die vorige, um zwei Stellen verschoben; was rechts herausfällt, kommt links wieder hinein. Ebenso liefert eine Matrix $G \in \mathbb{R}^{4\times 8}$ aus den g_k die Details $d_{1,0}, \dots, d_{1,3}$.

Allgemein sei M gerade und $w \in \mathbb{R}^M$ periodisch fortgesetzt, $w_{n+M} := w_n$. Die periodischen Mallat-Transformationen $H_M, G_M \colon \mathbb{R}^M \to \mathbb{R}^{M/2}$ sind

$$(H_M w)_k \;:=\; \sum_{n\in\mathbb{Z}} h_{n-2k}\, w_n, \qquad (G_M w)_k \;:=\; \sum_{n\in\mathbb{Z}} g_{n-2k}\, w_n, \qquad 0 \le k < \tfrac{M}{2}$$

[LMR98, Kap. 3.6.2]; das sind die Formeln aus Algorithmus 1 mit periodisch gelesenen Indizes. Wir setzen $S_M := \binom{H_M}{G_M} \in \mathbb{R}^{M\times M}$; das Beispiel oben ist $H = H_8$.

Lemma 5.3 ([LMR98, Kap. 3.6.2, Gl. (3.6.18)–(3.6.20)]). *Für die Filter h, g aus Kapitel 4 gilt $H_M H_M^\top = G_M G_M^\top = I$, $H_M G_M^\top = 0$ und $H_M^\top H_M + G_M^\top G_M = I$. Die Matrix S_M ist also orthogonal, das heißt $S_M^\top S_M = S_M S_M^\top = I$.*

Der Preis des Periodisierens: Sind Anfang und Ende des Signals verschieden, so verhalten sich die Koeffizienten am Rand, als hätte das Signal dort einen Sprung, und werden groß [Mal09, Kap. 7.5.1].

Die DWT als orthogonale Matrix. Die DWT der Tiefe J wendet S_N auf alle N Werte an und danach jeweils nur auf die zuletzt berechneten Approximationskoeffizienten; die Details bleiben stehen. Da jeder Schritt die Anzahl der Approximationskoeffizienten halbiert, sei N durch 2^J teilbar. Als Matrix ist das

$$A := \begin{pmatrix} S_{N/2^{J-1}} & 0 \\ 0 & I \end{pmatrix} \cdots \begin{pmatrix} S_{N/2} & 0 \\ 0 & I \end{pmatrix} S_N \in \mathbb{R}^{N\times N}, \qquad AY = (a_J, d_J, \ldots, d_1),$$

für $N = 8$, $J = 3$ etwa

$$A = \begin{pmatrix} S_2 & 0 \\ 0 & I_6 \end{pmatrix} \begin{pmatrix} S_4 & 0 \\ 0 & I_4 \end{pmatrix} S_8, \qquad AY = (a_3, d_3, d_2, d_1)$$

mit $1, 1, 2$ und 4 Einträgen. Jeder Faktor ist nach Lemma 5.3 orthogonal, also auch A. Wir bezeichnen die Zeilen von A mit $v_0, \ldots, v_{N-1}$. Sie bilden eine Orthonormalbasis des $\mathbb{R}^N$, und jeder Koeffizient ist ein Skalarprodukt mit einer von ihnen; Mallat nennt sie diskrete Wavelets und Skalierungsfunktionen [Mal09, Kap. 7.5, Gl. (7.173)]. Aus (5.1) wird damit

$$\tilde{Y}_m = \theta_m + \sigma \tilde{Z}_m \qquad \text{mit } \tilde{Y}_m = \langle Y, v_m\rangle,\ \theta_m = \langle f, v_m\rangle,\ \tilde{Z}_m = \langle Z, v_m\rangle, \tag{5.2}$$

kurz $\tilde{Y} = AY$, $\theta = Af$, $\tilde{Z} = AZ$ [Mal09, Kap. 11.2.1].

Was mit dem Rauschen geschieht.

Lemma 5.4 ([Mal09, Kap. 11.2.1–11.2.2]). *$\tilde{Z}$ ist wieder Gauß'sches weißes Rauschen der Varianz 1; die $\tilde{Z}_0, \ldots, \tilde{Z}_{N-1}$ sind also unabhängig und standardnormalverteilt.*

Beweis. Wegen der Linearität des Erwartungswerts ist $\mathbb{E}[\tilde{Z}_m] = \sum_n v_m[n]\,\mathbb{E}[Z_n] = 0$ und

$$\mathbb{E}\big[\tilde{Z}_m \tilde{Z}_p\big] = \sum_{n=0}^{N-1}\sum_{k=0}^{N-1} v_m[n]\, v_p[k]\, \mathbb{E}[Z_n Z_k] = \sum_{n=0}^{N-1} v_m[n]\, v_p[n] = \langle v_m, v_p\rangle = \delta_{m,p}$$

[Mal09, Kap. 11.2.1], da die v_m eine Orthonormalbasis bilden. Die $\tilde{Z}_m$ sind Linearkombinationen der gemeinsam normalverteilten Z_n und damit selbst gemeinsam normalverteilt, vgl. [Mal09, Kap. 11.2.2]; nach Satz 2.3 sind sie also unabhängig. □

Die Transformation verändert also das Signal, die Verteilung des Rauschens aber nicht: Jeder Koeffizient trägt Rauschen derselben Stärke σ, und das Rauschen beeinflusst die Wahl der Basis nicht [Mal09, Kap. 11.2.1].

Beispiel 5.5 (Ein verrauschter Sinus)**.** Als Testsignal dient ein Sinus mit Amplitude 1 und Periode 1, abgetastet an den $N = 2048$ Zeitpunkten $t_n = 8n/N = n/256$ im Intervall $[0, 8)$:

$$u_n := \sin(2\pi t_n), \qquad n = 0, \dots, 2047.$$

Jede Periode umfasst also 256 Abtastwerte, insgesamt sind es acht volle Perioden. Dazu kommt Rauschen der Stärke $\sigma = 0{,}3$: Die Z_n werden als Pseudozufallszahlen erzeugt, und nach (5.1) sind die Messwerte $Y_n = u_n + 0{,}3\, Z_n$ (Abbildung 5.2). Zerlegt wird mit dem Filter (4.6), periodisiert, in $J = 5$ Stufen; gerechnet ist mit PyWavelets [LGW+19] (Code in Anhang B.4).

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie gleich der Energie des Rauschens, $\|Y - u\|^2 = 181{,}3$, nahe am Erwartungswert $N\sigma^2 = 2048 \cdot 0{,}09 = 184{,}3$; dieser Wert dient später als Vergleich. Für die 2048 Werte $\tilde{Z}_m$ sind der empirische Mittelwert $\bar{z} = \frac{1}{N}\sum_m \tilde{Z}_m = 0{,}01$ und die empirische Varianz $\frac{1}{N}\sum_m (\tilde{Z}_m - \bar{z})^2 = 0{,}98$, wie nach Lemma 5.4 zu erwarten.

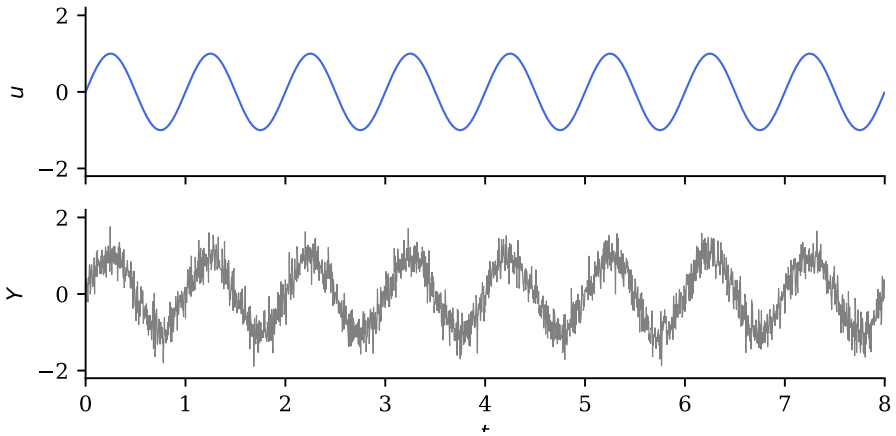


Abbildung 5.2.: Der Sinus u aus Beispiel 5.5 (oben) und die Messwerte $Y = u + 0{,}3\, Z$ (unten), $N = 2048$.

5.2. Diagonale Schätzer und Thresholding

Nach Abschnitt 5.1 bilden die Zeilen $v_0, \dots, v_{N-1}$ von A eine Orthonormalbasis des $\mathbb{R}^N$, und die Koeffizienten der Messwerte in dieser Basis sind $\tilde{Y}_m = \langle Y, v_m \rangle = \theta_m + \sigma \tilde{Z}_m$ nach (5.2). Im mittleren Schritt von Abbildung 5.1 wird jeder dieser Koeffizienten für sich mit einem Faktor λ_m multipliziert, der angibt, wie viel von ihm übrig bleibt: $\lambda_m = 1$ behält ihn, $\lambda_m = 0$ löscht ihn, ein Wert dazwischen verkleinert ihn.

Definition 5.6 (Diagonaler Schätzer, [Mal09, Kap. 11.2.1, Gl. (11.27)])**.** Ein Schätzer heißt diagonal in der Basis $\{v_m\}$, wenn er jeden Koeffizienten mit einem Faktor λ_m multipliziert,

$$\hat{\theta}_m \;=\; \lambda_m \tilde{Y}_m \qquad (m = 0, \dots, N-1),$$

und das Ergebnis mit $A^{-1} = A^\top$ zurücktransformiert: $\hat{f} = A^\top \hat{\theta}$. Dabei darf λ_m von den Messwerten nur über $\tilde{Y}_m$ abhängen, nicht über die übrigen Koeffizienten $\tilde{Y}_k$, $k \neq m$. Hängt kein λ_m von den Messwerten ab, heißt der Schätzer linear.

In den Koeffizienten ist ein diagonaler Schätzer die Multiplikation mit einer Diagonalmatrix,

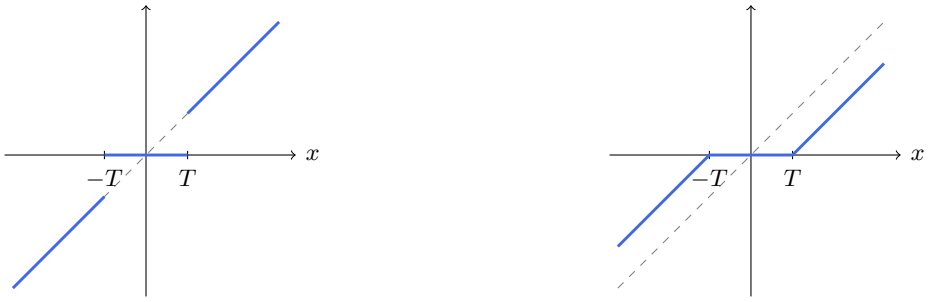
$$\hat{\theta} = \begin{pmatrix} \lambda_0 & 0 & \cdots & 0 \\ 0 & \lambda_1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_{N-1} \end{pmatrix} \tilde{Y}.$$

Die beiden wichtigsten diagonalen Schätzer sind nicht linear: Sie vergleichen $|\tilde{Y}_m|$ mit einer Schwelle $T > 0$, die Faktoren hängen also von $\tilde{Y}_m$ selbst ab [Mal09, Kap. 11.2.2].

Definition 5.7 (Hard- und Soft-Thresholding, [Mal09, Gl. (11.47), (11.49)]). Für $T > 0$ heißen

$$\rho_T^{\mathrm{H}}(x) := \begin{cases} x, & |x| > T, \\ 0, & |x| \leq T, \end{cases} \qquad \rho_T^{\mathrm{S}}(x) := \begin{cases} x - T, & x > T, \\ x + T, & x < -T, \\ 0, & |x| \leq T \end{cases}$$

Hard- bzw. Soft-Thresholding. Der zugehörige Schätzer berechnet mit ρ_T für eine der beiden Funktionen die Koeffizienten $\hat{\theta}_m = \rho_T(\tilde{Y}_m)$ und transformiert zurück: $\hat{f} = A^\top \hat{\theta}$.



(a) Hard-Thresholding (b) Soft-Thresholding

Abbildung 5.3.: Die Funktionen ρ_T^{H} (a) und ρ_T^{S} (b); gestrichelt die Identität.

Beispiel 5.8 (Fortsetzung von Beispiel 4.10). Wir gehen alle drei Schritte für die Messwerte $Y = (4,\ 2,\ 5,\ 7)$ durch, mit dem Haar-Filter, $N = 4$ und $J = 2$.

Schritt 1, Transformieren: Nach Beispiel 4.10 ist $\tilde{Y} = AY = (a_{2,0};\ d_{2,0};\ d_{1,0};\ d_{1,1}) = (9;\ -3;\ \sqrt{2};\ -\sqrt{2})$.

Schritt 2, Thresholding: Mit $T = 2$ vergleicht Hard-Thresholding den Betrag jedes Koeffizienten mit T:

$$|9| > 2, \qquad |-3| > 2, \qquad |\sqrt{2}| \leq 2, \qquad |-\sqrt{2}| \leq 2.$$

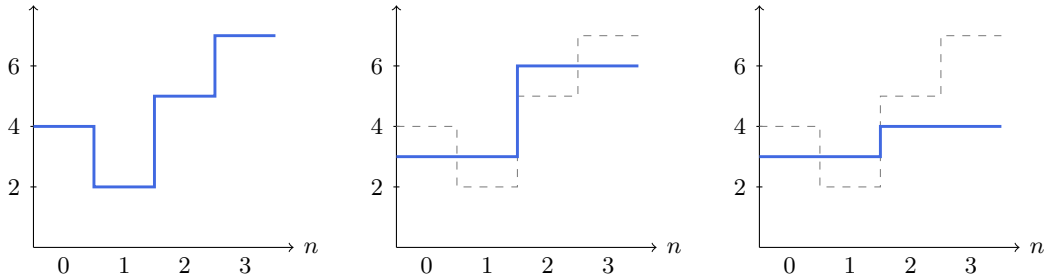
Die Koeffizienten 9 und -3 liegen über der Schwelle und bleiben unverändert, $\lambda_0 = \lambda_1 = 1$. Die beiden feinen Details $\pm\sqrt{2} \approx \pm 1{,}41$ liegen nicht darüber und werden auf null gesetzt, $\lambda_2 = \lambda_3 = 0$. Also ist $\hat{\theta} = (9;\ -3;\ 0;\ 0)$.

Schritt 3, Zurücktransformieren: Mit der Rekonstruktion aus Satz 4.11 ist zunächst $a_1 = \left(\frac{9-3}{\sqrt{2}},\ \frac{9+3}{\sqrt{2}}\right) = (3\sqrt{2},\ 6\sqrt{2})$ und, da beide $d_{1,k}$ null sind,

$$\hat{f} \;=\; A^{\top}\hat{\theta} \;=\; (3,\ 3,\ 6,\ 6).$$

Jedes Paar benachbarter Werte ist durch seinen Mittelwert ersetzt; das Nullsetzen der feinen Details wirkt also wie ein lokales Mitteln.

Soft-Thresholding setzt dieselben Koeffizienten auf null, verkleinert die übrigen aber zusätzlich um T: $\hat{\theta} = (7;\ -1;\ 0;\ 0)$ und damit $\hat{f} = (3,\ 3,\ 4,\ 4)$ (Abbildung 5.4). Dabei verkleinert es auch den Approximationskoeffizienten von 9 auf 7 und senkt so den Mittelwert von $4{,}5$ auf $3{,}5$; darauf kommt Abschnitt 5.4 zurück. In beiden Fällen wird jeder Koeffizient allein anhand seines eigenen Betrags behandelt (Abbildung 5.3).



(a) Messwerte Y (b) Hard-Thresholding (c) Soft-Thresholding

Abbildung 5.4.: Die Messwerte $Y = (4, 2, 5, 7)$ aus Beispiel 5.8 (a) und die Schätzungen $\hat{f} = (3, 3, 6, 6)$ nach Hard-Thresholding (b) und $\hat{f} = (3, 3, 4, 4)$ nach Soft-Thresholding (c), jeweils mit $T = 2$; gestrichelt Y.

Welches Risiko ein diagonaler Schätzer bestenfalls erreicht, lässt sich koeffizientenweise untersuchen: Das Risiko zerfällt in eine Summe von Einzelbeiträgen.

Lemma 5.9 ([Mal09, Gl. (11.28)]). *Für jeden Schätzer der Form $\hat{f} = A^{\top}\hat{\theta}$ gilt*

$$\mathbb{E}\,\|\hat{f} - f\|^2 \;=\; \sum_{m=0}^{N-1} \mathbb{E}\,|\hat{\theta}_m - \theta_m|^2. \tag{5.3}$$

Bei einem diagonalen Schätzer ist $\hat{\theta}_m = \lambda_m \tilde{Y}_m$; der m-te Summand in (5.3) hängt also nur von λ_m ab, und das Risiko wird minimiert, indem man jeden Summanden einzeln minimiert. Bekannt ist dabei nur die Summe $\tilde{Y}_m = \theta_m + \sigma\tilde{Z}_m$, nicht ihre beiden Anteile. Wir betrachten zunächst feste Faktoren $\lambda_m \in \{0, 1\}$, also diagonale Schätzer, die jeden Koeffizienten entweder behalten oder löschen [Mal09, Kap. 11.2.1]:

- Behalten, $\lambda_m = 1$: Das Signal bleibt, aber auch das Rauschen; die Abweichung ist $\hat{\theta}_m - \theta_m = \sigma\tilde{Z}_m$. Da $\tilde{Z}_m$ nach Lemma 5.4 Mittelwert 0 und Varianz 1 hat, ist $\mathbb{E}|\hat{\theta}_m - \theta_m|^2 = \sigma^2\,\mathbb{E}[\tilde{Z}_m^2] = \sigma^2$.
- Löschen, $\lambda_m = 0$: Dann ist $\hat{\theta}_m = 0$. Das Rauschen ist weg, aber ebenso das Signal; die Abweichung ist $-\theta_m$, der Fehler θ_m^2.

Behalten kostet also im Mittel σ^2, Löschen θ_m^2. Behalten ist daher genau dann mindestens so gut wie Löschen, wenn $|\theta_m|$ mindestens so groß wie σ ist: Für $\sigma = 0{,}3$ ist etwa bei $\theta_m = 2$ Behalten besser ($0{,}09$ statt 4), bei $\theta_m = 0{,}1$ Löschen ($0{,}01$ statt $0{,}09$).

Definition 5.10 (Ideale Auswahl, [Mal09, Gl. (11.32)–(11.34)]). Die ideale Auswahl ist der diagonale Schätzer mit den festen Faktoren $\lambda_m = 1$ für $|\theta_m| \geq \sigma$ und $\lambda_m = 0$ sonst.

Nach Lemma 5.9 ist ihr Risiko

$$r_{\mathrm{id}}(f) \;=\; \sum_{m=0}^{N-1} \min\bigl(\theta_m^2,\, \sigma^2\bigr), \tag{5.4}$$

und kein diagonaler Schätzer mit festen Faktoren $\lambda_m \in \{0, 1\}$ hat ein kleineres Risiko.

Da die λ_m der idealen Auswahl vom unbekannten θ_m abhängen, lässt sie sich nicht berechnen; Mallat spricht von einem Orakel [Mal09, Kap. 11.2.1]. Hard-Thresholding ist ihr praktischer Ersatz: Es behält oder löscht ebenfalls jeden Koeffizienten, entscheidet aber nach dem bekannten $|\tilde{Y}_m|$ und der Schwelle T statt nach $|\theta_m|$ und σ. Sein Risiko ist mindestens $r_{\mathrm{id}}(f)$ [Mal09, Kap. 11.2.2]; die ideale Auswahl ist also eine untere Schranke für das, was Hard-Thresholding erreichen kann.

Sind M Koeffizienten mindestens so groß wie σ, so lässt sich das Risiko der idealen Auswahl schreiben als

$$r_{\mathrm{id}}(f) \;=\; \sum_{|\theta_m| < \sigma} \theta_m^2 \;+\; M\sigma^2$$

[Mal09, Gl. (11.36), (11.37)]. Der erste Term ist der Fehler, wenn man f nur durch diese M Koeffizienten darstellt, der zweite das Rauschen auf ihnen. Das Risiko ist also klein, wenn sich f durch wenige Basisvektoren gut darstellen lässt [Mal09, Kap. 11.2.2]. Wir nennen f dann dünnbesetzt in der Basis $\{v_m\}$ [Mal09, Kap. 11.2.1].

Für Wavelets gilt das bei stückweise glatten Signalen: Große Koeffizienten entstehen nur an scharfen Übergängen, und davon gibt es wenige [Mal09, Kap. 11.3.1].

Beispiel 5.11 (Fortsetzung: Sinus mit Spitzen). Wir gehen vom Sinus u aus Beispiel 5.5 aus und setzen drei schmale Spitzen hinzu:

$$s_n := \sum_{c \in \{1{,}3;\ 3{,}7;\ 6{,}2\}} 3 \max\Bigl(0,\ 1 - \frac{|t_n - c|}{0{,}03}\Bigr), \qquad f := u + s,$$

also drei Dreiecke der Höhe 3 und halben Breite $0{,}03$ (Abbildung 5.5). Der Sinus ist glatt, die Spitzen sind scharfe Übergänge an drei Stellen.

Beide Signale transformieren wir wie in Beispiel 5.5: mit dem Filter (4.6), periodisiert, in $J = 5$ Stufen. Das liefert die $N = 2048$ Koeffizienten $\theta = Af = (a_5, d_5, \ldots, d_1)$; jede Stufe halbiert die Anzahl, sodass d_1 aus 1024, d_2 aus 512, …, d_5 aus 64 Koeffizienten besteht und die übrigen 64 die Approximation a_5 bilden. Für jede Stufe zeigt die Tabelle (Code in Anhang B.5):

- Anzahl: wie viele Koeffizienten die Stufe hat;
- größter Betrag (u): den betragsgrößten Koeffizienten des Sinus auf dieser Stufe;

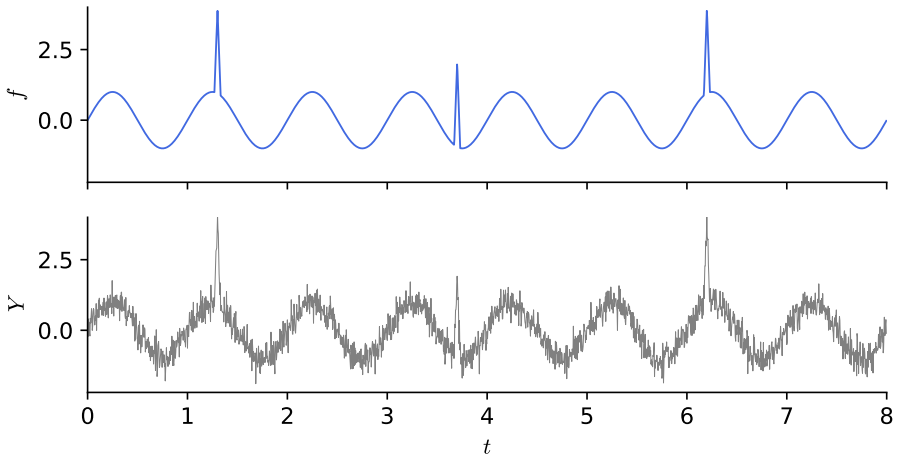


Abbildung 5.5.: Das Testsignal $f = u + s$ aus Beispiel 5.11 (oben) und die Beobachtung $Y = f + 0{,}3\,Z$ (unten), $N = 2048$ (Code in Anhang B.5).

- $\geq \sigma\ (u)$ und $\geq \sigma\ (f)$: wie viele Koeffizienten von u bzw. f betragsmäßig mindestens $\sigma = 0{,}3$ sind. Genau diese behält die ideale Auswahl (Definition 5.10); ihre Summe ist die Zahl M aus dem vorigen Absatz.

Stufe	Anzahl	größter Betrag (u)	$\geq \sigma\ (u)$	$\geq \sigma\ (f)$
a_5	64	5,4	64	64
d_5 (grob)	64	0,36	32	33
d_4	128	0,066	0	8
d_3	256	0,012	0	9
d_2	512	0,0021	0	4
d_1 (fein)	1024	0,00037	0	3
Summe	2048		96	121

Für den Sinus sind nur die 64 Approximationskoeffizienten und 32 Detailkoeffizienten auf Stufe 5 mindestens so groß wie σ, also $M = 96$ von 2048; ab Stufe 4 liegen alle Detailkoeffizienten weit darunter. Der Sinus ist in der Waveletbasis also dünnbesetzt. Zu feineren Stufen hin werden die Detailkoeffizienten des Sinus schnell kleiner, wie nach Lemma 4.15 zu erwarten. Die Spitzen fügen 25 große Koeffizienten hinzu, $M = 121$, fast alle auf den feinen Stufen d_4 bis d_1 und nur in der Nähe der drei Spitzen; in Abbildung 5.6 heben sie sich deutlich von den kleinen Koeffizienten des Sinus ab.

Damit lässt sich das Risiko (5.4) der idealen Auswahl konkret ausrechnen. Beim Sinus behält sie die $M = 96$ Koeffizienten mit $|\theta_m| \geq 0{,}3$; jeder davon kostet $\sigma^2 = 0{,}09$, zusammen $96 \cdot 0{,}09 = 8{,}6$. Die übrigen 1952 Koeffizienten löscht sie; jeder kostet sein Quadrat θ_m^2, und da sie fast alle nahe null liegen, ergibt das zusammen nur $1{,}1$. Insgesamt ist also $r_{\mathrm{id}}(u) = 8{,}6 + 1{,}1 = 9{,}7$. Beim Signal mit Spitzen behält sie $M = 121$ Koeffizienten, das kostet $121 \cdot 0{,}09 = 10{,}9$, und die gelöschten kosten $1{,}7$, also $r_{\mathrm{id}}(f) = 12{,}6$. Ohne Bearbeitung wäre das Risiko $N\sigma^2 = 184{,}3$, also rund fünfzehnmal so groß.

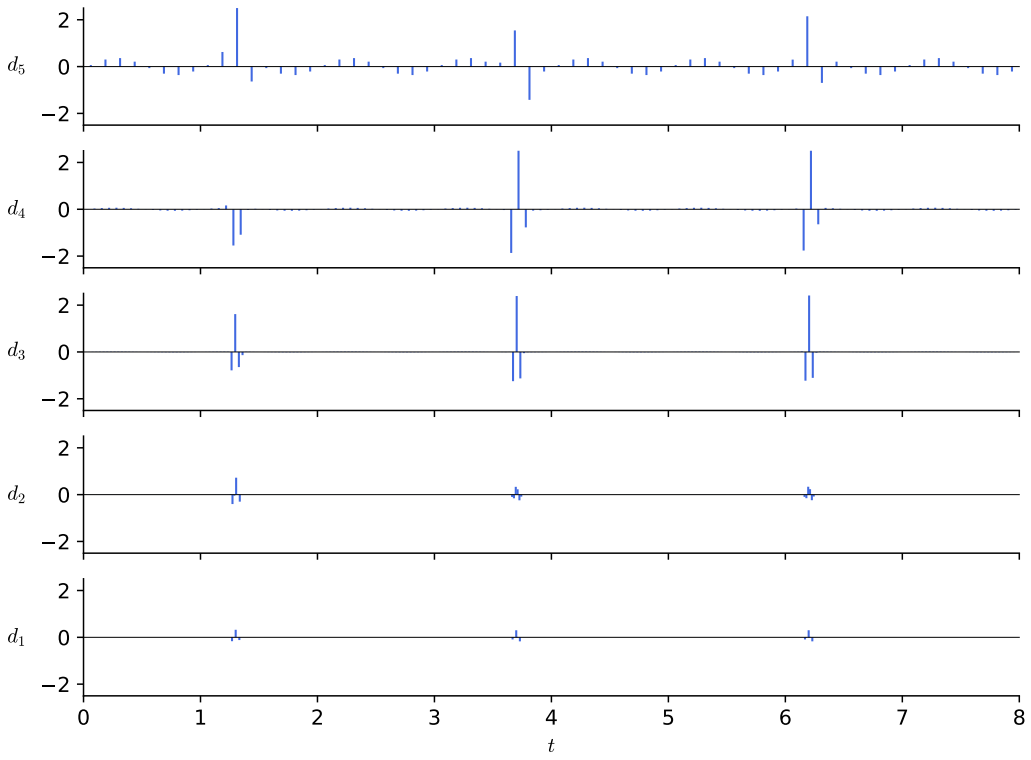


Abbildung 5.6.: Detailkoeffizienten d_5 (oben, grob) bis d_1 (unten, fein) des Testsignals $f = u+s$ aus Beispiel 5.11, aufgetragen über der Zeit t; sehr große Werte abgeschnitten.

5.3. Die Wahl der Schwelle

Die Schwelle T soll das Rauschen entfernen, aber möglichst wenig vom Signal. Ist $f = 0$, so besteht jeder Koeffizient nur aus Rauschen, $\tilde{Y}_m = \sigma\tilde{Z}_m$; damit alle gelöscht werden, muss T größer sein als der größte Rauschanteil $\max_m|\sigma\tilde{Z}_m|$. Ist $f \neq 0$, darf T nicht viel größer sein, sonst gehen auch Koeffizienten mit großem Signalanteil verloren. T soll also knapp über dem größten Rauschanteil liegen [Mal09, Kap. 11.2.2]. Dieses Maximum ist unbekannt. Für N unabhängige Rauschanteile liegt es aber mit hoher Wahrscheinlichkeit knapp unter

$$T \;=\; \sigma\sqrt{2\ln N} \tag{5.5}$$

[Mal09, Gl. (11.64)]. Diese Wahl heißt universelle Schwelle [Mal09, Kap. 11.3.2]. Dass T mit N wächst, liegt an den Ausläufern der Normalverteilung: Unter mehr Werten kommen auch größere vor [Mal09, Kap. 11.2.2].

Satz 5.12 (Donoho–Johnstone, [Mal09, Satz 11.7]). *Für $N \geq 4$ und $T = \sigma\sqrt{2\ln N}$ erfüllt das Risiko des Hard- und des Soft-Thresholding-Schätzers*

$$r(f) \;\leq\; (2\ln N + 1)\big(\sigma^2 + r_{\mathrm{id}}(f)\big). \tag{5.6}$$

Für den Beweis siehe [Mal09, Satz 11.7, Lemma 11.1]. Zusammen mit der unteren Schranke aus Abschnitt 5.2, die Mallat für Hard-Thresholding zeigt, ergibt sich dafür

$$r_{\mathrm{id}}(f) \;\le\; r(f) \;\le\; (2\ln N + 1)\big(\sigma^2 + r_{\mathrm{id}}(f)\big)$$

[Mal09, Kap. 11.2.2]. Bis auf den Faktor $2\ln N + 1$ ist Hard-Thresholding also so gut wie die ideale Auswahl. Die obere Schranke gilt für beide Varianten: Ist f dünnbesetzt und damit $r_{\mathrm{id}}(f)$ klein, so ist auch $r(f)$ klein. Mit diagonalen Schätzern lässt sich dieser Faktor für große N nicht verbessern [Mal09, Gl. (11.52)].

Die Schwelle (5.5) ist allerdings nicht optimal: Eine kleinere Schwelle senkt das Risiko oft, und Soft-Thresholding braucht für ähnliche Ergebnisse wie Hard-Thresholding etwa die halbe Schwelle [Mal09, Kap. 11.2.2].

5.4. Schätzung der Rauschstärke

Die Schwelle enthält das unbekannte σ. Mallat schätzt es aus den $N/2$ Detailkoeffizienten $d_{1,k}$ der feinsten Stufe [Mal09, Kap. 11.3.1]: Wo das Signal auf dem Träger des Wavelets glatt ist, ist sein Koeffizient klein, und $d_{1,k}$ besteht praktisch nur aus Rauschen. Nur an den wenigen scharfen Übergängen ist er groß; diese Werte nennt Mallat Ausreißer. Auch beim gemessenen EKG, das in Kapitel 6 relevant wird, enthält d_1 fast das gesamte Rauschen [LMR98, Kap. 3.1.2].

Der Median von P Zahlen ist der mittlere Wert, wenn man sie der Größe nach ordnet, also der Wert vom Rang $P/2$ [Mal09, Kap. 11.3.1]. Anders als der Mittelwert hängt er nicht davon ab, wie groß die Werte über ihm sind, und wird von wenigen Ausreißern daher kaum verändert. Ist M der Median der Beträge von P unabhängigen normalverteilten Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2, so ist $\mathbb{E}[M] \approx 0{,}6745\,\sigma$ [Mal09, Kap. 11.3.1]. Daraus ergibt sich der Schätzer

$$\hat\sigma \;=\; \frac{\mathrm{Median}\big(|d_{1,k}| : 0 \le k < N/2\big)}{0{,}6745} \tag{5.7}$$

[Mal09, Gl. (11.85)]. Er setzt voraus, dass das Rauschen in allen Koeffizienten dieselbe Stärke hat, was nach Lemma 5.4 für weißes Rauschen zutrifft. Ist das Rauschen nicht weiß, hängt seine Varianz vom Basisvektor ab, und die Schwelle muss mit dem Koeffizienten variieren [Mal09, Kap. 11.2.2]; darauf kommt Kapitel 6 zurück.

Anmerkung. Kap. 6 greift farbiges Rauschen bisher nicht auf – ergänzen oder Verweis streichen.

Das vollständige Verfahren. Mallat schwellt alle Koeffizienten der Waveletbasis, auch die der gröbsten Approximation [Mal09, Gl. (11.84)], und bestimmt σ mit (5.7) [Mal09, Kap. 11.3.1]. Zusammen ergibt sich:

Algorithmus 2 Entrauschen mit universeller Schwelle nach [Mal09, Kap. 11.2–11.3]

Eingabe: Messwerte $Y \in \mathbb{R}^N$, Filter h, g, Tiefe J mit $2^J \mid N$

1: $(a_J, d_J, \ldots, d_1) \leftarrow AY$ ▷ Algorithmus 1, periodisiert
2: $T \leftarrow \hat\sigma\sqrt{2\ln N}$ mit $\hat\sigma$ aus (5.7)
3: ersetze jeden Koeffizienten c von $a_J, d_J, \ldots, d_1$ durch $\rho_T(c)$
4: **Rückgabe** $\hat f \leftarrow A^\top$(geschwellte Koeffizienten) ▷ Satz 4.11

Satz 5.12 setzt das wahre σ voraus; mit dem geschätzten $\hat{\sigma}$ ist die Schranke (5.6) nur ein Anhaltspunkt. Ferner werden in Zeile 3 auch die Approximationskoeffizienten a_J geschwellt. Sie tragen den glatten, groben Anteil des Signals und sind meist groß; Soft-Thresholding verkleinert jeden von ihnen um T und verschiebt so den glatten Anteil, wie schon in Beispiel 5.8 den Mittelwert. In seinem Beispiel zur Bildentrauschung schwellt Mallat die Skalierungskoeffizienten deshalb nicht [Mal09, Kap. 11.3.2].

Beispiel 5.13 (Fortsetzung: Entrauschen des Testsignals)**.** Wir entrauschen jetzt die Messwerte $Y = f + 0{,}3\,Z$ aus Beispiel 5.11.

Zuerst wird die Schwelle bestimmt. Der Schätzer (5.7) liefert $\hat{\sigma} = 0{,}300$, trifft das wahre $\sigma = 0{,}3$ also sehr genau. Damit ist $T = \hat{\sigma}\sqrt{2 \ln N} = 1{,}17$.

Abbildung 5.7 zeigt, was diese Schwelle trennt. Das Rauschen bleibt auf allen Stufen zwischen den gestrichelten Linien: Kein einziger Rauschkoeffizient erreicht T, der größte hat den Betrag $1{,}02$. Darüber ragen nur die Koeffizienten an den drei Spitzen hinaus. Hard-Thresholding behält deshalb nur 75 der 2048 Koeffizienten.

Anmerkung. kein einziger rauschkoeff fühlt sich falsch an??

Das Ergebnis zeigt Abbildung 5.8. Mit Hard-Thresholding sinkt die Fehlerenergie von $181{,}3$ auf $27{,}6$, also auf etwa ein Siebtel, und die Spitzen bleiben weitgehend erhalten. Soft-Thresholding mit derselben Schwelle erreicht nur $127{,}1$ und macht die Spitzen deutlich niedriger. Der Grund ist, dass Soft-Thresholding auch jeden behaltenen Koeffizienten um T verkleinert. Das betrifft vor allem die 64 Approximationskoeffizienten, die alle größer als T sind und den glatten Sinus tragen.

Anmerkung. vll wäre es noch schön das alte verrauschte signal einzubauen...

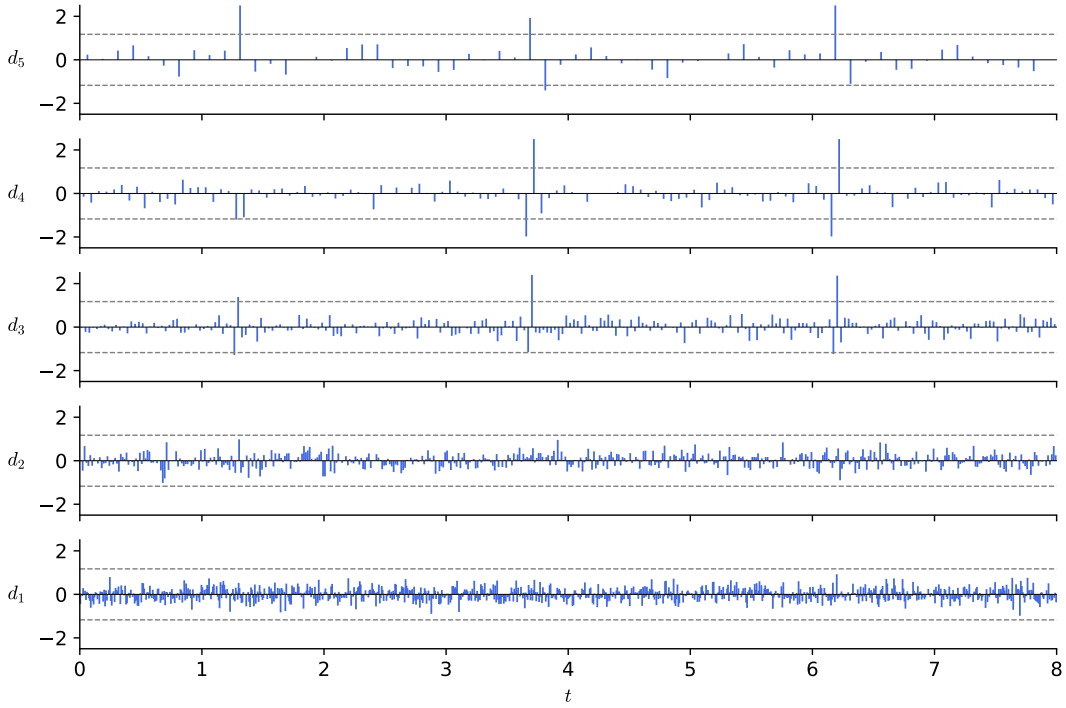


Abbildung 5.7.: Detailkoeffizienten d_5 (oben) bis d_1 (unten) der Messwerte $Y = f + 0{,}3\,Z$ aus Beispiel 5.13, im selben Maßstab wie Abbildung 5.6; gestrichelt die Schwelle $\pm T = \pm 1{,}17$.

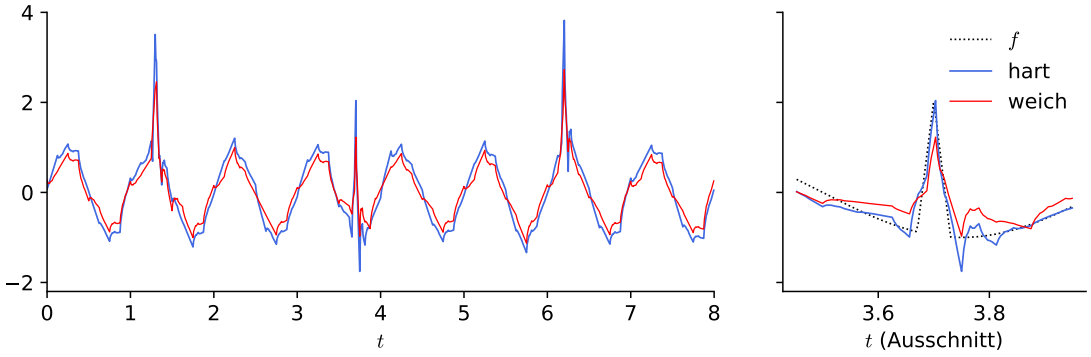


Abbildung 5.8.: Schätzungen aus Y mit Algorithmus 2, $T = 1{,}17$ (links), und Ausschnitt um die mittlere Spitze mit dem wahren Signal f (rechts)(Code in Anhang B.8).

6. Anwendung: Entrauschung von EKG-Signalen

In diesem Kapitel wird das Thresholding aus Kapitel 5 auf reale EKG-Aufzeichnungen der MIT-BIH Arrhythmia Database angewandt. Ziel ist, die Störungen zu entfernen, die in diesen Aufzeichnungen bereits enthalten sind. Wir folgen dabei Castillo et al. [CMG+13] und Alessio [Ale16, Kap. 15.2.4], die beide EKG-Signale mit der DWT von Drift und Rauschen befreien; Alessio stellt dort das Verfahren von Castillo et al. als Beispiel dar. Ein ungestörtes Vergleichssignal gibt es für reale Aufzeichnungen nicht; die Bewertung stützt sich deshalb auf Größen, die sich ohne ein solches Signal messen lassen.

6.1. EKG-Signale und ihre Störquellen

Ein EKG-Signal ist die Differenz elektrischer Potentiale an zwei Punkten des Körpers, die durch die Erregung des Herzmuskels entsteht [Gac12, Kap. 2.2]. Jeder Herzschlag erzeugt dieselbe Folge von Ausschlägen (Abbildung 6.1): die P-Welle bei der Erregung der Vorhöfe, den QRS-Komplex bei der Erregung der Kammern und die T-Welle bei deren Repolarisation [Gac12, Abb. 2.1], [Reb21, Kap. 2.1].

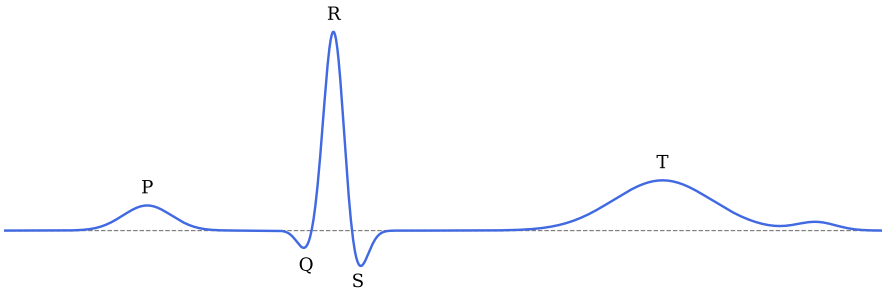


Abbildung 6.1.: Schematischer Herzschlag mit P-, Q-, R-, S- und T-Welle in Anlehnung an [Reb21, Abb. 2.2]; Amplituden und Dauern frei gewählt (Code in Anhang B.9).

Ein gemessenes EKG enthält neben dem Signal des Herzens Störungen [CMG+13, Abschn. 1]; Tabelle 6.1 fasst die wichtigsten zusammen. Wir nehmen an, dass sie sich zum EKG addieren. Rebstadt beschreibt die Artefakte als additive Funktionen im gestörten Signal [Reb21, Kap. 2.3.1], und auch Alessio und Castillo et al. gehen von additivem Rauschen aus [Ale16, Kap. 15.2.1], [CMG+13, Abschn. 2.2.2, Gl. (8)].

Größen wie die Höhe einer Zacke werden gegenüber der isoelektrischen Linie gemessen, der Nulllinie des EKG; sie wird in den meisten Rhythmen am besten durch die PQ-Strecke zwischen

Störung	Ursache	Frequenzen
Basisliniendrift	Atmung, Bewegung, Elektrodenkontakt	meist < 1 Hz
Elektrodenbewegung	Impedanzänderung der Haut	1–10 Hz
Netzbrummen	Erdung, Geräte in der Nähe	50 oder 60 Hz
Muskelrauschen	Aktivität der Skelettmuskeln	etwa 20–80 Hz
weißes Rauschen	Kanalübertragung, Messgeräte	alle

Tabelle 6.1.: Störungen im EKG nach [SL05, Kap. 6.5], [Gac12, Kap. 2.3, 2.4.3] und [Reb21, Kap. 2.1]; Zusammenstellung eigen.

P-Welle und QRS-Komplex dargestellt [SL05, Kap. 7.1.3]. Solange Drift vorhanden ist, ist diese Linie nicht bestimmt, und damit lassen sich auch die Größen nicht bestimmen, die gegen sie gemessen werden [SL05, Kap. 6.5]; deshalb muss die Drift entfernt werden. Elektrodenbewegung und Muskelrauschen überlappen mit dem EKG: Elektrodenartefakte werden manchmal für QRS-Komplexe gehalten, und Muskelrauschen lässt sich nur schwer entfernen, ohne das EKG zu verzerren [SL05, Kap. 6.5]. Das weiße Rauschen σZ dagegen verteilt sich auf alle Frequenzen; für dieses Rauschen ist das Thresholding aus Kapitel 5 gedacht (Abschnitt 6.4.1).

6.2. Die Datensätze

Die MIT-BIH Arrhythmia Database ist eine der meistgenutzten Datenbanken zur Bewertung von Verfahren für Herzrhythmusstörungen [SL05, Kap. 1.4.1]. Sie enthält 48 halbstündige Ausschnitte zweikanaliger Langzeit-EKG von 47 Personen, aufgezeichnet zwischen 1975 und 1979 am Beth Israel Hospital in Boston [MM01, Abschn. Selection of Data], und ist über PhysioNet frei zugänglich [MM05]. Die Aufzeichnungen entstanden im Alltag, etwa beim Arbeiten und Essen [SL05, Kap. 1.4.1].

Aufzeichnung und Digitalisierung. Vor der Digitalisierung wurden die Signale auf 0,1 bis 100 Hz bandbegrenzt [MM01, Abschn. Technical Limitations of the Data]; das heißt, Anteile mit Frequenzen außerhalb dieses Bereichs wurden durch ein Filter weitgehend entfernt. In der Zeit wurde mit $f_s = 360$ Hz abgetastet [MM01, Abschn. Digitization]; alle $1/360\,\mathrm{s} \approx 2{,}8$ ms wurde also ein Wert gespeichert. Welche Frequenzen sich damit darstellen lassen, behandelt Abschnitt 6.3.

Zu den Störquellen aus Tabelle 6.1 kommt eine technische hinzu: Die Bandgeräte, mit denen die Langzeit-EKG aufgezeichnet und später abgespielt wurden, erzeugen durch ihre Mechanik langsame Störungen mit Frequenzen zwischen 0,042 und 0,54 Hz [MM97, Abschn. Introduction, Analog recording and playback]. Das Netzbrummen aus Tabelle 6.1 liegt bei diesen Daten bei 60 Hz und entstand größtenteils erst beim Abspielen [MM01, Abschn. Technical Limitations of the Data].

Annotationen. Zu jeder Aufzeichnung gehört eine Annotationsdatei: Zwei Kardiologen haben unabhängig voneinander jeden Herzschlag geprüft und beschriftet [MM01, Abschn. Annotation], im Allgemeinen am Maximum der R-Zacke [MM97, Abschn. Introduction, Annotations]. Aus

diesen Markierungen bestimmen wir in Abschnitt 6.4.2 die Herzfrequenz. Außerdem kennzeichnen die Annotationen Abschnitte mit starkem Rauschen [MM01, Abschn. Annotation].

Datensätze 100 und 103. Zwischen welchen zwei Punkten des Körpers ein EKG-Signal die Spannung misst (Abschnitt 6.1), legt die *Ableitung* fest; die Ableitung II misst sie zwischen rechtem Arm und linkem Bein [Reb21, Kap. 2.1, Tab. 2.1]. Wir verwenden die Datensätze 100 und 103, jeweils das obere der beiden Signale. Es ist die modifizierte Ableitung II (MLII), bei der die Elektroden auf dem Brustkorb statt an den Extremitäten sitzen [MM97, Abschn. ECG lead configuration; Records]. Beide zeigen über die gesamte Dauer einen normalen Sinusrhythmus [MM97, Abschn. Records], also Schläge der Form aus Abbildung 6.1 [Reb21, Kap. 2.1, Abb. 2.2]. Bei Datensatz 100 ist kein Abschnitt des oberen Signals als stark verrauscht markiert, bei Datensatz 103 ein Abschnitt von etwa $9\,\mathrm{s}$ [MM97, Abschn. Records]; nach der Annotationsdatei liegt er zwischen $1089{,}8$ und $1098{,}4\,\mathrm{s}$ (Code in Anhang B.9).

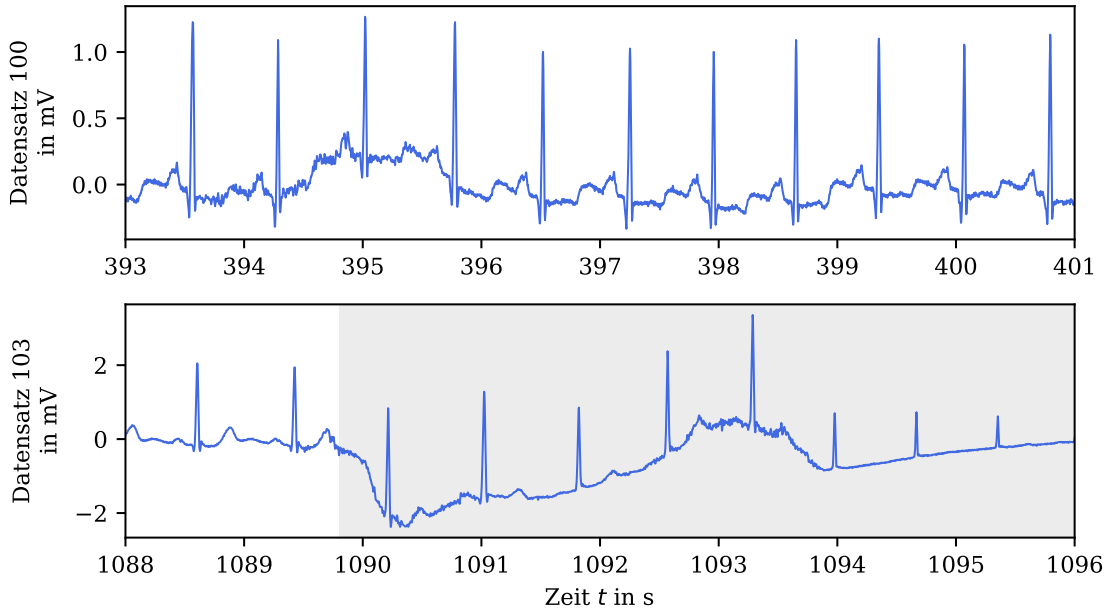


Abbildung 6.2.: Je ein Ausschnitt von $8\,\mathrm{s}$ aus den Datensätzen 100 (oben, ab $393\,\mathrm{s}$) und 103 (unten, ab $1088\,\mathrm{s}$), oberes Signal MLII. Grau hinterlegt der Abschnitt, in dem das obere Signal von Datensatz 103 als stark verrauscht annotiert ist (Code in Anhang B.9).

Abbildung 6.2 zeigt je einen Ausschnitt von $8\,\mathrm{s}$. Gestört sind beide Aufzeichnungen, auch außerhalb der als verrauscht markierten Abschnitte. In beiden Datensätzen ist die Basisliniendrift die auffälligste Störung. Bei Datensatz 100 schwankt die Nulllinie innerhalb weniger Sekunden um etwa $0{,}4\,\mathrm{mV}$. Bei Datensatz 103 fällt die Nulllinie zu Beginn des verrauschten Abschnitts innerhalb von etwa einer Sekunde um rund $2\,\mathrm{mV}$ und steigt danach langsam wieder an.

Länge. Wir transformieren jede Aufzeichnung als Ganzes. Das ist möglich, weil Langzeit-EKG erst ausgewertet werden, nachdem die Aufzeichnung abgeschlossen ist [SL05, Kap. 6.6.3]; das Verfahren muss also nicht schon während der Messung arbeiten. Damit die periodisierte DWT der Tiefe J definiert ist, muss 2^J die Länge N teilen (Abschnitt 5.1); wir verwenden die ersten $N = 2^{19} = 524\,288$ Abtastwerte, also $N/f_s = 524\,288/(360\,\mathrm{Hz}) \approx 1456\,\mathrm{s}$, das sind 24 min 16 s.

6.3. Skalen als Frequenzbänder

Um zu entscheiden, welche Stufen der DWT gelöscht, geschwellt oder unverändert gelassen werden, ordnen wir jeder Stufe ein Frequenzband zu. Castillo et al. wählen so die Tiefe für die Drift und die Zahl der geschwellten Stufen [CMG+13, Abschn. 3.1.2, 3.1.3].

Höchste Frequenz. Die Frequenzbänder der Stufen entstehen, indem das Band des Signals von oben her fortlaufend halbiert wird. Dazu brauchen wir seine obere Grenze. Nach dem Abtasttheorem ist ein mit der Rate f_s abgetastetes Signal nur bis zur Frequenz

$$F_{\max} = \frac{f_s}{2}$$

eindeutig darstellbar [CMG+13, Abschn. 3.1.2], [Bla03, Kap. 2.4, Satz (2.16)]; eine Schwingung der Frequenz $f > F_{\max}$ hat an den Abtastzeiten n/f_s dieselben Werte wie eine der Frequenz $f_s - f < F_{\max}$. In der Variablen $\omega = 2\pi f/f_s$ der Filter aus Kapitel 4 entspricht $[0, F_{\max}]$ dem Intervall $[0, \pi]$.

Halbierung des Bandes. Die Fourier-Filter

$$H(\omega) = \frac{1}{\sqrt{2}} \sum_k h_k e^{-ik\omega}, \qquad G(\omega) = \frac{1}{\sqrt{2}} \sum_k g_k e^{-ik\omega}$$

aus (4.2) und (4.9) sind nach Abschnitt 4.3 ein Tief- und ein Hochpass: $|H|$ ist auf $[0, \pi/2]$ groß und auf $[\pi/2, \pi]$ klein, $|G|$ umgekehrt (Abbildung 4.1).

Anmerkung. Abbildung 4.1 zeigt nur Haar und db2, nicht das hier verwendete ψ_6. Empfehlung: beim Beispiel 4.17 in Kapitel 4 eine Teilabbildung mit $|H|$ und $|G|$ für ψ_6 ergänzen und hier darauf verweisen. Werte zum Vergleich: $|H(\pi/4)| = 0{,}924$ / $0{,}971$ / $0{,}999$ und $|H(3\pi/4)| = 0{,}383$ / $0{,}241$ / $0{,}048$ für Haar / db2 / db6.

Eine Stufe der DWT wendet nach (4.11) beide auf a_{i-1} an und behält jeden zweiten Wert: a_i entsteht durch den Tiefpass und erhält die untere Hälfte des Bandes von a_{i-1}, d_i entsteht durch den Hochpass und erhält die obere [CMG+13, Abschn. 3.1.2]. Mit $a_0 = Y$ und dem Band $[0, F_{\max}]$ von Y folgt

$$a_i \leftrightarrow \left[0, \frac{F_{\max}}{2^i}\right], \qquad d_i \leftrightarrow \left[\frac{F_{\max}}{2^i}, \frac{F_{\max}}{2^{i-1}}\right] \tag{6.1}$$

[Reb21, Kap. 2.3.2, Tab. 2.4]. Bei Castillo et al. ist $f_s = 250\,\mathrm{Hz}$, also $F_{\max} = 125\,\mathrm{Hz}$, und a_7 erfasst 0 bis $125/2^7 \approx 0{,}977\,\mathrm{Hz}$ [CMG+13, Abschn. 3.1.2]. Die Zuordnung ist nicht scharf, da $|H|$ und $|G|$ nicht sprunghaft von 1 auf 0 fallen. Wegen $|H|^2 + |G|^2 = 1$ (Abschnitt 4.3)

und $|G(\pi/2)| = |H(\pi/2)|$ nach (4.9) gilt an der Grenze $|H(\pi/2)| = |G(\pi/2)| = 1/\sqrt{2}$: Eine Frequenz genau auf einer Bandgrenze verteilt ihre Energie je zur Hälfte auf beide benachbarten Stufen, Frequenzen nahe der Grenze auf beide.

Unsere Daten. Die Tiefe J ist die Anzahl der Stufen. Sie ist eine positive ganze Zahl mit $J \leq \log_2 N$ [CMG+13, Abschn. 3.1.2], bei uns also $J \leq \log_2 2^{19} = 19$; wir verwenden $J = 8$ (Abschnitt 6.4.2). Mit $F_{\max} = 360\,\mathrm{Hz}/2 = 180\,\mathrm{Hz}$ ergibt (6.1) Tabelle 6.2.

	d_1	d_2	d_3	d_4	d_5	d_6	d_7	d_8	a_8
von (Hz)	90	45	22,5	11,3	5,6	2,8	1,4	0,70	0
bis (Hz)	180	90	45	22,5	11,3	5,6	2,8	1,4	0,70
P- und T-Welle				(•)	•	•	•	•	
Herzfrequenz								•	
Basisliniendrift								(•)	•
Bandmechanik									•
Elektrodenbewegung					(•)	•	•	(•)	
Netzbrummen (60 Hz)		•							
Muskelrauschen		•	•	(•)					

Tabelle 6.2.: Frequenzbänder der Koeffizienten nach (6.1) für $f_s = 360\,\mathrm{Hz}$ und $J = 8$. Darunter die Bänder von: P- und T-Welle, 1 bis 20 Hz [Reb21, Kap. 2.3.1]; Herzfrequenz, über 0,88 Hz (Abschnitt 6.4.2); Drift, Elektrodenbewegung, Netzbrummen und Muskelrauschen nach Tabelle 6.1; Bandmechanik, 0,042 bis 0,54 Hz (Abschnitt 6.2). Die Zuordnung zu den Stufen ist eigen; in Klammern Stufen, die nur am Rand getroffen werden.

Bis auf σZ liegen alle Störungen aus Tabelle 6.1 in begrenzten Frequenzbändern und damit nach (6.1) näherungsweise nur in einigen Stufen; σZ liegt in allen Stufen und fehlt deshalb in Tabelle 6.2. Die Tabelle zerfällt in drei Bereiche:

- a_8, $[0;\, 0{,}70]$ Hz: Drift und Bandmechanik.
- d_4 bis d_8, $[0{,}70;\, 22{,}5]$ Hz: P- und T-Welle, Herzfrequenz und Elektrodenbewegung.
- d_1 bis d_3, $[22{,}5;\, 180]$ Hz: Netzbrummen und Muskelrauschen. Vom EKG, dessen Spektrum bis 150 Hz reicht [Gac12, Kap. 2.4.3.2], liegen P- und T-Welle und die tieffrequenten Anteile des QRS-Komplexes unter 20 Hz [Reb21, Kap. 2.3.1]; in diesen Stufen bleiben also nur seine hochfrequenten Anteile.

Deshalb wird a_8 gelöscht, d_4 bis d_8 bleiben unverändert, und d_1 bis d_3 werden geschwellt (Abschnitt 6.4).

6.4. Das Verfahren

Wir übernehmen das Ein-Schritt-Verfahren von Castillo et al., das Drift und Rauschen mit einer einzigen Zerlegung und Rekonstruktion entfernt [CMG+13, Abschn. 3]. Abschnitt 6.4.1 definiert das Verfahren, die folgenden Abschnitte wählen seine Parameter.

6.4.1. Modell und Ein-Schritt-Verfahren

Castillo et al. und Alessio gehen für das Rauschen vom Modell (5.1) aus, $Y_n = f_n + \sigma Z_n$ [CMG+13, Abschn. 2.2.2, Gl. (8)], [Ale16, Kap. 15.2.1], und behandeln die Basisliniendrift getrennt davon [CMG+13, Abschn. 2.2.1]. Wir fassen beides in einer Gleichung zusammen; diese Schreibweise ist eigen:

$$Y_n = f_n + b_n + \sigma Z_n, \qquad n = 0, \dots, N-1. \tag{6.2}$$

Dabei ist $f \in \mathbb{R}^N$ das EKG, $b \in \mathbb{R}^N$ die Basisliniendrift und σZ wie in (5.1) Gauß'sches weißes Rauschen. Elektrodenbewegung, Netzbrummen und Muskelrauschen aus Tabelle 6.1 sind darin nicht enthalten. Es bezeichne A die periodisierte DWT der Tiefe J aus Abschnitt 5.1 mit dem Filter (4.13) des Wavelets ψ_6 (Beispiel 4.17). AY ist die Zerlegung des Signals in die Stufen, also die Approximation a_J und die Details $d_J, \dots, d_1$:

$$AY = (a_J, d_J, d_{J-1}, \dots, d_1) \in \mathbb{R}^N, \qquad a_J \in \mathbb{R}^{N/2^J},\ d_j \in \mathbb{R}^{N/2^j}.$$

Bemerkung 6.1 (Wahl des Wavelets). Castillo et al. wählen das Wavelet nach seiner Ähnlichkeit mit dem QRS-Komplex und nehmen `db6`, also ψ_6 aus Satz 4.16 mit $p = 6$ verschwindenden Momenten, weil es einem echten EKG ähnelt [CMG+13, Abschn. 3.1.1]; ebenso Alessio [Ale16, Kap. 15.2.4]. Allgemein soll das Wavelet die Form der Merkmale haben, die erhalten bleiben sollen [Ale16, Kap. 15.2.1]. In ihrem Vergleich von zwölf Wavelets an synthetischen EKG finden Castillo et al. zwischen den Wavelets keine großen Unterschiede [CMG+13, Abschn. 4, Tab. 2].

Da A eine Matrix ist, folgt aus (6.2)

$$AY = Af + Ab + \sigma AZ. \tag{6.3}$$

Nach Lemma 5.4 hat jeder Koeffizient von σAZ die Varianz σ^2, gleich in welcher Stufe er liegt; Ab liegt bei geeigneter Wahl von J nach (6.1) näherungsweise nur in a_J, für $J = 8$ nach Tabelle 6.2 in a_8 und am Rand von d_8.

Castillo et al. gehen in vier Schritten vor [CMG+13, Abschn. 3]:

1. Y bis zur Tiefe J zerlegen,
2. a_J durch den Nullvektor ersetzen,
3. die Details $d_1, \dots, d_{J_S}$ schwellen, $J_S < J$,
4. aus dem Nullvektor, den unveränderten $d_{J_S+1}, \dots, d_J$ und den geschwellten $d_1, \dots, d_{J_S}$ rekonstruieren.

Als Formel:

Definition 6.2 (Ein-Schritt-Verfahren). Zu Tiefen $1 \le J_S < J$ und einer Schwelle $T > 0$ sei

$$\hat{f} = A^\top \big(0,\ d_J, \dots, d_{J_S+1},\ \rho_T^{\mathrm{S}}(d_{J_S}), \dots, \rho_T^{\mathrm{S}}(d_1)\big), \tag{6.4}$$

wobei das Soft-Thresholding ρ_T^{S} aus Definition 5.7 komponentenweise angewandt wird.

Soft- statt Hard-Thresholding verwenden wir, weil Hard-Thresholding Unstetigkeiten erzeugt, Soft-Thresholding nicht [CMG+13, Abschn. 3.1.6, Gl. (24), (25)], und weil Soft-Thresholding bei Castillo et al. mit weniger Stufen die größere SNR-Verbesserung erreicht [CMG+13, Abschn. 4]; auch Alessio schwellt weich [Ale16, Kap. 15.2.1]. Hard-Thresholding rechnen wir in Abschnitt 6.5 zum Vergleich mit. Gegenüber Algorithmus 2 ändern sich zwei Dinge: a_J wird nicht geschwellt, sondern gelöscht, und die gröberen Details bleiben unverändert.

Anmerkung. vll in algo 2 das auch so anpassen.....

Zu wählen sind noch die Tiefen J und J_S und die Schwelle T.

6.4.2. Tiefe J für die Drift

Castillo et al. schreiben L für unser J und M für unser J_S [CMG+13, Abschn. 3]. Da a_J gelöscht wird, soll es die Drift enthalten, aber keinen Anteil des EKG. Nach (6.1) erfasst a_J die Frequenzen $[0, F_{\max}/2^J]$. Die tiefste Frequenz des EKG ist die langsamste Herzfrequenz [SL05, Kap. 7.1]; die Grenze muss also zwischen Drift und Herzfrequenz liegen:

$$f_{\text{Drift}} < \frac{F_{\max}}{2^J} < f_{\text{Herz}}. \tag{6.5}$$

Castillo et al. und Alessio wählen dazu eine Grenze f_c, setzen $F_{\max}/2^J \approx f_c$ und erhalten

$$J_{BW} = \operatorname{int}\Big[\log_2\Big(\frac{F_{\max}}{f_c}\Big)\Big], \tag{6.6}$$

wobei int auf die nächste ganze Zahl rundet [CMG+13, Abschn. 3.1.2, Gl. (9)], [Ale16, Kap. 15.2.4]. Bei Castillo et al. ist $F_{\max} = 125\,\text{Hz}$ und $f_c = 1\,\text{Hz}$, also $J_{BW} = 7$, und a_7 erfasst 0 bis $0{,}977\,\text{Hz}$.

Unsere Daten. Die Atmungsdrift liegt bei $0{,}15$ bis $0{,}3\,\text{Hz}$ [CMG+13, Abschn. 2.2.1]. Nach den Annotationen liegt die Herzfrequenz im Mittel bei 75 bzw. 70 Schlägen pro Minute und für keinen Schlag unter 53 pro Minute, also $f_{\text{Herz}} > 53/60\,\text{Hz} \approx 0{,}88\,\text{Hz}$ (Code in Anhang B.9). Mit $F_{\max} = 180\,\text{Hz}$ gilt:

- $f_c = 1\,\text{Hz}$ wie bei Castillo et al. ergibt $J = \operatorname{int}[\log_2 180] = \operatorname{int}[7{,}49] = 7$ und die Grenze $180/2^7 = 1{,}41\,\text{Hz} > 0{,}88\,\text{Hz}$. Die rechte Ungleichung in (6.5) ist verletzt; a_7 enthielte Anteile des EKG.
- Sörnmo und Laguna empfehlen eine Grenze etwas unter der langsamsten Herzfrequenz, etwa $f_c = 0{,}5\,\text{Hz}$, und warnen, dass bei zu hoher Grenze eine mit der Herzfrequenz schwingende Störung entsteht [SL05, Kap. 7.1]. Das ergibt

  $$J = \operatorname{int}[\log_2 360] = \operatorname{int}[8{,}49] = 8, \qquad 0{,}3\,\text{Hz} < \frac{180}{2^8}\,\text{Hz} = 0{,}70\,\text{Hz} < 0{,}88\,\text{Hz},$$

  (6.5) ist also erfüllt.

Es kommt dabei nicht genau auf $0{,}5\,\text{Hz}$ an: Für jedes $f_c \in [0{,}50;\ 0{,}99]\,\text{Hz}$ ist $\log_2(180/f_c) \in [7{,}5;\ 8{,}5]$, also $J = 8$. Die Grenze darf aber nicht zu knapp über der Drift liegen: Bei Castillo et al. ist für alle drei Abtastraten die Stufe mit der Grenze nahe $0{,}98\,\text{Hz}$ am besten, die nächsttiefere mit $0{,}49\,\text{Hz}$ entfernt Drift bis $0{,}3\,\text{Hz}$ deutlich schlechter [CMG+13, Abschn. 4, Tab. 1]. Unsere Grenze $0{,}70\,\text{Hz}$ liegt mehr als doppelt so hoch wie die Drift. In Abschnitt 6.5 vergleichen wir $J = 7, 8, 9$ am Test-EKG.

6.4.3. Anzahl J_S der geschwellten Stufen

J_S legt fest, wie viele der feinsten Stufen geschwellt werden: d_1 bis d_{J_S} werden geschwellt, d_{J_S+1} bis d_J bleiben unverändert. Da nach Lemma 5.4 jeder Koeffizient von σAZ die Varianz σ^2 hat und d_j aus $N/2^j$ Koeffizienten besteht, bleibt in den unveränderten Stufen der Anteil

$$\frac{1}{\sigma^2 N} \sum_{j=J_S+1}^{J} \sigma^2 \frac{N}{2^j} = 2^{-J_S} - 2^{-J}$$

der Rauschenergie erhalten. Ein größeres J_S entfernt also mehr Rauschen, schwellt aber auch Stufen, in denen das EKG liegt. Wir wählen das größte J_S, dessen geschwellte Stufen nach (6.1) oberhalb von P- und T-Welle liegen, $f_{PT} = 20\,\text{Hz}$ [Reb21, Kap. 2.3.1]:

$$\frac{F_{\max}}{2^{J_S}} \geq f_{PT} \iff J_S \leq \log_2 \frac{180}{20} \approx 3{,}17, \qquad \text{also } J_S = 3.$$

Damit bleiben $2^{-3} - 2^{-8} = 31/256 \approx 12{,}1\,\%$ der Rauschenergie erhalten. In d_1 bis d_3 liegen neben Netzbrummen und Muskelrauschen auch die hochfrequenten Anteile des QRS-Komplexes [Reb21, Kap. 2.3]. Da das EKG durch wenige große Koeffizienten dargestellt wird, das Rauschen durch viele kleine [CMG+13, Abschn. 2.2.2], werden diese Stufen geschwellt statt gelöscht.

6.4.4. Schwelle

Als Schwelle verwenden wir die universelle Schwelle (5.5) mit dem Schätzer (5.7), $T = \hat{\sigma}\sqrt{2 \ln N}$, wie Castillo et al. und Alessio [CMG+13, Abschn. 3.1.4, Gl. (10); 3.1.5, Gl. (19), (23)], [Ale16, Kap. 15.2.2, 15.2.3]. Geschätzt wird $\hat{\sigma}$ aus d_1: Bei weißem Rauschen kann man die Standardabweichung aus den Koeffizienten der ersten Stufe nehmen [CMG+13, Abschn. 3.1.5], und nach Alessio sind diese im Wesentlichen Rauschen [Ale16, Kap. 15.2.2]. Für N zwischen 2^6 und 2^{19} überschreitet reines Rauschen diese Schwelle nur in etwa einem Zehntel der Realisierungen [Ale16, Kap. 15.2.3]. Gerechnet wurde mit PyWavelets [LGW+19] (Code in Anhang B.9). Im Folgenden testen wir das Verfahren zuerst an einem künstlichen EKG, bei dem f bekannt ist (Abschnitt 6.5), und wenden es dann auf die Datensätze 100 und 103 an (Abschnitt 6.6).

6.5. Test an einem künstlichen EKG

Bei echten Aufzeichnungen ist f unbekannt, und ein quantitatives Gütemaß lässt sich nur schwer angeben; Castillo et al. bewerten ihr Verfahren deshalb an künstlichen EKG [CMG+13, Abschn. 4]. Wir gehen ebenso vor.

Gütemaß. Als Gütemaß dient die Fehlerenergie aus Definition 5.2. Da sie vom zufälligen Rauschen abhängt, erzeugen wir 10 Realisierungen $Z^{(1)}, \ldots, Z^{(10)}$, entrauschen jede und mitteln:

$$\frac{1}{10} \sum_{k=1}^{10} \|\hat{f}^{(k)} - f\|^2 \;\approx\; r(f).$$

Das Verfahren löscht mit a_J auch den Mittelwert. Damit diese gewollte Verschiebung nicht als Fehler zählt, ziehen wir von f und $\hat{f}$ vorher den Mittelwert ab (eigene Festlegung).

Anmerkung. Später nochmal anschauen: Warum hat $\hat{f}$ Mittelwert 0? Kurz: $\bar{f}$ gehört zur Frequenz 0 und liegt ganz in a_J. Exakt: aus $H(0) = \sqrt{2}$ und $|H(\omega)|^2 + |H(\omega+\pi)|^2 = 2$ folgt $H(\pi) = 0$, also $\sum_k g_k = 0$ (gilt für jedes orthogonale Wavelet, nicht nur symmetrische; db6 ist unsymmetrisch). Dann ist $\langle \mathbf{1}, \psi_{j,k} \rangle = 0$, und $\hat{f}$ besteht nur aus Details. Prüfen, ob $\sum_k g_k = 0$ in Kap. 4 steht (dann verweisen); ohne Mittelwertabzug käme $N\bar{f}^2 \approx 494$ zum Fehler dazu. Außerdem: Spalte der Tabelle als $\hat{r}(f)$ bezeichnen?

Test-EKG und Störungen. Als f dient ein mit ECGSYN [MCTS03] erzeugtes EKG, berechnet mit NeuroKit2 [MPL+21] für $f_s = 360\,\mathrm{Hz}$, eine Herzfrequenz von 70 Schlägen pro Minute und $N = 2^{16}$ Abtastwerte, also etwa 3 min. ECGSYN enthält von sich aus eine Atmungsdrift [MCTS03, S. 290, Gl. (2)]; diese haben wir abgeschaltet, damit f selbst keine Drift enthält. Wie bei Castillo et al. addieren wir eine sinusförmige Drift und Gauß'sches weißes Rauschen [CMG+13, Abschn. 4]:

$$Y = f + b + \sigma Z, \qquad b(t) = 0{,}5\,\mathrm{mV} \cdot \sin(2\pi \cdot 0{,}25\,\mathrm{Hz} \cdot t),$$

mit $\sigma = 0{,}05\,\mathrm{mV}$ (eigene Wahl, Abbildung 6.3).

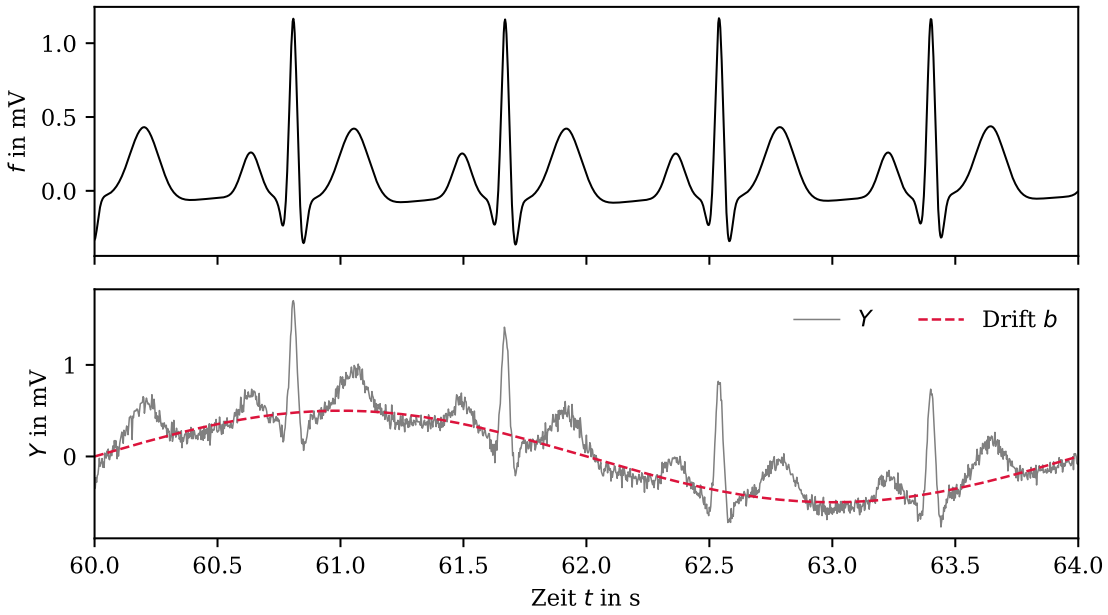


Abbildung 6.3.: Ausschnitt von 4 s aus dem Test-EKG f (oben) und der gestörten Messung Y mit der Drift b (gestrichelt, unten) mit $\sigma = 0{,}05\,\mathrm{mV}$ (Code in Anhang B.9).

Ergebnis. Tabelle 6.3 und die Abbildungen 6.4 und 6.5 zeigen:

- $J = 8$ ist deutlich besser als $J = 7$ und $J = 9$; das bestätigt (6.5): Mit $J = 7$ wird ein Teil des EKG gelöscht, mit $J = 9$ bleibt Drift stehen.

Variante	Fehlerenergie
vorher (Messung Y)	8354,4
$J = 8$, $J_S = 3$, Soft (Verfahren)	52,7
Hard statt Soft	44,3
$J_S = 2$	48,4
$J_S = 4$	96,4
nur Drift entfernt ($J_S = 0$)	170,7
$J = 7$	303,6
$J = 9$	555,7

Tabelle 6.3.: Fehlerenergie am Test-EKG, gemittelt über 10 Realisierungen von Z; zum Vergleich $\|f\|^2 \approx 3823$. Nicht genannte Parameter wie im Verfahren (Code in Anhang B.9).

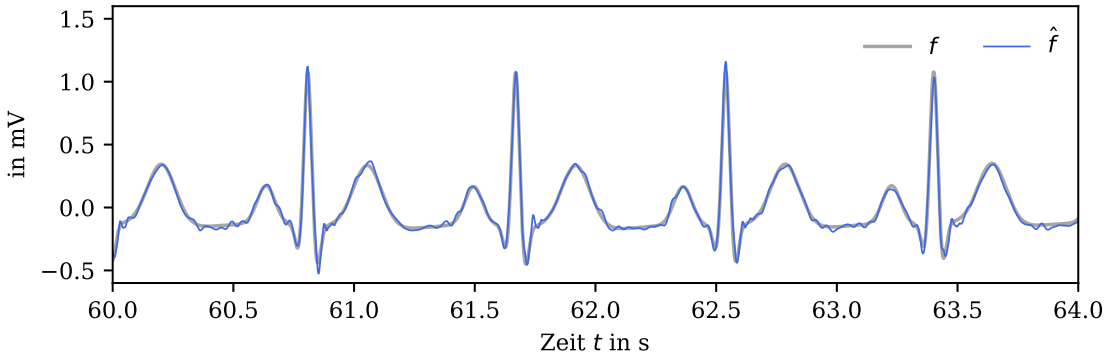


Abbildung 6.4.: Derselbe Ausschnitt von 4 s wie in Abbildung 6.3: f (grau) und $\hat{f}$ (blau), jeweils ohne Mittelwert (Code in Anhang B.9).

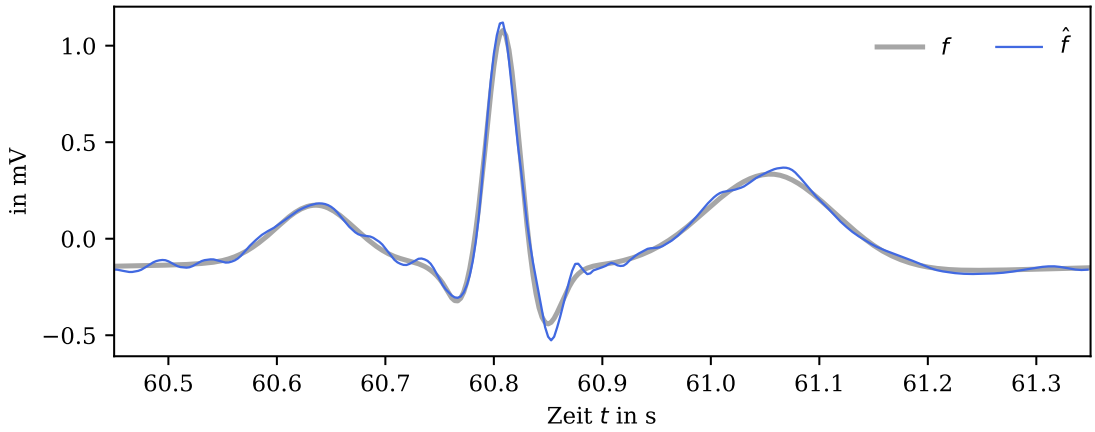


Abbildung 6.5.: Ein Herzschlag aus Abbildung 6.4 vergrößert: f (grau) und $\hat{f}$ (blau), jeweils ohne Mittelwert (Code in Anhang B.9).

- Das Thresholding von d_1 bis d_3 senkt die Fehlerenergie gegenüber dem bloßen Entfernen der Drift von $170{,}7$ auf $52{,}7$, also auf etwa ein Drittel.
- $J_S = 4$ ist deutlich schlechter als $J_S = 3$, $J_S = 2$ etwas besser. Schwellen entfernt in d_j das Rauschen, verkleinert aber auch jeden großen EKG-Koeffizienten um T; ab d_3, wo das EKG Energie hat, überwiegt beim Test-EKG dieser Verlust.
- Hard-Thresholding erreicht eine kleinere Fehlerenergie ($44{,}3$ statt $52{,}7$). Soft-Thresholding verkleinert bei gleicher Schwelle auch die großen Koeffizienten der R-Zacke und braucht für ähnliche Ergebnisse etwa die halbe Schwelle [Mal09, Kap. 11.2.2]. Wir bleiben wie Castillo et al. bei der universellen Schwelle mit Soft-Thresholding, das keine Unstetigkeiten erzeugt [CMG+13, Abschn. 3.1.6, 4].

6.6. Anwendung auf die Datensätze 100 und 103

Bei den echten Aufzeichnungen ist f unbekannt, ein Fehlermaß wie in Abschnitt 6.5 lässt sich also nicht berechnen. Wir beurteilen das Ergebnis deshalb nur an den Ausschnitten aus Abbildung 6.2.

Abbildung 6.6 zeigt jeweils oben $\hat{f}$ und darunter die Messwerte Y. Bei Datensatz 100 liegt die Grundlinie nach dem Entrauschen gleichmäßig bei null; die Anhebung zwischen 395 und 396 s ist entfernt, die Form der Schläge bleibt erhalten. Bei Datensatz 103 ist die Drift weitgehend entfernt. Nur der schnelle Abfall bei etwa 1090 s bleibt als Einbruch sichtbar: Ein so abrupter Sprung hat auch Anteile oberhalb von $F_{\max}/2^J \approx 0{,}70$ Hz, die nicht in a_8 liegen und deshalb nicht gelöscht werden.

6.7. Diskussion

Am Test-EKG sinkt das geschätzte Risiko von $8354{,}4$ auf $52{,}7$, und $J = 8$ ist deutlich besser als $J = 7$ und $J = 9$, wie es (6.5) erwarten lässt (Tabelle 6.3). An den Datensätzen 100 und 103 ist die Drift sichtbar entfernt, die Form der Schläge bleibt erhalten (Abbildung 6.6). Dazu braucht es beide Bausteine: Das Thresholding aus Kapitel 5 erreicht die Drift nicht, weil sie in der Approximation liegt; erst die Wahl von J nach den Frequenzen von Drift und Herzschlag erlaubt, a_J gezielt zu entfernen. Beides geschieht in einer einzigen Zerlegung [CMG+13, Abschn. 3].

Die Ergebnisse haben folgende Grenzen.

- Die Aussage über den Fehler gilt nur für das Test-EKG. Es enthält nur eine Sinusdrift und weißes Rauschen, kein Netzbrummen und kein Muskelrauschen. Die echten Aufzeichnungen beurteilen wir nur nach Augenschein. Ob die Änderungen am EKG klinisch unbedenklich sind, kann nur ärztlich beurteilt werden; ohne diese Erfahrung kann ein Verfahren klinisch unzulässige Verzerrungen einführen [SL05, Kap. 1.4.1].
- Das Nullsetzen von a_8 entfernt alles unter $0{,}70$ Hz, auch Anteile des EKG, dessen Spektrum bis $0{,}005$ Hz reicht [Gac12, Kap. 2.4.3.2]. Bei langsamem Herzschlag unter 42 Schlägen pro Minute läge die Herzfrequenz selbst unter $0{,}70$ Hz; Sörnmo und Laguna nennen für Bradykardie etwa 40 Schläge pro Minute [SL05, Kap. 7.1]. Dann wäre $J = 9$ zu wählen, mit mehr verbleibender Drift.

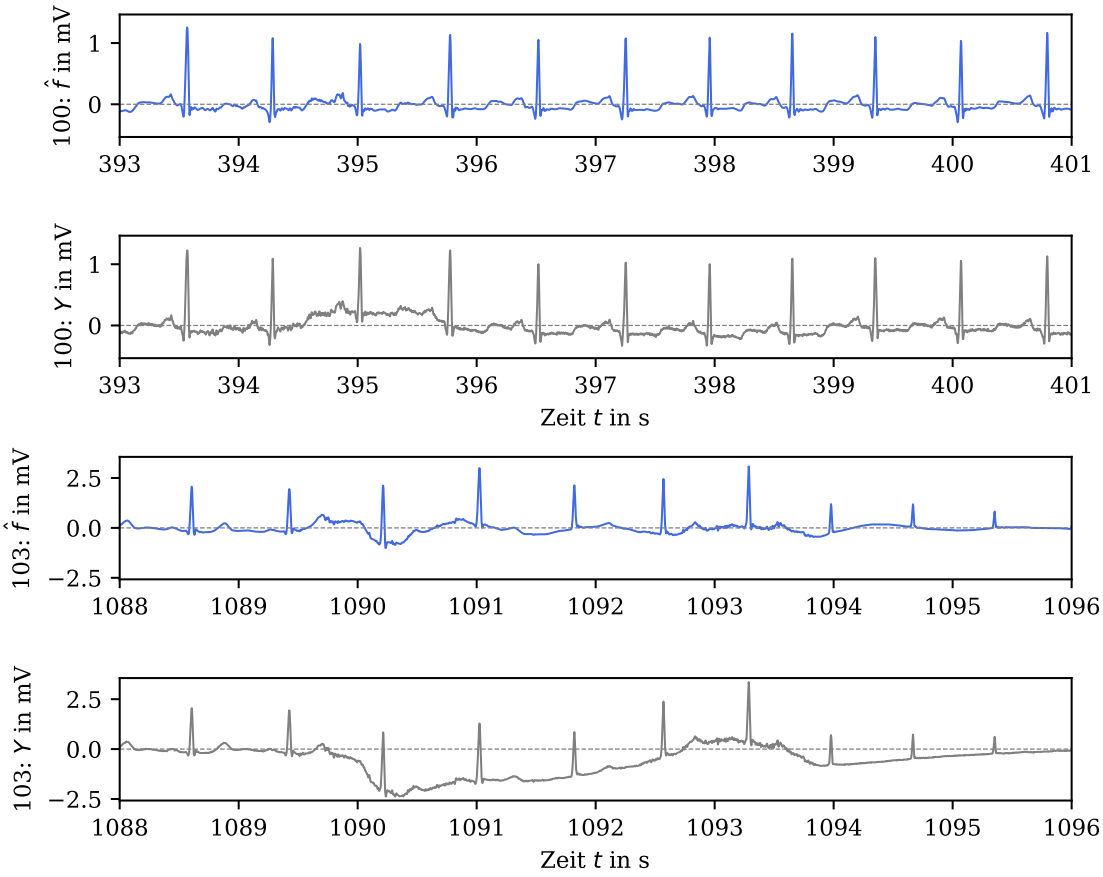


Abbildung 6.6.: Die Ausschnitte aus Abbildung 6.2 nach dem Entrauschen ($\hat{f}$, blau) und darunter vorher (Y, grau), je Datensatz im selben Maßstab; gestrichelt die Nulllinie (Code in Anhang B.9).

- Elektrodenbewegung liegt bei 1 bis $10\,\mathrm{Hz}$ und damit in den unveränderten Stufen; das Verfahren kann sie nicht entfernen. Ob der Sprung bei $1090\,\mathrm{s}$ in Datensatz 103 von einer Elektrodenbewegung stammt, lässt sich aus den Daten nicht sagen; das Directory markiert den Abschnitt nur als verrauscht. Er bleibt als Einbruch sichtbar.
- Die Schwelle beruht auf einem einzigen $\hat{\sigma}$ aus d_1 und setzt weißes Rauschen voraus. Für Rauschen, das nicht weiß ist, schätzt man σ auf jeder Stufe einzeln [Ale16, Kap. 15.2.2], [CMG+13, Abschn. 3.1.5]. Muskelrauschen, das auf d_2 und d_3 stärker ist als auf d_1, wird mit der globalen Schwelle daher womöglich nur unvollständig entfernt.
- Am Test-EKG sind $J_S = 2$ und Hard-Thresholding etwas besser als unser Verfahren. Soft-Thresholding verkleinert mit T auch die großen Koeffizienten des EKG; das kostet ab d_3 mehr, als es an Rauschen entfernt. Soft-Thresholding erreicht ähnliche Ergebnisse wie Hard-Thresholding etwa mit der halben Schwelle [Mal09, Kap. 11.2.2]; Castillo et al. schlagen außerdem eine Schwelle vor, die auf den feinen Stufen kleiner ist [CMG+13, Gl. (13)]. Unser $J_S = 3$ folgt aus f_{PT} (Abschnitt 6.4) und ist nicht am Test angepasst.
- Die Datenbank wurde für die Bewertung von Arrhythmie-Detektoren angelegt, nicht für das Entrauschen, und wir verwenden nur zwei Aufzeichnungen [SL05, Kap. 1.4.1]. Die Parameter sind allerdings aus der Literatur übernommen und nicht an diesen Daten angepasst.

Simulierte Signale, bei denen das wahre Signal bekannt ist, erlauben eine Genauigkeitsaussage wie in Abschnitt 6.5; den Hauptteil der Bewertung müssen aber gemessene Aufzeichnungen tragen [SL05, Kap. 1.4.2].

7. Fazit und Ausblick

Anmerkung. Zusammenfassung des Argumentationsbogens und Ausblick auf translationsinvariantes Thresholding, adaptive Schwellen und konkurrierende Zerlegungen.

Belegstellen.

- Mallat, „Translation-Invariant Thresholding", S. 632–633 [bestätigt]; S. 639 [bestätigt]
- Mallat, „Multiscale Sure Thresholds", S. 637 [bestätigt]
- LMR, Kap. 2.4.5 „Biorthogonale Wavelets", S. 184–190 [bestätigt]; Kap. 2.4.7.3 „Coiflets", S. 209 [bestätigt] — naheliegende Erweiterungen der Basiswahl
- LMR, Vorwort zur zweiten Auflage, S. 1 [bestätigt] — Multiwavelets und das Lifting-Prinzip als weiterführende Richtungen
- Rebstadt, Kap. 6.2, S. 76–77 [bestätigt]
- Chatterjee, Kap. 5, S. 585–587 [bestätigt]

A. Ergänzende Rechnungen

A.1. Fourier-Transformierte des Testsignals

Wir leiten (3.5) aus Beispiel 3.8 her. Wegen $f \in L^1(\mathbb{R})$ ist $\hat{f}$ punktweise durch das Integral gegeben; in der Konvention aus Bemerkung 2.1 ist

$$\hat{f}(\omega) = \frac{1}{\sqrt{2\pi}} \left(\int_0^3 \big(1 - \cos(2\pi t)\big) e^{-i\omega t}\, dt + \frac{1}{2} \int_4^5 \big(1 - \cos(10\pi t)\big) e^{-i\omega t}\, dt \right).$$

Sei zunächst $\omega \notin \{0, \pm 2\pi, \pm 10\pi\}$. Benutzt werden nur $\cos x = \frac{1}{2}\big(e^{ix} + e^{-ix}\big)$ und

$$\int_\alpha^\beta e^{ct}\, dt = \frac{1}{c}\big(e^{c\beta} - e^{c\alpha}\big), \qquad c \in \mathbb{C} \setminus \{0\}. \tag{A.1}$$

Die langsame Komponente. Mit $q_1 := 1 - e^{-3i\omega}$ zerlegen wir

$$\int_0^3 \big(1 - \cos(2\pi t)\big) e^{-i\omega t}\, dt = \underbrace{\int_0^3 e^{-i\omega t}\, dt}_{=:A_1} - \underbrace{\int_0^3 \cos(2\pi t)\, e^{-i\omega t}\, dt}_{=:B_1}.$$

Nach (A.1) mit $c = -i\omega$ ist

$$A_1 = \frac{e^{-3i\omega} - 1}{-i\omega} = \frac{q_1}{i\omega}.$$

Für B_1 schreiben wir $\cos(2\pi t) e^{-i\omega t} = \frac{1}{2}\big(e^{i(2\pi - \omega)t} + e^{-i(2\pi + \omega)t}\big)$ und erhalten nach (A.1)

$$B_1 = \frac{e^{3i(2\pi - \omega)} - 1}{2i(2\pi - \omega)} + \frac{e^{-3i(2\pi + \omega)} - 1}{-2i(2\pi + \omega)}.$$

Da auf $[0, 3]$ genau drei volle Perioden liegen, ist $e^{\pm 6\pi i} = 1$ und damit $e^{3i(2\pi - \omega)} = e^{-3i(2\pi + \omega)} = e^{-3i\omega}$. Beide Zähler werden zu $-q_1$, und

$$B_1 = \frac{q_1}{2i} \left(\frac{1}{2\pi + \omega} - \frac{1}{2\pi - \omega} \right) = \frac{q_1}{2i} \cdot \frac{2\omega}{\omega^2 - 4\pi^2} = \frac{q_1\, \omega}{i\,(\omega^2 - 4\pi^2)}.$$

Mit $1/i = -i$ folgt

$$A_1 - B_1 = \frac{q_1}{i} \left(\frac{1}{\omega} - \frac{\omega}{\omega^2 - 4\pi^2} \right) = \frac{q_1}{i} \cdot \frac{-4\pi^2}{\omega(\omega^2 - 4\pi^2)} = \frac{i\, 4\pi^2\, q_1}{\omega\,(\omega^2 - 4\pi^2)}.$$

Die schnelle Komponente. Mit $q_2 := e^{-4i\omega} - e^{-5i\omega}$ verläuft die Rechnung wörtlich gleich, nun mit 10π statt 2π und den Grenzen 4 und 5. An die Stelle von $e^{\pm 6\pi i} = 1$ treten $e^{\pm 40\pi i} = e^{\pm 50\pi i} = 1$, und man erhält

$$A_2 = \int_4^5 e^{-i\omega t}\,dt = \frac{q_2}{i\omega}, \qquad B_2 = \int_4^5 \cos(10\pi t)\, e^{-i\omega t}\,dt = \frac{q_2\,\omega}{i\,(\omega^2 - 100\pi^2)},$$

also mit dem Amplitudenfaktor $\frac{1}{2}$

$$\frac{1}{2}(A_2 - B_2) = \frac{q_2}{2i}\cdot\frac{-100\pi^2}{\omega(\omega^2 - 100\pi^2)} = \frac{i\,50\pi^2\,q_2}{\omega\,(\omega^2 - 100\pi^2)}.$$

Addition beider Anteile und der Vorfaktor $(2\pi)^{-1/2}$ ergeben (3.5).

Die Ausnahmestellen. Da $\hat f$ als Fourier-Transformierte einer L^1-Funktion stetig ist [Ser17, Satz 12.1], gilt (3.5) an den Stellen $\omega \in \{0, \pm 2\pi, \pm 10\pi\}$ im Sinne des Grenzwerts; dort verschwinden jeweils auch die Zähler, etwa $q_1 = 1 - e^{-6\pi i} = 0$ für $\omega = 2\pi$. Die Werte lassen sich einfacher direkt aus dem Integral bestimmen. Für $\omega = 0$ ist $\hat f(0) = (2\pi)^{-1/2}\int_{\mathbb R} f = (2\pi)^{-1/2}\big(3 + \frac{1}{2}\big)$. Für $\omega = 2\pi$ zerfällt der Integrand in Exponentialterme $e^{i\nu t}$; alle mit $\nu \neq 0$ integrieren sich über $[0,3]$ bzw. $[4,5]$ zu null, da ν jeweils ein ganzzahliges Vielfaches von 2π ist. Übrig bleibt allein der konstante Term $-\frac{1}{2}e^{2\pi i t}e^{-2\pi i t} = -\frac{1}{2}$ im ersten Integral, also $\hat f(2\pi) = -\frac{3}{2}(2\pi)^{-1/2}$. Ebenso ist $\hat f(10\pi) = \frac{1}{2}\cdot\big(-\frac{1}{2}\big)(2\pi)^{-1/2}$, und wegen $\hat f(-\omega) = \overline{\hat f(\omega)}$ folgt

$$|\hat f(0)| = \frac{7}{2\sqrt{2\pi}} \approx 1{,}396, \qquad |\hat f(\pm 2\pi)| = \frac{3}{2\sqrt{2\pi}} \approx 0{,}598, \qquad |\hat f(\pm 10\pi)| = \frac{1}{4\sqrt{2\pi}} \approx 0{,}0997.$$

Die in Beispiel 3.8 angegebenen Lagen der Maxima, $\omega \approx 1{,}90\pi$ mit $|\hat f| \approx 0{,}629$ und $\omega \approx 9{,}73\pi$ mit $|\hat f| \approx 0{,}102$, wurden numerisch aus (3.5) bestimmt; zur Kontrolle wurde (3.5) an mehreren Stellen mit numerischer Quadratur des definierenden Integrals verglichen (Anhang B).

A.2. Stammfunktion des Testsignals

Für $0 \le t \le 3$ ist $F(t) = \int_0^t \big(1 - \cos(2\pi s)\big)\,ds = t - \frac{\sin(2\pi t)}{2\pi}$, insbesondere $F(3) = 3$ wegen $\sin(6\pi) = 0$. Auf $[3,4]$ verschwindet f, also $F \equiv 3$. Für $4 \le t \le 5$ ist

$$F(t) = 3 + \frac{1}{2}\int_4^t \big(1 - \cos(10\pi s)\big)\,ds = 3 + \frac{t-4}{2} - \frac{\sin(10\pi t) - \sin(40\pi)}{20\pi} = 3 + \frac{t-4}{2} - \frac{\sin(10\pi t)}{20\pi},$$

und wegen $\sin(50\pi) = 0$ ist $F(5) = \frac{7}{2} = \int_{\mathbb R} f$, in Übereinstimmung mit $\hat f(0) = (2\pi)^{-1/2}\cdot\frac{7}{2}$. Da f stetig ist – an allen vier Trägerrändern hat $1 - \cos x = 2\sin^2(x/2)$ eine doppelte Nullstelle –, ist F stetig differenzierbar mit $F' = f$.

B. Python-Code

Alle Abbildungen und numerischen Werte dieser Arbeit wurden mit Python (NumPy, PyWavelets [LGW+19], Matplotlib) erzeugt.

Anmerkung. Versionen angeben (`python -version`, `pip show numpy matplotlib pywavelets`).

Die Skripte zu Kapitel 5 verwenden durchgehend den Filter (4.6), die periodisierte Transformation (Abschnitt 5.1) mit $J = 5$ Stufen und $N = 2048$ Abtastwerte. Der feste Startwert 93 des Zufallsgenerators sorgt dafür, dass alle Abbildungen dieses Kapitels dieselbe Realisierung des Rauschens zeigen.

B.1. Beispiel zur kontinuierlichen Wavelet-Transformation

Der folgende Code erzeugt die Abbildungen 3.4, 3.5 und 3.6. Die Wavelet-Transformierte wird nicht durch numerische Quadratur, sondern exakt nach (3.6) aus der Stammfunktion F berechnet.

Listing B.1: Testsignal aus Beispiel 3.8

```
# Beispiel aus Abschnitt 3.1.2: Signal, Fourier-Transformierte und Haar-CWT.
import numpy as np
import matplotlib.pyplot as plt

pi = np.pi


def f(t):
    y = np.zeros_like(t)
    m = (t >= 0) & (t <= 3)
    y[m] += 1 - np.cos(2 * pi * t[m])
    m = (t >= 4) & (t <= 5)
    y[m] += 0.5 * (1 - np.cos(10 * pi * t[m]))
    return y


def F(t):
    y = np.zeros_like(t)
    m = (t > 0) & (t < 3)
    y[m] += t[m] - np.sin(2 * pi * t[m]) / (2 * pi)
    y[t >= 3] += 3
    m = (t > 4) & (t < 5)
    y[m] += 0.5 * ((t[m] - 4) - np.sin(10 * pi * t[m]) / (10 * pi))
    y[t >= 5] += 0.5
    return y


```

```
28 def fourier(w):
29     w = w.astype(complex)
30     for p in [0, 2 * pi, -2 * pi, 10 * pi, -10 * pi]:
31         w = np.where(np.abs(w - p) < 1e-7, p + 1e-7, w)
32     a = 4 * pi**2 * (1 - np.exp(-3j * w)) / (w**2 - 4 * pi**2)
33     b = 50 * pi**2 * (np.exp(-4j * w) - np.exp(-5j * w)) / (w**2 - 100 * pi
           **2)
34     return 1j * (a + b) / (np.sqrt(2 * pi) * w)
35
36
37 def cwt_haar(a, b):
38     return (2 * F(b + a / 2) - F(b) - F(b + a)) / np.sqrt(a)
39
40
41 plt.rcParams.update({"font.size": 9, "font.family": "serif", "savefig.dpi":
       300})
42
43 t = np.linspace(-0.6, 5.6, 40000)
44 fig, ax = plt.subplots(figsize=(7.0, 2.8))
45 ax.plot(t, f(t), color="royalblue", lw=0.9)
46 for x in [0, 3, 4, 5]:
47     ax.axvline(x, color="gray", lw=0.6, alpha=0.3)
48 ax.set_xlim(-0.6, 5.6)
49 ax.set_ylim(-0.25, 2.45)
50 ax.set_xticks(range(6))
51 ax.set_xlabel("$t$")
52 ax.set_ylabel("$f(t)$")
53 ax.annotate("$f_1$", (1.5, 2.18), ha="center")
54 ax.annotate("$f_2$", (4.5, 1.22), ha="center")
55 ax.spines[["top", "right"]].set_visible(False)
56
57 w = np.linspace(-50, 50, 40000)
58 fig, ax = plt.subplots(figsize=(7.0, 2.8))
59 ax.plot(w, np.abs(fourier(w)), color="royalblue", lw=0.9)
60 for p in [-10 * pi, -2 * pi, 0, 2 * pi, 10 * pi]:
61     ax.axvline(p, color="gray", ls="--", lw=0.6)
62 ax.set_xlim(-50, 50)
63 ax.set_ylim(0, 1.55)
64 ax.set_xticks([-10 * pi, -2 * pi, 0, 2 * pi, 10 * pi])
65 ax.set_xticklabels([r"$-10\pi$", r"$-2\pi$", "$0$", r"$2\pi$", r"$10\pi$"])
66 ax.set_xlabel(r"$\omega$")
67 ax.set_ylabel(r"$|\hat f(\omega)|$")
68 ax.spines[["top", "right"]].set_visible(False)
69
70 a = np.logspace(np.log10(0.02), np.log10(3.0), 900)[:, None]
71 b = np.linspace(-0.6, 5.6, 1400)[None, :]
72 fig, ax = plt.subplots(figsize=(9.0, 4.6))
73 pc = ax.pcolormesh(b.ravel(), a.ravel(), np.abs(cwt_haar(a, b)), shading="
       gouraud", cmap="magma")
74 ax.set_yscale("log")
75 ax.set_xticks(range(6))
76 ax.set_xlabel("$b$")
77 ax.set_ylabel("$a$")
78 fig.colorbar(pc, ax=ax).set_label(r"$|W_\psi f(a,b)|$")
79
```

```
80 plt.show()
```

B.2. Daubechies-Wavelet

Der folgende Code erzeugt Abbildung 4.3. PyWavelets berechnet φ_2 und ψ_2 durch Iteration der Skalierungsgleichung (4.1) und legt ψ_2 auf $[0, 3]$. Die Verschiebung um 1 ergibt den Träger $[-1, 2]$, der nach Satz 4.16 zur Wahl (4.7) gehört.

Listing B.2: Skalierungsfunktion φ_2 und Wavelet ψ_2 aus Satz 4.16

```
# Daubechies-Skalierungsfunktion phi_2 und Wavelet psi_2 aus Kapitel 4.
import pywt
import matplotlib.pyplot as plt

phi, psi, t = pywt.Wavelet("db2").wavefun(level=10)

plt.rcParams.update({"font.size": 11, "axes.titlesize": 11, "mathtext.
    fontset": "cm"})
fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.6))

ax[0].plot(t, phi, color="royalblue", lw=0.9)
ax[0].set_title(r"(a) $\varphi_2$")
ax[1].plot(t - 1, psi, color="royalblue", lw=0.9)
ax[1].set_title(r"(b) $\psi_2$")

for a in ax:
    a.axhline(0, color="black", lw=0.5)
    a.set_xlabel("$t$")
    a.spines[["top", "right"]].set_visible(False)

plt.show()
```

B.3. Daubechies-Wavelet mit zwölf Koeffizienten

Der folgende Code erzeugt Abbildung 4.4. Wie in Anhang B.2 legt PyWavelets ψ_6 auf $[0, 11]$; die Verschiebung um 5 ergibt den Träger $[-5, 6]$ aus Satz 4.16.

Listing B.3: Skalierungsfunktion φ_6 und Wavelet ψ_6 aus Beispiel 4.17

```
# Abbildung 4.x: Skalierungsfunktion und Wavelet des Daubechies-Wavelets mit
    p = 6
import matplotlib.pyplot as plt
import pywt

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
p = 6
phi, psi, x = pywt.Wavelet(f"db{p}").wavefun(level=10)
fig, ax = plt.subplots(1, 2, figsize=(6.3, 2.2), sharey=True)
ax[0].plot(x, phi, color="royalblue", lw=1.0)
ax[1].plot(x + 1 - p, psi, color="royalblue", lw=1.0)
ax[0].set_title(r"(a) $\varphi_6$")
```

```
ax[1].set_title(r"(b) $\psi_6$")
ax[0].set_xlim(0, 2 * p - 1)
ax[1].set_xlim(1 - p, p)
for achse in ax:
    achse.axhline(0, color="gray", lw=0.5, ls="--")
    achse.set_xlabel("$t$")
fig.tight_layout()
fig.savefig("../abbildungen/abb4_db6.pdf")
plt.show()
```

B.4. Verrauschter Sinus

Der folgende Code erzeugt Abbildung 5.2 und die Zahlen aus Beispiel 5.5: die Fehlerenergie $\|Y - u\|^2$, ihren Erwartungswert $N\sigma^2$ sowie empirischen Mittelwert und empirische Varianz von $\tilde{Z} = AZ$. Als Kontrolle von Lemma 5.3 gibt das Skript zusätzlich $\|AZ\| - \|Z\|$ aus; der Wert verschwindet im Rahmen der Rundungsgenauigkeit.

Listing B.4: Verrauschter Sinus aus Beispiel 5.5

```
# Beispiel aus Kapitel 5: verrauschter Sinus, Fehlerenergie und Statistik
    der Rauschkoeffizienten (Abb. 5.2).
import numpy as np
import pywt
import matplotlib.pyplot as plt

N = 2048
J = 5
sigma = 0.3

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)

Z = np.random.default_rng(93).standard_normal(N)
Y = u + sigma * Z

Z_tilde = np.concatenate(pywt.wavedec(Z, "db2", mode="periodization", level=
    J))

print(f"||Y - u||^2 = {np.sum((Y - u) ** 2):.1f}")
print(f"N sigma^2 = {N * sigma**2:.1f}")
print(f"Mittelwert Z_tilde = {np.mean(Z_tilde):.2f}")
print(f"Varianz Z_tilde = {np.var(Z_tilde):.2f}")
print(f"||AZ|| - ||Z|| = {np.linalg.norm(Z_tilde) - np.linalg.norm(Z):.1e}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(2, 1, figsize=(7.0, 3.6), sharex=True)

ax[0].plot(t, u, color="royalblue", lw=0.9)
ax[0].set_ylabel("$u$")
ax[1].plot(t, Y, color="gray", lw=0.5)
ax[1].set_ylabel("$Y$")
ax[1].set_xlabel("$t$")
ax[1].set_xlim(0, 8)
```

```
33
34 for a in ax:
35     a.set_ylim(-2.2, 2.2)
36     a.spines[["top", "right"]].set_visible(False)
37
38 plt.show()
```

B.5. Sinus mit Spitzen

Der folgende Code erzeugt Abbildung 5.5 und die Zahlen aus Beispiel 5.11: für jede Stufe die Anzahl der Koeffizienten, den größten Betrag beim Sinus und die Anzahl der Koeffizienten von u und f mit Betrag mindestens σ, außerdem M, die Summe $\sum_{|\theta_m|<\sigma} \theta_m^2$ der gelöschten Koeffizienten und das Risiko r_{id} der idealen Auswahl (5.4).

Listing B.5: Sinus mit Spitzen aus Beispiel 5.11

```
1  # Beispiel aus Kapitel 5: Sinus mit drei Spitzen, Koeffizienten pro Stufe
       und Risiko der idealen Auswahl (Abb. 5.5).
2  import numpy as np
3  import pywt
4  import matplotlib.pyplot as plt
5
6  N = 2048
7  J = 5
8  sigma = 0.3
9  zentren = [1.3, 3.7, 6.2]
10
11 t = 8 * np.arange(N) / N
12 u = np.sin(2 * np.pi * t)
13
14 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
15 f = u + s
16
17 Z = np.random.default_rng(93).standard_normal(N)
18 Y = f + sigma * Z
19
20 cu = pywt.wavedec(u, "db2", mode="periodization", level=J)
21 cf = pywt.wavedec(f, "db2", mode="periodization", level=J)
22
23 namen = ["a5", "d5", "d4", "d3", "d2", "d1"]
24 print("Stufe  Anzahl  max|u|   >=sigma(u)  >=sigma(f)")
25 for name, a, b in zip(namen, cu, cf):
26     print(f"{name:5}  {len(a):6}  {np.max(np.abs(a)):.2g}  {np.sum(np.abs(a)
           >= sigma):10}  {np.sum(np.abs(b) >= sigma):10}")
27
28 for name, c in [("u", cu), ("f", cf)]:
29     theta = np.concatenate(c)
30     M = np.sum(np.abs(theta) >= sigma)
31     geloescht = np.sum(theta[np.abs(theta) < sigma] ** 2)
32     r = np.sum(np.minimum(theta**2, sigma**2))
33     print(f"{name}: M = {M}, M sigma^2 = {M * sigma**2:.1f}, geloescht = {
           geloescht:.1f}, r_id = {r:.1f}")
34
```

```
print(f"N sigma^2 = {N * sigma**2:.1f}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(2, 1, figsize=(7.0, 3.6), sharex=True)

ax[0].plot(t, f, color="royalblue", lw=0.9)
ax[0].set_ylabel("$f$")
ax[1].plot(t, Y, color="gray", lw=0.5)
ax[1].set_ylabel("$Y$")
ax[1].set_xlabel("$t$")
ax[1].set_xlim(0, 8)

for a in ax:
    a.set_ylim(-2.2, 4.0)
    a.spines[["top", "right"]].set_visible(False)

plt.show()
```

B.6. Detailkoeffizienten des Testsignals

Der folgende Code erzeugt Abbildung 5.6. Der k-te Koeffizient der Stufe j wird in der Mitte des Zeitabschnitts $\left[k\,2^j/256,\ (k+1)\,2^j/256\right)$ eingezeichnet, für den er steht. Beträge über $2{,}5$ werden abgeschnitten.

Listing B.6: Detailkoeffizienten des Testsignals aus Beispiel 5.11

```
# Beispiel aus Kapitel 5: Detailkoeffizienten d_5 bis d_1 des Testsignals f
    (Abb. 5.6).
import numpy as np
import pywt
import matplotlib.pyplot as plt

N = 2048
J = 5
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)

s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
f = u + s

c = pywt.wavedec(f, "db2", mode="periodization", level=J)

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(J, 1, figsize=(7.0, 6.0), sharex=True)

for i in range(J):
    j = J - i
    d = c[i + 1]
    pos = (np.arange(len(d)) + 0.5) * 2**j / 256
    ax[i].vlines(pos, 0, np.clip(d, -2.5, 2.5), color="royalblue", lw=1.1)
    ax[i].axhline(0, color="black", lw=0.4)
```

```
    ax[i].set_ylim(-2.5, 2.5)
    ax[i].set_yticks([-2, 0, 2])
    ax[i].set_ylabel(f"$d_{j}$", rotation=0, labelpad=12, va="center")
    ax[i].spines[["top", "right"]].set_visible(False)

ax[-1].set_xlim(0, 8)
ax[-1].set_xlabel("$t$")
fig.tight_layout(h_pad=0.3)

plt.show()
```

B.7. Detailkoeffizienten der Messwerte

Der folgende Code erzeugt Abbildung 5.7 und die Zahlen aus dem ersten Absatz von Beispiel 5.13: den Schätzwert $\hat{\sigma}$ nach (5.7), die Schwelle T, den größten Rauschkoeffizienten $\max_m |0{,}3\,\tilde{Z}_m|$ und die Anzahl der Koeffizienten, die Hard-Thresholding behält.

Listing B.7: Detailkoeffizienten der Messwerte aus Beispiel 5.13

```
# Beispiel aus Kapitel 5: Detailkoeffizienten d_5 bis d_1 der Messwerte Y
    mit Schwelle T (Abb. 5.7).
import numpy as np
import pywt
import matplotlib.pyplot as plt

N = 2048
J = 5
sigma = 0.3
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)

s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
f = u + s

Z = np.random.default_rng(93).standard_normal(N)
Y = f + sigma * Z

c = pywt.wavedec(Y, "db2", mode="periodization", level=J)

sigma_dach = np.median(np.abs(c[-1])) / 0.6745
T = sigma_dach * np.sqrt(2 * np.log(N))
AZ = np.concatenate(pywt.wavedec(Z, "db2", mode="periodization", level=J))

print(f"sigma_dach = {sigma_dach:.3f}")
print(f"T = {T:.2f}")
print(f"max|AZ| = {np.max(np.abs(AZ)):.2f}, max|sigma AZ| = {sigma * np.max(
    np.abs(AZ)):.2f}")
print(f"behalten (hart): {np.sum(np.abs(np.concatenate(c)) > T)} von {N}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(J, 1, figsize=(7.0, 6.0), sharex=True)
```

```
33
34 for i in range(J):
35     j = J - i
36     d = c[i + 1]
37     pos = (np.arange(len(d)) + 0.5) * 2**j / 256
38     ax[i].vlines(pos, 0, np.clip(d, -2.5, 2.5), color="royalblue", lw=1.0)
39     ax[i].axhline(0, color="black", lw=0.4)
40     ax[i].axhline(T, color="gray", ls="--", lw=0.8)
41     ax[i].axhline(-T, color="gray", ls="--", lw=0.8)
42     ax[i].set_ylim(-2.5, 2.5)
43     ax[i].set_yticks([-2, 0, 2])
44     ax[i].set_ylabel(f"$d_{j}$", rotation=0, labelpad=12, va="center")
45     ax[i].spines[["top", "right"]].set_visible(False)
46
47 ax[-1].set_xlim(0, 8)
48 ax[-1].set_xlabel("$t$")
49 fig.tight_layout(h_pad=0.3)
50
51 plt.show()
```

B.8. Entrauschtes Testsignal

Der folgende Code erzeugt Abbildung 5.8 und die Fehlerenergien aus Beispiel 5.13. Wie in Algorithmus 2 werden alle Koeffizienten mit der Schwelle T bearbeitet, einschließlich der Approximation a_5.

Listing B.8: Entrauschen des Testsignals aus Beispiel 5.13

```
1  # Beispiel aus Kapitel 5: Entrauschen des Testsignals mit Hard- und Soft-
       Thresholding (Abb. 5.8).
2  import numpy as np
3  import pywt
4  import matplotlib.pyplot as plt
5
6  N = 2048
7  J = 5
8  sigma = 0.3
9  zentren = [1.3, 3.7, 6.2]
10
11 t = 8 * np.arange(N) / N
12 u = np.sin(2 * np.pi * t)
13
14 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
15 f = u + s
16
17 Z = np.random.default_rng(93).standard_normal(N)
18 Y = f + sigma * Z
19
20 c = pywt.wavedec(Y, "db2", mode="periodization", level=J)
21 sigma_dach = np.median(np.abs(c[-1])) / 0.6745
22 T = sigma_dach * np.sqrt(2 * np.log(N))
23
```

```
hart = pywt.waverec([pywt.threshold(d, T, "hard") for d in c], "db2", mode="
    periodization")
weich = pywt.waverec([pywt.threshold(d, T, "soft") for d in c], "db2", mode=
    "periodization")

print(f"||Y - f||^2 = {np.sum((Y - f) ** 2):.1f}")
print(f"hart:  ||f_hart - f||^2 = {np.sum((hart - f) ** 2):.1f}")
print(f"weich: ||f_weich - f||^2 = {np.sum((weich - f) ** 2):.1f}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.8), sharey=True, gridspec_kw={"
    width_ratios": [2.2, 1]})

ax[0].plot(t, hart, color="royalblue", lw=0.9, label="hart")
ax[0].plot(t, weich, color="red", lw=0.7, label="weich")
ax[0].set_xlim(0, 8)
ax[0].set_ylim(-2.2, 4.0)
ax[0].set_xlabel("$t$")

aus = (t > 3.45) & (t < 3.95)
ax[1].plot(t[aus], f[aus], color="black", ls=":", lw=0.9, label="$f$")
ax[1].plot(t[aus], hart[aus], color="royalblue", lw=0.9, label="hart")
ax[1].plot(t[aus], weich[aus], color="red", lw=0.7, label="weich")
ax[1].set_xlabel("$t$ (Ausschnitt)")
ax[1].legend(frameon=False, loc="upper right")

for a in ax:
    a.spines[["top", "right"]].set_visible(False)

fig.tight_layout()

plt.show()
```

B.9. Anwendung auf EKG-Signale

Die Skripte zu Kapitel 6 lesen die Datensätze 100 und 103 der MIT-BIH Arrhythmia Database mit dem Paket `wfdb` aus dem Ordner `daten/mitdb`. `kap6_verfahren.py` enthält das Verfahren aus Abschnitt 6.4 und die Kennzahlen aus Abschnitt ??; `kap6_auswertung.py` erzeugt die Tabellen ?? und ??.

Listing B.9: Verfahren und Kennzahlen

```
# Gemeinsame Funktionen für Kapitel 6: Entrauschen nach Castillo et al.
import numpy as np
import pywt

fs = 360
N = 2 ** 19
wavelet = "db6"
J = 8
JS = 3


```

```
def entrauschen(y, modus="soft", a_null=True, J=J, JS=JS):
    c = pywt.wavedec(y, wavelet, mode="periodization", level=J)
    sigma = np.median(np.abs(c[-1])) / 0.6745
    T = sigma * np.sqrt(2 * np.log(len(y)))
    neu = [np.zeros_like(c[0]) if a_null else c[0]]
    for i, d in enumerate(c[1:]):
        if J - i <= JS:
            neu.append(pywt.threshold(d, T, modus))
        else:
            neu.append(d)
    return pywt.waverec(neu, wavelet, mode="periodization")
```

Listing B.10: Abbildung 6.1

```
# Abbildung 6.1: schematischer Herzschlag mit P-, Q-, R-, S- und T-Welle
import numpy as np
import matplotlib.pyplot as plt

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
t = np.linspace(0, 750, 2000)
wellen = {"P": (0.15, 130, 22), "Q": (-0.12, 275, 8), "R": (1.2, 300, 9),
          "S": (-0.25, 322, 9), "T": (0.3, 600, 45)}
schlag = sum(a * np.exp(-((t - m) / s) ** 2 / 2) for a, m, s in wellen.
    values())
fig, ax = plt.subplots(figsize=(6.3, 2.6))
ax.axhline(0, color="gray", lw=0.6, ls="--")
ax.plot(t, schlag, color="royalblue", lw=1.2)
for name, (a, m, s) in wellen.items():
    i = np.argmin(np.abs(t - m))
    ax.annotate(name, (t[i], schlag[i]), textcoords="offset points",
                xytext=(0, 6 if schlag[i] > 0 else -12), ha="center")
ax.set_xlabel("Zeit $t$ in ms")
ax.set_ylabel("Spannung in mV")
ax.set_xlim(t[0], t[-1])
ax.set_ylim(-0.4, 1.45)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_1_muster.pdf")
plt.show()
```

Listing B.11: Abbildung 6.2

```
# Abbildung 6.2: je ein Ausschnitt von 8 s aus den Datensätzen 100 und 103 (
    MLII)
import numpy as np
import matplotlib.pyplot as plt
import wfdb
from kap6_verfahren import fs, N

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
ausschnitte = {"100": 393, "103": 1088}
dauer = 8
verrauscht = (1089.8, 1098.4)
fig, ax = plt.subplots(2, 1, figsize=(6.3, 3.6))
for achse, (name, von) in zip(ax, ausschnitte.items()):
    x = wfdb.rdrecord("../daten/mitdb/" + name).p_signal[:N, 0]
```

```
    y = x - np.mean(x)
    t = np.arange(N) / fs
    m = (t >= von) & (t <= von + dauer)
    if name == "103":
        achse.axvspan(verrauscht[0], von + dauer, color="gray", alpha=0.15,
            lw=0)
    achse.plot(t[m], y[m], color="royalblue", lw=0.8)
    achse.set_xlim(von, von + dauer)
    achse.set_ylabel(f"Datensatz {name}\nin mV")
ax[1].set_xlabel("Zeit $t$ in s")
fig.tight_layout()
fig.savefig("../abbildungen/abb6_2_datensaetze.pdf")
plt.show()
```

Listing B.12: Abbildung ??

```
# Abbildung 6.7: Koeffizienten a8 und d8 bis d1 der 8-s-Ausschnitte aus den
    Datensätzen 100 und 103 (MLII)
import numpy as np
import matplotlib.pyplot as plt
import pywt
import wfdb
from kap6_verfahren import fs, N, J, JS, wavelet

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
ausschnitte = {"100": 393, "103": 1088}
dauer = 8
namen = ["$a_8$"] + [f"$d_{j}$" for j in range(J, 0, -1)]
fig, ax = plt.subplots(J + 1, 2, figsize=(6.3, 7.0), sharex="col")
for spalte, (name, von) in enumerate(ausschnitte.items()):
    x = wfdb.rdrecord("../daten/mitdb/" + name).p_signal[:N, 0]
    c = pywt.wavedec(x - np.mean(x), wavelet, mode="periodization", level=J)
    T = np.median(np.abs(c[-1])) / 0.6745 * np.sqrt(2 * np.log(N))
    for zeile, (d, beschriftung) in enumerate(zip(c, namen)):
        stufe = J if zeile == 0 else J + 1 - zeile
        t = (np.arange(len(d)) + 0.5) * 2 ** stufe / fs
        m = (t >= von) & (t <= von + dauer)
        achse = ax[zeile, spalte]
        achse.vlines(t[m], 0, d[m], color="royalblue", lw=0.6)
        if zeile > J - JS:
            achse.axhline(T, color="gray", lw=0.6, ls="--")
            achse.axhline(-T, color="gray", lw=0.6, ls="--")
        achse.set_xlim(von, von + dauer)
        if spalte == 0:
            achse.set_ylabel(beschriftung)
    ax[0, spalte].set_title(f"Datensatz {name}")
    ax[-1, spalte].set_xlabel("Zeit $t$ in s")
fig.tight_layout()
fig.savefig("../abbildungen/abb6_3_koeffizienten.pdf")
plt.show()
```

Listing B.13: Abbildung ??

```
# Abbildung 6.8: Wirkung der drei Schritte auf die 8-s-Ausschnitte aus den
    Datensätzen 100 und 103 (MLII)
```

```
import numpy as np
import matplotlib.pyplot as plt
import wfdb
from kap6_verfahren import entrauschen, fs, N

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
ausschnitte = {"100": 393, "103": 1088}
dauer = 8
fig, ax = plt.subplots(3, 2, figsize=(6.3, 5.0), sharex="col")
for spalte, (name, von) in enumerate(ausschnitte.items()):
    x = wfdb.rdrecord("../daten/mitdb/" + name).p_signal[:N, 0]
    y = x - np.mean(x)
    nur_schwelle = entrauschen(y, a_null=False)
    f = entrauschen(y)
    t = np.arange(N) / fs
    m = (t >= von) & (t <= von + dauer)
    ax[0, spalte].plot(t[m], y[m], color="gray", lw=0.7)
    ax[0, spalte].plot(t[m], (nur_schwelle - f)[m], color="royalblue", lw
        =1.0)
    ax[1, spalte].plot(t[m], 1000 * (y - nur_schwelle)[m], color="royalblue"
        , lw=0.5)
    ax[2, spalte].plot(t[m], f[m], color="royalblue", lw=0.8)
    ax[0, spalte].set_title(f"Datensatz {name}")
    ax[-1, spalte].set_xlabel("Zeit $t$ in s")
    ax[-1, spalte].set_xlim(von, von + dauer)
ax[0, 0].set_ylabel("$Y$ und $a_8$-Anteil\nin mV")
ax[1, 0].set_ylabel("durch Schwellen\nentfernt in $\\mu$V")
ax[2, 0].set_ylabel(r"Schätzung $\hat f$" + "\nin mV")
fig.tight_layout()
fig.savefig("../abbildungen/abb6_4_schritte.pdf")
plt.show()
```

Listing B.14: Abbildung 6.6

```
# Abbildung 6.6: 8-s-Ausschnitte aus den Datensätzen 100 und 103 (MLII) nach
    und vor dem Entrauschen
import numpy as np
import matplotlib.pyplot as plt
import wfdb
from kap6_verfahren import entrauschen, fs, N

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
ausschnitte = {"100": 393, "103": 1088}
dauer = 8
fig, ax = plt.subplots(4, 1, figsize=(6.3, 5.0))
for k, (name, von) in enumerate(ausschnitte.items()):
    x = wfdb.rdrecord("../daten/mitdb/" + name).p_signal[:N, 0]
    y = x - np.mean(x)
    f = entrauschen(y)
    t = np.arange(N) / fs
    m = (t >= von) & (t <= von + dauer)
    unten, oben = min(y[m].min(), f[m].min()) - 0.2, max(y[m].max(), f[m].
        max()) + 0.2
    ax[2 * k].plot(t[m], f[m], color="royalblue", lw=0.8)
    ax[2 * k].set_ylabel(f"{name}: $\\hat f$ in mV")
```

```
    ax[2 * k + 1].plot(t[m], y[m], color="gray", lw=0.8)
    ax[2 * k + 1].set_ylabel(f"{name}: $Y$ in mV")
    for achse in ax[2 * k:2 * k + 2]:
        achse.set_xlim(von, von + dauer)
        achse.set_ylim(unten, oben)
        achse.axhline(0, color="gray", lw=0.5, ls="--")
    ax[2 * k + 1].set_xlabel("Zeit $t$ in s")
fig.tight_layout()
fig.savefig("../abbildungen/abb6_6_vergleich.pdf")
plt.show()
```

Listing B.15: Tabellen ?? und ??

```
# Tabellen 6.2 und 6.3: referenzfreie Kennzahlen für die Datensätze 100 und 103 (MLII)
import numpy as np
import pywt
import wfdb
from kap6_verfahren import entrauschen, isoelektrisch, amplitude, stufenenergie, spektrum, fs, N, J, JS, wavelet

datensaetze = ["100", "103"]
pfad = "../daten/mitdb/"
rand = 10 * fs
fenster = 2 ** 13
baender = [(0, 0.7), (0.7, 1.5), (1.5, 40), (59, 61)]
varianten = [(7, 3), (9, 3), (8, 2), (8, 4)]


def kennzahlen(y, r, fr, P):
    iso = isoelektrisch(y, r)
    _, Q = spektrum(y)
    return {"Basislinie uV": 1e3 * np.std(iso),
            "60 Hz uV": 1e3 * np.mean([amplitude(y[k:k + fenster], 60) for k in range(0, N, fenster)]),
            "R-Zacke mV": np.mean(y[r] - iso),
            **{f"{a}-{b} Hz %": 100 * Q[(fr >= a) & (fr < b)].sum() / P[(fr >= a) & (fr < b)].sum() for a, b in baender}}


for name in datensaetze:
    x = wfdb.rdrecord(pfad + name).p_signal[:N, 0]
    ann = wfdb.rdann(pfad + name, "atr")
    y = x - np.mean(x)
    r = np.array([p for p, z in zip(ann.sample, ann.symbol) if rand <= p < N - rand and z == "N"])
    c = pywt.wavedec(y, wavelet, mode="periodization", level=J)
    sigma = np.median(np.abs(c[-1])) / 0.6745
    T = sigma * np.sqrt(2 * np.log(N))
    fr, P = spektrum(y)
    print(f"{name}: {len(r)} Normalschläge, sigma {1e3 * sigma:.2f} uV, T {1e3 * T:.1f} uV")
    print("  behalten in d3 d2 d1 in %: " + " ".join(f"{100 * np.mean(np.abs(d) > T):.1f}" for d in c[-JS:]))
    alle = np.array([p for p, z in zip(ann.sample, ann.symbol) if z in "
```

```
        NLRAaJSVFejE/fQ"])
    nahe = []
    for j, d in zip(range(JS, 0, -1), c[-JS:]):
        lage = (np.where(np.abs(d) > T)[0] + 0.5) * 2 ** j
        nahe.append(100 * np.mean(np.min(np.abs(lage[:, None] - alle[None,
            :]), axis=1) < 0.1 * fs))
    print("  davon höchstens 100 ms von einer R-Zacke, d3 d2 d1 in %: " + "
        ".join(f"{v:.0f}" for v in nahe))
    werte = {"vorher": kennzahlen(y, r, fr, P)}
    for modus in ["soft", "hard"]:
        f = entrauschen(y, modus)
        werte[modus] = kennzahlen(f, r, fr, P)
        entfernt = np.sqrt(stufenenergie(y - f) / N)
        print(f"  {modus}: entfernt (Effektivwert in uV) a8 {1e3 * entfernt
            [0]:.1f}, d3..d1 "
              + " ".join(f"{1e3 * v:.1f}" for v in entfernt[-JS:]))
        d = y - entrauschen(y, modus, a_null=False)
        print(f"  {modus}: entfernter Detailanteil, um die R-Zacken
            gemittelt: max "
              f"{1e3 * np.max(np.abs(np.mean([d[p - 72:p + 72] for p in r],
                  axis=0))):.1f} uV")
    for l, m in varianten:
        werte[f"J{l}JS{m}"] = kennzahlen(entrauschen(y, J=l, JS=m), r, fr, P
            )
    alle_rr = np.diff(alle[alle < N]) / fs
    print(f"  Herzfrequenz: Mittel {60 / np.mean(alle_rr):.1f}/min,
        kleinster Einzelwert {60 / np.max(alle_rr):.1f}/min")
    _, Q = spektrum(entrauschen(y))
    k60, umgebung = np.argmin(np.abs(fr - 60)), (np.abs(fr - 60) > 1) & (np.
        abs(fr - 60) < 5)
    print(f"  Spitze bei 60 Hz über der Umgebung: vorher {P[k60] / np.median
        (P[umgebung]):.0f}, "
          f"nachher {Q[k60] / np.median(Q[umgebung]):.0f}")
    for k in werte["vorher"]:
        print(f"  {k:14s} " + "  ".join(f"{m} {werte[m][k]:8.3f}" for m in
            werte))
```

Listing B.16: Abbildung ??

```
# Abbildung 6.9: Energiespektrum von Datensatz 103 (MLII) vor und nach dem
    Entrauschen
import numpy as np
import matplotlib.pyplot as plt
import wfdb
from kap6_verfahren import entrauschen, spektrum, fs, N, J, JS

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
x = wfdb.rdrecord("../daten/mitdb/103").p_signal[:N, 0]
y = x - np.mean(x)
f = entrauschen(y)
fr, P = spektrum(y)
_, Q = spektrum(f)
fig, ax = plt.subplots(1, 2, figsize=(6.3, 2.6))
for achse, hi in zip(ax, [2, 180]):
    m = (fr > 0) & (fr <= hi)
```

```
    achse.semilogy(fr[m], P[m], color="gray", lw=0.7)
    achse.semilogy(fr[m], Q[m], color="royalblue", lw=0.7)
    achse.set_xlim(0, hi)
    achse.set_xlabel("Frequenz in Hz")
ax[0].axvline(fs / 2 ** (J + 1), color="black", lw=0.6, ls="--")
ax[0].axvline(fs / 2 ** J, color="black", lw=0.6, ls=":")
ax[1].axvline(fs / 2 ** (JS + 1), color="black", lw=0.6, ls="--")
ax[0].set_ylabel(r"Energiespektrum")
fig.tight_layout()
fig.savefig("../abbildungen/abb6_5_spektrum.pdf")
plt.show()
```

Listing B.17: Test an einem künstlichen EKG, Tabelle 6.3

```
# Abschnitt 6.5: Test an einem künstlichen EKG (ECGSYN über NeuroKit2),
    Tabelle tab:test
import math
import sys
import numpy as np
import neurokit2 as nk
from kap6_verfahren import fs, entrauschen

N_TEST = 2 ** 16
DRIFT = (0.5, 0.25)          # Amplitude in mV, Frequenz in Hz
SIGMA = 0.05                 # Standardabweichung des Rauschens in mV
WIEDERHOLUNGEN = 10


def _ableitung_ohne_drift(t, x, rr, ti, sfint, ai, bi):
    # wie neurokit2 (_ecg_simulate_derivsecgsyn), aber ohne die eingebaute
        Atmungsdrift zbase
    ta = math.atan2(x[1], x[0])
    a0 = 1.0 - np.sqrt(x[0] ** 2 + x[1] ** 2)
    ip = np.floor(t * sfint).astype(int)
    w0 = 2 * np.pi / rr[min(ip, len(rr) - 1)]
    dti = (ta - ti) - np.round((ta - ti) / 2 / np.pi) * 2 * np.pi
    return np.array([a0 * x[0] - w0 * x[1], a0 * x[1] + w0 * x[0],
                     -np.sum(ai * dti * np.exp(-0.5 * (dti / bi) ** 2)) - x
                         [2]])


def testsignal(n=N_TEST, seed=42):
    sys.modules["neurokit2.ecg.ecg_simulate"]._ecg_simulate_derivsecgsyn =
        _ableitung_ohne_drift
    f = nk.ecg_simulate(duration=n / fs + 2, sampling_rate=fs, heart_rate
        =70,
                        noise=0, method="ecgsyn", random_state=seed)
    return np.asarray(f[:n])


def fehlerenergie(f, schaetzungen):
    # mittlere Fehlerenergie über die Realisierungen (Schätzung des Risikos
        r(f)),
    # Mittelwerte von f und den Schätzungen vorher abgezogen
    f = f - np.mean(f)
```

```
    return np.mean([np.sum((g - np.mean(g) - f) ** 2) for g in schaetzungen
        ])


def gestoert(f, seed):
    t = np.arange(len(f)) / fs
    b = DRIFT[0] * np.sin(2 * np.pi * DRIFT[1] * t)
    return f + b + SIGMA * np.random.default_rng(seed).standard_normal(len(f
        ))


varianten = [("J = 8, J_S = 3, Soft", dict()),
             ("Hard", dict(modus="hard")),
             ("J_S = 2", dict(JS=2)),
             ("J_S = 4", dict(JS=4)),
             ("nur Drift (J_S = 0)", dict(JS=0)),
             ("J = 7", dict(J=7)),
             ("J = 9", dict(J=9))]

if __name__ == "__main__":
    f = testsignal()
    messungen = [gestoert(f, s) for s in range(WIEDERHOLUNGEN)]
    print(f"||f||^2 = {np.sum((f - np.mean(f)) ** 2):.0f}")
    print(f"  {'vorher (Messung Y)':22s} {fehlerenergie(f, messungen):8.1f}"
        )
    for name, arg in varianten:
        print(f"  {name:22s} {fehlerenergie(f, [entrauschen(y, **arg) for y
            in messungen]):8.1f}")
```

Listing B.18: Abbildung 6.3

```
# Abbildung 6.3: Ausschnitt von 4 s aus dem Test-EKG f und der gestörten
    Messung Y (sigma = 0,05 mV)
import numpy as np
import matplotlib.pyplot as plt
from kap6_verfahren import fs
from kap6_test import testsignal, gestoert, DRIFT

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
f = testsignal()
y = gestoert(f, 0)
t = np.arange(len(f)) / fs
b = DRIFT[0] * np.sin(2 * np.pi * DRIFT[1] * t)
m = (t >= 60) & (t < 64)
fig, ax = plt.subplots(2, 1, figsize=(6.3, 3.6), sharex=True)
ax[0].plot(t[m], f[m], color="black", lw=0.8)
ax[0].set_ylabel("$f$ in mV")
ax[1].plot(t[m], y[m], color="gray", lw=0.6, label="$Y$")
ax[1].plot(t[m], b[m], color="crimson", lw=1.0, ls="--", label="Drift $b$")
ax[1].legend(loc="upper right", frameon=False, ncol=2)
ax[1].set_ylabel("$Y$ in mV")
ax[1].set_xlabel("Zeit $t$ in s")
ax[1].set_xlim(60, 64)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_3_testsignal.pdf")
```

```
plt.show()
```

Listing B.19: Abbildung 6.4

```
# Abbildung 6.4: Ausschnitt von 4 s aus dem Test-EKG f und dem Ergebnis
    f_hat (sigma = 0,05 mV)
import numpy as np
import matplotlib.pyplot as plt
from kap6_verfahren import fs, entrauschen
from kap6_test import testsignal, gestoert

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
f = testsignal()
fh = entrauschen(gestoert(f, 0))
t = np.arange(len(f)) / fs
m = (t >= 60) & (t < 64)
fig, ax = plt.subplots(figsize=(6.3, 2.2))
ax.plot(t[m], f[m] - np.mean(f), color="black", lw=1.4, alpha=0.35, label="
    $f$")
ax.plot(t[m], fh[m] - np.mean(fh), color="royalblue", lw=0.7, label=r"$\hat
    f$")
ax.set_ylabel("in mV")
ax.set_xlabel("Zeit $t$ in s")
ax.legend(loc="upper right", frameon=False, ncol=2)
ax.set_xlim(60, 64)
ax.set_ylim(-0.6, 1.6)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_4_test.pdf")
plt.show()
```

Listing B.20: Abbildung 6.5

```
# Abbildung 6.5: ein Herzschlag aus Abbildung 6.4 vergrößert, Test-EKG f und
    Ergebnis f_hat
import numpy as np
import matplotlib.pyplot as plt
from kap6_verfahren import fs, entrauschen
from kap6_test import testsignal, gestoert

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
f = testsignal()
fh = entrauschen(gestoert(f, 0))
t = np.arange(len(f)) / fs
m = (t >= 60.45) & (t < 61.35)
fig, ax = plt.subplots(figsize=(6.3, 2.6))
ax.plot(t[m], f[m] - np.mean(f), color="black", lw=2.0, alpha=0.35, label="
    $f$")
ax.plot(t[m], fh[m] - np.mean(fh), color="royalblue", lw=0.9, label=r"$\hat
    f$")
ax.set_ylabel("in mV")
ax.set_xlabel("Zeit $t$ in s")
ax.legend(loc="upper right", frameon=False, ncol=2)
ax.set_xlim(60.45, 61.35)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_5_test_schlag.pdf")
```

```
21 plt.show()
```

Literaturverzeichnis

[AJB17] Mounaim Aqil, Atman Jbari, and Abdennasser Bourouhou. ECG signal denoising by discrete wavelet transform. *International Journal of Online Engineering (iJOE)*, 13(9):51–68, 2017.

[Ale16] Silvia Maria Alessio. *Digital Signal Processing and Spectral Analysis for Scientists. Concepts and Applications*. Signals and Communication Technology. Springer, Cham, 2016.

[BK19] Steven L. Brunton and J. Nathan Kutz. *Fourier and Wavelet Transforms*, pages 47–83. Cambridge University Press, Cambridge, 2019.

[Bla03] Christian Blatter. *Wavelets – Eine Einführung*. Advanced Lectures in Mathematics. Vieweg, Braunschweig/Wiesbaden, 2., durchgesehene edition, 2003.

[CMG+13] Encarnación Castillo, Diego P. Morales, Antonio García, Francisco Martínez-Martí, Luis Parrilla, and Alberto J. Palma. Noise suppression in ECG signals through efficient one-step wavelet processing techniques. *Journal of Applied Mathematics*, 2013:763903, 2013.

[CTY+20] Shubhojeet Chatterjee, Rini Smita Thakur, Ram Narayan Yadav, Lalita Gupta, and Deepak Kumar Raghuvanshi. Review of noise removal techniques in ECG signals. *IET Signal Processing*, 14(9):569–590, 2020.

[Gac12] Adam Gacek. An introduction to ECG signal processing and analysis. In Adam Gacek and Witold Pedrycz, editors, *ECG Signal Processing, Classification and Interpretation*, pages 21–46. Springer, London, 2012.

[HB09] Martin Hanke-Bourgeois. *Grundlagen der Numerischen Mathematik und des Wissenschaftlichen Rechnens*. Vieweg+Teubner, Wiesbaden, 3., aktualisierte edition, 2009.

[KS20] Pramendra Kumar and Vijay Kumar Sharma. Detection and classification of ECG noises using decomposition on mixed codebook for quality analysis. *Healthcare Technology Letters*, 7(1):18–24, 2020.

[LGW+19] Gregory R. Lee, Ralf Gommers, Filip Waselewski, Kai Wohlfahrt, and Aaron O'Leary. PyWavelets: A Python package for wavelet analysis. *Journal of Open Source Software*, 4(36):1237, 2019.

[LMR98] Alfred Karl Louis, Peter Maaß, and Andreas Rieder. *Wavelets: Theorie und Anwendungen*. Teubner-Studienbücher: Mathematik. B. G. Teubner, Stuttgart, 2., überarbeitete und erweiterte edition, 1998.

[Mal09] Stéphane Mallat. *A Wavelet Tour of Signal Processing: The Sparse Way*. Academic Press / Elsevier, Burlington, MA, 3. edition, 2009.

[MCTS03] Patrick E. McSharry, Gari D. Clifford, Lionel Tarassenko, and Leonard A. Smith. A dynamical model for generating synthetic electrocardiogram signals. *IEEE Transactions on Biomedical Engineering*, 50(3):289–294, 2003.

[MM97] George B. Moody and Roger G. Mark. MIT-BIH arrhythmia database directory. https://archive.physionet.org/physiobank/database/html/mitdbdir/mitdbdir.htm, 1997. HTML-Ausgabe vom 24.05.1997, Einleitung überarbeitet am 24.06.2010; abgerufen am 09.10.2026.

[MM01] George B. Moody and Roger G. Mark. The impact of the MIT-BIH arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3):45–50, 2001.

[MM05] George B. Moody and Roger G. Mark. MIT-BIH arrhythmia database, version 1.0.0. PhysioNet, https://physionet.org/content/mitdb/1.0.0/, 2005. Abgerufen am 19.10.2026.

[MPL+21] Dominique Makowski, Tam Pham, Zen J. Lau, Jan C. Brammer, François Lespinasse, Hung Pham, Christopher Schölzel, and S. H. Annabel Chen. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods*, 53(4):1689–1696, 2021.

[PML+26] Tom Pollard, Benjamin E. Moody, Li-wei Lehman, Brian Gow, Chrystinne Fernandes, Chenxi Xie, Alistair Johnson, Roger G. Mark, and Thomas Heldt. PhysioNet as a global platform for biomedical research. *Nature Health*, 1(8):792–795, 2026.

[Reb21] Linda Rebstadt. Spark-basierte analyse von monitoring-daten intensiv überwachter patienten zur identifikation von anomalien: Ein use case der charité health data platform. Masterarbeit, Hochschule Darmstadt, 2021.

[Ser17] Valery Serov. *Fourier Series, Fourier Transform and Their Applications to Mathematical Physics*, volume 197 of *Applied Mathematical Sciences*. Springer, Cham, 2017.

[SL05] Leif Sörnmo and Pablo Laguna. *Bioelectrical Signal Processing in Cardiac and Neurological Applications*. Elsevier Academic Press, Burlington, 2005.

[SS03] Elias M. Stein and Rami Shakarchi. *Fourier Analysis: An Introduction*, volume I of *Princeton Lectures in Analysis*. Princeton University Press, Princeton, 2003.