

Universität Hamburg
DER FORSCHUNG | DER LEHRE | DER BILDUNG

BACHELORARBEIT

Die diskrete Wavelet-Transformation und ihre Anwendung zur Entrauschung von EKG-Signalen

ausgeführt am

Fachbereich Mathematik
Fakultät für Mathematik, Informatik und Naturwissenschaften
Universität Hamburg

unter der Anleitung von

Name des Betreuers

durch

Hilda Beuting
Matrikelnummer: 12345678
Straße und Hausnummer
PLZ und Ort

Hamburg, am Datum

Inhaltsverzeichnis

1. Einleitung **1**

2. Mathematische Grundlagen **2**
2.1. Der Hilbertraum $L^2(\mathbb{R})$ und Orthonormalbasen . . . 2
2.2. Unitäre Operatoren . . . 3
2.3. Fourier-Transformation . . . 4
2.4. Grundbegriffe der Wahrscheinlichkeitsrechnung . . . 4

3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse **6**
3.1. Die kontinuierliche Wavelet-Transformation . . . 6
3.1.1. Wavelets und die Zulässigkeitsbedingung . . . 7
3.1.2. Die Wavelet-Familie und die Transformation . . . 7
3.1.3. Die Plancherel-Formel . . . 11
3.2. Das dyadische Gitter und die Multiskalenanalyse . . . 12
3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j . . . 16
3.3.1. Die Orthonormalbasis auf allen Skalen . . . 16
3.3.2. Die Approximationsoperatoren . . . 17
3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$ . . . 18
3.4.1. Die Wavelet-Basis . . . 18

4. Konstruktion der diskreten Wavelet-Transformation **20**
4.1. Die Skalierungsgleichung . . . 20
4.2. Filterkoeffizienten: Tiefpass und Hochpass . . . 21
4.3. Der Mallat-Algorithmus . . . 22
4.4. Daubechies-Wavelets . . . 24
4.5. Die Filter im Frequenzbereich . . . 27

5. Entrauschung durch Thresholding **29**
5.1. Rauschmodell und diskrete Wavelet-Transformation . . . 29
5.2. Diagonale Schätzer und Thresholding . . . 32
5.3. Die Wahl der Schwelle . . . 38
5.4. Schätzung der Rauschstärke . . . 38

6. Anwendung: Entrauschung von EKG-Signalen **42**
6.1. EKG-Signale und ihre Störquellen . . . 42
6.2. Die Datensätze . . . 43
6.3. Skalen als Frequenzbänder . . . 45
6.4. Das Verfahren . . . 46
6.4.1. Modell und Ein-Schritt-Verfahren . . . 46

6.4.2. Tiefe J für die Drift . . . 47
6.4.3. Anzahl J_S der geschwellten Stufen . . . 48
6.4.4. Schwelle . . . 49
6.5. Test an einem künstlichen EKG . . . 50
6.6. Anwendung auf die Datensätze 100 und 103 . . . 56
6.7. Diskussion . . . 58

7. Fazit und Ausblick **60**

A. Ergänzende Rechnungen **61**
A.1. Zulässigkeitskonstante des Haar-Wavelets . . . 61
A.2. Fourier-Transformierte des Testsignals . . . 61
A.3. Stammfunktion des Testsignals . . . 62

B. Python-Code **64**
B.1. Kontinuierliche Wavelet-Transformation . . . 64
B.2. Daubechies-Wavelets . . . 64
B.3. Entrauschung durch Thresholding . . . 65
B.3.1. Verrauschter Sinus . . . 65
B.3.2. Sinus mit Spitzen . . . 65
B.3.3. Detailkoeffizienten des Testsignals . . . 66
B.3.4. Detailkoeffizienten der Messwerte . . . 67
B.3.5. Entrauschtes Testsignal . . . 67
B.4. Entrauschung von EKG-Signalen . . . 68
B.4.1. Verfahren . . . 68
B.4.2. Datensätze . . . 69
B.4.3. Annotationen . . . 69
B.4.4. Entrauschte Datensätze . . . 70
B.4.5. Test-EKG . . . 70
B.4.6. Test . . . 71
B.4.7. Abbildungen zum Test . . . 72

Literaturverzeichnis **74**

1. Einleitung

Das Elektrokardiogramm (EKG) zeichnet die elektrische Aktivität des Herzens auf und gehört zu den am besten erforschten biomedizinischen Signalen mit hohem diagnostischem Wert [Gac12, Kap. 2.1]. Jede Aufzeichnung ist jedoch gestört [Gac12, Kap. 2.3]: Bewegung und Atmung verschieben die Grundlinie, Muskelaktivität und das Stromnetz überlagern zusätzliche Schwingungen, und die Messung selbst erzeugt Rauschen (Abschnitt 6.1). Ein Teil dieser Störungen liegt im selben Frequenzbereich wie das EKG. Sie lassen sich daher nicht entfernen, ohne diagnostische Information zu beschädigen [Gac12, Kap. 2.3].

Die Fourier-Analyse stellt ein Signal durch Schwingungen dar, die über die ganze Zeitachse ausgedehnt sind. Kurze, scharfe Strukturen wie der QRS-Komplex erfassen sie schlecht. Hanke-Bourgeois zeigt das an einem EKG mit 2048 Messwerten: Seine Approximation durch trigonometrische Polynome glättet die Spitzen, und bei niedrigem Grad geht ein Minimum ganz verloren [HB09, Bsp. 52.7]. Wavelets sind dagegen zeitlich lokalisiert. Im selben EKG sind über ein Viertel der 2048 Waveletkoeffizienten betragsmäßig kleiner als 10^{-4}, aber nur 24 der Fourierkoeffizienten [HB09, Bsp. 56.3]. Das Signal steckt also in wenigen Waveletkoeffizienten. Darauf beruht das Thresholding nach Donoho und Johnstone: Setzt man kleine Koeffizienten auf null, entfernt man vor allem Rauschen, und scharfe Strukturen bleiben erhalten [Mal09, Kap. 11.3.1]. Castillo et al. entfernen auf diese Weise Drift und Rauschen aus EKG-Signalen in einer einzigen Zerlegung [CMG+13], Alessio stellt dieses Verfahren als Beispiel dar [Ale16, Kap. 15.2.4].

Diese Arbeit geht der Frage nach, warum das Thresholding von Waveletkoeffizienten Rauschen aus einem EKG entfernt und wie gut das Verfahren von Castillo et al. an realen Aufzeichnungen funktioniert. Wir beschränken uns dabei auf orthogonale Daubechies-Wavelets. Andere Verfahren werden nicht verglichen, und eine klinische Bewertung der Ergebnisse ist nicht Gegenstand der Arbeit.

Der eigene Beitrag liegt in zwei Teilen. Zum einen wird der Weg vom Hilbertraum $L^2(\mathbb{R})$ über die Multiskalenanalyse und die diskrete Wavelet-Transformation bis zum Thresholding geschlossen und in einheitlicher Notation hergeleitet. Zum anderen werden die Parameter des Verfahrens von Castillo et al. über die Frequenzbänder der Transformation begründet, an einem künstlichen EKG getestet und auf zwei Aufzeichnungen der MIT-BIH Arrhythmia Database angewandt.

Kapitel 2 stellt die mathematischen Grundlagen bereit. Kapitel 3 führt von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse und zu einer Orthonormalbasis aus Wavelets. Kapitel 4 konstruiert daraus die diskrete Wavelet-Transformation mit dem Mallat-Algorithmus und den Daubechies-Wavelets. Kapitel 5 begründet das Entrauschen durch Thresholding und die Wahl der Schwelle. Kapitel 6 wendet das Verfahren auf EKG-Signale an, zuerst an einem künstlichen EKG, dann an den realen Aufzeichnungen. Kapitel 7 fasst die Ergebnisse zusammen und gibt einen Ausblick.

2. Mathematische Grundlagen

Dieses Kapitel stellt die Begriffe bereit, die in den folgenden Kapiteln benutzt werden: den Hilbertraum $L^2(\mathbb{R})$, unitäre Operatoren, die Fourier-Transformation und das stochastische Modell für das Rauschen.

2.1. Der Hilbertraum $L^2(\mathbb{R})$ und Orthonormalbasen

Definition 2.1 (Hilbertraum, [Ser17, Def. 25.5, Def. 25.7]). Sei $\mathcal{H}$ ein Vektorraum mit Skalarprodukt $\langle \cdot, \cdot \rangle$ und der davon erzeugten Norm $\|x\| := \langle x, x \rangle^{1/2}$. Ist $\mathcal{H}$ bezüglich dieser Norm vollständig, konvergiert also jede Cauchy-Folge in $\mathcal{H}$, so heißt $\mathcal{H}$ Hilbertraum.

Definition 2.2 (Der Raum $L^2(\mathbb{R})$, [Ser17, Kap. 25]). $L^2(\mathbb{R})$ ist der Raum der messbaren Funktionen $f\colon \mathbb{R} \to \mathbb{C}$, deren Betrag quadratisch integrierbar ist[1], mit

$$\langle f, g \rangle := \int_{\mathbb{R}} f(t)\,\overline{g(t)}\,dt, \qquad \|f\| := \langle f, f \rangle^{1/2}.$$

Satz 2.3 ([Ser17, Kap. 25, Übung 25.3]). *$L^2(\mathbb{R})$ ist ein Hilbertraum. Für alle $f, g \in L^2(\mathbb{R})$ gilt die Cauchy-Schwarz-Ungleichung*

$$|\langle f, g \rangle| \;\leq\; \|f\|\,\|g\|.$$

Ebenso sind der $\mathbb{R}^N$ mit $\langle x, y \rangle := \sum_n x_n y_n$ und der Folgenraum $\ell^2(\mathbb{Z})$ mit $\langle c, d \rangle := \sum_{k \in \mathbb{Z}} c_k\,\overline{d_k}$ Hilberträume, vgl. [Ser17, Kap. 25]. Normen ohne Index sind im Folgenden Normen in $L^2(\mathbb{R})$, bei Vektoren die euklidische Norm. Analog zu $L^2(\mathbb{R})$ ist $L^1(\mathbb{R})$ der Raum der Funktionen mit $\|f\|_1 := \int_{\mathbb{R}} |f(t)|\,dt < \infty$ [Bla03, Kap. 2.2].

Definition 2.4 (Träger, vgl. [HB09, Def. 56.1]). Der Träger einer Funktion f ist

$$\operatorname{supp} f \;:=\; \overline{\{t \in \mathbb{R} : f(t) \neq 0\}}.$$

Ist $\operatorname{supp} f$ beschränkt, so heißt f kompakt getragen.

Definition 2.5 (Orthonormalbasis, [Ser17, Def. 25.4, Def. 25.17]). Sei $\mathcal{H}$ ein Hilbertraum. Eine Familie $\{e_k\}_{k \in \mathbb{Z}}$ in $\mathcal{H}$ heißt Orthonormalsystem, wenn $\langle e_k, e_l \rangle = \delta_{k,l}$ für alle $k, l \in \mathbb{Z}$ gilt. Lässt sich zudem jedes $x \in \mathcal{H}$ beliebig genau durch endliche Linearkombinationen der e_k approximieren, so heißt sie Orthonormalbasis von $\mathcal{H}$.

[1] Funktionen, die sich nur auf einer Nullmenge unterscheiden, werden dabei als gleich angesehen [Bla03, Kap. 2.1–2.2].

Satz 2.6 ([Ser17, Übung 25.2, Satz 25.18]). *Sei $\{e_k\}_{k\in\mathbb{Z}}$ ein Orthonormalsystem im Hilbertraum $\mathcal{H}$. Für jedes $x \in \mathcal{H}$ gilt die Bessel-Ungleichung*

$$\sum_{k\in\mathbb{Z}} |\langle x, e_k\rangle|^2 \;\leq\; \|x\|^2.$$

Ferner sind äquivalent:

(a) $\{e_k\}_{k\in\mathbb{Z}}$ ist eine Orthonormalbasis von $\mathcal{H}$.

(b) Jedes $x \in \mathcal{H}$ hat die Entwicklung $x = \sum_{k\in\mathbb{Z}} \langle x, e_k\rangle\, e_k$ mit Konvergenz in der Norm von $\mathcal{H}$.

(c) Jedes $x \in \mathcal{H}$ erfüllt die Parseval-Gleichung $\|x\|^2 = \sum_{k\in\mathbb{Z}} |\langle x, e_k\rangle|^2$.

Ist $\{e_k\}_{k\in\mathbb{Z}}$ eine Orthonormalbasis, so ordnet $x \mapsto (\langle x, e_k\rangle)_{k\in\mathbb{Z}}$ jedem $x \in \mathcal{H}$ nach (c) eine Folge in $\ell^2(\mathbb{Z})$ mit derselben Norm zu. Für einen Teilraum $M \subset \mathcal{H}$ heißt $M^\perp := \{y \in \mathcal{H} : \langle y, x\rangle = 0 \text{ für alle } x \in M\}$ das orthogonale Komplement von M [Ser17, Def. 25.8]. Der Teilraum M heißt abgeschlossen, wenn jeder Grenzwert einer Folge in M wieder in M liegt [Ser17, Def. 25.10].

Satz 2.7 (Projektionssatz, [Ser17, Satz 25.12]). *Sei M ein abgeschlossener Teilraum des Hilbertraums $\mathcal{H}$. Dann hat jedes $x \in \mathcal{H}$ genau eine Darstellung $x = u + v$ mit $u \in M$ und $v \in M^\perp$. Dabei gilt*

$$\|x - u\| \;=\; \inf_{y\in M} \|x - y\|.$$

Man schreibt dafür $\mathcal{H} = M \oplus M^\perp$ und nennt $\mathcal{H}$ die orthogonale Summe von M und $M^\perp$ [Ser17, Satz 25.12]. Die Abbildung $P_M \colon x \mapsto u$ ist linear, und es gilt $P_M^2 = P_M$ und $P_M^* = P_M$. Sie heißt Orthogonalprojektion auf M [Ser17, Def. 27.1, Prop. 27.2 (4)]. Nach Satz 2.7 ist $P_M x$ die beste Näherung von x in M.

2.2. Unitäre Operatoren

Definition 2.8 (Isometrie, unitärer Operator, [Ser17, Def. 27.6, Def. 27.7]). Sei $\mathcal{H}$ ein Hilbertraum. Eine lineare Abbildung $U \colon \mathcal{H} \to \mathcal{H}$ heißt Isometrie, wenn $\|Ux\| = \|x\|$ für alle $x \in \mathcal{H}$ gilt. Eine surjektive Isometrie heißt unitär.

Eine Isometrie erhält auch Skalarprodukte, also $\langle Ux, Uy\rangle = \langle x, y\rangle$ für alle $x, y \in \mathcal{H}$ [Ser17, Übung 27.2, Bem. 27.8].

Ein wichtiges Beispiel sind orthogonale Matrizen. Eine Matrix $S \in \mathbb{R}^{N\times N}$ heißt orthogonal, wenn $S^\top = S^{-1}$ gilt, also $S^\top S = S S^\top = I$ [Ser17, Übung 16.5]. Für quadratische Matrizen folgt das schon aus $S^\top S = I$. Sind $s_0, \ldots, s_{N-1}$ die Zeilen von S, so ist der Eintrag (m, p) von $SS^\top$ gleich $\langle s_m, s_p\rangle$. Die Bedingung $SS^\top = I$ besagt also, dass die Zeilen von S eine Orthonormalbasis des $\mathbb{R}^N$ bilden. Wegen

$$\|Sx\|^2 \;=\; x^\top S^\top S\, x \;=\; \|x\|^2$$

und $SS^\top = I$ ist S eine surjektive Isometrie, also ein unitärer Operator auf dem $\mathbb{R}^N$.

2.3. Fourier-Transformation

Definition 2.9 (Fourier-Transformation, [Bla03, Kap. 2.2]). Für $f \in L^1(\mathbb{R})$ heißt

$$\hat{f}(\omega) := \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} f(t)\, e^{-i\omega t}\, dt, \qquad \omega \in \mathbb{R},$$

die Fourier-Transformierte von f.

Bemerkung 2.10 (Fourier-Konvention). Diese Normierung gilt in der ganzen Arbeit. In der Literatur ist sie nicht einheitlich, und je nach Wahl ändern sich die Konstanten in den Formeln [Bla03, Kap. 2.2]. So gilt der Faktor 2π in (3.1) nur für diese Normierung.

Satz 2.11 ([Bla03, Satz (2.9)]). *Für $f \in L^1(\mathbb{R})$ ist $\hat{f}$ stetig.*

Satz 2.12 (Plancherel-Formel, [Bla03, Satz (2.11)]). *Die Fourier-Transformation lässt sich von $L^1(\mathbb{R}) \cap L^2(\mathbb{R})$ eindeutig zu einer bijektiven Abbildung $L^2(\mathbb{R}) \to L^2(\mathbb{R})$ fortsetzen. Für $f \in L^1(\mathbb{R}) \cap L^2(\mathbb{R})$ ist $\hat{f}$ also weiterhin durch das Integral aus Definition 2.9 gegeben. Für alle $f, g \in L^2(\mathbb{R})$ gilt*

$$\langle \hat{f}, \hat{g} \rangle = \langle f, g \rangle, \qquad \textit{insbesondere} \qquad \|\hat{f}\| = \|f\|. \tag{2.1}$$

Die Fourier-Transformation ist also unitär (Definition 2.8).

2.4. Grundbegriffe der Wahrscheinlichkeitsrechnung

In Kapitel 5 wird das Rauschen in einem Messsignal als zufällig modelliert. Dafür genügen die folgenden Begriffe [Mal09, Anhang A.6]. Alle Zufallsvariablen sind reellwertig. Ein Zufallsvektor $X = (X_0, \dots, X_{N-1})$ besteht aus N Zufallsvariablen X_n. Hat eine Zufallsvariable X die Wahrscheinlichkeitsdichte p, so heißen $\mathbb{E}[X] = \int_{\mathbb{R}} x\, p(x)\, dx$ ihr Erwartungswert und $\mathbb{E}\big[(X - \mathbb{E}[X])^2\big]$ ihre Varianz. Der Erwartungswert ist linear. Zwei Zufallsvariablen X_1, X_2 heißen unkorreliert, wenn $\mathbb{E}\big[(X_1 - \mathbb{E}[X_1])(X_2 - \mathbb{E}[X_2])\big] = 0$ gilt.

Definition 2.13 (Normalverteilung, vgl. [Bla03, Kap. 1.4, Satz (3.6)], [Mal09, Kap. 11.2.2]). Sei $\phi(x) = (2\pi)^{-1/2} e^{-x^2/2}$ die Gauß'sche Dichte. Eine Zufallsvariable X heißt normalverteilt mit Erwartungswert μ und Varianz $\sigma^2 > 0$, wenn sie die Dichte $p(x) = \sigma^{-1}\phi\big((x-\mu)/\sigma\big)$ hat. Im Fall $\mu = 0$, $\sigma = 1$ heißt X standardnormalverteilt.

Gemeinsam normalverteilt heißen Zufallsvariablen, die zusammen einen Gauß'schen Zufallsvektor bilden. Für sie gilt:

Satz 2.14 (vgl. [Mal09, Kap. 10.3.2]). *Sei Z ein Gauß'scher Zufallsvektor im $\mathbb{R}^N$.*

(i) Ist $\{g_m\}_{0 \le m < N}$ eine Orthonormalbasis des $\mathbb{R}^N$, so sind die Koeffizienten $\langle Z, g_0 \rangle, \dots, \langle Z, g_{N-1} \rangle$ gemeinsam normalverteilt.

(ii) Sind die Komponenten von Z paarweise unkorreliert, so sind sie unabhängig.

Definition 2.15 (Weißes Rauschen, [Mal09, Kap. 11.2.1]). Ein Zufallsvektor $W = (W_0, \dots, W_{N-1})^\top$ heißt weißes Rauschen der Varianz σ^2, wenn

$$\mathbb{E}[W_n] = 0 \qquad \text{und} \qquad \mathbb{E}[W_n W_k] = \sigma^2 \, \delta_{n,k} \qquad \text{für alle } n, k = 0, \dots, N-1$$

gilt. Ist W zudem ein Gauß'scher Zufallsvektor, heißt W Gauß'sches weißes Rauschen.

Nach Satz 2.14 (ii) sind die Komponenten eines Gauß'schen weißen Rauschens der Varianz 1 unabhängig und standardnormalverteilt.

Satz 2.16 (vgl. [Mal09, Kap. 11.2.1–11.2.2]). *Sei Z Gauß'sches weißes Rauschen der Varianz 1 im $\mathbb{R}^N$ und $S \in \mathbb{R}^{N \times N}$ orthogonal. Dann ist $\tilde{Z} := SZ$ wieder Gauß'sches weißes Rauschen der Varianz 1. Die $\tilde{Z}_0, \dots, \tilde{Z}_{N-1}$ sind also unabhängig und standardnormalverteilt.*

Beweis. Seien $s_0, \dots, s_{N-1}$ die Zeilen von S. Sie bilden eine Orthonormalbasis des $\mathbb{R}^N$ (Abschnitt 2.2), und es ist $\tilde{Z}_m = \langle Z, s_m \rangle = \sum_{n=0}^{N-1} s_m[n] \, Z_n$. Wegen der Linearität des Erwartungswerts ist $\mathbb{E}[\tilde{Z}_m] = \sum_n s_m[n] \, \mathbb{E}[Z_n] = 0$ und

$$\mathbb{E}\big[\tilde{Z}_m \tilde{Z}_p\big] = \sum_{n=0}^{N-1} \sum_{k=0}^{N-1} s_m[n] \, s_p[k] \, \mathbb{E}[Z_n Z_k] = \sum_{n=0}^{N-1} s_m[n] \, s_p[n] = \langle s_m, s_p \rangle = \delta_{m,p}.$$

Nach Satz 2.14 (i) sind die $\tilde{Z}_m$ gemeinsam normalverteilt. Also ist $\tilde{Z}$ Gauß'sches weißes Rauschen der Varianz 1. Da alle Erwartungswerte null sind, ist $\mathbb{E}[\tilde{Z}_m \tilde{Z}_p]$ die Kovarianz von $\tilde{Z}_m$ und $\tilde{Z}_p$. Die $\tilde{Z}_m$ sind also paarweise unkorreliert und nach Satz 2.14 (ii) unabhängig. Jedes $\tilde{Z}_m$ ist normalverteilt [Mal09, Kap. 10.3.2] mit Erwartungswert 0 und Varianz $\mathbb{E}[\tilde{Z}_m^2] = 1$, also standardnormalverteilt. □

Definition 2.17 (Median, [Mal09, Kap. 11.3.1]). Ordnet man P Zahlen der Größe nach, so heißt der Wert vom Rang $P/2$ ihr Median.

Anders als der Mittelwert hängt der Median nicht davon ab, wie groß die Werte über ihm sind. Wenige sehr große Werte verändern ihn daher kaum [Mal09, Kap. 11.3.1].

3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse

3.1. Die kontinuierliche Wavelet-Transformation

Die Darstellung folgt [Bla03, Kap. 3.1–3.3] und ergänzend [LMR98, Kap. 1.1]. Es gilt die Fourier-Konvention aus Bemerkung 2.10.

Die Fourier-Transformation misst mit $\hat{f}(\omega)$, wie stark die Frequenz ω in f vertreten ist. Ihre Analysefunktionen $e^{i\omega t}$ haben auf ganz $\mathbb{R}$ konstanten Betrag. Sie zerlegt daher nur entlang der Frequenzachse [LMR98, Bem. 1.3.4]. Wann eine Frequenz auftritt, ist an $|\hat{f}|$ nicht abzulesen [Bla03, Kap. 1.2–1.3].

Beim EKG ist das ungünstig. P- und T-Welle sind niederfrequent. Der QRS-Komplex enthält zusätzlich hochfrequente, zeitlich lokalisierte Anteile [Reb21, Kap. 2.3]. Eine geeignete Analyse muss beide Anteile zugleich auflösen.

Die gefensterte Fourier-Transformation (Abschnitt ??) bestimmt den Frequenzgehalt eines Ausschnitts. Die Fensterbreite ist dabei für alle Frequenzen gleich. Zeit- und Frequenzauflösung lassen sich nach der Heisenbergschen Unschärferelation nicht zugleich beliebig verbessern [Bla03, Kap. 2.3], [LMR98, Kap. 1.3.1]. Die Wavelet-Transformation wählt die Fensterbreite deshalb abhängig von der Frequenz. Hohe Frequenzen werden mit kurzen Fenstern untersucht, tiefe mit langen [LMR98, Kap. 1.3.2]. Abbildung 3.1 zeigt das schematisch.

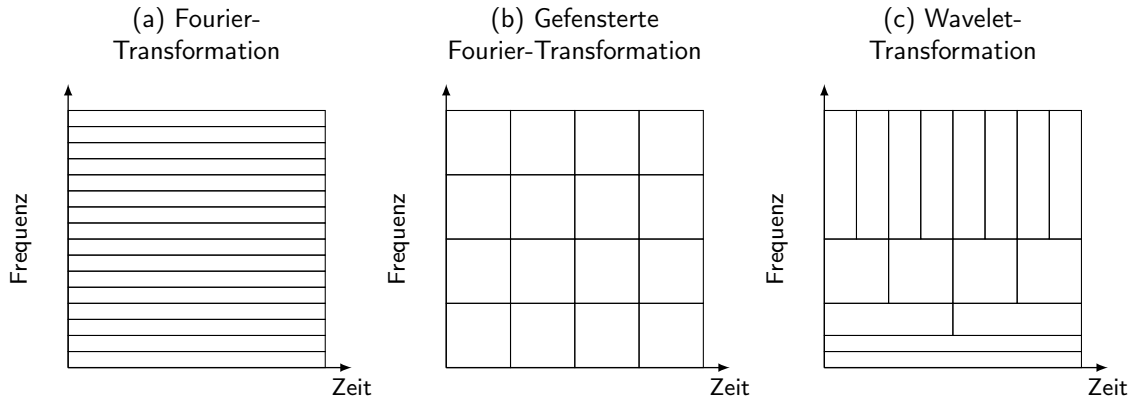


Abbildung 3.1.: Schematische Zeit-Frequenz-Auflösung. Jede Kachel steht für die kleinste Zelle, die die Transformation noch trennt. Alle Kacheln haben denselben Flächeninhalt. In (c) sind die Kacheln bei hohen Frequenzen schmal und bei tiefen breit. In Anlehnung an [BK19, Fig. 2.23].

3.1.1. Wavelets und die Zulässigkeitsbedingung

Definition 3.1 (Wavelet, [Bla03, Kap. 3.1, Bedingungen (1) und (2)]). Eine Funktion $\psi \in L^2(\mathbb{R})$ mit $\|\psi\|_{L^2(\mathbb{R})} = 1$ heißt Mutter-Wavelet (kurz: Wavelet), falls sie die Zulässigkeitsbedingung

$$C_\psi \;:=\; 2\pi \int_{\mathbb{R}^*} \frac{|\hat{\psi}(\omega)|^2}{|\omega|}\, d\omega \;<\; \infty \tag{3.1}$$

erfüllt. Dabei ist $\mathbb{R}^* := \mathbb{R} \setminus \{0\}$.

Ob ein gegebenes ψ die Bedingung (3.1) erfüllt, ist nicht direkt zu sehen [Bla03, Kap. 3.1]. Der folgende Satz führt sie auf eine einfache Bedingung im Zeitbereich zurück.

Satz 3.2 (Charakterisierung der Zulässigkeit, [Bla03, Satz (3.1)]). *Sei $\psi \in L^2(\mathbb{R})$, $\psi \neq 0$, mit $\int_{\mathbb{R}} |t|\,|\psi(t)|\,dt < \infty$. Dann sind äquivalent:*

(i) $C_\psi < \infty$,

(ii) $\displaystyle\int_{\mathbb{R}} \psi(t)\,dt = 0.$

Der Beweis steht bei [Bla03, Satz (3.1)]. Ein Wavelet erfüllt also $\int_{\mathbb{R}} \psi(t)\,dt = 0$. Man sagt dafür auch, ψ habe Mittelwert null [Bla03, Kap. 3.1]. Sein Graph verläuft daher teils oberhalb, teils unterhalb der t-Achse.

Beispiel 3.3 (Haar-Wavelet). Die Funktion

$$\psi^{\mathrm{H}}(t) \;:=\; \begin{cases} 1, & 0 \le t < 1/2, \\ -1, & 1/2 \le t < 1, \\ 0, & \text{sonst}, \end{cases}$$

hat kompakten Träger. Daher ist $\int_{\mathbb{R}} |t|\,|\psi^{\mathrm{H}}(t)|\,dt < \infty$, und Satz 3.2 ist anwendbar. Wegen $\int_{\mathbb{R}} \psi^{\mathrm{H}}(t)\,dt = \frac{1}{2} - \frac{1}{2} = 0$ ist Bedingung (ii) erfüllt. Also ist ψ^{H} zulässig. Mit $\|\psi^{\mathrm{H}}\|_{L^2(\mathbb{R})} = 1$ ist ψ^{H} ein Wavelet im Sinne von Definition 3.1.

Die Zulässigkeitskonstante lässt sich auch direkt berechnen. Mit $\operatorname{sinc}(x) := \sin(x)/x$ für $x \neq 0$ und $\operatorname{sinc}(0) := 1$ ist

$$\widehat{\psi^{\mathrm{H}}}(\omega) \;=\; \frac{i}{\sqrt{2\pi}}\, e^{-i\omega/2}\, \sin(\omega/4)\, \operatorname{sinc}(\omega/4), \qquad \omega \in \mathbb{R}. \tag{3.2}$$

Einsetzen in (3.1) ergibt $C_{\psi^{\mathrm{H}}} = 2\ln 2$ [LMR98, Kap. 1.1, Beispiel (1)] (Rechnung in Anhang A.1). Abbildung 3.2 zeigt ψ^{H} und $|\widehat{\psi^{\mathrm{H}}}|$.

3.1.2. Die Wavelet-Familie und die Transformation

Definition 3.4 (Wavelet-Familie und kontinuierliche Wavelet-Transformation, [Bla03, Kap. 3.1, Gl. (4)–(6)]). Sei ψ ein Wavelet im Sinne von Definition 3.1. Für $(a, b) \in \mathbb{R}^* \times \mathbb{R}$ sei

$$\psi_{a,b}(t) \;:=\; \frac{1}{|a|^{1/2}}\, \psi\!\left(\frac{t-b}{a}\right), \qquad t \in \mathbb{R}. \tag{3.3}$$

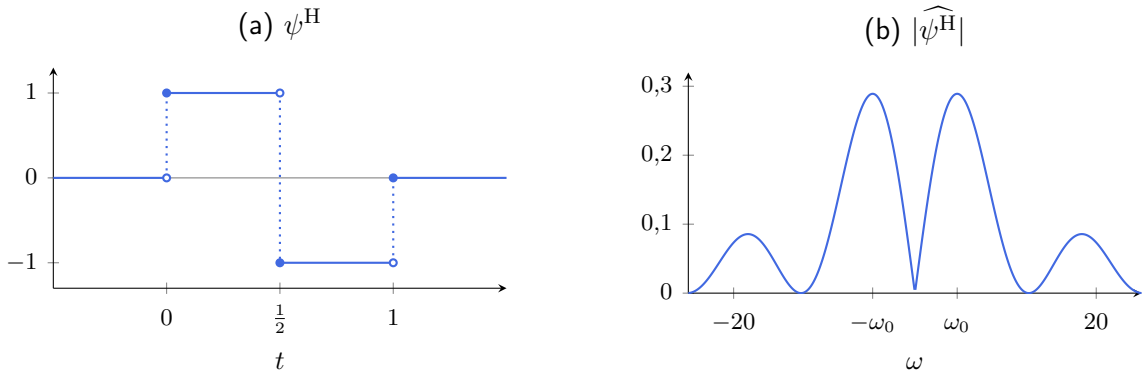


Abbildung 3.2.: Das Haar-Wavelet ψ^{H} (a) und der Betrag seiner Fourier-Transformierten (b). Das globale Maximum liegt bei $\omega_0 \approx 4{,}66$ [LMR98, Kap. 1.1, Beispiel (1)].

Die kontinuierliche Wavelet-Transformation (CWT) von $f \in L^2(\mathbb{R})$ ist

$$W_\psi f \colon \mathbb{R}^* \times \mathbb{R} \to \mathbb{C}, \qquad W_\psi f(a,b) \;:=\; \langle f, \psi_{a,b} \rangle \;=\; \frac{1}{|a|^{1/2}} \int_{\mathbb{R}} f(t)\, \overline{\psi\left(\frac{t-b}{a}\right)}\, dt. \tag{3.4}$$

Die Menge $\mathbb{R}^*_\square := \mathbb{R}^* \times \mathbb{R}$ heißt zersägte (a,b)-Ebene. Ist ψ aus dem Zusammenhang klar, schreiben wir kurz Wf.

Bemerkung 3.5 (Normierung der Familie)**.** Es gilt $\|\psi_{a,b}\|_{L^2(\mathbb{R})} = \|\psi\|_{L^2(\mathbb{R})} = 1$ für alle (a,b). Einsetzen von (3.3) und Quadrieren ergibt

$$\|\psi_{a,b}\|^2_{L^2(\mathbb{R})} \;=\; \int_{\mathbb{R}} \Big| |a|^{-1/2}\, \psi\big(\tfrac{t-b}{a}\big) \Big|^2 dt \;=\; \frac{1}{|a|} \int_{\mathbb{R}} \Big| \psi\big(\tfrac{t-b}{a}\big) \Big|^2 dt.$$

Nun substituiert man $s = \frac{t-b}{a}$, also $t = as + b$ und $dt = a\, ds$. Für $a < 0$ vertauscht die Substitution zusätzlich die Integrationsgrenzen. Das gleicht das Vorzeichen aus, und es bleibt $dt = |a|\, ds$. Damit folgt

$$\frac{1}{|a|} \int_{\mathbb{R}} \Big| \psi\big(\tfrac{t-b}{a}\big) \Big|^2 dt \;=\; \frac{1}{|a|} \int_{\mathbb{R}} |\psi(s)|^2\, |a|\, ds \;=\; \int_{\mathbb{R}} |\psi(s)|^2\, ds \;=\; \|\psi\|^2_{L^2(\mathbb{R})}.$$

Mit einem Vorfaktor $|a|^{-p}$ statt $|a|^{-1/2}$ ergäbe dieselbe Rechnung $|a|^{1-2p}\, \|\psi\|^2_{L^2(\mathbb{R})}$. Die Norm hängt also genau für $p = \frac{1}{2}$ nicht von a ab [Bla03, Kap. 3.1].

Bemerkung 3.6 (Bedeutung der beiden Parameter)**.** Ist ψ kompakt getragen, so gilt $\operatorname{supp} \psi_{a,b} = b + a \cdot \operatorname{supp} \psi$. Der Parameter b verschiebt das Wavelet entlang der Zeitachse. Daher trägt $Wf(a,b)$ Information über f in der Nähe von $t = b$. Der Parameter a streckt oder staucht das Wavelet und legt die Breite dieses Bereichs fest. Für $a \to 0$ zieht sich $\psi_{a,b}$ auf $t = b$ zusammen [LMR98, Kap. 1.1]. Abbildung 3.3 zeigt beides am Haar-Wavelet.

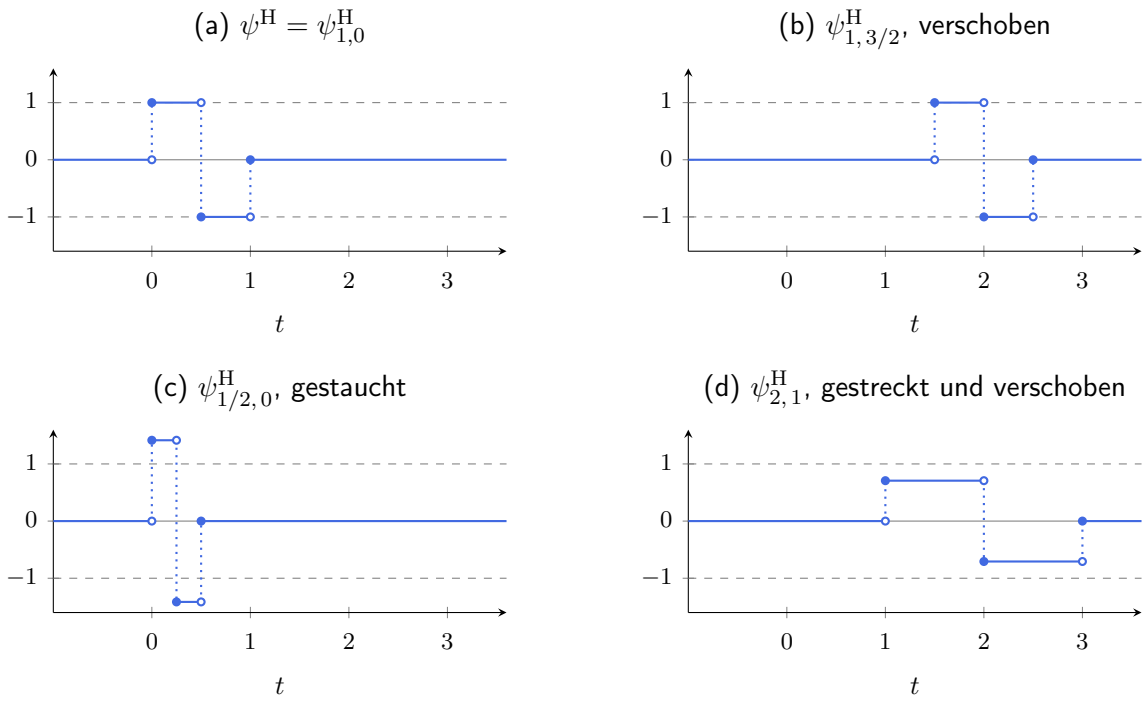


Abbildung 3.3.: Die Wavelet-Familie (3.3) am Haar-Wavelet. In (b) liegt der Träger auf $[\frac{3}{2}, \frac{5}{2}]$. In (c) liegt er auf $[0, \frac{1}{2}]$, die Amplitude ist $\sqrt{2}$. In (d) liegt er auf $[1, 3]$, die Amplitude ist $1/\sqrt{2}$. Gestrichelt die Werte ± 1. In allen vier Fällen ist das Produkt aus Trägerlänge und quadrierter Amplitude gleich eins (Bemerkung 3.5).

Beispiel 3.7 (Ein Testsignal mit zwei Frequenzen)**.** Betrachtet wird

$$f(t) = \begin{cases} 1 - \cos(2\pi t), & 0 \le t \le 3, \\ \frac{1}{2}\big(1 - \cos(10\pi t)\big), & 4 \le t \le 5, \\ 0, & \text{sonst.} \end{cases}$$

Die Funktion $\cos(2\pi\nu t)$ hat die Periode $1/\nu$, sie schwingt also mit der Frequenz ν. Auf $[0, 3]$ schwingt f daher mit der Frequenz 1, auf $[4, 5]$ mit der Frequenz 5 (Abbildung 3.4). Wir vergleichen, was Fourier- und Wavelet-Transformation über f aussagen.

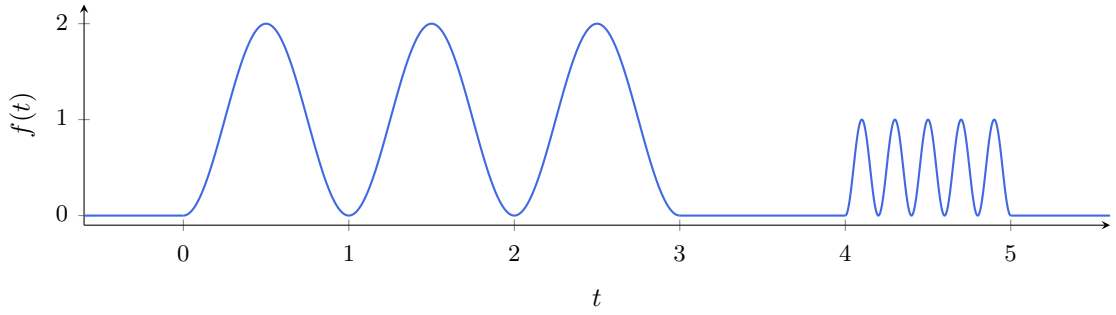


Abbildung 3.4.: Das Signal f aus Beispiel 3.7.

Fourier-Transformierte. Abbildung 3.5 zeigt $|\hat{f}|$. Die geschlossene Form ist (A.2) in Anhang A.2. Zur Frequenz ν gehört die Stelle $\omega = 2\pi\nu$. Daher erscheinen beide Frequenzen als Maxima nahe $\pm 2\pi$ und $\pm 10\pi$. Wann sie auftreten, ist $|\hat{f}|$ nicht zu entnehmen.

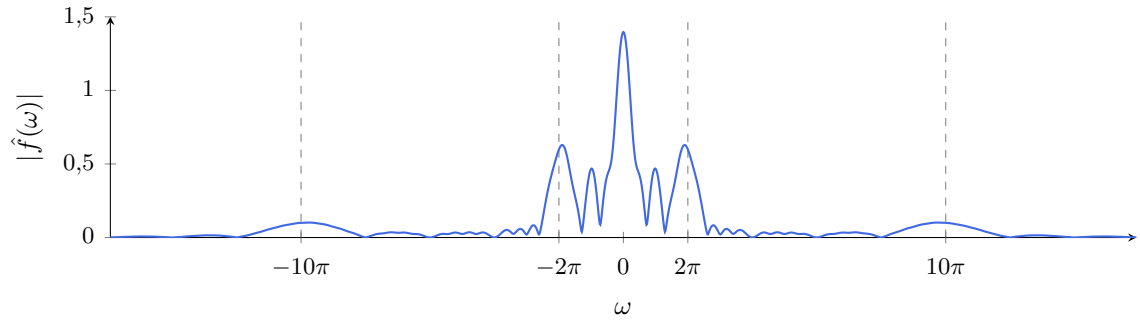


Abbildung 3.5.: Betragsspektrum $|\hat{f}(\omega)|$ des Testsignals. Gestrichelt die Stellen $\pm 2\pi$ und $\pm 10\pi$ (Code in Anhang B.1).

Wavelet-Transformierte. Wir verwenden das Haar-Wavelet und beschränken uns auf $a > 0$. Dann ist $|a|^{1/2} = \sqrt{a}$. Da ψ^{H} reell ist, entfällt die Konjugation in (3.4), und es gilt

$$W_{\psi^{\mathrm{H}}} f(a, b) = \frac{1}{\sqrt{a}} \int_{\mathbb{R}} f(t)\, \psi^{\mathrm{H}}\Big(\frac{t - b}{a}\Big)\, dt.$$

Das Fenster $[b,\, b+a[$ hat die Breite a. Auf seiner linken Hälfte $[b,\, b+\frac{a}{2}[$ ist $\psi^{\mathrm{H}}\left(\frac{t-b}{a}\right) = 1$, auf der rechten Hälfte $[b+\frac{a}{2},\, b+a[$ ist es -1, sonst null. Also ist

$$W_{\psi^{\mathrm{H}}} f(a,b) = \frac{1}{\sqrt{a}} \left(\int_b^{b+a/2} f(t)\,dt - \int_{b+a/2}^{b+a} f(t)\,dt \right).$$

Der Wert ist groß, wenn sich die Integrale über die beiden Fensterhälften stark unterscheiden. Ist f auf dem Fenster nahezu konstant, ist er nahe null. Mit der Stammfunktion $F(t) := \int_{-\infty}^{t} f(s)\,ds$ (Anhang A.3) folgt die geschlossene Form

$$W_{\psi^{\mathrm{H}}} f(a,b) = \frac{2F\left(b+\frac{a}{2}\right) - F(b) - F(b+a)}{\sqrt{a}}. \tag{3.5}$$

Abbildung 3.6 zeigt ihren Betrag.

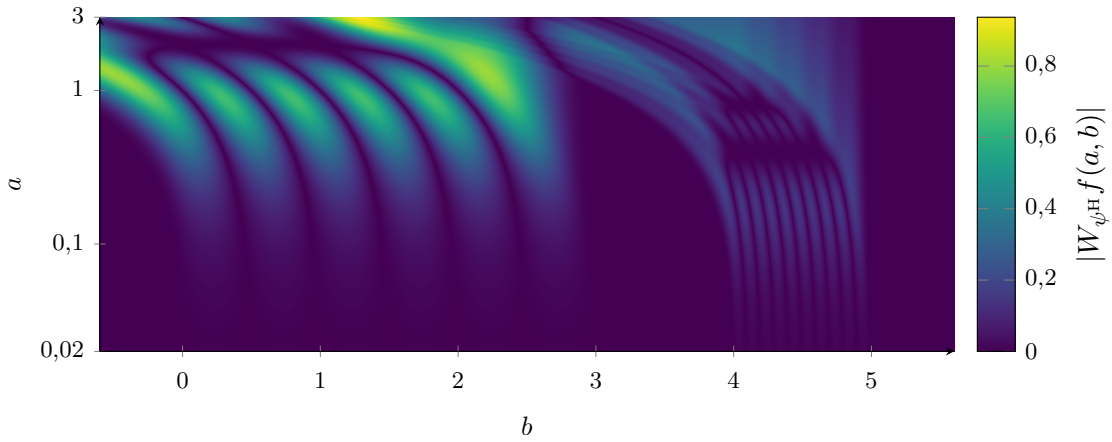


Abbildung 3.6.: Betrag $|W_{\psi^{\mathrm{H}}} f(a,b)|$ des Testsignals nach (3.5). Waagerecht ist die Verschiebung b aufgetragen, senkrecht die Skala a in logarithmischer Teilung. Die Farbe gibt den Betrag an (Code in Anhang B.1).

Kleine a gehören zu hohen Frequenzen, also schnellen Schwingungen, große a zu tiefen Frequenzen, also langsamen Schwingungen [Bla03, Kap. 1.5]. Genau das zeigt Abbildung 3.6. Die langsame Schwingung über $[0,3]$ liefert große Werte bei großen a, die schnelle über $[4,5]$ bei kleinen a. Die Wavelet-Transformation zeigt also gleichzeitig, wann und mit welcher Frequenz f schwingt.

3.1.3. Die Plancherel-Formel

Dieser Abschnitt zeigt, dass bei der CWT keine Information verloren geht, sie aber viel mehr Werte liefert als nötig. Das begründet den Übergang zum dyadischen Gitter in Abschnitt 3.2.

Für die Fourier-Transformation gilt $\|\hat{f}\|_{L^2(\mathbb{R})} = \|f\|_{L^2(\mathbb{R})}$ (Satz 2.12). Für die CWT gilt eine ähnliche Formel.

Satz 3.8 (Plancherel-Formel für die CWT, [Bla03, Satz (3.3)]). *Sei ψ ein Wavelet mit Zulässigkeitskonstante C_ψ gemäß (3.1). Dann gilt für jedes $f \in L^2(\mathbb{R})$*

$$\int_{\mathbb{R}^*_\square} |W_\psi f(a,b)|^2 \, \frac{da\,db}{a^2} \;=\; C_\psi \, \|f\|^2_{L^2(\mathbb{R})}. \tag{3.6}$$

Der Beweis steht bei [Bla03, Satz (3.3)]. Links steht das Integral über $|W_\psi f|^2$ auf der (a,b)-Ebene, gewichtet mit a^{-2}. Es ist bis auf den Faktor C_ψ gleich $\|f\|^2_{L^2(\mathbb{R})}$. Das Gewicht a^{-2} wird in Abschnitt 3.2 aufgegriffen.

Daraus folgt, dass f durch $W_\psi f$ eindeutig bestimmt ist [Bla03, Satz (3.3)]. Ist nämlich $W_\psi f = W_\psi g$, so ist $W_\psi(f-g) = 0$. Nach (3.6) folgt $\|f-g\|_{L^2(\mathbb{R})} = 0$, also $f = g$.

Bemerkung 3.9 (Redundanz der CWT). Da f durch $W_\psi f$ eindeutig bestimmt ist, geht bei der CWT keine Information verloren. Blatter gibt auch eine Formel an, mit der sich f aus $W_\psi f$ zurückgewinnen lässt [Bla03, Kap. 3.3]. Die Werte $W_\psi f(a,b)$ sind aber nicht frei. Nicht jede Funktion auf $\mathbb{R}^*_\square$ ist die Transformierte eines Signals [Bla03, Kap. 3.4]. Diese Eigenschaft heißt Redundanz. Anschaulich hängt f von einer Variablen ab, $W_\psi f$ von zweien.

Im Endlichdimensionalen sieht man das direkt. Für ein Signal $x \in \mathbb{R}^N$ liefern N Skalen und N Verschiebungen N^2 Koeffizienten. Jeder ist ein Skalarprodukt mit x. Zusammengefasst gilt daher $c = Ax$ mit einer Matrix $A \in \mathbb{R}^{N^2 \times N}$. Der Vektor c liegt also in einem Teilraum des $\mathbb{R}^{N^2}$ der Dimension höchstens N.

Das Thresholding in Kapitel 5 arbeitet dagegen mit den Koeffizienten bezüglich einer Orthonormalbasis [Mal09, Kap. 11.2]. Gesucht ist daher eine abzählbare Auswahl von Parametern (a,b), für die $\{\psi_{a,b}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ ist.

3.2. Das dyadische Gitter und die Multiskalenanalyse

Einen Anhaltspunkt für die Wahl der Punkte gibt die Plancherel-Formel (3.6). Dort geht jeder Punkt (a,b) mit dem Gewicht a^{-2} ein. Ersetzt man das Integral durch eine Summe über Gitterpunkte, sollte jeder Gitterpunkt eine Zelle mit gleichem Gewicht vertreten [Bla03, Kap. 4.3].

Das leistet das Gitter $a = 2^j$, $b = k2^j$ mit $j,k \in \mathbb{Z}$. Der Punkt $(2^j, k2^j)$ vertritt die Zelle

$$Z_{j,k} := [2^j,\, 2^{j+1}] \times [k2^j,\, (k+1)2^j].$$

In a reicht sie über eine Verdopplung der Skala, in b über die Länge 2^j. Für ihr Gewicht gilt

$$\int_{k2^j}^{(k+1)2^j} \int_{2^j}^{2^{j+1}} \frac{da\,db}{a^2} \;=\; 2^j\Big(\frac{1}{2^j} - \frac{1}{2^{j+1}}\Big) \;=\; \frac{1}{2}. \tag{3.7}$$

Das Gewicht hängt weder von j noch von k ab (Abbildung 3.7). Ob die zugehörigen Funktionen $\psi_{2^j,k2^j}$ eine Orthonormalbasis bilden, hängt aber von ψ ab.

Definition 3.10 (Dyadische Wavelet-Familie, [Bla03, Kap. 5.1]). Sei ψ ein Wavelet. Auf dem dyadischen Gitter $\{(2^j, k2^j) : j,k \in \mathbb{Z}\}$ sei

$$\psi_{j,k}(t) \;:=\; \psi_{2^j,\,k2^j}(t) \;=\; 2^{-j/2}\,\psi\Big(\frac{t}{2^j} - k\Big), \qquad j,k \in \mathbb{Z}. \tag{3.8}$$

Kleineres j gehört zur feineren Skala.[1]

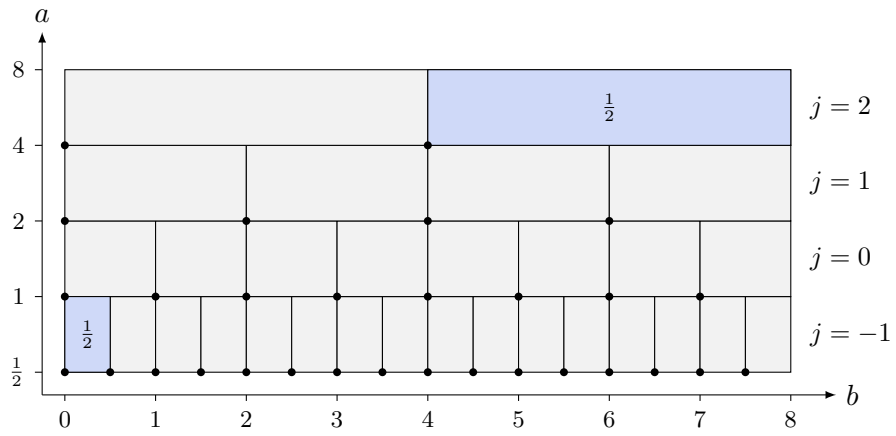


Abbildung 3.7.: Das dyadische Gitter. Die Skala a ist logarithmisch aufgetragen. Dabei zählt j die Skala $a = 2^j$ und k die Verschiebung $b = k2^j$. Jeder Punkt $(2^j, k2^j)$ vertritt die Zelle $Z_{j,k}$ rechts oberhalb von ihm. Hervorgehoben sind $Z_{-1,0} = [\frac{1}{2}, 1] \times [0, \frac{1}{2}]$ und $Z_{2,1} = [4, 8] \times [4, 8]$. Ihre gewöhnlichen Flächen sind $\frac{1}{4}$ und 16. Ihr Gewicht ist nach (3.7) in beiden Fällen $\frac{1}{2}$.

Ein Wavelet ψ, für das $\{\psi_{j,k}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ ist, lässt sich direkt schwer finden. Die Multiskalenanalyse beschreibt deshalb zuerst, wie ein Signal auf verschiedenen Skalen vergröbert wird. Das Wavelet ergibt sich aus dem Übergang zwischen zwei benachbarten Skalen [Bla03, Kap. 5.1]. Das folgende Beispiel zeigt das am Haar-Wavelet.

Beispiel 3.11 (Mittelwerte und Details, [LMR98, Kap. 2.2.1]). Sei $V_j \subset L^2(\mathbb{R})$ der Raum der Funktionen, die auf jedem Intervall $I_{j,k} := [k2^j, (k+1)2^j[$ konstant sind. Die Orthogonalprojektion P_j auf V_j ersetzt f auf jedem $I_{j,k}$ durch den Mittelwert $2^{-j} \int_{I_{j,k}} f(t)\,dt$ [HB09, Satz 43.1]. Wir betrachten die Treppenfunktion

$$f \;=\; 4 \cdot \mathbf{1}_{[0,1[} + 2 \cdot \mathbf{1}_{[1,2[} + 5 \cdot \mathbf{1}_{[2,3[} + 7 \cdot \mathbf{1}_{[3,4[} \;\in\; V_0$$

und schreiben kurz $f = (4, 2, 5, 7)$ (Abbildung 3.8).

Mittelung über je zwei benachbarte Intervalle liefert $P_1 f = (3, 3, 6, 6)$. Dabei geht $f - P_1 f = (1, -1, -1, 1)$ verloren. Mit dem Haar-Wavelet ist das

$$(f - P_1 f)(t) \;=\; \psi^{\mathrm{H}}\big(\tfrac{t}{2}\big) - \psi^{\mathrm{H}}\big(\tfrac{t}{2} - 1\big).$$

Nochmalige Mittelung liefert $P_2 f = (4{,}5,\ 4{,}5,\ 4{,}5,\ 4{,}5)$. Dabei geht $(P_1 f - P_2 f)(t) = -1{,}5\,\psi^{\mathrm{H}}\big(\frac{t}{4}\big)$ verloren. Insgesamt ist

$$f(t) \;=\; 4{,}5 \cdot \mathbf{1}_{[0,4[}(t) \;-\; 1{,}5\,\psi^{\mathrm{H}}\big(\tfrac{t}{4}\big) \;+\; \psi^{\mathrm{H}}\big(\tfrac{t}{2}\big) \;-\; \psi^{\mathrm{H}}\big(\tfrac{t}{2} - 1\big).$$

Die vier Werte von f sind durch vier andere Zahlen ersetzt: den Mittelwert $4{,}5$, ein grobes Detail $-1{,}5$ und zwei feine Details 1 und -1. Aus ihnen lässt sich f exakt zurückgewinnen. Die Normierungsfaktoren $2^{-j/2}$ aus (3.8) sind hier weggelassen.

[1] Diese Konvention folgt Blatter und Louis/Maaß/Rieder. Hanke-Bourgeois zählt umgekehrt [HB09, § 56].

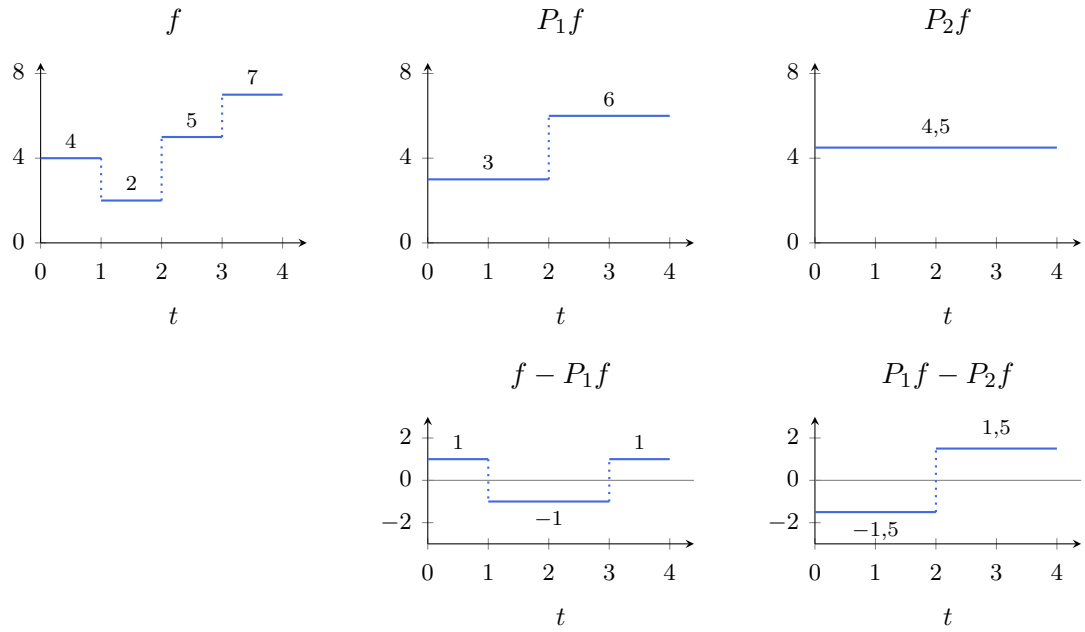


Abbildung 3.8.: Die Treppenfunktion $f = (4, 2, 5, 7)$ aus Beispiel 3.11 mit Stufenbreite 1 und ihre Mittelungen $P_1 f$ und $P_2 f$ mit Stufenbreite 2 und 4 (oben). Darunter das Detail, das beim Übergang zu der jeweiligen Mittelung verloren geht. Alle Teilbilder haben denselben vertikalen Maßstab.

Im Beispiel liegen die Räume V_j ineinander und gehen durch Mittelung auseinander hervor. Die folgende Definition fasst die Eigenschaften zusammen, auf die es dabei ankommt.

Definition 3.12 (Multiskalenanalyse, [Bla03, Kap. 5.1, (a)–(c)]). Eine Multiskalenanalyse (MSA) von $L^2(\mathbb{R})$ ist eine Folge $(V_j)_{j\in\mathbb{Z}}$ abgeschlossener Teilräume von $L^2(\mathbb{R})$ mit folgenden Eigenschaften:

(M1) (Schachtelung) $\cdots \subset V_2 \subset V_1 \subset V_0 \subset V_{-1} \subset V_{-2} \subset \cdots \subset L^2(\mathbb{R})$,

(M2) (Separation) $\bigcap_{j\in\mathbb{Z}} V_j = \{0\}$,

(M3) (Vollständigkeit) $\overline{\bigcup_{j\in\mathbb{Z}} V_j} = L^2(\mathbb{R})$,

(M4) (Skalierung) Für alle $j \in \mathbb{Z}$ gilt: $f \in V_j$ genau dann, wenn die Funktion $t \mapsto f(2^j t)$ in V_0 liegt,

(M5) (Erzeugende Funktion) Es gibt ein $\varphi \in L^2(\mathbb{R}) \cap L^1(\mathbb{R})$,[2] sodass die Funktionen $t \mapsto \varphi(t-k)$, $k \in \mathbb{Z}$, eine Orthonormalbasis von V_0 bilden.

Die Funktion φ heißt Skalierungsfunktion der MSA.

Bemerkung 3.13 (Zu den Axiomen, [Bla03, Kap. 5.1]). (a) (M1)–(M3): Je kleiner j, desto feinere Strukturen enthält V_j. Anschaulich geht V_j für $j \to -\infty$ gegen ganz $L^2(\mathbb{R})$ und für $j \to +\infty$ gegen $\{0\}$. Genau formuliert wird das durch (M3) und (M2) [LMR98, Bem. 2.2.2].

(b) (M4): Die V_j sind skalierte Kopien desselben Raumes V_0. Deshalb genügt eine einzige Skalierungsfunktion φ, um alle V_j festzulegen.

(c) (M5): Das Axiom liefert eine Orthonormalbasis, allerdings nur für den Grundraum V_0 [Bla03, Kap. 5.1, (c)]. Zusammen mit (M4) überträgt sie sich auf alle V_j (Satz 3.16).[3]

Beispiel 3.14 (Die Haar-MSA, [Bla03, Kap. 5.1, Beispiel 1]). Die Räume V_j aus Beispiel 3.11 bilden eine MSA mit der Skalierungsfunktion $\varphi := \mathbf{1}_{[0,1[}$. Die Skalierungsfunktion ist also eine einzelne Stufe und nicht das Haar-Wavelet. Die Axiome lassen sich einzeln prüfen.

- (M1): Eine Treppe der Stufenbreite 2^j ist auch eine Treppe der Stufenbreite 2^{j-1}.
- (M2): Liegt f in allen V_j, so ist f auf $[0, 2^j[$ für jedes j konstant, also auf $[0,\infty[$. In $L^2(\mathbb{R})$ geht das nur für $f = 0$. Dasselbe gilt auf $]-\infty, 0[$.
- (M3): Treppenfunktionen mit Sprungstellen der Form $k2^j$ liegen dicht in $L^2(\mathbb{R})$ [Bla03, Kap. 5.1]. Ein Beispiel: $\mathbf{1}_{[0,1/3[}$ springt bei $\frac{1}{3}$ und liegt daher in keinem V_j. Die Funktion $\mathbf{1}_{[0,5/16[}$ springt bei $\frac{5}{16} = 5 \cdot 2^{-4}$ und liegt in V_{-4}. Der Fehler ist

$$\|\mathbf{1}_{[0,1/3[} - \mathbf{1}_{[0,5/16[}\|^2_{L^2(\mathbb{R})} = \int_{5/16}^{1/3} 1\, dt = \tfrac{1}{3} - \tfrac{5}{16} = \tfrac{1}{48}.$$

[2] Die Forderung $\varphi \in L^1(\mathbb{R})$ folgt Blatter. Sie sichert, dass $\hat{\varphi}$ stetig ist. Das wird für (4.2) gebraucht.

[3] Louis, Maaß und Rieder verlangen in (M5) nur eine Riesz-Basis [LMR98, Def. 2.2.1]. Wir folgen Blatter und fordern eine Orthonormalbasis.

Mit feineren Stufen wird er beliebig klein.

- (M4): f ist genau dann auf allen Intervallen $[k2^j, (k+1)2^j[$ konstant, wenn $t \mapsto f(2^j t)$ auf allen Intervallen $[k, k+1[$ konstant ist. Etwa ist $f = \mathbf{1}_{[0,2[} \in V_1$. Für $g(t) := f(2t)$ gilt $g(t) = 1$ genau für $0 \le 2t < 2$, also für $0 \le t < 1$. Somit ist $g = \mathbf{1}_{[0,1[} \in V_0$.
- (M5): Die Verschiebungen $\varphi(t-k) = \mathbf{1}_{[k,k+1[}(t)$ haben disjunkte Träger und Norm 1. Sie sind also orthonormal. Etwa ist $f(t) = 4\varphi(t) + 2\varphi(t-1) + 5\varphi(t-2) + 7\varphi(t-3)$.

In Beispiel 3.11 entsteht jede gröbere Näherung $P_{j+1}f$ durch Mittelung aus $P_j f$. Das entspricht der Schachtelung (M1). Was bei der Mittelung verloren geht, sind Vielfache gestreckter und verschobener Haar-Wavelets [LMR98, Kap. 2.2.1]. Diese Unterschiede werden in Abschnitt 3.4 als Detailräume W_j gefasst. Aus vier Werten werden wieder vier Koeffizienten. Die Zerlegung ist also frei von der Redundanz aus Bemerkung 3.9.

3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j

In diesem Abschnitt wird die Basis aus (M5) auf alle Skalen übertragen (Satz 3.16). Außerdem wird gezeigt, dass die Orthogonalprojektionen P_j für $j \to -\infty$ gegen die Identität und für $j \to +\infty$ gegen null streben (Proposition 3.19). Normen ohne Index sind im Folgenden Normen in $L^2(\mathbb{R})$.

3.3.1. Die Orthonormalbasis auf allen Skalen

Definition 3.15 (Dilatationsoperator, [LMR98, Kap. 1.2]). Für $a \in \mathbb{R}^*$ heißt $D_a \colon L^2(\mathbb{R}) \to L^2(\mathbb{R})$,

$$(D_a f)(t) \;:=\; |a|^{-1/2}\, f\left(\frac{t}{a}\right), \qquad t \in \mathbb{R},$$

der Dilatationsoperator.

D_a ist linear. Mit der Substitution aus Bemerkung 3.5 für $b = 0$ folgt $\|D_a f\|_{L^2(\mathbb{R})} = \|f\|_{L^2(\mathbb{R})}$ für alle $f \in L^2(\mathbb{R})$. Außerdem ist D_a surjektiv. Für $g \in L^2(\mathbb{R})$ ist nämlich $(D_{1/a}\, g)(t) = |a|^{1/2}\, g(at)$ und daher $D_a(D_{1/a}\, g) = g$. Also ist D_a unitär (Definition 2.8) [LMR98, Kap. 1.2].

Nach (M4) liegt h genau dann in V_0, wenn die Funktion $t \mapsto h(t/2^j)$ in V_j liegt. Der Faktor $2^{-j/2}$ in D_{2^j} ändert daran nichts, da V_0 und V_j Teilräume sind. Daher gilt

$$V_j \;=\; D_{2^j}(V_0) \;=\; \{D_{2^j} h : h \in V_0\} \qquad \text{für alle } j \in \mathbb{Z} \tag{3.9}$$

[Bla03, Kap. 5.1, (b)].

Satz 3.16 (Orthonormalbasis von V_j, [Bla03, Kap. 5.1]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ. Mit*

$$\varphi_{j,k}(t) \;:=\; 2^{-j/2}\, \varphi\left(\frac{t}{2^j} - k\right), \qquad j, k \in \mathbb{Z}, \tag{3.10}$$

ist $\{\varphi_{j,k} : k \in \mathbb{Z}\}$ für jedes feste $j \in \mathbb{Z}$ eine Orthonormalbasis von V_j.

Ein unitärer Operator erhält Skalarprodukte [Ser17, Übung 27.2]. Für die Basisfunktionen von V_0 gilt

$$D_{2^j}\big[\varphi(t-k)\big] \;=\; 2^{-j/2}\,\varphi\!\left(\frac{t}{2^j}-k\right) \;=\; \varphi_{j,k}(t).$$

Nach (3.9) bildet D_{2^j} den Raum V_0 bijektiv auf V_j ab. Daher geht die Orthonormalbasis $\{\varphi(t-k)\}_k$ von V_0 in eine Orthonormalbasis $\{\varphi_{j,k}\}_k$ von V_j über [Ser17, Def. 27.7, Satz 25.18]. Das beweist den Satz.

3.3.2. Die Approximationsoperatoren

Definition 3.17 (Approximationsoperator, [LMR98, Bem. 2.2.2 (a)]). Für $f \in L^2(\mathbb{R})$ und $j \in \mathbb{Z}$ heißen $a_{j,k} := \langle f, \varphi_{j,k}\rangle$, $k \in \mathbb{Z}$, die Approximationskoeffizienten von f auf der Skala j. Die Abbildung $P_j\colon L^2(\mathbb{R}) \to V_j$,

$$P_j f \;:=\; \sum_{k\in\mathbb{Z}} a_{j,k}\,\varphi_{j,k}, \tag{3.11}$$

heißt Approximationsoperator.

Da $\{\varphi_{j,k}\}_k$ eine Orthonormalbasis von V_j ist, konvergiert (3.11) in $L^2(\mathbb{R})$, und es gilt $\|P_j f\|^2_{L^2(\mathbb{R})} = \sum_k |a_{j,k}|^2$ [Ser17, Satz 25.18].

Außerdem steht der Fehler $f - P_j f$ senkrecht auf jeder Basisfunktion $\varphi_{j,l}$. Wegen der Orthonormalität ist nämlich

$$\langle f - P_j f, \varphi_{j,l}\rangle \;=\; \langle f, \varphi_{j,l}\rangle - \sum_{k\in\mathbb{Z}} a_{j,k}\,\langle \varphi_{j,k}, \varphi_{j,l}\rangle \;=\; a_{j,l} - a_{j,l} \;=\; 0.$$

Also ist P_j die Orthogonalprojektion auf V_j. Daher ist $P_j f$ die beste Näherung von f in V_j, das heißt $\|f - P_j f\|_{L^2(\mathbb{R})} \le \|f - g\|_{L^2(\mathbb{R})}$ für alle $g \in V_j$ [HB09, Satz 31.6].

Beispiel 3.18 (Approximation in der Haar-MSA, [LMR98, Kap. 2.2]). Für die Haar-MSA ist $\varphi_{j,k} = 2^{-j/2}\,\mathbf{1}_{I_{j,k}}$ mit $I_{j,k} := [k2^j, (k+1)2^j[$. Dann ist $a_{j,k} = \langle f, \varphi_{j,k}\rangle = 2^{-j/2}\int_{I_{j,k}} f(t)\,dt$, also

$$a_{j,k}\,\varphi_{j,k} \;=\; 2^{-j/2}\int_{I_{j,k}} f(t)\,dt \cdot 2^{-j/2}\,\mathbf{1}_{I_{j,k}} \;=\; \Big(\frac{1}{2^j}\int_{I_{j,k}} f(t)\,dt\Big)\,\mathbf{1}_{I_{j,k}}.$$

Da $I_{j,k}$ die Länge 2^j hat, steht in der Klammer der Mittelwert von f auf $I_{j,k}$. P_j ersetzt f also auf jedem $I_{j,k}$ durch diesen Mittelwert. Das ist die Aussage aus Beispiel 3.11.

Proposition 3.19 (Approximationseigenschaft, [LMR98, Bem. 2.2.2 (a)]). *Für jedes $f \in L^2(\mathbb{R})$ gilt*

(a) $\lim\limits_{j\to-\infty} \|P_j f - f\|_{L^2(\mathbb{R})} = 0$ *und* *(b)* $\lim\limits_{j\to+\infty} \|P_j f\|_{L^2(\mathbb{R})} = 0.$

Aussage (a) bedeutet: Auf immer feineren Skalen nähert $P_j f$ jedes Signal beliebig genau an. Aussage (b) bedeutet: Auf immer gröberen Skalen bleibt von jedem Signal nichts übrig. Aussage (a) folgt aus (M3) und daraus, dass $P_j f$ die beste Näherung von f in V_j ist. Nach (M3) gibt es zu jedem $\varepsilon > 0$ ein j_0 und ein $g \in V_{j_0}$ mit $\|f - g\|_{L^2(\mathbb{R})} < \varepsilon$. Wegen (M1) liegt g auch in jedem V_j mit $j \le j_0$, also ist dort $\|f - P_j f\|_{L^2(\mathbb{R})} \le \|f - g\|_{L^2(\mathbb{R})} < \varepsilon$. Aussage (b) folgt aus (M2) [Bla03, Prop. (5.1)].

3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$

Wegen $V_j \subset V_{j-1}$ sind die Basen verschiedener V_j nicht zueinander orthogonal. Man betrachtet deshalb nur den Zuwachs beim Übergang zur nächstfeineren Skala [Bla03, Kap. 5.1].

Definition 3.20 (Detailräume, [Bla03, Kap. 5.1, Gl. (8)]). Für $j \in \mathbb{Z}$ sei W_j das orthogonale Komplement von V_j in V_{j-1},

$$V_{j-1} \;=\; V_j \oplus W_j, \qquad W_j \perp V_j, \tag{3.12}$$

und $Q_j := P_{j-1} - P_j$.

Q_j ist die Orthogonalprojektion auf W_j [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.9)]. Denn $Q_j f = (f - P_j f) - (f - P_{j-1} f)$ liegt in V_{j-1}, und beide Klammern stehen senkrecht auf V_j. Also liegt $Q_j f$ in W_j. Ferner steht $f - Q_j f = (f - P_{j-1} f) + P_j f$ senkrecht auf W_j.

Da D_{2^j} unitär ist und nach (3.9) V_0 auf V_j und V_{-1} auf V_{j-1} abbildet, gilt

$$W_j \;=\; D_{2^j}(W_0) \qquad \text{für alle } j \in \mathbb{Z} \tag{3.13}$$

[Bla03, Kap. 5.1, Gl. (9)]. Für $i > j$ ist $W_i \subset V_{i-1}$ nach (3.12) und $V_{i-1} \subset V_j$ nach (M1). Da $V_j \perp W_j$ gilt, folgt $W_i \perp W_j$. Die Detailräume sind also paarweise orthogonal [Bla03, Prop. (5.1)].

Satz 3.21 (Zerlegung von $L^2(\mathbb{R})$ in Detailräume, [Bla03, Prop. (5.1)]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Detailräumen W_j. Dann gilt*

$$L^2(\mathbb{R}) \;=\; \bigoplus_{j\in\mathbb{Z}} W_j \tag{3.14}$$

als orthogonale direkte Summe. Für jedes $f \in L^2(\mathbb{R})$ ist $f = \sum_{j\in\mathbb{Z}} Q_j f$ und

$$\|f\|^2_{L^2(\mathbb{R})} \;=\; \sum_{j\in\mathbb{Z}} \|Q_j f\|^2_{L^2(\mathbb{R})}. \tag{3.15}$$

Für jedes feste $J \in \mathbb{Z}$ gilt ferner

$$L^2(\mathbb{R}) \;=\; V_J \oplus \Big(\bigoplus_{j\le J} W_j\Big), \qquad f \;=\; P_J f + \sum_{j\le J} Q_j f. \tag{3.16}$$

Nach Definition von Q_j ist $\sum_{j=J_1+1}^{J_2} Q_j f = P_{J_1} f - P_{J_2} f$. Nach Proposition 3.19 strebt das für $J_1 \to -\infty$ und $J_2 \to +\infty$ gegen f. Mit $J_2 = J$ folgt (3.16). Gleichung (3.15) folgt aus der Orthogonalität der Summanden [Bla03, Prop. (5.1)], [LMR98, Gl. (2.2.11), (2.2.12)].

In der Anwendung wird die endliche Fassung (3.16) benutzt [LMR98, Kap. 2.2].

3.4.1. Die Wavelet-Basis

Nach Satz 3.21 ist $L^2(\mathbb{R})$ die orthogonale Summe der W_j. Für eine Orthonormalbasis von $L^2(\mathbb{R})$ braucht man also eine Orthonormalbasis jedes W_j. Wegen (3.13) genügt eine Orthonormalbasis von W_0. Sie soll wie in (M5) aus den Verschiebungen einer einzigen Funktion ψ bestehen [Bla03, Kap. 5.1]. Dass es ein solches ψ gibt, wird später in Satz 4.5 gezeigt. Im Haar-Fall ist es ψ^{H} (Beispiel 3.11).

Korollar 3.22 (Wavelet-Basis, [Bla03, Kap. 5.1]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA, und sei $\psi \in L^2(\mathbb{R})$ so, dass die Funktionen $t \mapsto \psi(t-k)$, $k \in \mathbb{Z}$, $t \in \mathbb{R}$, eine Orthonormalbasis von W_0 bilden. Mit $\psi_{j,k}$ wie in (3.8) gilt:*

(i) Für jedes feste $j \in \mathbb{Z}$ ist $\{\psi_{j,k} : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_j.

(ii) Die Familie

$$\{\psi_{j,k} : j,k \in \mathbb{Z}\} \tag{3.17}$$

ist eine Orthonormalbasis von $L^2(\mathbb{R})$, die Wavelet-Basis der MSA.

(iii) Mit den Detailkoeffizienten $d_{j,k} := \langle f, \psi_{j,k}\rangle$ gilt für jedes $f \in L^2(\mathbb{R})$ und jedes $J \in \mathbb{Z}$

$$\begin{aligned} f &= \sum_{k\in\mathbb{Z}} a_{J,k}\,\varphi_{J,k} + \sum_{j\le J}\sum_{k\in\mathbb{Z}} d_{j,k}\,\psi_{j,k}, \\ \|f\|^2_{L^2(\mathbb{R})} &= \sum_{k\in\mathbb{Z}} |a_{J,k}|^2 + \sum_{j\le J}\sum_{k\in\mathbb{Z}} |d_{j,k}|^2. \end{aligned} \tag{3.18}$$

Aussage (i) folgt wie Satz 3.16 aus (3.13). Nach (i) ist $Q_j f = \sum_k d_{j,k}\,\psi_{j,k}$. Damit folgen (ii) und (iii) aus Satz 3.21 und (3.11) [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.13)].

Beispiel 3.23 (Wavelet-Koeffizienten der Treppenfunktion). Wir zerlegen $f = (4,2,5,7)$ aus Beispiel 3.11 in der Haar-Wavelet-Basis [LMR98, Kap. 2.2]. Die Funktion $\psi_{j,k}$ ist auf der linken Hälfte von $I_{j,k}$ gleich $2^{-j/2}$ und auf der rechten gleich $-2^{-j/2}$. Daher ist $d_{j,k}$ das $2^{-j/2}$-Fache der Differenz der Integrale von f über die beiden Hälften. Für $J = 2$ erhält man

$$\begin{aligned} a_{2,0} &= \tfrac{1}{2}(4+2+5+7) = 9, & d_{2,0} &= \tfrac{1}{2}\big((4+2)-(5+7)\big) = -3, \\ d_{1,0} &= \tfrac{1}{\sqrt{2}}(4-2) = \sqrt{2}, & d_{1,1} &= \tfrac{1}{\sqrt{2}}(5-7) = -\sqrt{2}. \end{aligned}$$

Alle übrigen Koeffizienten mit $j \le 2$ verschwinden. Für $j \le 0$ liegt $I_{j,k}$ in einem Intervall $[n, n+1[$, auf dem f konstant ist. Das Integral von $\psi_{j,k}$ über einer Konstanten ist null. Für $j = 1$ und $j = 2$ trifft $I_{j,k}$ nur für die angegebenen k das Intervall $[0,4[$. Nach (3.18) ist

$$f \;=\; 9\,\varphi_{2,0} \;-\; 3\,\psi_{2,0} \;+\; \sqrt{2}\,\psi_{1,0} \;-\; \sqrt{2}\,\psi_{1,1}, \qquad \|f\|^2_{L^2(\mathbb{R})} \;=\; 81+9+2+2 \;=\; 94.$$

Bis auf den Faktor $2^{j/2}$ sind das die Zahlen $4{,}5$, $-1{,}5$, 1 und -1 aus Beispiel 3.11.

Zwei Beobachtungen verbinden das Beispiel mit den folgenden Kapiteln. Erstens ist nach Definition 3.10 $\psi_{j,k} = \psi_{2^j,k2^j}$, also nach (3.4)

$$d_{j,k} \;=\; \langle f, \psi_{2^j,k2^j}\rangle \;=\; W_\psi f(2^j, k2^j).$$

Die Detailkoeffizienten sind also Werte der CWT auf dem dyadischen Gitter, aber ohne Redundanz.

Zweitens bleibt $9\,\varphi_{2,0} - 3\,\psi_{2,0} = P_1 f = (3,3,6,6)$, wenn man die beiden betragskleinsten Koeffizienten $d_{1,0}$ und $d_{1,1}$ auf null setzt. Nach (3.18) ist der Fehler $\|f - P_1 f\|^2_{L^2(\mathbb{R})} = 2+2 = 4$, die Summe der Quadrate der gestrichenen Koeffizienten. Allgemein ist der Fehler die Summe der Quadrate der Änderungen. Welche Koeffizienten man streicht oder verändert, lässt sich also im Koeffizientenraum entscheiden. Darauf beruht die Entrauschung in Kapitel 5.

Gleichung (3.18) ist der Ausgangspunkt der folgenden Kapitel. Kapitel 4 konstruiert ψ und berechnet die Koeffizienten allein durch Filteroperationen.

4. Konstruktion der diskreten Wavelet-Transformation

Kapitel 3 endete mit einer bedingten Aussage. Bilden die Verschiebungen $\psi_{0,k}(t) = \psi(t-k)$, $k \in \mathbb{Z}$, einer Funktion ψ eine Orthonormalbasis von W_0, so ist $\{\psi_{j,k} : j,k \in \mathbb{Z}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ (Korollar 3.22). Dieses Kapitel konstruiert ein solches Wavelet ψ und beantwortet dabei drei Fragen.

1. Wie erhält man ψ aus der Skalierungsfunktion φ? (Abschnitte 4.1 und 4.2)
2. Wie berechnet man die Koeffizienten $a_{j,k}$ und $d_{j,k}$, ohne für jeden ein eigenes Integral auszuwerten? (Abschnitt 4.3)
3. Nach welchen Kriterien wählt man das Wavelet? (Abschnitt 4.4)

Abschnitt 4.5 deutet die Filter außerdem im Frequenzbereich. Damit ordnet Kapitel 6 den Stufen der Transformation Frequenzbänder zu. Als Beispiele dienen das Haar-Wavelet aus Kapitel 3, das Daubechies-Wavelet mit vier Koeffizienten, mit dem Kapitel 5 rechnet, und das Daubechies-Wavelet mit zwölf Koeffizienten, das Kapitel 6 verwendet.

4.1. Die Skalierungsgleichung

In diesem Abschnitt wird die Skalierungsfunktion φ durch eine Zahlenfolge (h_k) beschrieben. Wir betrachten nur reellwertige Skalierungsfunktionen.

Nach (M1) ist $\varphi \in V_0 \subset V_{-1}$, und nach Satz 3.16 bilden die Funktionen $\varphi_{-1,k}(t) = \sqrt{2}\,\varphi(2t-k)$ eine Orthonormalbasis von V_{-1}. Also lässt sich φ in dieser Basis darstellen:

$$\varphi = \sum_{k\in\mathbb{Z}} \langle \varphi, \varphi_{-1,k}\rangle\, \varphi_{-1,k}.$$

Wegen $\varphi(2t-k) = \varphi\big(2(t-k/2)\big)$ ist jede Funktion $\varphi(2t-k)$ eine um den Faktor 2 gestauchte und um $k/2$ verschobene Kopie von φ. Die Skalierungsfunktion setzt sich also aus schmaleren Kopien ihrer selbst zusammen.

Satz 4.1 (Skalierungsgleichung, vgl. [LMR98, Lemma 2.2.3]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ, und sei $h_k := \langle \varphi, \varphi_{-1,k}\rangle$. Dann gilt $\varphi = \sum_{k\in\mathbb{Z}} h_k\, \varphi_{-1,k}$, also*

$$\varphi(t) \;=\; \sqrt{2}\sum_{k\in\mathbb{Z}} h_k\, \varphi(2t-k), \qquad \sum_{k\in\mathbb{Z}} h_k^2 \;=\; 1. \tag{4.1}$$

Die Folge (h_k) heißt Skalierungsfolge oder Tiefpassfilter der MSA.

Beweis. Nach (M1) liegt φ in V_{-1}, und $\{\varphi_{-1,k}\}_k$ ist nach Satz 3.16 eine Orthonormalbasis von V_{-1}. Die Entwicklung in dieser Basis [Ser17, Satz 25.18 (3)] lautet $\varphi = \sum_k h_k\, \varphi_{-1,k}$. Nach der Parseval-Gleichung [Ser17, Satz 25.18 (5)] ist $\sum_k h_k^2 = \|\varphi\|^2 = 1$, denn nach (M5) ist $\varphi = \varphi_{0,0}$ selbst Element der Orthonormalbasis $\{\varphi_{0,k}\}_k$ von V_0. □

Außerdem gilt

$$\sum_{k\in\mathbb{Z}} h_k \;=\; \sqrt{2} \tag{4.2}$$

[LMR98, Satz 2.2.9].

Beispiel 4.2 (Haar). Für $\varphi = \mathbf{1}_{[0,1[}$ aus Beispiel 3.14 ist $\varphi(2t) = \mathbf{1}_{[0,1/2[}(t)$ und $\varphi(2t-1) = \mathbf{1}_{[1/2,1[}(t)$. Eine Stufe der Breite 1 besteht also aus zwei Stufen der Breite $\frac{1}{2}$:

$$\varphi(t) \;=\; \varphi(2t) + \varphi(2t-1) \;=\; \sqrt{2}\Big(\tfrac{1}{\sqrt{2}}\,\varphi(2t) + \tfrac{1}{\sqrt{2}}\,\varphi(2t-1)\Big).$$

Der Vergleich mit (4.1) liefert $h_0 = h_1 = \frac{1}{\sqrt{2}}$ und $h_k = 0$ sonst. Es ist $\sum_k h_k^2 = \frac{1}{2} + \frac{1}{2} = 1$ und $\sum_k h_k = \frac{2}{\sqrt{2}} = \sqrt{2}$.

4.2. Filterkoeffizienten: Tiefpass und Hochpass

Bisher wurde die Folge (h_k) aus einer gegebenen Skalierungsfunktion gewonnen. Für die Konstruktion neuer Wavelets geht man umgekehrt vor und gibt die Zahlen h_k vor. Dafür muss man wissen, welche Bedingungen eine solche Folge erfüllt. Neben (4.2) übersetzt sich auch die Orthonormalität der Funktionen $\varphi_{0,k}(t) = \varphi(t-k)$ aus (M5) in eine Bedingung an die Folge.

Lemma 4.3 (Orthogonalität der Filterkoeffizienten, [LMR98, Lemma 2.2.8]). *Die Skalierungsfolge (h_k) aus Satz 4.1 erfüllt*

$$\sum_{k\in\mathbb{Z}} h_k\, h_{k+2m} \;=\; \delta_{0,m} \qquad \textit{für alle } m \in \mathbb{Z}. \tag{4.3}$$

Der Beweis steht bei [LMR98, Lemma 2.2.8].

Beispiel 4.4 (Ein Filter der Länge vier). Gesucht seien reelle $h_0, \dots, h_3$ mit $h_k = 0$ für $k \notin \{0,\dots,3\}$. Für $|m| \geq 2$ ist (4.3) dann automatisch erfüllt. Es bleiben

$$\underbrace{h_0 + h_1 + h_2 + h_3 = \sqrt{2}}_{(4.2)}, \qquad \underbrace{h_0^2 + h_1^2 + h_2^2 + h_3^2 = 1}_{m=0}, \qquad \underbrace{h_0 h_2 + h_1 h_3 = 0}_{m=\pm 1}.$$

Drei Gleichungen für vier Unbekannte lassen eine einparametrige Lösungsschar, zu der auch das Haar-Filter $(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}, 0, 0)$ gehört. Eine weitere Lösung ist

$$h_0 = \tfrac{1+\sqrt{3}}{4\sqrt{2}}, \qquad h_1 = \tfrac{3+\sqrt{3}}{4\sqrt{2}}, \qquad h_2 = \tfrac{3-\sqrt{3}}{4\sqrt{2}}, \qquad h_3 = \tfrac{1-\sqrt{3}}{4\sqrt{2}} \tag{4.4}$$

[LMR98, Tabelle 2.3], dort in umgekehrter Reihenfolge. Zur Probe: Die Zähler summieren sich zu 8, also $\sum h_k = 8/(4\sqrt{2}) = \sqrt{2}$. Die quadrierten Zähler ergeben $(4+2\sqrt{3}) + (12+6\sqrt{3}) + (12-6\sqrt{3}) + (4-2\sqrt{3}) = 32 = (4\sqrt{2})^2$, also $\sum h_k^2 = 1$. Schließlich ist $(1+\sqrt{3})(3-\sqrt{3}) + (3+\sqrt{3})(1-\sqrt{3}) = 2\sqrt{3} - 2\sqrt{3} = 0$. Warum gerade diese Lösung ausgewählt wird, klärt Abschnitt 4.4.

Satz 4.5 (Wavelet aus der Skalierungsfolge, vgl. [LMR98, Satz 2.2.10]). *Sei (V_j) eine MSA mit Skalierungsfunktion φ und Skalierungsfolge (h_k). Setzt man*

$$g_k := (-1)^k h_{1-k}, \qquad \psi(t) := \sqrt{2} \sum_{k\in\mathbb{Z}} g_k \varphi(2t-k), \tag{4.5}$$

so ist $\{\psi_{0,k} : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_0. Nach Korollar 3.22 ist dann $\{\psi_{j,k} : j,k \in \mathbb{Z}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$.

Der Beweis steht bei [LMR98, Satz 2.2.10].

Beispiel 4.6 (Haar, Fortsetzung). Aus $h_0 = h_1 = 1/\sqrt{2}$ folgt $g_0 = h_1 = 1/\sqrt{2}$ und $g_1 = -h_0 = -1/\sqrt{2}$, also

$$\psi(t) = \varphi(2t) - \varphi(2t-1) = \mathbf{1}_{[0,1/2[}(t) - \mathbf{1}_{[1/2,1[}(t) = \psi^{\mathrm{H}}(t).$$

Damit ist ψ^{H} als Wavelet der Haar-MSA nachgewiesen, wie es Beispiel 3.11 nahegelegt hatte. Für die Folge (4.4) ist entsprechend $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$.

Die Folge (g_k) heißt Hochpassfolge. Die Namen Tief- und Hochpass begründet Abschnitt 4.5.

Damit ist die erste Frage der Einleitung beantwortet. Das Wavelet ψ entsteht nach (4.5) aus φ und der Hochpassfolge $g_k = (-1)^k h_{1-k}$.

4.3. Der Mallat-Algorithmus

Bisher erfordert jeder Koeffizient

$$a_{j,k} = \langle f, \varphi_{j,k}\rangle = \int_{\mathbb{R}} f(t)\,\varphi_{j,k}(t)\,dt, \qquad d_{j,k} = \langle f, \psi_{j,k}\rangle = \int_{\mathbb{R}} f(t)\,\psi_{j,k}(t)\,dt$$

(Definition 3.17, Korollar 3.22) ein eigenes Integral. Wir fassen die Koeffizienten einer Skala zu Folgen $a_j := (a_{j,k})_{k\in\mathbb{Z}}$ und $d_j := (d_{j,k})_{k\in\mathbb{Z}}$ zusammen. Nach [Bla03, Kap. 5.4] und [LMR98, Kap. 2.3, Abb. 2.8] lassen sich a_j und d_j allein aus a_{j-1} und den Filtern h, g berechnen. Grundlage dafür ist die folgende Darstellung der Basisfunktionen der Skala j durch die der feineren Skala $j-1$.

Lemma 4.7 (Zwei-Skalen-Relation, [Bla03, Kap. 5.4, (3), (4)]). *Für alle $j,k \in \mathbb{Z}$ gilt*

$$\varphi_{j,k} = \sum_{n\in\mathbb{Z}} h_{n-2k}\,\varphi_{j-1,n}, \qquad \psi_{j,k} = \sum_{n\in\mathbb{Z}} g_{n-2k}\,\varphi_{j-1,n}. \tag{4.6}$$

Für einen Beweis siehe [Bla03, Kap. 5.4]. Bildet man in (4.6) das Skalarprodukt mit f, so überträgt sich die Relation auf die Koeffizienten.

Satz 4.8 (Analyseschritt, [Bla03, Kap. 5.4]). *Für alle $j,k \in \mathbb{Z}$ gilt*

$$a_{j,k} = \sum_{n\in\mathbb{Z}} h_{n-2k}\,a_{j-1,n}, \qquad d_{j,k} = \sum_{n\in\mathbb{Z}} g_{n-2k}\,a_{j-1,n}. \tag{4.7}$$

Beweis. Vgl. [Bla03, Kap. 5.4]. Die Reihe in (4.6) konvergiert in $L^2(\mathbb{R})$, da $(h_{n-2k})_{n\in\mathbb{Z}} \in \ell^2(\mathbb{Z})$ und $\{\varphi_{j-1,n}\}_{n\in\mathbb{Z}}$ orthonormal ist. Wegen der Stetigkeit des Skalarprodukts und $h_n \in \mathbb{R}$ folgt

$$a_{j,k} = \left\langle f, \sum_n h_{n-2k}\, \varphi_{j-1,n} \right\rangle = \sum_n h_{n-2k} \left\langle f, \varphi_{j-1,n} \right\rangle = \sum_n h_{n-2k}\, a_{j-1,n}.$$

Analog für $d_{j,k}$ mit g. □

Die Koeffizienten der Skala j sind also gewichtete Summen der Approximationskoeffizienten der Skala $j-1$. Integrale treten nur noch bei der Berechnung der Startwerte a_0 auf.

Haben h und g jeweils höchstens L von null verschiedene Einträge, so sind die Summen in (4.7) endlich. Jeder Koeffizient $a_{j,k}$ bzw. $d_{j,k}$ erfordert dann höchstens L Multiplikationen [Bla03, Kap. 5.4]. Da die Gewichte mit $k \mapsto k+1$ um zwei Indizes weiterrücken, halbiert sich zudem die Anzahl der Koeffizienten von Skala zu Skala bis auf einen festen Randterm. Hat a_0 die Länge 2^J, so haben a_j und d_j höchstens $2^{J-j} + L - 2$ Einträge [Bla03, Kap. 5.4].

Wendet man (4.7) Stufe für Stufe an, so erhält man aus den Startwerten a_0 alle Folgen $a_1, \ldots, a_J$ und $d_1, \ldots, d_J$ bis zu einer Tiefe J. Das ist die schnelle Wavelet-Transformation (Algorithmus 1, Abbildung 4.1).

Algorithmus 1 Schnelle Wavelet-Transformation, vgl. [Bla03, Kap. 5.4], [LMR98, Kap. 2.3, Abb. 2.8]

Eingabe: Startfolge a_0, Filter h, g, Tiefe $J \in \mathbb{N}$
Ausgabe: Detailfolgen $d_1, \ldots, d_J$ und Approximation a_J

1: **für** $j = 1, \ldots, J$
2: **für** alle k
3: $a_{j,k} \leftarrow \sum_n h_{n-2k}\, a_{j-1,n}$
4: $d_{j,k} \leftarrow \sum_n g_{n-2k}\, a_{j-1,n}$
5: **Rückgabe** $d_1, \ldots, d_J,\ a_J$

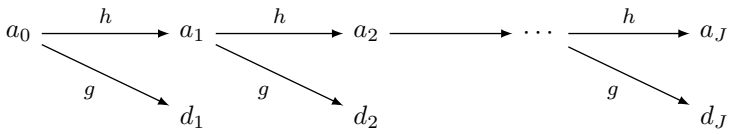


Abbildung 4.1.: Ablauf von Algorithmus 1, in Anlehnung an [Bla03, Kap. 5.4, (6)], vgl. auch [LMR98, Abb. 2.8]. Jeder Pfeil ist ein Rechenschritt nach (4.7) mit dem Filter h bzw. g und halbiert die Anzahl der Werte. Nur die Approximationskoeffizienten werden weiter zerlegt.

Beispiel 4.9 (Haar, Fortsetzung von Beispiel 3.23). Für das Haar-Filter $h_0 = h_1 = \frac{1}{\sqrt{2}}$ liefert (4.5) $g_0 = \frac{1}{\sqrt{2}}$ und $g_1 = -\frac{1}{\sqrt{2}}$. Alle übrigen h_k, g_k verschwinden. In (4.7) bleiben daher nur die Summanden $n = 2k$ und $n = 2k+1$:

$$a_{j,k} = \frac{a_{j-1,2k} + a_{j-1,2k+1}}{\sqrt{2}}, \qquad d_{j,k} = \frac{a_{j-1,2k} - a_{j-1,2k+1}}{\sqrt{2}},$$

also genau Mitteln und Differenzbilden aus Beispiel 3.11. Für die Treppenfunktion $f = (4, 2, 5, 7)$ der Haar-MSA ist $a_{0,k} = f(k)$. Die erste Stufe liefert $a_1 = (\frac{6}{\sqrt{2}}, \frac{12}{\sqrt{2}}) = (3\sqrt{2}, 6\sqrt{2})$ und $d_1 = (\sqrt{2}, -\sqrt{2})$, die zweite $a_{2,0} = 9$ und $d_{2,0} = -3$. Das sind genau die Koeffizienten aus Beispiel 3.23, nun ohne Integral berechnet.

Der Aufwand ist gering. Hat der Filter die Länge L, kostet eine Stufe mit N Eingangswerten etwa LN Multiplikationen. Da sich die Anzahl der Werte von Stufe zu Stufe ungefähr halbiert, sind es insgesamt etwa $L\,(N + N/2 + N/4 + \cdots) \approx 2LN$, also $O(N)$ Operationen [Bla03, Kap. 5.4].

Jeder Schritt lässt sich exakt rückgängig machen.

Satz 4.10 (Rekonstruktion, [Bla03, Kap. 5.4]). *Für alle $j, n \in \mathbb{Z}$ gilt*

$$a_{j-1,n} \;=\; \sum_{k\in\mathbb{Z}} h_{n-2k}\, a_{j,k} \;+\; \sum_{k\in\mathbb{Z}} g_{n-2k}\, d_{j,k}. \tag{4.8}$$

Beweis. Nach Definition 3.20 und Korollar 3.22 ist $P_{j-1}f = P_j f + Q_j f = \sum_k a_{j,k}\varphi_{j,k} + \sum_k d_{j,k}\psi_{j,k}$. Skalarprodukt mit $\varphi_{j-1,n}$ und Lemma 4.7 liefern (4.8), vgl. [Bla03, Kap. 5.4]. □

Im Haar-Fall wird daraus $a_{j-1,2k} = (a_{j,k} + d_{j,k})/\sqrt{2}$ und $a_{j-1,2k+1} = (a_{j,k} - d_{j,k})/\sqrt{2}$, im Beispiel $(3\sqrt{2} \pm \sqrt{2})/\sqrt{2} = 4$ bzw. 2. Auch die Rekonstruktion kostet nur $O(N)$ Operationen [Bla03, Kap. 5.4].

Damit ist die zweite Frage der Einleitung beantwortet. Ein Integral braucht man nur noch für die Startwerte a_0, alle weiteren Koeffizienten liefert Algorithmus 1. In der Anwendung ist f nicht bekannt, sondern nur durch Abtastwerte gegeben. Man setzt dann $a_{0,k} := f(k)$. Das ist eine brauchbare Näherung, besonders wenn φ einen schmalen Träger hat und sich benachbarte Werte $f(k)$ wenig unterscheiden [Bla03, Kap. 5.4]. Wie ein endliches Signal dabei am Rand fortgesetzt wird, beschreibt Abschnitt 5.1.

4.4. Daubechies-Wavelets

Die Formeln des Mallat-Algorithmus gelten für die Skalierungsfolge jeder MSA. Offen ist, welche man wählen soll. Das Haar-Filter erzeugt selbst auf glatten Signalabschnitten von null verschiedene Detailkoeffizienten (Beispiel 4.12). Für Approximationsprobleme ist es oft wichtig, dass die ersten Momente des Wavelets verschwinden [LMR98, Kap. 2.4.4].

Definition 4.11 (Verschwindende Momente, vgl. [Bla03, Kap. 3.5]). Ein Wavelet ψ mit kompaktem Träger hat p verschwindende Momente,[1] falls

$$\int_{\mathbb{R}} t^m\, \psi(t)\, dt \;=\; 0 \qquad \text{für } m = 0, 1, \ldots, p-1.$$

Das Moment $m = 0$ ist die Zulässigkeitsbedingung aus Satz 3.2. Allgemein ist $\int_{\mathbb{R}} q(t)\, \psi_{j,k}(t)\, dt = 0$ für jedes Polynom q vom Grad $< p$. Das Wavelet sieht Polynome niedrigen Grades also nicht. Wie sich das im Mallat-Algorithmus auswirkt, zeigt das folgende Beispiel.

[1] Wie bei Mallat bezeichnet p die Zahl der Momente. N bleibt der Signallänge vorbehalten.

Beispiel 4.12 (Ein lineares Signal). Nach (4.7) liefert die linear ansteigende Folge $a_{0,n} = n$ mit $m = n - 2k$ die Detailkoeffizienten

$$d_{1,k} \;=\; \sum_m g_m\,(m+2k) \;=\; \sum_m m\,g_m + 2k\sum_m g_m.$$

Für Haar ist $g_0 = -g_1 = 1/\sqrt{2}$ (Beispiel 4.6), also $\sum_m g_m = 0$, aber $\sum_m m\,g_m = g_1 = -1/\sqrt{2}$. Damit ist $d_{1,k} = -1/\sqrt{2}$ für jedes k, obwohl das Signal überall gleichmäßig ansteigt und weder Spitzen noch Knicke besitzt. Für die Koeffizienten $h_0, \ldots, h_3$ aus (4.4) ist $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$, und es gilt

$$\begin{aligned} 4\sqrt{2}\sum_m g_m &= (1-\sqrt{3}) - (3-\sqrt{3}) + (3+\sqrt{3}) - (1+\sqrt{3}) \;=\; 0,\\ 4\sqrt{2}\sum_m m\,g_m &= -2(1-\sqrt{3}) + (3-\sqrt{3}) - (1+\sqrt{3}) \;=\; 0, \end{aligned}$$

also $d_{1,k} = 0$. Lineare Abschnitte landen vollständig in den Approximationskoeffizienten, vgl. [LMR98, Lemma 2.4.29]. Damit ist auch die Frage aus Beispiel 4.4 beantwortet. Die Folge (4.4) ist das Daubechies-Filter mit zwei verschwindenden Momenten [Bla03, Kap. 6.3], das Haar-Filter aus derselben Schar hat nur eines.

Lemma 4.13 (Abklingen der Detailkoeffizienten, vgl. [LMR98, Beweis von Lemma 2.4.30]). *Sei ψ ein Wavelet mit p verschwindenden Momenten und $\operatorname{supp}\psi = [\alpha, \beta]$ mit $\alpha \le 0 \le \beta$. Ist f auf $\operatorname{supp}\psi_{j,k}$ p-mal stetig differenzierbar mit $|f^{(p)}| \le M$, so gilt*

$$|d_{j,k}| \;\le\; C_\psi\, M\, 2^{j(p+1/2)}, \qquad C_\psi := \frac{1}{p!}\int_{\mathbb{R}} |t^p\,\psi(t)|\,dt.$$

Der Beweis verläuft wie bei [LMR98, Beweis von Lemma 2.4.30], dort für global glattes f. Man entwickelt f nach Taylor. Der Polynomanteil vom Grad $< p$ trägt wegen der verschwindenden Momente nichts zu $d_{j,k}$ bei, es bleibt nur das Restglied. Wegen $\alpha \le 0 \le \beta$ liegt die Zwischenstelle des Restglieds in $\operatorname{supp}\psi_{j,k}$, sodass dort die Schranke M genügt.

Die Konstante C_ψ hängt nur vom Wavelet ab. Geht man eine Skala feiner, also von j zu $j-1$, so verkleinert sich die Schranke um den Faktor $2^{-(p+1/2)}$. Für Haar ($p = 1$) ist das $2^{-3/2} \approx 0{,}35$, für (4.4) ($p = 2$) $2^{-5/2} \approx 0{,}18$ und für ψ_6 ($p = 6$) $2^{-13/2} \approx 0{,}011$. Auf glatten Abschnitten werden die Detailkoeffizienten zu feinen Skalen hin also schnell klein, umso schneller, je größer p ist. An Sprüngen oder steilen Spitzen ist die Voraussetzung verletzt, und die Koeffizienten bleiben dort groß.

Viele verschwindende Momente allein genügen aber nicht. Der Mallat-Algorithmus ist nur mit endlichen Filtern exakt ausführbar. Die Daubechies-Wavelets verbinden beides. Zu p verschwindenden Momenten gehört ein Filter der Länge $2p$.

Satz 4.14 (Daubechies-Wavelets, [LMR98, Satz 2.4.22, Bem. 2.4.25, Satz 2.4.28]). *Zu jedem $p \in \mathbb{N}$ gibt es eine reelle Skalierungsfolge $h_0, \ldots, h_{2p-1}$ einer MSA mit*

$$\operatorname{supp}\varphi_p = [0,\, 2p-1], \qquad \operatorname{supp}\psi_p = [1-p,\, p],$$

und das zugehörige Wavelet ψ_p besitzt p verschwindende Momente.

Die Konstruktion steht bei [LMR98, Kap. 2.4.3], die Momente bei [LMR98, Satz 2.4.28], vgl. auch [Bla03, Kap. 6.2]. Ein Filter $h_0, \dots, h_{2p-1}$ liefert $\operatorname{supp} \varphi_p \subset [0, 2p-1]$ [LMR98, Satz 2.4.9]. Der Träger von ψ_p folgt dann aus (4.5), da dort nur $g_{2-2p}, \dots, g_1$ von null verschieden sind [LMR98, Gl. (2.4.13)]. Haar-Wavelet, für $p = 2$ die Folge (4.4) [Bla03, Kap. 6.3] mit φ_2 und ψ_2 aus Abbildung 4.2. In PyWavelets [LGW+19] heißt ψ_p `dbp`. Das Wavelet mit vier Koeffizienten ist also `db2`, nicht `db4`.

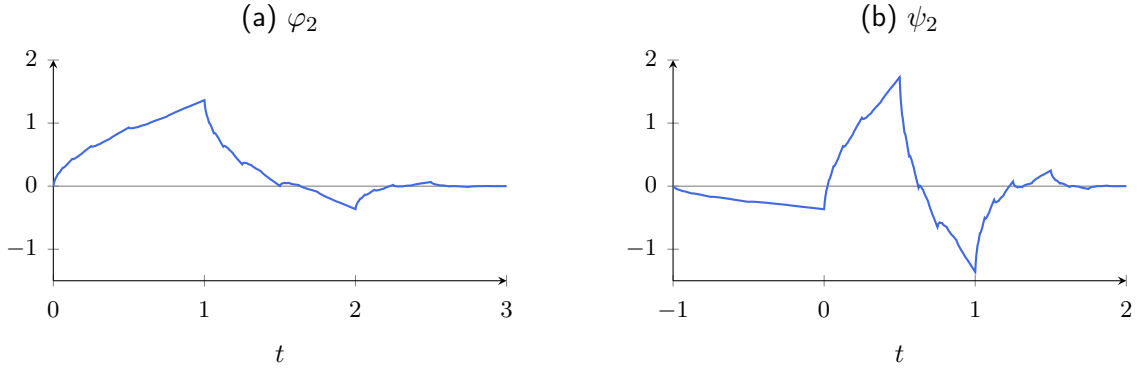


Abbildung 4.2.: Skalierungsfunktion φ_2 auf $[0, 3]$ (a) und Wavelet ψ_2 auf $[-1, 2]$ (b) zur Folge (4.4), berechnet durch Iteration der Skalierungsgleichung (4.1) (Code in Anhang B.2).

Gegenüber Haar ist ψ_2 stetig [Bla03, Satz (6.11)], aber dreimal so breit. Allgemein wird ψ_p mit wachsendem p glatter, nämlich $\psi_p \in H^{\alpha p}(\mathbb{R})$ mit $\alpha > 0{,}2$ [LMR98, Kap. 2.4.4], zugleich wächst aber die Trägerlänge $2p-1$. Bei der Wahl von p muss man daher abwägen. Viele Momente machen die Detailkoeffizienten glatter Abschnitte klein (Lemma 4.13). Ein breiter Träger verteilt dagegen jede steile Spitze auf mehr Koeffizienten. Wegen $\operatorname{supp} \psi_{j,k} = 2^j[1-p+k,\, p+k]$ liegt ein fester Punkt t_0 nämlich in den Trägern von bis zu $2p$ Wavelets jeder Skala j.

Beispiel 4.15 (Das Daubechies-Wavelet mit $p = 6$). Für $p = 6$ liefert Satz 4.14 die zwölf Filterkoeffizienten $h_0, \dots, h_{11}$, gerundet auf sechs Stellen

$$\begin{aligned}(h_0, \dots, h_5) &= (0{,}111541,\ 0{,}494624,\ 0{,}751134,\ 0{,}315250,\ -0{,}226265,\ -0{,}129767),\\ (h_6, \dots, h_{11}) &= (0{,}097502,\ 0{,}027523,\ -0{,}031582,\ 0{,}000554,\ 0{,}004777,\ -0{,}001077),\end{aligned} \tag{4.9}$$

mit $\operatorname{supp} \varphi_6 = [0, 11]$ und $\operatorname{supp} \psi_6 = [-5, 6]$. Blatter verweist für die Werte bis $p = 10$ auf die Tabelle bei Daubechies [Bla03, Kap. 6.2]. Die Werte oben stammen aus PyWavelets [LGW+19], wo ψ_6 `db6` heißt. Sie erfüllen (4.2) und (4.3) bis auf Rundungsfehler. Für die Hochpassfolge $g_k = (-1)^k h_{1-k}$, $k = -10, \dots, 1$, aus (4.5) gilt

$$\sum_k k^m\, g_k = 0 \qquad \text{für } m = 0, \dots, 5$$

[LMR98, Lemma 2.4.27]. Das sind die sechs verschwindenden Momente von ψ_6 in der Form, in der sie im Mallat-Algorithmus wirken, wie in Beispiel 4.12. Abbildung 4.3 zeigt φ_6 und ψ_6. Gegenüber ψ_2 ist der Träger fast viermal so lang, und ψ_6 ist glatter, $\psi_6 \in H^{6\alpha}(\mathbb{R})$ mit $\alpha > 0{,}2$

[LMR98, Kap. 2.4.4]. Castillo et al. verwenden ψ_6 für EKG-Signale, weil es einem echten EKG ähnelt [CMG+13, Abschn. 3.1.1]. Wir übernehmen es in Kapitel 6.

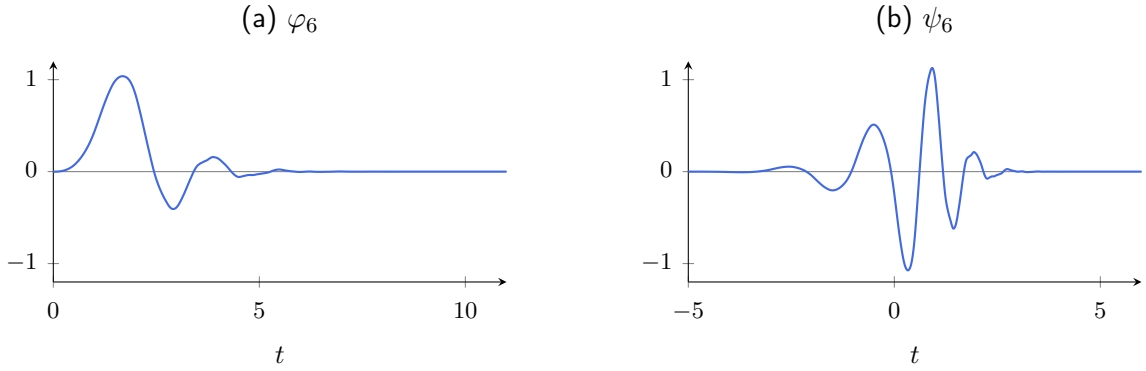


Abbildung 4.3.: Skalierungsfunktion φ_6 auf $[0, 11]$ (a) und Wavelet ψ_6 auf $[-5, 6]$ (b) zur Folge (4.9), berechnet durch Iteration der Skalierungsgleichung (4.1) (Code in Anhang B.2).

4.5. Die Filter im Frequenzbereich

Abschnitt 6.3 ordnet jeder Stufe der Transformation ein Frequenzband zu. Dafür beschreiben wir die Filter im Frequenzbereich.

Definition 4.16 (Fourier-Filter, [LMR98, Gl. (2.2.24)]). Seien (h_k) und (g_k) die Filter aus Abschnitt 4.2 mit $\sum_k |h_k| < \infty$. Die 2π-periodischen Funktionen

$$H(\omega) := \frac{1}{\sqrt{2}} \sum_{k\in\mathbb{Z}} h_k\, e^{-ik\omega}, \qquad G(\omega) := \frac{1}{\sqrt{2}} \sum_{k\in\mathbb{Z}} g_k\, e^{-ik\omega}, \qquad \omega \in \mathbb{R}, \tag{4.10}$$

heißen Fourier-Filter von (h_k) bzw. (g_k).

Wendet man den Analyseschritt (4.7) auf die Schwingung $a_{j-1,n} = e^{i\omega n}$ an, so folgt mit $m = n - 2k$

$$a_{j,k} = \sum_{n\in\mathbb{Z}} h_{n-2k}\, e^{i\omega n} = e^{i\omega\cdot 2k} \sum_{m\in\mathbb{Z}} h_m\, e^{i\omega m} = \sqrt{2}\,\overline{H(\omega)}\, e^{i\omega\cdot 2k},$$

analog $d_{j,k} = \sqrt{2}\,\overline{G(\omega)}\, e^{i\omega\cdot 2k}$. Die Filter verstärken die Schwingung also um die Faktoren $\sqrt{2}\,|H(\omega)|$ bzw. $\sqrt{2}\,|G(\omega)|$. Für $\omega = 0$ ist sie konstant, für $\omega = \pi$ wechselt $e^{i\pi n} = (-1)^n$ bei jedem Schritt das Vorzeichen.

Satz 4.17 (vgl. [LMR98, Satz 2.2.9, Korollar 2.2.12]). *Für alle $\omega \in \mathbb{R}$ gilt*

$$H(0) = 1, \qquad |H(\omega)|^2 + |H(\omega+\pi)|^2 = 1 \tag{4.11}$$

und

$$G(\omega) = -e^{-i\omega}\,\overline{H(\omega+\pi)}. \tag{4.12}$$

Die Gleichung $H(0) = 1$ ist (4.2), die zweite Gleichung in (4.11) ist Lemma 4.3 im Frequenzbereich. Aus (4.11) und (4.12) folgt:

(a) $H(0) = 1$ und $H(\pi) = 0$. Der Filter (h_k) lässt konstante Signale vollständig durch und löscht die schnellste Schwingung aus. Er ist ein Tiefpass.

(b) $G(0) = 0$ und $|G(\pi)| = 1$. Der Filter (g_k) ist ein Hochpass. Insbesondere ist $\sum_k g_k = \sqrt{2}\,G(0) = 0$.

(c) $|H(\omega)|^2 + |G(\omega)|^2 = 1$. Jede Frequenz wird vollständig auf beide Filter aufgeteilt [LMR98, Bem. 2.4.19].

Abbildung 4.4 zeigt $|H|$ und $|G|$. In allen Fällen ist $|H|$ auf $[0, \pi/2]$ groß und auf $[\pi/2, \pi]$ klein, $|G|$ umgekehrt. Mit wachsendem p wird der Übergang steiler [LMR98, Lemma 2.4.32].

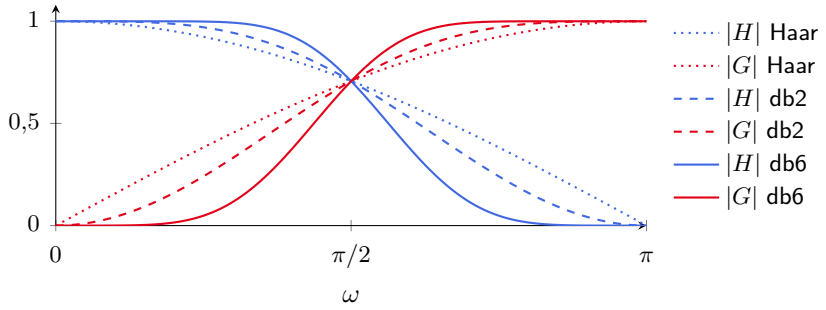


Abbildung 4.4.: Betrag der Fourier-Filter H (Tiefpass, blau) und G (Hochpass, rot) für das Haar-Filter (gepunktet), das Filter (4.4) (gestrichelt) und das Filter (4.9) (durchgezogen) auf $[0, \pi]$, berechnet nach [LMR98, Lemma 2.4.21] mit $p = 1, 2, 6$. In allen Fällen ist $|H|^2 + |G|^2 = 1$.

Damit sind die drei Fragen vom Anfang beantwortet. Das Wavelet ψ entsteht aus der Skalierungsfolge (h_k) über die Hochpassfolge (g_k) (Satz 4.5). Der Mallat-Algorithmus berechnet alle Koeffizienten aus den Startwerten a_0 und den Filtern h und g (Algorithmus 1). Bei der Wahl des Wavelets wägt man verschwindende Momente gegen die Trägerlänge ab (Abschnitt 4.4). Für das EKG folgen wir Castillo et al. und verwenden ψ_6 (Kapitel 6). Für Kapitel 5 ist entscheidend, dass die Transformation in $O(N)$ Operationen berechenbar ist und stückweise glatte Signale dünnbesetzt darstellt (Lemma 4.13).

5. Entrauschung durch Thresholding

Ziel dieses Kapitels ist, aus verrauschten Messwerten das ursprüngliche Signal möglichst genau zurückzugewinnen. Dafür verwenden wir die diskrete Wavelet-Transformation aus Kapitel 4. Die Idee: Eine geeignet gewählte Orthonormalbasis stellt das Signal mit wenigen Koeffizienten dar [Mal09, Kap. 11.3], während sich das Rauschen gleichmäßig auf alle Koeffizienten verteilt [Mal09, Kap. 11.2.1]. Setzt man die kleinen Koeffizienten auf null, verschwindet vor allem Rauschen, während große Waveletkoeffizienten und damit scharfe Kanten erhalten bleiben [Mal09, Kap. 11.3.1]. Donoho und Johnstone haben gezeigt, dass dieses einfache Thresholding fast optimale Schätzer liefert [Mal09, Kap. 11.2]. Das Verfahren hat drei Schritte (Abbildung 5.1).

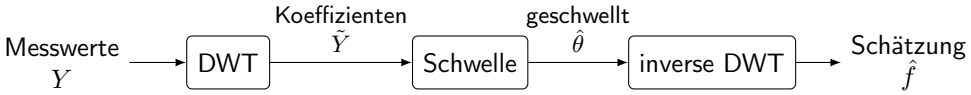


Abbildung 5.1.: Ablauf des Entrauschens: Die Messwerte Y werden mit Algorithmus 1 in Koeffizienten $\tilde{Y}$ zerlegt, jeder Koeffizient wird mit einer Schwelle bearbeitet, und die inverse DWT (Satz 4.10) liefert die Schätzung $\hat{f}$ des Signals. Die Bezeichnungen werden in den Abschnitten 5.1 bis 5.4 eingeführt. Vgl. [Mal09, Gl. (11.84)], [Reb21, Abb. 2.10].

Daraus ergeben sich die Fragen der folgenden Abschnitte: Was macht die Transformation mit dem Rauschen, was mit dem Signal? Wie setzt man kleine Koeffizienten auf null, wo liegt die Grenze, und wie bestimmt man sie aus den Daten? Ein Testsignal begleitet alle Abschnitte. Die Darstellung folgt [Mal09, Kap. 11.2–11.3.1].

Anders als in den Kapiteln 3 und 4 sind alle Signale in diesem Kapitel Vektoren im $\mathbb{R}^N$. Dabei ist $\langle x, y\rangle = \sum_{n=0}^{N-1} x_n y_n$ das euklidische Skalarprodukt und $\|x\|^2 = \sum_{n=0}^{N-1} x_n^2$ die euklidische Norm. Vektoren sind Spaltenvektoren.

5.1. Rauschmodell und diskrete Wavelet-Transformation

Das Rauschen wird als zufällig modelliert. Die dafür benötigten Begriffe, insbesondere Gauß'sches weißes Rauschen (Definition 2.15), stehen in Abschnitt 2.4.

Das Modell. Beobachtet werden N Messwerte

$$Y_n \;=\; f_n + \sigma Z_n, \qquad n = 0, \dots, N-1, \tag{5.1}$$

mit Gauß'schem weißem Rauschen Z der Varianz 1 und Rauschstärke $\sigma > 0$ [Mal09, Gl. (11.26)]. Dabei ist $f \in \mathbb{R}^N$ der unbekannte Vektor der Abtastwerte des Signals. Die Messwerte dienen

direkt als Startkoeffizienten $a_{0,n}$ von Algorithmus 1 [LMR98, Kap. 3.1.1]. Das Rauschen wird mit Z bezeichnet, da W bereits für die Detailräume vergeben ist.

Definition 5.1 (Schätzer und Risiko, [Mal09, Kap. 1.2.4])**.** Ein Schätzer ordnet den Messwerten Y einen Vektor $\hat{f} \in \mathbb{R}^N$ zu, der f annähern soll. Sein Risiko ist der erwartete quadratische Fehler

$$r(f) \;:=\; \mathbb{E}\big[\|\hat{f} - f\|^2\big].$$

Für eine einzelne Realisierung des Rauschens heißt $\|\hat{f} - f\|^2$ die Fehlerenergie.

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie die Energie des Rauschens $\|\sigma Z\|^2$, und ihr Erwartungswert ist $r(f) = \mathbb{E}\big[\|\sigma Z\|^2\big] = N\sigma^2$ [Mal09, Kap. 11.1.1].

Die DWT eines endlichen Signals. In Algorithmus 1 gilt für $j = 1$,

$$a_{1,k} \;=\; \sum_{n\in\mathbb{Z}} h_{n-2k}\, a_{0,n}.$$

Die Summe läuft also formal über alle ganzen Zahlen n. Beim Filter (4.4) sind nur $h_0, \dots, h_3$ von null verschieden. Für jedes k bleiben daher nur die vier Summanden mit $n = 2k, \dots, 2k+3$. Ein Messsignal hat aber nur die N Werte $a_{0,0}, \dots, a_{0,N-1}$. Für $N = 8$ ist etwa

$$a_{1,3} \;=\; h_0 a_{0,6} + h_1 a_{0,7} + h_2 a_{0,8} + h_3 a_{0,9},$$

und $a_{0,8}$, $a_{0,9}$ gibt es nicht. Man setzt das Signal daher periodisch fort, $a_{0,8} := a_{0,0}$, $a_{0,9} := a_{0,1}$ [LMR98, Kap. 2.4.7.2]. Das ist der einfachste von drei Wegen, die Mallat beschreibt. Die anderen spiegeln das Signal am Rand oder verwenden eigene Randwavelets [Mal09, Kap. 7.3.1, 7.5].

Schreibt man die vier Gleichungen für $a_{1,0}, \dots, a_{1,3}$ untereinander, so entsteht ein Matrix-Vektor-Produkt:

$$\begin{pmatrix} a_{1,0} \\ a_{1,1} \\ a_{1,2} \\ a_{1,3} \end{pmatrix} = \underbrace{\begin{pmatrix} h_0 & h_1 & h_2 & h_3 & 0 & 0 & 0 & 0 \\ 0 & 0 & h_0 & h_1 & h_2 & h_3 & 0 & 0 \\ 0 & 0 & 0 & 0 & h_0 & h_1 & h_2 & h_3 \\ h_2 & h_3 & 0 & 0 & 0 & 0 & h_0 & h_1 \end{pmatrix}}_{=:\, H \,\in\, \mathbb{R}^{4\times 8}} \begin{pmatrix} a_{0,0} \\ a_{0,1} \\ \vdots \\ a_{0,7} \end{pmatrix}.$$

Das ist der Tiefpass-Teil des ersten Schritts der DWT.

Ebenso liefert eine Matrix $G \in \mathbb{R}^{4\times 8}$ aus den g_k die Details $(d_{1,0}, \dots, d_{1,3})^\top = G\,(a_{0,0}, \dots, a_{0,7})^\top$.

Definition 5.2 (Periodische Mallat-Transformation, vgl. [LMR98, Kap. 3.6.2])**.** Sei M gerade und $w \in \mathbb{R}^M$ periodisch fortgesetzt, $w_{n+M} := w_n$. Die Abbildungen $H_M, G_M \colon \mathbb{R}^M \to \mathbb{R}^{M/2}$,

$$(H_M w)_k \;:=\; \sum_{n\in\mathbb{Z}} h_{n-2k}\, w_n, \qquad (G_M w)_k \;:=\; \sum_{n\in\mathbb{Z}} g_{n-2k}\, w_n, \qquad k = 0, \dots, \tfrac{M}{2} - 1,$$

heißen periodische Mallat-Transformationen. Ferner sei $S_M := \binom{H_M}{G_M} \in \mathbb{R}^{M\times M}$.

Das sind die Formeln aus Algorithmus 1 mit periodisch gelesenen Indizes. Das Beispiel oben ist $H = H_8$.

Lemma 5.3 ([LMR98, Kap. 3.6.2, Gl. (3.6.18)–(3.6.20)]). *Für die Filter h, g aus Kapitel 4 gilt $H_M H_M^\top = G_M G_M^\top = I$, $H_M G_M^\top = 0$ und $H_M^\top H_M + G_M^\top G_M = I$. Die Matrix S_M ist also orthogonal (Definition 2.2), und ihre Zeilen bilden eine Orthonormalbasis des $\mathbb{R}^M$.*

Der Preis des Periodisierens: Sind Anfang und Ende des Signals verschieden, so verhalten sich die Koeffizienten am Rand, als hätte das Signal dort einen Sprung, und werden groß [Mal09, Kap. 7.5.1].

Die DWT als orthogonale Matrix. Die DWT der Tiefe J wendet S_N auf alle N Werte an und danach jeweils nur auf die zuletzt berechneten Approximationskoeffizienten. Die Details bleiben stehen. Da jeder Schritt die Anzahl der Approximationskoeffizienten halbiert, sei N durch 2^J teilbar. Als Matrix ist das

$$A := \begin{pmatrix} S_{N/2^{J-1}} & 0 \\ 0 & I \end{pmatrix} \cdots \begin{pmatrix} S_{N/2} & 0 \\ 0 & I \end{pmatrix} S_N \in \mathbb{R}^{N\times N}, \qquad AY = (a_J, d_J, \ldots, d_1)^\top,$$

für $N = 8$, $J = 3$ etwa

$$A = \begin{pmatrix} S_2 & 0 \\ 0 & I_6 \end{pmatrix} \begin{pmatrix} S_4 & 0 \\ 0 & I_4 \end{pmatrix} S_8, \qquad AY = (a_3, d_3, d_2, d_1)^\top$$

mit $1, 1, 2$ und 4 Einträgen. Jeder Faktor ist nach Lemma 5.3 orthogonal, also auch A. Wegen $A^\top A = I$ ist A invertierbar mit $A^{-1} = A^\top$ (Definition 2.2). Die Rücktransformation ist also einfach die Multiplikation mit $A^\top$. Wir bezeichnen die Zeilen von A mit $v_0, \ldots, v_{N-1}$. Sie bilden eine Orthonormalbasis des $\mathbb{R}^N$, und jeder Koeffizient ist ein Skalarprodukt mit einer von ihnen. Mallat nennt sie diskrete Wavelets und Skalierungsfunktionen [Mal09, Kap. 7.5, Gl. (7.173)]. Aus (5.1) wird damit

$$\tilde{Y}_m = \theta_m + \sigma \tilde{Z}_m \qquad \text{mit } \tilde{Y}_m = \langle Y, v_m\rangle,\ \theta_m = \langle f, v_m\rangle,\ \tilde{Z}_m = \langle Z, v_m\rangle, \qquad m = 0, \ldots, N-1, \tag{5.2}$$

kurz $\tilde{Y} = AY$, $\theta = Af$, $\tilde{Z} = AZ$ [Mal09, Kap. 11.2.1].

Die Größen des Kapitels hängen also so zusammen:

$$\begin{array}{ccccccc} f & \xrightarrow{A} & \theta = Af & & & & \\ Y = f + \sigma Z & \xrightarrow{A} & \tilde{Y} = \theta + \sigma\tilde{Z} & \xrightarrow{\text{Schwelle}} & \hat{\theta} & \xrightarrow{A^\top} & \hat{f}. \end{array}$$

Gesucht ist f, beobachtet wird nur Y. Die Koeffizienten θ von f sind ebenso unbekannt wie f. Aus den bekannten Koeffizienten $\tilde{Y}$ bildet man eine Schätzung $\hat{\theta}$ von θ und daraus mit $A^{-1} = A^\top$ die Schätzung $\hat{f}$ von f.

Was mit dem Rauschen geschieht.

Lemma 5.4 ([Mal09, Kap. 11.2.1–11.2.2]). *$\tilde{Z} = AZ$ ist wieder Gauß'sches weißes Rauschen der Varianz 1. Die $\tilde{Z}_0, \ldots, \tilde{Z}_{N-1}$ sind also unabhängig und standardnormalverteilt.*

Beweis. A ist orthogonal, die Aussage folgt also aus Satz 2.16. □

Die Transformation verändert also das Signal, die Verteilung des Rauschens aber nicht. Jeder Koeffizient trägt Rauschen derselben Stärke σ, und das Rauschen beeinflusst die Wahl der Basis nicht [Mal09, Kap. 11.2.1].

Beispiel 5.5 (Ein verrauschter Sinus)**.** Als Testsignal dient ein Sinus mit Amplitude 1 und Periode 1, abgetastet an den $N = 2048$ Zeitpunkten $t_n = 8n/N = n/256$ im Intervall $[0, 8)$:

$$u_n := \sin(2\pi t_n), \qquad n = 0, \dots, 2047.$$

Jede Periode umfasst also 256 Abtastwerte, insgesamt sind es acht volle Perioden. Dazu kommt Rauschen der Stärke $\sigma = 0{,}3$. Die Z_n werden als Pseudozufallszahlen erzeugt, und nach (5.1) sind die Messwerte $Y_n = u_n + 0{,}3\, Z_n$ (Abbildung 5.2). Zerlegt wird mit dem Filter (4.4), periodisiert, in $J = 5$ Stufen. Gerechnet ist mit PyWavelets [LGW+19] (Code in Anhang B.3.1).

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie gleich der Energie des Rauschens, $\|Y - u\|^2 = 181{,}3$. Das liegt nahe am Erwartungswert $N\sigma^2 = 2048 \cdot 0{,}09 = 184{,}3$, der später als Vergleich dient. Für die 2048 Werte $\tilde{Z}_m$ sind der empirische Mittelwert $\bar{z} = \frac{1}{N}\sum_{m=0}^{N-1} \tilde{Z}_m = 0{,}01$ und die empirische Varianz $\frac{1}{N}\sum_{m=0}^{N-1}(\tilde{Z}_m - \bar{z})^2 = 0{,}98$, wie nach Lemma 5.4 zu erwarten.

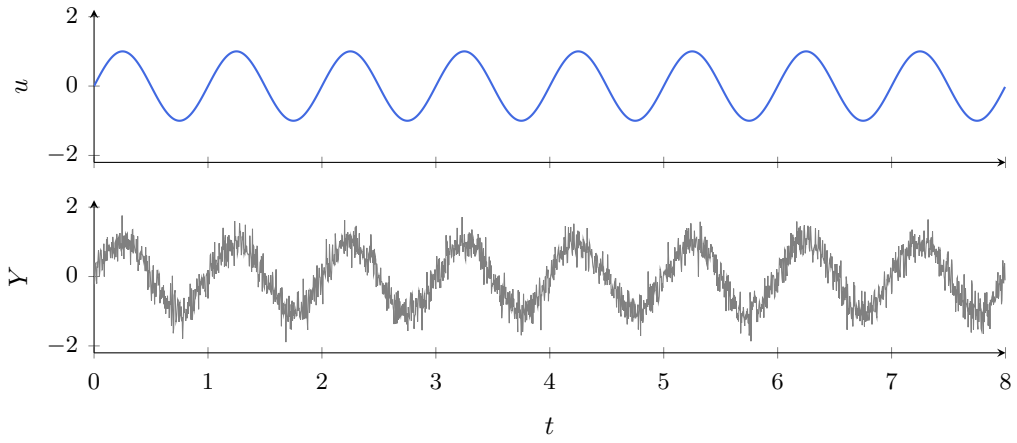


Abbildung 5.2.: Der Sinus u aus Beispiel 5.5 (oben) und die Messwerte $Y = u + 0{,}3\, Z$ (unten), $N = 2048$ (Code in Anhang B.3.1).

5.2. Diagonale Schätzer und Thresholding

Im mittleren Schritt von Abbildung 5.1 wird aus den Koeffizienten $\tilde{Y}_m = \theta_m + \sigma\tilde{Z}_m$ eine Schätzung $\hat{\theta}_m$ von θ_m gebildet. Dazu wird jeder Koeffizient $\tilde{Y}_m$ für sich mit einem Faktor λ_m multipliziert, der angibt, wie viel von ihm übrig bleibt. $\lambda_m = 1$ behält ihn, $\lambda_m = 0$ löscht ihn, ein Wert dazwischen verkleinert ihn.

Definition 5.6 (Diagonaler Schätzer, [Mal09, Kap. 11.2.1, Gl. (11.27)])**.** Ein Schätzer heißt diagonal in der Basis $\{v_m\}$, wenn er jeden Koeffizienten mit einem Faktor λ_m multipliziert,

$$\hat{\theta}_m = \lambda_m \tilde{Y}_m \qquad (m = 0, \dots, N-1),$$

und das Ergebnis mit $A^{-1} = A^\top$ zurücktransformiert: $\hat{f} = A^\top \hat{\theta}$. Dabei darf λ_m von den Messwerten nur über $\tilde{Y}_m$ abhängen, nicht über die übrigen Koeffizienten $\tilde{Y}_k$, $k \neq m$. Hängt kein λ_m von den Messwerten ab, heißt der Schätzer linear.

In den Koeffizienten ist ein diagonaler Schätzer die Multiplikation mit einer Diagonalmatrix,

$$\hat{\theta} = \begin{pmatrix} \lambda_0 & 0 & \cdots & 0 \\ 0 & \lambda_1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_{N-1} \end{pmatrix} \tilde{Y}.$$

Die beiden diagonalen Schätzer, die wir hier einführen, sind nicht linear. Sie vergleichen $|\tilde{Y}_m|$ mit einer Schwelle $T > 0$, die Faktoren hängen also von $\tilde{Y}_m$ selbst ab [Mal09, Kap. 11.2.2].

Definition 5.7 (Hard- und Soft-Thresholding, [Mal09, Gl. (11.47), (11.49)]). Für $T > 0$ heißen

$$\rho_T^{\mathrm{H}}(x) := \begin{cases} x, & |x| > T, \\ 0, & |x| \leq T, \end{cases} \qquad \rho_T^{\mathrm{S}}(x) := \begin{cases} x - T, & x > T, \\ x + T, & x < -T, \\ 0, & |x| \leq T \end{cases}$$

Hard- bzw. Soft-Thresholding. Der zugehörige Schätzer berechnet mit ρ_T für eine der beiden Funktionen die Koeffizienten $\hat{\theta}_m = \rho_T(\tilde{Y}_m)$, $m = 0, \ldots, N-1$, und transformiert zurück: $\hat{f} = A^\top \hat{\theta}$.

Hard-Thresholding ist also der diagonale Schätzer mit $\lambda_m = 1$ für $|\tilde{Y}_m| > T$ und $\lambda_m = 0$ sonst. Bei Soft-Thresholding ist $\lambda_m = 1 - T/|\tilde{Y}_m|$ für $|\tilde{Y}_m| > T$ und $\lambda_m = 0$ sonst.

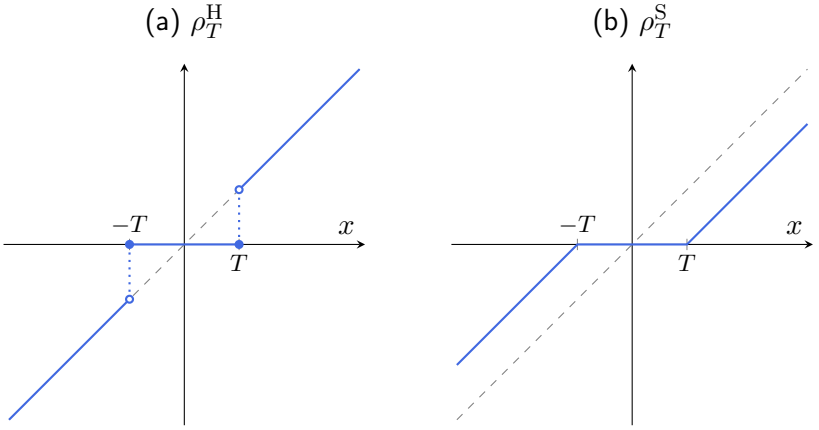


Abbildung 5.3.: Die Funktionen ρ_T^{H} (a) und ρ_T^{S} (b), gestrichelt die Identität.

Beispiel 5.8 (Fortsetzung von Beispiel 4.9). Wir gehen alle drei Schritte für die Messwerte $Y = (4,\ 2,\ 5,\ 7)^\top$ durch, mit dem Haar-Filter, $N = 4$ und $J = 2$.

Schritt 1, Transformieren. Nach Beispiel 4.9 liefert die erste Stufe $a_1 = (3\sqrt{2},\ 6\sqrt{2})^\top$ und $d_1 = (\sqrt{2},\ -\sqrt{2})^\top$, die zweite $a_{2,0} = 9$ und $d_{2,0} = -3$. Also ist $\tilde{Y} = AY = (a_{2,0},\ d_{2,0},\ d_{1,0},\ d_{1,1})^\top = (9,\ -3,\ \sqrt{2},\ -\sqrt{2})^\top$.

Schritt 2, Thresholding. Mit $T = 2$ vergleicht Hard-Thresholding den Betrag jedes Koeffizienten mit T:

$$|9| > 2, \qquad |-3| > 2, \qquad |\sqrt{2}| \leq 2, \qquad |-\sqrt{2}| \leq 2.$$

Die Koeffizienten 9 und -3 liegen über der Schwelle und bleiben unverändert, $\lambda_0 = \lambda_1 = 1$. Die beiden feinen Details $\pm\sqrt{2} \approx \pm 1{,}41$ liegen nicht darüber und werden auf null gesetzt, $\lambda_2 = \lambda_3 = 0$. Also ist $\hat{\theta} = (9,\ -3,\ 0,\ 0)^\top$.

Schritt 3, Zurücktransformieren. Die Rekonstruktion aus Satz 4.10 liefert aus $a_{2,0} = 9$ und $d_{2,0} = -3$ wieder $a_1 = (3\sqrt{2},\ 6\sqrt{2})^\top$. Da beide $d_{1,k}$ null sind, folgt

$$\hat{f} \ = \ A^\top \hat{\theta} \ = \ (3,\ 3,\ 6,\ 6)^\top.$$

Jedes Paar benachbarter Werte ist durch seinen Mittelwert ersetzt. Das Nullsetzen der feinen Details wirkt also wie ein lokales Mitteln.

Soft-Thresholding setzt dieselben Koeffizienten auf null, verkleinert die übrigen aber zusätzlich um T. Das ergibt $\hat{\theta} = (7,\ -1,\ 0,\ 0)^\top$ und damit $\hat{f} = (3,\ 3,\ 4,\ 4)^\top$ (Abbildung 5.4). Dabei verkleinert es auch den Approximationskoeffizienten von 9 auf 7 und senkt so den Mittelwert von $4{,}5$ auf $3{,}5$. Darauf kommt Abschnitt 5.4 zurück.

Ob ein Koeffizient behalten wird, hängt in beiden Fällen nur von seinem eigenen Betrag ab, nicht von den übrigen Koeffizienten (Abbildung 5.3). Darin sind beide Schätzer diagonal (Definition 5.6).

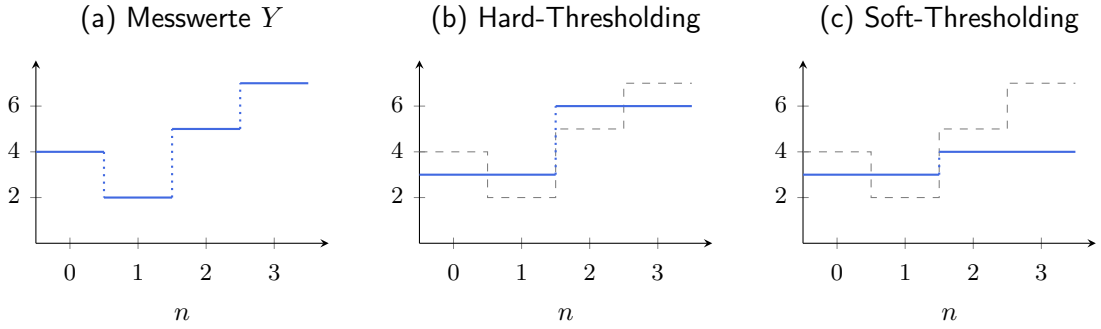


Abbildung 5.4.: Die Messwerte $Y = (4, 2, 5, 7)^\top$ aus Beispiel 5.8 (a) und die Schätzungen $\hat{f} = (3, 3, 6, 6)^\top$ nach Hard-Thresholding (b) und $\hat{f} = (3, 3, 4, 4)^\top$ nach Soft-Thresholding (c), jeweils mit $T = 2$. Gestrichelt Y.

Wie klein der erwartete Fehler eines diagonalen Schätzers höchstens werden kann, lässt sich koeffizientenweise untersuchen. Das Risiko zerfällt nämlich in eine Summe von Einzelbeiträgen.

Lemma 5.9 ([Mal09, Gl. (11.28)]). *Für jeden Schätzer der Form $\hat{f} = A^\top \hat{\theta}$ gilt*

$$\mathbb{E}\big[\|\hat{f} - f\|^2\big] \ = \ \sum_{m=0}^{N-1} \mathbb{E}\big[|\hat{\theta}_m - \theta_m|^2\big]. \tag{5.3}$$

Beweis. Wegen $\hat{f} = A^\top \hat{\theta}$ und $AA^\top = I$ ist $A\hat{f} = \hat{\theta}$, und nach (5.2) ist $Af = \theta$. Da A orthogonal ist und daher die Länge erhält (Abschnitt 2.4), folgt

$$\|\hat{f} - f\|^2 \;=\; \|A(\hat{f} - f)\|^2 \;=\; \|\hat{\theta} - \theta\|^2 \;=\; \sum_{m=0}^{N-1} |\hat{\theta}_m - \theta_m|^2.$$

Bilden des Erwartungswerts, der linear ist, liefert (5.3). □

Bei einem diagonalen Schätzer ist $\hat{\theta}_m = \lambda_m \tilde{Y}_m$. Der m-te Summand in (5.3) hängt also nur von λ_m ab, und das Risiko wird minimiert, indem man jeden Summanden einzeln minimiert. Bekannt ist dabei nur die Summe $\tilde{Y}_m = \theta_m + \sigma\tilde{Z}_m$, nicht ihre beiden Anteile. Wir betrachten zunächst feste Faktoren $\lambda_m \in \{0, 1\}$, also diagonale Schätzer, die jeden Koeffizienten entweder behalten oder löschen [Mal09, Kap. 11.2.1]:

- Behalten, $\lambda_m = 1$: Das Signal bleibt, aber auch das Rauschen. Die Abweichung ist $\hat{\theta}_m - \theta_m = \sigma\tilde{Z}_m$. Da $\tilde{Z}_m$ nach Lemma 5.4 Mittelwert 0 und Varianz 1 hat, ist $\mathbb{E}\big[|\hat{\theta}_m - \theta_m|^2\big] = \sigma^2\,\mathbb{E}\big[\tilde{Z}_m^2\big] = \sigma^2$.
- Löschen, $\lambda_m = 0$: Dann ist $\hat{\theta}_m = 0$. Das Rauschen ist weg, aber ebenso das Signal. Die Abweichung ist $-\theta_m$, der Fehler θ_m^2.

Definition 5.10 (Ideale Auswahl, [Mal09, Gl. (11.32)–(11.34)]). Die ideale Auswahl ist der diagonale Schätzer mit den festen Faktoren $\lambda_m = 1$ für $|\theta_m| \geq \sigma$ und $\lambda_m = 0$ sonst.

Sie wählt für jeden Koeffizienten den kleineren der beiden Fehler σ^2 und θ_m^2. Nach Lemma 5.9 ist ihr Risiko daher

$$r_{\mathrm{id}}(f) \;=\; \sum_{m=0}^{N-1} \min\big(\theta_m^2,\, \sigma^2\big) \;=\; \min_{\lambda_0,\ldots,\lambda_{N-1}\in\{0,1\}} \sum_{m=0}^{N-1} \mathbb{E}\Big[\big|\underbrace{\lambda_m \tilde{Y}_m}_{=\hat{\theta}_m} - \theta_m\big|^2\Big], \tag{5.4}$$

wobei das Minimum über alle diagonalen Schätzer mit festen Faktoren $\lambda_m \in \{0, 1\}$ läuft.

Da die λ_m der idealen Auswahl vom unbekannten θ_m abhängen, lässt sie sich nicht berechnen. Mallat spricht von einem Orakel [Mal09, Kap. 11.2.1]. Hard-Thresholding ist ihr praktischer Ersatz. Es behält oder löscht ebenfalls jeden Koeffizienten, entscheidet aber nach dem bekannten $|\tilde{Y}_m|$ und der Schwelle T statt nach $|\theta_m|$ und σ. Das Risiko des Hard-Thresholding ist mindestens $r_{\mathrm{id}}(f)$ [Mal09, Kap. 11.2.2]. Die ideale Auswahl ist also eine untere Schranke für das, was Hard-Thresholding erreichen kann.

Sind M Koeffizienten mindestens so groß wie σ, so lässt sich das Risiko der idealen Auswahl schreiben als

$$r_{\mathrm{id}}(f) \;=\; \sum_{|\theta_m|<\sigma} \theta_m^2 \;+\; M\sigma^2$$

[Mal09, Gl. (11.36), (11.37)]. Der erste Term ist der Fehler, wenn man f nur durch diese M Koeffizienten darstellt, der zweite das Rauschen auf ihnen. Das Risiko ist also klein, wenn sich f durch wenige Basisvektoren gut darstellen lässt [Mal09, Kap. 11.2.2]. Wir nennen f dann dünnbesetzt in der Basis $\{v_m\}$ [Mal09, Kap. 11.2.1].

Für Wavelets gilt das bei stückweise glatten Signalen. Große Koeffizienten entstehen nur an scharfen Übergängen, und davon gibt es wenige [Mal09, Kap. 11.3.1].

Beispiel 5.11 (Fortsetzung: Sinus mit Spitzen). Wir gehen vom Sinus u aus Beispiel 5.5 aus und setzen an den Zeitpunkten $t_n = n/256$ aus Beispiel 5.5 drei schmale Spitzen um die Stellen $c_1 = 1{,}3$, $c_2 = 3{,}7$ und $c_3 = 6{,}2$ hinzu:

$$s_n := \sum_{i=1}^{3} 3\max\Big(0,\ 1 - \frac{|t_n - c_i|}{0{,}03}\Big), \qquad f := u + s,$$

also drei Dreiecke der Höhe 3 und halben Breite $0{,}03$ (Abbildung 5.5). Der Sinus ist glatt, die Spitzen sind scharfe Übergänge an drei Stellen.

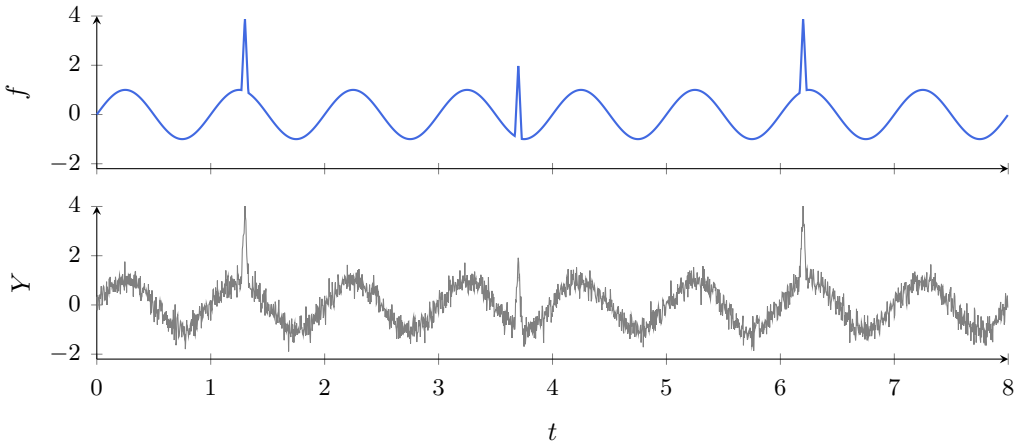


Abbildung 5.5.: Das Testsignal $f = u + s$ aus Beispiel 5.11 (oben) und die Beobachtung $Y = f + 0{,}3\,Z$ (unten), $N = 2048$ (Code in Anhang B.3.2).

Beide Signale transformieren wir ohne Rauschen wie in Beispiel 5.5, also mit dem Filter (4.4), periodisiert, in $J = 5$ Stufen. Das liefert die $N = 2048$ Koeffizienten $\theta_m = \langle f, v_m \rangle$ von f in der Basis $\{v_m\}$ nach (5.2), also $\theta = Af = (a_5, d_5, \ldots, d_1)^\top$, und ebenso die von u. Jede Stufe halbiert die Anzahl, sodass d_1 aus 1024, d_2 aus 512, …, d_5 aus 64 Koeffizienten besteht und die übrigen 64 die Approximation a_5 bilden. Für jede Stufe zeigt die Tabelle (Code in Anhang B.3.2):

- Anzahl: wie viele Koeffizienten die Stufe hat,
- größter Betrag (u): den betragsgrößten Koeffizienten des Sinus auf dieser Stufe,
- $\geq \sigma$ (u) und $\geq \sigma$ (f): wie viele Koeffizienten von u bzw. f betragsmäßig mindestens $\sigma = 0{,}3$ sind. Genau diese behält die ideale Auswahl (Definition 5.10). Ihre Summe ist die Zahl M aus dem vorigen Absatz.

Stufe	Anzahl	größter Betrag (u)	$\geq \sigma$ (u)	$\geq \sigma$ (f)
a_5	64	5,4	64	64
d_5 (grob)	64	0,36	32	33
d_4	128	0,066	0	8
d_3	256	0,012	0	9
d_2	512	0,0021	0	4
d_1 (fein)	1024	0,00037	0	3
Summe	2048		96	121

Für den Sinus sind nur die 64 Approximationskoeffizienten und 32 Detailkoeffizienten auf Stufe 5 mindestens so groß wie σ, also $M = 96$ von 2048. Ab Stufe 4 liegen alle Detailkoeffizienten weit darunter. Der Sinus ist in der Waveletbasis also dünnbesetzt. Zu feineren Stufen hin werden die Detailkoeffizienten des Sinus schnell kleiner, wie nach Lemma 4.13 zu erwarten. Die Spitzen fügen 25 große Koeffizienten hinzu, $M = 121$, fast alle auf den feinen Stufen d_4 bis d_1 und nur in der Nähe der drei Spitzen. In Abbildung 5.6 heben sie sich deutlich von den kleinen Detailkoeffizienten des Sinus ab. Die Approximation a_5 trägt dagegen den Sinus selbst und hat deshalb durchweg große Koeffizienten.

Damit lässt sich das Risiko (5.4) der idealen Auswahl konkret ausrechnen. Beim Sinus behält sie die $M = 96$ Koeffizienten mit $|\theta_m| \geq 0{,}3$. Jeder davon kostet $\sigma^2 = 0{,}09$, zusammen $96 \cdot 0{,}09 = 8{,}6$. Die übrigen 1952 Koeffizienten löscht sie. Jeder kostet sein Quadrat θ_m^2, und da sie fast alle nahe null liegen, ergibt das zusammen nur $1{,}1$. Insgesamt ist also $r_{\mathrm{id}}(u) = 8{,}6 + 1{,}1 = 9{,}7$. Beim Signal mit Spitzen behält sie $M = 121$ Koeffizienten, das kostet $121 \cdot 0{,}09 = 10{,}9$, und die gelöschten kosten $1{,}7$, also $r_{\mathrm{id}}(f) = 12{,}6$. Ohne Bearbeitung wäre das Risiko $N\sigma^2 = 184{,}3$, also rund fünfzehnmal so groß.

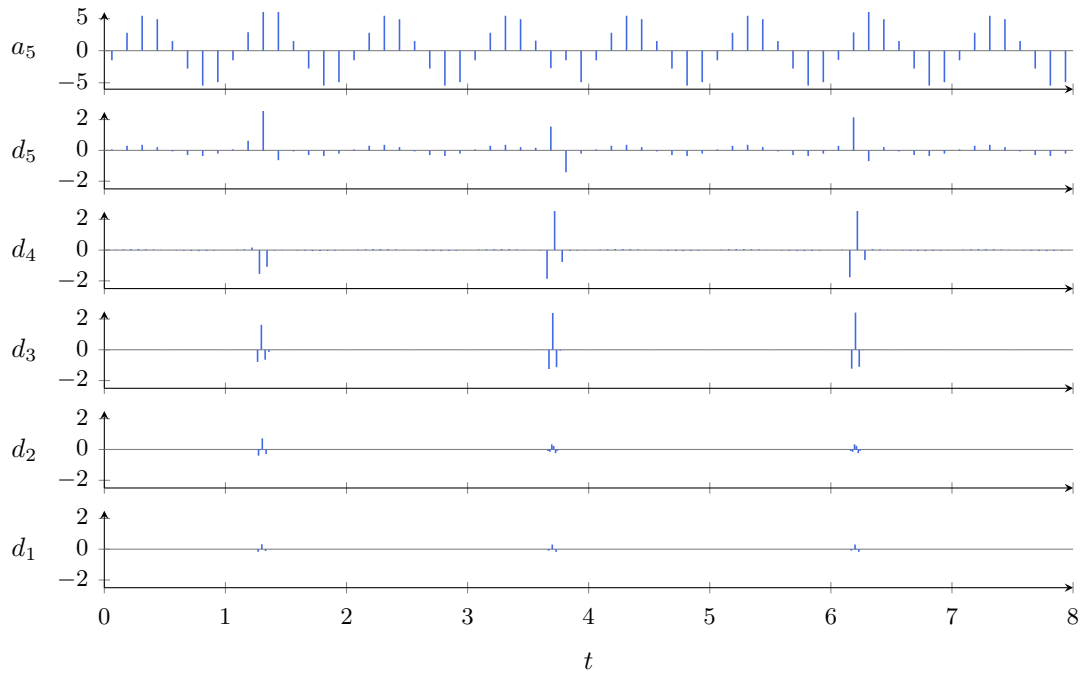


Abbildung 5.6.: Approximationskoeffizienten a_5 (oben, eigene Skala) und Detailkoeffizienten d_5 (grob) bis d_1 (unten, fein) des Testsignals $f = u + s$ aus Beispiel 5.11, aufgetragen über der Zeit t. Sehr große Werte sind abgeschnitten (Code in Anhang B.3.3).

5.3. Die Wahl der Schwelle

Die Schwelle T aus Definition 5.7 soll das Rauschen entfernen, aber möglichst wenig vom Signal. Ist $f = 0$, so besteht jeder Koeffizient nur aus Rauschen, $\tilde{Y}_m = \sigma \tilde{Z}_m$. Damit alle gelöscht werden, muss T größer sein als der größte Rauschanteil $\max_{m=0,\dots,N-1} |\sigma \tilde{Z}_m|$. Ist $f \neq 0$, darf T nicht viel größer sein, sonst gehen auch Koeffizienten mit großem Signalanteil verloren. T soll also knapp über dem größten Rauschanteil liegen [Mal09, Kap. 11.2.2]. Dieses Maximum ist unbekannt. Für N unabhängige Rauschanteile liegt es aber mit hoher Wahrscheinlichkeit knapp unter

$$T \;=\; \sigma\sqrt{2\ln N} \tag{5.5}$$

[Mal09, Gl. (11.64)]. Diese Wahl heißt universelle Schwelle [Mal09, Kap. 11.3.2]. Dass T mit N wächst, liegt an den Ausläufern der Normalverteilung. Unter mehr Werten kommen auch größere vor [Mal09, Kap. 11.2.2].

Dabei nimmt man in Kauf, dass auch Koeffizienten mit kleinem Signalanteil, $|\theta_m| < T$, gelöscht werden. Das kostet jeweils θ_m^2 statt σ^2. Ist f dünnbesetzt, gibt es davon aber nur wenige [Mal09, Kap. 11.2.2].

Satz 5.12 (Donoho–Johnstone, [Mal09, Satz 11.7]). *Für $N \geq 4$ und $T = \sigma\sqrt{2\ln N}$ erfüllt das Risiko des Hard- und des Soft-Thresholding-Schätzers*

$$r(f) \;\leq\; (2\ln N + 1)\big(\sigma^2 + r_{\mathrm{id}}(f)\big). \tag{5.6}$$

Für den Beweis siehe [Mal09, Satz 11.7, Lemma 11.1].

Zusammen mit der unteren Schranke aus Abschnitt 5.2, die Mallat für Hard-Thresholding zeigt, ergibt sich dafür

$$r_{\mathrm{id}}(f) \;\leq\; r(f) \;\leq\; (2\ln N + 1)\big(\sigma^2 + r_{\mathrm{id}}(f)\big)$$

[Mal09, Kap. 11.2.2]. Bis auf den Faktor $2\ln N + 1$ ist Hard-Thresholding also so gut wie die ideale Auswahl. Die obere Schranke gilt für beide Varianten. Ist f dünnbesetzt und damit $r_{\mathrm{id}}(f)$ klein, so ist auch $r(f)$ klein. Mit diagonalen Schätzern lässt sich dieser Faktor für große N nicht verbessern [Mal09, Gl. (11.52)].

Die Schwelle (5.5) ist allerdings nicht optimal. Es gibt also Schwellen, mit denen das Risiko $r(f)$ kleiner ist. Oft senkt schon eine kleinere Schwelle das Risiko, und Soft-Thresholding braucht für ähnliche Ergebnisse wie Hard-Thresholding etwa die halbe Schwelle [Mal09, Kap. 11.2.2].

5.4. Schätzung der Rauschstärke

Die Schwelle enthält das unbekannte σ. Mallat schätzt es aus den $N/2$ Detailkoeffizienten $d_{1,k}$ der feinsten Stufe [Mal09, Kap. 11.3.1]. Wo das Signal auf dem Träger des Wavelets glatt ist, ist sein Koeffizient klein, und $d_{1,k}$ besteht praktisch nur aus Rauschen. Nur an den wenigen scharfen Übergängen ist er groß. Diese Werte nennt Mallat Ausreißer. Auch beim gemessenen EKG, das in Kapitel 6 behandelt wird, enthält d_1 fast das gesamte Rauschen [LMR98, Kap. 3.1.2].

Ausreißer verändern den Median (Definition 2.17) kaum. Ist M der Median der Beträge von P unabhängigen normalverteilten Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2, so ist $\mathbb{E}[M] \approx 0{,}6745\,\sigma$ [Mal09, Kap. 11.3.1]. Da die $d_{1,k}$ bis auf wenige Ausreißer nur aus Rauschen bestehen, ergibt sich daraus der folgende Schätzer.

Definition 5.13 (Schätzer der Rauschstärke, [Mal09, Gl. (11.85)]). Die Rauschstärke σ wird geschätzt durch

$$\hat{\sigma} \;=\; \frac{\operatorname{Median}\bigl(|d_{1,k}| : k = 0, \ldots, N/2 - 1\bigr)}{0{,}6745}. \tag{5.7}$$

Der Schätzer setzt voraus, dass das Rauschen in allen Koeffizienten dieselbe Stärke hat, was nach Lemma 5.4 für weißes Rauschen zutrifft. Ist das Rauschen nicht weiß, hängt seine Varianz vom Basisvektor ab, und die Schwelle muss mit dem Koeffizienten variieren [Mal09, Kap. 11.2.2].

Das vollständige Verfahren. Mallat schwellt alle Koeffizienten der Waveletbasis, auch die der gröbsten Approximation [Mal09, Gl. (11.84)], und bestimmt σ mit (5.7) [Mal09, Kap. 11.3.1]. Zusammen ergibt sich:

Algorithmus 2 Entrauschen mit universeller Schwelle nach [Mal09, Kap. 11.2–11.3]

Eingabe: Messwerte $Y \in \mathbb{R}^N$, Filter h, g, Tiefe J mit $2^J \mid N$

1: $(a_J, d_J, \ldots, d_1)^\top \leftarrow AY$ ▷ Algorithmus 1, periodisiert
2: $T \leftarrow \hat{\sigma}\sqrt{2 \ln N}$ mit $\hat{\sigma}$ aus (5.7)
3: wende auf jeden Koeffizienten c von $a_J, d_J, \ldots, d_1$ Hard- oder Soft-Thresholding an: $c \leftarrow \rho_T(c)$ ▷ Definition 5.7
4: **Rückgabe** $\hat{f} \leftarrow A^\top$(geschwellte Koeffizienten) ▷ Satz 4.10

Satz 5.12 setzt das wahre σ voraus. Mit dem geschätzten $\hat{\sigma}$ hängt T von allen Koeffizienten $d_{1,k}$ ab. Der Schätzer ist dann streng genommen nicht mehr diagonal, und die Schranke (5.6) ist nur ein Anhaltspunkt. Ferner werden in Zeile 3 auch die Approximationskoeffizienten a_J geschwellt. Sie tragen den glatten, groben Anteil des Signals und sind meist groß. Soft-Thresholding verkleinert jeden von ihnen um T und verschiebt so den glatten Anteil, wie schon in Beispiel 5.8 den Mittelwert. In seinem Beispiel zur Bildentrauschung schwellt Mallat die Skalierungskoeffizienten deshalb nicht [Mal09, Kap. 11.3.2].

Beispiel 5.14 (Fortsetzung: Entrauschen des Testsignals). Wir entrauschen jetzt die Messwerte $Y = f + 0{,}3\,Z$ aus Beispiel 5.11.

Zuerst wird die Schwelle bestimmt. Der Schätzer (5.7) liefert $\hat{\sigma} = 0{,}300$ und trifft das wahre $\sigma = 0{,}3$ also sehr genau. Damit ist $T = \hat{\sigma}\sqrt{2 \ln N} = 1{,}17$ (Code in Anhang B.3.4).

Abbildung 5.7 zeigt, was diese Schwelle trennt. Das Rauschen bleibt auf allen Stufen zwischen den gestrichelten Linien. Kein Rauschkoeffizient erreicht T, der größte Rauschanteil ist $\max_{m=0,\ldots,N-1}|0{,}3\,\tilde{Z}_m| = 1{,}02$. Über die Schwelle ragen nur die Detailkoeffizienten an den drei Spitzen und fast alle Approximationskoeffizienten a_5, die den Sinus tragen. Hard-Thresholding behält deshalb nur 75 der 2048 Koeffizienten.

Das Ergebnis zeigt Abbildung 5.8. Mit Hard-Thresholding sinkt die Fehlerenergie von $181{,}3$ auf $27{,}6$, also auf etwa ein Siebtel, und die Spitzen bleiben weitgehend erhalten. Der untere Teil der Abbildung zeigt die Schätzung zusammen mit den Messwerten Y. Soft-Thresholding mit derselben Schwelle erreicht nur $127{,}1$ und macht die Spitzen deutlich niedriger. Der Grund ist, dass Soft-Thresholding auch jeden behaltenen Koeffizienten um T verkleinert. Das betrifft vor allem die Approximationskoeffizienten, die den glatten Sinus tragen.

Allerdings löscht die Schwelle auch Koeffizienten des Signals, vor allem auf den groben Stufen. Auf d_5 liegen fast alle Koeffizienten des Sinus unter T. Auf d_1 und d_2 sind die Signalkoeffizienten so klein, dass sie sich vom Rauschen nicht unterscheiden lassen. Auf groben Stufen sollte die Schwelle deshalb kleiner sein [Mal09, Kap. 11.3.1], darauf kommt Kapitel 6 zurück.

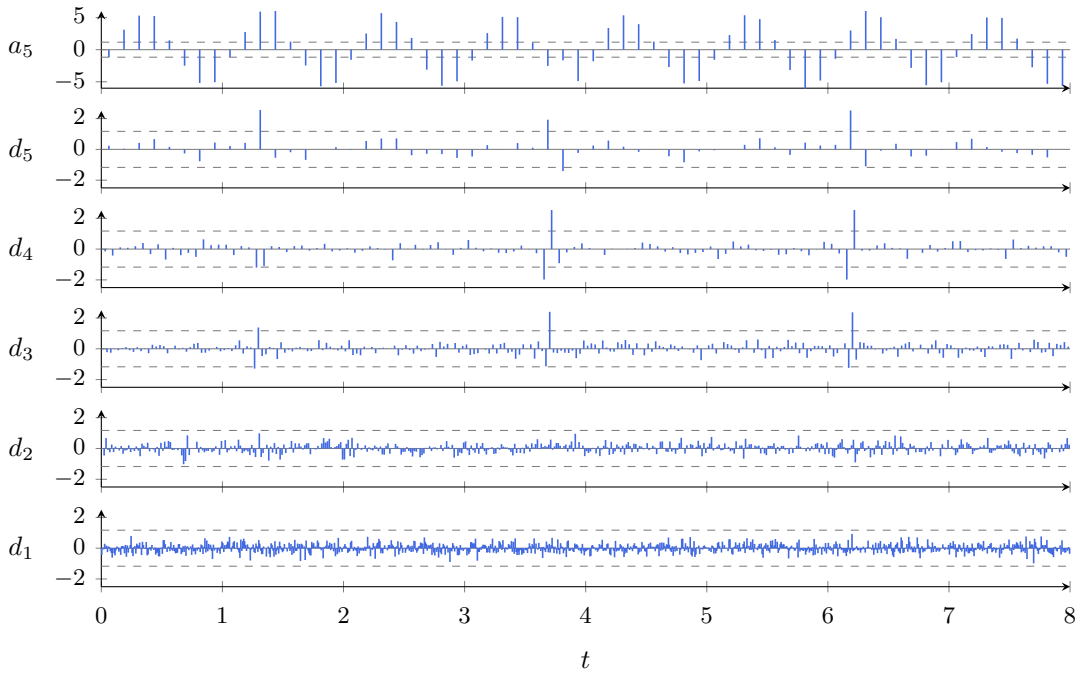


Abbildung 5.7.: Approximationskoeffizienten a_5 (oben, eigene Skala) und Detailkoeffizienten d_5 bis d_1 (unten) der Messwerte $Y = f + 0{,}3\,Z$ aus Beispiel 5.14, im selben Maßstab wie Abbildung 5.6. Gestrichelt die Schwelle $\pm T = \pm 1{,}17$ (Code in Anhang B.3.4).

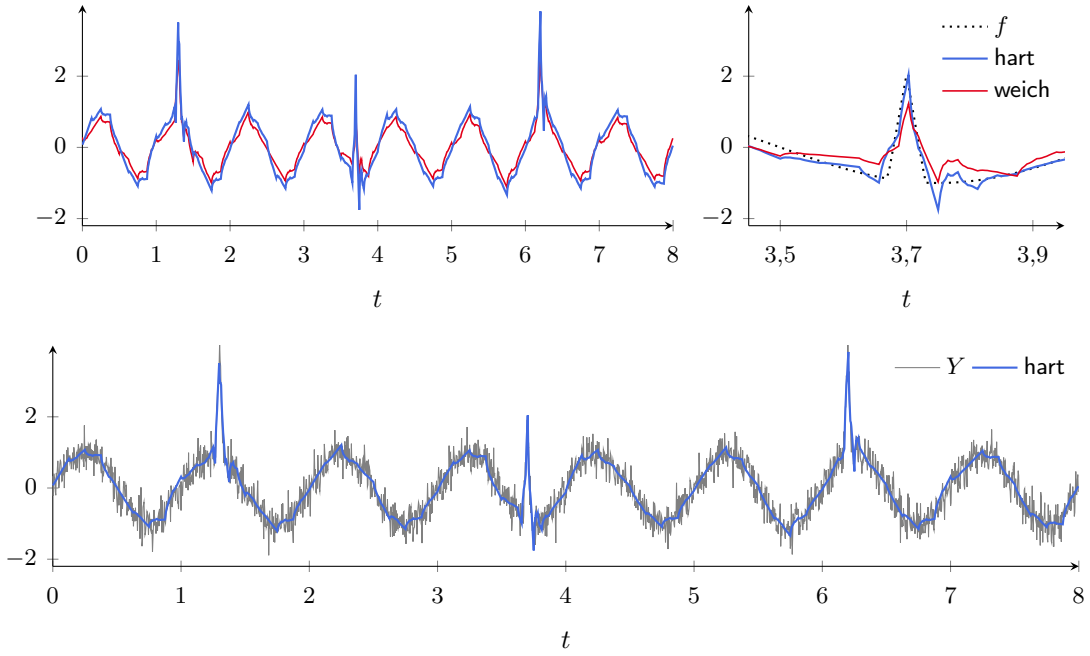


Abbildung 5.8.: Schätzungen aus Y mit Algorithmus 2, $T = 1{,}17$. Oben links beide Schätzungen, oben rechts ein Ausschnitt um die mittlere Spitze mit dem wahren Signal f. Unten die Messwerte Y (grau) und die Schätzung mit Hard-Thresholding (blau) (Code in Anhang B.3.5).

6. Anwendung: Entrauschung von EKG-Signalen

In diesem Kapitel wird das Thresholding aus Kapitel 5 auf reale EKG-Aufzeichnungen der MIT-BIH Arrhythmia Database angewandt. Ziel ist, die Störungen zu entfernen, die in diesen Aufzeichnungen bereits enthalten sind. Wir folgen dabei Castillo et al. [CMG+13] und Alessio [Ale16, Kap. 15.2.4], die beide EKG-Signale mit der DWT von Drift und Rauschen befreien, Alessio stellt dort das Verfahren von Castillo et al. als Beispiel dar. Ein ungestörtes Vergleichssignal gibt es für reale Aufzeichnungen nicht, wir testen das Verfahren deshalb zuerst an einem künstlichen EKG, bei dem es bekannt ist, und beurteilen die realen Aufzeichnungen nach Augenschein.

6.1. EKG-Signale und ihre Störquellen

Ein EKG-Signal ist die Differenz elektrischer Potentiale an zwei Punkten des Körpers, die durch die Erregung des Herzmuskels entsteht [Gac12, Kap. 2.2]. Jeder Herzschlag erzeugt dieselbe Folge von Ausschlägen (Abbildung 6.1): die P-Welle bei der Erregung der Vorhöfe, den QRS-Komplex bei der Erregung der Kammern und die T-Welle bei deren Repolarisation [Gac12, Abb. 2.1], [Reb21, Kap. 2.1].

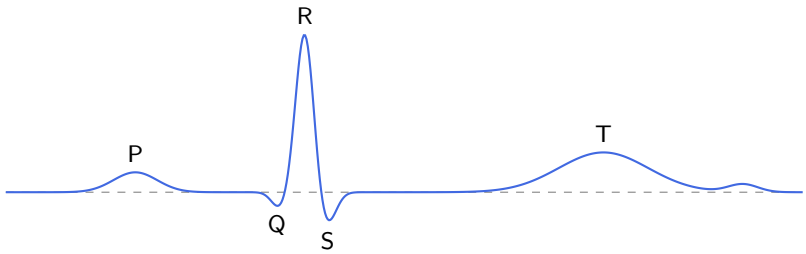


Abbildung 6.1.: Schematischer Herzschlag mit P-, Q-, R-, S- und T-Welle in Anlehnung an [Reb21, Abb. 2.2], Amplituden und Dauern frei gewählt.

Ein gemessenes EKG enthält neben dem Signal des Herzens Störungen [CMG+13, Abschn. 1], Tabelle 6.1 fasst die wichtigsten zusammen. Wir nehmen an, dass sie sich zum EKG addieren. Rebstadt beschreibt die Artefakte als additive Funktionen im gestörten Signal [Reb21, Kap. 2.3.1], und auch Alessio und Castillo et al. gehen von additivem Rauschen aus [Ale16, Kap. 15.2.1], [CMG+13, Abschn. 2.2.2, Gl. (8)].

Größen wie die Höhe einer Zacke werden gegenüber der isoelektrischen Linie gemessen, der Nulllinie des EKG, sie wird in den meisten Rhythmen am besten durch die PQ-Strecke zwischen P-Welle und QRS-Komplex dargestellt [SL05, Kap. 7.1.3]. Solange Drift vorhanden ist, ist diese Linie nicht bestimmt, und damit lassen sich auch die Größen nicht bestimmen, die gegen sie

Störung	Ursache	Frequenzen
Basisliniendrift	Atmung, Bewegung, Elektrodenkontakt	meist < 1 Hz
Elektrodenbewegung	Impedanzänderung der Haut	1–10 Hz
Netzbrummen	Erdung, Geräte in der Nähe	50 oder 60 Hz
Muskelrauschen	Aktivität der Skelettmuskeln	etwa 20–80 Hz
weißes Rauschen	Kanalübertragung, Messgeräte	alle

Tabelle 6.1.: Störungen im EKG nach [SL05, Kap. 6.5], [Gac12, Kap. 2.3, 2.4.3] und [Reb21, Kap. 2.1], Zusammenstellung eigen.

gemessen werden [SL05, Kap. 6.5], deshalb muss die Drift entfernt werden. Elektrodenbewegung und Muskelrauschen überlappen mit dem EKG: Elektrodenartefakte werden manchmal für QRS-Komplexe gehalten, und Muskelrauschen lässt sich nur schwer entfernen, ohne das EKG zu verzerren [SL05, Kap. 6.5]. Das weiße Rauschen σZ dagegen verteilt sich auf alle Frequenzen, für dieses Rauschen ist das Thresholding aus Kapitel 5 gedacht (Abschnitt 6.4.1).

6.2. Die Datensätze

Die MIT-BIH Arrhythmia Database ist eine der meistgenutzten Datenbanken zur Bewertung von Verfahren für Herzrhythmusstörungen [SL05, Kap. 1.4.1]. Sie enthält 48 halbstündige Ausschnitte zweikanaliger Langzeit-EKG von 47 Personen, aufgezeichnet zwischen 1975 und 1979 am Beth Israel Hospital in Boston [MM01, Abschn. Selection of Data], und ist über PhysioNet frei zugänglich [MM05]. Die Aufzeichnungen entstanden im Alltag, etwa beim Arbeiten und Essen [SL05, Kap. 1.4.1].

Aufzeichnung und Digitalisierung. Vor der Digitalisierung wurden die Signale auf 0,1 bis 100 Hz bandbegrenzt [MM01, Abschn. Technical Limitations of the Data]; das heißt, Anteile mit Frequenzen außerhalb dieses Bereichs wurden durch ein Filter weitgehend entfernt. In der Zeit wurde mit $f_s = 360$ Hz abgetastet [MM01, Abschn. Digitization]; alle $1/360\,\mathrm{s} \approx 2{,}8$ ms wurde also ein Wert gespeichert. Welche Frequenzen sich damit darstellen lassen, behandelt Abschnitt 6.3.

Zu den Störquellen aus Tabelle 6.1 kommt eine technische hinzu: Die Bandgeräte, mit denen die Langzeit-EKG aufgezeichnet und später abgespielt wurden, erzeugen durch ihre Mechanik langsame Störungen mit Frequenzen zwischen 0,042 und 0,54 Hz [MM97, Abschn. Introduction, Analog recording and playback]. Das Netzbrummen aus Tabelle 6.1 liegt bei diesen Daten bei 60 Hz und entstand größtenteils erst beim Abspielen [MM01, Abschn. Technical Limitations of the Data].

Annotationen. Zu jeder Aufzeichnung gehört eine Annotationsdatei: Zwei Kardiologen haben unabhängig voneinander jeden Herzschlag geprüft und beschriftet [MM01, Abschn. Annotation], im Allgemeinen am Maximum der R-Zacke [MM97, Abschn. Introduction, Annotations]. Aus diesen Markierungen bestimmen wir in Abschnitt 6.4.2 die Herzfrequenz. Außerdem kennzeichnen die Annotationen Abschnitte mit starkem Rauschen [MM01, Abschn. Annotation].

Datensätze 100 und 103. Zwischen welchen zwei Punkten des Körpers ein EKG-Signal die Spannung misst (Abschnitt 6.1), legt die *Ableitung* fest, die Ableitung II misst sie zwischen rechtem Arm und linkem Bein [Reb21, Kap. 2.1, Tab. 2.1]. Wir verwenden die Datensätze 100 und 103, jeweils das obere der beiden Signale. Es ist die modifizierte Ableitung II (MLII), bei der die Elektroden auf dem Brustkorb statt an den Extremitäten sitzen [MM97, Abschn. ECG lead configuration; Records]. Beide zeigen über die gesamte Dauer einen normalen Sinusrhythmus [MM97, Abschn. Records], also Schläge der Form aus Abbildung 6.1 [Reb21, Kap. 2.1, Abb. 2.2]. Bei Datensatz 100 ist kein Abschnitt des oberen Signals als stark verrauscht markiert, bei Datensatz 103 ein Abschnitt von etwa $9\,\mathrm{s}$ [MM97, Abschn. Records], nach der Annotationsdatei liegt er zwischen $1089{,}8$ und $1098{,}4\,\mathrm{s}$ (Code in Anhang B.4.3).

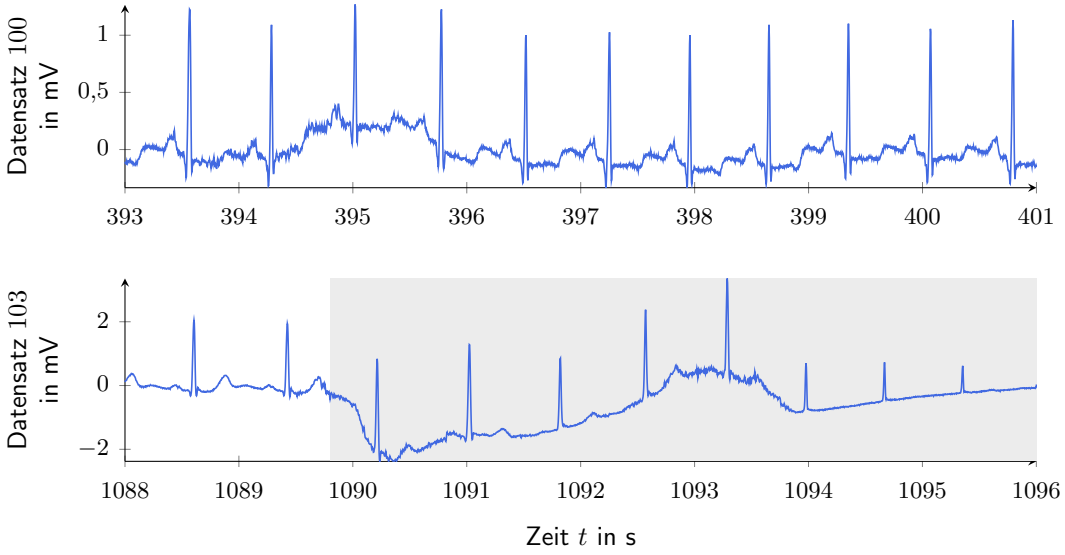


Abbildung 6.2.: Je ein Ausschnitt von $8\,\mathrm{s}$ aus den Datensätzen 100 (oben, ab $393\,\mathrm{s}$) und 103 (unten, ab $1088\,\mathrm{s}$), oberes Signal MLII. Grau hinterlegt der Abschnitt, in dem das obere Signal von Datensatz 103 als stark verrauscht annotiert ist (Code in Anhang B.4.2).

Abbildung 6.2 zeigt je einen Ausschnitt von $8\,\mathrm{s}$. Gestört sind beide Aufzeichnungen, auch außerhalb der als verrauscht markierten Abschnitte. In beiden Datensätzen ist die Basisliniendrift die auffälligste Störung. Bei Datensatz 100 schwankt die Nulllinie innerhalb weniger Sekunden um etwa $0{,}4\,\mathrm{mV}$. Bei Datensatz 103 fällt die Nulllinie zu Beginn des verrauschten Abschnitts innerhalb von etwa einer Sekunde um rund $2\,\mathrm{mV}$ und steigt danach langsam wieder an.

Länge. Wir transformieren jede Aufzeichnung als Ganzes. Das ist möglich, weil Langzeit-EKG erst ausgewertet werden, nachdem die Aufzeichnung abgeschlossen ist [SL05, Kap. 6.6.3], das Verfahren muss also nicht schon während der Messung arbeiten. Damit die periodisierte DWT der Tiefe J definiert ist, muss 2^J die Länge N teilen (Abschnitt 5.1), wir verwenden die ersten $N = 2^{19} = 524\,288$ Abtastwerte, also $N/f_s = 524\,288/(360\,\mathrm{Hz}) \approx 1456\,\mathrm{s}$, das sind $24\,\mathrm{min}\ 16\,\mathrm{s}$.

6.3. Skalen als Frequenzbänder

Um zu entscheiden, welche Stufen der DWT gelöscht, geschwellt oder unverändert gelassen werden, ordnen wir jeder Stufe ein Frequenzband zu. Castillo et al. wählen so die Tiefe für die Drift und die Zahl der geschwellten Stufen [CMG+13, Abschn. 3.1.2, 3.1.3].

Höchste Frequenz. Die Frequenzbänder der Stufen entstehen, indem das Band des Signals von oben her fortlaufend halbiert wird. Dazu brauchen wir seine obere Grenze. Nach dem Abtasttheorem von Shannon (vgl. [Bla03, Kap. 2.4, Satz (2.16)]) ist ein mit der Rate f_s abgetastetes Signal nur bis zur Frequenz

$$F_{\max} = \frac{f_s}{2}$$

eindeutig darstellbar [CMG+13, Abschn. 3.1.2]. In der Variablen $\omega = 2\pi f / f_s$ der Filter aus Kapitel 4 entspricht $[0, F_{\max}]$ dem Intervall $[0, \pi]$. Damit liegt das gesamte Signal Y im Band $[0, F_{\max}]$, dieses Band verteilt die DWT im Folgenden auf die Stufen.

Halbierung des Bandes. Die Fourier-Filter

$$H(\omega) = \frac{1}{\sqrt{2}} \sum_k h_k e^{-ik\omega}, \qquad G(\omega) = \frac{1}{\sqrt{2}} \sum_k g_k e^{-ik\omega}$$

aus (4.10) und (4.12) sind nach Abschnitt 4.5 ein Tief- und ein Hochpass: $|H|$ ist auf $[0, \pi/2]$ groß und auf $[\pi/2, \pi]$ klein, $|G|$ umgekehrt (Abbildung 4.4). Eine Stufe der DWT wendet nach (4.7) beide auf a_{i-1} an und behält jeden zweiten Wert: a_i entsteht durch den Tiefpass und erhält die untere Hälfte des Bandes von a_{i-1}, d_i entsteht durch den Hochpass und erhält die obere [CMG+13, Abschn. 3.1.2]. Mit $a_0 = Y$ und dem Band $[0, F_{\max}]$ von Y folgt

$$a_i \leftrightarrow \left[0, \frac{F_{\max}}{2^i}\right], \qquad d_i \leftrightarrow \left[\frac{F_{\max}}{2^i}, \frac{F_{\max}}{2^{i-1}}\right] \tag{6.1}$$

[Reb21, Kap. 2.3.2, Tab. 2.4]. Bei Castillo et al. ist $f_s = 250\,\text{Hz}$, also $F_{\max} = 125\,\text{Hz}$, und a_7 erfasst 0 bis $125/2^7 \approx 0{,}977\,\text{Hz}$ [CMG+13, Abschn. 3.1.2]. Die Zuordnung ist nicht scharf, da $|H|$ und $|G|$ nicht sprunghaft von 1 auf 0 fallen. Wegen $|H|^2 + |G|^2 = 1$ (Abschnitt 4.5) und $|G(\pi/2)| = |H(\pi/2)|$ nach (4.12) gilt an der Grenze $|H(\pi/2)| = |G(\pi/2)| = 1/\sqrt{2}$: Eine Frequenz genau auf einer Bandgrenze verteilt ihre Energie je zur Hälfte auf beide benachbarten Stufen, Frequenzen nahe der Grenze auf beide.

Unsere Daten. Die Tiefe J ist die Anzahl der Stufen. Sie ist eine positive ganze Zahl mit $J \le \log_2 N$ [CMG+13, Abschn. 3.1.2], bei uns also $J \le \log_2 2^{19} = 19$; wir verwenden $J = 8$ (Abschnitt 6.4.2). Mit $F_{\max} = 360\,\text{Hz}/2 = 180\,\text{Hz}$ ergibt (6.1) Tabelle 6.2.

Bis auf σZ liegen alle Störungen aus Tabelle 6.1 in begrenzten Frequenzbändern und damit nach (6.1) näherungsweise nur in einigen Stufen; σZ liegt in allen Stufen und fehlt deshalb in Tabelle 6.2. Welche Stufen gelöscht, geschwellt oder unverändert gelassen werden, legen wir in Abschnitt 6.4 fest.

	d_1	d_2	d_3	d_4	d_5	d_6	d_7	d_8	a_8
von (Hz)	90	45	22,5	11,3	5,6	2,8	1,4	0,70	0
bis (Hz)	180	90	45	22,5	11,3	5,6	2,8	1,4	0,70
P- und T-Welle				•	•	•	•	•	
Herzfrequenz								•	
Basisliniendrift								(•)	•
Bandmechanik									•
Elektrodenbewegung					•	•	•	•	
Netzbrummen (60 Hz)		•							
Muskelrauschen		•	•	(•)					

Tabelle 6.2.: Frequenzbänder der Koeffizienten nach (6.1) für $f_s = 360\,\text{Hz}$ und $J = 8$. Darunter die Bänder der Wellen und Störungen. P- und T-Welle: 1 bis 20 Hz [Reb21, Kap. 2.3.1]. Herzfrequenz: über 0,88 Hz (Abschnitt 6.4.2). Drift, Elektrodenbewegung, Netzbrummen und Muskelrauschen: nach Tabelle 6.1. Bandmechanik: 0,042 bis 0,54 Hz (Abschnitt 6.2). Die Zuordnung zu den Stufen ist eigen. Ein Punkt in Klammern bedeutet, dass weniger als die Hälfte des Bandes der Stufe getroffen wird.

6.4. Das Verfahren

Wir übernehmen das Ein-Schritt-Verfahren von Castillo et al., das Drift und Rauschen mit einer einzigen Zerlegung und Rekonstruktion entfernt [CMG+13, Abschn. 3]. Abschnitt 6.4.1 definiert das Verfahren, die folgenden Abschnitte wählen seine Parameter.

6.4.1. Modell und Ein-Schritt-Verfahren

Castillo et al. und Alessio gehen für das Rauschen vom Modell (5.1) aus, $Y_n = f_n + \sigma Z_n$ [CMG+13, Abschn. 2.2.2, Gl. (8)], [Ale16, Kap. 15.2.1], und behandeln die Basisliniendrift getrennt davon [CMG+13, Abschn. 2.2.1]. Wir fassen beides in einer Gleichung zusammen; diese Schreibweise ist eigen:

$$Y_n = f_n + b_n + \sigma Z_n, \qquad n = 0, \dots, N-1. \tag{6.2}$$

Dabei ist $f \in \mathbb{R}^N$ das EKG, $b \in \mathbb{R}^N$ die Basisliniendrift und $\sigma Z \in \mathbb{R}^N$ wie in (5.1) Gauß'sches weißes Rauschen. Elektrodenbewegung, Netzbrummen und Muskelrauschen aus Tabelle 6.1 sind darin nicht enthalten. Es bezeichne A die periodisierte DWT der Tiefe J aus Abschnitt 5.1 mit dem Filter (4.9) des Wavelets ψ_6 (Beispiel 4.15). AY ist die Zerlegung des Signals in die Stufen, also die Approximation a_J und die Details $d_J, \dots, d_1$:

$$AY = (a_J, d_J, d_{J-1}, \dots, d_1) \in \mathbb{R}^N, \qquad a_J \in \mathbb{R}^{N/2^J},\ d_j \in \mathbb{R}^{N/2^j}.$$

Bemerkung 6.1 (Wahl des Wavelets). Castillo et al. wählen das Wavelet nach seiner Ähnlichkeit mit dem QRS-Komplex und nehmen `db6`, also ψ_6 aus Satz 4.14 mit $p = 6$ verschwindenden Momenten, weil es einem echten EKG ähnelt [CMG+13, Abschn. 3.1.1]. Allgemein soll das Wavelet die Form der Merkmale haben, die erhalten bleiben sollen [Ale16, Kap. 15.2.1]. In ihrem

Vergleich von zwölf Wavelets an synthetischen EKG finden Castillo et al. zwischen den Wavelets keine großen Unterschiede [CMG+13, Abschn. 4, Tab. 2].

Da $A\colon \mathbb{R}^N \to \mathbb{R}^N$ linear ist, folgt aus (6.2)

$$AY = Af + Ab + \sigma AZ. \tag{6.3}$$

Nach Lemma 5.4 hat jeder Koeffizient von σAZ die Varianz σ^2, gleich in welcher Stufe er liegt; Ab liegt bei geeigneter Wahl von J nach (6.1) näherungsweise nur in a_J, für $J = 8$ nach Tabelle 6.2 in a_8 und am Rand von d_8.

Castillo et al. gehen in vier Schritten vor [CMG+13, Abschn. 3]; sie schreiben dabei L für unser J und M für unser J_S:

1. Y bis zur Tiefe J zerlegen,
2. a_J durch den Nullvektor ersetzen,
3. die Details $d_1, \dots, d_{J_S}$ schwellen, $J_S < J$,
4. aus dem Nullvektor, den unveränderten $d_{J_S+1}, \dots, d_J$ und den geschwellten $d_1, \dots, d_{J_S}$ rekonstruieren.

Als Formel:

Definition 6.2 (Ein-Schritt-Verfahren). Zu Tiefen $1 \le J_S < J$ und einer Schwelle $T > 0$ sei

$$\hat{f} = A^\top\big(0,\ d_J, \dots, d_{J_S+1},\ \rho_T^{\mathrm{S}}(d_{J_S}), \dots, \rho_T^{\mathrm{S}}(d_1)\big), \tag{6.4}$$

wobei das Soft-Thresholding ρ_T^{S} aus Definition 5.7 komponentenweise angewandt wird.

Da A orthogonal ist, ist $A^\top = A^{-1}$ die Rekonstruktion (Abschnitt 5.1); ohne Änderung der Koeffizienten wäre $A^\top(AY) = Y$.

Soft- statt Hard-Thresholding verwenden wir wie Castillo et al., weil Hard-Thresholding Unstetigkeiten erzeugt, Soft-Thresholding nicht [CMG+13, Abschn. 3.1.6]; auch Alessio schwellt weich [Ale16, Kap. 15.2.1]. Hard-Thresholding rechnen wir in Abschnitt 6.5 zum Vergleich mit. Gegenüber Algorithmus 2 ändern sich zwei Dinge: a_J wird nicht geschwellt, sondern gelöscht, und die gröberen Details bleiben unverändert.

Zu wählen sind noch die Tiefen J und J_S und die Schwelle T.

6.4.2. Tiefe J für die Drift

Da a_J gelöscht wird, soll es die Drift enthalten, aber keinen Anteil des EKG. Nach (6.1) erfasst a_J die Frequenzen $[0, F_{\max}/2^J]$. Die tiefste Frequenz des EKG ist die langsamste Herzfrequenz [SL05, Kap. 7.1]; die Grenze muss also zwischen Drift und Herzfrequenz liegen:

$$f_{\mathrm{Drift}} \ < \ \frac{F_{\max}}{2^J} \ < \ f_{\mathrm{Herz}}. \tag{6.5}$$

Castillo et al. und Alessio wählen dazu eine Grenze f_c, setzen $F_{\max}/2^J \approx f_c$ und erhalten

$$J_{BW} = \operatorname{int}\Big[\log_2\Big(\frac{F_{\max}}{f_c}\Big)\Big], \tag{6.6}$$

wobei int auf die nächste ganze Zahl rundet [CMG+13, Abschn. 3.1.2, Gl. (9)], [Ale16, Kap. 15.2.4]. Bei Castillo et al. ist $F_{\max} = 125\,\mathrm{Hz}$ und $f_c = 1\,\mathrm{Hz}$, also $J_{BW} = 7$, und a_7 erfasst 0 bis $0{,}977\,\mathrm{Hz}$.

Unsere Daten. Die Basisliniendrift entsteht meist durch die Atmung und liegt dann bei $0{,}15$ bis $0{,}3\,\mathrm{Hz}$ [CMG+13, Abschn. 2.2.1]. Nach den Annotationen liegt die Herzfrequenz im Mittel bei 75 bzw. 70 Schlägen pro Minute und für keinen Schlag unter 53 pro Minute, also $f_{\mathrm{Herz}} > 53/60\,\mathrm{Hz} \approx 0{,}88\,\mathrm{Hz}$ (Code in Anhang B.4.3). Mit $F_{\max} = 180\,\mathrm{Hz}$ gilt:

- $f_c = 1\,\mathrm{Hz}$ wie bei Castillo et al. ergibt $J = \mathrm{int}[\log_2 180] = \mathrm{int}[7{,}49] = 7$ und die Grenze $180/2^7 = 1{,}41\,\mathrm{Hz} > 0{,}88\,\mathrm{Hz}$. Die rechte Ungleichung in (6.5) ist verletzt; a_7 enthielte Anteile des EKG.
- Sörnmo und Laguna empfehlen eine Grenze etwas unter der langsamsten Herzfrequenz, etwa $f_c = 0{,}5\,\mathrm{Hz}$, und warnen, dass bei zu hoher Grenze eine mit der Herzfrequenz schwingende Störung entsteht [SL05, Kap. 7.1]. Das ergibt

  $$J = \mathrm{int}[\log_2 360] = 8 \quad (\log_2 360 \approx 8{,}49), \qquad 0{,}3\,\mathrm{Hz} \;<\; \frac{180}{2^8}\,\mathrm{Hz} \approx 0{,}70\,\mathrm{Hz} \;<\; 0{,}88\,\mathrm{Hz},$$

  (6.5) ist also erfüllt.

Es kommt dabei nicht genau auf $0{,}5\,\mathrm{Hz}$ an: Für jedes $f_c \in [0{,}50;\, 0{,}99]\,\mathrm{Hz}$ ist $\log_2(180/f_c) \in [7{,}5;\, 8{,}5]$, also $J = 8$. Die Grenze darf aber nicht zu knapp über der Drift liegen: Bei Castillo et al. ist für alle drei Abtastraten die Stufe mit der Grenze $F_{\max}/2^L \approx 0{,}98\,\mathrm{Hz}$ am besten [CMG+13, Abschn. 4, Tab. 1]; die nächsttiefere mit $0{,}49\,\mathrm{Hz}$ entfernt Drift bis $0{,}31\,\mathrm{Hz}$ meist deutlich schlechter. Die Grenzfrequenzen sind aus $F_{\max}/2^L$ berechnet. Unsere Grenze $0{,}70\,\mathrm{Hz}$ liegt mehr als doppelt so hoch wie die Drift. In Abschnitt 6.5 vergleichen wir $J = 7, 8, 9$ am Test-EKG.

6.4.3. Anzahl J_S der geschwellten Stufen

J_S legt fest, wie viele der feinsten Stufen geschwellt werden: d_1 bis d_{J_S} werden geschwellt, d_{J_S+1} bis d_J bleiben unverändert. Nach Lemma 5.4 hat jeder Koeffizient von σAZ den Erwartungswert 0 und die Varianz σ^2. Die erwartete Energie des Rauschens ist damit

$$\mathbb{E}\big[\|\sigma AZ\|^2\big] = \sum_{m=0}^{N-1} \mathbb{E}\big[(\sigma AZ)_m^2\big] = \sigma^2 N,$$

und auf d_j mit $N/2^j$ Koeffizienten entfällt der Teil $\sigma^2 N/2^j$. In den unveränderten Stufen d_{J_S+1} bis d_J bleibt damit im Mittel der Anteil

$$\begin{aligned}\frac{1}{\sigma^2 N}\sum_{j=J_S+1}^{J} \sigma^2\,\frac{N}{2^j} = \sum_{j=J_S+1}^{J} 2^{-j} &= 2^{-J_S}\sum_{k=1}^{J-J_S} 2^{-k} \\ &= 2^{-J_S}\big(1 - 2^{-(J-J_S)}\big) = 2^{-J_S} - 2^{-J}\end{aligned}$$

der Rauschenergie erhalten. Dabei wurde $j = J_S + k$ gesetzt und die geometrische Summe $\sum_{k=1}^{n} 2^{-k} = 1 - 2^{-n}$ verwendet. Ein größeres J_S entfernt also mehr Rauschen, schwellt aber auch Stufen, in denen das EKG liegt.

Castillo et al. schwellen bei $f_s = 500\,\mathrm{Hz}$ die Stufen d_1 bis d_3, weil dort der Rauschanteil groß ist und die gröberen Stufen die wesentlichen Teile des EKG enthalten [CMG+13, Abschn. 3.1.3]. Wegen $F_{\max} = 250\,\mathrm{Hz}$ wird dort nach (6.1) alles oberhalb von

$$f_S := \frac{250\,\mathrm{Hz}}{2^3} = 31{,}25\,\mathrm{Hz}$$

geschwellt. Da dieselbe Zahl von Stufen bei anderer Abtastrate andere Frequenzen bedeutet, übertragen wir nicht die Zahl der Stufen, sondern diese Grenze (eigene Festlegung): Wir wählen das größte J_S, dessen geschwellte Stufen oberhalb von f_S liegen,

$$\frac{F_{\max}}{2^{J_S}} \geq f_S \iff J_S \leq \log_2 \frac{180}{31{,}25} \approx 2{,}53, \qquad \text{also } J_S = 2.$$

Die geschwellten Stufen d_1 und d_2 beginnen damit bei $45\,\mathrm{Hz}$ und liegen insbesondere oberhalb von P- und T-Welle, die bis $20\,\mathrm{Hz}$ reichen [Reb21, Kap. 2.3.1]. Es bleiben $2^{-2} - 2^{-8} = 63/256 \approx 24{,}6\,\%$ der Rauschenergie erhalten. In d_1 und d_2 liegen neben Netzbrummen und Muskelrauschen auch die hochfrequenten Anteile des QRS-Komplexes: Das EKG-Spektrum reicht bis $150\,\mathrm{Hz}$ [Gac12, Kap. 2.4.3.2], und nur P- und T-Welle und die tieffrequenten Anteile des QRS-Komplexes liegen unter $20\,\mathrm{Hz}$ [Reb21, Kap. 2.3.1]. Da das Rauschen gleichmäßig auf alle Detailkoeffizienten verteilt ist, das EKG dagegen durch wenige große Koeffizienten dargestellt wird, entfernt Schwellen das Rauschen und erhält die Spitzen des QRS-Komplexes [CMG+13, Abschn. 2.2.2]; diese Stufen werden deshalb geschwellt statt gelöscht.

6.4.4. Schwelle

Als Schwelle verwenden wir die universelle Schwelle (5.5) mit dem Schätzer (5.7), $T = \hat{\sigma}\sqrt{2\ln N}$, wie Castillo et al. und Alessio [CMG+13, Abschn. 3.1.4, Gl. (10); 3.1.5, Gl. (19), (23)], [Ale16, Kap. 15.2.2, 15.2.3]. Geschätzt wird $\hat{\sigma}$ aus d_1: Bei weißem Rauschen kann man die Standardabweichung aus den Koeffizienten der ersten Stufe schätzen, die bis auf wenige große Werte nur Rauschen enthalten, und für alle Stufen verwenden [CMG+13, Abschn. 3.1.5], [Ale16, Kap. 15.2.2]. Für N zwischen 2^6 und 2^{19} überschreitet reines Rauschen diese Schwelle nur in etwa einem Zehntel der Realisierungen [Ale16, Kap. 15.2.3]. Umgesetzt ist das Verfahren mit PyWavelets [LGW+19] (Listing B.8 in Anhang B.4.1).

Zusammenfassung. Mit den gewählten Parametern lautet das Verfahren:

Definition 6.3 (Verfahren zur Entrauschung von EKG-Signalen). Gegeben seien Messwerte $Y \in \mathbb{R}^N$ mit Abtastrate $f_s = 360\,\mathrm{Hz}$, wobei N durch 2^8 teilbar ist. Das entrauschte Signal $\hat{f} \in \mathbb{R}^N$ entsteht in vier Schritten:

1. *Zerlegen:* $AY = (a_8, d_8, \ldots, d_1)$ mit der periodisierten DWT der Tiefe $J = 8$ und dem Wavelet ψ_6 (Abschnitt 6.4.2).
2. *Schwelle bestimmen:* $\hat{\sigma}$ nach (5.7) aus d_1 und $T = \hat{\sigma}\sqrt{2\ln N}$.
3. *Koeffizienten ändern:* a_8 durch 0 ersetzen, d_1 und d_2 mit ρ_T^{S} schwellen ($J_S = 2$), d_3 bis d_8 unverändert lassen.

4. *Rekonstruieren:*
$$\hat{f} = A^\top\big(0,\ d_8, \dots, d_3,\ \rho_T^{\mathrm{S}}(d_2),\ \rho_T^{\mathrm{S}}(d_1)\big).$$

Das ist das Ein-Schritt-Verfahren aus Definition 6.2 mit $J = 8$, $J_S = 2$ und der universellen Schwelle.

Im Folgenden testen wir das Verfahren zuerst an einem künstlichen EKG, bei dem f bekannt ist (Abschnitt 6.5), und wenden es dann auf die Datensätze 100 und 103 an (Abschnitt 6.6).

6.5. Test an einem künstlichen EKG

Bei echten Aufzeichnungen ist f unbekannt, und ein quantitatives Gütemaß lässt sich nur schwer angeben. Castillo et al. bewerten ihr Verfahren deshalb an künstlichen EKG [CMG+13, Abschn. 4]. Wir gehen ebenso vor.

Als Grundlage dient ein EKG $f_{\mathrm{syn}} \in \mathbb{R}^N$ aus dem dynamischen Modell von McSharry et al. [MCTS03], berechnet mit der Funktion `ecg_simulate` (Methode `ecgsyn`) aus NeuroKit2 [MPL+21] für $f_s = 360\,\mathrm{Hz}$, eine Herzfrequenz von 70 Schlägen pro Minute und $N = 2^{16}$ Abtastwerte, also etwa 3 min. Das Modell enthält von sich aus eine Atmungsdrift [MCTS03, Abschn. IV, Gl. (2)]. Diese haben wir abgeschaltet, damit das Test-EKG selbst keine Drift enthält. Die Differentialgleichung des Modells lösen wir mit der relativen Toleranz 10^{-8} statt der voreingestellten 10^{-3}, da das Ergebnis sonst von der Rechenumgebung abhängt (eigene Festlegung, Code in Anhang B.4.5).

Für $x \in \mathbb{R}^N$ sei $\bar{x} = \frac{1}{N}\sum_{n=0}^{N-1} x_n$ der Mittelwert und $\mathbf{1} = (1, \dots, 1) \in \mathbb{R}^N$, also $\langle x, \mathbf{1}\rangle = N\bar{x}$.

Lemma 6.4. *Jedes $\hat{f}$ nach (6.4) hat den Mittelwert $\bar{\hat{f}} = 0$.*

Beweis. Setzt man $\omega = 0$ in (4.10) ein, so ist $H(0) = 2^{-1/2}\sum_k h_k$, wegen $H(0) = 1$ nach (4.11) also $\sum_k h_k = \sqrt{2}$. Ebenso ist $G(0) = 2^{-1/2}\sum_k g_k$, und nach (4.11) und (4.12) gilt $G(0) = 0$ (Abschnitt 4.5, Aussage (b)), also $\sum_k g_k = 0$. Für einen konstanten Vektor $a_{j-1,n} = c$ liefert (4.7) daher
$$a_{j,k} = c\sum_n h_{n-2k} = \sqrt{2}\,c, \qquad d_{j,k} = c\sum_n g_{n-2k} = 0,$$
bei periodischer Fortsetzung durchläuft $n - 2k$ dabei jeden Index des Filters genau einmal. Eine Stufe bildet einen konstanten Vektor also auf einen konstanten Vektor in der Approximation und auf den Nullvektor in den Details ab. Wiederholt man das J-mal, ist $A\mathbf{1}$ nur im Teil a_J von null verschieden. In (6.4) ist $\hat{f} = A^\top u$, wobei u im Teil a_J null ist. Damit ist
$$N\,\bar{\hat{f}} = \langle \hat{f}, \mathbf{1}\rangle = \langle A^\top u, \mathbf{1}\rangle = \langle u, A\mathbf{1}\rangle = 0. \qquad \square$$

Einen konstanten Versatz kann das Verfahren also nicht wiedergeben. Er ist für das EKG ohne Bedeutung, da dessen Größen gegenüber der isoelektrischen Linie gemessen werden (Abschnitt 6.1). Als Test-EKG wählen wir deshalb das mittelwertfreie
$$f := f_{\mathrm{syn}} - \bar{f}_{\mathrm{syn}}\,\mathbf{1}$$

(eigene Festlegung). Wie Castillo et al. verwenden wir eine sinusförmige Drift und Gauß'sches weißes Rauschen, addieren beide aber gemeinsam (vgl. [CMG+13, Abschn. 4]):

$$Y = f + b + \sigma Z, \qquad b(t) = 0{,}5\,\mathrm{mV} \cdot \sin(2\pi \cdot 0{,}25\,\mathrm{Hz} \cdot t),$$

mit $\sigma = 0{,}025\,\mathrm{mV}$. Mit diesem Wert bilden McSharry et al. das Messrauschen eines echten EKG nach [MCTS03, Abschn. V]. Dabei ist $Z \in \mathbb{R}^N$ eine feste Realisierung, also ein Vektor mit N standardnormalverteilten Einträgen. Abbildung 6.3 zeigt einen Ausschnitt von $4\,\mathrm{s}$: oben das Test-EKG f, unten die Messung Y. Die Drift b verschiebt Y langsam nach oben und unten und durchläuft im Ausschnitt genau eine Periode ($1/0{,}25\,\mathrm{Hz} = 4\,\mathrm{s}$). Das Rauschen σZ macht die Kurve unruhig, die R-Zacken bleiben aber erkennbar.

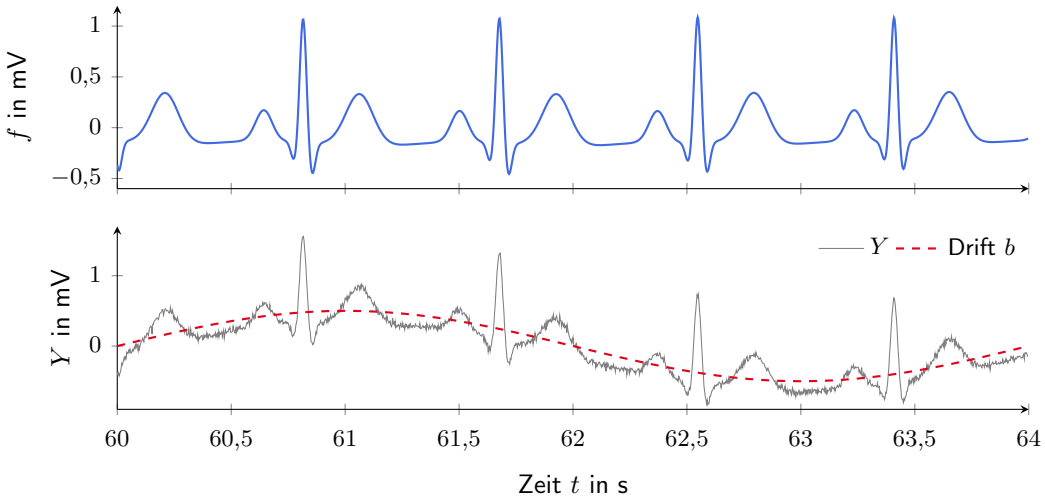


Abbildung 6.3.: Ausschnitt von $4\,\mathrm{s}$ aus dem Test-EKG f (oben) und der gestörten Messung Y mit der Drift b (gestrichelt, unten) mit $\sigma = 0{,}025\,\mathrm{mV}$ (Code in Anhang B.4.7).

Gütemaß. Als Gütemaß dient die Fehlerenergie $\|\hat{f} - f\|^2$ aus Definition 5.1, wobei $\hat{f}$ das Ergebnis des Verfahrens aus Definition 6.3 für die Messung Y ist. Sie hängt von der Realisierung Z ab, wegen der großen Länge N aber kaum: Für 10 verschiedene Realisierungen weichen alle Werte in Tabelle 6.3 um höchstens $2{,}2\,\%$ von denen für unser Z ab, und die Reihenfolge der Varianten bleibt gleich (eigene Rechnung, Code im Anhang B.13).

Ergebnis. Abbildung 6.4 zeigt denselben Ausschnitt wie Abbildung 6.3, nun f und die Schätzung $\hat{f}$: Die Drift ist vollständig entfernt, und $\hat{f}$ folgt f in allen vier Herzschlägen eng. Abbildung 6.5 vergrößert einen Schlag: P-Welle, QRS-Komplex und T-Welle bleiben in Form und Lage erhalten. $\hat{f}$ ist nur leicht unruhiger als f. Der Fehler $\hat{f} - f$ besteht vor allem aus dem Rauschen in den unveränderten Stufen d_3 bis d_8, dessen erwartete Energie nach Abschnitt 6.4 $(2^{-2} - 2^{-8})\,\sigma^2 N \approx 0{,}246 \cdot 40{,}96 \approx 10{,}1$ beträgt, also etwa die Hälfte von $\|\hat{f} - f\|^2 = 20{,}4$. Fehler, die das Thresholding selbst erzeugt, entstehen dort, wo f große Koeffizienten hat: Jeder geänderte Koeffizient $\langle f, \psi_{j,m} \rangle$ hinterlässt im Fehler ein kurzes Wavelet $\psi_{j,m}$ [Mal09, Kap. 11.3.1]. Auf d_1 und d_2 hat f aber kaum solche Koeffizienten.

Variante	$\|\hat{f} - f\|^2$ in mV^2
vorher (Messung Y)	8236,4
$J = 8$, $J_S = 2$, Soft (Verfahren)	20,4
Hard statt Soft	20,4
$J_S = 1$	30,5
$J_S = 3$	26,6
d_3 mit $0{,}2\,T$	17,5
nur Drift entfernt ($J_S = 0$)	51,1
$J = 7$	272,4
$J = 9$	523,6

Tabelle 6.3.: Fehlerenergie $\|\hat{f} - f\|^2$ am Test-EKG, zum Vergleich $\|f\|^2 \approx 3841$. In der Zeile „vorher“ ist $\hat{f} = Y$. In jeder Zeile ist nur der genannte Parameter gegenüber dem Verfahren geändert ($J = 8$, $J_S = 2$, Soft, db6, universelle Schwelle). Code in Anhang B.4.6.

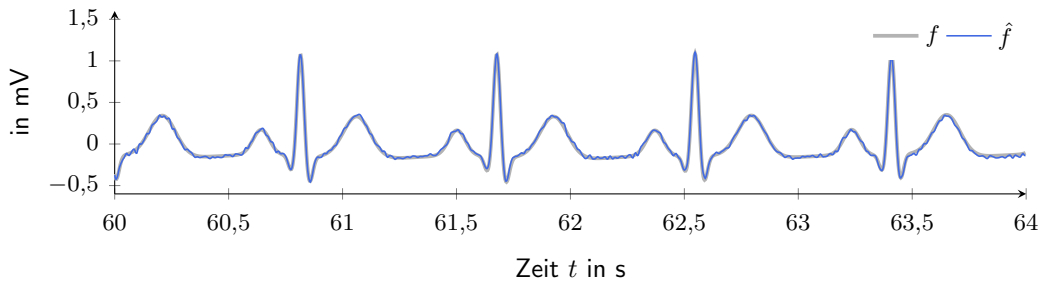


Abbildung 6.4.: Derselbe Ausschnitt von 4 s wie in Abbildung 6.3: f (grau) und $\hat{f}$ (blau) (Code in Anhang B.4.7).

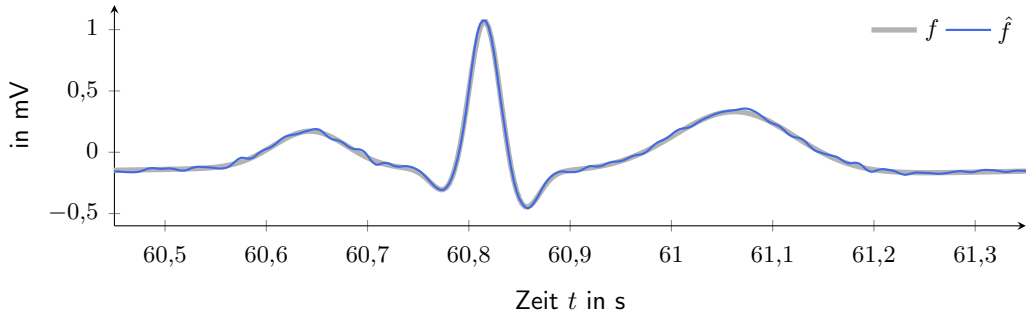


Abbildung 6.5.: Ein Herzschlag aus Abbildung 6.4 vergrößert: f (grau) und $\hat{f}$ (blau) (Code in Anhang B.4.7).

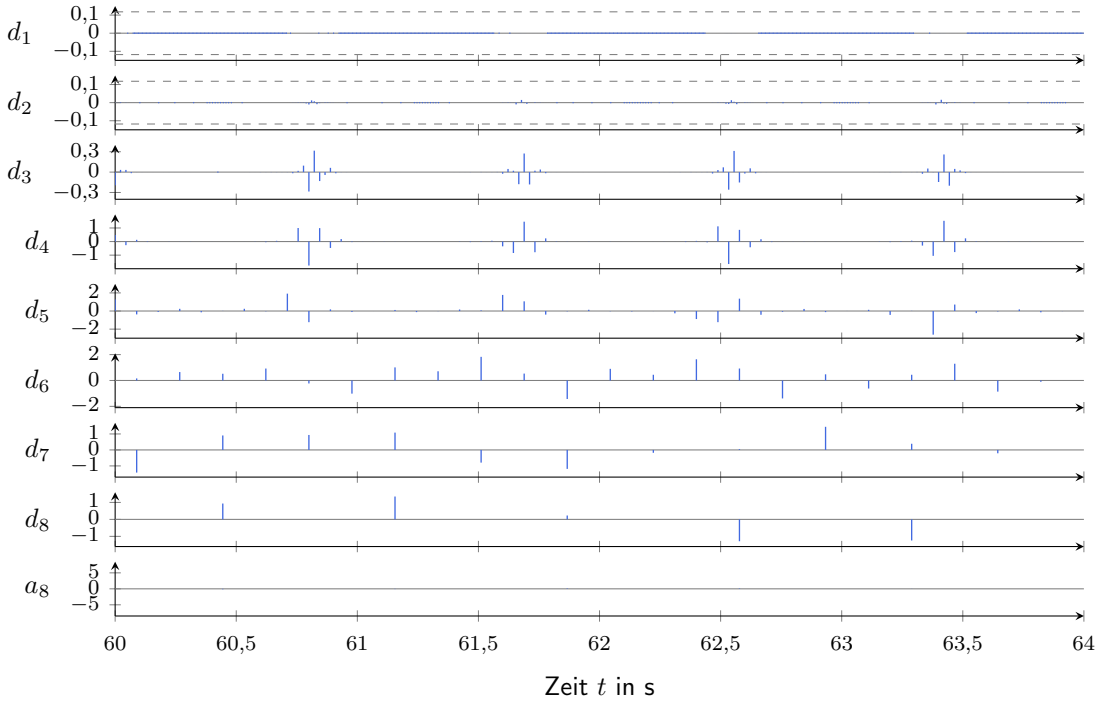


Abbildung 6.6.: Koeffizienten d_1 (oben) bis d_8 und a_8 (unten) von f in mV im Ausschnitt aus Abbildung 6.3. Gestrichelt $\pm T$ auf den geschwellten Stufen (Code in Anhang B.4.7).

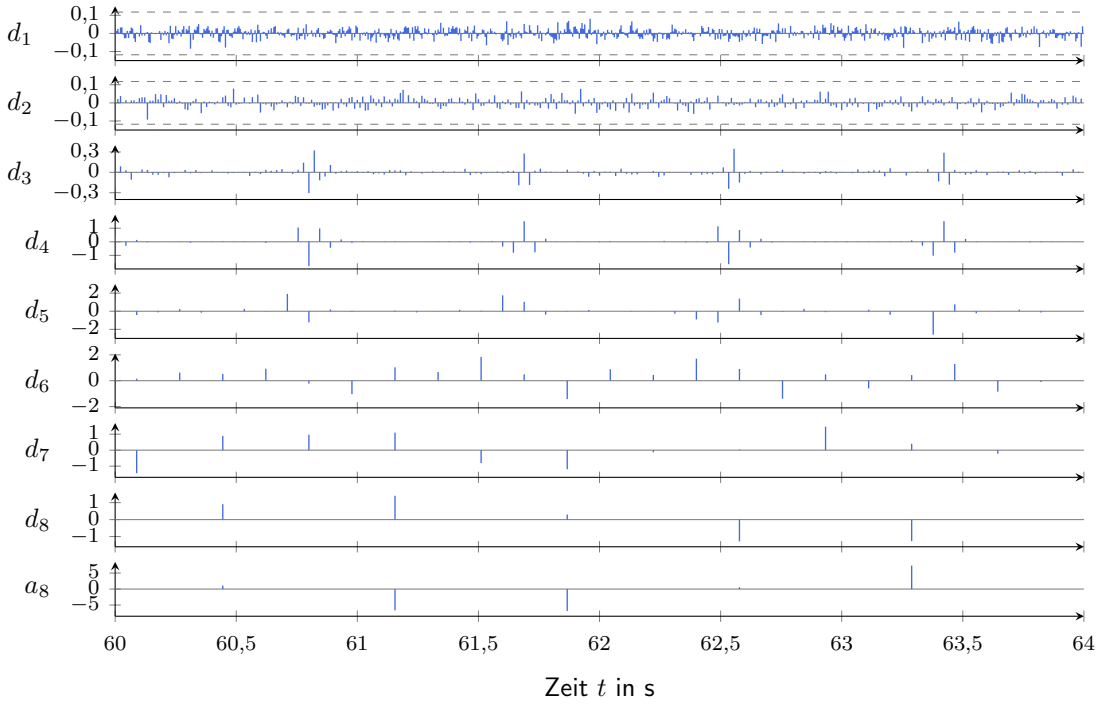


Abbildung 6.7.: Wie Abbildung 6.6, für die Messung Y, Maßstab je Stufe gleich (Code in Anhang B.4.7).

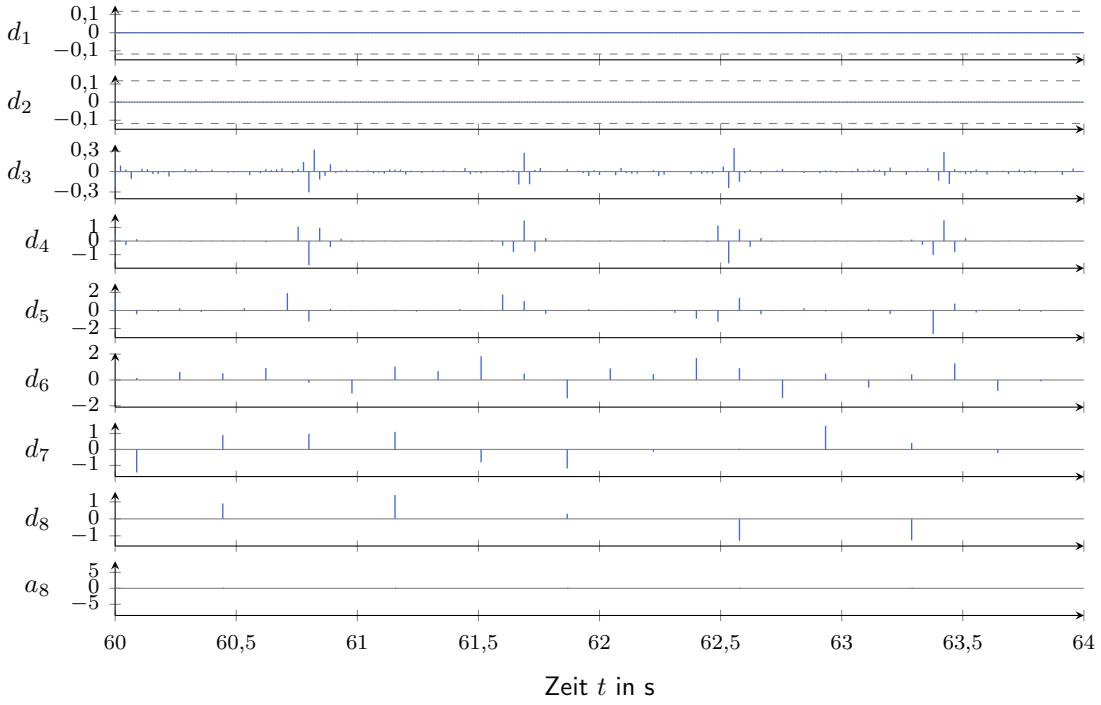


Abbildung 6.8.: Wie Abbildung 6.6, für $\hat{f}$, Maßstab je Stufe gleich (Code in Anhang B.4.7).

Das zeigen die Abbildungen 6.6 bis 6.8 mit den Koeffizienten von f, Y und $\hat{f}$ im selben Ausschnitt. Die Energien sind über das ganze Signal gerechnet (eigene Rechnung, Listing B.13):

- In a_8 liegt bei Y die Drift, bei f fast nichts. In $\hat{f}$ ist a_8 null.
- Auf d_1 und d_2 hat f fast keine Energie ($0{,}2$ und $0{,}4$), Y dort also fast nur Rauschen mit erwarteter Energie $\sigma^2 N/2^j$ ($20{,}5$ und $10{,}2$). Das Thresholding setzt fast alle Koeffizienten auf null und entfernt so das Rauschen.
- Wie Abbildung 6.6 zeigt, hat f auf d_3 noch große Koeffizienten, die zum QRS-Komplex gehören und erhalten bleiben sollen. In Y liegt auf d_3 zusätzlich Rauschen (Abbildung 6.7). Das Verfahren nach Definition 6.3 lässt d_3 unverändert und nimmt damit in Kauf, dass dieses Rauschen in $\hat{f}$ erhalten bleibt (Abbildung 6.8).
- Auch d_4 bis d_8 bleiben unverändert, mit dem kleinen Rauschanteil.

Der Code steht in Listing B.13 (Tabelle 6.3) und Listing B.14 (Abbildungen) im Anhang. Aus Tabelle 6.3 folgt:

- $J = 8$ ist deutlich besser als $J = 7$ und $J = 9$. Das bestätigt (6.5): Mit $J = 7$ wird ein Teil des EKG gelöscht, mit $J = 9$ bleibt Drift stehen.
- Das Thresholding von d_1 und d_2 senkt die Fehlerenergie gegenüber dem bloßen Entfernen der Drift von $51{,}1$ auf $20{,}4$, also auf zwei Fünftel.
- $J_S = 1$ ist deutlich schlechter, weil das Rauschen auf d_2 stehen bleibt. Auch $J_S = 3$ ist schlechter, weil das Schwellen von d_3 mehr vom EKG entfernt als vom Rauschen. Da A orthogonal ist, gilt

$$\|\hat{f} - f\|^2 = \|a_8(\hat{f}) - a_8(f)\|^2 + \sum_{j=1}^{8} \|d_j(\hat{f}) - d_j(f)\|^2,$$

  und beide Varianten unterscheiden sich nur auf d_3. Dort ist der Fehler $5{,}1$, wenn d_3 unverändert bleibt, und $11{,}2$ nach dem Schwellen. Das ergibt $11{,}2 - 5{,}1 = 6{,}1$, bis auf Rundung den Unterschied $26{,}6 - 20{,}4$ der Fehlerenergien (eigene Rechnung, Listing B.13). Das bestätigt die Wahl $J_S = 2$ aus Abschnitt 6.4.
- Hard- und Soft-Thresholding liefern dieselbe Fehlerenergie ($20{,}4$). Soft-Thresholding verkleinert zwar auch die großen Koeffizienten um T und braucht deshalb für ähnliche Ergebnisse oft etwa die halbe Schwelle [Mal09, Kap. 11.2.2]. Auf d_1 und d_2 hat f aber kaum große Koeffizienten. Wir bleiben wie Castillo et al. bei der universellen Schwelle mit Soft-Thresholding, das keine Unstetigkeiten erzeugt [CMG+13, Abschn. 3.1.6, 4].

Kleinere Schwelle auf d_3. Nach den Abbildungen 6.6 und 6.7 liegt auf d_3 neben den großen Koeffizienten des QRS-Komplexes auch Rauschen, das das Verfahren unverändert lässt. Mit der universellen Schwelle $T \approx 0{,}118\,\text{mV}$ entfernt das Schwellen von d_3 aber mehr vom EKG als vom Rauschen. Da am Test-EKG f bekannt ist, probieren wir aus, ob sich f mit einer kleineren Schwelle auf d_3 noch besser rekonstruieren lässt. Wir schwellen d_3 dazu mit cT für c von 0 bis

1 in Schritten von $0{,}05$ und wählen das c mit der kleinsten Fehlerenergie. Das ist $c = 0{,}2$, also die Schwelle $0{,}2\,T \approx 0{,}024\,\mathrm{mV}$, und das Ergebnis ist

$$\hat{f}_3 = A^\top\big(0,\ d_8, \ldots, d_4,\ \rho^{\mathrm{S}}_{0{,}2T}(d_3),\ \rho^{\mathrm{S}}_{T}(d_2),\ \rho^{\mathrm{S}}_{T}(d_1)\big).$$

Die Fehlerenergie sinkt von $20{,}4$ auf $17{,}5$. Der Fehler auf d_3 fällt von $5{,}1$ auf $2{,}2$, alle anderen Stufen bleiben gleich (eigene Rechnung, Listing B.13). Abbildung 6.9 zeigt denselben Herzschlag wie Abbildung 6.5. Oben ist $\hat{f}_3$ vor und nach dem QRS-Komplex etwas glatter als $\hat{f}$. Unten sieht man, dass der Fehler im QRS-Komplex gleich bleibt und vor und nach ihm kleiner wird.

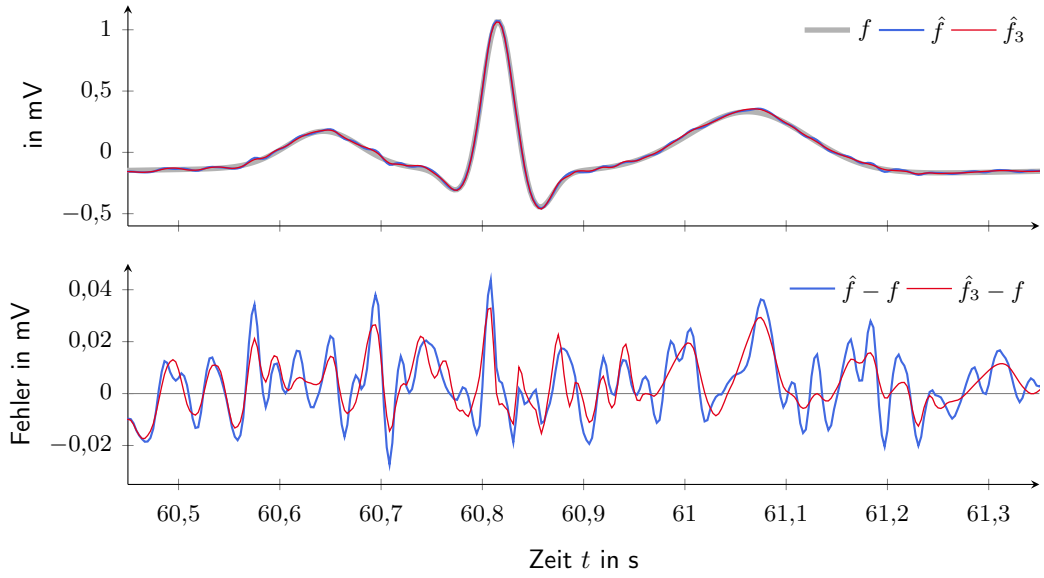


Abbildung 6.9.: Der Herzschlag aus Abbildung 6.5: oben f (grau), $\hat{f}$ (blau) und $\hat{f}_3$ mit Schwelle $0{,}2\,T$ auf d_3 (rot), unten die Fehler $\hat{f} - f$ (blau) und $\hat{f}_3 - f$ (rot) (Code in Anhang B.4.7).

Bei echten Aufzeichnungen lässt sich das nicht umsetzen. Die Schwelle $0{,}2\,T$ haben wir mit Kenntnis von f gewählt, und bei echten Aufzeichnungen ist f unbekannt. Zudem hängt die beste Schwelle vom Rauschen ab. Wir bleiben deshalb beim Verfahren aus Definition 6.3.

6.6. Anwendung auf die Datensätze 100 und 103

Bei den echten Aufzeichnungen ist f unbekannt, ein Fehlermaß wie in Abschnitt 6.5 lässt sich also nicht berechnen. Wir beurteilen das Ergebnis deshalb nur an den Ausschnitten aus Abbildung 6.2.

Abbildung 6.10 zeigt die Messwerte Y und darüber $\hat{f}$. Bei Datensatz 100 liegt die Grundlinie nach dem Entrauschen gleichmäßig bei null; die Anhebung zwischen 395 und $396\,\mathrm{s}$ ist entfernt, die Form der Schläge bleibt erhalten. Bei Datensatz 103 ist die Drift weitgehend entfernt. Nur der schnelle Abfall bei etwa $1090\,\mathrm{s}$ bleibt als Einbruch sichtbar. Abbildung 6.11 vergrößert je $2\,\mathrm{s}$: P-Welle, QRS-Komplex und T-Welle bleiben in Form und Höhe erhalten, $\hat{f}$ ist nur etwas glatter als Y. Das passt zu $\hat{\sigma} \approx 0{,}006\,\mathrm{mV}$: Das weiße Rauschen ist in beiden Datensätzen schwach.

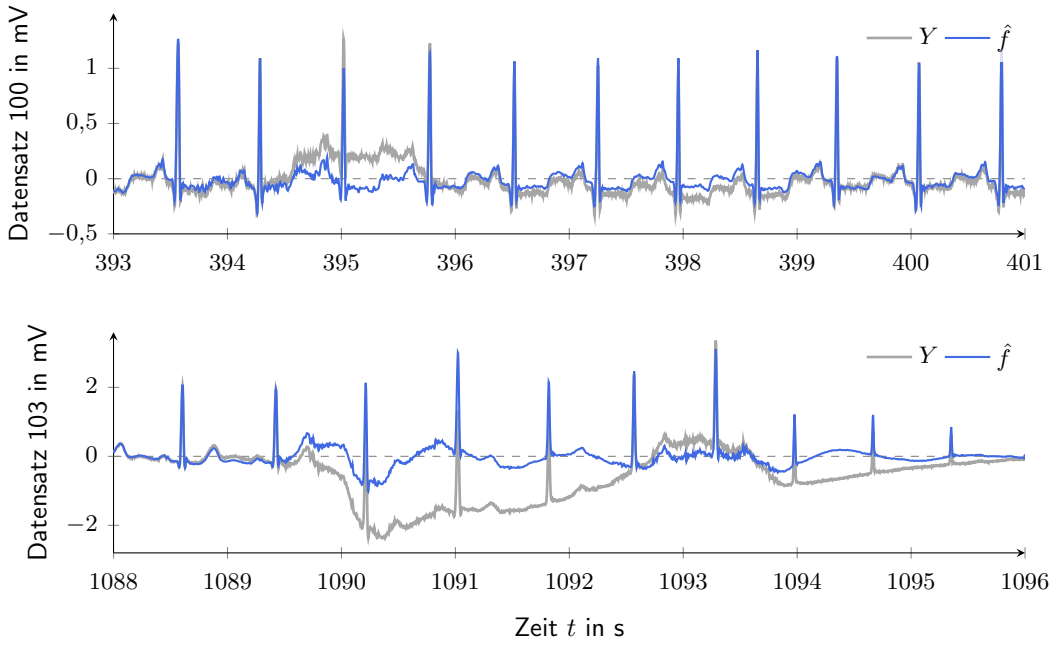


Abbildung 6.10.: Die Ausschnitte aus Abbildung 6.2 vor (Y, grau) und nach dem Entrauschen ($\hat{f}$, blau); gestrichelt die Nulllinie (Code in Anhang B.4.4).

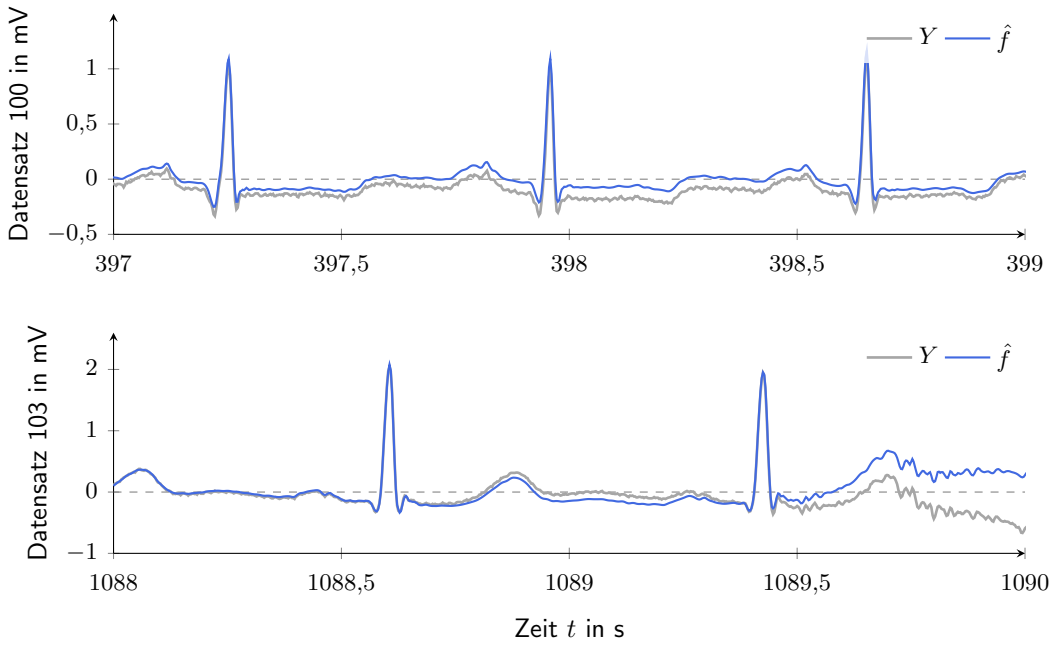


Abbildung 6.11.: Je 2 s aus Abbildung 6.10 vergrößert: vor (Y, grau) und nach dem Entrauschen ($\hat{f}$, blau); gestrichelt die Nulllinie (Code in Anhang B.4.4).

6.7. Diskussion

Am Test-EKG sinkt die Fehlerenergie von $8236{,}4$ auf $20{,}4$, und $J = 8$ ist deutlich besser als $J = 7$ und $J = 9$, wie es(6.5) erwarten lässt (Tabelle 6.3). An den Datensätzen 100 und 103 ist die Drift sichtbar entfernt, die Form der Schläge bleibt erhalten (Abbildung 6.10). Dazu braucht es beide Bausteine: Das Thresholding aus Kapitel 5 entfernt die Drift nicht. Ihre Energie steckt in wenigen großen Koeffizienten von a_J, und große Koeffizienten bleiben beim Thresholding erhalten. Erst die Wahl von J nach den Frequenzen von Drift und Herzschlag erlaubt, a_J gezielt zu entfernen. Beides geschieht in einer einzigen Zerlegung (Abschnitt 6.4).

Die Ergebnisse haben folgende Grenzen.

- Die Aussage über den Fehler gilt nur für das Test-EKG. Es enthält nur eine Sinusdrift und weißes Rauschen, kein Netzbrummen und kein Muskelrauschen. Die echten Aufzeichnungen beurteilen wir nur nach Augenschein. Ob die Änderungen am EKG klinisch unbedenklich sind, müsste ärztlich beurteilt werden; ohne klinische Erfahrung kann ein Verfahren unzulässige Verzerrungen einführen [SL05, Kap. 1.4.1].

- Das Nullsetzen von a_8 entfernt alles unter $0{,}70\,\text{Hz}$, auch langsame Anteile des EKG: Dessen Spektrum reicht nach unten bis $0{,}005\,\text{Hz}$ [Gac12, Kap. 2.4.3.2], bei den MIT-BIH-Daten, die auf $0{,}1$ bis $100\,\text{Hz}$ bandbegrenzt sind, bis $0{,}1\,\text{Hz}$ (Abschnitt 6.2). Bei langsamem Herzschlag unter 42 Schlägen pro Minute läge die Herzfrequenz selbst unter $0{,}70\,\text{Hz}$; Sörnmo und Laguna nennen für Bradykardie etwa 40 Schläge pro Minute [SL05, Kap. 7.1]. Dann wäre $J = 9$ zu wählen, mit mehr verbleibender Drift.

- Elektrodenbewegung liegt bei 1 bis $10\,\text{Hz}$ und damit in den unveränderten Stufen; das Verfahren kann sie nicht entfernen. Ob der Abfall bei $1090\,\text{s}$ in Datensatz 103 von einer Elektrodenbewegung stammt, lässt sich aus den Daten nicht sagen; das Directory markiert den Abschnitt nur als verrauscht. Er bleibt als Einbruch sichtbar.

- Die Schwelle beruht auf einem einzigen $\hat{\sigma}$ aus d_1 und setzt weißes Rauschen voraus. Für Rauschen, das nicht weiß ist, schätzt man σ auf jeder Stufe einzeln [Ale16, Kap. 15.2.2], [CMG+13, Abschn. 3.1.5]. Muskelrauschen liegt bei 20 bis $80\,\text{Hz}$ (Tabelle 6.1), also vor allem in d_2 und d_3. Auf d_3 bleibt es unverändert stehen, und auf d_2 ist die aus d_1 geschätzte Schwelle womöglich zu klein; das Muskelrauschen wird also nur unvollständig entfernt.

- $J_S = 2$ beruht auf der von Castillo et al. übertragenen Grenze $f_S = 31{,}25\,\text{Hz}$ (Abschnitt 6.4) und bestätigt sich am Test-EKG. Welches J_S am besten ist, hängt aber vom Verhältnis von EKG und Rauschen auf d_3 ab: Bei $\sigma = 0{,}01$ und $0{,}05\,\text{mV}$ ist ebenfalls $J_S = 2$ besser ($12{,}0$ statt $14{,}0$ und $50{,}5$ statt $55{,}3$), bei $\sigma = 0{,}1\,\text{mV}$ dagegen $J_S = 3$ ($120{,}2$ statt $170{,}4$; Listing B.13). Bei den Datensätzen 100 und 103 ist $\hat{\sigma} \approx 0{,}006\,\text{mV}$ (Listing B.11), das weiße Rauschen also schwächer als im Test; für dieses spricht das ebenfalls für $J_S = 2$.

- Die Datenbank wurde für die Bewertung von Arrhythmie-Detektoren angelegt [MM01], nicht für das Entrauschen; eine Datenbank für Fragen zu nutzen, für die sie nicht gedacht war, ist ein bekanntes Risiko [SL05, Kap. 1.4.1]. Zudem verwenden wir nur zwei Aufzeichnungen. Die Parameter sind allerdings aus der Literatur übernommen und nicht an diesen Daten angepasst.

Simulierte Signale, bei denen das wahre Signal bekannt ist, erlauben eine Genauigkeitsaussage wie in Abschnitt 6.5, den Hauptteil der Bewertung müssen aber gemessene Aufzeichnungen tragen [SL05, Kap. 1.4.2].

7. Fazit und Ausblick

Anmerkung. Zusammenfassung des Argumentationsbogens und Ausblick auf translationsinvariantes Thresholding, adaptive Schwellen und konkurrierende Zerlegungen.

Belegstellen.

- Mallat, „Translation-Invariant Thresholding", S. 632–633 [bestätigt]; S. 639 [bestätigt]
- Mallat, „Multiscale Sure Thresholds", S. 637 [bestätigt]
- LMR, Kap. 2.4.5 „Biorthogonale Wavelets", S. 184–190 [bestätigt]; Kap. 2.4.7.3 „Coiflets", S. 209 [bestätigt] — naheliegende Erweiterungen der Basiswahl
- LMR, Vorwort zur zweiten Auflage, S. 1 [bestätigt] — Multiwavelets und das Lifting-Prinzip als weiterführende Richtungen
- Rebstadt, Kap. 6.2, S. 76–77 [bestätigt]
- Chatterjee, Kap. 5, S. 585–587 [bestätigt]

A. Ergänzende Rechnungen

A.1. Zulässigkeitskonstante des Haar-Wavelets

Wir berechnen $C_{\psi^{\mathrm{H}}}$ aus (3.2). Für $\omega \neq 0$ ist $\sin(\omega/4)\,\mathrm{sinc}(\omega/4) = 4\sin^2(\omega/4)/\omega$, also

$$\left|\widehat{\psi^{\mathrm{H}}}(\omega)\right|^2 = \frac{16\sin^4(\omega/4)}{2\pi\,\omega^2}.$$

Dieser Ausdruck ist gerade in ω. Mit der Substitution $u = \omega/4$ folgt

$$C_{\psi^{\mathrm{H}}} = 2\pi \cdot 2\int_0^\infty \frac{16\sin^4(\omega/4)}{2\pi\,\omega^3}\,d\omega = 32\int_0^\infty \frac{\sin^4(\omega/4)}{\omega^3}\,d\omega = 2\int_0^\infty \frac{\sin^4 u}{u^3}\,du.$$

Zur Auswertung schreiben wir $8\sin^4 u = g(u)$ mit $g(u) := 3 - 4\cos(2u) + \cos(4u)$. Die Taylorentwicklung liefert $g(u) = 8u^4 + O(u^6)$ für $u \to 0$. Zweimalige partielle Integration ist daher ohne Randterme möglich und ergibt

$$\int_0^\infty \frac{g(u)}{u^3}\,du = \frac{1}{2}\int_0^\infty \frac{g''(u)}{u}\,du = 8\int_0^\infty \frac{\cos(2u) - \cos(4u)}{u}\,du = 8\ln 2.$$

Im letzten Schritt wurde das Frullani-Integral $\int_0^\infty \big(\cos(\alpha u) - \cos(\beta u)\big)/u\,du = \ln(\beta/\alpha)$ für $\alpha, \beta > 0$ verwendet. Also ist $\int_0^\infty \sin^4(u)/u^3\,du = \ln 2$ und $C_{\psi^{\mathrm{H}}} = 2\ln 2$, in Übereinstimmung mit [LMR98, Kap. 1.1, Beispiel (1)].

A.2. Fourier-Transformierte des Testsignals

Wir berechnen $\hat{f}$ für das Testsignal aus Beispiel 3.7. Wegen $f \in L^1(\mathbb{R})$ ist $\hat{f}$ punktweise durch das Integral gegeben. In der Konvention aus Bemerkung 2.10 ist

$$\hat{f}(\omega) = \frac{1}{\sqrt{2\pi}}\left(\int_0^3 \big(1 - \cos(2\pi t)\big)e^{-i\omega t}\,dt + \frac{1}{2}\int_4^5 \big(1 - \cos(10\pi t)\big)e^{-i\omega t}\,dt\right).$$

Sei zunächst $\omega \notin \{0, \pm 2\pi, \pm 10\pi\}$. Benutzt werden nur $\cos x = \frac{1}{2}\big(e^{ix} + e^{-ix}\big)$ und

$$\int_\alpha^\beta e^{ct}\,dt = \frac{1}{c}\big(e^{c\beta} - e^{c\alpha}\big), \qquad c \in \mathbb{C}\setminus\{0\}. \tag{A.1}$$

Die langsame Komponente. Mit $q_1 := 1 - e^{-3i\omega}$ zerlegen wir

$$\int_0^3 \big(1 - \cos(2\pi t)\big)e^{-i\omega t}\,dt = \underbrace{\int_0^3 e^{-i\omega t}\,dt}_{=:A_1} - \underbrace{\int_0^3 \cos(2\pi t)\,e^{-i\omega t}\,dt}_{=:B_1}.$$

Nach (A.1) mit $c = -i\omega$ ist $A_1 = q_1/(i\omega)$. Für B_1 schreiben wir $\cos(2\pi t)e^{-i\omega t} = \frac{1}{2}\big(e^{i(2\pi-\omega)t} + e^{-i(2\pi+\omega)t}\big)$. Nach (A.1) ist

$$B_1 = \frac{e^{3i(2\pi-\omega)} - 1}{2i(2\pi-\omega)} + \frac{e^{-3i(2\pi+\omega)} - 1}{-2i(2\pi+\omega)}.$$

Auf $[0,3]$ liegen genau drei volle Perioden. Daher ist $e^{\pm 6\pi i} = 1$ und $e^{3i(2\pi-\omega)} = e^{-3i(2\pi+\omega)} = e^{-3i\omega}$. Beide Zähler werden zu $-q_1$, und es folgt

$$B_1 = \frac{q_1}{2i}\left(\frac{1}{2\pi+\omega} - \frac{1}{2\pi-\omega}\right) = \frac{q_1\,\omega}{i\,(\omega^2 - 4\pi^2)}.$$

Mit $1/i = -i$ ergibt sich

$$A_1 - B_1 = \frac{q_1}{i}\left(\frac{1}{\omega} - \frac{\omega}{\omega^2 - 4\pi^2}\right) = \frac{i\,4\pi^2\,q_1}{\omega\,(\omega^2 - 4\pi^2)}.$$

Die schnelle Komponente. Mit $q_2 := e^{-4i\omega} - e^{-5i\omega}$ verläuft die Rechnung gleich, mit 10π statt 2π und den Grenzen 4 und 5. An die Stelle von $e^{\pm 6\pi i} = 1$ treten $e^{\pm 40\pi i} = e^{\pm 50\pi i} = 1$. Mit dem Amplitudenfaktor $\frac{1}{2}$ erhält man

$$\frac{1}{2}\left(\int_4^5 e^{-i\omega t}\,dt - \int_4^5 \cos(10\pi t)\,e^{-i\omega t}\,dt\right) = \frac{i\,50\pi^2\,q_2}{\omega\,(\omega^2 - 100\pi^2)}.$$

Ergebnis. Addition beider Anteile und der Vorfaktor $(2\pi)^{-1/2}$ ergeben

$$\hat f(\omega) = \frac{i}{\sqrt{2\pi}\,\omega}\left[\frac{4\pi^2\big(1 - e^{-3i\omega}\big)}{\omega^2 - 4\pi^2} + \frac{50\pi^2\big(e^{-4i\omega} - e^{-5i\omega}\big)}{\omega^2 - 100\pi^2}\right]. \tag{A.2}$$

Da $\hat f$ als Fourier-Transformierte einer L^1-Funktion stetig ist [Ser17, Satz 12.1], gilt (A.2) an den Stellen $\omega \in \{0, \pm 2\pi, \pm 10\pi\}$ im Sinne des Grenzwerts. Direkt aus dem Integral folgen

$$|\hat f(0)| = \frac{7}{2\sqrt{2\pi}}, \qquad |\hat f(\pm 2\pi)| = \frac{3}{2\sqrt{2\pi}}, \qquad |\hat f(\pm 10\pi)| = \frac{1}{4\sqrt{2\pi}}.$$

A.3. Stammfunktion des Testsignals

Für die Stammfunktion $F(t) := \int_{-\infty}^{t} f(s)\,ds$ des Testsignals gilt

$$F(t) = \begin{cases} 0, & t < 0, \\ t - \dfrac{\sin(2\pi t)}{2\pi}, & 0 \le t \le 3, \\ 3, & 3 \le t \le 4, \\ 3 + \dfrac{t-4}{2} - \dfrac{\sin(10\pi t)}{20\pi}, & 4 \le t \le 5, \\ \dfrac{7}{2}, & t > 5. \end{cases}$$

Auf $[0,3]$ folgt das durch direkte Integration. Wegen $\sin(6\pi) = 0$ ist $F(3) = 3$. Auf $[3,4]$ verschwindet f. Auf $[4,5]$ ist

$$F(t) = 3 + \frac{1}{2}\int_4^t \big(1 - \cos(10\pi s)\big)ds = 3 + \frac{t-4}{2} - \frac{\sin(10\pi t)}{20\pi},$$

da $\sin(40\pi) = 0$ ist. Wegen $\sin(50\pi) = 0$ ist $F(5) = \frac{7}{2} = \int_{\mathbb{R}} f$. Das passt zu $\hat{f}(0) = (2\pi)^{-1/2} \cdot \frac{7}{2}$.

B. Python-Code

Alle numerischen Werte und die Daten der Abbildungen dieser Arbeit wurden mit Python (NumPy, PyWavelets [LGW+19]) berechnet. Gezeichnet sind die Abbildungen mit pgfplots. Abgedruckt ist jeweils der rechnende Teil der Skripte, die Zeilen zum Speichern der Daten sind weggelassen.

Anmerkung. Versionen angeben (`python -version`, `pip show numpy pywavelets`).

B.1. Kontinuierliche Wavelet-Transformation

Der folgende Code berechnet die Daten der Abbildungen 3.5 und 3.6. Die Fourier-Transformierte wird nach (A.2) berechnet, die Wavelet-Transformierte nicht durch numerische Quadratur, sondern exakt nach (3.5) aus der Stammfunktion F. Abbildung 3.4 zeichnet pgfplots direkt aus der Definition von f.

Listing B.1: Testsignal aus Beispiel 3.7

```
# Beispiel 3.7: Testsignal, Abbildungen 3.5 und 3.6
import numpy as np
pi = np.pi
omega = np.linspace(-50, 50, 2001)
b, a = np.meshgrid(np.linspace(-0.6, 5.6, 1000), np.geomspace(0.02, 3, 600))

def F(t):
    return np.select([t < 0, t <= 3, t <= 4, t <= 5],
                     [0, t - np.sin(2 * pi * t) / (2 * pi), 3,
                      3 + (t - 4) / 2 - np.sin(10 * pi * t) / (20 * pi)],
                     3.5)

def f_dach(w):
    hebbar = [0, 2 * pi, -2 * pi, 10 * pi, -10 * pi]
    w = np.where(np.isin(w, hebbar), w + 1e-9, w)
    langsam = 4 * pi**2 * (1 - np.exp(-3j * w)) / (w**2 - 4 * pi**2)
    schnell = (50 * pi**2 * (np.exp(-4j * w) - np.exp(-5j * w))
               / (w**2 - 100 * pi**2))
    return 1j * (langsam + schnell) / (np.sqrt(2 * pi) * w)

W = np.abs(2 * F(b + a / 2) - F(b) - F(b + a)) / np.sqrt(a)
```

B.2. Daubechies-Wavelets

Der folgende Code berechnet die Daten der Abbildungen 4.2 und 4.3. PyWavelets berechnet φ_p und ψ_p durch Iteration der Skalierungsgleichung (4.1) und legt ψ_p auf $[0, 2p-1]$. Die

Verschiebung um $p-1$ ergibt den Träger $[1-p, p]$, der nach Satz 4.14 zur Wahl (4.5) gehört.

Listing B.2: Daubechies-Wavelets aus Satz 4.14 und Beispiel 4.15

```
# Satz 4.14 und Beispiel 4.15: Daubechies-Wavelets mit p = 2 und p = 6
import numpy as np
import pywt
for p in [2, 6]:
    phi, psi, t = pywt.Wavelet(f"db{p}").wavefun(level=8)
    tabelle = np.column_stack([t, phi, t + 1 - p, psi])
```

B.3. Entrauschung durch Thresholding

Die Skripte zu Kapitel 5 verwenden durchgehend den Filter (4.4), die periodisierte Transformation (Abschnitt 5.1) mit $J = 5$ Stufen und $N = 2048$ Abtastwerte. Der feste Startwert 93 des Zufallsgenerators sorgt dafür, dass alle Abbildungen dieses Kapitels dieselbe Realisierung des Rauschens zeigen.

B.3.1. Verrauschter Sinus

Der folgende Code berechnet die Daten von Abbildung 5.2 und die Zahlen aus Beispiel 5.5: die Fehlerenergie $\|Y-u\|^2$, ihren Erwartungswert $N\sigma^2$ sowie empirischen Mittelwert und empirische Varianz von $\tilde{Z} = AZ$. Als Kontrolle von Lemma 5.3 gibt das Skript zusätzlich $\|AZ\| - \|Z\|$ aus. Der Wert verschwindet im Rahmen der Rundungsgenauigkeit.

Listing B.3: Verrauschter Sinus aus Beispiel 5.5

```
# Beispiel 5.5: Verrauschter Sinus, Abbildung 5.2
import numpy as np
import pywt
N = 2048
J = 5
sigma = 0.3

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)
Z = np.random.default_rng(93).standard_normal(N)
Y = u + sigma * Z
koeff = pywt.wavedec(Z, "db2", mode="periodization", level=J)
Z_tilde = np.concatenate(koeff)

print(f"||Y - u||^2 = {np.sum((Y - u) ** 2):.1f}")
print(f"N sigma^2 = {N * sigma**2:.1f}")
print(f"Mittelwert Z_tilde = {np.mean(Z_tilde):.2f}")
print(f"Varianz Z_tilde = {np.var(Z_tilde):.2f}")
print(f"||AZ|| - ||Z|| = {np.linalg.norm(Z_tilde) - np.linalg.norm(Z):.1e}")
```

B.3.2. Sinus mit Spitzen

Der folgende Code berechnet die Daten von Abbildung 5.5 und die Zahlen aus Beispiel 5.11: für jede Stufe die Anzahl der Koeffizienten, den größten Betrag beim Sinus und die Anzahl der

Koeffizienten von u und f mit Betrag mindestens σ, außerdem M, die Summe $\sum_{|\theta_m|<\sigma} \theta_m^2$ der gelöschten Koeffizienten und das Risiko r_{id} der idealen Auswahl (5.4).

Listing B.4: Sinus mit Spitzen aus Beispiel 5.11

```
# Beispiel 5.11: Sinus mit Spitzen, Abbildung 5.5
import numpy as np
import pywt
N = 2048
J = 5
sigma = 0.3
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)
s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
f = u + s
Z = np.random.default_rng(93).standard_normal(N)
Y = f + sigma * Z
cu = pywt.wavedec(u, "db2", mode="periodization", level=J)
cf = pywt.wavedec(f, "db2", mode="periodization", level=J)

print("Stufe, Anzahl, max|u|, >= sigma (u), >= sigma (f)")
for name, a, b in zip(["a5", "d5", "d4", "d3", "d2", "d1"], cu, cf):
    print(name, len(a), f"{np.max(np.abs(a)):.2g}",
          np.sum(np.abs(a) >= sigma), np.sum(np.abs(b) >= sigma))
for name, c in [("u", cu), ("f", cf)]:
    theta = np.concatenate(c)
    M = np.sum(np.abs(theta) >= sigma)
    geloescht = np.sum(theta[np.abs(theta) < sigma] ** 2)
    r_id = np.sum(np.minimum(theta**2, sigma**2))
    print(f"{name}: M = {M}, geloescht = {geloescht:.1f}, r_id = {r_id:.1f}"
        )
```

B.3.3. Detailkoeffizienten des Testsignals

Der folgende Code berechnet die Daten von Abbildung 5.6. Der k-te Koeffizient der Stufe j wird in der Mitte des Zeitabschnitts $\left[k\,2^j/256,\ (k+1)\,2^j/256\right)$ eingezeichnet, für den er steht.

Listing B.5: Detailkoeffizienten des Testsignals aus Beispiel 5.11

```
# Beispiel 5.11: Koeffizienten des Testsignals, Abbildung 5.6
import numpy as np
import pywt
N = 2048
J = 5
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)
s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
f = u + s
c = pywt.wavedec(f, "db2", mode="periodization", level=J)
stufe = [J] + list(range(J, 0, -1))
zeit = [(np.arange(len(d)) + 0.5) * 2**j / 256 for d, j in zip(c, stufe)]
```

B.3.4. Detailkoeffizienten der Messwerte

Der folgende Code berechnet die Daten von Abbildung 5.7 und die Zahlen aus dem ersten Absatz von Beispiel 5.14: den Schätzwert $\hat{\sigma}$ nach (5.7), die Schwelle T, den größten Rauschkoeffizienten $\max_m|0{,}3\,\tilde{Z}_m|$ und die Anzahl der Koeffizienten, die Hard-Thresholding behält.

Listing B.6: Detailkoeffizienten der Messwerte aus Beispiel 5.14

```
# Beispiel 5.12: Koeffizienten der Messwerte, Abbildung 5.7
import numpy as np
import pywt
N = 2048
J = 5
sigma = 0.3
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)
s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
f = u + s
Z = np.random.default_rng(93).standard_normal(N)
Y = f + sigma * Z
c = pywt.wavedec(Y, "db2", mode="periodization", level=J)
stufe = [J] + list(range(J, 0, -1))
zeit = [(np.arange(len(d)) + 0.5) * 2**j / 256 for d, j in zip(c, stufe)]

sigma_dach = np.median(np.abs(c[-1])) / 0.6745
T = sigma_dach * np.sqrt(2 * np.log(N))
koeff = pywt.wavedec(Z, "db2", mode="periodization", level=J)
Z_tilde = np.concatenate(koeff)
print(f"sigma_dach = {sigma_dach:.3f}")
print(f"T = {T:.2f}")
print(f"max |sigma Z_tilde| = {sigma * np.max(np.abs(Z_tilde)):.2f}")
print(f"behalten: {np.sum(np.abs(np.concatenate(c)) > T)} von {N}")
```

B.3.5. Entrauschtes Testsignal

Der folgende Code berechnet die Daten von Abbildung 5.8 und die Fehlerenergien aus Beispiel 5.14. Wie in Algorithmus 2 werden alle Koeffizienten mit der Schwelle T bearbeitet, einschließlich der Approximation a_5.

Listing B.7: Entrauschen des Testsignals aus Beispiel 5.14

```
# Beispiel 5.14: Entrauschtes Testsignal, Abbildung 5.8
import numpy as np
import pywt
N = 2048
J = 5
sigma = 0.3
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)
s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
```

```
f = u + s
Z = np.random.default_rng(93).standard_normal(N)
Y = f + sigma * Z
c = pywt.wavedec(Y, "db2", mode="periodization", level=J)
sigma_dach = np.median(np.abs(c[-1])) / 0.6745
T = sigma_dach * np.sqrt(2 * np.log(N))
c_hart = [pywt.threshold(d, T, "hard") for d in c]
c_weich = [pywt.threshold(d, T, "soft") for d in c]
hart = pywt.waverec(c_hart, "db2", mode="periodization")
weich = pywt.waverec(c_weich, "db2", mode="periodization")

print(f"||Y - f||^2 = {np.sum((Y - f) ** 2):.1f}")
print(f"hart:  ||f_hart - f||^2 = {np.sum((hart - f) ** 2):.1f}")
print(f"weich: ||f_weich - f||^2 = {np.sum((weich - f) ** 2):.1f}")
```

B.4. Entrauschung von EKG-Signalen

Die Skripte zu Kapitel 6 lesen ihre Daten aus dem Ordner `data` (im Code `daten`): die Datensätze 100 und 103 der MIT-BIH Arrhythmia Database mit dem Paket `wfdb` und das Test-EKG aus Abschnitt 6.5.

B.4.1. Verfahren

Der folgende Code enthält das Ein-Schritt-Verfahren aus Definition 6.2 mit den Parametern aus Abschnitt 6.4. Die übrigen Skripte dieses Kapitels importieren es. Die zusätzlichen Argumente erzeugen die Varianten aus Tabelle 6.3.

Listing B.8: Ein-Schritt-Verfahren aus Definition 6.2

```
# Abschnitt 6.4: Ein-Schritt-Verfahren nach Castillo et al.
import numpy as np
import pywt

fs = 360
N = 2 ** 19
wavelet = "db6"
J = 8
JS = 2

def entrauschen(y, modus="soft", a_null=True, J=J, JS=JS, JH=0, faktor=1.0):
    c = pywt.wavedec(y, wavelet, mode="periodization", level=J)
    sigma_dach = np.median(np.abs(c[-1])) / 0.6745
    T = sigma_dach * np.sqrt(2 * np.log(len(y)))
    neu = [np.zeros_like(c[0]) if a_null else c[0]]
    for j, d in zip(range(J, 0, -1), c[1:]):
        if j <= JS:
            d = pywt.threshold(d, T, modus)
        elif j <= JS + JH:
            d = pywt.threshold(d, faktor * T, modus)
        neu.append(d)
    return pywt.waverec(neu, wavelet, mode="periodization")
```

B.4.2. Datensätze

Der folgende Code berechnet die Daten von Abbildung 6.2. Von jedem Datensatz wird das obere Signal (MLII) gelesen, auf die ersten $N = 2^{19}$ Werte gekürzt und mittelwertfrei gemacht.

Listing B.9: Ausschnitte aus den Datensätzen 100 und 103

```
# Abschnitt 6.2: Ausschnitte aus den Datensätzen 100 und 103, Abbildung 6.2
import os
import numpy as np
import wfdb
from kap6_verfahren import fs, N
ausschnitte = {"100": 393, "103": 1088}
dauer = 8

spalten = []
for name, von in ausschnitte.items():
    x = wfdb.rdrecord(os.path.join(daten, name)).p_signal[:N, 0]
    y = x - np.mean(x)
    n = np.arange(von * fs, (von + dauer) * fs + 1)
    spalten += [n / fs, y[n]]
```

B.4.3. Annotationen

Der folgende Code wertet die Annotationen der Datensätze aus: die mittlere Herzfrequenz und die des langsamsten Schlags (Abschnitt 6.4.2) sowie die als verrauscht markierten Abschnitte (Abschnitt 6.2). Als Herzschlag zählen alle Annotationen, deren Symbol einen Schlag markiert [MM97]. Das Symbol ~ markiert eine Änderung der Signalqualität. Der Subtyp 0 bedeutet, dass beide Signale sauber sind, 1 das obere und 2 das untere Signal verrauscht.

Listing B.10: Herzfrequenz und verrauschte Abschnitte

```
# Abschnitt 6.2 und 6.4.2: Auswertung der Annotationen der Datensätze 100
    und 103
# (Herzfrequenz aus den Schlagmarkierungen, verrauschte Abschnitte aus der
    Signalqualität)
import numpy as np
import wfdb
from kap6_verfahren import fs, N
    ann = wfdb.rdann("../daten/mitdb/" + name, "atr")
    r = np.array([p for p, z in zip(ann.sample, ann.symbol) if z in schlaege
        and p < N])
    rr = np.diff(r) / fs    # Abstände aufeinanderfolgender Schläge in s
    print(f"{name}: Mittel {60 / np.mean(rr):.1f}/min, langsamster Schlag
        {60 / np.max(rr):.1f}/min")
    # Signalqualität: Symbol "~", Subtyp 0 = beide sauber, 1 = oberes, 2 =
        unteres Signal verrauscht
    for p, z, s in zip(ann.sample, ann.symbol, ann.subtype):
        if z == "~" and p < N:
            print(f"  ab {p / fs:7.1f} s: Signalqualität {s}")
```

B.4.4. Entrauschte Datensätze

Der folgende Code berechnet die Daten der Abbildungen 6.10 und 6.11 und den Schätzer $\hat{\sigma}$ aus (5.7) für beide Datensätze.

Listing B.11: Ausschnitte vor und nach dem Entrauschen

```
# Abschnitt 6.6: Ausschnitte vor und nach dem Entrauschen, Abbildung 6.10
import numpy as np
import pywt
import wfdb
from kap6_verfahren import fs, N, wavelet, entrauschen
ausschnitte = {"100": 393, "103": 1088}
dauer = 8

spalten = []
for name, von in ausschnitte.items():
    x = wfdb.rdrecord(os.path.join(daten, name)).p_signal[:N, 0]
    y = x - np.mean(x)
    f_dach = entrauschen(y)
    d1 = pywt.dwt(y, wavelet, mode="periodization")[1]
    print(f"{name}: sigma_dach = {np.median(np.abs(d1)) / 0.6745:.4f} mV")
    n = np.arange(von * fs, (von + dauer) * fs + 1)
    spalten += [n / fs, y[n], f_dach[n]]
```

B.4.5. Test-EKG

Der folgende Code erzeugt das Test-EKG f aus Abschnitt 6.5 mit dem Modell ECGSYN [MCTS03] aus dem Paket NeuroKit2 [MPL+21] (Version 0.3.0) und speichert es in `data/testekg.dat`. Die Funktion `ableitung_ohne_drift` ist die rechte Seite der Differentialgleichung aus NeuroKit2 ohne die eingebaute Atmungsdrift.

Listing B.12: Erzeugung des Test-EKG

```
# Abschnitt 6.5: Erzeugung des Test-EKG ohne Atmungsdrift
import functools
import math
import sys
import numpy as np
import scipy.integrate
import neurokit2 as nk
from kap6_verfahren import fs
n = 2 ** 16

def ableitung_ohne_drift(t, x, rr, ti, sfint, ai, bi):
    ta = math.atan2(x[1], x[0])
    a0 = 1.0 - np.sqrt(x[0] ** 2 + x[1] ** 2)
    w0 = 2 * np.pi / rr[min(int(np.floor(t * sfint)), len(rr) - 1)]
    dti = (ta - ti) - np.round((ta - ti) / 2 / np.pi) * 2 * np.pi
    dz = -np.sum(ai * dti * np.exp(-0.5 * (dti / bi) ** 2)) - x[2]
    return np.array([a0 * x[0] - w0 * x[1], a0 * x[1] + w0 * x[0], dz])

scipy.integrate.solve_ivp = functools.partial(scipy.integrate.solve_ivp,
                                              rtol=1e-8, atol=1e-10)
```

```
modul = sys.modules["neurokit2.ecg.ecg_simulate"]
modul._ecg_simulate_derivsecgsyn = ableitung_ohne_drift
f = nk.ecg_simulate(duration=n / fs + 2, sampling_rate=fs, heart_rate=70,
                    noise=0, method="ecgsyn", random_state=42)
f = np.asarray(f[:n])
f = f - np.mean(f)
print(f"||f||^2 = {np.sum(f ** 2):.0f}")
```

B.4.6. Test

Der folgende Code liest das Test-EKG, erzeugt die gestörte Messung Y und berechnet die Fehlerenergien aus Tabelle 6.3, die Energien je Stufe, die Fehlerenergie für verschiedene Schwellen auf d_3, die Kontrolle über 10 Realisierungen von Z und die Abhängigkeit vom Rauschpegel.

Listing B.13: Test an einem künstlichen EKG

```
# Abschnitt 6.5: Test an einem künstlichen EKG, Tabelle 6.3
import numpy as np
import pywt
from kap6_verfahren import fs, entrauschen
DRIFT = (0.5, 0.25)
SIGMA = 0.025
SEED = 0

def testsignal():
    return np.loadtxt(os.path.join(daten, "testekg.dat"), skiprows=1)

def drift(n):
    return DRIFT[0] * np.sin(2 * np.pi * DRIFT[1] * np.arange(n) / fs)

def gestoert(f, seed, sigma=SIGMA):
    z = np.random.default_rng(seed).standard_normal(len(f))
    return f + drift(len(f)) + sigma * z

def fehler(f, g):
    return np.sum((g - f) ** 2)

varianten = {"Verfahren": {}, "Hard": dict(modus="hard"),
             "J_S = 1": dict(JS=1), "J_S = 3": dict(JS=3),
             "d_3 mit 0,2 T": dict(JH=1, faktor=0.2), "nur Drift": dict(JS
                 =0),
             "J = 7": dict(J=7), "J = 9": dict(J=9)}

if __name__ == "__main__":
    f = testsignal()
    y = gestoert(f, SEED)
    print(f"||f||^2 = {np.sum(f ** 2):.0f}")
    print(f"vorher: {fehler(f, y):.1f}")
    for name, arg in varianten.items():
        print(f"{name}: {fehler(f, entrauschen(y, **arg)):.1f}")

    zerl = lambda x: pywt.wavedec(x, "db6", mode="periodization",
                                  level=8)[::-1]
    sigma_dach = np.median(np.abs(zerl(y)[0])) / 0.6745
```

```
38      print(f"T = {sigma_dach * np.sqrt(2 * np.log(len(y))):.3f}")
39      print("Stufe: Energie f, sigma^2 N/2^j, Fehler je Variante")
40      c = zerl(f)
41      auswahl = ["Verfahren", "J_S = 3", "d_3 mit 0,2 T"]
42      fe = [zerl(entrauschen(y, **varianten[v]) - f) for v in auswahl]
43      for j in range(1, 5):
44          erwartet = SIGMA**2 * len(f) / 2**j
45          print(f"d_{j}: {np.sum(c[j - 1] ** 2):.1f}, {erwartet:.1f},",
46                ", ".join(f"{np.sum(e[j - 1] ** 2):.1f}" for e in fe))
47      print("a_8:", ", ".join(f"{np.sum(e[-1] ** 2):.1f}" for e in [c] + fe))
48
49      print("d_3 mit faktor * T:")
50      for faktor in np.arange(0, 1.01, 0.05):
51          e = fehler(f, entrauschen(y, JH=1, faktor=faktor))
52          print(f"{faktor:.2f}: {e:.1f}")
53
54      print("Kontrolle, 10 Realisierungen (min, max, Abweichung von Seed 0):")
55      for name, arg in [("vorher", None)] + list(varianten.items()):
56          y_s = [gestoert(f, s) for s in range(10)]
57          e = [fehler(f, y if arg is None else entrauschen(y, **arg))
58               for y in y_s]
59          abw = max(abs(x - e[0]) for x in e) / e[0]
60          print(f"{name}: {min(e):.1f}, {max(e):.1f}, {abw:.1%}")
61
62      print("Rauschpegel sigma: J_S = 2, J_S = 3, d_3 mit 0,2 T")
63      for s in [0.01, 0.025, 0.05, 0.1]:
64          y_s = gestoert(f, SEED, sigma=s)
65          werte = [fehler(f, entrauschen(y_s, **arg))
66                   for arg in (dict(JS=2), dict(JS=3), dict(JH=1, faktor=0.2))
                     ]
67          print(f"{s}:", ", ".join(f"{w:.1f}" for w in werte))
```

B.4.7. Abbildungen zum Test

Der folgende Code berechnet die Daten der Abbildungen 6.3 bis 6.8 im Ausschnitt 60 bis 64 Sekunden. Der Koeffizient k der Stufe j gehört zur Zeit $k \cdot 2^j / f_s$.

Listing B.14: Abbildungen zum Test

```
1  # Abschnitt 6.5: Daten der Abbildungen 6.3 bis 6.10 zum Test-EKG
2  import numpy as np
3  import pywt
4  from kap6_verfahren import fs, wavelet, J, entrauschen
5  from kap6_test import testsignal, gestoert, drift, SEED
6  von, bis = 60, 64
7
8  f = testsignal()
9  y = gestoert(f, SEED)
10 f_dach = entrauschen(y)
11 f_dach3 = entrauschen(y, JH=1, faktor=0.2)
12 t = np.arange(len(f)) / fs
13 m = (t >= von) & (t < bis)
14
15 def zerlegung(x):
```

```
16      c = pywt.wavedec(x, wavelet, mode="periodization", level=J)
17      return c[:0:-1] + [c[0]]
18
19  stufe = list(range(1, J + 1)) + [J]
20
21  tabelle = np.column_stack([t, f, y, drift(len(f)), f_dach, f_dach3])[m]
22  kopf = "t f Y b fdach fdach3"
23  np.savetxt(os.path.join(ordner, "kap6_test.dat"), tabelle, header=kopf,
        comments="", fmt="%.6f")
24  namen = ["d1", "d2", "d3", "d4", "d5", "d6", "d7", "d8", "a8"]
25  kopf = " ".join(f"t{n} {n}" for n in namen)
26  for name, x in [("f", f), ("Y", y), ("fdach", f_dach)]:
27      tabelle = np.full((int((bis - von) * fs) // 2, 18), np.nan)
28      for i, (d, j) in enumerate(zip(zerlegung(x), stufe)):
29          tk = np.arange(len(d)) * 2**j / fs
30          mk = (tk >= von) & (tk < bis)
31          tabelle[:mk.sum(), 2 * i], tabelle[:mk.sum(), 2 * i + 1] = tk[mk], d
                [mk]
32      np.savetxt(os.path.join(ordner, f"kap6_zerlegung_{name}.dat"), tabelle,
            header=kopf, comments="", fmt="%.6f")
```

Literaturverzeichnis

[AJB17] Mounaim Aqil, Atman Jbari, and Abdennasser Bourouhou. ECG signal denoising by discrete wavelet transform. *International Journal of Online Engineering (iJOE)*, 13(9):51–68, 2017.

[Ale16] Silvia Maria Alessio. *Digital Signal Processing and Spectral Analysis for Scientists. Concepts and Applications*. Signals and Communication Technology. Springer, Cham, 2016.

[BK19] Steven L. Brunton and J. Nathan Kutz. *Fourier and Wavelet Transforms*, pages 47–83. Cambridge University Press, Cambridge, 2019.

[Bla03] Christian Blatter. *Wavelets – Eine Einführung*. Advanced Lectures in Mathematics. Vieweg, Braunschweig/Wiesbaden, 2., durchgesehene edition, 2003.

[CMG+13] Encarnación Castillo, Diego P. Morales, Antonio García, Francisco Martínez-Martí, Luis Parrilla, and Alberto J. Palma. Noise suppression in ECG signals through efficient one-step wavelet processing techniques. *Journal of Applied Mathematics*, 2013:763903, 2013.

[CTY+20] Shubhojeet Chatterjee, Rini Smita Thakur, Ram Narayan Yadav, Lalita Gupta, and Deepak Kumar Raghuvanshi. Review of noise removal techniques in ECG signals. *IET Signal Processing*, 14(9):569–590, 2020.

[Gac12] Adam Gacek. An introduction to ECG signal processing and analysis. In Adam Gacek and Witold Pedrycz, editors, *ECG Signal Processing, Classification and Interpretation*, pages 21–46. Springer, London, 2012.

[HB09] Martin Hanke-Bourgeois. *Grundlagen der Numerischen Mathematik und des Wissenschaftlichen Rechnens*. Vieweg+Teubner, Wiesbaden, 3., aktualisierte edition, 2009.

[KS20] Pramendra Kumar and Vijay Kumar Sharma. Detection and classification of ECG noises using decomposition on mixed codebook for quality analysis. *Healthcare Technology Letters*, 7(1):18–24, 2020.

[LGW+19] Gregory R. Lee, Ralf Gommers, Filip Wasilewski, Kai Wohlfahrt, and Aaron O'Leary. PyWavelets: A Python package for wavelet analysis. *Journal of Open Source Software*, 4(36):1237, 2019.

[LMR98] Alfred Karl Louis, Peter Maaß, and Andreas Rieder. *Wavelets: Theorie und Anwendungen*. Teubner-Studienbücher: Mathematik. B. G. Teubner, Stuttgart, 2., überarbeitete und erweiterte edition, 1998.

[Mal09] Stéphane Mallat. *A Wavelet Tour of Signal Processing: The Sparse Way*. Academic Press / Elsevier, Burlington, MA, 3. edition, 2009.

[MCTS03] Patrick E. McSharry, Gari D. Clifford, Lionel Tarassenko, and Leonard A. Smith. A dynamical model for generating synthetic electrocardiogram signals. *IEEE Transactions on Biomedical Engineering*, 50(3):289–294, 2003.

[MM97] George B. Moody and Roger G. Mark. MIT-BIH arrhythmia database directory. https://archive.physionet.org/physiobank/database/html/mitdbdir/mitdbdir.htm, 1997. HTML-Ausgabe vom 24.05.1997, Einleitung überarbeitet am 24.06.2010; abgerufen am 09.10.2026.

[MM01] George B. Moody and Roger G. Mark. The impact of the MIT-BIH arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3):45–50, 2001.

[MM05] George B. Moody and Roger G. Mark. MIT-BIH arrhythmia database, version 1.0.0. PhysioNet, https://physionet.org/content/mitdb/1.0.0/, 2005. Abgerufen am 19.10.2026.

[MPL+21] Dominique Makowski, Tam Pham, Zen J. Lau, Jan C. Brammer, François Lespinasse, Hung Pham, Christopher Schölzel, and S. H. Annabel Chen. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods*, 53(4):1689–1696, 2021.

[PML+26] Tom Pollard, Benjamin E. Moody, Li-wei Lehman, Brian Gow, Chrystinne Fernandes, Chenxi Xie, Alistair Johnson, Roger G. Mark, and Thomas Heldt. PhysioNet as a global platform for biomedical research. *Nature Health*, 1(8):792–795, 2026.

[Reb21] Linda Rebstadt. Spark-basierte analyse von monitoring-daten intensiv überwachter patienten zur identifikation von anomalien: Ein use case der charité health data platform. Masterarbeit, Hochschule Darmstadt, 2021.

[Ser17] Valery Serov. *Fourier Series, Fourier Transform and Their Applications to Mathematical Physics*, volume 197 of *Applied Mathematical Sciences*. Springer, Cham, 2017.

[SL05] Leif Sörnmo and Pablo Laguna. *Bioelectrical Signal Processing in Cardiac and Neurological Applications*. Elsevier Academic Press, Burlington, 2005.

[SS03] Elias M. Stein and Rami Shakarchi. *Fourier Analysis: An Introduction*, volume I of *Princeton Lectures in Analysis*. Princeton University Press, Princeton, 2003.