

Universität Hamburg
DER FORSCHUNG | DER LEHRE | DER BILDUNG

BACHELORARBEIT

Die diskrete Wavelet-Transformation und ihre Anwendung zur Entrauschung von EKG-Signalen

ausgeführt am

Fachbereich Mathematik
Fakultät für Mathematik, Informatik und Naturwissenschaften
Universität Hamburg

unter der Anleitung von

Name des Betreuers

durch

Hilda Beuting
Matrikelnummer: 12345678
Straße und Hausnummer
PLZ und Ort

Hamburg, am Datum

Inhaltsverzeichnis

1. Einleitung **1**
- 1.1. Motivation: EKG-Signale und ihre Störquellen . . . 1
- 1.2. Warum die Fourier-Analyse nicht genügt . . . 1
- 1.3. Zielsetzung und Abgrenzung . . . 2
- 1.4. Aufbau der Arbeit . . . 2

2. Funktionalanalytische Grundlagen **3**
- 2.1. Der Hilbertraum $L^2(\mathbb{R})$ . . . 3
- 2.2. Orthonormalbasen und ihre Charakterisierung . . . 3
- 2.3. Unitäre Operatoren . . . 4
- 2.4. Fourier-Transformation und Satz von Plancherel . . . 4
- 2.5. Die gefensterte Fourier-Transformation . . . 5
- 2.6. Grundbegriffe der Wahrscheinlichkeitsrechnung . . . 5

3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse **6**
- 3.1. Die kontinuierliche Wavelet-Transformation . . . 6
  - 3.1.1. Wavelets und die Zulässigkeitsbedingung . . . 6
  - 3.1.2. Die Wavelet-Familie und die Transformation . . . 8
  - 3.1.3. Die Plancherel-Formel . . . 12
- 3.2. Das dyadische Gitter und die Multiskalenanalyse . . . 12
- 3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j . . . 16
  - 3.3.1. Die Orthonormalbasis auf allen Skalen . . . 16
  - 3.3.2. Die Approximationsoperatoren . . . 16
- 3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$ . . . 17
  - 3.4.1. Die Wavelet-Basis . . . 18

4. Konstruktion der diskreten Wavelet-Transformation **20**
- 4.1. Die Skalierungsgleichung . . . 20
- 4.2. Filterkoeffizienten: Tiefpass und Hochpass . . . 21
- 4.3. Bedingungen im Fourier-Bereich . . . 23
- 4.4. Der Mallat-Algorithmus . . . 24
- 4.5. Daubechies-Wavelets . . . 26

5. Entrauschung durch Thresholding **30**
- 5.1. Rauschmodell und diskrete Wavelet-Transformation . . . 30
- 5.2. Diagonale Schätzer und Thresholding . . . 33
- 5.3. Die Wahl der Schwelle . . . 38
- 5.4. Schätzung der Rauschstärke . . . 39

6. Anwendung: Entrauschung von EKG-Signalen **42**
6.1. EKG-Signale und ihre Störquellen . . . 42
6.2. Die Datensätze . . . 43
6.3. Skalen als Frequenzbänder . . . 45
6.4. Das Verfahren . . . 46
6.4.1. Modell und Ein-Schritt-Verfahren . . . 46
6.4.2. Tiefe J für die Drift . . . 48
6.4.3. Anzahl J_S der geschwellten Stufen . . . 48
6.4.4. Schwelle . . . 49
6.5. Test an einem künstlichen EKG . . . 50
6.6. Anwendung auf die Datensätze 100 und 103 . . . 57
6.7. Diskussion . . . 57

7. Fazit und Ausblick **60**

A. Ergänzende Rechnungen **61**
A.1. Zulässigkeitskonstante des Haar-Wavelets . . . 61
A.2. Fourier-Transformierte des Testsignals . . . 61
A.3. Stammfunktion des Testsignals . . . 62

B. Python-Code **64**
B.1. Beispiel zur kontinuierlichen Wavelet-Transformation . . . 64
B.2. Daubechies-Wavelet . . . 66
B.3. Daubechies-Wavelet mit zwölf Koeffizienten . . . 66
B.4. Verrauschter Sinus . . . 67
B.5. Sinus mit Spitzen . . . 68
B.6. Detailkoeffizienten des Testsignals . . . 69
B.7. Detailkoeffizienten der Messwerte . . . 70
B.8. Entrauschtes Testsignal . . . 71
B.9. Anwendung auf EKG-Signale . . . 72

Literaturverzeichnis **81**

1. Einleitung

Anmerkung. Einleitung ganz zum Schluss schreiben. Laut Vorlage muss hier stehen: (a) Worum geht es, (b) Einordnung ins Forschungsfeld, (c) Fragestellung, (d) Relevanz, (e) vorhandene Literatur, (f) EIGENER ANTEIL der Arbeit, (g) grober Aufbau der Arbeit.

1.1. Motivation: EKG-Signale und ihre Störquellen

Anmerkung. EKG-Signale und ihre Störquellen Das EKG ist ein nichtstationäres biomedizinisches Signal, dessen diagnostisch entscheidende Strukturen von Störungen überlagert werden, die im selben Frequenzband liegen wie das Nutzsignal — womit einfache Frequenzfilter ausscheiden.

Anmerkung. hier schon kurzer aufbau ekg signal kurzer qrskomplex und langer t p welle...

Belegstellen.

- LMR, Kap. 3.1.2 „EKG-Analyse", S. 238–240 [bestätigt] — Herzklappenrhythmus und „late potentialsäls diagnostische Fragestellungen; Abb. 3.1 (S. 239)
- Gacek, Kap. 2.1, S. 21–22 [bestätigt] — diagnostische Bedeutung, historische Einordnung
- Gacek, Kap. 2.3, S. 25–27 [bestätigt] — Störquellen im Überblick
- Chatterjee, Kap. 1.1 „Predominant noises in ECG", S. 570 [bestätigt]
- Aqil, Kap. 2, S. 53–54 [bestätigt] — Fig. 3, Rauschtypen
- Rebstadt, Kap. 2.1, S. 7–11 [bestätigt] — Abb. 2.3 (S. 10)

1.2. Warum die Fourier-Analyse nicht genügt

Anmerkung. VERSCHOBEN aus dem alten Abschnitt 2.5. Begründung: In Kapitel 2 war das ein Fremdkörper – dort werden Werkzeuge bereitgestellt, hier wird die Fragestellung motiviert. Der Abschnitt liefert genau das Argument, das die ganze Arbeit trägt: Die Fourier-Basis sagt, *welche* Frequenzen auftreten, nicht *wann*.

Anmerkung. Die Fourier-Basis ist global; sie sagt welche Frequenzen auftreten, nicht wann — bei einem QRS-Komplex ist genau die Lokalisierung entscheidend.

Belegstellen.

- LMR, Kap. 1.3.2 „Wavelet-Transformation und gefensterte Fourier-Transformation", S. 36–37 [bestätigt] — direkter Vergleich beider Transformationen, in der 2. Auflage eigens dafür neu aufgenommen

- LMR, Kap. 1.3.1 „Phasenraumdarstellung", S. 30–35 [bestätigt]
- LMR, Vorwort zur ersten Auflage, S. 3 [bestätigt] — fehlende Lokalisierungseigenschaft der Fourier-Transformation, prägnant formuliert
- Blatter, Kap. 1.4, S. 10–12 [bestätigt]; Kap. 2.3 „Heisenbergsche Unschärferelation", S. 43–46 [bestätigt]
- SteinShakarchi, Kap. 5.4, S. 158–160 [bestätigt]
- HankeBourgeois, Beispiel 52.7 mit Abbildung 52.1, S. 403–404 [bestätigt] — reales EKG-Signal mit $N = 2048$ Meßwerten und seinen Bestapproximationen aus T_8 und T_{32} ; die scharfen Peaks werden mit sinkendem Polynomgrad ausgeglättet, t_8 „übersieht"das Minimum am ca. 200. Datenpunkt
- HankeBourgeois, S. 433–434 [bestätigt] — quantitativ: die Fourierkoeffizienten von $\chi_{[a,b]}$ fallen nur wie $1/k$, der L^2-Fehler nach n Termen ist $\sim n^{-1/2}$; „schlechte Lokalisierungseigenschaft bezüglich der Ortsvariablen"
- HankeBourgeois, Beispiel 56.3 mit Abbildung 56.2, S. 440 [bestätigt] — Fourier- vs. Waveletkoeffizienten desselben EKG-Signals in logarithmischer Skala
- Rebstadt, Abb. 2.7, S. 22 [bestätigt]
- Fußnote S. 404: Die EKG-Daten stammen laut HankeBourgeois von Prof. Dr. P. Maaß, Universität Bremen — demselben Maaß wie in Louis/Maaß/Rieder. Deine beiden deutschsprachigen Quellen arbeiten am selben Signal.

1.3. Zielsetzung und Abgrenzung

Anmerkung. Ziel ist die mathematisch vollständige Herleitung der DWT-Entrauschung; Abgrenzung gegenüber konkurrierenden Verfahren, die nur benannt werden.

Belegstellen.

- LMR, Vorwort zur ersten Auflage, S. 3–4 [bestätigt] — Verzahnung von Theorie und Anwendung als Programm
- Chatterjee, Kap. 2–4, S. 571–581
- Rebstadt, Kap. 2.3, S. 14–31 [bestätigt]

1.4. Aufbau der Arbeit

2. Funktionalanalytische Grundlagen

Anmerkung. Block A. Kapiteleinleitung: Ziel ist der funktionalanalytische Rahmen, in dem die Wavelet-Transformation als unitäre Abbildung erscheint.

2.1. Der Hilbertraum $L^2(\mathbb{R})$

Anmerkung. Einführung von $L^2(\mathbb{R})$ als vollständigem Raum mit Skalarprodukt — dem Raum, in dem sämtliche Signale und Wavelets im Folgenden leben.

Belegstellen.

- Serov, Kap. 25, S. 249–253 [bestätigt] (Def. 25.1 Skalarprodukt, Def. 25.7 Hilbertraum)
- Blatter, Kap. 2.1, S. 26–27 [bestätigt]
- LMR, „Notationen", S. 9–12 [bestätigt] — Räume $L^p, C^(\infty), S(\mathbb{R}), S'(\mathbb{R})$ in genau der Notation, die LMR durchgehend verwendet

2.2. Orthonormalbasen und ihre Charakterisierung

Anmerkung. Der zentrale Satz: Vollständigkeit, Parseval-Gleichung und die Entwicklung jedes Elements sind für ein Orthonormalsystem äquivalent.

Belegstellen.

- Serov, Satz 25.18 „Characterization of an orthonormal basis", S. 258 [bestätigt]
- Serov, Def. 25.16–25.17, S. 257–258 [bestätigt]
- Serov, Satz 25.12 (Projektionssatz), S. 254–255 [geschätzt]
- Blatter, Kap. 2.1, S. 27 [bestätigt]
- HankeBourgeois, Satz 31.6, S. 281 [bestätigt] — (a) Entwicklung, (b) Satz des Pythagoras, (c) Bestapproximation, (d) Besselsche Ungleichung, mit Beweis
- HankeBourgeois, §31 „Innenprodukträume, Orthonormalbasen und Gramsche Matrizen", S. 275–282 [bestätigt]; Definition von $L\omega$, S. 279–280 [geschätzt]

2.3. Unitäre Operatoren

Anmerkung. Ein unitärer Operator ist eine surjektive Isometrie; er erhält Skalarprodukte und damit Energie — der Grund, warum Rauschen unter der DWT seine Statistik behält.

Belegstellen.

- Serov, Def. 27.7 und Bem. 27.8, S. 282 [bestätigt] (Sachverz.: „unitary operator, 282")
- LMR, Kap. 1.2 „Affine Operatoren", S. 26–29 [bestätigt] — Dilatationsoperator D_a, Translationsoperator T_b, beide Isometrien mit Bild ganz L^2, daher Adjungierte = Inverse
- LMR, Lemma 1.2.1 (adjungierte affine Operatoren), S. 27 [bestätigt]
- LMR, S. 27 [bestätigt] — affin-lineare Gruppe $G_{a,f}$ und Verknüpfungsgesetz $T_{b'}D_{a'}T_bD_a = T_{b'+a'b}D_{aa'}$

Definition 2.1 (Isometrie, unitärer Operator, vgl. [Ser17, Def. 27.6, Def. 27.7])**.** Seien $\mathcal{H}_1$ und $\mathcal{H}_2$ Hilberträume. Eine lineare Abbildung $U\colon \mathcal{H}_1 \to \mathcal{H}_2$ heißt Isometrie, wenn $\|Ux\| = \|x\|$ für alle $x \in \mathcal{H}_1$ gilt. Eine surjektive Isometrie heißt unitär.

Eine Isometrie erhält auch Skalarprodukte, also $\langle Ux, Uy\rangle = \langle x, y\rangle$ für alle x, y [Ser17, Übung 27.2]. Serov formuliert die Definition für $\mathcal{H}_1 = \mathcal{H}_2$. Wir brauchen sie auch für verschiedene Räume, etwa für die Abbildung von $L^2(\mathbb{R})$ in den Bildraum der Wavelet-Transformation (Satz 3.8).

2.4. Fourier-Transformation und Satz von Plancherel

Anmerkung. Die Fourier-Transformation setzt sich von der Schwartz-Klasse eindeutig zu einem unitären Isomorphismus auf $L^2(\mathbb{R})$ fort.

Belegstellen.

- Serov, Satz 17.5 (Plancherel), S. 145 [bestätigt]
- Serov, Kap. 16–17, S. 133–152 [bestätigt]
- SteinShakarchi, Kap. 5.1, S. 131–144 [bestätigt]
- Blatter, Kap. 2.2, S. 31–42 [bestätigt]; Plancherel-Formel S. 36 [bestätigt]
- LMR, Anhang „Fourier-Transformation", S. 313–316 [bestätigt] — kompakte Zusammenstellung genau der Regeln, die LMR im Waveletteil benutzt

Bemerkung 2.2 (Fourier-Konvention)**.** In dieser Arbeit wird durchgehend die unitäre Normierung

$$\hat{f}(\omega) \;=\; (2\pi)^{-1/2} \int_{\mathbb{R}} f(t)\, e^{-i\omega t}\, dt$$

verwendet. Mit ihr ist die Fourier-Transformation ein unitärer Operator auf $L^2(\mathbb{R})$, und die Plancherel-Formel gilt ohne Vorfaktor: $\langle f, g\rangle = \langle \hat{f}, \hat{g}\rangle$.

Die Literatur normiert uneinheitlich, und die Konstanten der folgenden Kapitel hängen von der Wahl ab: Der Faktor 2π in der Zulässigkeitsbedingung (3.1) und der Wert $|\hat{\varphi}(0)| = (2\pi)^{-1/2}$ in Abschnitt 4.1 gelten nur für diese Normierung. Beim Vergleich mit einer Quelle ist deshalb zuerst deren Konvention nachzusehen.

Anmerkung. das vll besser erst später

2.5. Die gefensterte Fourier-Transformation

Anmerkung. Hierher gehört die quantitative Begründung der festen Fensterbreite: Heisenbergsche Unschärferelation, Zeit-Bandbreite-Produkt. Abschnitt 3.1 verweist darauf. Belege: Blatter, Kap. 2.3, S. 43–46 [bestätigt]; LMR, Kap. 1.3.1, S. 30–35 [bestätigt].

2.6. Grundbegriffe der Wahrscheinlichkeitsrechnung

In Kapitel 5 wird das Rauschen in einem Messsignal als zufällig modelliert. Dafür genügen die folgenden Begriffe [Mal09, Anhang A.6]. Ein Zufallsvektor $X = (X_0, \dots, X_{N-1})$ besteht aus N Zufallsvariablen X_n. Hat eine Zufallsvariable X die Wahrscheinlichkeitsdichte p, so heißen

$$\mathbb{E}[X] \;=\; \int_{\mathbb{R}} x\, p(x)\, dx \qquad \text{und} \qquad \operatorname{Var}(X) \;=\; \mathbb{E}\big[|X - \mathbb{E}[X]|^2\big]$$

ihr Erwartungswert und ihre Varianz; die Kovarianz zweier Zufallsvariablen ist

$$\operatorname{Cov}(X_1, X_2) \;=\; \mathbb{E}\big[(X_1 - \mathbb{E}[X_1])\,(X_2 - \mathbb{E}[X_2])\big].$$

Ist $\operatorname{Cov}(X_1, X_2) = 0$, so heißen X_1 und X_2 unkorreliert. Der Erwartungswert ist linear. Mit $\mathbb{P}$ bezeichnen wir Wahrscheinlichkeiten.

Definition 2.3 (Normalverteilung, vgl. [Mal09, Kap. 11.2.2]). Sei $\phi(x) = (2\pi)^{-1/2} e^{-x^2/2}$ die Gauß'sche Dichte. Eine Zufallsvariable X heißt normalverteilt mit Erwartungswert μ und Varianz $\sigma^2 > 0$, kurz $X \sim \mathcal{N}(\mu, \sigma^2)$, wenn sie die Dichte $p(x) = \sigma^{-1}\phi\big((x-\mu)/\sigma\big)$ hat, und standardnormalverteilt im Fall $\mu = 0$, $\sigma = 1$.

Gemeinsam normalverteilt heißen Zufallsvariablen, die zusammen einen Gauß'schen Zufallsvektor bilden. Für sie gilt:

Satz 2.4 (vgl. [Mal09, Kap. 11.1.1]). *Gemeinsam normalverteilte Zufallsvariablen, die paarweise unkorreliert sind, sind unabhängig.*

3. Von der kontinuierlichen Wavelet-Transformation zur Multiskalenanalyse

3.1. Die kontinuierliche Wavelet-Transformation

Die Darstellung folgt [Bla03, Kap. 3.1–3.3] und ergänzend [LMR98, Kap. 1.1]. Es gilt die Fourier-Konvention aus Bemerkung 2.2.

Die Fourier-Transformation misst mit $\hat{f}(\omega)$, wie stark die Frequenz ω in f vertreten ist. Ihre Analysefunktionen $e^{i\omega t}$ haben auf ganz $\mathbb{R}$ konstanten Betrag. Sie zerlegt daher nur entlang der Frequenzachse [LMR98, Bem. 1.3.4]. Wann eine Frequenz auftritt, ist an $|\hat{f}|$ nicht abzulesen [Bla03, Kap. 1.2–1.3].

Beim EKG ist das ungünstig. Der QRS-Komplex ist kurz und breitbandig. P- und T-Welle sind lang und schmalbandig [Reb21, Kap. 2.3.1]. Eine geeignete Analyse muss beide Anteile zugleich auflösen.

Die gefensterte Fourier-Transformation (Abschnitt 2.5) bestimmt den Frequenzgehalt eines Ausschnitts. Die Fensterbreite ist dabei für alle Frequenzen gleich. Zeit- und Frequenzauflösung lassen sich nach der Heisenbergschen Unschärferelation nicht zugleich beliebig verbessern [Bla03, Kap. 2.3], [LMR98, Kap. 1.3.1]. Die Wavelet-Transformation wählt die Fensterbreite deshalb abhängig von der Frequenz. Hohe Frequenzen werden mit kurzen Fenstern untersucht, tiefe mit langen [LMR98, Kap. 1.3.2]. Abbildung 3.1 zeigt das schematisch.

Anmerkung. wenn heisenbergunschärfe geschirieben dann richtigen verweis einfügen...

3.1.1. Wavelets und die Zulässigkeitsbedingung

Anmerkung. davor auf jeden fall l2 norm definienren

Definition 3.1 (Wavelet, [Bla03, Kap. 3.1, Bedingungen (1) und (2)])**.** Eine Funktion $\psi \in L^2(\mathbb{R})$ mit $\|\psi\|_{L^2(\mathbb{R})} = 1$ heißt Mutter-Wavelet (kurz: Wavelet), falls sie die Zulässigkeitsbedingung

$$C_\psi := 2\pi \int_{\mathbb{R}^*} \frac{|\hat{\psi}(\omega)|^2}{|\omega|}\, d\omega < \infty \tag{3.1}$$

erfüllt. Dabei ist $\mathbb{R}^* := \mathbb{R} \setminus \{0\}$.

Ob ein gegebenes ψ die Bedingung (3.1) erfüllt, ist nicht direkt zu sehen [Bla03, Kap. 3.1]. Der folgende Satz führt sie auf eine einfache Bedingung im Zeitbereich zurück.

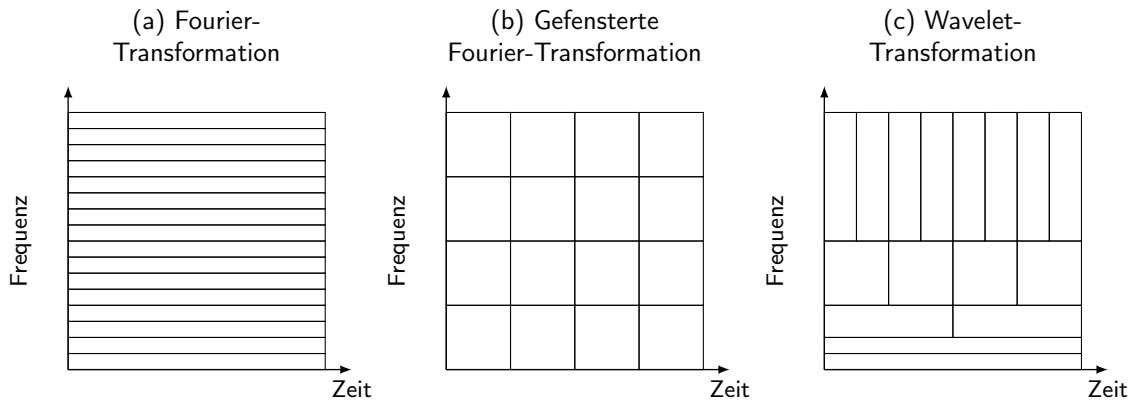


Abbildung 3.1.: Schematische Zeit-Frequenz-Auflösung. Jede Kachel steht für die kleinste Zelle, die die Transformation noch trennt. Alle Kacheln haben denselben Flächeninhalt. In (c) sind die Kacheln bei hohen Frequenzen schmal und bei tiefen breit. Dieselbe Einteilung in Oktavbänder tritt in Abschnitt 6.3 bei der diskreten Transformation auf. In Anlehnung an [BK19, Figure 2.23].

Satz 3.2 (Charakterisierung der Zulässigkeit, [Bla03, Satz (3.1)]). *Sei* $\psi \in L^2(\mathbb{R})$, $\psi \neq 0$, *mit* $\int_{\mathbb{R}} |t|\,|\psi(t)|\,dt < \infty$. *Dann sind äquivalent:*

(i) $C_\psi < \infty$,

(ii) $\displaystyle\int_{\mathbb{R}} \psi(t)\,dt = 0.$

Der Beweis steht bei [Bla03, Satz (3.1)]. Ein Wavelet erfüllt also $\int_{\mathbb{R}} \psi(t)\,dt = 0$. Man sagt dafür auch, ψ habe Mittelwert null [Bla03, Kap. 3.1]. Sein Graph verläuft daher teils oberhalb, teils unterhalb der t-Achse.

Beispiel 3.3 (Haar-Wavelet)**.** Die Funktion

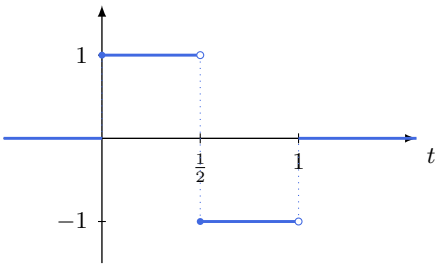
$$\psi^{\mathrm{H}}(t) \;:=\; \begin{cases} 1, & 0 \le t < 1/2, \\ -1, & 1/2 \le t < 1, \\ 0, & \text{sonst}, \end{cases}$$

hat kompakten Träger. Daher ist $\int_{\mathbb{R}} |t|\,|\psi^{\mathrm{H}}(t)|\,dt < \infty$, und Satz 3.2 ist anwendbar. Wegen $\int_{\mathbb{R}} \psi^{\mathrm{H}}(t)\,dt = \frac{1}{2} - \frac{1}{2} = 0$ ist Bedingung (ii) erfüllt. Also ist ψ^{H} zulässig. Mit $\|\psi^{\mathrm{H}}\|_{L^2(\mathbb{R})} = 1$ ist ψ^{H} ein Wavelet im Sinne von Definition 3.1.

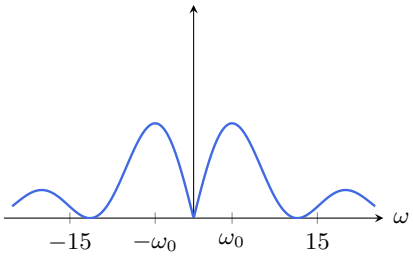
Die Zulässigkeitskonstante lässt sich auch direkt berechnen. Mit $\operatorname{sinc}(x) := \sin(x)/x$ für $x \neq 0$ und $\operatorname{sinc}(0) := 1$ ist

$$\widehat{\psi^{\mathrm{H}}}(\omega) \;=\; \frac{i}{\sqrt{2\pi}}\, e^{-i\omega/2}\, \sin(\omega/4)\, \operatorname{sinc}(\omega/4), \qquad \omega \in \mathbb{R}. \tag{3.2}$$

Einsetzen in (3.1) ergibt $C_{\psi^{\mathrm{H}}} = 2\ln 2$ [LMR98, Kap. 1.1, Beispiel (1)] (Rechnung in Anhang A.1). Abbildung 3.2 zeigt ψ^{H} und $|\widehat{\psi^{\mathrm{H}}}|$.



(a) ψ^{H}



(b) $|\widehat{\psi^{\mathrm{H}}}|$

Abbildung 3.2.: Das Haar-Wavelet ψ^{H} (a) und der Betrag seiner Fourier-Transformierten (b). Das globale Maximum liegt bei $\omega_0 \approx 4{,}66$ [LMR98, Kap. 1.1, Beispiel (1)].

3.1.2. Die Wavelet-Familie und die Transformation

Definition 3.4 (Wavelet-Familie und kontinuierliche Wavelet-Transformation, [Bla03, Kap. 3.1, Gl. (4)–(6)]). Sei ψ ein Wavelet im Sinne von Definition 3.1. Für $(a,b) \in \mathbb{R}^* \times \mathbb{R}$ sei

$$\psi_{a,b}(t) \;:=\; \frac{1}{|a|^{1/2}}\,\psi\!\left(\frac{t-b}{a}\right), \qquad t \in \mathbb{R}. \tag{3.3}$$

Die kontinuierliche Wavelet-Transformation (CWT) von $f \in L^2(\mathbb{R})$ ist

$$W_\psi f\colon \mathbb{R}^* \times \mathbb{R} \to \mathbb{C}, \qquad W_\psi f(a,b) \;:=\; \langle f, \psi_{a,b}\rangle \;=\; \frac{1}{|a|^{1/2}} \int_{\mathbb{R}} f(t)\,\overline{\psi\!\left(\frac{t-b}{a}\right)}\,dt. \tag{3.4}$$

Die Menge $\mathbb{R}^*_\square := \mathbb{R}^* \times \mathbb{R}$ heißt zersägte (a,b)-Ebene. Ist ψ aus dem Zusammenhang klar, schreiben wir kurz Wf.

Bemerkung 3.5 (Normierung der Familie). Es gilt $\|\psi_{a,b}\|_{L^2(\mathbb{R})} = \|\psi\|_{L^2(\mathbb{R})} = 1$ für alle (a,b). Einsetzen von (3.3) und Quadrieren ergibt

$$\|\psi_{a,b}\|^2_{L^2(\mathbb{R})} \;=\; \int_{\mathbb{R}} \Big||a|^{-1/2}\,\psi\big(\tfrac{t-b}{a}\big)\Big|^2 dt \;=\; \frac{1}{|a|}\int_{\mathbb{R}} \Big|\psi\big(\tfrac{t-b}{a}\big)\Big|^2 dt.$$

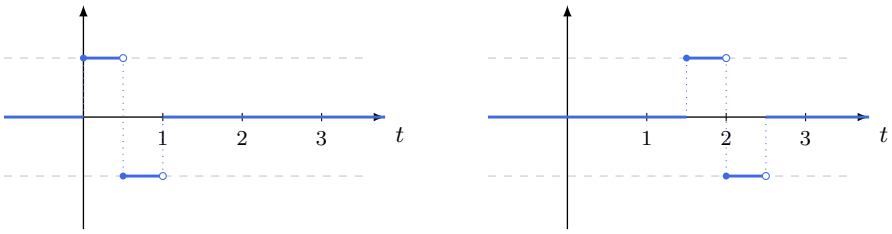
Nun substituiert man $s = \frac{t-b}{a}$, also $t = as + b$ und $dt = a\,ds$. Für $a < 0$ vertauscht die Substitution zusätzlich die Integrationsgrenzen. Das gleicht das Vorzeichen aus, und es bleibt $dt = |a|\,ds$. Damit folgt

$$\frac{1}{|a|}\int_{\mathbb{R}} \Big|\psi\big(\tfrac{t-b}{a}\big)\Big|^2 dt \;=\; \frac{1}{|a|}\int_{\mathbb{R}} |\psi(s)|^2\,|a|\,ds \;=\; \int_{\mathbb{R}} |\psi(s)|^2\,ds \;=\; \|\psi\|^2_{L^2(\mathbb{R})}.$$

Mit einem Vorfaktor $|a|^{-p}$ statt $|a|^{-1/2}$ ergäbe dieselbe Rechnung $|a|^{1-2p}\,\|\psi\|^2_{L^2(\mathbb{R})}$. Die Norm hängt also genau für $p = \frac{1}{2}$ nicht von a ab [Bla03, Kap. 3.1].

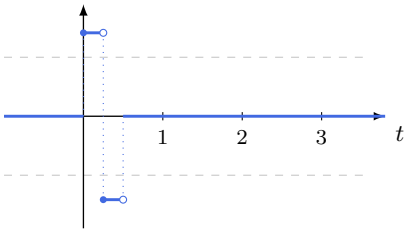
Anmerkung. davor support definieren - in grundlagen ist der träger einfach...

Bemerkung 3.6 (Bedeutung der beiden Parameter)**.** Ist ψ kompakt getragen, so gilt $\operatorname{supp} \psi_{a,b} = b + a \cdot \operatorname{supp} \psi$. Der Parameter b verschiebt das Wavelet entlang der Zeitachse. Daher trägt $Wf(a,b)$ Information über f in der Nähe von $t = b$. Der Parameter a streckt oder staucht das Wavelet und legt die Breite dieses Bereichs fest. Für $a \to 0$ zieht sich $\psi_{a,b}$ auf $t = b$ zusammen [LMR98, Kap. 1.1]. Abbildung 3.3 zeigt beides am Haar-Wavelet.

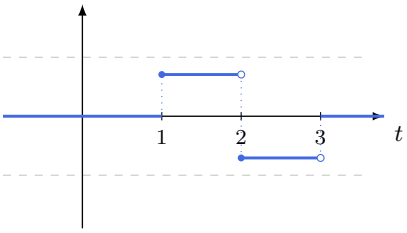


(a) $\psi^{\mathrm{H}} = \psi^{\mathrm{H}}_{1,0}$

(b) $\psi^{\mathrm{H}}_{1,\,3/2}$, verschoben



(c) $\psi^{\mathrm{H}}_{1/2,\,0}$, gestaucht



(d) $\psi^{\mathrm{H}}_{2,\,1}$, gestreckt und verschoben

Abbildung 3.3.: Die Wavelet-Familie (3.3) am Haar-Wavelet. In (b) liegt der Träger auf $[\frac{3}{2}, \frac{5}{2}]$. In (c) liegt er auf $[0, \frac{1}{2}]$, die Amplitude ist $\sqrt{2}$. In (d) liegt er auf $[1, 3]$, die Amplitude ist $1/\sqrt{2}$. Gestrichelt die Werte ± 1. In allen vier Fällen ist das Produkt aus Trägerlänge und quadrierter Amplitude gleich eins (Bemerkung 3.5).

Anmerkung. stört das die im index hier nicht als bruch sind?

Beispiel 3.7 (Ein Testsignal mit zwei Frequenzen)**.** Betrachtet wird

$$f(t) = \begin{cases} 1 - \cos(2\pi t), & 0 \le t \le 3, \\ \frac{1}{2}\big(1 - \cos(10\pi t)\big), & 4 \le t \le 5, \\ 0, & \text{sonst.} \end{cases}$$

Die Funktion $\cos(2\pi\nu t)$ hat die Periode $1/\nu$, sie schwingt also mit der Frequenz ν. Auf $[0,3]$ schwingt f daher mit der Frequenz 1, auf $[4,5]$ mit der Frequenz 5 (Abbildung 3.4). Wir vergleichen, was Fourier- und Wavelet-Transformation über f aussagen.

Fourier-Transformierte. Abbildung 3.5 zeigt $|\hat{f}|$. Die geschlossene Form ist (A.2) in Anhang A.2. Zur Frequenz ν gehört die Stelle $\omega = 2\pi\nu$. Daher erscheinen beide Frequenzen als Maxima nahe $\pm 2\pi$ und $\pm 10\pi$. Wann sie auftreten, ist $|\hat{f}|$ nicht zu entnehmen.

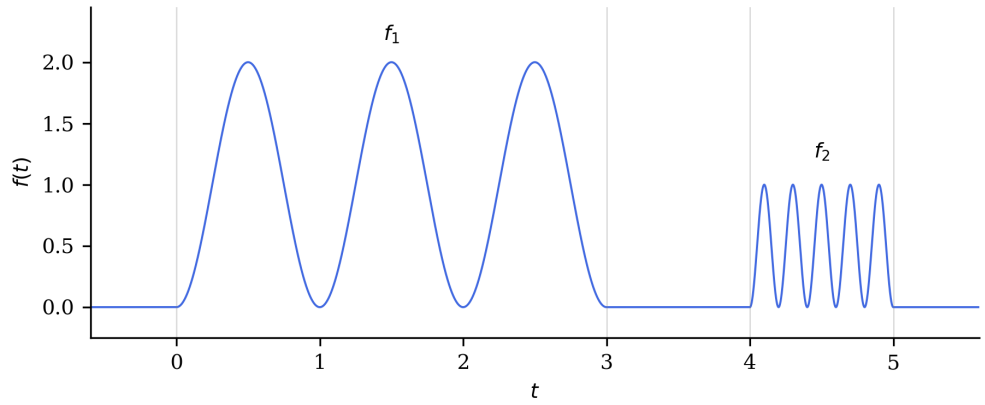


Abbildung 3.4.: Das Signal f aus Beispiel 3.7.

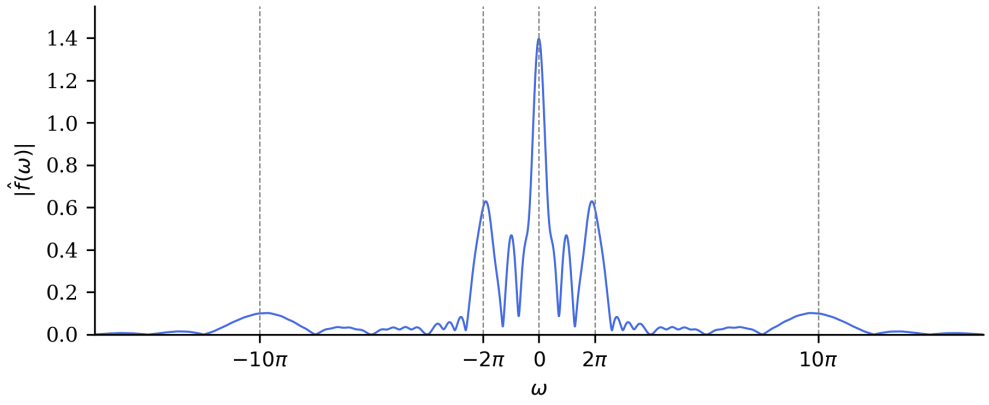


Abbildung 3.5.: Betragsspektrum $|\hat{f}(\omega)|$ des Testsignals. Gestrichelt die Stellen $\pm 2\pi$ und $\pm 10\pi$.

Wavelet-Transformierte. Wir verwenden das Haar-Wavelet und beschränken uns auf $a > 0$. Dann ist $|a|^{1/2} = \sqrt{a}$. Da ψ^{H} reell ist, entfällt die Konjugation in (3.4), und es gilt

$$W_{\psi^{\mathrm{H}}} f(a,b) = \frac{1}{\sqrt{a}} \int_{\mathbb{R}} f(t)\, \psi^{\mathrm{H}}\Big(\frac{t-b}{a}\Big)\, dt.$$

Das Fenster $[b,\, b+a[$ hat die Breite a. Auf seiner linken Hälfte $[b,\, b+\frac{a}{2}[$ ist $\psi^{\mathrm{H}}\big(\frac{t-b}{a}\big) = 1$, auf der rechten Hälfte $[b+\frac{a}{2},\, b+a[$ ist es -1, sonst null. Also ist

$$W_{\psi^{\mathrm{H}}} f(a,b) = \frac{1}{\sqrt{a}} \left(\int_b^{b+a/2} f(t)\, dt - \int_{b+a/2}^{b+a} f(t)\, dt \right).$$

Der Wert ist groß, wenn sich die Integrale über die beiden Fensterhälften stark unterscheiden. Ist f auf dem Fenster nahezu konstant, ist er nahe null. Mit der Stammfunktion $F(t) := \int_{-\infty}^{t} f(s)\, ds$ (Anhang A.3) folgt die geschlossene Form

$$W_{\psi^{\mathrm{H}}} f(a,b) = \frac{2F\big(b+\frac{a}{2}\big) - F(b) - F(b+a)}{\sqrt{a}}. \tag{3.5}$$

Abbildung 3.6 zeigt ihren Betrag.

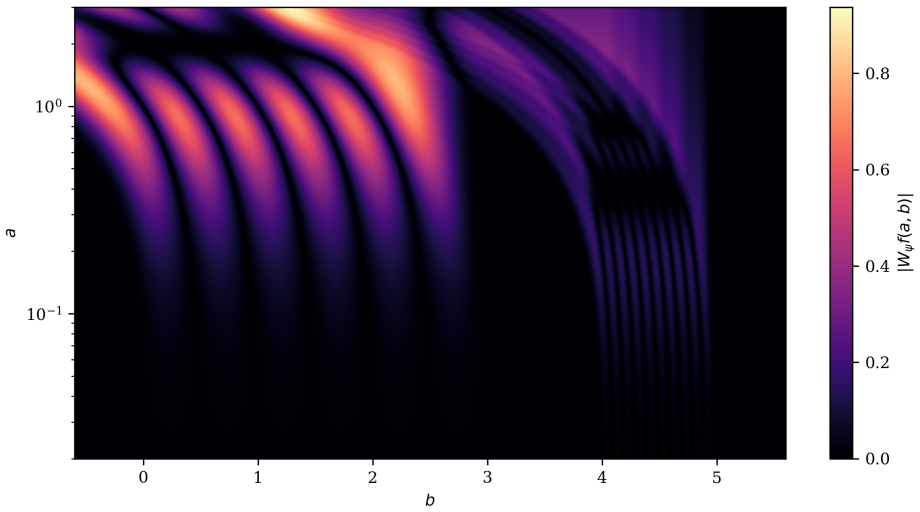


Abbildung 3.6.: Betrag $|W_{\psi^{\mathrm{H}}} f(a,b)|$ des Testsignals nach (3.5). Waagerecht ist die Verschiebung b aufgetragen, senkrecht die Skala a in logarithmischer Teilung. Die Farbe gibt den Betrag an.

Kleine a gehören zu hohen Frequenzen, also schnellen Schwingungen, große a zu tiefen Frequenzen, also langsamen Schwingungen [Bla03, Kap. 1.5]. Genau das zeigt Abbildung 3.6. Die langsame Schwingung über $[0,3]$ liefert große Werte bei großen a, die schnelle über $[4,5]$ bei kleinen a. Die Wavelet-Transformation zeigt also gleichzeitig, wann und mit welcher Frequenz f schwingt.

3.1.3. Die Plancherel-Formel

Dieser Abschnitt zeigt, dass bei der CWT keine Information verloren geht, sie aber viel mehr Werte liefert als nötig. Das begründet den Übergang zum dyadischen Gitter in Abschnitt 3.2.

Für die Fourier-Transformation gilt $\|\hat{f}\| = \|f\|$ (Bemerkung 2.2). Für die CWT gilt eine ähnliche Formel.

Satz 3.8 (Plancherel-Formel für die CWT, [Bla03, Satz (3.3)]). *Sei ψ ein Wavelet mit Zulässigkeitskonstante C_ψ gemäß (3.1). Dann gilt für jedes $f \in L^2(\mathbb{R})$*

$$\int_{\mathbb{R}^*_\square} |W_\psi f(a,b)|^2 \, \frac{da\,db}{a^2} \;=\; C_\psi \, \|f\|^2_{L^2(\mathbb{R})}. \tag{3.6}$$

Anmerkung. hab ich das mit R kästchen schon definert?

Der Beweis steht bei [Bla03, Satz (3.3)]. Links steht das Integral über $|W_\psi f|^2$ auf der (a,b)-Ebene, gewichtet mit a^{-2}. Es ist bis auf den Faktor C_ψ gleich $\|f\|^2$. Das Gewicht a^{-2} wird in Abschnitt 3.2 erklärt.

Daraus folgt, dass f durch $W_\psi f$ eindeutig bestimmt ist [Bla03, Satz (3.3)]. Ist nämlich $W_\psi f = W_\psi g$, so ist $W_\psi(f-g) = 0$. Nach (3.6) folgt $\|f-g\| = 0$, also $f = g$.

Bemerkung 3.9 (Redundanz der CWT). Da f durch $W_\psi f$ eindeutig bestimmt ist, geht bei der CWT keine Information verloren. Blatter gibt auch eine Formel an, mit der sich f aus $W_\psi f$ zurückgewinnen lässt [Bla03, Kap. 3.3]. Die Werte $W_\psi f(a,b)$ sind aber nicht frei. Nicht jede Funktion auf $\mathbb{R}^*_\square$ ist die Transformierte eines Signals [Bla03, Kap. 3.4]. Diese Eigenschaft heißt Redundanz. Anschaulich hängt f von einer Variablen ab, $W_\psi f$ von zweien.

Im Endlichdimensionalen sieht man das direkt. Für ein Signal $x \in \mathbb{R}^N$ liefern N Skalen und N Verschiebungen N^2 Koeffizienten. Jeder ist ein Skalarprodukt mit x. Zusammengefasst gilt daher $c = Ax$ mit einer Matrix $A \in \mathbb{R}^{N^2 \times N}$. Der Vektor c liegt also in einem Teilraum des $\mathbb{R}^{N^2}$ der Dimension höchstens N.

Das Thresholding in Kapitel 5 arbeitet dagegen mit den Koeffizienten bezüglich einer Orthonormalbasis [Mal09, Kap. 11.2]. Gesucht ist daher eine abzählbare Auswahl von Parametern (a,b), für die $\{\psi_{a,b}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ ist.

3.2. Das dyadische Gitter und die Multiskalenanalyse

Einen Anhaltspunkt für die Wahl der Punkte gibt die Plancherel-Formel (3.6). Dort geht jeder Punkt (a,b) mit dem Gewicht a^{-2} ein. Ersetzt man das Integral durch eine Summe über Gitterpunkte, sollte jeder Gitterpunkt eine Zelle mit gleichem Gewicht vertreten [Bla03, Kap. 4.3].

Das leistet das Gitter $a = 2^j$, $b = k2^j$ mit $j,k \in \mathbb{Z}$. Der Punkt $(2^j, k2^j)$ vertritt die Zelle

$$Z_{j,k} := [2^j,\, 2^{j+1}] \times [k2^j,\, (k+1)2^j].$$

In a reicht sie über eine Verdopplung der Skala, in b über die Länge 2^j. Für ihr Gewicht gilt

$$\int_{k2^j}^{(k+1)2^j} \int_{2^j}^{2^{j+1}} \frac{da\,db}{a^2} \;=\; 2^j\Big(\frac{1}{2^j} - \frac{1}{2^{j+1}}\Big) \;=\; \frac{1}{2}. \tag{3.7}$$

Das Gewicht hängt weder von j noch von k ab (Abbildung 3.7). Ob die zugehörigen Funktionen $\psi_{2^j,k2^j}$ eine Orthonormalbasis bilden, hängt aber von ψ ab. Das klärt die Multiskalenanalyse in Definition 3.12.

Definition 3.10 (Dyadische Wavelet-Familie, [Bla03, Kap. 5.1]). Sei ψ ein Wavelet. Auf dem dyadischen Gitter $\{(2^j, k2^j) : j, k \in \mathbb{Z}\}$ sei

$$\psi_{j,k}(t) \;:=\; \psi_{2^j,\,k2^j}(t) \;=\; 2^{-j/2}\,\psi\!\left(\frac{t}{2^j} - k\right), \qquad j,k \in \mathbb{Z}. \tag{3.8}$$

Kleineres j gehört zur feineren Skala.[1]

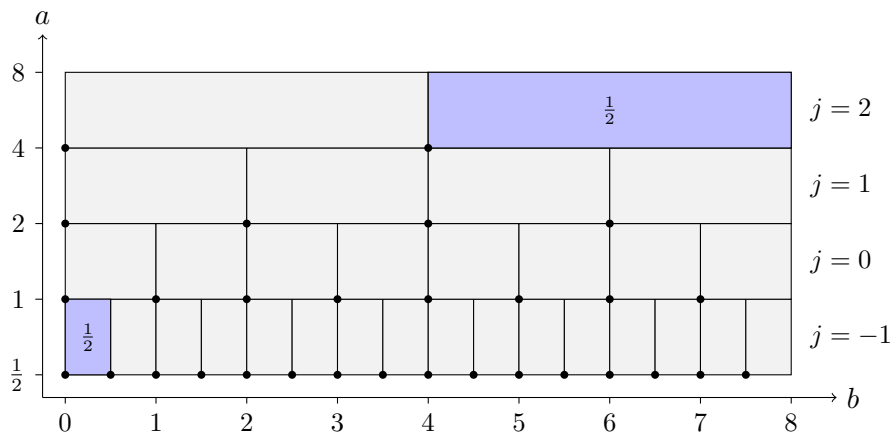


Abbildung 3.7.: Das dyadische Gitter. Die Skala a ist logarithmisch aufgetragen. Dabei zählt j die Skala und k die Position auf dieser Skala. Jeder Punkt $(2^j, k2^j)$ vertritt die Zelle $Z_{j,k}$ rechts oberhalb von ihm. Hervorgehoben sind $Z_{-1,0} = [\frac{1}{2}, 1] \times [0, \frac{1}{2}]$ und $Z_{2,1} = [4, 8] \times [4, 8]$. Ihre gewöhnlichen Flächen sind $\frac{1}{4}$ und 16. Ihr Gewicht ist nach (3.7) in beiden Fällen $\frac{1}{2}$.

Gesucht ist ein Wavelet ψ, für das $\{\psi_{j,k}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ ist. Direkt lässt sich ein solches ψ schwer finden. Die Multiskalenanalyse beschreibt deshalb zuerst, wie ein Signal auf verschiedenen Skalen vergröbert wird. Das Wavelet ergibt sich aus dem Übergang zwischen zwei benachbarten Skalen [Bla03, Kap. 5.1]. Das folgende Beispiel zeigt das am Haar-Wavelet.

Beispiel 3.11 (Mittelwerte und Details, [LMR98, Kap. 2.2.1]). Sei $V_j \subset L^2(\mathbb{R})$ der Raum der Funktionen, die auf jedem Intervall $I_{j,k} := [k2^j, (k+1)2^j[$ konstant sind. Die Orthogonalprojektion P_j auf V_j ersetzt f auf jedem $I_{j,k}$ durch den Mittelwert $2^{-j} \int_{I_{j,k}} f(t)\,dt$ [HB09, Satz 43.1]. Wir betrachten die Treppenfunktion

$$f \;=\; 4 \cdot \mathbf{1}_{[0,1[} + 2 \cdot \mathbf{1}_{[1,2[} + 5 \cdot \mathbf{1}_{[2,3[} + 7 \cdot \mathbf{1}_{[3,4[} \;\in\; V_0$$

und schreiben kurz $f = (4, 2, 5, 7)$ (Abbildung 3.8).

[1] Diese Konvention folgt Blatter und Louis/Maaß/Rieder. Hanke-Bourgeois zählt umgekehrt [HB09, § 56].

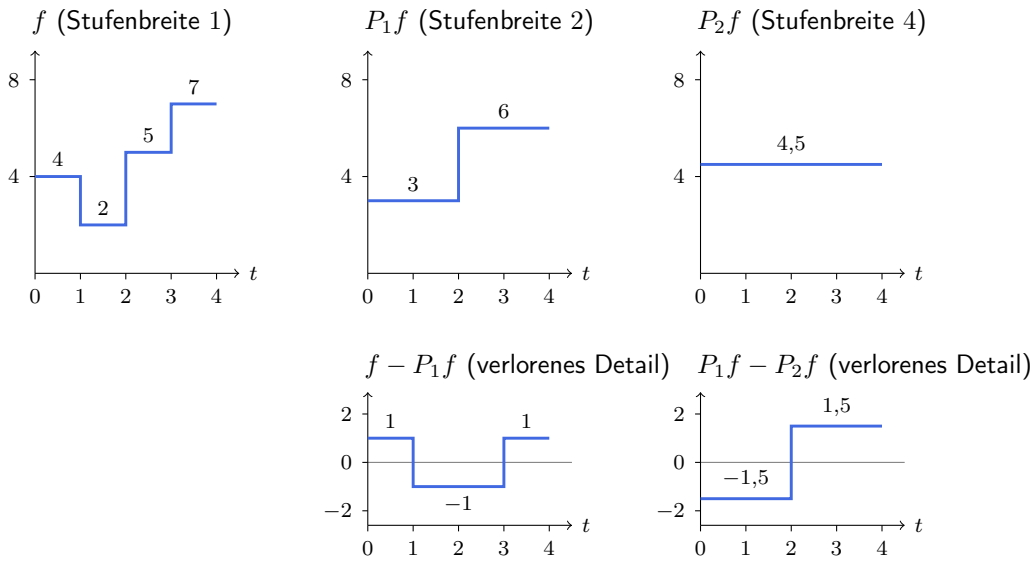


Abbildung 3.8.: Die Treppenfunktion $f = (4, 2, 5, 7)$ aus Beispiel 3.11 und ihre Mittelungen $P_1 f$ und $P_2 f$ (oben). Darunter das Detail, das beim Übergang zu der jeweiligen Mittelung verloren geht. Alle Panels haben denselben vertikalen Maßstab.

Mittelung über je zwei benachbarte Intervalle liefert $P_1 f = (3, 3, 6, 6)$. Dabei geht $f - P_1 f = (1, -1, -1, 1)$ verloren. Mit dem Haar-Wavelet ist das

$$(f - P_1 f)(t) \;=\; \psi^{\mathrm{H}}\big(\tfrac{t}{2}\big) - \psi^{\mathrm{H}}\big(\tfrac{t}{2} - 1\big).$$

Nochmalige Mittelung liefert $P_2 f = (4{,}5,\ 4{,}5,\ 4{,}5,\ 4{,}5)$. Dabei geht $(P_1 f - P_2 f)(t) = -1{,}5\,\psi^{\mathrm{H}}\big(\tfrac{t}{4}\big)$ verloren. Insgesamt ist

$$f(t) \;=\; 4{,}5 \cdot \mathbf{1}_{[0,4[}(t) \;-\; 1{,}5\,\psi^{\mathrm{H}}\big(\tfrac{t}{4}\big) \;+\; \psi^{\mathrm{H}}\big(\tfrac{t}{2}\big) \;-\; \psi^{\mathrm{H}}\big(\tfrac{t}{2} - 1\big).$$

Die vier Werte von f sind durch vier andere Zahlen ersetzt: den Mittelwert $4{,}5$, ein grobes Detail $-1{,}5$ und zwei feine Details 1 und -1. Aus ihnen lässt sich f exakt zurückgewinnen. Die Normierungsfaktoren $2^{-j/2}$ aus (3.8) sind hier weggelassen.

Im Beispiel liegen die Räume V_j ineinander und gehen durch Mittelung auseinander hervor. Die folgende Definition fasst die Eigenschaften zusammen, auf die es dabei ankommt.

Definition 3.12 (Multiskalenanalyse, [Bla03, Kap. 5.1, (a)–(c)]). Eine Multiskalenanalyse (MSA) von $L^2(\mathbb{R})$ ist eine Folge $(V_j)_{j\in\mathbb{Z}}$ abgeschlossener Teilräume von $L^2(\mathbb{R})$ mit folgenden Eigenschaften:

(M1) (Schachtelung) $\cdots \subset V_2 \subset V_1 \subset V_0 \subset V_{-1} \subset V_{-2} \subset \cdots \subset L^2(\mathbb{R})$,

(M2) (Separation) $\bigcap_{j\in\mathbb{Z}} V_j = \{0\}$,

(M3) (Vollständigkeit) $\overline{\bigcup_{j\in\mathbb{Z}} V_j} = L^2(\mathbb{R})$,

(M4) (Skalierung) Für alle $j \in \mathbb{Z}$ gilt: $f \in V_j$ genau dann, wenn die Funktion $t \mapsto f(2^j t)$ in V_0 liegt,

(M5) (Erzeugende Funktion) Es gibt ein $\varphi \in L^2(\mathbb{R}) \cap L^1(\mathbb{R})$,[2] sodass die Funktionen $t \mapsto \varphi(t-k)$, $k \in \mathbb{Z}$, eine Orthonormalbasis von V_0 bilden.

Die Funktion φ heißt Skalierungsfunktion der MSA.

Bemerkung 3.13 (Zu den Axiomen, [Bla03, Kap. 5.1]). (a) (M1)–(M3): Je kleiner j, desto feinere Strukturen enthält V_j. Anschaulich geht V_j für $j \to -\infty$ gegen ganz $L^2(\mathbb{R})$ und für $j \to +\infty$ gegen $\{0\}$. Genau formuliert wird das durch (M3) und (M2) [LMR98, Bem. 2.2.2].

(b) (M4): Die V_j sind skalierte Kopien desselben Raumes V_0. Deshalb genügt eine einzige Skalierungsfunktion φ, um alle V_j festzulegen.

(c) (M5): Das Axiom liefert eine Orthonormalbasis, allerdings nur für den Grundraum V_0 [Bla03, Kap. 5.1, (c)]. Zusammen mit (M4) überträgt sie sich auf alle V_j (Satz 3.15).[3]

Beispiel 3.14 (Die Haar-MSA, [Bla03, Kap. 5.1, Beispiel 1]). Die Räume V_j aus Beispiel 3.11 bilden eine MSA mit der Skalierungsfunktion $\varphi := \mathbf{1}_{[0,1[}$. Die Skalierungsfunktion ist also eine einzelne Stufe und nicht das Haar-Wavelet. Die Axiome lassen sich einzeln prüfen.

- (M1): Eine Treppe der Stufenbreite 2^j ist auch eine Treppe der Stufenbreite 2^{j-1}.
- (M2): Liegt f in allen V_j, so ist f auf $[0, 2^j[$ für jedes j konstant, also auf $[0, \infty[$. In $L^2(\mathbb{R})$ geht das nur für $f = 0$. Dasselbe gilt auf $]-\infty, 0[$.
- (M3): Treppenfunktionen mit Sprungstellen der Form $k2^j$ liegen dicht in $L^2(\mathbb{R})$ [Bla03, Kap. 5.1]. Ein Beispiel: $\mathbf{1}_{[0,1/3[}$ springt bei $\frac{1}{3}$ und liegt daher in keinem V_j. Die Funktion $\mathbf{1}_{[0,5/16[}$ springt bei $\frac{5}{16} = 5 \cdot 2^{-4}$ und liegt in V_{-4}. Der Fehler ist

$$\|\mathbf{1}_{[0,1/3[} - \mathbf{1}_{[0,5/16[}\|^2_{L^2(\mathbb{R})} = \int_{5/16}^{1/3} 1 \, dt = \tfrac{1}{3} - \tfrac{5}{16} = \tfrac{1}{48}.$$

  Mit feineren Stufen wird er beliebig klein.
- (M4): f ist genau dann auf allen Intervallen $[k2^j, (k+1)2^j[$ konstant, wenn $t \mapsto f(2^j t)$ auf allen Intervallen $[k, k+1[$ konstant ist. Etwa ist $f = \mathbf{1}_{[0,2[} \in V_1$. Für $g(t) := f(2t)$ gilt $g(t) = 1$ genau für $0 \le 2t < 2$, also für $0 \le t < 1$. Somit ist $g = \mathbf{1}_{[0,1[} \in V_0$.
- (M5): Die Verschiebungen $\varphi(t-k) = \mathbf{1}_{[k,k+1[}(t)$ haben disjunkte Träger und Norm 1. Sie sind also orthonormal. Etwa ist $f(t) = 4\varphi(t) + 2\varphi(t-1) + 5\varphi(t-2) + 7\varphi(t-3)$.

In Beispiel 3.11 entsteht jede gröbere Näherung $P_{j+1}f$ durch Mittelung aus $P_j f$. Das entspricht der Schachtelung (M1). Was bei der Mittelung verloren geht, sind Vielfache gestreckter und verschobener Haar-Wavelets [LMR98, Kap. 2.2.1]. Diese Unterschiede werden in Abschnitt 3.4 als Detailräume W_j gefasst. Aus vier Werten werden wieder vier Koeffizienten. Die Zerlegung ist also frei von der Redundanz aus Bemerkung 3.9.

[2] Die Forderung $\varphi \in L^1(\mathbb{R})$ folgt Blatter. Sie sichert, dass $\hat{\varphi}$ stetig ist. Das wird für (4.4) gebraucht.

[3] Louis, Maaß und Rieder verlangen in (M5) nur eine Riesz-Basis [LMR98, Def. 2.2.1]. Wir folgen Blatter und fordern eine Orthonormalbasis.

3.3. Skalierungsfunktion und Orthonormalbasis der Räume V_j

In diesem Abschnitt wird die Basis aus (M5) auf alle Skalen übertragen (Satz 3.15). Außerdem wird gezeigt, dass die Orthogonalprojektionen P_j für $j \to -\infty$ gegen die Identität und für $j \to +\infty$ gegen null streben (Proposition 3.17). Normen ohne Index sind im Folgenden Normen in $L^2(\mathbb{R})$.

3.3.1. Die Orthonormalbasis auf allen Skalen

Sei $D_a f := |a|^{-1/2} f(\cdot/a)$ der Dilatationsoperator, $a \in \mathbb{R}^*$. Nach (M4) liegt f genau dann in V_j, wenn $f = h(\cdot/2^j)$ mit einem $h \in V_0$ ist. Da V_j ein linearer Raum ist, spielt der Vorfaktor keine Rolle. Es folgt

$$V_j \;=\; D_{2^j}(V_0) \qquad \text{für alle } j \in \mathbb{Z} \tag{3.9}$$

[Bla03, Kap. 5.1, (b)]. Der Operator D_{2^j} ist unitär [LMR98, Kap. 1.2].

Satz 3.15 (Orthonormalbasis von V_j, [Bla03, Kap. 5.1]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ. Mit*

$$\varphi_{j,k}(t) \;:=\; 2^{-j/2}\,\varphi\!\left(\frac{t}{2^j} - k\right), \qquad j,k \in \mathbb{Z}, \tag{3.10}$$

ist $\{\varphi_{j,k} : k \in \mathbb{Z}\}$ für jedes feste $j \in \mathbb{Z}$ eine Orthonormalbasis von V_j.

Ein unitärer Operator erhält Skalarprodukte. Er bildet daher eine Orthonormalbasis eines abgeschlossenen Teilraums auf eine Orthonormalbasis des Bildes ab [Ser17, Def. 27.7, Satz 25.18]. Nach (3.9) bildet D_{2^j} die Basis $\{\varphi(\cdot - k)\}_k$ von V_0 auf $\{\varphi_{j,k}\}_k$ ab. Das beweist den Satz.

Anmerkung. Der rote Faden: Die gesamte Konstruktion liefert Orthonormalbasen. In Abschnitt 5.1 ist es die Orthogonalität der DWT (Lemma 5.3), die das Rauschen invariant lässt.

3.3.2. Die Approximationsoperatoren

Definition 3.16 (Approximationsoperator, [LMR98, Bem. 2.2.2 (a)]). Für $f \in L^2(\mathbb{R})$ und $j \in \mathbb{Z}$ heißen $a_{j,k} := \langle f, \varphi_{j,k}\rangle$, $k \in \mathbb{Z}$, die Approximationskoeffizienten von f auf der Skala j. Die Abbildung $P_j \colon L^2(\mathbb{R}) \to V_j$,

$$P_j f \;:=\; \sum_{k\in\mathbb{Z}} a_{j,k}\,\varphi_{j,k}, \tag{3.11}$$

heißt Approximationsoperator.

Wir halten drei Eigenschaften fest.

(i) Da $\{\varphi_{j,k}\}_k$ eine Orthonormalbasis von V_j ist, konvergiert (3.11) in $L^2(\mathbb{R})$, und es gilt $\|P_j f\|^2 = \sum_k |a_{j,k}|^2$ [Ser17, Satz 25.18].

(ii) Für alle $l \in \mathbb{Z}$ ist $\langle f - P_j f, \varphi_{j,l}\rangle = a_{j,l} - a_{j,l} = 0$. Also steht $f - P_j f$ senkrecht auf V_j, und P_j ist die Orthogonalprojektion auf V_j.

(iii) Aus (ii) und dem Satz des Pythagoras folgt $\|f-g\| \geq \|f-P_j f\|$ für alle $g \in V_j$. Also ist $P_j f$ die beste Näherung von f in V_j [HB09, Satz 31.6].

Für die Haar-MSA ist $\varphi_{j,k} = 2^{-j/2}\,\mathbf{1}_{I_{j,k}}$ mit $I_{j,k} := [k2^j, (k+1)2^j[$. Dann ist

$$a_{j,k}\,\varphi_{j,k} \;=\; \Big(\frac{1}{2^j}\int_{I_{j,k}} f(t)\,dt\Big)\,\mathbf{1}_{I_{j,k}}.$$

P_j ersetzt f also auf jedem $I_{j,k}$ durch seinen Mittelwert [LMR98, Kap. 2.2]. Das ist die Aussage aus Beispiel 3.11.

Proposition 3.17 (Approximationseigenschaft, [LMR98, Bem. 2.2.2 (a)]). *Für jedes $f \in L^2(\mathbb{R})$ gilt*

$$\textit{(a)}\quad \lim_{j\to-\infty}\|P_j f - f\| = 0 \qquad \textit{und} \qquad \textit{(b)}\quad \lim_{j\to+\infty}\|P_j f\| = 0.$$

Aussage (a) folgt aus (M3) und Eigenschaft (iii). Aussage (b) folgt aus (M2) [Bla03, Prop. (5.1)].

3.4. Detailräume W_j und die Zerlegung von $L^2(\mathbb{R})$

Wegen $V_j \subset V_{j-1}$ sind die Basen verschiedener V_j nicht zueinander orthogonal. Man betrachtet deshalb nur den Zuwachs beim Übergang zur nächstfeineren Skala [Bla03, Kap. 5.1].

Definition 3.18 (Detailräume, [Bla03, Kap. 5.1, Gl. (8)]). Für $j \in \mathbb{Z}$ sei W_j das orthogonale Komplement von V_j in V_{j-1},

$$V_{j-1} \;=\; V_j \oplus W_j, \qquad W_j \perp V_j, \tag{3.12}$$

und $Q_j := P_{j-1} - P_j$.

Q_j ist die Orthogonalprojektion auf W_j [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.9)]. Denn $Q_j f = (f - P_j f) - (f - P_{j-1} f)$ liegt in V_{j-1}, und beide Klammern stehen senkrecht auf V_j. Also liegt $Q_j f$ in W_j. Ferner steht $f - Q_j f = (f - P_{j-1} f) + P_j f$ senkrecht auf W_j.

Da D_{2^j} unitär ist und nach (3.9) V_0 auf V_j und V_{-1} auf V_{j-1} abbildet, gilt

$$W_j \;=\; D_{2^j}(W_0) \qquad \text{für alle } j \in \mathbb{Z} \tag{3.13}$$

[Bla03, Kap. 5.1, Gl. (9)]. Für $i > j$ ist $W_i \subset V_{i-1} \subset V_j \perp W_j$. Die Detailräume sind also paarweise orthogonal [Bla03, Prop. (5.1)].

Satz 3.19 (Zerlegung von $L^2(\mathbb{R})$ in Detailräume, [Bla03, Prop. (5.1)]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Detailräumen W_j. Dann gilt*

$$L^2(\mathbb{R}) \;=\; \bigoplus_{j\in\mathbb{Z}} W_j \tag{3.14}$$

als orthogonale direkte Summe. Für jedes $f \in L^2(\mathbb{R})$ ist $f = \sum_{j\in\mathbb{Z}} Q_j f$ und

$$\|f\|^2 \;=\; \sum_{j\in\mathbb{Z}} \|Q_j f\|^2. \tag{3.15}$$

Für jedes feste $J \in \mathbb{Z}$ gilt ferner

$$L^2(\mathbb{R}) \;=\; V_J \oplus \bigoplus_{j\leq J} W_j, \qquad f \;=\; P_J f + \sum_{j\leq J} Q_j f. \tag{3.16}$$

Nach Definition von Q_j ist $\sum_{j=J_1+1}^{J_2} Q_j f = P_{J_1} f - P_{J_2} f$. Nach Proposition 3.17 strebt das für $J_1 \to -\infty$ und $J_2 \to +\infty$ gegen f. Mit $J_2 = J$ folgt (3.16). Die Energiegleichung folgt aus der Orthogonalität der Summanden [Bla03, Prop. (5.1)], [LMR98, Gl. (2.2.11), (2.2.12)].

In der Anwendung wird die endliche Fassung (3.16) benutzt [LMR98, Kap. 2.2]. Ein Mittelwert ungleich null verschwindet durch P_j nämlich nicht, er wird nur auseinandergezogen. Für die Treppenfunktion aus Beispiel 3.11 ist etwa $P_j f = 18 \cdot 2^{-j}\, \mathbf{1}_{[0,2^j[}$ für alle $j \geq 2$. In Kapitel 6 wird $P_J f$ dagegen gezielt entfernt, weil dort die Basisliniendrift liegt (Abschnitt 6.4.1).

3.4.1. Die Wavelet-Basis

V_{-1} besitzt zwei Basisfunktionen pro Zeiteinheit, V_0 eine. Es liegt daher nahe, W_0 durch die ganzzahligen Verschiebungen einer einzigen Funktion ψ aufzuspannen [Bla03, Kap. 5.1]. Dass es ein solches ψ gibt, zeigt Kapitel 4 [LMR98, Satz 2.2.10]. Im Haar-Fall ist es ψ^{H} [LMR98, Kap. 2.2].

Korollar 3.20 (Wavelet-Basis, [Bla03, Kap. 5.1]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA, und sei $\psi \in L^2(\mathbb{R})$ so, dass $\{\psi(\,\cdot - k) : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_0 ist. Mit $\psi_{j,k}$ wie in (3.8) gilt:*

(i) Für jedes feste $j \in \mathbb{Z}$ ist $\{\psi_{j,k} : k \in \mathbb{Z}\}$ eine Orthonormalbasis von W_j.

(ii) Die Familie

$$\{\psi_{j,k} : j,k \in \mathbb{Z}\} \tag{3.17}$$

ist eine Orthonormalbasis von $L^2(\mathbb{R})$, die Wavelet-Basis der MSA.

(iii) Mit den Detailkoeffizienten $d_{j,k} := \langle f, \psi_{j,k}\rangle$ gilt für jedes $f \in L^2(\mathbb{R})$ und jedes $J \in \mathbb{Z}$

$$f \;=\; \sum_{k\in\mathbb{Z}} a_{J,k}\,\varphi_{J,k} + \sum_{j\leq J}\sum_{k\in\mathbb{Z}} d_{j,k}\,\psi_{j,k}, \qquad \|f\|^2 \;=\; \sum_{k\in\mathbb{Z}} |a_{J,k}|^2 + \sum_{j\leq J}\sum_{k\in\mathbb{Z}} |d_{j,k}|^2. \tag{3.18}$$

Aussage (i) folgt wie Satz 3.15 aus (3.13). Nach (i) ist $Q_j f = \sum_k d_{j,k}\,\psi_{j,k}$. Damit folgen (ii) und (iii) aus Satz 3.19 und (3.11) [Bla03, Kap. 5.1], [LMR98, Gl. (2.2.13)].

Beispiel 3.21 (Wavelet-Koeffizienten der Treppenfunktion). Wir zerlegen $f = (4,2,5,7)$ aus Beispiel 3.11 in der Haar-Wavelet-Basis [LMR98, Kap. 2.2]. Die Funktion $\psi_{j,k}$ ist auf der linken Hälfte von $I_{j,k}$ gleich $2^{-j/2}$ und auf der rechten gleich $-2^{-j/2}$. Daher ist $d_{j,k}$ das $2^{-j/2}$-Fache der Differenz der Integrale von f über die beiden Hälften. Für $J = 2$ erhält man

$$a_{2,0} = \tfrac{1}{2}(4+2+5+7) = 9, \qquad d_{2,0} = \tfrac{1}{2}\big((4+2)-(5+7)\big) = -3,$$
$$d_{1,0} = \tfrac{1}{\sqrt{2}}(4-2) = \sqrt{2}, \qquad d_{1,1} = \tfrac{1}{\sqrt{2}}(5-7) = -\sqrt{2}.$$

Alle übrigen Koeffizienten mit $j \leq 2$ verschwinden. Nach (3.18) ist

$$f \;=\; 9\,\varphi_{2,0} \;-\; 3\,\psi_{2,0} \;+\; \sqrt{2}\,\psi_{1,0} \;-\; \sqrt{2}\,\psi_{1,1}, \qquad \|f\|^2 \;=\; 81+9+2+2 \;=\; 94.$$

Bis auf den Faktor $2^{j/2}$ sind das die Zahlen $4{,}5$, $-1{,}5$, 1 und -1 aus Beispiel 3.11.

Zwei Beobachtungen verbinden das Beispiel mit den folgenden Kapiteln. Erstens ist $d_{j,k} = W_\psi f(2^j, k2^j)$. Die Detailkoeffizienten sind also Werte der CWT auf dem dyadischen Gitter,

aber ohne Redundanz. Zweitens bleibt $9\,\varphi_{2,0} - 3\,\psi_{2,0} = P_1 f = (3, 3, 6, 6)$, wenn man die beiden betragskleinsten Koeffizienten $d_{1,0}$ und $d_{1,1}$ auf null setzt. Nach der Energiegleichung ist der Fehler $\|f - P_1 f\|^2 = 2 + 2 = 4$, die Summe der Quadrate der gestrichenen Koeffizienten. Welche Koeffizienten man streicht, lässt sich also im Koeffizientenraum entscheiden. Darauf beruht die Entrauschung in Kapitel 5.

Gleichung (3.18) ist der Ausgangspunkt der folgenden Kapitel. Kapitel 4 konstruiert ψ und berechnet die Koeffizienten allein durch Filteroperationen. Der Schlüssel ist die Inklusion $\varphi \in V_0 \subset V_{-1}$ [LMR98, Lemma 2.2.3], [Bla03, Satz (5.3)]. Kapitel 5 nutzt, dass $f \mapsto (a_{J,k}, d_{j,k})$ nach (3.18) eine Isometrie ist (Definition 2.1).

4. Konstruktion der diskreten Wavelet-Transformation

Kapitel 3 endete mit einer bedingten Aussage: Gibt es eine Funktion ψ, deren um ganze Zahlen verschobene Kopien $\psi(\cdot - k)$, $k \in \mathbb{Z}$, eine Orthonormalbasis von W_0 bilden, so ist $\{\psi_{j,k}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$ (Korollar 3.20). Dieses Kapitel konstruiert ein solches ψ und beantwortet dabei drei Fragen: Wie erhält man ψ aus φ? Wie berechnet man die Koeffizienten $a_{j,k}$ und $d_{j,k}$, ohne ein einziges Integral auszuwerten? Und welche Wavelets eignen sich für Signale wie das EKG? Alle drei Antworten stecken in einer einzigen Zahlenfolge $(h_k)_{k\in\mathbb{Z}}$. Begleitet wird das Kapitel von zwei Beispielen: dem Haar-Wavelet aus Kapitel 3 und dem Daubechies-Wavelet mit vier Koeffizienten, das in Kapitel 6 verwendet wird.

4.1. Die Skalierungsgleichung

Belegstellen. LMR, Lemma 2.2.3, S. 113 [bestätigt]; LMR, Gl. (2.2.23), (2.2.24) und Satz 2.2.9, S. 121 [bestätigt]; LMR, Anhang, S. 314 [bestätigt]; Serov, Satz 25.18, S. 257–258 [bestätigt]; Blatter, Kap. 5.2, Gl. (1), S. 110 [bestätigt], bewiesen in Satz (5.8) [Seite nachtragen]; Blatter, Satz (5.3), S. 111 [bestätigt].

In diesem Abschnitt wird die Skalierungsfunktion φ durch eine Zahlenfolge (h_k) beschrieben, und es werden zwei Bedingungen an diese Folge hergeleitet. Alles Weitere in diesem Kapitel wird nur noch mit den h_k rechnen; die Funktionen φ und ψ selbst werden dafür nicht mehr benötigt.

Nach (M1) ist $\varphi \in V_0 \subset V_{-1}$, und nach Satz 3.15 bilden die Funktionen $\varphi_{-1,k}(t) = \sqrt{2}\,\varphi(2t-k)$ eine Orthonormalbasis von V_{-1}. Also lässt sich φ in dieser Basis darstellen:

$$\varphi = \sum_{k\in\mathbb{Z}} \langle \varphi, \varphi_{-1,k}\rangle\, \varphi_{-1,k}.$$

Rechts steht eine gewichtete Summe der Funktionen $\varphi(2t-k)$. Jede davon ist eine Kopie von φ, die um den Faktor 2 zusammengedrückt und um $k/2$ verschoben ist, denn $\varphi(2t-k) = \varphi\big(2(t-k/2)\big)$. Die Skalierungsfunktion lässt sich also aus schmaleren Kopien ihrer selbst zusammensetzen.

Satz 4.1 (Skalierungsgleichung, vgl. [LMR98, Lemma 2.2.3]). *Sei $(V_j)_{j\in\mathbb{Z}}$ eine MSA mit Skalierungsfunktion φ. Mit $h_k := \langle \varphi, \varphi_{-1,k}\rangle$ gilt*

$$\varphi(t) \;=\; \sqrt{2}\sum_{k\in\mathbb{Z}} h_k\,\varphi(2t-k) \quad \textit{für fast alle } t\in\mathbb{R} \qquad \textit{und} \qquad \sum_{k\in\mathbb{Z}} |h_k|^2 \;=\; 1, \tag{4.1}$$

wobei die Reihe in $L^2(\mathbb{R})$ konvergiert. Die Folge (h_k) heißt Skalierungsfolge oder Tiefpassfilter der MSA.

Beweis. Nach (M1) liegt φ in V_{-1}, und $\{\varphi_{-1,k}\}_k$ ist nach Satz 3.15 eine Orthonormalbasis von V_{-1}. Die Fourier-Entwicklung in dieser Basis [Ser17, Satz 25.18 (3)] lautet $\varphi = \sum_k h_k\,\varphi_{-1,k}$ mit $h_k\,\varphi_{-1,k}(t) = \sqrt{2}\,h_k\,\varphi(2t-k)$. Nach der Parseval-Gleichung [Ser17, Satz 25.18 (5)] ist $\sum_k |h_k|^2 = \|\varphi\|^2 = 1$, denn φ ist nach (M5) selbst Element der Orthonormalbasis $\{\varphi(\cdot - k)\}_k$ von V_0. □

Beispiel 4.2 (Haar). Für $\varphi = \mathbf{1}_{[0,1[}$ aus Beispiel 3.14 ist $\varphi(2t) = \mathbf{1}_{[0,1/2[}(t)$ und $\varphi(2t-1) = \mathbf{1}_{[1/2,1[}(t)$. Eine Stufe der Breite 1 besteht also aus zwei Stufen der Breite $\frac{1}{2}$:

$$\varphi(t) \;=\; \varphi(2t) + \varphi(2t-1) \;=\; \sqrt{2}\Big(\tfrac{1}{\sqrt{2}}\,\varphi(2t) + \tfrac{1}{\sqrt{2}}\,\varphi(2t-1)\Big).$$

Der Vergleich mit (4.1) liefert $h_0 = h_1 = \frac{1}{\sqrt{2}}$ und $h_k = 0$ sonst, in Übereinstimmung mit $h_0 = \langle \varphi, \varphi_{-1,0}\rangle = \sqrt{2}\cdot\frac{1}{2}$ und $\sum_k |h_k|^2 = 1$.

Aus der Skalierungsgleichung folgt eine zweite Bedingung an (h_k), die man im Frequenzbereich sieht; dabei sei $\sum_k |h_k| < \infty$, was für endliche Filter stets gilt. Nach den Rechenregeln der Fourier-Transformation für Stauchung und Verschiebung [LMR98, Anhang] ist $\widehat{\varphi_{-1,k}}(\omega) = \frac{1}{\sqrt{2}}\,e^{-ik\omega/2}\,\hat\varphi\big(\frac{\omega}{2}\big)$. Transformiert man $\varphi = \sum_k h_k\,\varphi_{-1,k}$ gliedweise und zieht den von k unabhängigen Faktor $\hat\varphi(\omega/2)$ vor die Summe, so wird die Skalierungsgleichung mit dem 2π-periodischen Fourier-Filter

$$H(\omega) \;:=\; \frac{1}{\sqrt{2}} \sum_{k\in\mathbb{Z}} h_k\, e^{-ik\omega} \tag{4.2}$$

zu einem Produkt [LMR98, Gl. (2.2.23)]:

$$\hat\varphi(\omega) \;=\; H\big(\tfrac{\omega}{2}\big)\,\hat\varphi\big(\tfrac{\omega}{2}\big), \qquad \omega \in \mathbb{R}. \tag{4.3}$$

Für die hier betrachteten MSA ist $|\hat\varphi(0)| = (2\pi)^{-1/2}$, insbesondere $\hat\varphi(0) \neq 0$ [Bla03, Kap. 5.2]. Da beide Seiten von (4.3) stetig sind, darf man $\omega = 0$ einsetzen; Division durch $\hat\varphi(0)$ ergibt

$$H(0) \;=\; 1, \qquad \text{das heißt} \qquad \sum_{k\in\mathbb{Z}} h_k \;=\; \sqrt{2}, \tag{4.4}$$

im Haar-Fall $\frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} = \sqrt{2}$; vgl. [LMR98, Satz 2.2.9].

4.2. Filterkoeffizienten: Tiefpass und Hochpass

Belegstellen. LMR, Lemma 2.2.8, Gl. (2.2.22) [Seite nachtragen, vermutl. S. 120–121]; LMR, Satz 2.2.10, S. 122, Beweis S. 122–123 [bestätigt]; LMR, Beispiel S. 169 und Tabelle 2.3, S. 170 [bestätigt], dort umgekehrte Reihenfolge wegen $e^{+ik\omega}$; Serov, Satz 25.18, S. 257–258 [bestätigt]; Blatter, Kap. 5.2, S. 110–116 [bestätigt].

Bisher wurde die Folge (h_k) aus einer gegebenen Skalierungsfunktion gewonnen. Für die Konstruktion neuer Wavelets geht man umgekehrt vor: Man wählt die Zahlen h_k und erhält φ und ψ daraus. Dafür muss man wissen, welche Bedingungen eine Folge erfüllen muss, um zu einer MSA zu gehören. Neben (4.4) übersetzt sich auch die Orthonormalität der Verschiebungen $\varphi(\cdot - k)$ aus (M5) in eine Bedingung an die Folge selbst.

Lemma 4.3 (Orthogonalität der Filterkoeffizienten, vgl. [LMR98, Lemma 2.2.8]). *Die Skalierungsfolge einer MSA erfüllt*

$$\sum_{n\in\mathbb{Z}} h_n\,\overline{h_{n-2m}} \;=\; \delta_{m,0} \qquad \text{für alle } m\in\mathbb{Z}. \tag{4.5}$$

Beweis. Ersetzt man in (4.1) t durch $t-m$ und setzt $n=k+2m$, so wird $\varphi(t-m)=\sqrt{2}\sum_k h_k\,\varphi(2t-2m-k)=\sum_n h_{n-2m}\,\varphi_{-1,n}(t)$. Die Vollständigkeitsrelation in V_{-1} [Ser17, Satz 25.18 (4)] und (M5) liefern $\delta_{m,0}=\langle\varphi,\varphi(\,\cdot-m)\rangle=\sum_n h_n\,\overline{h_{n-2m}}$. □

Anschaulich: Die Basisfunktionen $\varphi_{-1,n}$ liegen im Abstand $\frac12$. Verschiebt man φ um 1, so rückt ihr Koeffizientenvektor (h_n) deshalb um zwei Stellen weiter. Die Orthogonalität der verschobenen Funktionen wird so zur Orthogonalität des Vektors (h_n) zu seinen um gerade Schrittweiten verschobenen Kopien. Für das Haar-Filter ist das trivial, denn für $m\neq 0$ überlappen (h_n) und (h_{n-2m}) nicht.

Beispiel 4.4 (Ein Filter der Länge vier). Gesucht seien reelle $h_0,\dots,h_3$, alle übrigen null. Die Bedingungen (4.4) und (4.5) lauten

$$h_0+h_1+h_2+h_3=\sqrt{2},\qquad h_0^2+h_1^2+h_2^2+h_3^2=1,\qquad h_0h_2+h_1h_3=0;$$

für $|m|\geq 2$ überlappen die Folgen nicht. Drei Gleichungen für vier Unbekannte lassen eine einparametrige Lösungsschar, zu der auch das Haar-Filter $(\frac{1}{\sqrt2},\frac{1}{\sqrt2},0,0)$ gehört. Eine weitere Lösung ist

$$h_0=\tfrac{1+\sqrt3}{4\sqrt2},\qquad h_1=\tfrac{3+\sqrt3}{4\sqrt2},\qquad h_2=\tfrac{3-\sqrt3}{4\sqrt2},\qquad h_3=\tfrac{1-\sqrt3}{4\sqrt2} \tag{4.6}$$

[LMR98, Tabelle 2.3], dort in umgekehrter Reihenfolge. Zur Probe: Die Zähler summieren sich zu 8, also $\sum h_k=8/(4\sqrt2)=\sqrt2$. Die quadrierten Zähler ergeben $(4+2\sqrt3)+(12+6\sqrt3)+(12-6\sqrt3)+(4-2\sqrt3)=32=(4\sqrt2)^2$, also $\sum h_k^2=1$. Schließlich ist $(1+\sqrt3)(3-\sqrt3)+(3+\sqrt3)(1-\sqrt3)=2\sqrt3-2\sqrt3=0$. Warum gerade diese Lösung aus der Schar ausgewählt wird, klärt Abschnitt 4.5.

Im Haar-Fall haben die Zahlen h_k eine einfache Bedeutung: Mit $h_0=h_1=\frac{1}{\sqrt2}$ bildet (h_k) aus zwei benachbarten Werten deren (normierten) Mittelwert, wie in Beispiel 3.11. Konstante Signale bleiben dabei erhalten, rasche Schwankungen werden geglättet; daher der Name Tiefpass. Das Gegenstück, das in Beispiel 3.11 die verlorenen Details liefert, ist die Differenz benachbarter Werte. Sie verschwindet für konstante Signale und heißt Hochpass. Für allgemeine (h_k) gewinnt man die Hochpassfolge durch Umkehren der Reihenfolge und alternierende Vorzeichen.

Satz 4.5 (Wavelet aus der Skalierungsfolge, vgl. [LMR98, Satz 2.2.10]). *Sei (V_j) eine MSA mit Skalierungsfolge (h_k). Setzt man*

$$g_k \;:=\; (-1)^k\,\overline{h_{1-k}},\qquad \psi(t)\;:=\;\sqrt{2}\sum_{k\in\mathbb{Z}} g_k\,\varphi(2t-k), \tag{4.7}$$

so ist $\{\psi(\,\cdot-k):k\in\mathbb{Z}\}$ eine Orthonormalbasis von W_0. Nach Korollar 3.20 ist dann $\{\psi_{j,k}:j,k\in\mathbb{Z}\}$ eine Orthonormalbasis von $L^2(\mathbb{R})$.

Der vollständige Beweis steht bei [LMR98, Satz 2.2.10].

Beispiel 4.6 (Haar, Fortsetzung). Aus $h_0 = h_1 = 1/\sqrt{2}$ folgt $g_0 = h_1 = 1/\sqrt{2}$ und $g_1 = -h_0 = -1/\sqrt{2}$, also

$$\psi(t) \;=\; \varphi(2t) - \varphi(2t-1) \;=\; \mathbf{1}_{[0,1/2[}(t) - \mathbf{1}_{[1/2,1[}(t) \;=\; \psi^{\mathrm{H}}(t).$$

Damit ist ψ^{H} als Wavelet der Haar-MSA nachgewiesen, wie es Beispiel 3.11 nahegelegt hatte. Für die Folge (4.6) ist entsprechend $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$.

4.3. Bedingungen im Fourier-Bereich

Belegstellen. LMR, Satz 2.2.9, S. 121 [bestätigt]; LMR, Korollar 2.2.12, S. 123 [bestätigt]; LMR, Bem. 2.4.19, S. 165 [bestätigt]; LMR, Kap. 2.4.2, S. 145–164 [bestätigt].

In Abschnitt 4.2 wurden die Namen Tiefpass und Hochpass nur am Haar-Filter begründet. Für beliebige Filter liefert das Fourier-Filter H aus (4.2) die Begründung. Es gibt an, wie stark der Filter eine Schwingung der Frequenz ω durchlässt: Für $x_n = e^{i\omega n}$ ist $\sum_k h_k\, x_{n-k} = \sqrt{2}\, H(\omega)\, x_n$. Für $\omega = 0$ ist $x_n = 1$ konstant, für $\omega = \pi$ ist $x_n = (-1)^n$, die Folge wechselt also bei jedem Schritt das Vorzeichen. Schneller kann eine abgetastete Schwingung nicht oszillieren, da $e^{i(\omega+2\pi)n} = e^{i\omega n}$ gilt. Wie in Abschnitt 4.1 sei $\sum_k |h_k| < \infty$.

Satz 4.7 (Bedingungen an das Fourier-Filter, [LMR98, Satz 2.2.9]). *Das Fourier-Filter* (4.2) *einer MSA erfüllt*

$$H(0) = 1 \qquad \textit{und} \qquad |H(\omega)|^2 + |H(\omega+\pi)|^2 = 1 \quad \textit{für alle } \omega \in \mathbb{R}. \tag{4.8}$$

Die erste Gleichung ist (4.4). Die zweite ist Lemma 4.3, in den Frequenzbereich übersetzt: Die unendlich vielen Gleichungen für die Zahlen h_k werden zu einer einzigen Gleichung für die Funktion H. Umgekehrt liefert jede endliche Folge mit (4.8), deren Fourier-Filter auf $[-\pi/2, \pi/2]$ keine Nullstelle hat, eine Lösung φ der Skalierungsgleichung mit orthonormalen Verschiebungen $\varphi(\cdot - k)$ [LMR98, Satz 2.4.7].

Für die Hochpassfolge (g_k) aus (4.7) setzt man analog $G(\omega) := 2^{-1/2} \sum_k g_k e^{-ik\omega}$. Die Substitution $n = 1 - k$ ergibt

$$G(\omega) \;=\; -e^{-i\omega}\, \overline{H(\omega+\pi)}, \qquad \hat{\psi}(\omega) \;=\; G\big(\tfrac{\omega}{2}\big)\, \hat{\varphi}\big(\tfrac{\omega}{2}\big) \tag{4.9}$$

[LMR98, Korollar 2.2.12], also $|G(\omega)| = |H(\omega+\pi)|$. Aus (4.8) und (4.9) folgen drei Aussagen:

(a) $H(0) = 1$ und $H(\pi) = 0$: (h_k) lässt konstante Signale vollständig durch und löscht die schnellste Schwingung aus. Das ist ein Tiefpass.

(b) $G(0) = 0$ und $|G(\pi)| = 1$: (g_k) verhält sich genau umgekehrt. Das ist ein Hochpass. Wegen $\hat{\psi}(0) = G(0)\, \hat{\varphi}(0) = 0$ hat ψ Mittelwert null, wie es Satz 3.2 von einem zulässigen Wavelet verlangt; zulässig ist ψ tatsächlich stets [LMR98, Satz 2.2.10 (iii)].

(c) $|H(\omega)|^2 + |G(\omega)|^2 = 1$: Jede Frequenz wird vollständig auf die beiden Filter aufgeteilt, es geht nichts verloren. In der Signalverarbeitung heißen solche Filterpaare Conjugate Quadrature Filter [LMR98, Bem. 2.4.19].

Abbildung 4.1 zeigt beide Filter. Beim Haar-Filter ist $|H(\omega)| = |\cos(\omega/2)|$ und die Nullstelle bei $\omega = \pi$ einfach. Für (4.6) ist $|H(\omega)|^2 = \cos^4(\omega/2)\left(1 + 2\sin^2(\omega/2)\right)$, vgl. [LMR98, Kap. 2.4.3], die Nullstelle also doppelt, und die Kurven verlaufen an den Rändern flacher. Abschnitt 4.5 zeigt, dass genau diese Ordnung der Nullstelle bestimmt, wie gut sich ein Wavelet für glatte Signalabschnitte eignet.

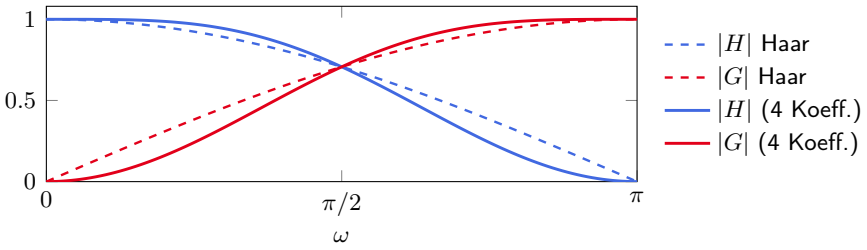


Abbildung 4.1.: Betrag der Fourier-Filter H (Tiefpass) und G (Hochpass) für das Haar-Filter (gestrichelt) und das Filter (4.6) (durchgezogen) auf $[0, \pi]$. In beiden Fällen ist $|H|^2 + |G|^2 = 1$.

4.4. Der Mallat-Algorithmus

Belegstellen. Blatter, Kap. 5.4, S. 130–136 [bestätigt], insb. Skalierungs- gleichungen 5.4.(1)/(2), S. 130 [bestätigt], Zwei-Skalen-Relation 5.4.(3)/(4) mit Herleitung, S. 131 [bestätigt], Analyseformeln (eingerahmt, unnummeriert), S. 132–133 [bestätigt]; LMR, Kap. 2.3, S. 132–141 [bestätigt], insb. Analyseformeln (unnummeriert, mit Verweis auf Skalierungsgl. (2.2.8)/(2.2.27)), S. 133 [bestätigt], Gl. (2.3.1)/(2.3.2), S. 133 [bestätigt], Abb. 2.8, S. 134 [bestätigt]; Aufwand: Blatter, Kap. 5.4, S. 133–135 [bestätigt], Hanke-Bourgeois, § 56, S. 438 [bestätigt]; LMR, Kap. 3.1.1, S. 237–238 [bestätigt].

Bisher erfordert jeder Koeffizient

$$a_{j,k} = \langle f, \varphi_{j,k} \rangle = \int_{\mathbb{R}} f(t)\, \varphi_{j,k}(t)\, dt, \qquad d_{j,k} = \langle f, \psi_{j,k} \rangle = \int_{\mathbb{R}} f(t)\, \psi_{j,k}(t)\, dt$$

(Definition 3.16, Korollar 3.20) ein eigenes Integral. Nach [Bla03, Kap. 5.4] und [LMR98, Kap. 2.3, Abb. 2.8] lassen sich $a_{j,\cdot}$ und $d_{j,\cdot}$ jedoch allein aus $a_{j-1,\cdot}$ und den Filtern h, g berechnen. Grundlage dafür ist die folgende Darstellung der Basisfunktionen der Skala j durch die der feineren Skala $j - 1$.

Lemma 4.8 (Zwei-Skalen-Relation, [Bla03, Kap. 5.4, (3), (4)]). *Für alle $j, k \in \mathbb{Z}$ gilt*

$$\varphi_{j,k} = \sum_{n \in \mathbb{Z}} h_{n-2k}\, \varphi_{j-1,n}, \qquad \psi_{j,k} = \sum_{n \in \mathbb{Z}} g_{n-2k}\, \varphi_{j-1,n}. \tag{4.10}$$

Für einen Beweis siehe [Bla03, Kap. 5.4]. Bildet man in (4.10) das Skalarprodukt mit f, so überträgt sich die Relation auf die Koeffizienten.

Satz 4.9 (Analyseschritt, [Bla03, Kap. 5.4]). *Für reelle Filter h, g und alle $j, k \in \mathbb{Z}$ gilt*

$$a_{j,k} = \sum_{n\in\mathbb{Z}} h_{n-2k}\, a_{j-1,n}, \qquad d_{j,k} = \sum_{n\in\mathbb{Z}} g_{n-2k}\, a_{j-1,n}. \tag{4.11}$$

Beweis. Vgl. [Bla03, Kap. 5.4]. Die Reihe in (4.10) konvergiert in $L^2(\mathbb{R})$, da $(h_n) \in \ell^2(\mathbb{Z})$ und $\{\varphi_{j-1,n}\}_{n\in\mathbb{Z}}$ orthonormal ist. Wegen der Stetigkeit des Skalarprodukts und $h_n \in \mathbb{R}$ folgt

$$a_{j,k} = \Big\langle f, \sum_n h_{n-2k}\, \varphi_{j-1,n} \Big\rangle = \sum_n h_{n-2k} \langle f, \varphi_{j-1,n}\rangle = \sum_n h_{n-2k}\, a_{j-1,n}.$$

Analog für $d_{j,k}$ mit g. □

Die Koeffizienten der Skala j sind also gewichtete Summen der Approximationskoeffizienten der Skala $j-1$; Integrale treten nur noch bei der Berechnung der Startwerte $a_{0,\cdot}$ auf.

Haben h und g jeweils höchstens L von Null verschiedene Einträge, so sind die Summen in (4.11) endlich: Jeder Koeffizient $a_{j,k}$ bzw. $d_{j,k}$ erfordert höchstens L Multiplikationen, vgl. [Bla03, Kap. 5.4]. Da die Gewichte mit $k \mapsto k+1$ um zwei Indizes weiterrücken, halbiert sich zudem die Anzahl der Koeffizienten von Skala zu Skala bis auf einen Randterm der Größe $L-2$, vgl. [Bla03, Kap. 5.4, (7)].

Algorithmus 1 Schnelle Wavelet-Transformation, vgl. [Bla03, Kap. 5.4], [LMR98, Kap. 2.3, Abb. 2.8]

Eingabe: Startfolge $a_{0,\cdot}$, Filter h, g, Tiefe $J \in \mathbb{N}$
Ausgabe: Detailfolgen $d_{1,\cdot}, \ldots, d_{J,\cdot}$ und Approximation $a_{J,\cdot}$

1: **für** $j = 1, \ldots, J$ **tue**
2: **für** alle k **tue**
3: $a_{j,k} \leftarrow \sum_n h_{n-2k}\, a_{j-1,n}$
4: $d_{j,k} \leftarrow \sum_n g_{n-2k}\, a_{j-1,n}$
5: **Ende für**
6: **Ende für**
7: **Rückgabe** $d_{1,\cdot}, \ldots, d_{J,\cdot}, \; a_{J,\cdot}$

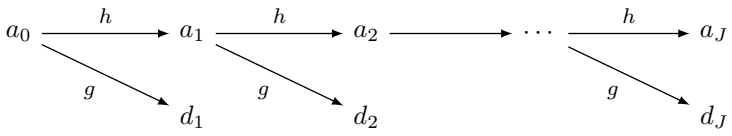


Abbildung 4.2.: Ablauf von Algorithmus 1, in Anlehnung an [Bla03, Kap. 5.4, (6)]; vgl. auch [LMR98, Abb. 2.8]. Jeder Pfeil ist ein Rechenschritt nach (4.11) mit dem Filter h bzw. g und halbiert die Anzahl der Werte. Nur die Approximationskoeffizienten werden weiter zerlegt.

Beispiel 4.10 (Haar, Fortsetzung von Beispiel 3.21)**.** Für das Haar-Filter $h_0 = h_1 = \frac{1}{\sqrt{2}}$ liefert (4.7) $g_0 = \frac{1}{\sqrt{2}}$, $g_1 = -\frac{1}{\sqrt{2}}$; alle übrigen h_k, g_k verschwinden. In (4.11) bleiben daher nur die Summanden $n = 2k$ und $n = 2k+1$:

$$a_{j,k} = \frac{a_{j-1,2k} + a_{j-1,2k+1}}{\sqrt{2}}, \qquad d_{j,k} = \frac{a_{j-1,2k} - a_{j-1,2k+1}}{\sqrt{2}},$$

also genau Mitteln und Differenzbilden aus Beispiel 3.11. Für die Treppenfunktion $f = (4, 2, 5, 7)$ der Haar-MSA ist $a_{0,k} = f(k)$. Die erste Stufe liefert $a_1 = (\frac{6}{\sqrt{2}}, \frac{12}{\sqrt{2}}) = (3\sqrt{2}, 6\sqrt{2})$ und $d_1 = (\sqrt{2}, -\sqrt{2})$, die zweite $a_{2,0} = 9$ und $d_{2,0} = -3$. Das sind genau die Koeffizienten aus Beispiel 3.21, nun ohne ein einziges Integral berechnet.

Der Aufwand ist gering. Hat der Filter die Länge L, kostet eine Stufe mit N Eingangswerten etwa LN Multiplikationen. Da sich die Anzahl der Werte von Stufe zu Stufe ungefähr halbiert, sind es insgesamt etwa $L\,(N + N/2 + N/4 + \cdots) \approx 2LN$, also $O(N)$ Operationen [Bla03, Kap. 5.4]. Die schnelle Fourier-Transformation braucht dagegen $O(N \log N)$ [HB09, § 53].

Jeder Schritt lässt sich exakt rückgängig machen.

Satz 4.11 (Rekonstruktion, [Bla03, Kap. 5.4])**.** *Für alle $j, n \in \mathbb{Z}$ gilt*

$$a_{j-1,n} \;=\; \sum_{k\in\mathbb{Z}} h_{n-2k}\, a_{j,k} \;+\; \sum_{k\in\mathbb{Z}} g_{n-2k}\, d_{j,k}. \tag{4.12}$$

Beweis. Nach Definition 3.18 und Korollar 3.20 ist $P_{j-1}f = P_j f + Q_j f = \sum_k a_{j,k}\varphi_{j,k} + \sum_k d_{j,k}\psi_{j,k}$. Skalarprodukt mit $\varphi_{j-1,n}$ und Lemma 4.8 liefern (4.12), vgl. [Bla03, Kap. 5.4]. □

Im Haar-Fall wird daraus $a_{j-1,2k} = (a_{j,k} + d_{j,k})/\sqrt{2}$ und $a_{j-1,2k+1} = (a_{j,k} - d_{j,k})/\sqrt{2}$, im Beispiel $(3\sqrt{2} \pm \sqrt{2})/\sqrt{2} = 4$ bzw. 2. Auch die Rekonstruktion kostet nur $O(N)$ Operationen, bleibt also weiterhin linear [Bla03, Kap. 5.4].

Bemerkung 4.12. Jeder Schritt $a_{j-1,\cdot} \mapsto (a_{j,\cdot}, d_{j,\cdot})$ von Algorithmus 1 ersetzt die Orthonormalbasis $\{\varphi_{j-1,n}\}_n$ von V_{j-1} durch die Orthonormalbasis $\{\varphi_{j,k}\}_k \cup \{\psi_{j,k}\}_k$ [Bla03, Kap. 5.4]. Die Parseval-Gleichung [Ser17, Satz 25.18 (5)], angewandt auf $P_{j-1}f$ in beiden Basen, liefert

$$\sum_n |a_{j-1,n}|^2 \;=\; \|P_{j-1}f\|^2 \;=\; \sum_k |a_{j,k}|^2 + \sum_k |d_{j,k}|^2,$$

im Beispiel $4^2 + 2^2 = 20 = (3\sqrt{2})^2 + (\sqrt{2})^2$. Ein Schritt ist also eine orthogonale Abbildung der Koeffizientenfolgen; genau diese Eigenschaft wird in Abschnitt 5.1 gebraucht.

In der Anwendung ist f nicht bekannt, sondern nur durch Abtastwerte gegeben. Diese werden als Koeffizienten $a_{0,k}$ der feinsten Skala verwendet [Bla03, Kap. 5.4]; wie ein endliches Signal dabei am Rand fortgesetzt wird, beschreibt Abschnitt 5.1.

4.5. Daubechies-Wavelets

Belegstellen. Blatter, Kap. 3.5, S. 74 [bestätigt]; LMR, Lemma 2.4.30, S. 176 [bestätigt]; LMR, Satz 2.4.9, S. 153 [bestätigt]; LMR, Kap. 2.4.4, S. 173–175 [bestätigt], insb. Satz 2.4.28 (Momente), S. 174, Träger von ψ_N, S. 175, Regularität $H^{\alpha N}$, $\alpha > 0{,}2$, S. 173; Blatter, Kap. 6.2, S. 146–151 [bestätigt]; Blatter, Kap. 6.3, S. 158 [bestätigt]; Rebstadt, Kap. 2.3.1, S. 16–20 [bestätigt].

Die Formeln des Mallat-Algorithmus gelten für die Skalierungsfolge jeder MSA; offen ist aber, welche man wählen soll. Das Haar-Filter erzeugt selbst auf glatten Signalabschnitten von null verschiedene Detailkoeffizienten. Gesucht sind daher kurze Filter, deren Wavelet glatte Abschnitte möglichst nicht sieht. Die dafür entscheidende Eigenschaft ist die folgende.

Definition 4.13 (Verschwindende Momente, vgl. [Bla03, Kap. 3.5]). Ein Wavelet ψ mit kompaktem Träger hat p verschwindende Momente,[1] falls

$$\int_{\mathbb{R}} t^m \, \psi(t) \, dt \;=\; 0 \qquad \text{für } m = 0, 1, \ldots, p-1.$$

Das Moment $m = 0$ ist die Zulässigkeitsbedingung aus Satz 3.2. Allgemein ist $\int_{\mathbb{R}} q(t)\, \psi_{j,k}(t)\, dt = 0$ für jedes Polynom q vom Grad $< p$: Das Wavelet sieht Polynome niedrigen Grades nicht. Wie sich das im Mallat-Algorithmus auswirkt, zeigt das folgende Beispiel.

Beispiel 4.14 (Ein lineares Signal). Nach (4.11) liefert die linear ansteigende Folge $a_{0,n} = n$ die Detailkoeffizienten

$$d_{1,k} \;=\; \sum_m g_m \, (m + 2k) \;=\; \sum_m m\, g_m + 2k \sum_m g_m.$$

Für Haar ist $g_0 = -g_1 = 1/\sqrt{2}$ (Beispiel 4.6), also $\sum_m g_m = 0$, aber $\sum_m m\, g_m = g_1 = -1/\sqrt{2}$. Damit ist $d_{1,k} = -1/\sqrt{2}$ für jedes k, obwohl das Signal überall gleichmäßig ansteigt und weder Spitzen noch Knicke besitzt. Für die Koeffizienten $h_0, \ldots, h_3$ aus (4.6) ist $(g_{-2}, g_{-1}, g_0, g_1) = (h_3, -h_2, h_1, -h_0)$, und es gilt

$$4\sqrt{2} \sum_m g_m \;=\; (1-\sqrt{3}) - (3-\sqrt{3}) + (3+\sqrt{3}) - (1+\sqrt{3}) \;=\; 0,$$

$$4\sqrt{2} \sum_m m\, g_m \;=\; -2(1-\sqrt{3}) + (3-\sqrt{3}) - (1+\sqrt{3}) \;=\; 0,$$

also $d_{1,k} = 0$: Lineare Abschnitte landen vollständig in den Approximationskoeffizienten, vgl. [LMR98, Lemma 2.4.29]. Damit ist auch die Frage aus Beispiel 4.4 beantwortet: Die Folge (4.6) ist das Daubechies-Filter mit zwei verschwindenden Momenten [Bla03, Kap. 6.3], das Haar-Filter aus derselben Schar hat nur eines.

Für glatte, nicht polynomiale Signale gilt das näherungsweise, umso besser, je feiner die Skala ist.

Lemma 4.15 (Abklingen der Detailkoeffizienten, vgl. [LMR98, Beweis von Lemma 2.4.30]). *Sei ψ ein Wavelet mit p verschwindenden Momenten und $\operatorname{supp}\psi = [\alpha, \beta] \ni 0$. Ist f auf $I_{j,k} := \operatorname{supp}\psi_{j,k}$ p-mal stetig differenzierbar mit $|f^{(p)}| \le M_{j,k}$, so gilt*

$$|d_{j,k}| \;\le\; 2^{j(p+1/2)} \, \frac{M_{j,k}}{p!} \int_{\mathbb{R}} |t^p \, \psi(t)| \, dt.$$

[1] Wie bei Mallat bezeichnet p die Zahl der Momente; N bleibt der Signallänge vorbehalten.

Beweis. Die Substitution $x = 2^j(t+k)$ ergibt $d_{j,k} = 2^{j/2} \int_{\mathbb{R}} f(2^j k + 2^j t)\, \psi(t)\, dt$. Nach Taylor [LMR98, (2.4.20)] ist $f(2^j k + 2^j t) = q(t) + R(t)$ mit einem Polynom q vom Grad $< p$ und dem Rest $R(t) = \frac{1}{p!} f^{(p)}(\eta_t)\, (2^j t)^p$, $\eta_t \in I_{j,k}$. Wegen der verschwindenden Momente ist $\int_{\mathbb{R}} q\, \psi\, dt = 0$, also $d_{j,k} = 2^{j/2} \int_{\mathbb{R}} R(t)\, \psi(t)\, dt$, und $|R(t)| \le \frac{M_{j,k}}{p!}\, 2^{jp}\, |t|^p$ liefert die Behauptung. □

Nach Lemma 4.15 werden die Detailkoeffizienten glatter Abschnitte auf feinen Skalen ($j \to -\infty$) also schnell klein, umso schneller, je größer p ist. An Sprüngen oder steilen Spitzen ist die Voraussetzung des Lemmas verletzt, und die Koeffizienten bleiben dort groß.

Für den Mallat-Algorithmus braucht man zugleich kurze Filter, denn er ist nur mit endlichen Filtern exakt ausführbar. Viele verschwindende Momente und kurze Filter verbinden die Daubechies-Wavelets.

Satz 4.16 (Daubechies-Wavelets, [Bla03, Kap. 6.2], [LMR98, Kap. 2.4.4]). *Zu jedem $p \in \mathbb{N}$ gibt es eine reelle Skalierungsfolge $h_0, \dots, h_{2p-1}$ einer MSA mit*

$$\operatorname{supp} \varphi_p = [0,\, 2p-1], \qquad \operatorname{supp} \psi_p = [1-p,\, p],$$

und das zugehörige Wavelet ψ_p besitzt p verschwindende Momente.

Anmerkung. bruach ich dafür nen beweis??

Der Träger von ψ_p folgt aus (4.7), da dort nur $g_{2-2p}, \dots, g_1$ von null verschieden sind, vgl. [LMR98, Kap. 2.4.4]. Für $p = 1$ entsteht das Haar-Wavelet, für $p = 2$ die Folge (4.6) [Bla03, Kap. 6.3] mit φ_2 und ψ_2 aus Abbildung 4.3. In PyWavelets [LGW+19] heißt ψ_p `dbp`; das Wavelet mit vier Koeffizienten ist also `db2`, nicht `db4`.

Anmerkung. Bib-Eintrag pywavelets anlegen und über DOI prüfen.

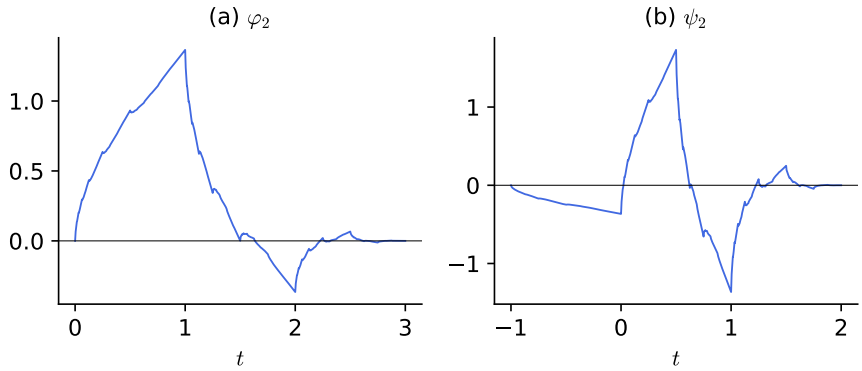


Abbildung 4.3.: Skalierungsfunktion φ_2 auf $[0, 3]$ (a) und Wavelet ψ_2 auf $[-1, 2]$ (b) zur Folge (4.6), berechnet durch Iteration der Skalierungsgleichung (4.1).

Anmerkung. Python-Datei zur Abbildung richtig ablegen.

Gegenüber Haar ist ψ_2 stetig [Bla03, Satz (6.11)], aber dreimal so breit. Allgemein wird ψ_p mit wachsendem p glatter, nämlich $\psi_p \in H^{\alpha p}(\mathbb{R})$ mit $\alpha > 0{,}2$ [LMR98, Kap. 2.4.4], zugleich wächst aber die Trägerlänge $2p-1$. Bei der Wahl von p muss man daher abwägen. Viele Momente

sind gut für die ruhigen, langsam verlaufenden Teile des EKG wie P- und T-Welle: Dort werden die Detailkoeffizienten fast null (Lemma 4.15). Ein breiter Träger ist dagegen schlecht für den steilen QRS-Komplex [Reb21, Kap. 2.3.1], denn dessen Spitze wird dann von mehreren Wavelets gleichzeitig erfasst und verteilt sich auf mehrere Koeffizienten. Insgesamt bleibt das Bild aber dasselbe: Wenige große Koeffizienten tragen die Spitzen, fast alle übrigen sind klein [HB09, Beispiel 56.3]. Auf dieser Dünnbesetztheit baut Abschnitt 5.2 auf.

Beispiel 4.17 (Das Daubechies-Wavelet mit $p = 6$)**.** Für $p = 6$ liefert Satz 4.16 die zwölf Filterkoeffizienten $h_0, \dots, h_{11}$, gerundet auf sechs Stellen

$$\begin{aligned}(h_0, \dots, h_5) &= (0{,}111541,\ 0{,}494624,\ 0{,}751134,\ 0{,}315250,\ -0{,}226265,\ -0{,}129767),\\ (h_6, \dots, h_{11}) &= (0{,}097502,\ 0{,}027523,\ -0{,}031582,\ 0{,}000554,\ 0{,}004777,\ -0{,}001077),\end{aligned} \tag{4.13}$$

mit $\operatorname{supp}\varphi_6 = [0, 11]$ und $\operatorname{supp}\psi_6 = [-5, 6]$. Blatter verweist für die Werte bis $p = 10$ auf die Tabelle bei Daubechies [Bla03, Kap. 6.2]; die Werte oben stammen aus PyWavelets [LGW+19], wo ψ_6 db6 heißt. Sie erfüllen (4.4) und (4.5) bis auf Rundungsfehler, und für die Hochpassfolge $g_k = (-1)^k h_{1-k}$, $k = -10, \dots, 1$, aus (4.7) gilt wie in Beispiel 4.14

$$\sum_k k^m\, g_k = 0 \qquad \text{für } m = 0, \dots, 5;$$

das sind die sechs verschwindenden Momente von ψ_6 in der Form, in der sie im Mallat-Algorithmus wirken. Abbildung 4.4 zeigt φ_6 und ψ_6. Gegenüber ψ_2 ist der Träger fast viermal so lang, und ψ_6 ist glatter, $\psi_6 \in H^{6\alpha}(\mathbb{R})$ mit $\alpha > 0{,}2$ [LMR98, Kap. 2.4.4]. Castillo et al. verwenden ψ_6 für EKG-Signale, weil es einem echten EKG ähnelt [CMG+13, Abschn. 3.1.1]; wir übernehmen es in Kapitel 6.

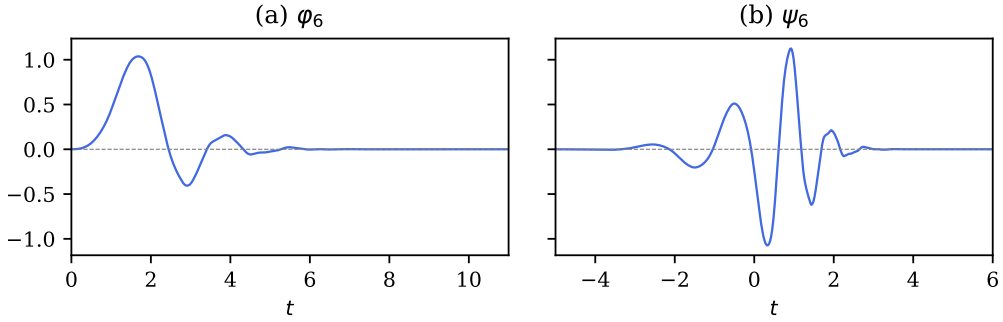


Abbildung 4.4.: Skalierungsfunktion φ_6 auf $[0, 11]$ (a) und Wavelet ψ_6 auf $[-5, 6]$ (b) zur Folge (4.13), berechnet durch Iteration der Skalierungsgleichung (4.1) (Code in Anhang B.3).

Damit liegen die drei Eigenschaften vor, die Kapitel 5 voraussetzt: Die diskrete Wavelet-Transformation ist orthogonal (Bemerkung 4.12), in $O(N)$ Operationen berechenbar (Algorithmus 1) und stellt stückweise glatte Signale dünnbesetzt dar (Lemma 4.15).

5. Entrauschung durch Thresholding

Ziel dieses Kapitels ist, aus verrauschten Messwerten das ursprüngliche Signal möglichst genau zurückzugewinnen. Dafür verwenden wir die diskrete Wavelet-Transformation aus Kapitel 4. Die Idee: Eine geeignet gewählte Orthonormalbasis stellt das Signal mit wenigen Koeffizienten dar [Mal09, Kap. 11.3], während sich das Rauschen gleichmäßig auf alle Koeffizienten verteilt [Mal09, Kap. 11.2.1]. Setzt man die kleinen Koeffizienten auf null, verschwindet vor allem Rauschen, während große Waveletkoeffizienten und damit scharfe Kanten erhalten bleiben [Mal09, Kap. 11.3.1]. Donoho und Johnstone haben gezeigt, dass dieses einfache Thresholding fast optimale Schätzer liefert [Mal09, Kap. 11.2]. Das Verfahren hat drei Schritte (Abbildung 5.1).

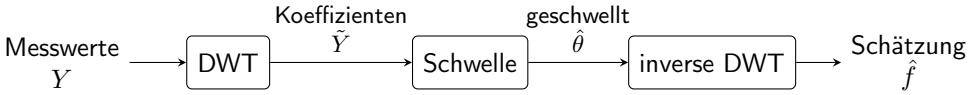


Abbildung 5.1.: Ablauf des Entrauschens: Die Messwerte Y werden mit Algorithmus 1 in Koeffizienten $\tilde{Y}$ zerlegt, jeder Koeffizient wird mit einer Schwelle bearbeitet, und die inverse DWT (Satz 4.11) liefert die Schätzung $\hat{f}$ des Signals. Die Bezeichnungen werden in den Abschnitten 5.1 bis 5.4 eingeführt. Vgl. [Mal09, Gl. (11.84)], [Reb21, Abb. 2.10].

Daraus ergeben sich die Fragen der folgenden Abschnitte: Was macht die Transformation mit dem Rauschen, was mit dem Signal? Wie setzt man kleine Koeffizienten auf null, wo liegt die Grenze, und wie bestimmt man sie aus den Daten? Ein Testsignal begleitet alle Abschnitte. Die Darstellung folgt [Mal09, Kap. 11.2–11.3.1].

5.1. Rauschmodell und diskrete Wavelet-Transformation

Das Rauschen wird als zufällig modelliert; die dafür benötigten Begriffe stehen in Abschnitt 2.6.

Definition 5.1 (Gauß'sches weißes Rauschen, [Mal09, Kap. 11.2.1–11.2.2]). Ein Zufallsvektor $W = (W_0, \dots, W_{N-1})$ heißt weißes Rauschen der Varianz σ^2, wenn $\mathbb{E}[W_n] = 0$ und $\mathbb{E}[W_n W_k] = \sigma^2 \, \delta_{n,k}$ für alle n, k gilt. Sind die W_n zudem gemeinsam normalverteilt, heißt W Gauß'sches weißes Rauschen.

Nach Satz 2.4 sind die Komponenten eines Gauß'schen weißen Rauschens der Varianz 1 unabhängig und standardnormalverteilt.

Das Modell. Beobachtet werden N Messwerte

$$Y_n \;=\; f_n + \sigma Z_n, \qquad n = 0, \dots, N-1, \tag{5.1}$$

mit Gauß'schem weißem Rauschen Z der Varianz 1 und Rauschstärke $\sigma > 0$ [Mal09, Gl. (11.26)]. Anders als in den Kapiteln 3 und 4 ist f hier keine Funktion, sondern der unbekannte Vektor $f \in \mathbb{R}^N$ der Abtastwerte des Signals. Die Messwerte dienen direkt als Startkoeffizienten $a_{0,n}$ von Algorithmus 1 [LMR98, Kap. 3.1.1]. Das Rauschen wird mit Z bezeichnet, da W bereits für die Detailräume vergeben ist.

Definition 5.2 (Schätzer und Risiko, [Mal09, Kap. 1.2.4]). Ein Schätzer ordnet den Messwerten Y einen Vektor $\hat{f} \in \mathbb{R}^N$ zu, der f annähern soll. Sein Risiko ist der erwartete quadratische Fehler

$$r(f) \;:=\; \mathbb{E}\,\|\hat{f} - f\|^2.$$

Für eine einzelne Realisierung des Rauschens heißt $\|\hat{f} - f\|^2$ die Fehlerenergie.

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie die Energie des Rauschens $\|\sigma Z\|^2$, und ihr Erwartungswert ist $r(f) = N\sigma^2$ [Mal09, Kap. 11.1.1].

Die DWT eines endlichen Signals. In Algorithmus 1 ist

$$a_{1,k} \;=\; \sum_{n\in\mathbb{Z}} h_{n-2k}\, a_{0,n},$$

die Summe läuft also formal über alle ganzen Zahlen n. Beim Filter (4.6) sind nur $h_0, \dots, h_3$ von null verschieden; für jedes k bleiben daher nur die vier Summanden mit $n = 2k, \dots, 2k+3$. Ein Messsignal hat aber nur die N Werte $a_{0,0}, \dots, a_{0,N-1}$. Für $N = 8$ ist etwa

$$a_{1,3} \;=\; h_0 a_{0,6} + h_1 a_{0,7} + h_2 a_{0,8} + h_3 a_{0,9},$$

und $a_{0,8}$, $a_{0,9}$ gibt es nicht. Man setzt das Signal daher periodisch fort, $a_{0,8} := a_{0,0}$, $a_{0,9} := a_{0,1}$ [LMR98, Kap. 2.4.7.2]. Das ist der einfachste von drei Wegen, die Mallat beschreibt; die anderen spiegeln das Signal am Rand oder verwenden eigene Randwavelets [Mal09, Kap. 7.3.1, 7.5].

Schreibt man die vier Gleichungen für $a_{1,0}, \dots, a_{1,3}$ untereinander, entsteht eine Matrix $H \in \mathbb{R}^{4\times 8}$ mit $(a_{1,k})_k = H\,(a_{0,n})_n$:

$$H \;=\; \begin{pmatrix} h_0 & h_1 & h_2 & h_3 & 0 & 0 & 0 & 0 \\ 0 & 0 & h_0 & h_1 & h_2 & h_3 & 0 & 0 \\ 0 & 0 & 0 & 0 & h_0 & h_1 & h_2 & h_3 \\ h_2 & h_3 & 0 & 0 & 0 & 0 & h_0 & h_1 \end{pmatrix}.$$

Jede Zeile ist die vorige, um zwei Stellen verschoben; was rechts herausfällt, kommt links wieder hinein. Ebenso liefert eine Matrix $G \in \mathbb{R}^{4\times 8}$ aus den g_k die Details $d_{1,0}, \dots, d_{1,3}$.

Allgemein sei M gerade und $w \in \mathbb{R}^M$ periodisch fortgesetzt, $w_{n+M} := w_n$. Die periodischen Mallat-Transformationen $H_M, G_M \colon \mathbb{R}^M \to \mathbb{R}^{M/2}$ sind

$$(H_M w)_k \;:=\; \sum_{n\in\mathbb{Z}} h_{n-2k}\, w_n, \qquad (G_M w)_k \;:=\; \sum_{n\in\mathbb{Z}} g_{n-2k}\, w_n, \qquad 0 \le k < \tfrac{M}{2}$$

[LMR98, Kap. 3.6.2]; das sind die Formeln aus Algorithmus 1 mit periodisch gelesenen Indizes. Wir setzen $S_M := \binom{H_M}{G_M} \in \mathbb{R}^{M\times M}$; das Beispiel oben ist $H = H_8$.

Lemma 5.3 ([LMR98, Kap. 3.6.2, Gl. (3.6.18)–(3.6.20)]). *Für die Filter h, g aus Kapitel 4 gilt $H_M H_M^\top = G_M G_M^\top = I$, $H_M G_M^\top = 0$ und $H_M^\top H_M + G_M^\top G_M = I$. Die Matrix S_M ist also orthogonal, das heißt $S_M^\top S_M = S_M S_M^\top = I$.*

Der Preis des Periodisierens: Sind Anfang und Ende des Signals verschieden, so verhalten sich die Koeffizienten am Rand, als hätte das Signal dort einen Sprung, und werden groß [Mal09, Kap. 7.5.1].

Die DWT als orthogonale Matrix. Die DWT der Tiefe J wendet S_N auf alle N Werte an und danach jeweils nur auf die zuletzt berechneten Approximationskoeffizienten; die Details bleiben stehen. Da jeder Schritt die Anzahl der Approximationskoeffizienten halbiert, sei N durch 2^J teilbar. Als Matrix ist das

$$A := \begin{pmatrix} S_{N/2^{J-1}} & 0 \\ 0 & I \end{pmatrix} \cdots \begin{pmatrix} S_{N/2} & 0 \\ 0 & I \end{pmatrix} S_N \in \mathbb{R}^{N\times N}, \qquad AY = (a_J, d_J, \ldots, d_1),$$

für $N = 8$, $J = 3$ etwa

$$A = \begin{pmatrix} S_2 & 0 \\ 0 & I_6 \end{pmatrix} \begin{pmatrix} S_4 & 0 \\ 0 & I_4 \end{pmatrix} S_8, \qquad AY = (a_3, d_3, d_2, d_1)$$

mit $1, 1, 2$ und 4 Einträgen. Jeder Faktor ist nach Lemma 5.3 orthogonal, also auch A. Wir bezeichnen die Zeilen von A mit $v_0, \ldots, v_{N-1}$. Sie bilden eine Orthonormalbasis des $\mathbb{R}^N$, und jeder Koeffizient ist ein Skalarprodukt mit einer von ihnen; Mallat nennt sie diskrete Wavelets und Skalierungsfunktionen [Mal09, Kap. 7.5, Gl. (7.173)]. Aus (5.1) wird damit

$$\tilde{Y}_m = \theta_m + \sigma \tilde{Z}_m \qquad \text{mit } \tilde{Y}_m = \langle Y, v_m\rangle,\ \theta_m = \langle f, v_m\rangle,\ \tilde{Z}_m = \langle Z, v_m\rangle, \tag{5.2}$$

kurz $\tilde{Y} = AY$, $\theta = Af$, $\tilde{Z} = AZ$ [Mal09, Kap. 11.2.1].

Was mit dem Rauschen geschieht.

Lemma 5.4 ([Mal09, Kap. 11.2.1–11.2.2]). *$\tilde{Z}$ ist wieder Gauß'sches weißes Rauschen der Varianz 1; die $\tilde{Z}_0, \ldots, \tilde{Z}_{N-1}$ sind also unabhängig und standardnormalverteilt.*

Beweis. Wegen der Linearität des Erwartungswerts ist $\mathbb{E}[\tilde{Z}_m] = \sum_n v_m[n]\,\mathbb{E}[Z_n] = 0$ und

$$\mathbb{E}\big[\tilde{Z}_m \tilde{Z}_p\big] = \sum_{n=0}^{N-1}\sum_{k=0}^{N-1} v_m[n]\, v_p[k]\, \mathbb{E}[Z_n Z_k] = \sum_{n=0}^{N-1} v_m[n]\, v_p[n] = \langle v_m, v_p\rangle = \delta_{m,p}$$

[Mal09, Kap. 11.2.1], da die v_m eine Orthonormalbasis bilden. Die $\tilde{Z}_m$ sind Linearkombinationen der gemeinsam normalverteilten Z_n und damit selbst gemeinsam normalverteilt, vgl. [Mal09, Kap. 11.2.2]; nach Satz 2.4 sind sie also unabhängig. □

Die Transformation verändert also das Signal, die Verteilung des Rauschens aber nicht: Jeder Koeffizient trägt Rauschen derselben Stärke σ, und das Rauschen beeinflusst die Wahl der Basis nicht [Mal09, Kap. 11.2.1].

Beispiel 5.5 (Ein verrauschter Sinus)**.** Als Testsignal dient ein Sinus mit Amplitude 1 und Periode 1, abgetastet an den $N = 2048$ Zeitpunkten $t_n = 8n/N = n/256$ im Intervall $[0, 8)$:

$$u_n := \sin(2\pi t_n), \qquad n = 0, \dots, 2047.$$

Jede Periode umfasst also 256 Abtastwerte, insgesamt sind es acht volle Perioden. Dazu kommt Rauschen der Stärke $\sigma = 0{,}3$: Die Z_n werden als Pseudozufallszahlen erzeugt, und nach (5.1) sind die Messwerte $Y_n = u_n + 0{,}3\, Z_n$ (Abbildung 5.2). Zerlegt wird mit dem Filter (4.6), periodisiert, in $J = 5$ Stufen; gerechnet ist mit PyWavelets [LGW+19] (Code in Anhang B.4).

Ohne jede Bearbeitung, also mit $\hat{f} = Y$, ist die Fehlerenergie gleich der Energie des Rauschens, $\|Y - u\|^2 = 181{,}3$, nahe am Erwartungswert $N\sigma^2 = 2048 \cdot 0{,}09 = 184{,}3$; dieser Wert dient später als Vergleich. Für die 2048 Werte $\tilde{Z}_m$ sind der empirische Mittelwert $\bar{z} = \frac{1}{N}\sum_m \tilde{Z}_m = 0{,}01$ und die empirische Varianz $\frac{1}{N}\sum_m (\tilde{Z}_m - \bar{z})^2 = 0{,}98$, wie nach Lemma 5.4 zu erwarten.

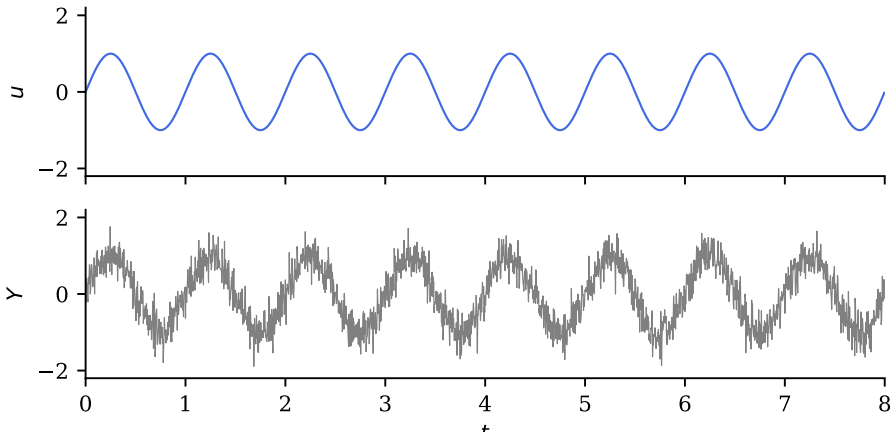


Abbildung 5.2.: Der Sinus u aus Beispiel 5.5 (oben) und die Messwerte $Y = u + 0{,}3\, Z$ (unten), $N = 2048$.

5.2. Diagonale Schätzer und Thresholding

Nach Abschnitt 5.1 bilden die Zeilen $v_0, \dots, v_{N-1}$ von A eine Orthonormalbasis des $\mathbb{R}^N$, und die Koeffizienten der Messwerte in dieser Basis sind $\tilde{Y}_m = \langle Y, v_m \rangle = \theta_m + \sigma \tilde{Z}_m$ nach (5.2). Im mittleren Schritt von Abbildung 5.1 wird jeder dieser Koeffizienten für sich mit einem Faktor λ_m multipliziert, der angibt, wie viel von ihm übrig bleibt: $\lambda_m = 1$ behält ihn, $\lambda_m = 0$ löscht ihn, ein Wert dazwischen verkleinert ihn.

Definition 5.6 (Diagonaler Schätzer, [Mal09, Kap. 11.2.1, Gl. (11.27)])**.** Ein Schätzer heißt diagonal in der Basis $\{v_m\}$, wenn er jeden Koeffizienten mit einem Faktor λ_m multipliziert,

$$\hat{\theta}_m \;=\; \lambda_m \tilde{Y}_m \qquad (m = 0, \dots, N-1),$$

und das Ergebnis mit $A^{-1} = A^\top$ zurücktransformiert: $\hat{f} = A^\top \hat{\theta}$. Dabei darf λ_m von den Messwerten nur über $\tilde{Y}_m$ abhängen, nicht über die übrigen Koeffizienten $\tilde{Y}_k$, $k \neq m$. Hängt kein λ_m von den Messwerten ab, heißt der Schätzer linear.

In den Koeffizienten ist ein diagonaler Schätzer die Multiplikation mit einer Diagonalmatrix,

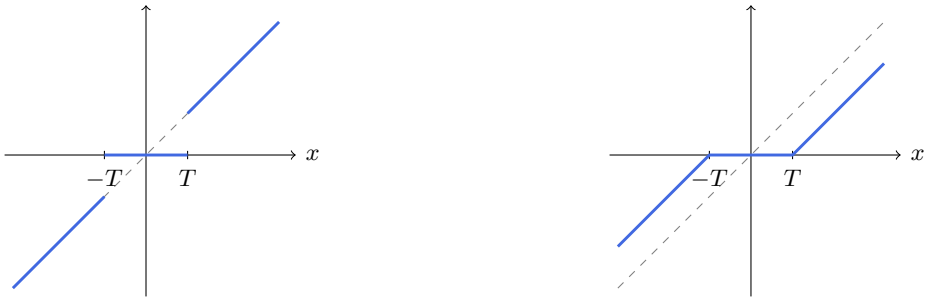
$$\hat{\theta} = \begin{pmatrix} \lambda_0 & 0 & \cdots & 0 \\ 0 & \lambda_1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_{N-1} \end{pmatrix} \tilde{Y}.$$

Die beiden wichtigsten diagonalen Schätzer sind nicht linear: Sie vergleichen $|\tilde{Y}_m|$ mit einer Schwelle $T > 0$, die Faktoren hängen also von $\tilde{Y}_m$ selbst ab [Mal09, Kap. 11.2.2].

Definition 5.7 (Hard- und Soft-Thresholding, [Mal09, Gl. (11.47), (11.49)]). Für $T > 0$ heißen

$$\rho_T^{\mathrm{H}}(x) := \begin{cases} x, & |x| > T, \\ 0, & |x| \leq T, \end{cases} \qquad \rho_T^{\mathrm{S}}(x) := \begin{cases} x - T, & x > T, \\ x + T, & x < -T, \\ 0, & |x| \leq T \end{cases}$$

Hard- bzw. Soft-Thresholding. Der zugehörige Schätzer berechnet mit ρ_T für eine der beiden Funktionen die Koeffizienten $\hat{\theta}_m = \rho_T(\tilde{Y}_m)$ und transformiert zurück: $\hat{f} = A^\top \hat{\theta}$.



(a) Hard-Thresholding (b) Soft-Thresholding

Abbildung 5.3.: Die Funktionen ρ_T^{H} (a) und ρ_T^{S} (b); gestrichelt die Identität.

Beispiel 5.8 (Fortsetzung von Beispiel 4.10). Wir gehen alle drei Schritte für die Messwerte $Y = (4,\ 2,\ 5,\ 7)$ durch, mit dem Haar-Filter, $N = 4$ und $J = 2$.

Schritt 1, Transformieren: Nach Beispiel 4.10 ist $\tilde{Y} = AY = (a_{2,0};\ d_{2,0};\ d_{1,0};\ d_{1,1}) = (9;\ -3;\ \sqrt{2};\ -\sqrt{2})$.

Schritt 2, Thresholding: Mit $T = 2$ vergleicht Hard-Thresholding den Betrag jedes Koeffizienten mit T:

$$|9| > 2, \qquad |-3| > 2, \qquad |\sqrt{2}| \leq 2, \qquad |-\sqrt{2}| \leq 2.$$

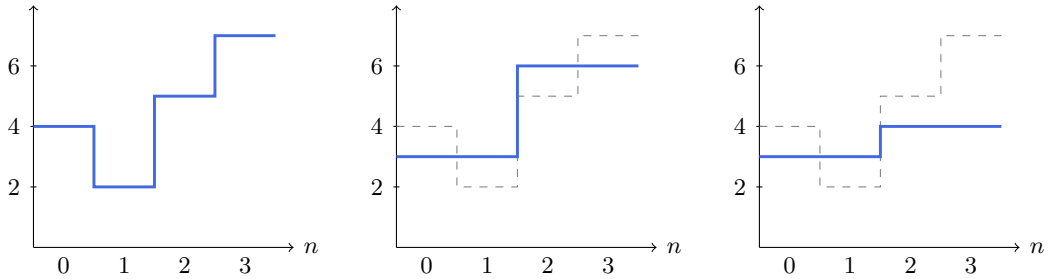
Die Koeffizienten 9 und -3 liegen über der Schwelle und bleiben unverändert, $\lambda_0 = \lambda_1 = 1$. Die beiden feinen Details $\pm\sqrt{2} \approx \pm 1{,}41$ liegen nicht darüber und werden auf null gesetzt, $\lambda_2 = \lambda_3 = 0$. Also ist $\hat{\theta} = (9;\ -3;\ 0;\ 0)$.

Schritt 3, Zurücktransformieren: Mit der Rekonstruktion aus Satz 4.11 ist zunächst $a_1 = \left(\frac{9-3}{\sqrt{2}},\ \frac{9+3}{\sqrt{2}}\right) = (3\sqrt{2},\ 6\sqrt{2})$ und, da beide $d_{1,k}$ null sind,

$$\hat{f} \;=\; A^{\top}\hat{\theta} \;=\; (3,\ 3,\ 6,\ 6).$$

Jedes Paar benachbarter Werte ist durch seinen Mittelwert ersetzt; das Nullsetzen der feinen Details wirkt also wie ein lokales Mitteln.

Soft-Thresholding setzt dieselben Koeffizienten auf null, verkleinert die übrigen aber zusätzlich um T: $\hat{\theta} = (7;\ -1;\ 0;\ 0)$ und damit $\hat{f} = (3,\ 3,\ 4,\ 4)$ (Abbildung 5.4). Dabei verkleinert es auch den Approximationskoeffizienten von 9 auf 7 und senkt so den Mittelwert von $4{,}5$ auf $3{,}5$; darauf kommt Abschnitt 5.4 zurück. In beiden Fällen wird jeder Koeffizient allein anhand seines eigenen Betrags behandelt (Abbildung 5.3).



(a) Messwerte Y (b) Hard-Thresholding (c) Soft-Thresholding

Abbildung 5.4.: Die Messwerte $Y = (4, 2, 5, 7)$ aus Beispiel 5.8 (a) und die Schätzungen $\hat{f} = (3, 3, 6, 6)$ nach Hard-Thresholding (b) und $\hat{f} = (3, 3, 4, 4)$ nach Soft-Thresholding (c), jeweils mit $T = 2$; gestrichelt Y.

Welches Risiko ein diagonaler Schätzer bestenfalls erreicht, lässt sich koeffizientenweise untersuchen: Das Risiko zerfällt in eine Summe von Einzelbeiträgen.

Lemma 5.9 ([Mal09, Gl. (11.28)]). *Für jeden Schätzer der Form $\hat{f} = A^{\top}\hat{\theta}$ gilt*

$$\mathbb{E}\,\|\hat{f} - f\|^2 \;=\; \sum_{m=0}^{N-1} \mathbb{E}\,|\hat{\theta}_m - \theta_m|^2. \tag{5.3}$$

Bei einem diagonalen Schätzer ist $\hat{\theta}_m = \lambda_m \tilde{Y}_m$; der m-te Summand in (5.3) hängt also nur von λ_m ab, und das Risiko wird minimiert, indem man jeden Summanden einzeln minimiert. Bekannt ist dabei nur die Summe $\tilde{Y}_m = \theta_m + \sigma\tilde{Z}_m$, nicht ihre beiden Anteile. Wir betrachten zunächst feste Faktoren $\lambda_m \in \{0, 1\}$, also diagonale Schätzer, die jeden Koeffizienten entweder behalten oder löschen [Mal09, Kap. 11.2.1]:

- Behalten, $\lambda_m = 1$: Das Signal bleibt, aber auch das Rauschen; die Abweichung ist $\hat{\theta}_m - \theta_m = \sigma\tilde{Z}_m$. Da $\tilde{Z}_m$ nach Lemma 5.4 Mittelwert 0 und Varianz 1 hat, ist $\mathbb{E}|\hat{\theta}_m - \theta_m|^2 = \sigma^2\,\mathbb{E}[\tilde{Z}_m^2] = \sigma^2$.
- Löschen, $\lambda_m = 0$: Dann ist $\hat{\theta}_m = 0$. Das Rauschen ist weg, aber ebenso das Signal; die Abweichung ist $-\theta_m$, der Fehler θ_m^2.

Behalten kostet also im Mittel σ^2, Löschen θ_m^2. Behalten ist daher genau dann mindestens so gut wie Löschen, wenn $|\theta_m|$ mindestens so groß wie σ ist: Für $\sigma = 0{,}3$ ist etwa bei $\theta_m = 2$ Behalten besser ($0{,}09$ statt 4), bei $\theta_m = 0{,}1$ Löschen ($0{,}01$ statt $0{,}09$).

Definition 5.10 (Ideale Auswahl, [Mal09, Gl. (11.32)–(11.34)]). Die ideale Auswahl ist der diagonale Schätzer mit den festen Faktoren $\lambda_m = 1$ für $|\theta_m| \geq \sigma$ und $\lambda_m = 0$ sonst.

Nach Lemma 5.9 ist ihr Risiko

$$r_{\mathrm{id}}(f) \;=\; \sum_{m=0}^{N-1} \min\bigl(\theta_m^2,\, \sigma^2\bigr), \tag{5.4}$$

und kein diagonaler Schätzer mit festen Faktoren $\lambda_m \in \{0, 1\}$ hat ein kleineres Risiko.

Da die λ_m der idealen Auswahl vom unbekannten θ_m abhängen, lässt sie sich nicht berechnen; Mallat spricht von einem Orakel [Mal09, Kap. 11.2.1]. Hard-Thresholding ist ihr praktischer Ersatz: Es behält oder löscht ebenfalls jeden Koeffizienten, entscheidet aber nach dem bekannten $|\tilde{Y}_m|$ und der Schwelle T statt nach $|\theta_m|$ und σ. Sein Risiko ist mindestens $r_{\mathrm{id}}(f)$ [Mal09, Kap. 11.2.2]; die ideale Auswahl ist also eine untere Schranke für das, was Hard-Thresholding erreichen kann.

Sind M Koeffizienten mindestens so groß wie σ, so lässt sich das Risiko der idealen Auswahl schreiben als

$$r_{\mathrm{id}}(f) \;=\; \sum_{|\theta_m| < \sigma} \theta_m^2 \;+\; M\sigma^2$$

[Mal09, Gl. (11.36), (11.37)]. Der erste Term ist der Fehler, wenn man f nur durch diese M Koeffizienten darstellt, der zweite das Rauschen auf ihnen. Das Risiko ist also klein, wenn sich f durch wenige Basisvektoren gut darstellen lässt [Mal09, Kap. 11.2.2]. Wir nennen f dann dünnbesetzt in der Basis $\{v_m\}$ [Mal09, Kap. 11.2.1].

Für Wavelets gilt das bei stückweise glatten Signalen: Große Koeffizienten entstehen nur an scharfen Übergängen, und davon gibt es wenige [Mal09, Kap. 11.3.1].

Beispiel 5.11 (Fortsetzung: Sinus mit Spitzen). Wir gehen vom Sinus u aus Beispiel 5.5 aus und setzen drei schmale Spitzen hinzu:

$$s_n := \sum_{c \in \{1{,}3;\ 3{,}7;\ 6{,}2\}} 3 \max\Bigl(0,\ 1 - \frac{|t_n - c|}{0{,}03}\Bigr), \qquad f := u + s,$$

also drei Dreiecke der Höhe 3 und halben Breite $0{,}03$ (Abbildung 5.5). Der Sinus ist glatt, die Spitzen sind scharfe Übergänge an drei Stellen.

Beide Signale transformieren wir wie in Beispiel 5.5: mit dem Filter (4.6), periodisiert, in $J = 5$ Stufen. Das liefert die $N = 2048$ Koeffizienten $\theta = Af = (a_5, d_5, \ldots, d_1)$; jede Stufe halbiert die Anzahl, sodass d_1 aus 1024, d_2 aus 512, …, d_5 aus 64 Koeffizienten besteht und die übrigen 64 die Approximation a_5 bilden. Für jede Stufe zeigt die Tabelle (Code in Anhang B.5):

- Anzahl: wie viele Koeffizienten die Stufe hat;
- größter Betrag (u): den betragsgrößten Koeffizienten des Sinus auf dieser Stufe;

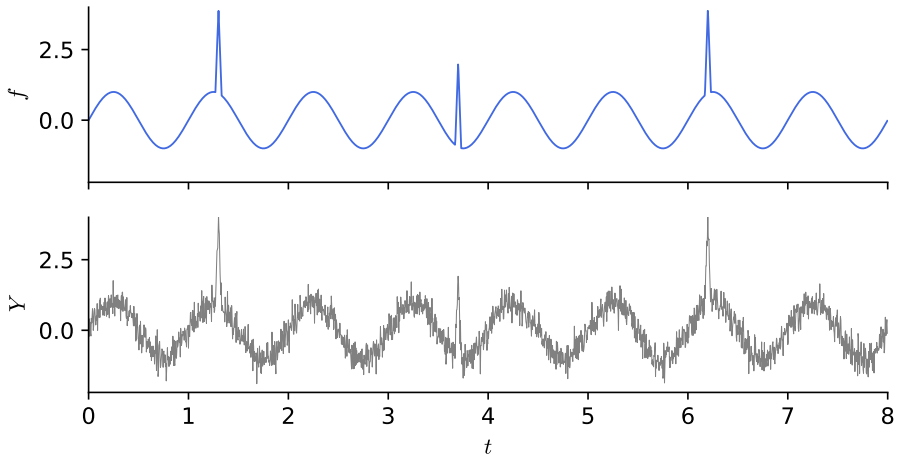


Abbildung 5.5.: Das Testsignal $f = u + s$ aus Beispiel 5.11 (oben) und die Beobachtung $Y = f + 0{,}3\,Z$ (unten), $N = 2048$ (Code in Anhang B.5).

- $\geq \sigma\ (u)$ und $\geq \sigma\ (f)$: wie viele Koeffizienten von u bzw. f betragsmäßig mindestens $\sigma = 0{,}3$ sind. Genau diese behält die ideale Auswahl (Definition 5.10); ihre Summe ist die Zahl M aus dem vorigen Absatz.

Stufe	Anzahl	größter Betrag (u)	$\geq \sigma\ (u)$	$\geq \sigma\ (f)$
a_5	64	5,4	64	64
d_5 (grob)	64	0,36	32	33
d_4	128	0,066	0	8
d_3	256	0,012	0	9
d_2	512	0,0021	0	4
d_1 (fein)	1024	0,00037	0	3
Summe	2048		96	121

Für den Sinus sind nur die 64 Approximationskoeffizienten und 32 Detailkoeffizienten auf Stufe 5 mindestens so groß wie σ, also $M = 96$ von 2048; ab Stufe 4 liegen alle Detailkoeffizienten weit darunter. Der Sinus ist in der Waveletbasis also dünnbesetzt. Zu feineren Stufen hin werden die Detailkoeffizienten des Sinus schnell kleiner, wie nach Lemma 4.15 zu erwarten. Die Spitzen fügen 25 große Koeffizienten hinzu, $M = 121$, fast alle auf den feinen Stufen d_4 bis d_1 und nur in der Nähe der drei Spitzen; in Abbildung 5.6 heben sie sich deutlich von den kleinen Koeffizienten des Sinus ab.

Damit lässt sich das Risiko (5.4) der idealen Auswahl konkret ausrechnen. Beim Sinus behält sie die $M = 96$ Koeffizienten mit $|\theta_m| \geq 0{,}3$; jeder davon kostet $\sigma^2 = 0{,}09$, zusammen $96 \cdot 0{,}09 = 8{,}6$. Die übrigen 1952 Koeffizienten löscht sie; jeder kostet sein Quadrat θ_m^2, und da sie fast alle nahe null liegen, ergibt das zusammen nur 1,1. Insgesamt ist also $r_{\mathrm{id}}(u) = 8{,}6 + 1{,}1 = 9{,}7$. Beim Signal mit Spitzen behält sie $M = 121$ Koeffizienten, das kostet $121 \cdot 0{,}09 = 10{,}9$, und die gelöschten kosten 1,7, also $r_{\mathrm{id}}(f) = 12{,}6$. Ohne Bearbeitung wäre das Risiko $N\sigma^2 = 184{,}3$, also rund fünfzehnmal so groß.

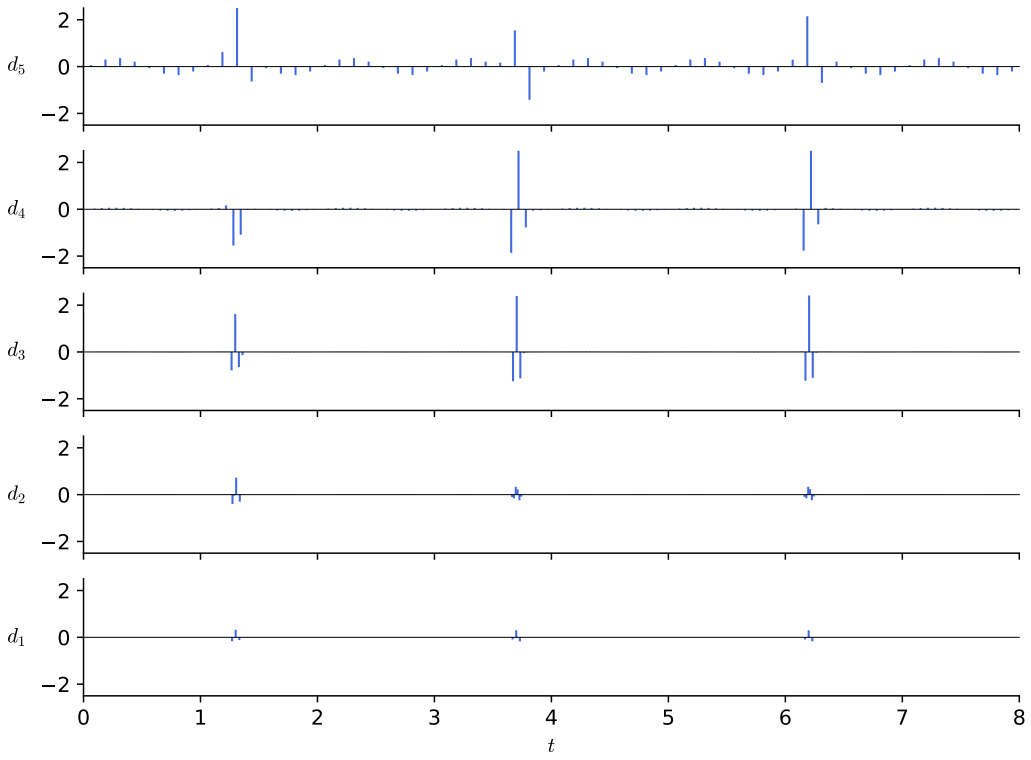


Abbildung 5.6.: Detailkoeffizienten d_5 (oben, grob) bis d_1 (unten, fein) des Testsignals $f = u+s$ aus Beispiel 5.11, aufgetragen über der Zeit t; sehr große Werte abgeschnitten.

5.3. Die Wahl der Schwelle

Die Schwelle T soll das Rauschen entfernen, aber möglichst wenig vom Signal. Ist $f = 0$, so besteht jeder Koeffizient nur aus Rauschen, $\tilde{Y}_m = \sigma\tilde{Z}_m$; damit alle gelöscht werden, muss T größer sein als der größte Rauschanteil $\max_m|\sigma\tilde{Z}_m|$. Ist $f \neq 0$, darf T nicht viel größer sein, sonst gehen auch Koeffizienten mit großem Signalanteil verloren. T soll also knapp über dem größten Rauschanteil liegen [Mal09, Kap. 11.2.2]. Dieses Maximum ist unbekannt. Für N unabhängige Rauschanteile liegt es aber mit hoher Wahrscheinlichkeit knapp unter

$$T \;=\; \sigma\sqrt{2\ln N} \tag{5.5}$$

[Mal09, Gl. (11.64)]. Diese Wahl heißt universelle Schwelle [Mal09, Kap. 11.3.2]. Dass T mit N wächst, liegt an den Ausläufern der Normalverteilung: Unter mehr Werten kommen auch größere vor [Mal09, Kap. 11.2.2].

Satz 5.12 (Donoho–Johnstone, [Mal09, Satz 11.7]). *Für $N \geq 4$ und $T = \sigma\sqrt{2\ln N}$ erfüllt das Risiko des Hard- und des Soft-Thresholding-Schätzers*

$$r(f) \;\leq\; (2\ln N + 1)\big(\sigma^2 + r_{\mathrm{id}}(f)\big). \tag{5.6}$$

Für den Beweis siehe [Mal09, Satz 11.7, Lemma 11.1]. Zusammen mit der unteren Schranke aus Abschnitt 5.2, die Mallat für Hard-Thresholding zeigt, ergibt sich dafür

$$r_{\mathrm{id}}(f) \;\le\; r(f) \;\le\; (2\ln N + 1)\big(\sigma^2 + r_{\mathrm{id}}(f)\big)$$

[Mal09, Kap. 11.2.2]. Bis auf den Faktor $2\ln N + 1$ ist Hard-Thresholding also so gut wie die ideale Auswahl. Die obere Schranke gilt für beide Varianten: Ist f dünnbesetzt und damit $r_{\mathrm{id}}(f)$ klein, so ist auch $r(f)$ klein. Mit diagonalen Schätzern lässt sich dieser Faktor für große N nicht verbessern [Mal09, Gl. (11.52)].

Die Schwelle (5.5) ist allerdings nicht optimal: Eine kleinere Schwelle senkt das Risiko oft, und Soft-Thresholding braucht für ähnliche Ergebnisse wie Hard-Thresholding etwa die halbe Schwelle [Mal09, Kap. 11.2.2].

5.4. Schätzung der Rauschstärke

Die Schwelle enthält das unbekannte σ. Mallat schätzt es aus den $N/2$ Detailkoeffizienten $d_{1,k}$ der feinsten Stufe [Mal09, Kap. 11.3.1]: Wo das Signal auf dem Träger des Wavelets glatt ist, ist sein Koeffizient klein, und $d_{1,k}$ besteht praktisch nur aus Rauschen. Nur an den wenigen scharfen Übergängen ist er groß; diese Werte nennt Mallat Ausreißer. Auch beim gemessenen EKG, das in Kapitel 6 relevant wird, enthält d_1 fast das gesamte Rauschen [LMR98, Kap. 3.1.2].

Der Median von P Zahlen ist der mittlere Wert, wenn man sie der Größe nach ordnet, also der Wert vom Rang $P/2$ [Mal09, Kap. 11.3.1]. Anders als der Mittelwert hängt er nicht davon ab, wie groß die Werte über ihm sind, und wird von wenigen Ausreißern daher kaum verändert. Ist M der Median der Beträge von P unabhängigen normalverteilten Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2, so ist $\mathbb{E}[M] \approx 0{,}6745\,\sigma$ [Mal09, Kap. 11.3.1]. Daraus ergibt sich der Schätzer

$$\hat\sigma \;=\; \frac{\mathrm{Median}\big(|d_{1,k}| : 0 \le k < N/2\big)}{0{,}6745} \tag{5.7}$$

[Mal09, Gl. (11.85)]. Er setzt voraus, dass das Rauschen in allen Koeffizienten dieselbe Stärke hat, was nach Lemma 5.4 für weißes Rauschen zutrifft. Ist das Rauschen nicht weiß, hängt seine Varianz vom Basisvektor ab, und die Schwelle muss mit dem Koeffizienten variieren [Mal09, Kap. 11.2.2]; darauf kommt Kapitel 6 zurück.

Anmerkung. Kap. 6 greift farbiges Rauschen bisher nicht auf – ergänzen oder Verweis streichen.

Das vollständige Verfahren. Mallat schwellt alle Koeffizienten der Waveletbasis, auch die der gröbsten Approximation [Mal09, Gl. (11.84)], und bestimmt σ mit (5.7) [Mal09, Kap. 11.3.1]. Zusammen ergibt sich:

Algorithmus 2 Entrauschen mit universeller Schwelle nach [Mal09, Kap. 11.2–11.3]

Eingabe: Messwerte $Y \in \mathbb{R}^N$, Filter h, g, Tiefe J mit $2^J \mid N$

1: $(a_J, d_J, \ldots, d_1) \leftarrow AY$ ▷ Algorithmus 1, periodisiert
2: $T \leftarrow \hat\sigma\sqrt{2\ln N}$ mit $\hat\sigma$ aus (5.7)
3: ersetze jeden Koeffizienten c von $a_J, d_J, \ldots, d_1$ durch $\rho_T(c)$
4: **Rückgabe** $\hat f \leftarrow A^\top$(geschwellte Koeffizienten) ▷ Satz 4.11

Satz 5.12 setzt das wahre σ voraus; mit dem geschätzten $\hat{\sigma}$ ist die Schranke (5.6) nur ein Anhaltspunkt. Ferner werden in Zeile 3 auch die Approximationskoeffizienten a_J geschwellt. Sie tragen den glatten, groben Anteil des Signals und sind meist groß; Soft-Thresholding verkleinert jeden von ihnen um T und verschiebt so den glatten Anteil, wie schon in Beispiel 5.8 den Mittelwert. In seinem Beispiel zur Bildentrauschung schwellt Mallat die Skalierungskoeffizienten deshalb nicht [Mal09, Kap. 11.3.2].

Beispiel 5.13 (Fortsetzung: Entrauschen des Testsignals)**.** Wir entrauschen jetzt die Messwerte $Y = f + 0{,}3\,Z$ aus Beispiel 5.11.

Zuerst wird die Schwelle bestimmt. Der Schätzer (5.7) liefert $\hat{\sigma} = 0{,}300$, trifft das wahre $\sigma = 0{,}3$ also sehr genau. Damit ist $T = \hat{\sigma}\sqrt{2 \ln N} = 1{,}17$.

Abbildung 5.7 zeigt, was diese Schwelle trennt. Das Rauschen bleibt auf allen Stufen zwischen den gestrichelten Linien: Kein einziger Rauschkoeffizient erreicht T, der größte hat den Betrag $1{,}02$. Darüber ragen nur die Koeffizienten an den drei Spitzen hinaus. Hard-Thresholding behält deshalb nur 75 der 2048 Koeffizienten.

Anmerkung. kein einziger rauschkoeff fühlt sich falsch an??

Das Ergebnis zeigt Abbildung 5.8. Mit Hard-Thresholding sinkt die Fehlerenergie von $181{,}3$ auf $27{,}6$, also auf etwa ein Siebtel, und die Spitzen bleiben weitgehend erhalten. Soft-Thresholding mit derselben Schwelle erreicht nur $127{,}1$ und macht die Spitzen deutlich niedriger. Der Grund ist, dass Soft-Thresholding auch jeden behaltenen Koeffizienten um T verkleinert. Das betrifft vor allem die 64 Approximationskoeffizienten, die alle größer als T sind und den glatten Sinus tragen.

Anmerkung. vll wäre es noch schön das alte verrauschte signal einzubauen...

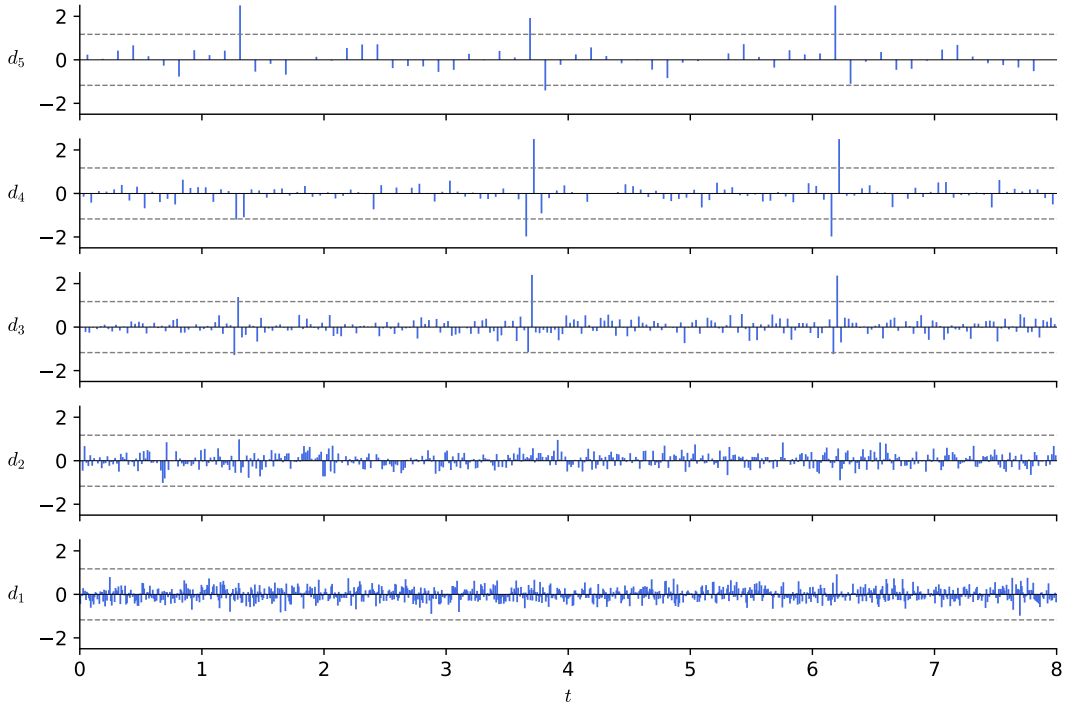


Abbildung 5.7.: Detailkoeffizienten d_5 (oben) bis d_1 (unten) der Messwerte $Y = f + 0{,}3\,Z$ aus Beispiel 5.13, im selben Maßstab wie Abbildung 5.6; gestrichelt die Schwelle $\pm T = \pm 1{,}17$.

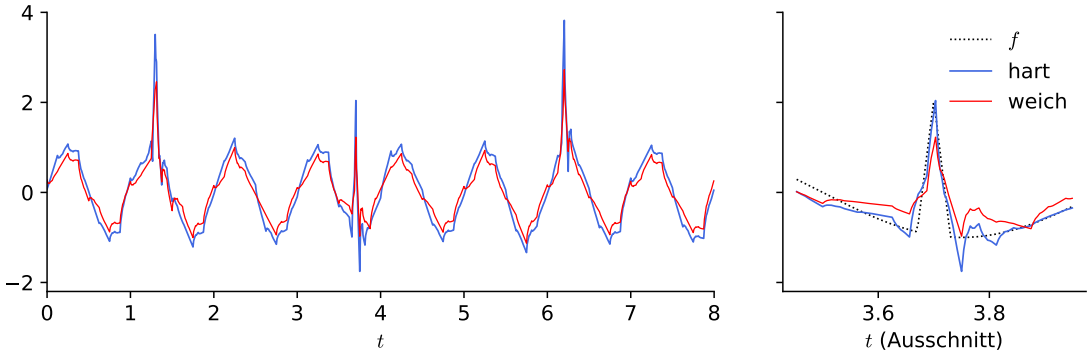


Abbildung 5.8.: Schätzungen aus Y mit Algorithmus 2, $T = 1{,}17$ (links), und Ausschnitt um die mittlere Spitze mit dem wahren Signal f (rechts)(Code in Anhang B.8).

6. Anwendung: Entrauschung von EKG-Signalen

In diesem Kapitel wird das Thresholding aus Kapitel 5 auf reale EKG-Aufzeichnungen der MIT-BIH Arrhythmia Database angewandt. Ziel ist, die Störungen zu entfernen, die in diesen Aufzeichnungen bereits enthalten sind. Wir folgen dabei Castillo et al. [CMG+13] und Alessio [Ale16, Kap. 15.2.4], die beide EKG-Signale mit der DWT von Drift und Rauschen befreien; Alessio stellt dort das Verfahren von Castillo et al. als Beispiel dar. Ein ungestörtes Vergleichssignal gibt es für reale Aufzeichnungen nicht; wir testen das Verfahren deshalb zuerst an einem künstlichen EKG, bei dem es bekannt ist, und beurteilen die realen Aufzeichnungen nach Augenschein.

6.1. EKG-Signale und ihre Störquellen

Ein EKG-Signal ist die Differenz elektrischer Potentiale an zwei Punkten des Körpers, die durch die Erregung des Herzmuskels entsteht [Gac12, Kap. 2.2]. Jeder Herzschlag erzeugt dieselbe Folge von Ausschlägen (Abbildung 6.1): die P-Welle bei der Erregung der Vorhöfe, den QRS-Komplex bei der Erregung der Kammern und die T-Welle bei deren Repolarisation [Gac12, Abb. 2.1], [Reb21, Kap. 2.1].

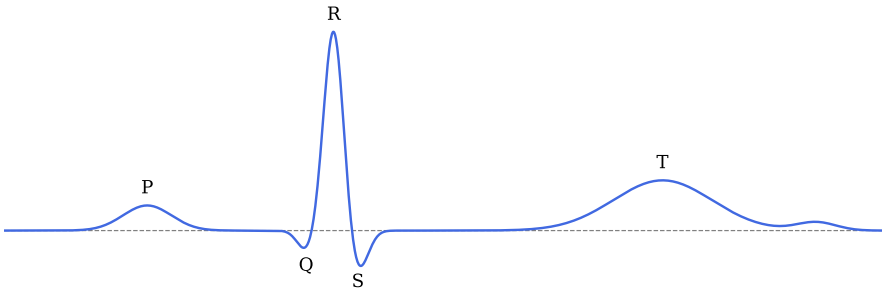


Abbildung 6.1.: Schematischer Herzschlag mit P-, Q-, R-, S- und T-Welle in Anlehnung an [Reb21, Abb. 2.2]; Amplituden und Dauern frei gewählt (Code in Anhang B.9).

Ein gemessenes EKG enthält neben dem Signal des Herzens Störungen [CMG+13, Abschn. 1]; Tabelle 6.1 fasst die wichtigsten zusammen. Wir nehmen an, dass sie sich zum EKG addieren. Rebstadt beschreibt die Artefakte als additive Funktionen im gestörten Signal [Reb21, Kap. 2.3.1], und auch Alessio und Castillo et al. gehen von additivem Rauschen aus [Ale16, Kap. 15.2.1], [CMG+13, Abschn. 2.2.2, Gl. (8)].

Größen wie die Höhe einer Zacke werden gegenüber der isoelektrischen Linie gemessen, der Nulllinie des EKG; sie wird in den meisten Rhythmen am besten durch die PQ-Strecke zwischen

Störung	Ursache	Frequenzen
Basisliniendrift	Atmung, Bewegung, Elektrodenkontakt	meist < 1 Hz
Elektrodenbewegung	Impedanzänderung der Haut	1–10 Hz
Netzbrummen	Erdung, Geräte in der Nähe	50 oder 60 Hz
Muskelrauschen	Aktivität der Skelettmuskeln	etwa 20–80 Hz
weißes Rauschen	Kanalübertragung, Messgeräte	alle

Tabelle 6.1.: Störungen im EKG nach [SL05, Kap. 6.5], [Gac12, Kap. 2.3, 2.4.3] und [Reb21, Kap. 2.1]; Zusammenstellung eigen.

P-Welle und QRS-Komplex dargestellt [SL05, Kap. 7.1.3]. Solange Drift vorhanden ist, ist diese Linie nicht bestimmt, und damit lassen sich auch die Größen nicht bestimmen, die gegen sie gemessen werden [SL05, Kap. 6.5]; deshalb muss die Drift entfernt werden. Elektrodenbewegung und Muskelrauschen überlappen mit dem EKG: Elektrodenartefakte werden manchmal für QRS-Komplexe gehalten, und Muskelrauschen lässt sich nur schwer entfernen, ohne das EKG zu verzerren [SL05, Kap. 6.5]. Das weiße Rauschen σZ dagegen verteilt sich auf alle Frequenzen; für dieses Rauschen ist das Thresholding aus Kapitel 5 gedacht (Abschnitt 6.4.1).

6.2. Die Datensätze

Die MIT-BIH Arrhythmia Database ist eine der meistgenutzten Datenbanken zur Bewertung von Verfahren für Herzrhythmusstörungen [SL05, Kap. 1.4.1]. Sie enthält 48 halbstündige Ausschnitte zweikanaliger Langzeit-EKG von 47 Personen, aufgezeichnet zwischen 1975 und 1979 am Beth Israel Hospital in Boston [MM01, Abschn. Selection of Data], und ist über PhysioNet frei zugänglich [MM05]. Die Aufzeichnungen entstanden im Alltag, etwa beim Arbeiten und Essen [SL05, Kap. 1.4.1].

Aufzeichnung und Digitalisierung. Vor der Digitalisierung wurden die Signale auf 0,1 bis 100 Hz bandbegrenzt [MM01, Abschn. Technical Limitations of the Data]; das heißt, Anteile mit Frequenzen außerhalb dieses Bereichs wurden durch ein Filter weitgehend entfernt. In der Zeit wurde mit $f_s = 360$ Hz abgetastet [MM01, Abschn. Digitization]; alle $1/360\,\mathrm{s} \approx 2{,}8$ ms wurde also ein Wert gespeichert. Welche Frequenzen sich damit darstellen lassen, behandelt Abschnitt 6.3.

Zu den Störquellen aus Tabelle 6.1 kommt eine technische hinzu: Die Bandgeräte, mit denen die Langzeit-EKG aufgezeichnet und später abgespielt wurden, erzeugen durch ihre Mechanik langsame Störungen mit Frequenzen zwischen 0,042 und 0,54 Hz [MM97, Abschn. Introduction, Analog recording and playback]. Das Netzbrummen aus Tabelle 6.1 liegt bei diesen Daten bei 60 Hz und entstand größtenteils erst beim Abspielen [MM01, Abschn. Technical Limitations of the Data].

Annotationen. Zu jeder Aufzeichnung gehört eine Annotationsdatei: Zwei Kardiologen haben unabhängig voneinander jeden Herzschlag geprüft und beschriftet [MM01, Abschn. Annotation], im Allgemeinen am Maximum der R-Zacke [MM97, Abschn. Introduction, Annotations]. Aus

diesen Markierungen bestimmen wir in Abschnitt 6.4.2 die Herzfrequenz. Außerdem kennzeichnen die Annotationen Abschnitte mit starkem Rauschen [MM01, Abschn. Annotation].

Datensätze 100 und 103. Zwischen welchen zwei Punkten des Körpers ein EKG-Signal die Spannung misst (Abschnitt 6.1), legt die *Ableitung* fest; die Ableitung II misst sie zwischen rechtem Arm und linkem Bein [Reb21, Kap. 2.1, Tab. 2.1]. Wir verwenden die Datensätze 100 und 103, jeweils das obere der beiden Signale. Es ist die modifizierte Ableitung II (MLII), bei der die Elektroden auf dem Brustkorb statt an den Extremitäten sitzen [MM97, Abschn. ECG lead configuration; Records]. Beide zeigen über die gesamte Dauer einen normalen Sinusrhythmus [MM97, Abschn. Records], also Schläge der Form aus Abbildung 6.1 [Reb21, Kap. 2.1, Abb. 2.2]. Bei Datensatz 100 ist kein Abschnitt des oberen Signals als stark verrauscht markiert, bei Datensatz 103 ein Abschnitt von etwa $9\,\mathrm{s}$ [MM97, Abschn. Records]; nach der Annotationsdatei liegt er zwischen $1089{,}8$ und $1098{,}4\,\mathrm{s}$ (Code in Anhang B.9).

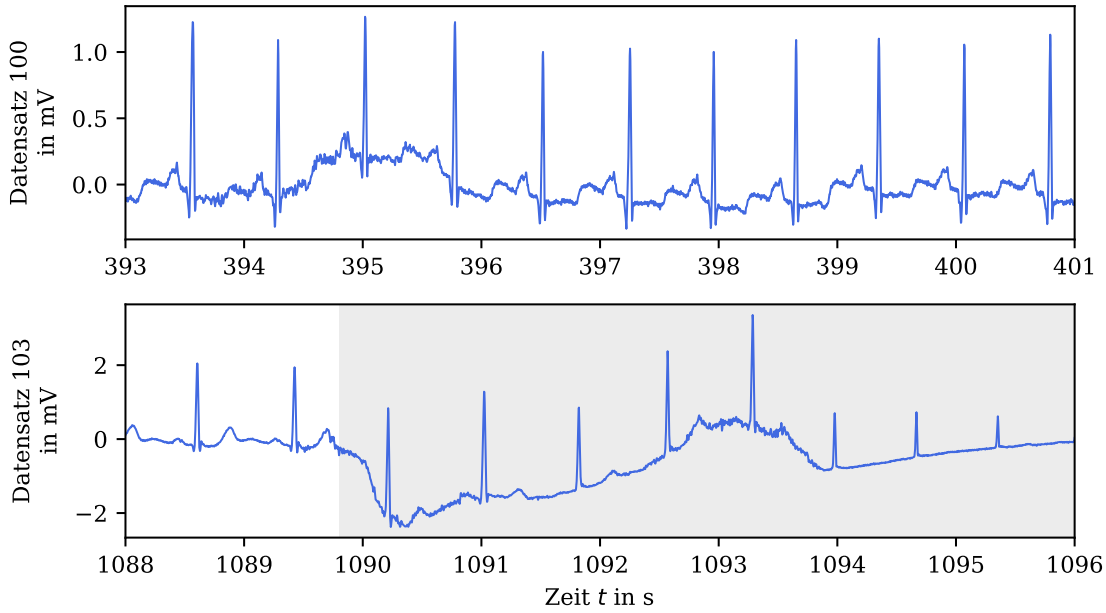


Abbildung 6.2.: Je ein Ausschnitt von $8\,\mathrm{s}$ aus den Datensätzen 100 (oben, ab $393\,\mathrm{s}$) und 103 (unten, ab $1088\,\mathrm{s}$), oberes Signal MLII. Grau hinterlegt der Abschnitt, in dem das obere Signal von Datensatz 103 als stark verrauscht annotiert ist (Code in Anhang B.9).

Abbildung 6.2 zeigt je einen Ausschnitt von $8\,\mathrm{s}$. Gestört sind beide Aufzeichnungen, auch außerhalb der als verrauscht markierten Abschnitte. In beiden Datensätzen ist die Basisliniendrift die auffälligste Störung. Bei Datensatz 100 schwankt die Nulllinie innerhalb weniger Sekunden um etwa $0{,}4\,\mathrm{mV}$. Bei Datensatz 103 fällt die Nulllinie zu Beginn des verrauschten Abschnitts innerhalb von etwa einer Sekunde um rund $2\,\mathrm{mV}$ und steigt danach langsam wieder an.

Länge. Wir transformieren jede Aufzeichnung als Ganzes. Das ist möglich, weil Langzeit-EKG erst ausgewertet werden, nachdem die Aufzeichnung abgeschlossen ist [SL05, Kap. 6.6.3]; das Verfahren muss also nicht schon während der Messung arbeiten. Damit die periodisierte DWT der Tiefe J definiert ist, muss 2^J die Länge N teilen (Abschnitt 5.1); wir verwenden die ersten $N = 2^{19} = 524\,288$ Abtastwerte, also $N/f_s = 524\,288/(360\,\mathrm{Hz}) \approx 1456\,\mathrm{s}$, das sind 24 min 16 s.

6.3. Skalen als Frequenzbänder

Um zu entscheiden, welche Stufen der DWT gelöscht, geschwellt oder unverändert gelassen werden, ordnen wir jeder Stufe ein Frequenzband zu. Castillo et al. wählen so die Tiefe für die Drift und die Zahl der geschwellten Stufen [CMG+13, Abschn. 3.1.2, 3.1.3].

Höchste Frequenz. Die Frequenzbänder der Stufen entstehen, indem das Band des Signals von oben her fortlaufend halbiert wird. Dazu brauchen wir seine obere Grenze. Nach dem Abtasttheorem von Shannon (vgl. [Bla03, Kap. 2.4, Satz (2.16)]) ist ein mit der Rate f_s abgetastetes Signal nur bis zur Frequenz

$$F_{\max} = \frac{f_s}{2}$$

eindeutig darstellbar [CMG+13, Abschn. 3.1.2]; eine Schwingung der Frequenz $f > F_{\max}$ hat an den Abtastzeiten n/f_s dieselben Werte wie eine der Frequenz $f_s - f < F_{\max}$. In der Variablen $\omega = 2\pi f/f_s$ der Filter aus Kapitel 4 entspricht $[0, F_{\max}]$ dem Intervall $[0, \pi]$. Damit liegt das gesamte Signal Y im Band $[0, F_{\max}]$; dieses Band verteilt die DWT im Folgenden auf die Stufen.

Halbierung des Bandes. Die Fourier-Filter

$$H(\omega) = \frac{1}{\sqrt{2}} \sum_k h_k e^{-ik\omega}, \qquad G(\omega) = \frac{1}{\sqrt{2}} \sum_k g_k e^{-ik\omega}$$

aus (4.2) und (4.9) sind nach Abschnitt 4.3 ein Tief- und ein Hochpass: $|H|$ ist auf $[0, \pi/2]$ groß und auf $[\pi/2, \pi]$ klein, $|G|$ umgekehrt (Abbildung 4.1).

Anmerkung. Abbildung 4.1 zeigt nur Haar und db2, nicht das hier verwendete ψ_6. Empfehlung: beim Beispiel 4.17 in Kapitel 4 eine Teilabbildung mit $|H|$ und $|G|$ für ψ_6 ergänzen und hier darauf verweisen. Werte zum Vergleich: $|H(\pi/4)| = 0{,}924$ / $0{,}971$ / $0{,}999$ und $|H(3\pi/4)| = 0{,}383$ / $0{,}241$ / $0{,}048$ für Haar / db2 / db6.

Eine Stufe der DWT wendet nach (4.11) beide auf a_{i-1} an und behält jeden zweiten Wert: a_i entsteht durch den Tiefpass und erhält die untere Hälfte des Bandes von a_{i-1}, d_i entsteht durch den Hochpass und erhält die obere [CMG+13, Abschn. 3.1.2]. Mit $a_0 = Y$ und dem Band $[0, F_{\max}]$ von Y folgt

$$a_i \leftrightarrow \left[0, \frac{F_{\max}}{2^i}\right], \qquad d_i \leftrightarrow \left[\frac{F_{\max}}{2^i}, \frac{F_{\max}}{2^{i-1}}\right] \tag{6.1}$$

[Reb21, Kap. 2.3.2, Tab. 2.4]. Bei Castillo et al. ist $f_s = 250\,\mathrm{Hz}$, also $F_{\max} = 125\,\mathrm{Hz}$, und a_7 erfasst 0 bis $125/2^7 \approx 0{,}977\,\mathrm{Hz}$ [CMG+13, Abschn. 3.1.2]. Die Zuordnung ist nicht scharf, da $|H|$ und $|G|$ nicht sprunghaft von 1 auf 0 fallen. Wegen $|H|^2 + |G|^2 = 1$ (Abschnitt 4.3)

und $|G(\pi/2)| = |H(\pi/2)|$ nach (4.9) gilt an der Grenze $|H(\pi/2)| = |G(\pi/2)| = 1/\sqrt{2}$: Eine Frequenz genau auf einer Bandgrenze verteilt ihre Energie je zur Hälfte auf beide benachbarten Stufen, Frequenzen nahe der Grenze auf beide.

Unsere Daten. Die Tiefe J ist die Anzahl der Stufen. Sie ist eine positive ganze Zahl mit $J \le \log_2 N$ [CMG+13, Abschn. 3.1.2], bei uns also $J \le \log_2 2^{19} = 19$; wir verwenden $J = 8$ (Abschnitt 6.4.2). Mit $F_{\max} = 360\,\mathrm{Hz}/2 = 180\,\mathrm{Hz}$ ergibt (6.1) Tabelle 6.2.

	d_1	d_2	d_3	d_4	d_5	d_6	d_7	d_8	a_8
von (Hz)	90	45	22,5	11,3	5,6	2,8	1,4	0,70	0
bis (Hz)	180	90	45	22,5	11,3	5,6	2,8	1,4	0,70
P- und T-Welle				(•)	•	•	•	•	
Herzfrequenz								•	
Basisliniendrift								(•)	•
Bandmechanik									•
Elektrodenbewegung					(•)	•	•	(•)	
Netzbrummen (60 Hz)		•							
Muskelrauschen		•	•	(•)					

Tabelle 6.2.: Frequenzbänder der Koeffizienten nach (6.1) für $f_s = 360\,\mathrm{Hz}$ und $J = 8$. Darunter die Bänder von: P- und T-Welle, 1 bis 20 Hz [Reb21, Kap. 2.3.1]; Herzfrequenz, über 0,88 Hz (Abschnitt 6.4.2); Drift, Elektrodenbewegung, Netzbrummen und Muskelrauschen nach Tabelle 6.1; Bandmechanik, 0,042 bis 0,54 Hz (Abschnitt 6.2). Die Zuordnung zu den Stufen ist eigen; in Klammern Stufen, die nur am Rand getroffen werden.

Bis auf σZ liegen alle Störungen aus Tabelle 6.1 in begrenzten Frequenzbändern und damit nach (6.1) näherungsweise nur in einigen Stufen; σZ liegt in allen Stufen und fehlt deshalb in Tabelle 6.2. Welche Stufen gelöscht, geschwellt oder unverändert gelassen werden, legen wir in Abschnitt 6.4 fest.

6.4. Das Verfahren

Wir übernehmen das Ein-Schritt-Verfahren von Castillo et al., das Drift und Rauschen mit einer einzigen Zerlegung und Rekonstruktion entfernt [CMG+13, Abschn. 3]. Abschnitt 6.4.1 definiert das Verfahren, die folgenden Abschnitte wählen seine Parameter.

6.4.1. Modell und Ein-Schritt-Verfahren

Castillo et al. und Alessio gehen für das Rauschen vom Modell (5.1) aus, $Y_n = f_n + \sigma Z_n$ [CMG+13, Abschn. 2.2.2, Gl. (8)], [Ale16, Kap. 15.2.1], und behandeln die Basisliniendrift getrennt davon [CMG+13, Abschn. 2.2.1]. Wir fassen beides in einer Gleichung zusammen; diese Schreibweise ist eigen:

$$Y_n = f_n + b_n + \sigma Z_n, \qquad n = 0, \dots, N-1. \tag{6.2}$$

Dabei ist $f \in \mathbb{R}^N$ das EKG, $b \in \mathbb{R}^N$ die Basisliniendrift und $\sigma Z \in \mathbb{R}^N$ wie in (5.1) Gauß'sches weißes Rauschen. Elektrodenbewegung, Netzbrummen und Muskelrauschen aus Tabelle 6.1 sind darin nicht enthalten. Es bezeichne A die periodisierte DWT der Tiefe J aus Abschnitt 5.1 mit dem Filter (4.13) des Wavelets ψ_6 (Beispiel 4.17). AY ist die Zerlegung des Signals in die Stufen, also die Approximation a_J und die Details $d_J, \dots, d_1$:

$$AY = (a_J, d_J, d_{J-1}, \dots, d_1) \in \mathbb{R}^N, \qquad a_J \in \mathbb{R}^{N/2^J},\ d_j \in \mathbb{R}^{N/2^j}.$$

Bemerkung 6.1 (Wahl des Wavelets). Castillo et al. wählen das Wavelet nach seiner Ähnlichkeit mit dem QRS-Komplex und nehmen db6, also ψ_6 aus Satz 4.16 mit $p = 6$ verschwindenden Momenten, weil es einem echten EKG ähnelt [CMG+13, Abschn. 3.1.1]. Allgemein soll das Wavelet die Form der Merkmale haben, die erhalten bleiben sollen [Ale16, Kap. 15.2.1]. In ihrem Vergleich von zwölf Wavelets an synthetischen EKG finden Castillo et al. zwischen den Wavelets keine großen Unterschiede [CMG+13, Abschn. 4, Tab. 2].

Da $A\colon \mathbb{R}^N \to \mathbb{R}^N$ linear ist, folgt aus (6.2)

$$AY = Af + Ab + \sigma AZ. \tag{6.3}$$

Nach Lemma 5.4 hat jeder Koeffizient von σAZ die Varianz σ^2, gleich in welcher Stufe er liegt; Ab liegt bei geeigneter Wahl von J nach (6.1) näherungsweise nur in a_J, für $J = 8$ nach Tabelle 6.2 in a_8 und am Rand von d_8.

Castillo et al. gehen in vier Schritten vor [CMG+13, Abschn. 3]; sie schreiben dabei L für unser J und M für unser J_S:

1. Y bis zur Tiefe J zerlegen,
2. a_J durch den Nullvektor ersetzen,
3. die Details $d_1, \dots, d_{J_S}$ schwellen, $J_S < J$,
4. aus dem Nullvektor, den unveränderten $d_{J_S+1}, \dots, d_J$ und den geschwellten $d_1, \dots, d_{J_S}$ rekonstruieren.

Als Formel:

Definition 6.2 (Ein-Schritt-Verfahren). Zu Tiefen $1 \le J_S < J$ und einer Schwelle $T > 0$ sei

$$\hat{f} = A^\top\big(0,\ d_J, \dots, d_{J_S+1},\ \rho_T^{\mathrm{S}}(d_{J_S}), \dots, \rho_T^{\mathrm{S}}(d_1)\big), \tag{6.4}$$

wobei das Soft-Thresholding ρ_T^{S} aus Definition 5.7 komponentenweise angewandt wird.

Da A orthogonal ist, ist $A^\top = A^{-1}$ die Rekonstruktion (Abschnitt 5.1); ohne Änderung der Koeffizienten wäre $A^\top(AY) = Y$.

Soft- statt Hard-Thresholding verwenden wir wie Castillo et al., weil Hard-Thresholding Unstetigkeiten erzeugt, Soft-Thresholding nicht [CMG+13, Abschn. 3.1.6]; auch Alessio schwellt weich [Ale16, Kap. 15.2.1]. Hard-Thresholding rechnen wir in Abschnitt 6.5 zum Vergleich mit. Gegenüber Algorithmus 2 ändern sich zwei Dinge: a_J wird nicht geschwellt, sondern gelöscht, und die gröberen Details bleiben unverändert.

Zu wählen sind noch die Tiefen J und J_S und die Schwelle T.

6.4.2. Tiefe J für die Drift

Da a_J gelöscht wird, soll es die Drift enthalten, aber keinen Anteil des EKG. Nach (6.1) erfasst a_J die Frequenzen $[0, F_{\max}/2^J]$. Die tiefste Frequenz des EKG ist die langsamste Herzfrequenz [SL05, Kap. 7.1]; die Grenze muss also zwischen Drift und Herzfrequenz liegen:

$$f_{\text{Drift}} \;<\; \frac{F_{\max}}{2^J} \;<\; f_{\text{Herz}}. \tag{6.5}$$

Castillo et al. und Alessio wählen dazu eine Grenze f_c, setzen $F_{\max}/2^J \approx f_c$ und erhalten

$$J_{BW} = \operatorname{int}\Big[\log_2\Big(\frac{F_{\max}}{f_c}\Big)\Big], \tag{6.6}$$

wobei int auf die nächste ganze Zahl rundet [CMG+13, Abschn. 3.1.2, Gl. (9)], [Ale16, Kap. 15.2.4]. Bei Castillo et al. ist $F_{\max} = 125\,\text{Hz}$ und $f_c = 1\,\text{Hz}$, also $J_{BW} = 7$, und a_7 erfasst 0 bis $0{,}977\,\text{Hz}$.

Unsere Daten. Die Basisliniendrift entsteht meist durch die Atmung und liegt dann bei $0{,}15$ bis $0{,}3\,\text{Hz}$ [CMG+13, Abschn. 2.2.1]. Nach den Annotationen liegt die Herzfrequenz im Mittel bei 75 bzw. 70 Schlägen pro Minute und für keinen Schlag unter 53 pro Minute, also $f_{\text{Herz}} > 53/60\,\text{Hz} \approx 0{,}88\,\text{Hz}$ (Code in Anhang B.9). Mit $F_{\max} = 180\,\text{Hz}$ gilt:

- $f_c = 1\,\text{Hz}$ wie bei Castillo et al. ergibt $J = \operatorname{int}[\log_2 180] = \operatorname{int}[7{,}49] = 7$ und die Grenze $180/2^7 = 1{,}41\,\text{Hz} > 0{,}88\,\text{Hz}$. Die rechte Ungleichung in (6.5) ist verletzt; a_7 enthielte Anteile des EKG.
- Sörnmo und Laguna empfehlen eine Grenze etwas unter der langsamsten Herzfrequenz, etwa $f_c = 0{,}5\,\text{Hz}$, und warnen, dass bei zu hoher Grenze eine mit der Herzfrequenz schwingende Störung entsteht [SL05, Kap. 7.1]. Das ergibt

  $$J = \operatorname{int}[\log_2 360] = 8 \quad (\log_2 360 \approx 8{,}49), \qquad 0{,}3\,\text{Hz} \;<\; \frac{180}{2^8}\,\text{Hz} \approx 0{,}70\,\text{Hz} \;<\; 0{,}88\,\text{Hz},$$

  (6.5) ist also erfüllt.

Es kommt dabei nicht genau auf $0{,}5\,\text{Hz}$ an: Für jedes $f_c \in [0{,}50;\, 0{,}99]\,\text{Hz}$ ist $\log_2(180/f_c) \in [7{,}5;\, 8{,}5]$, also $J = 8$. Die Grenze darf aber nicht zu knapp über der Drift liegen: Bei Castillo et al. ist für alle drei Abtastraten die Stufe mit der Grenze $F_{\max}/2^L \approx 0{,}98\,\text{Hz}$ am besten [CMG+13, Abschn. 4, Tab. 1]; die nächsttiefere mit $0{,}49\,\text{Hz}$ entfernt Drift bis $0{,}31\,\text{Hz}$ meist deutlich schlechter. Die Grenzfrequenzen sind aus $F_{\max}/2^L$ berechnet. Unsere Grenze $0{,}70\,\text{Hz}$ liegt mehr als doppelt so hoch wie die Drift. In Abschnitt 6.5 vergleichen wir $J = 7, 8, 9$ am Test-EKG.

6.4.3. Anzahl J_S der geschwellten Stufen

J_S legt fest, wie viele der feinsten Stufen geschwellt werden: d_1 bis d_{J_S} werden geschwellt, d_{J_S+1} bis d_J bleiben unverändert. Nach Lemma 5.4 hat jeder Koeffizient von σAZ den Erwartungswert 0 und die Varianz σ^2. Die erwartete Energie des Rauschens ist damit

$$\mathbb{E}\,\|\sigma AZ\|^2 = \sum_{m=0}^{N-1} \mathbb{E}\big[(\sigma AZ)_m^2\big] = \sigma^2 N,$$

und auf d_j mit

Anmerkung. normen konventinnen überarbeiten hier euklidisch aber in 3 ist ja L2..

$N/2^j$ Koeffizienten entfällt der Teil $\sigma^2 N/2^j$. In den unveränderten Stufen d_{J_S+1} bis d_J bleibt damit im Mittel der Anteil

$$\begin{aligned}\frac{1}{\sigma^2 N}\sum_{j=J_S+1}^{J}\sigma^2\frac{N}{2^j} &= \sum_{j=J_S+1}^{J}2^{-j} = 2^{-J_S}\sum_{k=1}^{J-J_S}2^{-k}\\ &= 2^{-J_S}\left(1-2^{-(J-J_S)}\right) = 2^{-J_S}-2^{-J}\end{aligned}$$

der Rauschenergie erhalten. Dabei wurde $j = J_S + k$ gesetzt und die geometrische Summe $\sum_{k=1}^{n} 2^{-k} = 1 - 2^{-n}$ verwendet. Ein größeres J_S entfernt also mehr Rauschen, schwellt aber auch Stufen, in denen das EKG liegt.

Castillo et al. schwellen bei $f_s = 500\,\mathrm{Hz}$ die Stufen d_1 bis d_3, weil dort der Rauschanteil groß ist und die gröberen Stufen die wesentlichen Teile des EKG enthalten [CMG+13, Abschn. 3.1.3]. Wegen $F_{\max} = 250\,\mathrm{Hz}$ wird dort nach (6.1) alles oberhalb von

$$f_S := \frac{250\,\mathrm{Hz}}{2^3} = 31{,}25\,\mathrm{Hz}$$

geschwellt. Da dieselbe Zahl von Stufen bei anderer Abtastrate andere Frequenzen bedeutet, übertragen wir nicht die Zahl der Stufen, sondern diese Grenze (eigene Festlegung): Wir wählen das größte J_S, dessen geschwellte Stufen oberhalb von f_S liegen,

$$\frac{F_{\max}}{2^{J_S}} \geq f_S \iff J_S \leq \log_2\frac{180}{31{,}25} \approx 2{,}53, \qquad \text{also } J_S = 2.$$

Die geschwellten Stufen d_1 und d_2 beginnen damit bei $45\,\mathrm{Hz}$ und liegen insbesondere oberhalb von P- und T-Welle, die bis $20\,\mathrm{Hz}$ reichen [Reb21, Kap. 2.3.1]. Es bleiben $2^{-2} - 2^{-8} = 63/256 \approx 24{,}6\,\%$ der Rauschenergie erhalten. In d_1 und d_2 liegen neben Netzbrummen und Muskelrauschen auch die hochfrequenten Anteile des QRS-Komplexes: Das EKG-Spektrum reicht bis $150\,\mathrm{Hz}$ [Gac12, Kap. 2.4.3.2], und nur P- und T-Welle und die tieffrequenten Anteile des QRS-Komplexes liegen unter $20\,\mathrm{Hz}$ [Reb21, Kap. 2.3.1]. Da das Rauschen gleichmäßig auf alle Detailkoeffizienten verteilt ist, das EKG dagegen durch wenige große Koeffizienten dargestellt wird, entfernt Schwellen das Rauschen und erhält die Spitzen des QRS-Komplexes [CMG+13, Abschn. 2.2.2]; diese Stufen werden deshalb geschwellt statt gelöscht.

6.4.4. Schwelle

Als Schwelle verwenden wir die universelle Schwelle (5.5) mit dem Schätzer (5.7), $T = \hat{\sigma}\sqrt{2\ln N}$, wie Castillo et al. und Alessio [CMG+13, Abschn. 3.1.4, Gl. (10); 3.1.5, Gl. (19), (23)], [Ale16, Kap. 15.2.2, 15.2.3]. Geschätzt wird $\hat{\sigma}$ aus d_1: Bei weißem Rauschen kann man die Standardabweichung aus den Koeffizienten der ersten Stufe schätzen, die bis auf wenige große Werte nur Rauschen enthalten, und für alle Stufen verwenden [CMG+13, Abschn. 3.1.5], [Ale16, Kap. 15.2.2]. Für N zwischen 2^6 und 2^{19} überschreitet reines Rauschen diese Schwelle nur in etwa einem Zehntel der Realisierungen [Ale16, Kap. 15.2.3]. Gerechnet wurde mit PyWavelets [LGW+19] (Code in Anhang B.9).

Zusammenfassung. Mit den gewählten Parametern lautet das Verfahren:

Definition 6.3 (Verfahren zur Entrauschung von EKG-Signalen)**.** Gegeben seien Messwerte $Y \in \mathbb{R}^N$ mit Abtastrate $f_s = 360\,\mathrm{Hz}$, wobei N durch 2^8 teilbar ist. Das entrauschte Signal $\hat{f} \in \mathbb{R}^N$ entsteht in vier Schritten:

1. *Zerlegen:* $AY = (a_8, d_8, \ldots, d_1)$ mit der periodisierten DWT der Tiefe $J = 8$ und dem Wavelet ψ_6 (Abschnitt 6.4.2).
2. *Schwelle bestimmen:* $\hat{\sigma}$ nach (5.7) aus d_1 und $T = \hat{\sigma}\sqrt{2\ln N}$.
3. *Koeffizienten ändern:* a_8 durch 0 ersetzen, d_1 und d_2 mit ρ_T^{S} schwellen ($J_S = 2$), d_3 bis d_8 unverändert lassen.
4. *Rekonstruieren:*
$$\hat{f} = A^\top\big(0,\ d_8, \ldots, d_3,\ \rho_T^{\mathrm{S}}(d_2),\ \rho_T^{\mathrm{S}}(d_1)\big).$$

Das ist das Ein-Schritt-Verfahren aus Definition 6.2 mit $J = 8$, $J_S = 2$ und der universellen Schwelle.

Im Folgenden testen wir das Verfahren zuerst an einem künstlichen EKG, bei dem f bekannt ist (Abschnitt 6.5), und wenden es dann auf die Datensätze 100 und 103 an (Abschnitt 6.6).

6.5. Test an einem künstlichen EKG

Bei echten Aufzeichnungen ist f unbekannt, und ein quantitatives Gütemaß lässt sich nur schwer angeben; Castillo et al. bewerten ihr Verfahren deshalb an künstlichen EKG [CMG+13, Abschn. 4]. Wir gehen ebenso vor.

Als Grundlage dient ein EKG $f_{\mathrm{syn}} \in \mathbb{R}^N$ aus dem dynamischen Modell von McSharry et al. [MCTS03], berechnet mit der Funktion `ecg_simulate` (Methode `ecgsyn`) aus NeuroKit2 [MPL+21] für $f_s = 360\,\mathrm{Hz}$, eine Herzfrequenz von 70 Schlägen pro Minute und $N = 2^{16}$ Abtastwerte, also etwa $3\,\mathrm{min}$. Das Modell enthält von sich aus eine Atmungsdrift [MCTS03, Abschn. IV, Gl. (2)]; diese haben wir abgeschaltet, damit das Test-EKG selbst keine Drift enthält.

Für $x \in \mathbb{R}^N$ sei $\bar{x} = \frac{1}{N}\sum_{n=0}^{N-1} x_n$ der Mittelwert und $\mathbf{1} = (1, \ldots, 1) \in \mathbb{R}^N$, also $\langle x, \mathbf{1}\rangle = N\bar{x}$.

Lemma 6.4. *Jedes $\hat{f}$ nach (6.4) hat den Mittelwert $\bar{\hat{f}} = 0$.*

Beweis. Setzt man $\omega = 0$ in (4.2) ein, so ist $H(0) = 2^{-1/2}\sum_k h_k$, wegen $H(0) = 1$ nach (4.8) also $\sum_k h_k = \sqrt{2}$. Ebenso ist $G(0) = 2^{-1/2}\sum_k g_k$, und nach (4.8) und (4.9) gilt $G(0) = 0$ (Abschnitt 4.3, Aussage (b)), also $\sum_k g_k = 0$. Für einen konstanten Vektor $a_{j-1,n} = c$ liefert (4.11) daher

$$a_{j,k} = c\sum_n h_{n-2k} = \sqrt{2}\,c, \qquad d_{j,k} = c\sum_n g_{n-2k} = 0,$$

bei periodischer Fortsetzung durchläuft $n - 2k$ dabei jeden Index des Filters genau einmal. Eine Stufe bildet einen konstanten Vektor also auf einen konstanten Vektor in der Approximation und auf den Nullvektor in den Details ab. Wiederholt man das J-mal, ist $A\mathbf{1}$ nur im Teil a_J von null verschieden. In (6.4) ist $\hat{f} = A^\top u$, wobei u im Teil a_J null ist. Damit ist

$$N\,\bar{\hat{f}} = \langle \hat{f}, \mathbf{1}\rangle = \langle A^\top u, \mathbf{1}\rangle = \langle u, A\mathbf{1}\rangle = 0. \qquad \square$$

Einen konstanten Versatz kann das Verfahren also nicht wiedergeben; er ist für das EKG ohne Bedeutung, da dessen Größen gegenüber der isoelektrischen Linie gemessen werden (Abschnitt 6.1). Als Test-EKG wählen wir deshalb das mittelwertfreie

$$f := f_{\text{syn}} - \bar{f}_{\text{syn}}\,\mathbf{1}$$

(eigene Festlegung). Wie Castillo et al. verwenden wir eine sinusförmige Drift und Gauß'sches weißes Rauschen, addieren beide aber gemeinsam (vgl. [CMG+13, Abschn. 4]):

$$Y = f + b + \sigma Z, \qquad b(t) = 0{,}5\,\text{mV} \cdot \sin(2\pi \cdot 0{,}25\,\text{Hz} \cdot t),$$

mit $\sigma = 0{,}025\,\text{mV}$; mit diesem Wert bilden McSharry et al. das Messrauschen eines echten EKG nach [MCTS03, Abschn. V]. Dabei ist $Z \in \mathbb{R}^N$ eine feste Realisierung, also ein Vektor mit N standardnormalverteilten Einträgen. Abbildung 6.3 zeigt einen Ausschnitt von $4\,\text{s}$: oben das Test-EKG f, unten die Messung Y. Die Drift b verschiebt Y langsam nach oben und unten und durchläuft im Ausschnitt genau eine Periode ($1/0{,}25\,\text{Hz} = 4\,\text{s}$); das Rauschen σZ macht die Kurve unruhig, die R-Zacken bleiben aber erkennbar.

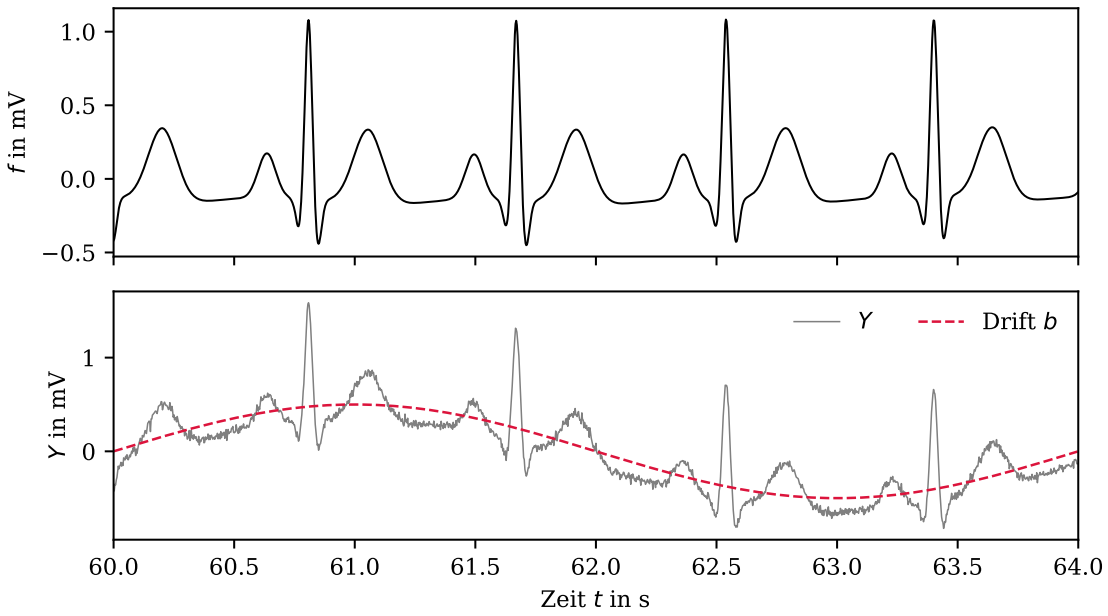


Abbildung 6.3.: Ausschnitt von $4\,\text{s}$ aus dem Test-EKG f (oben) und der gestörten Messung Y mit der Drift b (gestrichelt, unten) mit $\sigma = 0{,}025\,\text{mV}$ (Code in Anhang B.9).

Gütemaß. Als Gütemaß dient die Fehlerenergie $\|\hat{f} - f\|^2$ aus Definition 5.2, wobei $\hat{f}$ das Ergebnis des Verfahrens aus Definition 6.3 für die Messung Y ist. Sie hängt von der Realisierung Z ab, wegen der großen Länge N aber kaum: Für 10 verschiedene Realisierungen weichen alle Werte in Tabelle 6.3 um höchstens $2\,\%$ von denen für unser Z ab, und die Reihenfolge der Varianten bleibt gleich (eigene Rechnung, Listing B.14).

Variante	$\|\hat{f} - f\|^2$
vorher (Messung Y)	8236,4
$J = 8$, $J_S = 2$, Soft (Verfahren)	18,1
Hard statt Soft	18,1
$J_S = 1$	28,2
$J_S = 3$	24,1
nur Drift entfernt ($J_S = 0$)	48,7
$J = 7$	269,4
$J = 9$	521,2

Tabelle 6.3.: Fehlerenergie $\|\hat{f} - f\|^2$ am Test-EKG; zum Vergleich $\|f\|^2 \approx 3823$. In der Zeile „vorher“ ist $\hat{f} = Y$. In jeder Zeile ist nur der genannte Parameter gegenüber dem Verfahren geändert ($J = 8$, $J_S = 2$, Soft, db6, universelle Schwelle). Code in Anhang B.9.

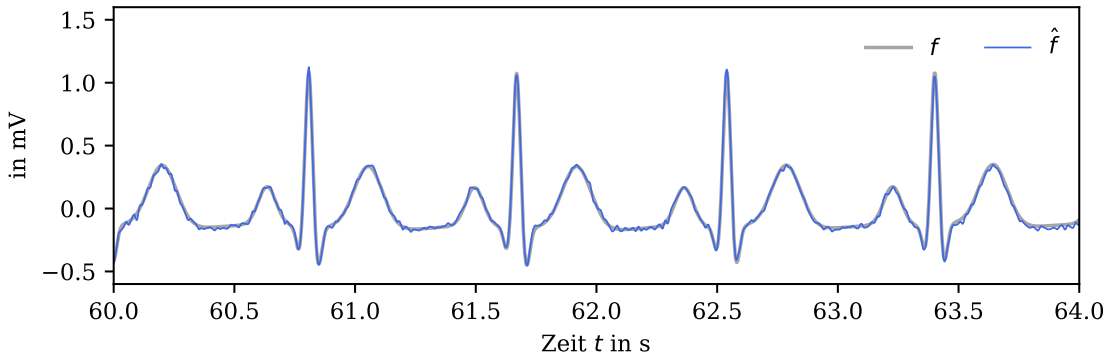


Abbildung 6.4.: Derselbe Ausschnitt von 4 s wie in Abbildung 6.3: f (grau) und $\hat{f}$ (blau). Code in Anhang B.9.

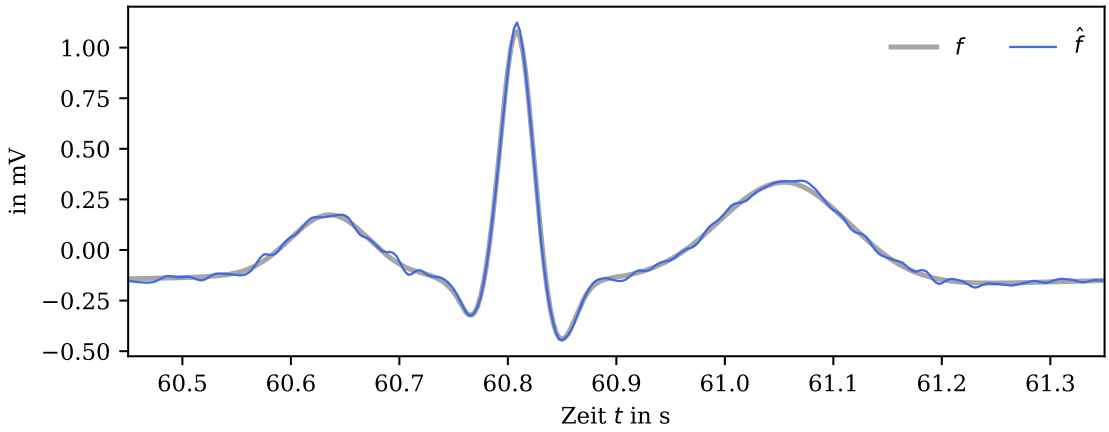


Abbildung 6.5.: Ein Herzschlag aus Abbildung 6.4 vergrößert: f (grau) und $\hat{f}$ (blau). Code in Anhang B.9.

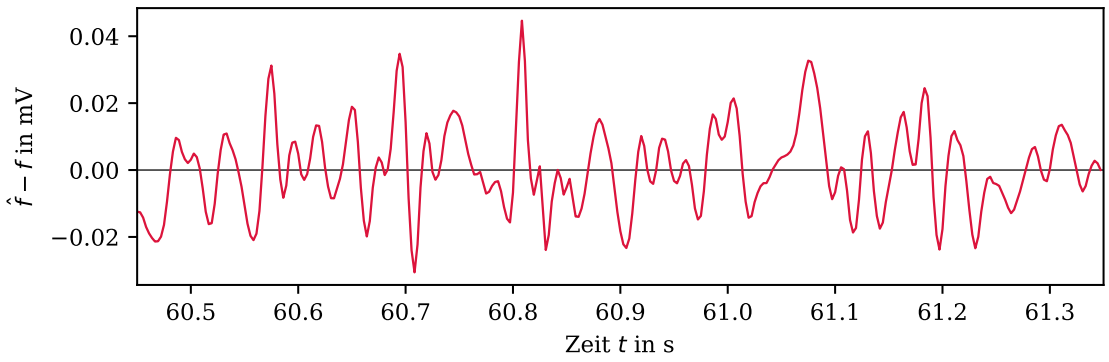


Abbildung 6.6.: Fehler $\hat{f} - f$ für den Herzschlag aus Abbildung 6.5. Code in Anhang B.9.

Ergebnis. Abbildung 6.4 zeigt denselben Ausschnitt wie Abbildung 6.3, nun f und die Schätzung $\hat{f}$: Die Drift ist vollständig entfernt, und $\hat{f}$ folgt f in allen vier Herzschlägen eng. Abbildung 6.5 vergrößert einen Schlag: P-Welle, QRS-Komplex und T-Welle bleiben in Form und Lage erhalten; $\hat{f}$ ist nur leicht unruhiger als f. Abbildung 6.6 zeigt den Fehler $\hat{f} - f$: Er bleibt hier unter $0{,}05\,\mathrm{mV}$ und ist über den ganzen Schlag verteilt. Er besteht vor allem aus dem Rauschen in den unveränderten Stufen d_3 bis d_8, dessen erwartete Energie nach Abschnitt 6.4 $(2^{-2} - 2^{-8})\,\sigma^2 N \approx 0{,}246 \cdot 40{,}96 \approx 10{,}1$ beträgt, also gut die Hälfte von $\|\hat{f} - f\|^2 = 18{,}1$. Fehler, die das Thresholding selbst erzeugt, entstehen dort, wo f große Koeffizienten hat: Jeder geänderte Koeffizient $\langle f, \psi_{j,m} \rangle$ hinterlässt im Fehler ein kurzes Wavelet $\psi_{j,m}$ [Mal09, Kap. 11.3.1]. Auf d_1 und d_2 hat f aber kaum solche Koeffizienten.

Das zeigen die Abbildungen 6.7 bis 6.9 mit den Koeffizienten von f, Y und $\hat{f}$ im selben Ausschnitt; die Energien sind über das ganze Signal gerechnet (eigene Rechnung, Listing B.14):

- In a_8 liegt bei Y die Drift, bei f fast nichts; in $\hat{f}$ ist a_8 null.
- Auf d_1 und d_2 hat f fast keine Energie ($0{,}2$ und $0{,}5$), Y dort also fast nur Rauschen mit erwarteter Energie $\sigma^2 N / 2^j$ ($20{,}5$ und $10{,}2$). Das Thresholding setzt fast alle Koeffizienten auf null und entfernt so das Rauschen.
- Wie Abbildung 6.7 zeigt, hat f auf d_3 noch große Koeffizienten, die zum QRS-Komplex gehören und erhalten bleiben sollen. In Y liegt auf d_3 zusätzlich Rauschen (Abbildung 6.8). Das Verfahren nach Definition 6.3 lässt d_3 unverändert und nimmt damit in Kauf, dass dieses Rauschen in $\hat{f}$ erhalten bleibt (Abbildung 6.9).
- Auch d_4 bis d_8 bleiben unverändert, mit dem kleinen Rauschanteil.

Der Code steht in Listing B.14 (Tabelle 6.3) sowie in den Listings B.16, B.17, B.18 und B.19 (Abbildungen) im Anhang. Aus Tabelle 6.3 folgt:

- $J = 8$ ist deutlich besser als $J = 7$ und $J = 9$; das bestätigt (6.5): Mit $J = 7$ wird ein Teil des EKG gelöscht, mit $J = 9$ bleibt Drift stehen.
- Das Thresholding von d_1 und d_2 senkt die Fehlerenergie gegenüber dem bloßen Entfernen der Drift von $48{,}7$ auf $18{,}1$, also auf gut ein Drittel.

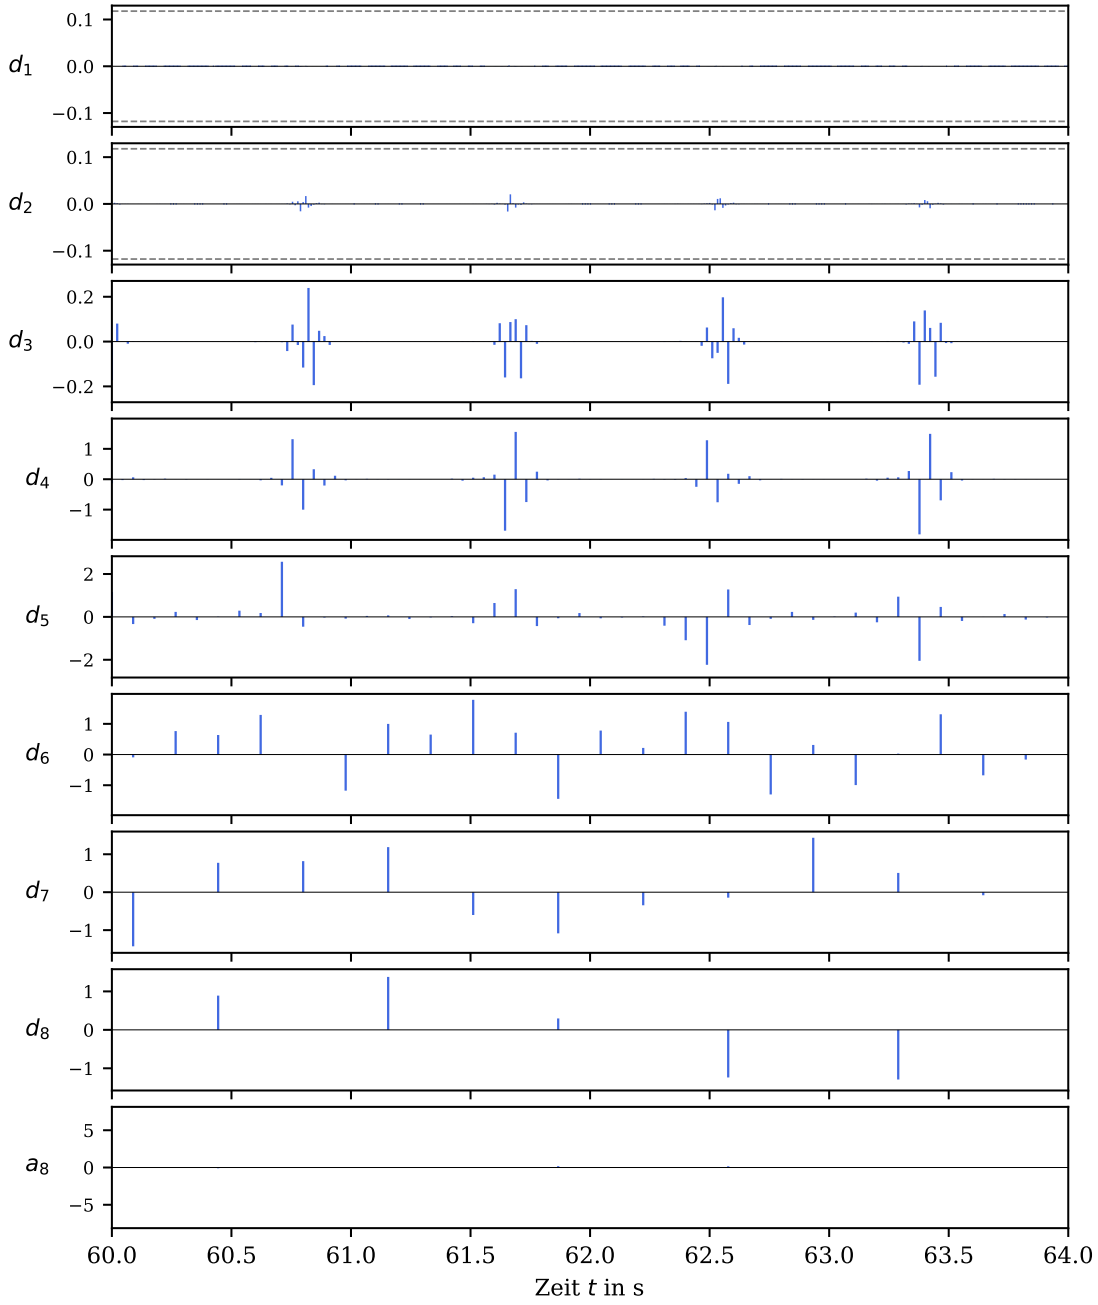


Abbildung 6.7.: Koeffizienten d_1 (oben) bis d_8 und a_8 (unten) von f im Ausschnitt aus Abbildung 6.3; gestrichelt $\pm T$ auf den geschwellten Stufen. Code in Anhang B.9.

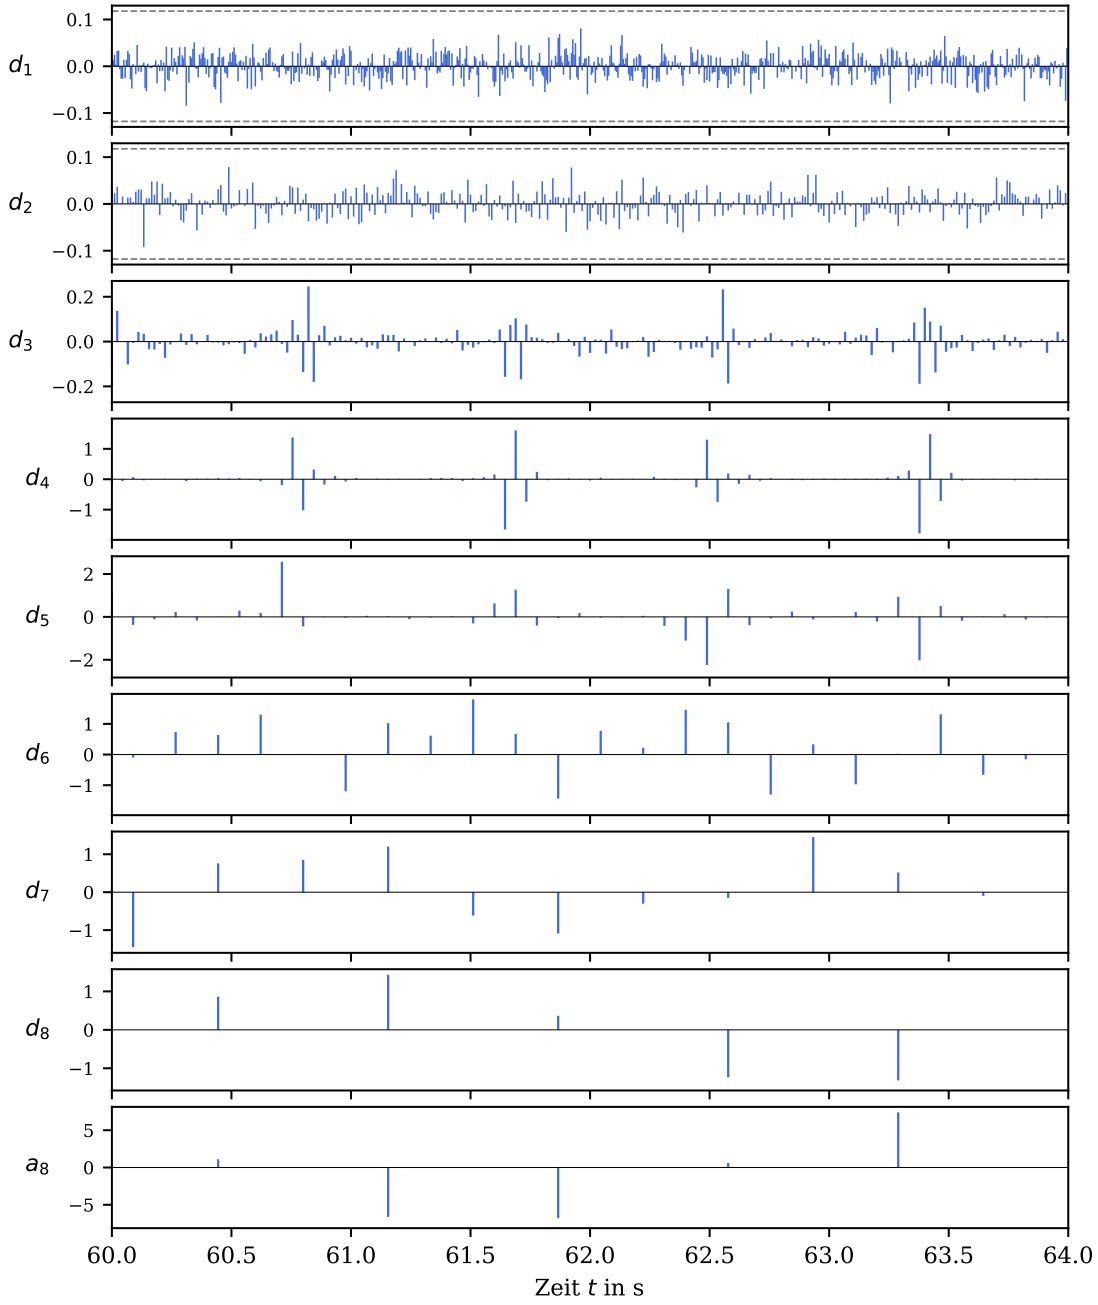


Abbildung 6.8.: Wie Abbildung 6.7, für die Messung Y; Maßstab je Stufe gleich. Code in Anhang B.9.

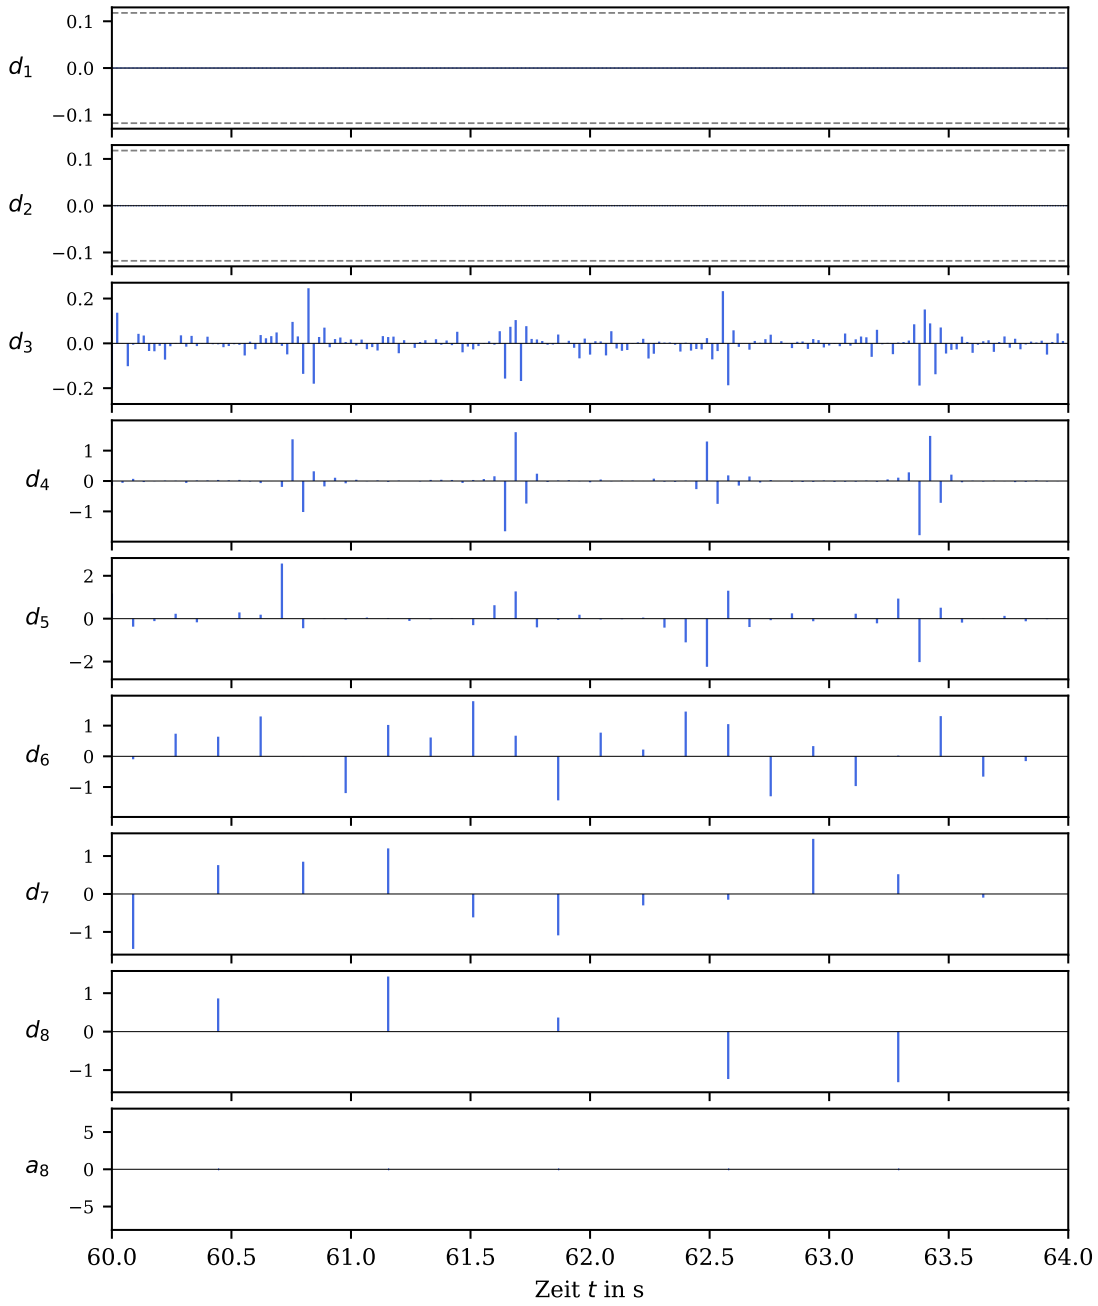


Abbildung 6.9.: Wie Abbildung 6.7, für $\hat{f}$; Maßstab je Stufe gleich. Code in Anhang B.9.

- $J_S = 1$ ist deutlich schlechter, weil das Rauschen auf d_2 stehen bleibt. Auch $J_S = 3$ ist schlechter, weil das Schwellen von d_3 mehr vom EKG entfernt als vom Rauschen: Der Unterschied $24{,}1 - 18{,}1 = 6{,}0$ passt zur Bilanz $11{,}3 - 5{,}1 = 6{,}2$ von oben. Das bestätigt die Wahl $J_S = 2$ aus Abschnitt 6.4.

- Hard- und Soft-Thresholding liefern dieselbe Fehlerenergie $(18{,}1)$. Soft-Thresholding verkleinert zwar auch die großen Koeffizienten um T und braucht deshalb für ähnliche Ergebnisse oft etwa die halbe Schwelle [Mal09, Kap. 11.2.2]; auf d_1 und d_2 hat f aber kaum große Koeffizienten. Wir bleiben wie Castillo et al. bei der universellen Schwelle mit Soft-Thresholding, das keine Unstetigkeiten erzeugt [CMG+13, Abschn. 3.1.6, 4].

6.6. Anwendung auf die Datensätze 100 und 103

Bei den echten Aufzeichnungen ist f unbekannt, ein Fehlermaß wie in Abschnitt 6.5 lässt sich also nicht berechnen. Wir beurteilen das Ergebnis deshalb nur an den Ausschnitten aus Abbildung 6.2.

Abbildung 6.10 zeigt jeweils oben $\hat{f}$ und darunter die Messwerte Y. Bei Datensatz 100 liegt die Grundlinie nach dem Entrauschen gleichmäßig bei null; die Anhebung zwischen 395 und $396\,\mathrm{s}$ ist entfernt, die Form der Schläge bleibt erhalten. Bei Datensatz 103 ist die Drift weitgehend entfernt. Nur der schnelle Abfall bei etwa $1090\,\mathrm{s}$ bleibt als Einbruch sichtbar.

6.7. Diskussion

Am Test-EKG sinkt die Fehlerenergie von $8236{,}4$ auf $18{,}1$, und $J = 8$ ist deutlich besser als $J = 7$ und $J = 9$, wie es (6.5) erwarten lässt (Tabelle 6.3). An den Datensätzen 100 und 103 ist die Drift sichtbar entfernt, die Form der Schläge bleibt erhalten (Abbildung 6.10). Dazu braucht es beide Bausteine: Das Thresholding aus Kapitel 5 erreicht die Drift nicht, denn ihre Energie steckt in den Approximationskoeffizienten a_J, und die lässt das Thresholding unverändert; erst die Wahl von J nach den Frequenzen von Drift und Herzschlag erlaubt, a_J gezielt zu entfernen. Beides geschieht in einer einzigen Zerlegung (Abschnitt 6.4).

Die Ergebnisse haben folgende Grenzen.

- Die Aussage über den Fehler gilt nur für das Test-EKG. Es enthält nur eine Sinusdrift und weißes Rauschen, kein Netzbrummen und kein Muskelrauschen. Die echten Aufzeichnungen beurteilen wir nur nach Augenschein. Ob die Änderungen am EKG klinisch unbedenklich sind, müsste ärztlich beurteilt werden; ohne klinische Erfahrung kann ein Verfahren unzulässige Verzerrungen einführen [SL05, Kap. 1.4.1].

- Das Nullsetzen von a_8 entfernt alles unter $0{,}70\,\mathrm{Hz}$, auch langsame Anteile des EKG: Dessen Spektrum reicht nach unten bis $0{,}005\,\mathrm{Hz}$ [Gac12, Kap. 2.4.3.2], bei den MIT-BIH-Daten, die auf $0{,}1$ bis $100\,\mathrm{Hz}$ bandbegrenzt sind, bis $0{,}1\,\mathrm{Hz}$ (Abschnitt 6.2). Bei langsamem Herzschlag unter 42 Schlägen pro Minute läge die Herzfrequenz selbst unter $0{,}70\,\mathrm{Hz}$; Sörnmo und Laguna nennen für Bradykardie etwa 40 Schläge pro Minute [SL05, Kap. 7.1]. Dann wäre $J = 9$ zu wählen, mit mehr verbleibender Drift.

- Elektrodenbewegung liegt bei 1 bis $10\,\mathrm{Hz}$ und damit in den unveränderten Stufen; das Verfahren kann sie nicht entfernen. Ob der Abfall bei $1090\,\mathrm{s}$ in Datensatz 103 von einer

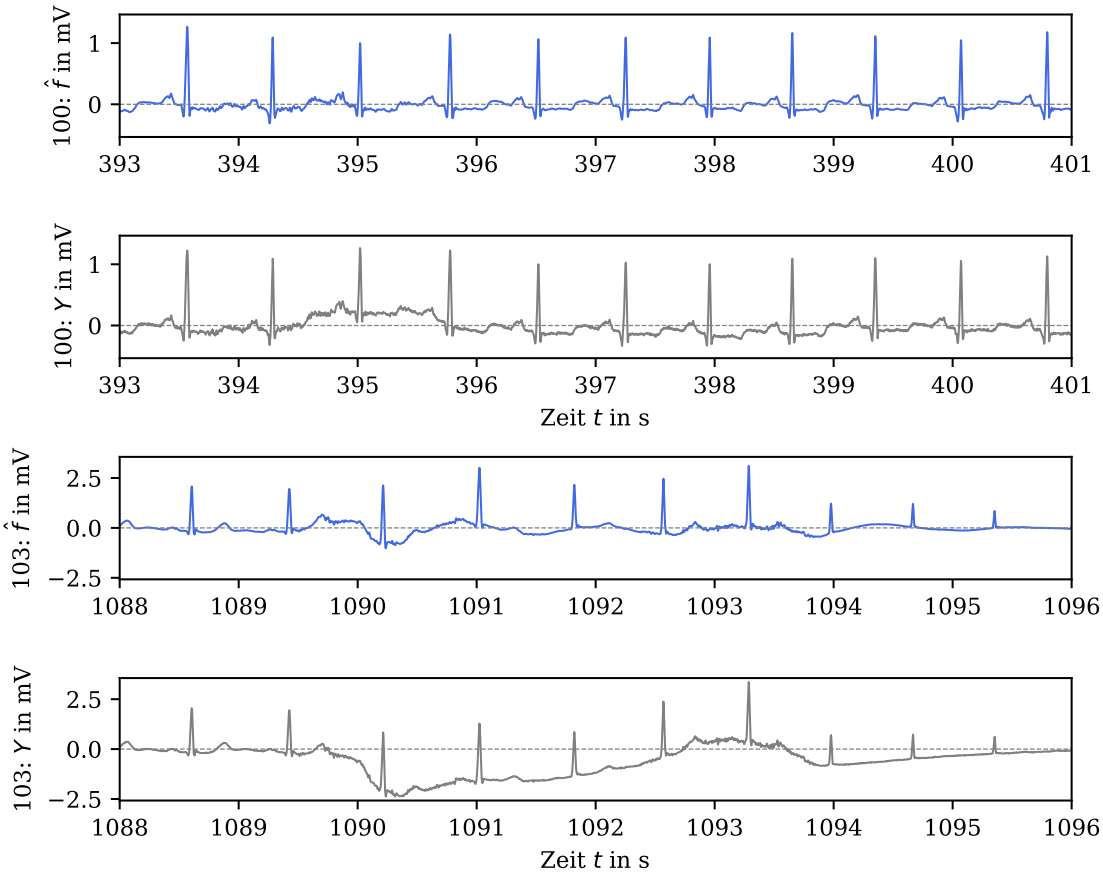


Abbildung 6.10.: Die Ausschnitte aus Abbildung 6.2 nach dem Entrauschen ($\hat{f}$, blau) und darunter vorher (Y, grau), je Datensatz im selben Maßstab; gestrichelt die Nulllinie (Code in Anhang B.9).

Elektrodenbewegung stammt, lässt sich aus den Daten nicht sagen; das Directory markiert den Abschnitt nur als verrauscht. Er bleibt als Einbruch sichtbar.

- Die Schwelle beruht auf einem einzigen $\hat{\sigma}$ aus d_1 und setzt weißes Rauschen voraus. Für Rauschen, das nicht weiß ist, schätzt man σ auf jeder Stufe einzeln [Ale16, Kap. 15.2.2], [CMG+13, Abschn. 3.1.5]. Muskelrauschen liegt bei 20 bis 80 Hz (Tabelle 6.1), also vor allem in d_2 und d_3. Auf d_3 bleibt es unverändert stehen, und auf d_2 ist die aus d_1 geschätzte Schwelle womöglich zu klein; das Muskelrauschen wird also nur unvollständig entfernt.

- $J_S = 2$ beruht auf der von Castillo et al. übertragenen Grenze $f_S = 31{,}25$ Hz (Abschnitt 6.4) und bestätigt sich am Test-EKG. Welches J_S am besten ist, hängt aber vom Verhältnis von EKG und Rauschen auf d_3 ab: Bei $\sigma = 0{,}01$ und $0{,}05$ mV ist ebenfalls $J_S = 2$ besser ($9{,}7$ statt $11{,}7$ und $48{,}2$ statt $52{,}0$), bei $\sigma = 0{,}1$ mV dagegen $J_S = 3$ ($116{,}1$ statt $168{,}1$; eigene Rechnung, Listing B.14). Bei den Datensätzen 100 und 103 ist $\hat{\sigma} \approx 0{,}006$ mV (Listing B.13), das weiße Rauschen also schwächer als im Test; für dieses spricht das ebenfalls für $J_S = 2$.

- Die Datenbank wurde für die Bewertung von Arrhythmie-Detektoren angelegt [MM01], nicht für das Entrauschen; eine Datenbank für Fragen zu nutzen, für die sie nicht gedacht war, ist ein bekanntes Risiko [SL05, Kap. 1.4.1]. Zudem verwenden wir nur zwei Aufzeichnungen. Die Parameter sind allerdings aus der Literatur übernommen und nicht an diesen Daten angepasst.

Simulierte Signale, bei denen das wahre Signal bekannt ist, erlauben eine Genauigkeitsaussage wie in Abschnitt 6.5; den Hauptteil der Bewertung müssen aber gemessene Aufzeichnungen tragen [SL05, Kap. 1.4.2].

7. Fazit und Ausblick

Anmerkung. Zusammenfassung des Argumentationsbogens und Ausblick auf translationsinvariantes Thresholding, adaptive Schwellen und konkurrierende Zerlegungen.

Belegstellen.

- Mallat, „Translation-Invariant Thresholding", S. 632–633 [bestätigt]; S. 639 [bestätigt]
- Mallat, „Multiscale Sure Thresholds", S. 637 [bestätigt]
- LMR, Kap. 2.4.5 „Biorthogonale Wavelets", S. 184–190 [bestätigt]; Kap. 2.4.7.3 „Coiflets", S. 209 [bestätigt] — naheliegende Erweiterungen der Basiswahl
- LMR, Vorwort zur zweiten Auflage, S. 1 [bestätigt] — Multiwavelets und das Lifting-Prinzip als weiterführende Richtungen
- Rebstadt, Kap. 6.2, S. 76–77 [bestätigt]
- Chatterjee, Kap. 5, S. 585–587 [bestätigt]

A. Ergänzende Rechnungen

A.1. Zulässigkeitskonstante des Haar-Wavelets

Wir berechnen $C_{\psi^{\mathrm{H}}}$ aus (3.2). Für $\omega \neq 0$ ist $\sin(\omega/4)\,\mathrm{sinc}(\omega/4) = 4\sin^2(\omega/4)/\omega$, also

$$\left|\widehat{\psi^{\mathrm{H}}}(\omega)\right|^2 = \frac{16\sin^4(\omega/4)}{2\pi\,\omega^2}.$$

Dieser Ausdruck ist gerade in ω. Mit der Substitution $u = \omega/4$ folgt

$$C_{\psi^{\mathrm{H}}} = 2\pi \cdot 2\int_0^\infty \frac{16\sin^4(\omega/4)}{2\pi\,\omega^3}\,d\omega = 32\int_0^\infty \frac{\sin^4(\omega/4)}{\omega^3}\,d\omega = 2\int_0^\infty \frac{\sin^4 u}{u^3}\,du.$$

Zur Auswertung schreiben wir $8\sin^4 u = g(u)$ mit $g(u) := 3 - 4\cos(2u) + \cos(4u)$. Die Taylorentwicklung liefert $g(u) = 8u^4 + O(u^6)$ für $u \to 0$. Zweimalige partielle Integration ist daher ohne Randterme möglich und ergibt

$$\int_0^\infty \frac{g(u)}{u^3}\,du = \frac{1}{2}\int_0^\infty \frac{g''(u)}{u}\,du = 8\int_0^\infty \frac{\cos(2u) - \cos(4u)}{u}\,du = 8\ln 2.$$

Im letzten Schritt wurde das Frullani-Integral $\int_0^\infty \big(\cos(\alpha u) - \cos(\beta u)\big)/u\,du = \ln(\beta/\alpha)$ für $\alpha, \beta > 0$ verwendet. Also ist $\int_0^\infty \sin^4(u)/u^3\,du = \ln 2$ und $C_{\psi^{\mathrm{H}}} = 2\ln 2$, in Übereinstimmung mit [LMR98, Kap. 1.1, Beispiel (1)].

A.2. Fourier-Transformierte des Testsignals

Wir berechnen $\hat{f}$ für das Testsignal aus Beispiel 3.7. Wegen $f \in L^1(\mathbb{R})$ ist $\hat{f}$ punktweise durch das Integral gegeben. In der Konvention aus Bemerkung 2.2 ist

$$\hat{f}(\omega) = \frac{1}{\sqrt{2\pi}}\left(\int_0^3 \big(1 - \cos(2\pi t)\big)e^{-i\omega t}\,dt + \frac{1}{2}\int_4^5 \big(1 - \cos(10\pi t)\big)e^{-i\omega t}\,dt\right).$$

Sei zunächst $\omega \notin \{0, \pm 2\pi, \pm 10\pi\}$. Benutzt werden nur $\cos x = \frac{1}{2}\big(e^{ix} + e^{-ix}\big)$ und

$$\int_\alpha^\beta e^{ct}\,dt = \frac{1}{c}\big(e^{c\beta} - e^{c\alpha}\big), \qquad c \in \mathbb{C}\setminus\{0\}. \tag{A.1}$$

Die langsame Komponente. Mit $q_1 := 1 - e^{-3i\omega}$ zerlegen wir

$$\int_0^3 \big(1 - \cos(2\pi t)\big)e^{-i\omega t}\,dt = \underbrace{\int_0^3 e^{-i\omega t}\,dt}_{=:A_1} - \underbrace{\int_0^3 \cos(2\pi t)\,e^{-i\omega t}\,dt}_{=:B_1}.$$

Nach (A.1) mit $c = -i\omega$ ist $A_1 = q_1/(i\omega)$. Für B_1 schreiben wir $\cos(2\pi t)e^{-i\omega t} = \frac{1}{2}\big(e^{i(2\pi-\omega)t} + e^{-i(2\pi+\omega)t}\big)$. Nach (A.1) ist

$$B_1 = \frac{e^{3i(2\pi-\omega)} - 1}{2i(2\pi-\omega)} + \frac{e^{-3i(2\pi+\omega)} - 1}{-2i(2\pi+\omega)}.$$

Auf $[0,3]$ liegen genau drei volle Perioden. Daher ist $e^{\pm 6\pi i} = 1$ und $e^{3i(2\pi-\omega)} = e^{-3i(2\pi+\omega)} = e^{-3i\omega}$. Beide Zähler werden zu $-q_1$, und es folgt

$$B_1 = \frac{q_1}{2i}\left(\frac{1}{2\pi+\omega} - \frac{1}{2\pi-\omega}\right) = \frac{q_1\,\omega}{i\,(\omega^2 - 4\pi^2)}.$$

Mit $1/i = -i$ ergibt sich

$$A_1 - B_1 = \frac{q_1}{i}\left(\frac{1}{\omega} - \frac{\omega}{\omega^2 - 4\pi^2}\right) = \frac{i\,4\pi^2\,q_1}{\omega\,(\omega^2 - 4\pi^2)}.$$

Die schnelle Komponente. Mit $q_2 := e^{-4i\omega} - e^{-5i\omega}$ verläuft die Rechnung gleich, mit 10π statt 2π und den Grenzen 4 und 5. An die Stelle von $e^{\pm 6\pi i} = 1$ treten $e^{\pm 40\pi i} = e^{\pm 50\pi i} = 1$. Mit dem Amplitudenfaktor $\frac{1}{2}$ erhält man

$$\frac{1}{2}\left(\int_4^5 e^{-i\omega t}\,dt - \int_4^5 \cos(10\pi t)\,e^{-i\omega t}\,dt\right) = \frac{i\,50\pi^2\,q_2}{\omega\,(\omega^2 - 100\pi^2)}.$$

Ergebnis. Addition beider Anteile und der Vorfaktor $(2\pi)^{-1/2}$ ergeben

$$\hat f(\omega) = \frac{i}{\sqrt{2\pi}\,\omega}\left[\frac{4\pi^2\big(1 - e^{-3i\omega}\big)}{\omega^2 - 4\pi^2} + \frac{50\pi^2\big(e^{-4i\omega} - e^{-5i\omega}\big)}{\omega^2 - 100\pi^2}\right]. \tag{A.2}$$

Da $\hat f$ als Fourier-Transformierte einer L^1-Funktion stetig ist [Ser17, Satz 12.1], gilt (A.2) an den Stellen $\omega \in \{0, \pm 2\pi, \pm 10\pi\}$ im Sinne des Grenzwerts. Direkt aus dem Integral folgen

$$|\hat f(0)| = \frac{7}{2\sqrt{2\pi}}, \qquad |\hat f(\pm 2\pi)| = \frac{3}{2\sqrt{2\pi}}, \qquad |\hat f(\pm 10\pi)| = \frac{1}{4\sqrt{2\pi}}.$$

Zur Kontrolle wurde (A.2) an mehreren Stellen mit numerischer Quadratur des Integrals verglichen (Anhang B.1).

A.3. Stammfunktion des Testsignals

Für die Stammfunktion $F(t) := \int_{-\infty}^{t} f(s)\,ds$ des Testsignals gilt

$$F(t) = \begin{cases} 0, & t < 0, \\ t - \dfrac{\sin(2\pi t)}{2\pi}, & 0 \le t \le 3, \\ 3, & 3 \le t \le 4, \\ 3 + \dfrac{t-4}{2} - \dfrac{\sin(10\pi t)}{20\pi}, & 4 \le t \le 5, \\ \dfrac{7}{2}, & t > 5. \end{cases}$$

Auf $[0,3]$ folgt das durch direkte Integration. Wegen $\sin(6\pi) = 0$ ist $F(3) = 3$. Auf $[3,4]$ verschwindet f. Auf $[4,5]$ ist

$$F(t) = 3 + \frac{1}{2}\int_4^t \big(1 - \cos(10\pi s)\big)ds = 3 + \frac{t-4}{2} - \frac{\sin(10\pi t)}{20\pi},$$

da $\sin(40\pi) = 0$ ist. Wegen $\sin(50\pi) = 0$ ist $F(5) = \frac{7}{2} = \int_{\mathbb{R}} f$. Das passt zu $\hat{f}(0) = (2\pi)^{-1/2} \cdot \frac{7}{2}$.

B. Python-Code

Alle Abbildungen und numerischen Werte dieser Arbeit wurden mit Python (NumPy, PyWavelets [LGW+19], Matplotlib) erzeugt.

Anmerkung. Versionen angeben (`python -version`, `pip show numpy matplotlib pywavelets`).

Die Skripte zu Kapitel 5 verwenden durchgehend den Filter (4.6), die periodisierte Transformation (Abschnitt 5.1) mit $J = 5$ Stufen und $N = 2048$ Abtastwerte. Der feste Startwert 93 des Zufallsgenerators sorgt dafür, dass alle Abbildungen dieses Kapitels dieselbe Realisierung des Rauschens zeigen.

B.1. Beispiel zur kontinuierlichen Wavelet-Transformation

Der folgende Code erzeugt die Abbildungen 3.4, 3.5 und 3.6. Die Wavelet-Transformierte wird nicht durch numerische Quadratur, sondern exakt nach (3.5) aus der Stammfunktion F berechnet.

Listing B.1: Testsignal aus Beispiel 3.7

```
# Beispiel aus Abschnitt 3.1.2: Signal, Fourier-Transformierte und Haar-CWT.
import numpy as np
import matplotlib.pyplot as plt

pi = np.pi


def f(t):
    y = np.zeros_like(t)
    m = (t >= 0) & (t <= 3)
    y[m] += 1 - np.cos(2 * pi * t[m])
    m = (t >= 4) & (t <= 5)
    y[m] += 0.5 * (1 - np.cos(10 * pi * t[m]))
    return y


def F(t):
    y = np.zeros_like(t)
    m = (t > 0) & (t < 3)
    y[m] += t[m] - np.sin(2 * pi * t[m]) / (2 * pi)
    y[t >= 3] += 3
    m = (t > 4) & (t < 5)
    y[m] += 0.5 * ((t[m] - 4) - np.sin(10 * pi * t[m]) / (10 * pi))
    y[t >= 5] += 0.5
    return y


```

```
def fourier(w):
    w = w.astype(complex)
    for p in [0, 2 * pi, -2 * pi, 10 * pi, -10 * pi]:
        w = np.where(np.abs(w - p) < 1e-7, p + 1e-7, w)
    a = 4 * pi**2 * (1 - np.exp(-3j * w)) / (w**2 - 4 * pi**2)
    b = 50 * pi**2 * (np.exp(-4j * w) - np.exp(-5j * w)) / (w**2 - 100 * pi
        **2)
    return 1j * (a + b) / (np.sqrt(2 * pi) * w)


def cwt_haar(a, b):
    return (2 * F(b + a / 2) - F(b) - F(b + a)) / np.sqrt(a)


plt.rcParams.update({"font.size": 9, "font.family": "serif", "savefig.dpi":
    300})

t = np.linspace(-0.6, 5.6, 40000)
fig, ax = plt.subplots(figsize=(7.0, 2.8))
ax.plot(t, f(t), color="royalblue", lw=0.9)
for x in [0, 3, 4, 5]:
    ax.axvline(x, color="gray", lw=0.6, alpha=0.3)
ax.set_xlim(-0.6, 5.6)
ax.set_ylim(-0.25, 2.45)
ax.set_xticks(range(6))
ax.set_xlabel("$t$")
ax.set_ylabel("$f(t)$")
ax.annotate("$f_1$", (1.5, 2.18), ha="center")
ax.annotate("$f_2$", (4.5, 1.22), ha="center")
ax.spines[["top", "right"]].set_visible(False)

w = np.linspace(-50, 50, 40000)
fig, ax = plt.subplots(figsize=(7.0, 2.8))
ax.plot(w, np.abs(fourier(w)), color="royalblue", lw=0.9)
for p in [-10 * pi, -2 * pi, 0, 2 * pi, 10 * pi]:
    ax.axvline(p, color="gray", ls="--", lw=0.6)
ax.set_xlim(-50, 50)
ax.set_ylim(0, 1.55)
ax.set_xticks([-10 * pi, -2 * pi, 0, 2 * pi, 10 * pi])
ax.set_xticklabels([r"$-10\pi$", r"$-2\pi$", "$0$", r"$2\pi$", r"$10\pi$"])
ax.set_xlabel(r"$\omega$")
ax.set_ylabel(r"$|\hat f(\omega)|$")
ax.spines[["top", "right"]].set_visible(False)

a = np.logspace(np.log10(0.02), np.log10(3.0), 900)[:, None]
b = np.linspace(-0.6, 5.6, 1400)[None, :]
fig, ax = plt.subplots(figsize=(9.0, 4.6))
pc = ax.pcolormesh(b.ravel(), a.ravel(), np.abs(cwt_haar(a, b)), shading="
    gouraud", cmap="magma")
ax.set_yscale("log")
ax.set_xticks(range(6))
ax.set_xlabel("$b$")
ax.set_ylabel("$a$")
fig.colorbar(pc, ax=ax).set_label(r"$|W_\psi f(a,b)|$")

```

```
80 plt.show()
```

B.2. Daubechies-Wavelet

Der folgende Code erzeugt Abbildung 4.3. PyWavelets berechnet φ_2 und ψ_2 durch Iteration der Skalierungsgleichung (4.1) und legt ψ_2 auf $[0, 3]$. Die Verschiebung um 1 ergibt den Träger $[-1, 2]$, der nach Satz 4.16 zur Wahl (4.7) gehört.

Listing B.2: Skalierungsfunktion φ_2 und Wavelet ψ_2 aus Satz 4.16

```
# Daubechies-Skalierungsfunktion phi_2 und Wavelet psi_2 aus Kapitel 4.
import pywt
import matplotlib.pyplot as plt

phi, psi, t = pywt.Wavelet("db2").wavefun(level=10)

plt.rcParams.update({"font.size": 11, "axes.titlesize": 11, "mathtext.
    fontset": "cm"})
fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.6))

ax[0].plot(t, phi, color="royalblue", lw=0.9)
ax[0].set_title(r"(a) $\varphi_2$")
ax[1].plot(t - 1, psi, color="royalblue", lw=0.9)
ax[1].set_title(r"(b) $\psi_2$")

for a in ax:
    a.axhline(0, color="black", lw=0.5)
    a.set_xlabel("$t$")
    a.spines[["top", "right"]].set_visible(False)

plt.show()
```

B.3. Daubechies-Wavelet mit zwölf Koeffizienten

Der folgende Code erzeugt Abbildung 4.4. Wie in Anhang B.2 legt PyWavelets ψ_6 auf $[0, 11]$; die Verschiebung um 5 ergibt den Träger $[-5, 6]$ aus Satz 4.16.

Listing B.3: Skalierungsfunktion φ_6 und Wavelet ψ_6 aus Beispiel 4.17

```
# Abbildung 4.x: Skalierungsfunktion und Wavelet des Daubechies-Wavelets mit
    p = 6
import matplotlib.pyplot as plt
import pywt

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
p = 6
phi, psi, x = pywt.Wavelet(f"db{p}").wavefun(level=10)
fig, ax = plt.subplots(1, 2, figsize=(6.3, 2.2), sharey=True)
ax[0].plot(x, phi, color="royalblue", lw=1.0)
ax[1].plot(x + 1 - p, psi, color="royalblue", lw=1.0)
ax[0].set_title(r"(a) $\varphi_6$")
```

```
ax[1].set_title(r"(b) $\psi_6$")
ax[0].set_xlim(0, 2 * p - 1)
ax[1].set_xlim(1 - p, p)
for achse in ax:
    achse.axhline(0, color="gray", lw=0.5, ls="--")
    achse.set_xlabel("$t$")
fig.tight_layout()
fig.savefig("../abbildungen/abb4_db6.pdf")
plt.show()
```

B.4. Verrauschter Sinus

Der folgende Code erzeugt Abbildung 5.2 und die Zahlen aus Beispiel 5.5: die Fehlerenergie $\|Y - u\|^2$, ihren Erwartungswert $N\sigma^2$ sowie empirischen Mittelwert und empirische Varianz von $\tilde{Z} = AZ$. Als Kontrolle von Lemma 5.3 gibt das Skript zusätzlich $\|AZ\| - \|Z\|$ aus; der Wert verschwindet im Rahmen der Rundungsgenauigkeit.

Listing B.4: Verrauschter Sinus aus Beispiel 5.5

```
# Beispiel aus Kapitel 5: verrauschter Sinus, Fehlerenergie und Statistik
    der Rauschkoeffizienten (Abb. 5.2).
import numpy as np
import pywt
import matplotlib.pyplot as plt

N = 2048
J = 5
sigma = 0.3

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)

Z = np.random.default_rng(93).standard_normal(N)
Y = u + sigma * Z

Z_tilde = np.concatenate(pywt.wavedec(Z, "db2", mode="periodization", level=
    J))

print(f"||Y - u||^2 = {np.sum((Y - u) ** 2):.1f}")
print(f"N sigma^2 = {N * sigma**2:.1f}")
print(f"Mittelwert Z_tilde = {np.mean(Z_tilde):.2f}")
print(f"Varianz Z_tilde = {np.var(Z_tilde):.2f}")
print(f"||AZ|| - ||Z|| = {np.linalg.norm(Z_tilde) - np.linalg.norm(Z):.1e}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(2, 1, figsize=(7.0, 3.6), sharex=True)

ax[0].plot(t, u, color="royalblue", lw=0.9)
ax[0].set_ylabel("$u$")
ax[1].plot(t, Y, color="gray", lw=0.5)
ax[1].set_ylabel("$Y$")
ax[1].set_xlabel("$t$")
ax[1].set_xlim(0, 8)
```

```
33
34 for a in ax:
35     a.set_ylim(-2.2, 2.2)
36     a.spines[["top", "right"]].set_visible(False)
37
38 plt.show()
```

B.5. Sinus mit Spitzen

Der folgende Code erzeugt Abbildung 5.5 und die Zahlen aus Beispiel 5.11: für jede Stufe die Anzahl der Koeffizienten, den größten Betrag beim Sinus und die Anzahl der Koeffizienten von u und f mit Betrag mindestens σ, außerdem M, die Summe $\sum_{|\theta_m|<\sigma} \theta_m^2$ der gelöschten Koeffizienten und das Risiko r_{id} der idealen Auswahl (5.4).

Listing B.5: Sinus mit Spitzen aus Beispiel 5.11

```
1  # Beispiel aus Kapitel 5: Sinus mit drei Spitzen, Koeffizienten pro Stufe
       und Risiko der idealen Auswahl (Abb. 5.5).
2  import numpy as np
3  import pywt
4  import matplotlib.pyplot as plt
5
6  N = 2048
7  J = 5
8  sigma = 0.3
9  zentren = [1.3, 3.7, 6.2]
10
11 t = 8 * np.arange(N) / N
12 u = np.sin(2 * np.pi * t)
13
14 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
15 f = u + s
16
17 Z = np.random.default_rng(93).standard_normal(N)
18 Y = f + sigma * Z
19
20 cu = pywt.wavedec(u, "db2", mode="periodization", level=J)
21 cf = pywt.wavedec(f, "db2", mode="periodization", level=J)
22
23 namen = ["a5", "d5", "d4", "d3", "d2", "d1"]
24 print("Stufe  Anzahl  max|u|   >=sigma(u)  >=sigma(f)")
25 for name, a, b in zip(namen, cu, cf):
26     print(f"{name:5}  {len(a):6}  {np.max(np.abs(a)):.2g}  {np.sum(np.abs(a)
           >= sigma):10}  {np.sum(np.abs(b) >= sigma):10}")
27
28 for name, c in [("u", cu), ("f", cf)]:
29     theta = np.concatenate(c)
30     M = np.sum(np.abs(theta) >= sigma)
31     geloescht = np.sum(theta[np.abs(theta) < sigma] ** 2)
32     r = np.sum(np.minimum(theta**2, sigma**2))
33     print(f"{name}: M = {M}, M sigma^2 = {M * sigma**2:.1f}, geloescht = {
           geloescht:.1f}, r_id = {r:.1f}")
34
```

```
print(f"N sigma^2 = {N * sigma**2:.1f}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(2, 1, figsize=(7.0, 3.6), sharex=True)

ax[0].plot(t, f, color="royalblue", lw=0.9)
ax[0].set_ylabel("$f$")
ax[1].plot(t, Y, color="gray", lw=0.5)
ax[1].set_ylabel("$Y$")
ax[1].set_xlabel("$t$")
ax[1].set_xlim(0, 8)

for a in ax:
    a.set_ylim(-2.2, 4.0)
    a.spines[["top", "right"]].set_visible(False)

plt.show()
```

B.6. Detailkoeffizienten des Testsignals

Der folgende Code erzeugt Abbildung 5.6. Der k-te Koeffizient der Stufe j wird in der Mitte des Zeitabschnitts $\left[k\,2^j/256,\ (k+1)\,2^j/256\right)$ eingezeichnet, für den er steht. Beträge über $2{,}5$ werden abgeschnitten.

Listing B.6: Detailkoeffizienten des Testsignals aus Beispiel 5.11

```
# Beispiel aus Kapitel 5: Detailkoeffizienten d_5 bis d_1 des Testsignals f
    (Abb. 5.6).
import numpy as np
import pywt
import matplotlib.pyplot as plt

N = 2048
J = 5
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)

s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
f = u + s

c = pywt.wavedec(f, "db2", mode="periodization", level=J)

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(J, 1, figsize=(7.0, 6.0), sharex=True)

for i in range(J):
    j = J - i
    d = c[i + 1]
    pos = (np.arange(len(d)) + 0.5) * 2**j / 256
    ax[i].vlines(pos, 0, np.clip(d, -2.5, 2.5), color="royalblue", lw=1.1)
    ax[i].axhline(0, color="black", lw=0.4)
```

```
    ax[i].set_ylim(-2.5, 2.5)
    ax[i].set_yticks([-2, 0, 2])
    ax[i].set_ylabel(f"$d_{j}$", rotation=0, labelpad=12, va="center")
    ax[i].spines[["top", "right"]].set_visible(False)

ax[-1].set_xlim(0, 8)
ax[-1].set_xlabel("$t$")
fig.tight_layout(h_pad=0.3)

plt.show()
```

B.7. Detailkoeffizienten der Messwerte

Der folgende Code erzeugt Abbildung 5.7 und die Zahlen aus dem ersten Absatz von Beispiel 5.13: den Schätzwert $\hat{\sigma}$ nach (5.7), die Schwelle T, den größten Rauschkoeffizienten $\max_m |0{,}3\,\tilde{Z}_m|$ und die Anzahl der Koeffizienten, die Hard-Thresholding behält.

Listing B.7: Detailkoeffizienten der Messwerte aus Beispiel 5.13

```
# Beispiel aus Kapitel 5: Detailkoeffizienten d_5 bis d_1 der Messwerte Y
    mit Schwelle T (Abb. 5.7).
import numpy as np
import pywt
import matplotlib.pyplot as plt

N = 2048
J = 5
sigma = 0.3
zentren = [1.3, 3.7, 6.2]

t = 8 * np.arange(N) / N
u = np.sin(2 * np.pi * t)

s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
f = u + s

Z = np.random.default_rng(93).standard_normal(N)
Y = f + sigma * Z

c = pywt.wavedec(Y, "db2", mode="periodization", level=J)

sigma_dach = np.median(np.abs(c[-1])) / 0.6745
T = sigma_dach * np.sqrt(2 * np.log(N))
AZ = np.concatenate(pywt.wavedec(Z, "db2", mode="periodization", level=J))

print(f"sigma_dach = {sigma_dach:.3f}")
print(f"T = {T:.2f}")
print(f"max|AZ| = {np.max(np.abs(AZ)):.2f}, max|sigma AZ| = {sigma * np.max(
    np.abs(AZ)):.2f}")
print(f"behalten (hart): {np.sum(np.abs(np.concatenate(c)) > T)} von {N}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(J, 1, figsize=(7.0, 6.0), sharex=True)
```

```
33
34 for i in range(J):
35     j = J - i
36     d = c[i + 1]
37     pos = (np.arange(len(d)) + 0.5) * 2**j / 256
38     ax[i].vlines(pos, 0, np.clip(d, -2.5, 2.5), color="royalblue", lw=1.0)
39     ax[i].axhline(0, color="black", lw=0.4)
40     ax[i].axhline(T, color="gray", ls="--", lw=0.8)
41     ax[i].axhline(-T, color="gray", ls="--", lw=0.8)
42     ax[i].set_ylim(-2.5, 2.5)
43     ax[i].set_yticks([-2, 0, 2])
44     ax[i].set_ylabel(f"$d_{j}$", rotation=0, labelpad=12, va="center")
45     ax[i].spines[["top", "right"]].set_visible(False)
46
47 ax[-1].set_xlim(0, 8)
48 ax[-1].set_xlabel("$t$")
49 fig.tight_layout(h_pad=0.3)
50
51 plt.show()
```

B.8. Entrauschtes Testsignal

Der folgende Code erzeugt Abbildung 5.8 und die Fehlerenergien aus Beispiel 5.13. Wie in Algorithmus 2 werden alle Koeffizienten mit der Schwelle T bearbeitet, einschließlich der Approximation a_5.

Listing B.8: Entrauschen des Testsignals aus Beispiel 5.13

```
1  # Beispiel aus Kapitel 5: Entrauschen des Testsignals mit Hard- und Soft-
       Thresholding (Abb. 5.8).
2  import numpy as np
3  import pywt
4  import matplotlib.pyplot as plt
5
6  N = 2048
7  J = 5
8  sigma = 0.3
9  zentren = [1.3, 3.7, 6.2]
10
11 t = 8 * np.arange(N) / N
12 u = np.sin(2 * np.pi * t)
13
14 s = sum(3 * np.maximum(0, 1 - np.abs(t - c) / 0.03) for c in zentren)
15 f = u + s
16
17 Z = np.random.default_rng(93).standard_normal(N)
18 Y = f + sigma * Z
19
20 c = pywt.wavedec(Y, "db2", mode="periodization", level=J)
21 sigma_dach = np.median(np.abs(c[-1])) / 0.6745
22 T = sigma_dach * np.sqrt(2 * np.log(N))
23
```

```
hart = pywt.waverec([pywt.threshold(d, T, "hard") for d in c], "db2", mode="
    periodization")
weich = pywt.waverec([pywt.threshold(d, T, "soft") for d in c], "db2", mode=
    "periodization")

print(f"||Y - f||^2 = {np.sum((Y - f) ** 2):.1f}")
print(f"hart:  ||f_hart - f||^2 = {np.sum((hart - f) ** 2):.1f}")
print(f"weich: ||f_weich - f||^2 = {np.sum((weich - f) ** 2):.1f}")

plt.rcParams.update({"font.size": 11, "mathtext.fontset": "cm"})
fig, ax = plt.subplots(1, 2, figsize=(7.0, 2.8), sharey=True, gridspec_kw={"
    width_ratios": [2.2, 1]})

ax[0].plot(t, hart, color="royalblue", lw=0.9, label="hart")
ax[0].plot(t, weich, color="red", lw=0.7, label="weich")
ax[0].set_xlim(0, 8)
ax[0].set_ylim(-2.2, 4.0)
ax[0].set_xlabel("$t$")

aus = (t > 3.45) & (t < 3.95)
ax[1].plot(t[aus], f[aus], color="black", ls=":", lw=0.9, label="$f$")
ax[1].plot(t[aus], hart[aus], color="royalblue", lw=0.9, label="hart")
ax[1].plot(t[aus], weich[aus], color="red", lw=0.7, label="weich")
ax[1].set_xlabel("$t$ (Ausschnitt)")
ax[1].legend(frameon=False, loc="upper right")

for a in ax:
    a.spines[["top", "right"]].set_visible(False)

fig.tight_layout()

plt.show()
```

B.9. Anwendung auf EKG-Signale

Die Skripte zu Kapitel 6 lesen die Datensätze 100 und 103 der MIT-BIH Arrhythmia Database mit dem Paket `wfdb` aus dem Ordner `daten/mitdb`. `kap6_verfahren.py` enthält das Verfahren aus Abschnitt 6.4, `kap6_test.py` den Test aus Abschnitt 6.5.

Listing B.9: Verfahren

```
# Gemeinsame Funktionen für Kapitel 6: Entrauschen nach Castillo et al.
import numpy as np
import pywt

fs = 360
N = 2 ** 19
wavelet = "db6"
J = 8
JS = 2


def entrauschen(y, modus="soft", a_null=True, J=J, JS=JS):
```

```
    c = pywt.wavedec(y, wavelet, mode="periodization", level=J)
    sigma = np.median(np.abs(c[-1])) / 0.6745
    T = sigma * np.sqrt(2 * np.log(len(y)))
    neu = [np.zeros_like(c[0]) if a_null else c[0]]
    for i, d in enumerate(c[1:]):
        if J - i <= JS:
            neu.append(pywt.threshold(d, T, modus))
        else:
            neu.append(d)
    return pywt.waverec(neu, wavelet, mode="periodization")
```

Listing B.10: Abbildung 6.1

```
# Abbildung 6.1: schematischer Herzschlag mit P-, Q-, R-, S- und T-Welle
import numpy as np
import matplotlib.pyplot as plt

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
t = np.linspace(0, 750, 2000)
wellen = {"P": (0.15, 130, 22), "Q": (-0.12, 275, 8), "R": (1.2, 300, 9),
          "S": (-0.25, 322, 9), "T": (0.3, 600, 45)}
schlag = sum(a * np.exp(-((t - m) / s) ** 2 / 2) for a, m, s in wellen.
    values())
fig, ax = plt.subplots(figsize=(6.3, 2.6))
ax.axhline(0, color="gray", lw=0.6, ls="--")
ax.plot(t, schlag, color="royalblue", lw=1.2)
for name, (a, m, s) in wellen.items():
    i = np.argmin(np.abs(t - m))
    ax.annotate(name, (t[i], schlag[i]), textcoords="offset points",
                xytext=(0, 6 if schlag[i] > 0 else -12), ha="center")
ax.set_xlabel("Zeit $t$ in ms")
ax.set_ylabel("Spannung in mV")
ax.set_xlim(t[0], t[-1])
ax.set_ylim(-0.4, 1.45)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_1_muster.pdf")
plt.show()
```

Listing B.11: Abbildung 6.2

```
# Abbildung 6.2: je ein Ausschnitt von 8 s aus den Datensätzen 100 und 103 (
    MLII)
import numpy as np
import matplotlib.pyplot as plt
import wfdb
from kap6_verfahren import fs, N

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
ausschnitte = {"100": 393, "103": 1088}
dauer = 8
verrauscht = (1089.8, 1098.4)
fig, ax = plt.subplots(2, 1, figsize=(6.3, 3.6))
for achse, (name, von) in zip(ax, ausschnitte.items()):
    x = wfdb.rdrecord("../daten/mitdb/" + name).p_signal[:N, 0]
    y = x - np.mean(x)
```

```
    t = np.arange(N) / fs
    m = (t >= von) & (t <= von + dauer)
    if name == "103":
        achse.axvspan(verrauscht[0], von + dauer, color="gray", alpha=0.15,
            lw=0)
    achse.plot(t[m], y[m], color="royalblue", lw=0.8)
    achse.set_xlim(von, von + dauer)
    achse.set_ylabel(f"Datensatz {name}\nin mV")
ax[1].set_xlabel("Zeit $t$ in s")
fig.tight_layout()
fig.savefig("../abbildungen/abb6_2_datensaetze.pdf")
plt.show()
```

Listing B.12: Annotationen: Herzfrequenz (Abschnitt 6.4.2) und verrauschter Abschnitt (Abschnitt 6.2)

```
# Abschnitt 6.2 und 6.4.2: Auswertung der Annotationen der Datensätze 100
    und 103
# (Herzfrequenz aus den Schlagmarkierungen, verrauschte Abschnitte aus der
    Signalqualität)
import numpy as np
import wfdb
from kap6_verfahren import fs, N

schlaege = "NLRAaJSVFejE/fQ"   # Annotationssymbole, die einen Herzschlag
    markieren
for name in ["100", "103"]:
    ann = wfdb.rdann("../daten/mitdb/" + name, "atr")
    r = np.array([p for p, z in zip(ann.sample, ann.symbol) if z in schlaege
        and p < N])
    rr = np.diff(r) / fs    # Abstände aufeinanderfolgender Schläge in s
    print(f"{name}: Mittel {60 / np.mean(rr):.1f}/min, langsamster Schlag
        {60 / np.max(rr):.1f}/min")
    # Signalqualität: Symbol "~", Subtyp 0 = beide sauber, 1 = oberes, 2 =
        unteres Signal verrauscht
    for p, z, s in zip(ann.sample, ann.symbol, ann.subtype):
        if z == "~" and p < N:
            print(f"  ab {p / fs:7.1f} s: Signalqualität {s}")
```

Listing B.13: Abbildung 6.10; Schätzer $\hat{\sigma}$ der Datensätze

```
# Abbildung 6.10: 8-s-Ausschnitte aus den Datensätzen 100 und 103 (MLII)
    nach und vor dem Entrauschen
import numpy as np
import matplotlib.pyplot as plt
import wfdb
import pywt
from kap6_verfahren import entrauschen, fs, N

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
ausschnitte = {"100": 393, "103": 1088}
dauer = 8
fig, ax = plt.subplots(4, 1, figsize=(6.3, 5.0))
for k, (name, von) in enumerate(ausschnitte.items()):
    x = wfdb.rdrecord("../daten/mitdb/" + name).p_signal[:N, 0]
```

```
    y = x - np.mean(x)
    f = entrauschen(y)
    d1 = pywt.wavedec(y, "db6", mode="periodization", level=1)[1]
    print(f"{name}: sigma_hat = {np.median(np.abs(d1)) / 0.6745:.4f} mV")
        # Schätzer wie im Verfahren
    t = np.arange(N) / fs
    m = (t >= von) & (t <= von + dauer)
    unten, oben = min(y[m].min(), f[m].min()) - 0.2, max(y[m].max(), f[m].
        max()) + 0.2
    ax[2 * k].plot(t[m], f[m], color="royalblue", lw=0.8)
    ax[2 * k].set_ylabel(f"{name}: $\\hat f$ in mV")
    ax[2 * k + 1].plot(t[m], y[m], color="gray", lw=0.8)
    ax[2 * k + 1].set_ylabel(f"{name}: $Y$ in mV")
    for achse in ax[2 * k:2 * k + 2]:
        achse.set_xlim(von, von + dauer)
        achse.set_ylim(unten, oben)
        achse.axhline(0, color="gray", lw=0.5, ls="--")
    ax[2 * k + 1].set_xlabel("Zeit $t$ in s")
fig.tight_layout()
fig.savefig("../abbildungen/abb6_10_vergleich.pdf")
plt.show()
```

Listing B.14: Test an einem künstlichen EKG: Tabelle 6.3, Energien je Stufe, Kontrolle über 10 Realisierungen und Rauschpegel

```
# Abschnitt 6.5: Test an einem künstlichen EKG (ECGSYN über NeuroKit2),
    Tabelle tab:test
import math
import sys
import numpy as np
import neurokit2 as nk
import pywt
from kap6_verfahren import fs, entrauschen

N_TEST = 2 ** 16
DRIFT = (0.5, 0.25)          # Amplitude in mV, Frequenz in Hz
SIGMA = 0.025                # Standardabweichung des Rauschens in mV (
    McSharry et al., Abschn. V)
SEED = 0                     # feste Realisierung von Z für Tabelle und
    Abbildungen
KONTROLLE = 10               # Realisierungen für die Kontrolle der
    Schwankung


def _ableitung_ohne_drift(t, x, rr, ti, sfint, ai, bi):
    # wie neurokit2 (_ecg_simulate_derivsecgsyn), aber ohne die eingebaute
        Atmungsdrift zbase
    ta = math.atan2(x[1], x[0])
    a0 = 1.0 - np.sqrt(x[0] ** 2 + x[1] ** 2)
    ip = np.floor(t * sfint).astype(int)
    w0 = 2 * np.pi / rr[min(ip, len(rr) - 1)]
    dti = (ta - ti) - np.round((ta - ti) / 2 / np.pi) * 2 * np.pi
    return np.array([a0 * x[0] - w0 * x[1], a0 * x[1] + w0 * x[0],
                     -np.sum(ai * dti * np.exp(-0.5 * (dti / bi) ** 2)) - x
                         [2]])
```

```
25
26
27  def testsignal(n=N_TEST, seed=42):
28      sys.modules["neurokit2.ecg.ecg_simulate"]._ecg_simulate_derivsecgsyn =
            _ableitung_ohne_drift
29      f = nk.ecg_simulate(duration=n / fs + 2, sampling_rate=fs, heart_rate
            =70,
30                          noise=0, method="ecgsyn", random_state=seed)
31      f = np.asarray(f[:n])
32      return f - np.mean(f)    # Test-EKG mittelwertfrei (eigene Festlegung)
33
34
35  def fehlerenergie(f, g):
36      # Fehlerenergie ||g - f||^2 (Definition 5.2)
37      return np.sum((g - f) ** 2)
38
39
40  def gestoert(f, seed):
41      t = np.arange(len(f)) / fs
42      b = DRIFT[0] * np.sin(2 * np.pi * DRIFT[1] * t)
43      return f + b + SIGMA * np.random.default_rng(seed).standard_normal(len(f
            ))
44
45
46  varianten = [("J = 8, J_S = 2, Soft", dict()),
47               ("Hard", dict(modus="hard")),
48               ("J_S = 1", dict(JS=1)),
49               ("J_S = 3", dict(JS=3)),
50               ("nur Drift (J_S = 0)", dict(JS=0)),
51               ("J = 7", dict(J=7)),
52               ("J = 9", dict(J=9))]
53
54  if __name__ == "__main__":
55      f = testsignal()
56      y = gestoert(f, SEED)
57      print(f"||f||^2 = {np.sum(f ** 2):.0f}")
58      print(f"  {'vorher (Messung Y)':22s} {fehlerenergie(f, y):8.1f}")
59      for name, arg in varianten:
60          print(f"  {name:22s} {fehlerenergie(f, entrauschen(y, **arg)):8.1f}"
                )
61      # Energie von f und erwartete Rauschenergie sigma^2 N / 2^j auf d_1 bis
            d_4
62      c = pywt.wavedec(f, "db6", mode="periodization", level=8)[::-1]
63      cy = pywt.wavedec(y, "db6", mode="periodization", level=8)
64      T = np.median(np.abs(cy[-1])) / 0.6745 * np.sqrt(2 * np.log(len(y)))   #
             Schwelle wie im Verfahren
65      print(f"T = {T:.3f}")
66      print("Energie je Stufe (f, sigma^2 N/2^j, Verlust sum min(|f|,T)^2 beim
             Schwellen):")
67      for j in range(1, 5):
68          print(f"  d_{j}: {np.sum(c[j - 1] ** 2):7.1f} {SIGMA ** 2 * len(f) /
                2 ** j:7.1f}"
69                f" {np.sum(np.minimum(np.abs(c[j - 1]), T) ** 2):7.1f}")
70      # Kontrolle: Schwankung der Fehlerenergie über KONTROLLE Realisierungen
71      print("Kontrolle (min, max, max. relative Abweichung von Seed 0):")
```

```
    for name, arg in [("vorher (Messung Y)", None)] + varianten:
        e = [fehlerenergie(f, gestoert(f, s) if arg is None else entrauschen
            (gestoert(f, s), **arg))
             for s in range(KONTROLLE)]
        print(f"  {name:22s} {min(e):8.1f} {max(e):8.1f} {max(abs(x - e[0])
            for x in e) / e[0]:6.1%}")
    # Abhängigkeit vom Rauschpegel: J_S = 2 gegen J_S = 3 bei derselben
        Realisierung Z
    print("Rauschpegel (sigma in mV: J_S = 2, J_S = 3):")
    t = np.arange(len(f)) / fs
    b = DRIFT[0] * np.sin(2 * np.pi * DRIFT[1] * t)
    z = np.random.default_rng(SEED).standard_normal(len(f))
    for s in [0.01, 0.025, 0.05, 0.1]:
        y_s = f + b + s * z
        print(f"  {s:5.3f}: " + "  ".join(f"{fehlerenergie(f, entrauschen(
            y_s, JS=js)):7.1f}" for js in (2, 3)))
```

Listing B.15: Abbildung 6.3

```
# Abbildung 6.3: Ausschnitt von 4 s aus dem Test-EKG f und der gestörten
    Messung Y (sigma = 0,025 mV)
import numpy as np
import matplotlib.pyplot as plt
from kap6_verfahren import fs
from kap6_test import testsignal, gestoert, DRIFT, SEED

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
f = testsignal()
y = gestoert(f, SEED)
t = np.arange(len(f)) / fs
b = DRIFT[0] * np.sin(2 * np.pi * DRIFT[1] * t)
m = (t >= 60) & (t < 64)
fig, ax = plt.subplots(2, 1, figsize=(6.3, 3.6), sharex=True)
ax[0].plot(t[m], f[m], color="black", lw=0.8)
ax[0].set_ylabel("$f$ in mV")
ax[1].plot(t[m], y[m], color="gray", lw=0.6, label="$Y$")
ax[1].plot(t[m], b[m], color="crimson", lw=1.0, ls="--", label="Drift $b$")
ax[1].legend(loc="upper right", frameon=False, ncol=2)
ax[1].set_ylabel("$Y$ in mV")
ax[1].set_xlabel("Zeit $t$ in s")
ax[1].set_xlim(60, 64)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_3_testsignal.pdf")
plt.show()
```

Listing B.16: Abbildung 6.4

```
# Abbildung 6.4: Ausschnitt von 4 s aus dem Test-EKG f und dem Ergebnis
    f_hat (sigma = 0,025 mV)
import numpy as np
import matplotlib.pyplot as plt
from kap6_verfahren import fs, entrauschen
from kap6_test import testsignal, gestoert, SEED

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
```

```
f = testsignal()
fh = entrauschen(gestoert(f, SEED))
t = np.arange(len(f)) / fs
m = (t >= 60) & (t < 64)
fig, ax = plt.subplots(figsize=(6.3, 2.2))
ax.plot(t[m], f[m], color="black", lw=1.4, alpha=0.35, label="$f$")
ax.plot(t[m], fh[m], color="royalblue", lw=0.7, label=r"$\hat f$")
ax.set_ylabel("in mV")
ax.set_xlabel("Zeit $t$ in s")
ax.legend(loc="upper right", frameon=False, ncol=2)
ax.set_xlim(60, 64)
ax.set_ylim(-0.6, 1.6)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_4_test.pdf")
plt.show()
```

Listing B.17: Abbildung 6.5

```
# Abbildung 6.5: ein Herzschlag aus Abbildung 6.4 vergrößert, Test-EKG f und
    Ergebnis f_hat
import numpy as np
import matplotlib.pyplot as plt
from kap6_verfahren import fs, entrauschen
from kap6_test import testsignal, gestoert, SEED

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
f = testsignal()
fh = entrauschen(gestoert(f, SEED))
t = np.arange(len(f)) / fs
m = (t >= 60.45) & (t < 61.35)
fig, ax = plt.subplots(figsize=(6.3, 2.6))
ax.plot(t[m], f[m], color="black", lw=2.0, alpha=0.35, label="$f$")
ax.plot(t[m], fh[m], color="royalblue", lw=0.9, label=r"$\hat f$")
ax.set_ylabel("in mV")
ax.set_xlabel("Zeit $t$ in s")
ax.legend(loc="upper right", frameon=False, ncol=2)
ax.set_xlim(60.45, 61.35)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_5_test_schlag.pdf")
plt.show()
```

Listing B.18: Abbildung 6.6

```
# Abbildung 6.6: Fehler f_hat - f für denselben Herzschlag wie in Abbildung
    6.5 (Realisierung Z^(1), Seed 0)
import numpy as np
import matplotlib.pyplot as plt
from kap6_verfahren import fs, entrauschen
from kap6_test import testsignal, gestoert, SEED

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
f = testsignal()
fh = entrauschen(gestoert(f, SEED))
t = np.arange(len(f)) / fs
m = (t >= 60.45) & (t < 61.35)
```

```
fig, ax = plt.subplots(figsize=(6.3, 2.2))
ax.axhline(0, color="black", lw=0.5)
ax.plot(t[m], (fh - f)[m], color="crimson", lw=0.9)
ax.set_ylabel(r"$\hat f - f$ in mV")
ax.set_xlabel("Zeit $t$ in s")
ax.set_xlim(60.45, 61.35)
fig.tight_layout()
fig.savefig("../abbildungen/abb6_6_test_fehler.pdf")
plt.show()
```

Listing B.19: Abbildungen 6.7 bis 6.9

```
# Abbildungen 6.7 bis 6.9: DWT-Zerlegung (d_1 bis d_8, a_8) von f, Y und f_hat im Ausschnitt 60-64 s
import numpy as np
import matplotlib.pyplot as plt
import pywt
from kap6_verfahren import fs, wavelet, J, JS, entrauschen
from kap6_test import testsignal, gestoert, SEED

plt.rcParams.update({"font.size": 9, "font.family": "serif"})
f = testsignal()
y = gestoert(f, SEED)
fh = entrauschen(y)

def zerlegung(x):
    # pywt liefert [a_J, d_J, ..., d_1]; umsortiert zu [d_1, ..., d_J, a_J]
    c = pywt.wavedec(x, wavelet, mode="periodization", level=J)
    return c[:0:-1] + [c[0]]

namen = [f"$d_{{{j}}}$" for j in range(1, J + 1)] + [f"$a_{{{J}}}$"]
stufen = list(range(1, J + 1)) + [J]                    # Skala 2^j jeder Zeile
Z = {"f": zerlegung(f), "Y": zerlegung(y), "fhat": zerlegung(fh)}
sigma = np.median(np.abs(Z["Y"][0])) / 0.6745
T = sigma * np.sqrt(2 * np.log(len(y)))                 # universelle Schwelle wie im Verfahren
t0, t1 = 60, 64

def ausschnitt(c, j):
    t = np.arange(len(c)) * 2 ** j / fs                 # Koeffizient k gehört ungefähr zur Zeit k 2^j / f_s
    m = (t >= t0) & (t < t1)
    return t[m], c[m]

# gleicher Maßstab je Zeile in allen drei Zerlegungen
grenze = [1.1 * max([np.max(np.abs(ausschnitt(Z[s][i], stufen[i])[1])) for s in Z]
                    + ([T] if i < JS else []))   # Schwelle T auf d_1 bis d_JS sichtbar
          for i in range(J + 1)]

for s in Z:
    fig, ax = plt.subplots(J + 1, 1, figsize=(6.3, 7.4), sharex=True)
    for i in range(J + 1):
```

```
        t, c = ausschnitt(Z[s][i], stufen[i])
        ax[i].vlines(t, 0, c, color="royalblue", lw=0.6 if i < 2 else 0.9)
        ax[i].axhline(0, color="black", lw=0.4)
        if i < JS:
            ax[i].axhline(T, color="gray", lw=0.7, ls="--")
            ax[i].axhline(-T, color="gray", lw=0.7, ls="--")
        ax[i].set_ylim(-grenze[i], grenze[i])
        ax[i].set_ylabel(namen[i], rotation=0, labelpad=12, va="center")
        ax[i].tick_params(axis="y", labelsize=7)
    ax[-1].set_xlim(t0, t1)
    ax[-1].set_xlabel("Zeit $t$ in s")
    fig.tight_layout(h_pad=0.2)
    fig.savefig(f"../abbildungen/abb6_7_zerlegung_{s}.pdf")
print(f"T = {T:.3f}")
plt.show()
```

Literaturverzeichnis

[AJB17] Mounaim Aqil, Atman Jbari, and Abdennasser Bourouhou. ECG signal denoising by discrete wavelet transform. *International Journal of Online Engineering (iJOE)*, 13(9):51–68, 2017.

[Ale16] Silvia Maria Alessio. *Digital Signal Processing and Spectral Analysis for Scientists. Concepts and Applications*. Signals and Communication Technology. Springer, Cham, 2016.

[BK19] Steven L. Brunton and J. Nathan Kutz. *Fourier and Wavelet Transforms*, pages 47–83. Cambridge University Press, Cambridge, 2019.

[Bla03] Christian Blatter. *Wavelets – Eine Einführung*. Advanced Lectures in Mathematics. Vieweg, Braunschweig/Wiesbaden, 2., durchgesehene edition, 2003.

[CMG+13] Encarnación Castillo, Diego P. Morales, Antonio García, Francisco Martínez-Martí, Luis Parrilla, and Alberto J. Palma. Noise suppression in ECG signals through efficient one-step wavelet processing techniques. *Journal of Applied Mathematics*, 2013:763903, 2013.

[CTY+20] Shubhojeet Chatterjee, Rini Smita Thakur, Ram Narayan Yadav, Lalita Gupta, and Deepak Kumar Raghuvanshi. Review of noise removal techniques in ECG signals. *IET Signal Processing*, 14(9):569–590, 2020.

[Gac12] Adam Gacek. An introduction to ECG signal processing and analysis. In Adam Gacek and Witold Pedrycz, editors, *ECG Signal Processing, Classification and Interpretation*, pages 21–46. Springer, London, 2012.

[HB09] Martin Hanke-Bourgeois. *Grundlagen der Numerischen Mathematik und des Wissenschaftlichen Rechnens*. Vieweg+Teubner, Wiesbaden, 3., aktualisierte edition, 2009.

[KS20] Pramendra Kumar and Vijay Kumar Sharma. Detection and classification of ECG noises using decomposition on mixed codebook for quality analysis. *Healthcare Technology Letters*, 7(1):18–24, 2020.

[LGW+19] Gregory R. Lee, Ralf Gommers, Filip Waselewski, Kai Wohlfahrt, and Aaron O'Leary. PyWavelets: A Python package for wavelet analysis. *Journal of Open Source Software*, 4(36):1237, 2019.

[LMR98] Alfred Karl Louis, Peter Maaß, and Andreas Rieder. *Wavelets: Theorie und Anwendungen*. Teubner-Studienbücher: Mathematik. B. G. Teubner, Stuttgart, 2., überarbeitete und erweiterte edition, 1998.

[Mal09] Stéphane Mallat. *A Wavelet Tour of Signal Processing: The Sparse Way*. Academic Press / Elsevier, Burlington, MA, 3. edition, 2009.

[MCTS03] Patrick E. McSharry, Gari D. Clifford, Lionel Tarassenko, and Leonard A. Smith. A dynamical model for generating synthetic electrocardiogram signals. *IEEE Transactions on Biomedical Engineering*, 50(3):289–294, 2003.

[MM97] George B. Moody and Roger G. Mark. MIT-BIH arrhythmia database directory. https://archive.physionet.org/physiobank/database/html/mitdbdir/mitdbdir.htm, 1997. HTML-Ausgabe vom 24.05.1997, Einleitung überarbeitet am 24.06.2010; abgerufen am 09.10.2026.

[MM01] George B. Moody and Roger G. Mark. The impact of the MIT-BIH arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3):45–50, 2001.

[MM05] George B. Moody and Roger G. Mark. MIT-BIH arrhythmia database, version 1.0.0. PhysioNet, https://physionet.org/content/mitdb/1.0.0/, 2005. Abgerufen am 19.10.2026.

[MPL+21] Dominique Makowski, Tam Pham, Zen J. Lau, Jan C. Brammer, François Lespinasse, Hung Pham, Christopher Schölzel, and S. H. Annabel Chen. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods*, 53(4):1689–1696, 2021.

[PML+26] Tom Pollard, Benjamin E. Moody, Li-wei Lehman, Brian Gow, Chrystinne Fernandes, Chenxi Xie, Alistair Johnson, Roger G. Mark, and Thomas Heldt. PhysioNet as a global platform for biomedical research. *Nature Health*, 1(8):792–795, 2026.

[Reb21] Linda Rebstadt. Spark-basierte analyse von monitoring-daten intensiv überwachter patienten zur identifikation von anomalien: Ein use case der charité health data platform. Masterarbeit, Hochschule Darmstadt, 2021.

[Ser17] Valery Serov. *Fourier Series, Fourier Transform and Their Applications to Mathematical Physics*, volume 197 of *Applied Mathematical Sciences*. Springer, Cham, 2017.

[SL05] Leif Sörnmo and Pablo Laguna. *Bioelectrical Signal Processing in Cardiac and Neurological Applications*. Elsevier Academic Press, Burlington, 2005.

[SS03] Elias M. Stein and Rami Shakarchi. *Fourier Analysis: An Introduction*, volume I of *Princeton Lectures in Analysis*. Princeton University Press, Princeton, 2003.